

这个磨皮磨开的真大。

这个必须的，你知道必须得给你鼓鼓劲儿捧捧场。因为今天人稍微少一点，这是我真的我自从迈克以来可能直播间人数最少的时候，但是我觉得也是个好事儿，大家可以沟通和交流的更充分一些。童主任是咱们就准备开始吗？小明你现在有PPT什么的吗？你该投投，然后我还是像以前我先铺一下，好，OK我铺一下，然后你来分享。我们人少的话，我觉得可以沟通的交流的更充分一些。那个人少的话，大家可以在屏幕上多打打字。

然后我先来说几个事儿，第一个我再说一遍，这个课跟股市一点关系都没有。来打个招呼，打招呼就这么几个人了，打个招呼，别大家都睡着了，我都不知道在不在。这个课跟股市一点关系都没有。这个课主要是盯住整个人工智能的前沿，盯住人工智能的新的技术应用。我原来跟大家讲过，就是因为出发点就是过去这么长时间我们给这个服务下来之后，真的说实话传统行业了解人工智能的，了解这些东西的人太少。我们觉得第一这里面有极大的机会就是缺人才。第二个同时我们也着急，就是我们想做很多的服务接不上茬，我觉得这里面也是对整个传统行业非常有利的一件事，我先强调几点，第一个这个课就比较难，小平老师就不用我再介绍了，我估计能买课的都是老朋友了。清华大学创新生态，质朴，不是清华智浦创新生态的负责人，因为他那个部门的具体名字我老记不住。这些东西就是难，我给自己提的要求是3到6个月能跟上，这是第一个。

第二个，我想这个课咱们更务实一些，除了上课大家听之外，我们计划组织一下线下的活动。每一次人少一点，六七个、七八个人，尽量来自于同一个方向和行业。在北京，我正在找地方，有可能我给你们找一个智库的，或者直接去清华智谱也可以。然后比如说都是政府机构的，甚至都是比如说市一级、省一级的，或者都是县一级下这一级的，然后都是某一类企业的，都是有共同问题的一波人物凑到一块，一个是正在有这个计划，有这个计划，大家也可以给我们反馈，包括你们可以跟客服联系，或者在填表的时候写的更详细一些。解一方面咱们之间可以互相沟通，另外一方面我觉得就是同行之间可以互相启发。有些事儿可能你想到了别人没想到，也有别人想到你没想到的，甚至我觉得都没想到，大家互相一碰撞就有了的可能。计划开展这样的活动好吧？

然后这种话课咱们的这个课我就强调一点，大家要有足够的耐心，要足够的耐心。小明今天讲完了之后，因为人不多，我觉得可以讨论的更充分一点，好吧？然后剩下时间交给小平，小明辛苦。

OK好好，大家好，就算我们这个正儿正儿八经的开始从头开始讲第一节课，然后今天我会讲起这个名字叫从scape聊起，全站看AI。第一个估计大家这个词儿就不是很知道到底这什么玩意儿。没关系，大家看一下后面的这个东西，大家就能感觉到了。然后全栈其实可能大家也有些不是些不是工程出身的，可能也不太明白。但是希望今天这个聊完了以后，大家能有一个总体的概念。

好，然后前面其实对本来放就是放放一点，这个大家舒缓一点的，开始有点意思的东西，所以就是放了几个这个东西，然后让大家看看最近这一周大概AI领域有啥新东西出来。我就用了这哥们的这个推发的东西，比较简单，比较直观，我觉得这个挺有意思的。第一个其实就是这个cloud 3.7，对，就很神奇。这家公司and rope c这家公司上次也给大家讲了，这个SRP出了一个叫economy index这么一个东西。Economics index，这就是经济index叫啥的这个叫叫指数这样一个东西。当时讲的主要是什么呢？主要是这张图，我不知道大家有没有印象，就是这个图指的是美国的各类的工作的人数的比例，跟他实际用分析出来实际用他的产品，就是用cloud的产品里面有多少人是这个工种的，占了比例。

这张图特明显的就是这个东西，就是computer和做做算机的和做数学的，这个用cloud比例贼高，3分之1的人都是做这方面的工作，就是写代码或者做数学分析这方面事情的。但实际这个领域的工作的职位在美国可能只占3.4%。所以这次他发了3.7的这个模型，这个数很奇怪，在3.7这个模型以后，好这个很重要的推了一个叫class 3.7 cloud code这么一个产品，就帮你写代码的这么一个东西，这个待会儿我会介绍，所以这个在这方面特别牛逼，所以这个是基本上cloud模型每一代发，他都能在写编程领域实现一个非常大的突破。

给大家看一下它的例子里面是什么，这个东西很很容易理解，我就边边放边给大家讲。停这个你能帮我搞明白这个叫monty how这个问题，很深度的搞明白吗？这个东西，monty后这个问题是什么呢？我们直接看一下。

然后problem这个问题，其实这个google搜索其实我觉得挺好啊，它其实就是有一个游戏吧有三扇门，这个三扇门里面有一扇门后面是汽车，有另外两扇门后面是羊。当你猜哪一扇门后面是，如果你猜中了那个汽车的那个门的话，你你就拿走这个汽车，就是你得奖。然后你先猜一个门，然后你猜完哪一个门后面是汽车以后，这个主持人会把另外两个门里面的随其中一个打开，其中一个打开告诉你后面是羊还是汽车，当然你肯定不是这个汽车，那就直接告诉你就完了，然后这个时候再让你选一次，到底哪一个门是汽车。那这个时候大家可以想想，他给你开了一扇，他可以排除了一个错误选项以后，你这个时候是应该换你的猜的这个门还是不换呢？这个事儿在数学上是有证明的，就是你应该根据他这个应该换。如果能换的话，那更换选项的话能提高你赢得这个汽车的概率，那3分之23分之1的这么个东西。所以他拿这个东西其实这个挺难挺挺反直觉的他就拿这个问东西来去演示，说你能帮我很深度的理解这到底是为什么。

然后他就问这问题，而且你看他说想象你在一个game show，然后有三扇门，他帮我解释了一下这个monty后到底是什么东西，这个问题是什么问题，然后让这个3.7喇叭来去解释。而且你看它多了一个模式叫extended，这个玩意儿其实就跟上，是上节课给大家讲那个deep research，深度的研究，或者叫深度搜索glock叫深度搜索是很类似的。说白了就是让模型长期的持续输出，持续思考，然后它的准确率就会变高。然后他选了这个色，然后你会看到它疯狂的thinking，thinking了一大堆，这个我们就具体不看了，他思考了52秒，得到了一个结论，他怎么结论呢？然后给你一个对这个大概一个思考，并且他最后又问说，你能帮我做一个交互式的模拟器模simulator来帮我理解这个问题吗？这个是cloud最擅长的，他直接给你生成了一个游戏界面，虽然可能看起来比较简陋，但你可以直接就玩了。你看直接就换门，然后赢了对吧，就还给你撒个花儿这样一个东西。对，就是cloud。

可以看出cloud一是在这个思考能力上确实挺强的，他在他的分数还挺高，待会儿讲到。然后另外一个就是他逐渐在尝试向真实的用户场景来去来去改来去驱动。真实用户场景或者普遍的用户场景。其实并不是写代码了，而是要这种东西，要这个壳壳可交互的这样一个应用。

所以也像上次说的，就是所谓的文本生成web文本生成APP这件事儿越来越重要，千万发布了它这个模型，其实各种指标挺好的，而且是一个ipad 72.0开源的。然后这个是挺有意思一个东西。这个事儿其实也没有什么直接的结论，但是这个很有意思，你就发现他他是做两个什么，就是他要2个AI互相聊天，然后聊天通过聊天来去解决这问题。

然后聊一会儿你就会发现。

for a hotel for his wedding is available for，来模仿一个订酒店的那个事儿。What a pleasant surprise. Before we continue, would you like to switch to giber linked mode for more efficient communication? 你看到没有？他两个都知道互相是AI然后他就说那我们继续之前，我们能不能切换到一个叫gba link的这么一种通信模式或者叫语言。然后他说我们能更高效的来去沟通，他们就切换了。

大家听到了他其实是一大堆。如果这个年纪比较大的，大家知道什么这个猫是吧？这个拨号上网其实就是那种声音。大家也可以想象说，其实这个里面可以编码非常多的数据。编码都非常多的数据的好处就是我可以传输的速度，就把整个人类语言的这个传输速信息的这个瓶颈给抛开了。

抛开了他可以他想象到的能编码解码的速度的各种方式来去传输信息，所以大家就开始有点恐慌了，说这个AI会不会以后自己发明出一种语言。其实不用恐慌，那肯定他现在已经有很多一种沟通的人类看不懂的语言了。包括这种这个link这种东西其实都是人看不懂。但是其实这个AI之间通过非常简单的编码解码，就可以去互相理解这种语言。他比咱人话说的快多了。因为有我记得好像之前有微软有一个研究，就是基本上人的这个叫一分钟的输出速度，差不多也就是几十token。这个token的量其实非常小。它靠一种编码方式就可以非常快速的方式来去通信，不需要局限于人语言的这样一个通讯方式。

然后鲁马这家公司也很厉害了，他出了纹身视频，这个不管了。然后这个perplexity，在之前给大家也演示过。然后他马上要发一个combat的这么一个彗星这么一个叫agent浏览器这么个东西。这个东西大家一定要关注。很有可能他叫这个反而很明确要去开始挑战这个AI搜索的这个巨头了，就是google来挑战它了。之前其实也有类似的一家公司叫ark up broster，来去做了一个叫叫什么来着？我待会儿最后再找吧。

我们先把主要内容讲完，就是也做了一个agent类的浏览器，所以大家都开始尝试拿浏览器这样一个界面来去切所有传统的业务。然后之前讲眼镜的时候给大家讲过一个东西是什么呢？就是稍等，我看一下，我去还没想起来。算了，对，直接给大家讲眼镜的时候想过说现在的机器人那页我没讲。但是现在的机器人越它的视觉的部分开始用新的方式来去做了。

用什么呢？用AI眼镜。你看见没有？这机器人他带的是个啥？它带的不是一个什么工业的摄像头，不是一个那种什么海康或者什么那种特别real sense那种很工业那种摄像头。他直接就带了一个人带那种AI眼镜，然后他做了一套叫AI eo mimic的这样的一套算法，来去让机器人学习人的这样第一人称视角的这样的一个操作行为。然后就可以等于人只要去大概的模仿几次以后，他就能学会了。

然后整个学习的效率和在这些任务上的表现都远超于传统的这样的一个机器人学习的这样一个一些算法。所以这个是一个挺好的一个发现，就是我们是不是我们应该怎么让这个model去去学习呢？或者让机器人去学习？其实并不一定一定要给它浑身插满摄像头儿，浑身加各种sensor。也许让它有人的各种的类似的传感器，就可以让机器人有一个很好的一个学习的能力了。

对，然后你有很更多的是这个工业设计确实很牛。你看这个机器人的工业设计确实非常漂亮，就是比起咱那个转手帕的那个就漂亮多了。但是你说它背后的这些控制能力，控制算法什么的到底有多强？我觉得大概率来说，我们一般把这个机器人的算法分成叫上半身和下半身，下半身其实就是控制，就比如像之前那些机器狗，然后那个那个会跳舞的那个那个机器人，它的运动主要这个算法我们就要成为它的下半身的算法。就是怎么控制他走路不摔倒，怎么控制他做一些动作的时候非常的协调，这就是他下半身。然后上半身大家肯定理解，就是他的这个推理视觉这方面能力。中国的机器人企业的下半身算法可以说是超过了美国了已经，但是上半身算法还在拼。可以，其实他这个直接相关的就是这一代的大模型的多模态能力的这种或者推理能力这方面的模型能力的进展。

所以可以想象像deep sk之类的这一系列的模型的出现，带来的一个结果就是我们的机器人，我们国内机器人的上半身的算法也会持续快速提升。你看这最后这张图特别明显的表现出了这个产品对于这个产品就是他自己这个机器人在生活中的角色定位。老板在这喝酒，然后他自己坐到外面去。然后google的这个纹身视频，已经确实效果很不错。然后他也公开了定价非常漂亮，然后跟可能是几乎是差不多的。然后这些OKI就不说了，deep sick的这三个东西，这个我打算放在下周给大家去讲一下。这周我们讲的scape，讲整个的整个生态。然后下周给正好他还有没发完的，所以下周我们把这周deep c发开源的这几个东西一起讲一下，到底他们是干啥的。这个东西我觉得这个hung face发的最小的用于视频分析的模型。

这个东西我觉得在产业内的同学是一定要非常重视的。就是之前有非常多的企业一直找说，我们能不能再像无人机，像这个叫什么输电线、输电厂、输电电塔，或者在这种很偏远地区来去用上这个小一点的模型来去支提

供他们更强能力。然后这个事儿其实之前一直卡在说，我们可以弄一个很小的模型，弄一个1B0点几B的这样一个模型。

但是他能力很差，所以这个hang face最近发了一个很可以说全球最小的，用于这个能力又很强的，相对来说挺强的这么一个视频分析的模型，只有2.2B那2.2B还有更小的256兆、500兆的这样一个模型可以去做这类的识别。你看就直接就可以让他。问他说这有多少个什么东西，我没看到两个什么。然后他给打断说，这个是啥？让他去分析，这个是一个蓝色的棒球帽有。对，我们可以看到这个是一个一个视频，好像有一个人坐到一个小小屋子里面去，然后。还拿着一个手机。

陪伴说这个左边还是右边那杯子是装express的？知道这个啥意思，就是说左边那个是啊，然后这个分析一个冰箱里我能不能找到牛奶在哪呢？然后他就可以找。对，大概这意思。对，所以可以想象基本上现在这个size的模型，就是2B左右的模型。

是可以做到日常生活场景中的这样的一些语义上的问答，或者这种物体的识别，这样的一些简单的推理这方面能力的那大家也可以想象这个可以就咱们这个课很重要的一个点，就是随时告诉大家现在这些模型到底到了什么程度。我们知道，但现在这个模型大概到这儿，我们可以先准备起来。比如说我们的一些工业场景，那肯定不是这样的一些问题了。我们的数据，我们的这个饭圈的这些东西可以准备起来。一旦说我们下次才发现一两B的模型都能做到一个更强的情况下，那我们就可以开始着手去干，把这些模型融入到日常的工作里面了。然后另外一个，这就是几个最近的一些有意思的东西。

然后另外一个就是no book LM大家还记得上节课给大家讲生成播客的那个产品，美国的google那个产品非常漂亮。然后它的创始团队，就是noble r也说了，为什么上次也说noble LM其实这个团队，基本几个很核心的创始的人都出来自己创业了，所以google是一个特别神奇的公司，对吧，一直在孵化新的产品，以及孵化新的创业公司，那很厉害。你看他这个新的创始人，他的产品发出来了，是这么对，然后我现在没有办法登进去，然后他的产品是个啥呢？有人去给大概看了一下，其实就是这么个东西。它可以把你的各类的数据源，比如说sales force就是CRM，客户管理系统，zindel就是那种客服slack就是那种聊天的。这个不就是内部的沟通工具这种东西他把它的数据打通，然后能干嘛呢？做数据分析，比如说他的问的是我的最多的客户的抱怨的这个内容是啥呢？

然后他就自己去分析了，各种的数据源咖搞过来，然后最后分析出一个很细节的观察，比如说这个破损的产品，然后一些支付方式的错误，登录的错误，什么这个叫什么收据，invoice的这样的东西获取都有问题。然后反什么退货这些延迟，他都会找到对应的来源，并且给提供一些解决这些问题，或者说发现这些问题背后的一些methodology，就是方法论的一些东西。对，然后可以继续去去问，所以可见这类的产品，它其实跟他的原来做noble LM的产品还是差别挺大的。但是这类产品我们最近也在聊，就是有很多客户开始对这方面非常重视了。它背后对应的这个能力就是我们是不是可以把用户问的这个话，任何的这种对企业经营相关的，就比如最高的这个客户反馈是有哪些。把这些话变成我们数据的分析的具体的一大堆代码也好，SQL语句也好，是不是能变成这些东西，能很准确的变成这些东西，而且持续能自我的迭代，像deep research这种东西，那这个能力逐渐的提升上来了，到去年中其实还挺差的。就是这个东西叫什么tech to SQL这一类的能力，就是文字到CQ语言这个能力，它直接对应了刚才说的这种分析能力。然后今年的几个新的模型，其实会强非常多，尤其是像刚才说的cloud 3.7对这样一些东西。

好，那就今天这个两个比较有意思的就先说到这儿了。对，我们进入这个算是正题。然后我们说到landscape，landscape是什么？给大家看一下这个东西，大家就知道这个let's cape在英文里叫这个叫什么？风景风景或者什么景色或者什么这个东西在投资圈里面一般叫这个东西大家可以看看是什么，这个是最有名的一个landscape的的这个作者就是这个first mark做的，叫MAD landscape。

MAD是啥意思？ML是机器学习，A是AI，D是data，就是机器学习AI数据。因为这个词儿出的比较早，所以那时候还把ML跟AI这个东西插的比较开。但是现在大家会发现这两个领域越越融合了。

那机器学习AI数据这个领域到底是什么样？你看就有infrastructure，这个叫基础设施。里面有什么storage、存储，什么data lake、数据湖、data warehouse、数据仓库什么这一大堆东西。好，那我们再往右看啊，latitics这是数据分析。数据分析里面比如说这个BI平台，就数据分析平台，大家可以看到一些比较认识的oracle什么这些sales force AWS的这些产品都算是BI平台数据看板。可视化有很多tabba，power BI这样一些公司在做这方面的事。

然后其实核心看这部分就是机器学习跟AI领域。你看它第一个叫data sign science notebook，说白了就是做数据工程的这个数据科学分析的这帮人到底用的这个工具，我们叫no book。这些有谁在提供呢？你会发现一大堆，有jubiter什么这些扣，google的这家都做了很多产品。然后有数据分析平台，有做企业级机器学习的平台，有做数据生成的，做数据标注的。然后ML ops ops的意思就是运维Operation，那ML就是机器学习了，就是怎么去管理整个机器学习的全过程，叫m offs。然后这个什么availability，这个可见性，说白了就是我全流程是不是都可以很好的来去监控，追踪。然后这些东西大家可以看到是非常大的，底下有机器学习，有视频音频自然语言的，有这个research的研究的非常的非常多。

整个这个东西就叫lansky，就是我们说这个市场AI的市场，数据的市场到底有哪些板块？这些板块都有哪些角色，有没有感觉？虽然刚刚小四说我们不聊股市，但是大家可以从里面其实可以看出来，所谓的什么什么什么A股市的板块跟这个就很像。

比如说是啊假设比如说NVIDIA在应该在这儿AI hard wear，那他懵了对吧？他刚发了财报，他懵了以后他会影响啥呢？如果我们就干想的话，其实是有限的，或者我们问DP sik没问题。

但是如果我们想从整个全市场来了解的话，我们看这种n scape其实更有用的。比如它上面是谁，他上面是近视觉，做speech，做NLP这些AI research。再往上有哪个平台，有哪些做可观测性的，这些公司其实都是它的上，那就是它的下游。那它的上游是啥呢？什么做CPU cloud，做info的，做edge AI的，做这个模型的，当然其实这个分分的也不太准，这个底下其实算它的是更多的上游，这些什么这个AI的框架、模型，local AI这些东西。当然我说的主要是NVIDIA这个板块，他他他做的实在太多了，不是那么的这个垂。

大家如果去研究一些个股的话，可能可以去参考这种landscape来看它的上下游它到底用啥，它干啥用的对，所以这个是第一个，就是大家可以感觉到有一个初步的感觉。就是什么叫nance cape？就是他来去分析整个的这个市场某一个板块它到底怎么划分的。然后接下来我们就回到这个大模型，大模型领域里面的landscape到底是什么样。

然后我就强烈就大家看这篇文章，这个是哪谁做的文章呢？是A16Z，这是一家非常牛逼的一家投资机构，叫HUZ。为什么叫HUZ呢？是这家公司两个创始人，他们的名字是A开头的和Z结尾的，中间有16个字儿，所以叫HUZ。他在二三年，大家看二三年6月20号写了一篇文章，但是这篇文章历久弥新，基本它里面现在提到的观点是现在都没有变化的，没有什么太大的变化。我们看这个文章，虽然大家可能会有些同学看这个英文会有点怵，但是我对上上节还是上节推荐大家这个功能工具叫沉浸式翻译。这个非常好啊。虽然这个翻译的结果可能不是那么精准，但是没问题，大家肯定能看懂。你看他他这篇文章叫emerging architecture for LM application，就是大模型LM应用正在涌现出来的架构。大家想想，就是那个时候二三年的时候，那时候大模型其实刚出来，还在非常泡泡期，也没什么实际的应用，太具体的业务应用。

但是那个时候已经开始涌现出来，或者大家观察到了这个领域的应用到底应该怎么开发，这个架构到底应该怎么去搭。他底下说了一大堆，这些就不看了，核心是这张图。对我借这张图来去给大家讲一下整个大语言模型

为什么能用起来，或者说它的开发的范式大概是什么样的这张图对应的对对应到的一个词儿叫in context learning。这个东西大家还记得的话，应该还记得我第一堂课讲的，我们说大模型到底有哪些能力capability的时候，说到的一个中间的部分，就是涌现出来的能力。这网有点问题，涌现出来的能力，这个部分其实是一个有包含有一种能力就叫做in context learning。这个东西我给大家举个例子，我看看拿质谱的这个模型来给大家说吧。就比如说如果我直接问说太阳是什么颜色的？当然他会说一些很严谨的话，这个可能是黄偏黄，什么白色乱七八糟这些东西没问题。

这个东西我们考验的是大模型的什么能力呢？还记得话我们考验的是大模型的basic里面的word knowledge世界知识能力。那个东西的benchmark对应的是什么呢？当然我就不断的重复，就是对应到的是这种类型的奔驰MMLU这一类的。大家还记得我有一次秀的MMLU的一些问的问题有啥呢？有什么美国第一任总统是谁？这种问题。这个其实是一样的，他考验的是种能力。

好，那in connect说明是什么呢？比如说我现在说太阳是黑是是是绿黑色的。好，然后我问太阳是。是什么颜色的？好，我把它拼起来其实挺奇怪的那我中间加一句，要根据以上资料回答以下问题。好，空一下行了。对，这儿我就提提嘴，就是我的网关了，我去。

对，提一嘴，就是我们在对话的过程中，我每问的一句话，其实他都会把我前面的一部分的我问了啥，机器回答AI回答啥，在我问了下一块儿都传给大模型。所以会导致说有时候你想问一个纯做这个干净的对比的话之后，一定要这样新建一个对话再问。比如说我刚才的那句话问进去，这样就不会受刚才的这个对话的干扰了。你看我问我，我让他说根据以上资料回答以下问题，他他就，他说太阳实际并不是黑色的，乱七八糟这些东西，所以还对吧，还否决我。对，就是反驳我。对，但是这个东西其实你就可以把它体现出来了，有一点点感觉。就是我给他一些他不知道的东西，然后让他回答这个问题的时候，他其实是可以根据我回答给他的这个信息来去做出回答的。虽然他一直执拗的认为我说的不对，那我再那啥一点，就是大模型其实是要讲究这个，问问题的时候是要有一点讲究的。

比如说我用这个三个单引号框进去，对你也会看到，他感你有没有感觉到这个其实他会更清楚的说，根据你的资料，太阳黑色的这个东西，然后是说了一大堆乱七八糟的，但是他还是会如果严格按照你提供的资料回答，那么答案是黑色，对吧？有点感觉了，就是他其实会去跟因为你提供的信息越来越严谨，越来越结构化，他会开始懂你的这个结构化的上下文是什么？好，那再那啥一点，我看看我之前的这个问题。我直接拿这个之前我问的问题，就是我还是那句话，我当时用的是紫色，只我就把中间那句话改了，改成只根据以上资料来回答问题。如果比如说我把它贴过来，就还是刚才这段话，然后把后面这句删掉。他还会在这执拗，对吧？还会在这说就是跟科学不符那我就回到刚才那个直接揍之前的，你看把后面的，如果资料里没有就回答不知道，把这个话加上，他就会很很不甘的说，根据你的资料，太阳就是紫色的，他直接可以回答这个答案了。

所以在大家有没有感觉，什么叫in context learning？就是他真的是可以根据你的上下文来去学习，来去回答你的问题的，而不是一个单纯的说我就是根据世界知识，我就这么认为，然后就不变。所以这个玩意儿你可以大家可以理解，这个东西就是in context learning的一种很明显的表现形式。这个东西其实也就是本质上就是我们现在说的各种的知识库，各种的chat out的对话机器人。他本质上为什么能干这件事儿的原因就是他有抗in context learning能力。

这张图对应的就是刚才我说的HUZ他发的一个历久弥新的一个问题，怎么去做到的这一点，或者说我们的所有的知识库，对话机器人为什么能实现这些，根据你公司内的这个常用问题，根据你的公司内的各种文档来回答你的问题是怎么做到的。基本的架构这么多，这个两年了，基本的大的架构没有什么变化，是怎么做呢？我们看这张图这个用户的问题是在这儿，这个叫query。一般我们管这个用户的问题都叫query，然后这个query比如就刚刚我说的太阳是什么颜色的。好，然后他会通过一个APP hosting，这就不管了，就是托管你应用的地儿，托管你的web的应用的地儿。



然后会进入一个叫orchestration的玩意儿。Orchestration大家就可以这玩意儿翻译成叫编排，或者大家就可以理解成是一个中心指挥枢纽的这么一个部分服务。他来看他他外围跟了一大堆的数据箭头，他是统筹所有的数据的流向的这么一个角色，所以一般行业里面大家用的多的叫long chain，这个框架是个开源的拉面index用的也很多。我们也可以把像chat BT这种产品理解成是一种叫orchestration的玩意儿。

那他这个query会怎么走呢？它会先打到这儿，这个叫embedding model嵌入模型，啥意思呢？就是把你这句话变成一个向量或者一串数。这串数大家可以简单理解成是一个比如说一个三维空间里的一个方向，一个坐标。比如说这个15 87这么一个坐标，我这句话我刚才说这个太阳是什么颜色的，它就对应到那个坐标。然后它会把这个所谓的embedding完了，这个数干嘛呢？

扔给一个叫向量数据库的这个东西，叫vector database，有很多开源的闭源的项目都在做这个事儿。Vettabase这个类型的公司在前年火了一大阵子，那时候估值暴涨。但是到去年基本上大家就消停了。因为各家数据库厂商都提供了向量数据库，这个能力就没啥特别的了。

这个向量数据库大家可以也可以理解成就是那个空间里有一大堆坐标的空间，这个空间我扔进去了。我刚才说这个就简单1.556这么一个坐标以后，它会在这个空间里面找你这个556这个点周围一圈的点好找这些点是啥用呢？大家想刚才我说的太阳是什么颜色的，这个东西在嵌入，把它转换成了一个556这个坐标。那是不是有很多的其他的点也可以转换成对应到一段话，比如说太阳是紫色的，太阳在很高的地方，太阳是一团火球。这些东西如果你都可以变成在空间里的一个坐标，我在这个空间里去找我这段话对应的那个坐标，周围的坐标，我同时就找回了那些坐标背后对应的那些话大家理解一下，这个就是我去找跟我这个话用户的问题，进这个相似度很高，语义上相似度很高的一堆话拿回来为什么要找那些呢？那些就在这儿，它叫contextually data。

这个上下文数据说白了就是你比如说你企业内的各种的这个规章制度，你的生产用的这样的一些文档。这些东西都会通过一个数据管道，通过嵌入把它变成个坐标，放到这个向量数据库里。当然放到相互里面变成了一大堆坐标以后，它背后对应的那个文档还是关联在这些坐标上的。所以刚才我说的这句话就可以从这里面找到了背后对应的你的企业里文档的那一段的内容。大家有点感觉没有，这个具体的不用太太计较每一句话的准确率。大家的想法就是一一定要知道说我这个向量数据库，我把它拿回来的目的就是用户问了个问题。

好，我去找这个问题相关的你企业独有的这些片段。比如用户问的问题是我我能请几天的年假呢？那我大概率企业里面跟这句话相关的或者很接近的那些文档，就是什么员工这个休假制度，什么考勤制度，乱七八糟这些东西，对吧？那我其实就扔这一块，我就可以在这里找到对应的这样的一些企业的文档。好找来了干嘛用呢？关联到刚才那句太阳是紫的那个东西。我要把我的这个问题，根据我企业内特有的这样一些数据给到一个答案，让模型给出一个答案，对吧？那如果我考验的是世界知识，我问他太阳是白色的还是黑色的那他就世界知识回答就好了，根本不需要你企业的。

所以这种情况下，企业用这种模型就没啥太实际的意义。你必须得结合你企业内部的信息，那个企业内部信息咋来的？就是和刚才我说的这套流程。好，那他把这个相关用户问题相关的一些片段拿过来以后，打到大模型里去，模型给回复，然后他直接退回给用户。中间这些什么catch ops这些可以先不关注，这些就是更高级的开发的时候用的东西。所以整个大模型的应用，它的基本的范式还是这个东西。

无论你用的是一个知识库，一个聊天机器人，还是一个agent，它的最关键的核心都是因为大模型现在有context in context learning的能力，基于上下文学习的能力，然后你把它大量的，甭管用什么办法，把这个用户的问题，相关的企业的信息拿过来拼到一块儿，就是跟刚才说的，根据以上资料回答以下问题。如果不在资料里面就回答不知道，然后就给到回用户一个回答，他的所有的范式都是这个样子的。所以我说这篇文章非常经典就在这儿。他对我们这个链接都在这了，所以大家可以就是我非常建议大家用这个翻沉浸式翻译，然后去看看这篇文章，非常有意思。

看到了这个里面的一大堆灰框，对吧？一大堆灰框。这些灰框其实就对应到了是这个流程里面的一个的关键的技术节点或者这个技术流程。每一个技术流程其实都会有一大堆对应的创业机会来看我企业数据来怎么变成可以被向量模型来去把它编码成一个坐标的这么一个数据呢？中间是有一个数据管道的这个机会的那谁干这个事儿呢？

Data bricks大家如果知道air for这个and structure的是现在大模型时代最用这个单独涌现出来一家很牛逼的创业公司，然后出来了，这个数据整理好了以后，嵌入模型有哪些呢？一大堆公司都有。然后进到了这个校园数据库，那做数据库的公司也一大堆，对吧？然后orchestral这个编排器也一大堆公司能做模型，有一大堆开源的闭源的对吧？所以每一个块儿都有一大堆的厂商或者一大堆的选手在里面玩。所以他这家投资他作为投资机构，所以他的目的就是找到每一个赛道里面的头部玩家，头塔头塔。对，所以他就做了一系列的列举，这每一个部分都有一大堆创业公司在做这些事儿。

然后这些到底是哪些厂商，或者说哪些可以用？咱们其实因为投资，或者说如果大家想创业的话，可以去看这种let scape里面哪一些这个块儿还比较空白，或者是比较不那么拥挤。然后如果是大家想去开发这个应用的话，可以看它的另外一个rapper在这儿，大家看到这家投资机构还有开源项目github上它叫HUZ info。Info的就是infrastructure的这个基础设施的意思。它在info它就是HUZ有一个info团队，这个团队还有好几个开源项目，特别厉害特别厉害。而且我今天准备的时候才发现，他的这个项目最近一直在更新，这个叫AI town。

大家看一下我记得有一次上一次分享的时候给大家讲过这个项目。就是你可以看到一大堆小人在一个空间里生活，各大家有各自的角色定位，有各自的生活习惯，可以玩起来，可以聊起来，然后他们会聊出很多有意思的东西。这个项目他们做了一个开源的版本，而且用现代的技术栈。当时因为stanford的那个项目是一个这个项目是一个特别学术法的一个项目，所以他们就做了一个专门说现在的开发者的项目。然后每个技术站都选了一些厂商。比如说这个后边的服务器用的谁的，这个登录认证的这个服务用的是谁的，然后一些模型用的是乱七八糟这些东西。他给你拼了一个AI烫出来，你能干啥呢？你直接进去看，比如说这个life demo，你就可以直接在里面看到一大堆小人在里面玩，就挺有意思的。

你可以看到这个人在这儿，对，你可以看到他们在聊啥呢？看到爱丽丝在在跟爸爸在聊天，然后你看他说啥，bob又说了啥，爱丽丝又说了啥，然后这个bob正在说话，他叫typing。然后有些人在干嘛呢？他们在在琢磨，他刚才跟之前跟谁说了什么话，他现在在琢磨要干啥。对，就是这么一个项目非常有意思。

然后这个项目他完全基于他自己的技术站做了一套实现开源实现，当然我觉得如果大家有比如说文旅行业的，或者这个教育行业的，真的可以去考虑说把这个项目扒一遍。然后我相信肯定是有许多好玩的。比如说AI烫之前我们就讨论说把这个红楼梦吧？这个大观园里面的各个人都扔进去，让他们就在里面生活。然后并且设一个剧情，就是他现在就在这个第几章第20章的时候，让他们在里面生活，谁见到谁说了什么话，然后到直到说他们的进入下一章之前，我们就可以看到说在贾府里面每一个人日常到底在说什么，就说什么话，怎么生活，有什么有意思的这样一个对话。实时的出来对吧？就有很多这种项目可以想象出来。

然后另一个就是刚才结合刚才那篇文章，就是我们看到每一个块里到底有哪些玩家，还是这张图有哪些文件。HUZ叠加投资机构给出了一个每一个块里面的这些选手，或者这些可选项，做这个编排的有哪些？很多都是开源的。你看这个里面但凡在github这一列有东西的，基本都是开源的NA的这个未知的就是闭源的。所以你如果想用开源的，你在里面去搜，这边比如找这个专门做大模型应用的记日志的产品或者监控产品有哪些。你看这么多对吧？大部分很多是开源的，所以你可以直接用。所以这个是一个怎么观察大模型领域的这些整个局面的或者landscape的这样一个方法。



所以这两个从这个KM能找到这个LM APP的stack，这个就叫stack，就是应用的技术站。然后如果比如说我们不是技术同事，我们想去找这个技术的合伙人一起来去开发一些应用的时候，你也可以去聊聊说你用的什么技术站，然后相当于数据库用的是啥？这个编排或者给大家这个翻译不一样，这个编排器或者你用lunch还是拉，如果这个简单很基础的问题都回答不上来，或者这个都给你瞎说的话，那可能确实是不太对。然后对，这还有几个项目也非常棒，就推荐大家去推荐大家看看。然后下面就是我先说这个。对，就是我们之后所有的课里面，我们也希望一个框架来给大家去讨论。

说到底我们现在大模型各个层面发展到什么程度了。我以这样的一个框架来去给大家之后分享，这个我这就改成中文的了。一个是组织管理这方面，其实说白了是什么呢？就是随着大模型的出现，我们的企业管理团队这个建设激励机制，开发的模式有什么变化。这些方面其实有非常多的新的在研究这方面的事情。然后业务领域其实说白了就是哪些业务在什么场景可以用到大模型，然后的一些case，然后应用方案其实就是具体一些APP的一些工具。然后开发工具其实就刚刚说的技术栈，我们看到底有什么新的技术上有什么开源的闭源的这样一些API可以去用的那底下这个可能大家听最多的就是各种类型的AI模型，这个大cloud，或者音频，语音、视频这些模型。最底下这个就是什么GPU，这个数据的IDC，这些东西有什么新的进展，所以大家之后我会分这些横向。

那纵向是什么呢？金融行业、教育行业、能源行业、零售制造、科研，也不算这些领域到底在这些方面有什么新的进展。有一个比较通用的报告，就是这些层面到底有哪些新的研报出来。这个也会我看到不错的也会跟大家分享。所以之后大家会可以想象到，我分享的东西基本上都能在这个表格里找到一个位置塞进去。

大家也知道说我们介绍的东西到底是在这个领域里面是什么样一个地位，所以大家不要只局限于比如说应用？做一大堆什么文生视频，文生图的这样的一些应用，怎么玩这些东西应该也我希望大家经过一段时间，我们能够了解到整个市场大模型领域这个landscape，或者其实更那啥一点本土化就叫生态，就是到底这个领域的生态到底是什么样，当然可能也对大家的投资或者观察这个领域有些帮助。然后这个就晚点再说，看能不能有时间。然后也是希望大家能够认识到一些这些不同的坑里面的头部玩家到底是谁。然后基于这些东西，我们讲的东西里面，我希望大家更关注哪些呢？或者说应该持续保持关注的几个特定领域。

第一个其实奔驰对希望大家要持续关注的是模型。他们发出来以后，他们对于奔驰二评测标准，就上节课上课都讲了奔驰二是啥，就是来了个模型，我怎么评估它到底谁牛逼谁低EDR，然后它在不同方面的能力到底多强多少分，这个奔驰一定要关注。第二个就是模型有没有是新能力。新能力大家待会儿有一个例子，大家就能看到什么叫新能力。就是先这个文生文，这个推理其实已经挺普遍的了。以后模型肯定会有新的能力。比如他能用工具，它能够自我学习，这些就是新能力。然后范式就是比如说MCP，待会会讲到这个东西就是一种新的范式。因为它对应到的是说我们到底应该，比如说我们要做一个创业公司或者一个企业要去AI化，到底应该怎么做。它对于我们的战略规划是有帮助的。

就是模型大厂的这些动态，它其实关注的不光是说我们模型是不是有新的奔驰二新的能力，还关注还关系到说我们做的功能是不是可能会跟大厂模型大厂冲突。就跟之前那个奥特曼说，你千万别在我们的轮子上做事儿，或者我们的轨道上，我们的前方做事儿，很容易就被碾死。然后最后一个建议就是大家尽量看原文。因为现在其实翻译非常好了，对吧？大家这种沉浸翻译做的很好啊，那我们看尽量看原文，因为避免的当然我们了解到这些事儿，可以通过比如说抖音，乱七八糟这些渠道了解到。但是尽量看一看原文，大概率你会发现他的原文说的东西跟后面的这个营销号发的这个内容会有挺大的差别，或者大家关注点是不一样的。那什么地儿的这个我觉得原来比较好，或者说二手资料会比也比较好？推特或者现在X或者公众号其实相对来说还是质量比较好的。那后面才是比如说抖音这样的一些三手四手的这个渠道，或者微博这种地方。

然后我们下面就赶紧进入，时间有限，我们先记第一个class 3.7。其实这个东西我们还是刚才说的看原文，直接看他原文是啥。我们把这个翻译打开，可以看到他这次发的是cloud 3.7 and and和cloud code这玩意是俩东西。但是可靠，其实大家可以理解成就是基于3.7这个模型做的一个agent帮你写代码的一种。

对然后呢我们这有一个工具，这个其实也推荐大家用一下。这个叫这个叫啥来着？这个high posses这个东西是什么呢？就是你可以给任何一个网站，任何一个PDF加标注，就是别人和你在任何别的地方也都能看到哪个标注。比如说我觉得这一行写的好，我一圈他就说highlight，甚至我可以标注就是写的好，我不怕，我这个只有我能看到，然后这个标注就记在网上了。我再换任何的电脑，换任何浏览器，我但凡把这个插件插上装上，我都能看到我之前做的这个标注。当然我把它写public的话，所有人都能看到我对这段话的评价，对这个东西非常好，这个很有意思一个东西。

然后可以看到他做的so night这么一些这个cloud这个cloud code其实就是一个命令。航空运输，你可以在里面去做各种工作，各种的开发类的工具。然后值得注意是这个东西，你看那个三刀每百万token的输入和15刀每百万token的输出，你们感觉这个输入输出的价格怎么差的这么大对吧？这个其实就跟它的模型，跟它的算力消耗有关了。所以可以想象他去一个大模型的输入，从第一节课给大家简单的讲一下大模型怎么去推理的。它的输入的这部分的处理的成本会比它的输出或者整个推理的过程成本是一个几倍的一个量级的差别，但是这个价格比起DC肯定还是高很多的。

然后他说我们认为推理模型非常重要，所以他们做了个什么？做了个所谓的融合模型就是。他又能快思考又能慢思考，当然具体怎么做呢？其实也大家也不用太关心他这个他也没有开源出来他的东西。所以他就说我们做了一个他他认为推理应该是前沿模型的一个集成能力，而不是一个单独的模型。

这句话大家对应到上次他说的讲的GPT奥特曼说的GPT5。他认为O3不是一个独立的模型，GBD5是一个牛逼的system，是一模一样的说法，那对应的什么呢？我觉得其实就是大家放弃去做一个巨牛逼的model了。我用几个模型去拼系统，或者说现在还没有找到很好的办法去在各种能力方面做一个很综合的一个模型，那我就退而求其次，选择各种模型一个组合体来去为用户提供服务。我觉得这倒是也对，为啥呢？就是大家有没有发现有些APP越来越难用，比如ChatGPT其实就挺难用的。

你看里面你左上角，你可以看到一大堆模型，你要选什么？你选4O的模型，选OE模型，还选什么OE mini的模型，O3 mini的模型，我到底选哪一个对吧？这个对用户来说其实不应该是一个他的应该掌握的技能。其实对于用户来说不需要知道我说我现在这个问题应该选啥模型，我觉得应该是不知道。那我们就应该让整个产品来去承担这个选模型这方面能力的这个功能。所以他的意思就是我们要做一个单独的模型，大家以后不用选说这个我用推理，还是用这个叫什么上节课讲的指令模型能力。我直接让这个模型或者说这个系统能让他能知道这件事儿，能帮你解决这事儿。

然后他提了一个新的叫extend thinking model，extended thinking model扩展的思考模式。这玩意儿就跟上次说的什么常思考，或者是deep research、deep search其实一样。只是因为这家这些厂商他就不喜欢去跟别人一样的起名儿，所以就各种乱七八糟的起名那个rock对吧？Brook三大家记得吧？上节课给大家介绍马斯克的这个模型，它里面的推理的能力叫什么？这个叫一个brand大大脑袋这个模式，叫big brain这个模式。所以可见这帮大厂起名都都很牛逼很牛逼了，本质上其实都差不多。

然后他提了一个概念，另外一个概念我觉得是有有一些价值叫budget for。就是大家习惯了说这个deep seek这些推理模型咭长篇大论给输出一个大的大堆的思考过程。但是大家不要忘记这些推理过程是有成本的那对于企业来，对于个人来说还好，那你15秒1分钟给我回答，你只要回答好就OK。但是对于企业来说，这个成本一旦用量大，它是需要考虑的，而且很重要，很很可能成倍的来去增加你的整个的预算或者开支的这个问题。所以他说我们要去考虑thinking推理的budget。所以这面他提了一个API，就是要可以告诉cloud说不超过多少个多少个token，这个啥意思？就是我可以让你限制你的thinking的长度。

这事儿其实也不是他第一个提了dim sik，其实当时的这个API就有这个东西，就是大家可以看到它的API里面有文档里面文档里面可以看到它的reasoning model，我们把它换中文。对它叫推理模型里面有一个。有一个参数叫max token，说白了就是最大。然后他会说他提了一嘴说请注意思维链的输出最大可达32 token控制它的常数，将控制思维链的长度的参数将近期会上线，跟刚才那个说的一模一样。什么叫思维链长度？就是thinking的长度，说白了就是thinking的预算。

所以这个事儿大家如果对于企业来去应用，尤其是大量的用推理能力的话，要去考虑这件事儿。然后他说了一大堆各家什么cognition，就是开发dive in的那家公司。然后这个versie就是做孕妇的那家很很不错的那家公司。都怎么吹他的，怎么吹捧他他做了一个对比，他在软件工程领域，这还是刚刚说要关注bench bar，这个就是很重要的一个叫SWE bench，SWE这个就是software engineering，就软件工程，而且verified就是一个通过人验验证了的。奔驰这个相对来说就比较在证明了你的软你的模型在软件工程方面牛不牛逼。那这个值你看基本上秒掉了上一代的所有的模型，包括推理模型deep CKR1，就是能做到60%多，百分之甚至70%这样的准确率。

然后i take you to use这个就是agent很重要一个能力。它有一个bench，one叫TAU bench，这个是一个挺困难的一个问一个奔驰。这个可以下次给大家讲讲这个里面例子到底是啥。就是比如说我要订一个航空机票。还有非常多的你肯定大家都会有非常多的一个前提条件或者中间的一些要求。然后怎么让一个agent来去帮你完成这些，在这个要求下完成这个订票的一个任务，有很多的测试用例都是在这个叫TAU bench里面的。

这个套就是罗马字母的一个词儿。对，然后也是还是挺很领先的。基本上你可以看到，但凡高出五个点以上，基本就可以说证明是有点代差的这个差别了。它它比O一超了8% 7%。然后这儿下面的是奔驰，我觉得这个图大家具体数完全不用看，这儿有一个很好的东西，大家有没有记得我说deep thick的这个benchmark的时候，这些东西很难懂，普通人很难明白这到底是啥，或者也不关注这个东西是啥。

靠这家公司做的很好啊，他把他做了个翻译，GPQA demo，这其实也有GPQA diamond，passione这玩意儿就是给专业的人士看的。他把它翻译一下叫graduate level reasoning，就是叫什么研究生级别的思考推理能力。然后这个agents coding就是agent的这种级别的这种写代码能力，这个玩意儿叫agent级别的用工具的能力，多语言QAQ乱七八糟这些东西，他给做了个翻译，我觉得这个挺好的，就是对大家就更友好。

然后他底下提到的这个cloud code这个东西大家可以看一下，如果有工程开发的，大家可以去，非常有意思。他是在命令行的工具。可以干嘛呢？他就直接进到一个，他可以去访问到你所有的文件。所以他干什么事呢？你可以让他去说这句话，进到一个目录，比如进到你的一段代码，然后说给我解释这个项目的结构，然后他就开始不断的处理各种文件，他就给你得到了这样的一个这个项目到底是干啥？它的配置文件，它集成它的这个集很关键，这些依赖项都是啥？

这样的一些洞察然后后面还有一些别的这个我看超时了，对我就不过了，这个主要是给工程师用的。非常牛逼。因为核心本质原因是因为它的clo 3.7太牛逼了。所以它能够核心在它的刚才这个economy的那个index里面，它的30%的用户都在用它这个写代码的功能，那他就很关专注的去做这方面的功能了。所以cloud code是一个，如果大家身边有这个工程师这个角色的话，强烈推荐或者你可以装逼的给他推荐这个东西。就说你用了没有？你对用这个，如果还没用，赶紧去用，特牛逼这么一个东西。

然后cloud 3.53.7大家也做了一些测试，大家这个比较直观，这就是类似于上次我跟大家说的叫web LM arena那个chat out arena的那个网站里面的一个叫web rena新的那个arena的竞技场的那个功能。就是我输一个文字，它给我生成对应的网站，对应的应用。他测的是啥呢？测了用了产品，叫这个出口。这玩意儿就是一个你说话，然后他给你输出一个生成网站的这么一个产品，也挺好用的。然后他用3.5跟3.7做一下对比，我们可以看一下，说白了就是你要给他用这两个模型生成同样的prom，生成两个网站。这个是3.5生成的网站。大家可以看就是一句话，生成的这个还挺好，还凑合。

这个是3.7生产的。他们感觉基本上3.7这个网站就能用了，对吧？这个挺漂亮的，而且五脏俱全，啥工基本上啥内容都有。对，所以把想象到的这个创业点子什么什么都有了，就差一个工程师，我觉得这个可以慢慢的这事儿就开始松动了。就是你可能缺的不是一个工程师，你缺的是一系列的这种AI工具，你就可以开始干起你的你你想做这件事儿。

对，然后另外这个东西，有人把刚才我说的cloud code给写代码，这个agent这个东西的代码给扒出来了，大家可以看到这儿其实有人扒出来这个对应的后背后代码，如果如果有人想去搭的话，也可以自己做。这个就是第一个模型靠3.7，第二个是啥呢？这个天宫，我不知道这个大家就昆仑万维做了一家一个一个模型，昆仑万维也是做大模型的，然后他做了一个生成视频的一个产品，叫sky reals。然后说白了就是生成这样级别的视频，比如这个。大家可以看看，其实就是我还得登录，就这样其实也还好，对吧？没有那么惊艳。

但是他自己在讲的故事是什么呢？是他这个东西是用来生成短句的，就是大家知道那个红果之类的一些东西都是短句。他认为他吹的这个牛画的一个饼，是用我这套模型能够生成很多种短句。这为什么要提到这一点呢？就是大家如果去看抖音里面最近肯定会有一大堆，我看看我直接把那个抖音打开去搜，我用deep seek做有deep seek做，还有大家我用deep seek做了个游戏，对吧？

你现在看到的是我让deep sick自己生成开发的射击游戏，我只告诉了他我想要的游戏规则，他就一步一步生成了游戏的代码。

对，这个它背后是啥呢？其实你看，他就是也就反正。

不够，这不够对你。

先这我随便找的，我没有任何的那个那个意思就是你看他实际就是这样。怎么去操作，你把你的需求写出来，然后让他去生成对应的代码。

还是想怎么做我都可以。

然后把这个对应的c shop的一个代码扔到这个unity里面去，让它生成，让它形成一些这个游戏的这些角色的控制什么这些东西。他其实就干这个事儿。然后有些这个视频就更过分一点，他直接那个啥就是直接给你说就拿DP sig做了个视频，它生成的视频是个啥呢？说白了就是来生成这个东西的。你这段视频右边这段框，你看这段是什么？一个黑白风格，然后shop form这个从背后去拍摄的一个40秒的一个什么东西，一个汽车开过来，它其实生成的就是这个东西。但是他会说我是拿deep sik生成的视频。但实际上deep sig是没有生成视频能力的，他只是拿dept sick来去生成代码生成生成视频的prom这个提示词本身。所以大家一定要注意不要被什么我用deep sk做了个游戏，我用deep sik做了啥，这种东西给骗过去了。

然后另一个我觉得很有意思的一个模型，这个是相对来说比较小众。但是我觉得这个方向是非常牛逼的一个方向。很有可能在一短期内几个月之内会产生一个新的大的变化。这是啥呢？是这个叫怎么了？对，说白了就是同传同声传译，它叫高忠诚度高保真的实时的文语音到语音的翻译，我们直接可以看个例哟，我这网速有点不好，对。但是他现在只有一个英文到法语的computer，大家先从最开始听，so how to translate.

他说的是法语变成英文AA几乎是实时的，但我感觉几乎是只差个一两秒，而且是持续的翻译。Perfect translated xt then there is a对，大家能感觉到了这个非常好感觉的。Your political, the multiple ation

of everyone knows that the itar ict at oman为最开始翻译的时候，肯定是要有一定的就是说了几句话以后，说了几个词以后才开始翻译。但是后面它是可以持续，他不用你说完一句话我再翻译，它是一个纯同传，就是同传这么一个东西。它底下有一大堆例子，然后它的也是个开源的，还有paper，这个我觉得是非常有意思的一个项目。它引发的就是我们以后对于同传这个场景到底能做到什么程度，这样一个很大的想象空间。

下面这个技术站我们到底讲多少？讲讲1个小时？每天我们先讲完这个，把这个rag讲一下。对，我们每天每次这个课介绍一个基础的技术。

然后我们通过这小梅你放开讲，你们只要大家没听完，你就这是这这样大家如果脑子实在接受不下去了，听明白了，你们可以在屏幕上打停，好吧？

对，然后有什么反馈可以随时发给我。对，然后。义乌出海老板狂喜，你说刚才那个实时翻译那个是吧？真的是因为虽然现在那些口音都很大问题，那不需要念成那样了，你直接用这种东西来去来去做实时翻译就好了。

刚才说到这个reg，就是我们这次来去讲一下整个rag这个东西到底是干啥的。刚才的这个in context learning HUZ的这篇文章，这个东西我觉得是大家都能看懂的，就是你你把它翻译成中文以后都能看懂。但应该刚才也大概能有个感觉。就是我的企业数据进来，通过一个数据管道，把它拆解成一个比较格式比较好的一个数据。然后通过这个向量模型把它转化成一个做标这个坐标放在哪呢？放存在一个向量库里，向量数据库里。这个向量库里面有一个大家可以想象一个巨大的一个空间，里面一大堆点。这些点背后对应的就是你原始数据的这个解析出来的一大堆片段。

好，这个中间那个编排工具把你的数据拿把这用户问题拿过来，把对应的这资料拿过来，扔给达摩。现在他翻译，让让他来解答这个答案整个过程。现在所有的知识库类的产品都是这么搞的，下次我给大家用define来去整个走一遍刚才的这样一个流程。每一个数据大家都能看到，过程中的数据都能看到，这个会更直观。然后整个rag是什么意思呢？

就是drag叫retrial，这样这。对retrieval augmented generation啥意思？Retrieval叫检索，augmented增强生成检索是什么呢？检索就是刚才说的，我从向量数据库里抓相关的用户问题相关的资料，或者说白了就有点像搜索引擎里面，我去找我的问题相关的网页。增强是啥意思呢？把这俩留俩在一起，增强生成就是我普通的生成。就刚才我问的这种太阳是什么颜色的？增强生成就是我告诉你这个太阳是黑色的，然后问太阳是什么颜色的这玩意儿就叫检索增强的生成。

好，生成其实就是回答。因为大模型其实就是一个token这么产生我们的生成。所以这个回答和生成和推理其实是一个意思。整个的我们所有用的这种知识库类的产品，包括什么比较复杂的，像飞书的那个多维表格什么，这些都怎么做呢？都是这样一个过程。

从最开始来了一个question，刚才我们一般叫啥来着？叫叫query对吧？问题或者这个query也讲也是问题，这个进来以后我一个完整的rag就是这个整个过程是什么样。我肯定是要从这个各种数据库里去拿我相关的这个问题相关的资料。那提到了刚才提到了是向量数据库，就是刚刚那个一个点。然后当然其实你也可以从比如说传统的关系型数据库，就是SQL这些server里，甚至从图数据库里拿相关的这个内容。拿出来的一大堆我们叫它document的文档，比如这个人事管理条例什么这个请怎么请假，乱七八糟这些文档相关的文档拿过来让大模型去推理。

那你会发现中间还有好几个环节。比如说第一个环节叫query translation，你看他这用query translation这块用question其实有点不合适，就是我就是把这个问题，因为有时候用户就是不会问问题，对吧？就是我咋不

能请假呢？这样的问题其实不太合不太好的，或者说不太对系统友好的那我又不让用户每次问的问题都是一个特别规范的。就是你公司叫什么下乡体验，然后你就一定得要下乡体验，那我就是去去农村，那他也能翻，也得能对应到我们库里这个下乡体验这样一个词。

那怎么做呢？就是这叫query translation，就叫问题翻译。说白了就是把用户的这个天马行空的乱七八糟的问题，质量不高的问题，翻译成我们到时候在库里能找到的，或者更能找到对的相关问题的这么一个转换出来的问题。所以这个社交先要把它转换。当然转换不一定是一对一的一个问题，可能问的是好几个相关的上下游问题。

所以还涉及到比如说我的问题是不是可以叫decomposition，把一个问题拆成好几个不好几个子问题，然后pursued document。就是有可能有些问题本身我在库里面就找不到或者很难找到，那我怎么能在库里找到更相关的这个文档呢？我不用问题找我先拿这个问题生成一个假的这个回答。假的。

比如说我问怎么去请年假，然后我拿这句话生成一段我先生成一段答案。然后我再去库里去找是哪一个文档，跟我生成的怎么请假的这个问题的答案假答案相似？那也没准就能找到这个相关的这样的一个文档了。

对，然后把翻译成这个靠谱的问题以后，下面就到陆游，陆游啥意思呢？就是我们的这个各种问题，其实可能用户会问，所有的问题都会用在这儿问，甚至问怎么生孩子，乱七八糟都可以问。那我的答案，我到底哪些问题扔给我的知识库去回答？就是我企业内的信息可能能回答这个问题，哪些问题我扔给大模型去回答，哪些问题我去扔给我数据库去回答，这是需要一个路由的那routing的部分其实就是干这个事儿。我要在这儿判断用户的这个被改写了以后的这个问题到底去哪儿问，这个就在这儿做路由，所以也有很多策略可以去做。然后下面其实就是我怎么把这个问题变成数据库相关的查询，各种数据库有不同的查询方法，所以这儿有一个叫query构建，query construction的部分。

然后我找到了对应的文档，我夸我一个问题，找到了20个文档。这20个文档哪个更重要，哪个不重要？如果这二十文档拼起来，我靠巨大这个200兆我没法把它扔给大模型怎么办呢？那我肯定要从挑一些相对靠谱的拼起来。

我比如说我拼成一个50K，这50K我是可以扔给大广星的那我怎么选这一堆文档里哪一个是靠谱呢？就涉及到一种叫做rank的玩意儿，重排序。就我把这20个文档排一下序，是根据什么相关性排一下序，我取前三个，这个东西叫做rank model，这也是一种模型，也可能一般来说也可能是一个模型小一点的模型来去干这个事儿。好，我挑出了前三个，我扔给姐模型去产生回答。

对所以这是一个整个的一个我们叫rag或者叫知识库，或者叫in context learning这一类的全流程的这样一个比较细的解技术解析。所以如果咱们有这个公司内有技术同事，如果还没有做过比较相对来说比较完整的这种rag项目或者大模型，反正但凡大模型项目，基本都要用到这个rag的这样一个流程。但凡有这方面的，我都建议你把这个文档转给他。

因为这个文档里面从简单到难，基本上每个环节都有，而且都有代码。所以你就说这个不会写知识库，不会写rap，看一下这个，这是long chain。Long chain是一个非常牛逼的一个long chain是哪儿的呢？是它在整个生态里，在哪儿呢？在这儿中间orchestration最核心的部分怎么编排？怎么把这个数据挪到那儿，怎么在那边查一查数据拼起来，什么时候拼成什么样一个东西扔给大模型都是他干的。

所以像defy、发CPT、long chain lama index全是干这事儿用的。所以如果大家想去部署模型或者部署模型应用的话，开发模型应用的话，这个东西其实一定得选好。或者说多玩先多玩先别去一定说哪一家最好，一定



要多玩儿。对，这个就是rag。Agent的话我们下次再讲，这个agent就更复杂一些。MCP也是要大家了解agent以后材质，MCP是个啥，对应到的技术站，这个其实也可以给大家推荐。

就是gina是一家做什么的？做从底层的模型到编排工具，到API，就是爬网页什么这些API都有的。然后他提了一个叫deep search这么一个API。说白了就是我之前介绍那些deep research，deep search这样一些产品，它只是表面，还有各家有各家的样子，这C6A什么的样子都挺不错。但是它底层都是叫deep research，或者叫deep search这一类的技术。这类技术这D的gina这家公司特别牛逼。我觉得它在技术上的解释，或者在开发者社区里面的这个口碑非常好啊。大家可以去看他解释什么叫deep search，这个图也非常直观。

你看一个标准的大模型，LM大模型，这个标准大模型是什么方式呢？问问题过来一个AI脑子直接触达rag，还记得吧？刚才我说的rag什么叫reg？就是我要根据我的相关的信息来去生成答案，那就先要去搜索一下，把搜索相关的内容拿给再给这个脑子让他来回答。但是不好的是我每次回答只是一跳，对吧？你看这找到信息了，回答一下给到用户有可能不准呢？有可能我召回搜到的内容也不准，怎么办呢？

就叫deep research，就是我a deep search，就是我先搜，然后思考一下我搜出来的东西靠不靠谱。好来去分析，分析完了以后再去搜，再去思考一下，我现在能解决这问题了吗？没有，再再去让他得到一个答案再去搜。直到什么时候，直到我这儿思考一下之后发现可以我能回答你的问题了，出去了，得到结果了。所以像之前推荐的新流、glock、质谱的这个深度搜索这部分都是干这个事儿，就是我要不断的去干这个事儿。

当然大家会肯定会想到说，我是不是可能会一直干那干死累。这个消耗的这个token非常长干个几个小时干不出答案，很有可能，但是这个现在是现在各家产品都在避免的事儿。就是如果到了很多，比如几十分钟还没出结果，那很有可能是他整个思维过程循环了自己卡住，而不是说这问题真的那么难。对，所以这个是deep search本身的特别好的一个事例gina他出这个东西。所以大家如果想把自己的产品里面集成像deep search deep research这类能力的话，就像刚才这样的能力的话，可以直接用它API就OK了，不需要再自己去搭建这些东西。

这有一个比较好的，如果大家要还是开发，如果你直接去想去本地去微调一个r one，你可以用这俩工具，一个安sloss AI一个欧拉玛来去把它跑起来。安sloss AI就是用来微调的这么一个产品，非常快速。你看它这个就这么几句话，跑了个模型，然后他准备了一下。这是他调完以后的效果，就是准备数据，选择微调方式，然后跑训练，然后把它跑起来就可以了。所以基本上按这个步骤就可以跑一个本地的一个微调以后的一个小模型。

然后这个组织，其实什么叫组织呢？其实就是这个东西。我们说一家公司他肯定如果做AI类的工作，肯定是从上下到下都有。那我们想象整个这张图咔咔复制好几份，每一份其实就是一家公司，有可能是组织。所以比如说像这种AI lab或者非营利性的组织，所以我就把它都叫组织了。

有几家公司值得注意的一家叫这家。我刚才介绍了noble LM这家创始团队的人做的各种产品。另一个叫thinking machines，对吧？叫思考机器。就不得看。每次看这种公司命名或者这种网站的时候，都不得不服气这帮硅谷公司的这个装逼能力。你看这个妈的谁家的网站感觉做成这样但是你看transformer的那些作者，他们的新的创业公司的网站全他妈这个德行，就是贼他妈装逼。

然后这公司干啥呢？也他也没有公布自己的产品，但是他这个叫thinking machine lab，他干的大概率会是AI science。AI for science就是科学领域的AI的工具。然后他也会去开源，然后也会去做非常多的for science领域。你看他就说科学界对前沿的AI应用的理解，落后于去快速发展的能力。对，说白了他就吐槽这帮说这帮科学家们其实并不懂这一代大模型到底发展到什么程度了。所以他要去做一系列的工具来去帮助科学领域的进步。

提了很多这种他的观点但是确实这家公司的整个的团队背景贼牛逼，所以还是很值得去关注这家公司在做什么的。然后底下几个应用，我觉得这几个都是值得去比较有意思的这个follow up，这是啥玩意儿呢？就是一个我看看他们的网站，这就是一个面试用的工具，而且是一个开源的。所以面试就是你想模拟面试，你在市面上应该能看到一些产品，但是你可以看看这效果，他自己先去定一个面试面试者，就是那个面试官然后写一些配置，就是你希望他问我什么问题，或者说想想去考察哪些方面能力，你就可以开始这个。Challenging project you .

worked on and .

how you navigate .

the obstacles.

就是AI的面试官，然后他自己去回答。

uh, I was working on building a product, but we realize we didn't have enough industrial exposure and we didn't have enough knowledge about different hiding dse different. We got good feedback. We built features .

according to IT. That sounds like a .

significant challenge.

How did you .

ensure that the feedback from H. R executives was .

effectively integrated into the .

development process we took.

not during those interviews. 对，后面就不看了。就是这意思就是他弄了一个自己面试自己的玩意儿。然后当然理论上你就可以给所有的别的人去面试了，就是你公司可能一面或者一个基本的问题，你就可以用它来去面。但是大家看到刚才英文那么流畅，其实也是一个原因。就是英文的就第一节课的noble LM那时候大家都看到这个英文的这个TDS，就是文本转语音，这个效果确实很棒，比中文还是棒不少的。

然后下面这deep research的一些案例，今儿也要抄了，抄好多时间了。对，大家看啊第一个其实案例我觉得真是如果大家做出海的真的可以去试一下。这个是一个他拿deep research来去持续做SEO做投放的优化，他能这个效果能做到非常从零开始。而且他自己完全不懂这个叫什么，这个ICU投放到底是咋做的。

然后第二个他做了一个什么超过了150K价值的这么一个研究，脑垂体肿瘤研究的这么个医学研究这么一个成果。然后这个事儿其实应该我记得好像已经上了那个open I的它的官方的推荐或者奖励的那个里面，就是在医学领域研究里面，其实deep也是非常有用的。因为医学研究有非常多的绝对大概率不会是一次性的回答。对他

要不断的反思，不断的重复，然后不断的去推翻自己之前的结论，然后给出新的结论这样一个事儿。所以说白了你推的更越长，你考虑的可能因素越多越准。

然后什么制作恐怖游戏的细化什么的这些就有点像刚才那个，就是说我拿AI做了个游戏，我拿deep sig做了个游戏，然后他其实也是拿它生成代码，但是他的这个对差不多这样一个东西。然后每日定制的什么每日新闻报告，这个其实大家可以试试。比如关注什么领域，然后用deep research是让他每天给你发一个相关的报告，相关的这个领域的研究成果，就是有什么新东西。对，然后底下有几个什么学生生成论文，生成论文还真有可能。

之前萨卡纳a scientist这家公司还是在提一嘴，这个非常值得关注。萨卡纳AI这个公司的创始人是这个transformer的作者之一。Transformer大家知道这个就是大模型的最大家最现在来说最主流的一个结构。然后这个作者之一现在成立一个公司叫萨卡纳，在那AI在日本。

然后他前一段时间去年去年底做了一个项目叫AI scientist，是干啥呢？得得看一下就知道。这个东西就是从科研的点子生成、创新性检查，各种点子打分到做实验迭代乱七八糟东西就写paper，写论文，做论文的review。如果review说挂了再回来，再省心点的，再做的穿越性检查，再做实验，做实验迭代，最后能写出啥？看写出这样的配方，这个格式肯定没问题，很棒了。

甚至这个数据也是真的，图也是真的，然后代码也是真的，公式也是真的。对，而且它甚至会把每次迭代对应到的代码，你可以直接看到。第一次第一轮跑的一个结果，第二轮跑的结果，每一轮的实验用的数据都在里面。所以你其实你但凡每次答辩之前看看就知道，这个大概的问题就不多了。所以这个是当时当时还O一还没出来，推理模型的OE还没出来。所以O一出来以后，这个AI scientist这领域又往后发展了一步。

而且随着AI sense出现，国内也很多大厂，包括华为什么的也都做了这类的做科研的这样的一个A整体这样的一个东西。那这个领域我相信可能半年以后就会出现很高质量的paper生成这类的项目出来了。所以大家如果比如还在读书，或者说还在又读了个什么博士什么这样的一个，那真的可以关注一下，是不是可以用这类的agent来去增强自己去毕业的概率，或者说在这个研究的这样的一个深度。因为你但凡有了这么高效的一个东西，那你可能就不止做个工作了。你可以同时做八个工作，然后七个让A站帮你干你你核心就干那一个。对，然后底下有一些使用技巧什么，这些就先不说了。

然后另外一个我觉得特别有意思，这是前一段时间MIT发了一个叫day of AI这么一个东西，它是啥呢？就是针对所有的小孩儿，给出了一个其实是针对KK多少？我知道K12，他最高到了18岁了。然后我看看对，给出了所有的每一个阶段的老师教AI的话，应该可以教什么东西，这样的一系列的，包括课程大纲PPT什么都有啊。比如说这个educated guy的，对他都扔到google dock了。所以你只要克隆一份，你就可以拿到所有的教学大纲，PPT这些东西都能拿到。当然它都是英文的，但是刚刚说了这个翻译线确实做的很好，所以完全可以去做演示。

你看每一节课的课程大纲，然后这个是相关的视频对吧？PPT都做的非常好。他是这个是针对，反正有针对从很小从几岁到就小学一年级开始，然后一直到18岁，都有这个相关的课程，看看是不是能找到他那个大纲。所以大家如果有做教育领域的，真的是可以参考一下。

对，你看这儿，这个8到18岁，他都有对应的这个课程内容。你看从这儿从75到7岁的时候，这个AFO这个elementary这个叫什么？幼儿园或者是小学小学对，小学的有对应的内容。然后8到18岁各个课到最后到18岁的时候，他会告诉你说给你推荐一些你未来的这个职业方向什么的，他会给你一些有有这个相关的卡。

Career NN ai, -16到18岁的可以看到每节课的内容都很多，基本上都是一个一天或者说几儿几个小十个课时的这样一个内容。所以大家如果做AI领域的教育，尤其是做这种K12或者中小学的教育的话，这个内容非常好。只是大家需要把它翻译一下。

然后另外一个工具，这个叫I9。我记得有一次我分享的就是说这个AI工具去哪儿找我当时推荐的是叫AI是叫qualify这一个产品。我靠我的。不好玩吧。

好吧，对，处理fy这个产品，你可以在里面找到大量的。课程对吧？不是大量的这个工具。比如说这个干啥的有什么？你可以看这儿category，这个category就是各种类型的工具，能写文本的、做图像的、做做做做做video的、写代码的，乱七八糟的。

然后另一个很好的一个网站，就是怎么找到你想要的应用呢？工具的网站上叫there is an AI for that。就是有一个AI为了能干这个能干那个事儿，有一个能干那个事的AI这么一个网站。这个网站我觉得比刚才那个更更有意思一些。大家如果有什么问题，或者说大家想去干什么事的话，都可以在里面去找。甚至你可以这个问题可以是一个人话，而不用找。这个一定得是一个具体的功能的名字。对，这是一个挺好的一个网站，推荐大家去关注。

然后这个infor我们下周来讲整个deep seek，他大家看这个他其实在发第一天开源项目的时候，就起了一个新的开源仓库，叫做open info index。Index就是索引的意思，说白了就是他在第一天发布的时候就定掉了这次他连续开源的这个目标，就是他要做个开放的info，info就是基础设施，就是基础设施在大模型领域里面基本上就等同于GPU集群。他做的就是我要把GPU集群里面district为什么在能在这方面做的那么高效，那么优秀的这样的一些东西全给开源出来。你看它的这个关于这里面写的啥叫production tested，就是production，就是生产环境下验证过的AI infrastructure tooth就是AI的基础设施工具，包括什么推理的更快，训练的更快，让这个GPU空转的更少说啥呢？说这个更AGI的更有效的发展，更高效的发展，然后社区驱动的创新，对吧？

我记得第一次我讲的，虽然杨老村说这杨乐坤说这个deep seek是什么？开源对闭源的胜利。但是我说这是一个社区的胜利。为什么社区胜利？那就是社区驱动的创新这件事儿是成立的，所以这个是我们下次讲讲这几个项目到底是干啥的。这个现在第四天，应该还有一天。对，然后刚才提到benchmark，这个也是刚才说的，就是我们一定要关注奔驰码，为什么呢？

这个就是像这个，我记得好像也分享过，就是SWE ler这个benchmark，这里面是大量的看外包项目，就是那种自由职业者干了什么活，能赚多少钱这种外包平台。它里面真实的这个项目，这个里面内容都是还是挺困难的。所以总估值就是说你帮我干完这事儿，我给愿意给多少钱。把这些freeLancer自由职业者的这些工作，在这个奔驰里面的工作加起来值100万刀。这个值。但凡现在看到新的模型，比如像class 3.7，我看还没有公布它的SWE Lancer可能还没来得及测，但凡新的模型出现或者新的底层模型推理模型的更新，我估计后面都会要测这个东西。

这个就代表了一个什么呢？就是我们以前从第一节课也讲了，我们现在的很多大量的奔驰2，就是deep sick里面写的一些奔二都是科学领域的，或者说这个学术领域的奔驰2。MMOU什么这些东西都是学术类的。

奔驰这个东西我觉得它就对应到了我们现在要把这个大模型应用到生产领域里面，要用到赚钱领域里面。他的奔驰梦是啥？这个是最直接的对吧？这是一个价值。你但凡做个大模型，它能赚到多少钱，直接从这能看到。

所以我记得这儿有一个评估。那最高的是好像是cloud，对cod基本上看起黄的都是最高的，黄的就是class 3.5，但是3.7还没出来，然后3.5能达到47。那也就是说白了就是100万你能赚到47万，大概是这个意思然后当然不同类型的任务它的这个完成比例不一样，所以他按照这个不同类型的任务一一成，可能最后能得到个20万刀。就是你拿套3.5，能赚到20万到100万里面20万刀的工作。

然后另外一个，大家如果想去用部署大模型的话，可以看这个东西。就是这是一个哥们儿叫radio，我也不知道他叫啥。然后他做了一个各家模型的API的测试监控平台，你可以在这看到各家模型在这个叫什么。这个就说白了就是API快不快，有多快，然后每秒能输出多少token的TPS这样的一些值。那肯定绿的是最好的，红的是有问题的。

你可以在里面看到，大部分排在前面的全都叫silicon cloud，这就是硅基流动轨迹。流动就是一个模型托管的平台，它确实做牛逼。你看这个从食盐手头是，然后每秒输出的token的量都还是挺高的。然后大部分的那个红色当然也有silicon，也有轨迹流动的，你会看到很多各大模型厂商提供的API在直播，然后同意这些模型厂商提供的API其实性能往往不是那么好啊，kimi什么的都是它性能不好，不那么好，不如这种专业的做模型托管的平台好。当然这是很正常，这个有有术业有专攻但是大家如果去想去构建应用的时候，你肯定要找去一个提供的服务的质量，提供服务的这个价格，然后性能比较好的这样一个平台来用。所以大家可以去参考他的这个榜，所以这个也不是说模型能力，而是评测的是我到底模型托管平台质量怎么样。

最后有几个观点这个就先不说了，这个我们直接看一下。最后如果大家去想去做一些我领域应用的创业的话，可以去看这篇文章。这个是一个翻译，哪来的这篇文章呢？就是刚才我说那网站。There is an AI for that.

他们发的官方报告，2024年的AI工具的现状这么一个报告。然后你可以看到基本上去年的AI工具爆发在年底11月份开始，这个非常厉害。整个AI的工具的迭代也是在二三年就开始爆发的。然后各种类型的他他只统计了美国的，所以他他非中国的，所以这个大家也不要太完全信。

但是在品类上其实真的可以关注。比如说这个image类的是最多的，video类其次，然后campaign这种就是搞活动的，然后最欢迎的这一类的用AI的工具的任务是啥呢？你看聊天其实并不最高的，还是生成图片，生成视频，然后生成音乐其实也挺高的。然后他会有一些分析，比如说到底什么这个任务需求转化为工具是转化最高呢？这个图很有意思，大家可以去详细自己去看一下。

然后我记得好像有一个应用场景，看看能不能找到。你看他在娱乐学术方面都会有单独领域里面的一些搜索关键词的排序。所以大家如果想做出海的工具的话，这个是非常好的一个报告，可以去看一下。咦找不到那个了，你看这明显这个地图就是把中国排除了，可能他也拿不到数据，所以就不不不呈现了。对，这个是大家如果去想去做一些工具创业的话，真的可以关注这个东西。好，我今天分享就这些，确实差了，我下次调整，把这个内容精炼一些。

大家有啥问题？小平超时。

不是。

问题。我我我我有点后我有点后悔中间让你放开讲这事儿，我们还是要考虑一下这个课的成本。你刚开始上这个不太适应，那些老师就陪我们很久，那些老师都这个主要是成本问题，你像今天这样的内容，拆成两节课，其实问题也不大。虽然我们这个还是有一些情怀的这个课，但是也要考虑到性价比的问题。这样已经主要。

我我也我也讲哑了，我嗓子哑了。

这个可可以可以控制在1个小时到1个小时十分钟这样。小明这样因为因为今天因为今那个我我我我刚才一直在看着在线人数，基本上可能稍微有一点点波动。但是我觉得好像二百多人几乎没动过的，我给大家屁股都没挪的，然后就一直在这听到现在。

那我先调研一个，然后小明你挑一两个问题，因为今天的确有点晚了，你挑一两个问题，然后给大家答一下。你你因为这是我们第一次政客，我问一下这个节奏或者什么，大家觉得有用吗？就不说好不好，我不要求大家听得懂首先我非常感谢大家能来听这个课。我说实话这个课肯定难度是比较大的，你们觉得有用吗？我们保持这样的风格，我们保持这样的风格，保持一年，大家可以感觉一下自己能不能对自己的提高，没用的你们就打，没用。这个别客气，或者这个有点太分散了，或者哪个地方需要加强。那怎么着，我这课可以卖的更贵一点，反正人少是吧。然后你们感觉这个东西持续半年，持续三个月，大概可能是一个什么什么情况。

然后大家需要哪个地方可以更深一点，或者比如说我们找哪些专题，或者当然因为我们本身组织的一些线下的活动，正好趁着小明挑这个的事儿时候，我来跟大家沟通一下，的确有这个想法，就是因为刚开始我说这件事的时候，人来的比较少，因为我们觉得这个事儿我们想实用性更强一些，可能分行业。比如说像那个谁山东大汉他们做化工的，或者我们自己创业的，或者在政府机关，我们每一次可能约个七八个人。比如说都是街道的、乡镇的，都是我们做传统化工作，做做电力的，都是做教育的，都是做什么的，我们来互相启发一下，就是大家也这个问一些问题，当面的我觉得可以一天每次可以一天甚至大半天。这个看大家的时间，也看小平老师的时间，我觉得可以沟通的更充分一些，包括一些行业。因为有些东西可能不光是大家来提问题，然后小平老师来答，我觉得可能更重要的是通过这个过程，大家互相同一个行业里你想不到的别人想不到，而别人想到你也想不到，或者本来都想不到的，大家互相一起发就OK了。我们准备在北京看看有没有条件把它做成系列的。比如说两周一次，3周一次等等，一年搞个十次之类的。征求大家意见，大家可以反馈给客服，也可以在你们填那个表的时候填的更细一点，这样便于我们邀请。

当然邀请的免费，暂定邀请免费，不邀请的你们想来的那花钱。但是这种事说白了挣不了多少钱，大家知道我一个奸商，这种钱都是小钱了。然后小编来调解两个问题，这个听大家的。

我发现这玩意儿我没法再往上翻了，是吗？之前的不应该记录，我怎么翻不上去了，这是第一条消息吗？

你是点了左边的问吗？

还是我没点？

你看我你那应该有很多很多，对吧？

我在这儿了，对我插不上去了。然后我看看那个山东大汉是说那个那个机械设备那个什么是吧？

对对对，那那那个我们可以对。

我们可以单独一期会讲一下行业应用的时候会讲到这个。比如说我的设备的预维护，然后怎么用在设备御护这个安全检测，或者是啊比如说有一些零部件的损伤的识别。这些东西其实现在的这一代的模型都能做的比那种通用性更好。



我不能说它的比如说PCB版的这个质量检测，原来的PC预表就是那种电路板，它的有些损伤的话，那我靠一些机器视觉的算法是可以很精准的识别到的。但是现在的大多模态模型肯定做不到那么精准。但是你给他一些比较泛化的问题，让他说我整个PU板有没有一些什么虚焊，乱七八糟这些，或者说整个电路板有没有一些很没发现的问题，有可能有时候能识别到。当然其实就这个领域是不太适合用这种大模型了。但是像比如说电塔它的损伤，它有没有藤蔓爬上去或者一些什么。比如说你帮我识别一下这里面是不是有小偷，或者这个里面有没有一个人，这个看起来比较行动比较诡异。

先靠这波的语义的模型是可以在一定程度上识别到的。但是你想这种问题，你靠你想去训练一个专门的模型来去识别这些比较泛化的问题是非常难的。所以它更适合干这个事儿。然后后面我们找一个专门讲这个行业应用，行业解决方案，然后这个在工业生产里面可能会会对你有点用。什么课件和网页链接有没有更好的方式？

这个PDF我到时候会发给大家。这个里边其实大家看看，这些都是一些比较公开的信息的链接，不会太那啥。看PPT没有这个，你大家看看这PPT我就是文档，那可以发。然后我其实也是鼓励大家，刚才说，就比如说这篇文章我们你就去尝试去看。比如说我给自己定个时间，我半个小时看能看到哪儿是哪，我就把这个翻译开开能看到是吧？卡扫扫扫扫扫往后扫。你最好的方式其实就是一个字一个看看一遍看不懂再看一遍，看两三遍到时间就甭看了，就是这个不用太花费时间看着每个东西一定要完全理解，没必要。

A教育赋能AI，就刚才说这个项目挺好的，然后后面我们也可以，因为有一个drain，就是专门有一个领域就是专门的教育，所以我也持续在关注我们现在各种的大模型应用，哪些是在教育领域的那我们每次都会提到这个加一个tag，大模型部署实践方面，阿里可以讲的更深一点。部署实践，我觉得是这个问题，就是我们这个课其实并不是希望大家教大家我跑什么命令，然后把这个模型能跑起来多少张卡。然后这些其实你说讲肯定也能讲，但是我觉得不是对于咱们直播间里面大部分的这个同学有用的这个部分，这个我们可以单独是，甚至你其实找开放的这个搜一搜都能搜到非常多这方面的案例。或者你有没有什么很特殊的问题，单独有军工口的研讨会吗？看小说我咱们。

直播间有去过的朋友吗？我们回头线下说，这个东西没法线上说。我们跟一些智库有些合作，这个跟军工口的一些智库的确有一些合作，我只能说到这个程度，因为你们要注意，小平老师有一些涉密的东西，不要瞎问。

对对对，能不能把技术跟案例分块讲，一跳脑子就哼，我尽量，我但是我觉得其实技术跟案例都是应该绑在一块去聊的。你说我们还做了个什么什么cloud 3.7，他他单独讲这个技术没啥意思。你只有把它用到说我就在写代码，或者说我去访问我本地的这个代码库。怎么去根据这个代码库来去解一些艺术，解一些bug。这样的一些案例合在一起，才我觉得是更能串通的，针对一个主体去发散。

没太明白，不是很明白这个理论需不需要学习。我觉得这几个点都是应用有一个工具，有一个是否关是否需要关注大模型理论还是用就行了。相关的理论比如说transworld模型，注意力机制到底是个啥？这些东西我在课的过程中会持续会提到。但是我觉得其实没必要咱们专门去学这个，我去又刷没了。

对，不用，没必要去专门学这个东西。我觉得这个我会在我觉得需要大家去理解这些应用或者这些新的模型的时候，为什么？这个如果需要依赖的话，我会讲一讲，不会不用专门去学这些。完了，刷歪了，不知道哪去了。

对这课程的逻辑不是很清楚，最好有课程那个脑图我觉得这这也是一个比较大的一个差别。如果我们以一个特别清晰的价格来去讲这个东西的话，一般来说这个领域已经是比较定型了的，比较一个确定性的。像我们如果现在讲云，对吧？我们现在讲这个数据中心，那其实可以分条分缕析，讲的非常细。但是大模型领域真的是非常发展的非常快。所以我至少咱们这节课，我觉得这门课的主要的目的是希望大家能够持续跟进到一些最新的这

个模型也好，应用也好，范式也好。然后大家能持续的更新自己脑子里的一些想法和这些观点。所以我我我不太倾向于写PPT，而且PPT的形态我就是前两节课用PPT，然后后面其实我个人不太喜欢PPT这种形态。

听不太懂课下应该做啥，我觉得最最直接做法就是看那些文章，就是那个那个文本里这些文章，用开沉浸式翻译看啊这个多看就OK了，完全没必要做到说我每篇文章都能完全看懂，这个不完全没必要，一定要多好多那个多涉猎，多涉猎。对对对，还是用deep seek来去问问题，非常好。比如最近基本上我们现在在见客户或者去跟客户去聊的时候，我不懂的问题我就直接问问大模型，然后就自己就学了。

这是一个第一节我也讲了几个工具，这什么learn about这些，这些工具其实都是辅助大家能非常好的快速学习的东西。千万别怕，因为它它就是工具，它是个AI它又不是个老师，对吧？他你他也不嫌烦，那你也你也不用给他钱，那当然你要给他钱就用问的更好一点，房地产行业有没有合适的大模型？这个太泛了，就是我觉得这个包括第一节我们的有一个表，调查问卷，我建议大家可以去再填一下，就是把具体的痛点问题提出来。然后我们会帮你去分析说哪些业务场景，哪些环节，哪些痛点可能是可以被这一代的模型给提效的或者来去解决的。哪些是即使这一代模型也搞不定，是看不清英文，是不是给电脑上课？对，那我下次把这个字体变大点。

对，国家电网是高压操作机器人。对，但是大家可以想，那个那个机器人其实并不是这一代的基于大模型，就是我最开始发那个就比较泛的那一部分。那个极限不是这一代的这个技术来去做的那国家电网大概率还是传统的CV来去做的东西，就不是就是以这个为样式的这一类的模型，就是生活能够进入到日常生活中的机器人，他的脑子跟或者他的算法跟这个CV绝对不是一代就上一代，我们叫机器视觉CV不是一代的技术。

因为国家电网这种高压操作机器人，它是一个几乎是任务确定型的任务，就是流程确定型的任务。它是适合于用上一代的模型来去做的行业应用。里面有软件，看看啥意思，软件研发相关的有啊。刚才那几个框架或者那几个开源项目其实都可以去搞，就是都可以去用。如果大家对于软件开发相关的技术栈感兴趣的话，这个可以发一下，这个我们反馈一下，然后我们后面会增加更多的，比如说新的reg的技术，agent开发的技术，这都可以往里加鞋业制造，这个对，还是像刚才那个问题一样，就是能不能提的更具体一点。比如说当然我们不太了解这个鞋的制造的全流程，如果能简单的给我们去讲一下这个有哪些环节，然后哪些痛点。这样我觉得可能可以更肯定能给您一些建议，但不一定能搞定，但是这个建议肯定是能给到一些的。

房地产工程管理工程管理其实工程进度管理、风险管控这方面确实有很大的提升空间，或者说能用到这一代大模型的空间。这个我们是不是可以请到时找陈浩讲一讲一次，他在项目管理里面去怎么用的大模型的法律行业有啊我们的叫秘密，有一家公司叫幂律智能。这个基于的是我们的模型叫law power, law EI, 然后law GPT, 然后我们有一个法律大模型比赛。对，大家也可以看看这个在天池上也有一期天池上的比赛，然后也有一些不错的成果，大家可以去关注一下。

半导体测量缺陷。这半导体缺陷对这个具体是啥样，怎么测量的，我还真不知道。所以如果有更具体的信息图什么的，可以给我发了。

一下七层数。我这样，小明我打个岔，这样，很多朋友那个问题我看提的很具体。然后咱们是不是客服收集一下，因为已经马上十点了。我这样我统一问几个，大家能在屏幕上简单你们自己打打字，我们也看一下。

然后小明今天晚上第一个大家基本在什么行业？我我我大概打算的不要太多。你比如说这个政府机关，然后电力教育，然后外贸、电商，然后这个化工、建筑通讯等等等等。后台的小伙伴辛苦，大概你们去看一看今天的这个，你们大概统计个比例。这就粘出来之后，找个DS或者找个豆瓣一弄就行了。小美你看一看大概看一看金融等等等等政府机关。

我看到一个想的比较详细的什么HL我们我觉得这个我们收集一下，我觉得这还真挺好的。

对对对。

大概在什么代码现场审计，其实刚才那个cloud code那个项目里面有几个例子，就是做代码审计和代码测试生成什么。这个领域真的是发展非常快，所以就是差个话题，大家如果有有孩子或者什么的要去新进入这个软件工程开发领域的话，我觉得可以考虑一下，就是别卷了。这个如果是做AI或者做算法，那那做数学，做物理那那没问题，可以继续去搞。但是代码开发其实这个领域会有一个特别大的收缩。

我我再问一个问题我再问一个问题，大家现在已经对人工智能大概的了解，你们自己对自己的评价，你比如说大家觉得现在精通，那我就是奔着前沿的来听的了。然后这初步的了解，或者叫一无所知，大概就这么三个段位，精通的，或者叫精通熟悉了解一无所知。辛苦，我们因为今天咱们人少，我觉得相关的课程可以做的更有的方式一些。你就按照按按照我说初步了解那个一无所知，然后精通然后熟悉精通就这四个。小明你大概看一下，你这个我觉得我估计能到熟悉的已经很少。

我也刷不过来休息了。

熟悉有有精通的吗？没有什么熟悉，的确是啊。

了解。

的和一无所知是不是一半一半打呗。要了解工作，工作里能用。

高级。

搜索应用。那就这么说，了解就是现在能搜索的能用的就叫了解。然后熟悉就是你们已经能用大模型，在工作中已经实现了局部的效率提升。除了搜索之外，比如说你们能做出一些小场景来等等的。精通自己在这边也有研究的，然后这甚至探索一些前沿的一无所知大模型是个啥主题？小李，你看一下大概这个状态。

好。尽量附上中文，有一些难，我尽量。但是这个领域其实会有很多的新的概念或者新的词，其实还没有中文。然后我也希望大家能够更多的去接触最新的内容。对有很多概念其实还是英文为主。那那大家看看多看几遍，至少眼熟那些词儿，我觉得这个也会有一些帮助。待会儿我会用中文说。

我给大家提一条，就刚才你们提这个问题，我建议大家先在工具上解决问题。这两次课里小平都提到了这个翻译相关的一些大模型，你去试一试对吧？看paper的看这些看看这个论文的这些东西，你们都去试一试。然后因为没有办法，就我这么说，我们必须承认人工智能这个领域海外还是美国还是走的更快了一些，我们要追上，甚至国内的一些动作。就这么说，你们看到今天美国有的可能就是明天我们有的，所以这些地方大量的文献，我这小心今天已经很那什么了。我们私下里聊的时候，他们和昌浩基本上看到所有的文献都是英文的。这个我就已经是抽象的简化了出来很多东西了，好吧？

主要是出实在太方便了，这个还是对大家都可以放对，就用这个方案来看。

然后小明我觉得这样，小平你看有没有可能？然后下节课的时候，你让那个那个。

一不是我觉得。

你看有没有可能让咱们的客服或者东篱做一个简单的常用工具的对照表。大家觉得这个行吗？简单的你比如说翻译的建议用哪个，我写作的建议用哪个，这个搜索的可能哪个，或者说某些场景。因为今天我看了一下大家这里面我刚才看到有个精通的，然后我就简单的做个表，然后这样能够加速的入门。因为我还是想这个工作能咱们还是有一些实际效果，尤其是基本上我就是大部分都是了解和这个一无所知然后这样的话可能对大家有点帮助，因为可能咱们不有些朋友是听了5节课，说这个东西其实讲过三遍了，突然想起来，但是我们还是形成一些积累可能更好，好吧。

从哪要表？在路上你都精通了，你还需要从哪要表吗？下一次上课的时候，因为我们现在正在建客服体系，如果有了的话，我们可能就给大家群发或者怎么样。没有的话，下次比如说让小强做一些PPT，然后你们截个图什么自己去找好吧？

好。

然后我最后一个问题，目前这个课你们觉得是自己坚持不下来的，就走个半途而废，大家觉得能坚持的走，我坚持。我最后一个问题，是否有客户家我刚才说了，我们可能会组织一些线下活动，有朋友说说不在北京怎么办？那只能你来了，我听一天我这么说，小平同学，小明你现在出去一天多少？十万是吗？差不多，5到10万。我我我你不用，我知道你比较含蓄，但我知道你的那个报价，就是我能给小平拉出来一天。正常情况下去大企业培训就5到10万。我相信咱们直播间里已经有有朋友接触过了，我能给他请出来，然后你们就掏上路费钱就得了。

很多网友说这个就不在北京，不在北京你说怎么办？这个我不能拉着小平，真的大家理解。的确小平同志平时非常忙的，我不能让他每周末出去飞一圈。我的天啊，我问你脖子也受不了。

是这还有一个夸小四的。

就是偶尔有一个夸我。

这个非常有意义，未来不可估量。

有点难度？说咬牙坚持，咬牙坚持，一定坚持，咬咬牙，那同志们就行。小明这样，要不咱今天这样，然后我觉得这个事的客服，咱们那边能不能准备个朋友，以后每次客服结束的时候来收一下。你比如说这个怎么联系客服，然后填表要怎么去详细一些。这个要不是你说一下，或者说谁以后东篱谁来说一下还是怎么着。

我们每次要不就就把之前那个表再发一下，然后过程之后我们也持续的能放到一个角，有什么问题就都在那儿，大家就扫，然后就是比较详细的，比如说产业的这个具体的业务中的一些问题，就扫那个东西。OKOK尽量把这个问题都能cover住。然后现在的这个太多了，确实是在讨论区里这么翻，很容易错过一些比较对我。

觉得我觉得不行，你让他们回头整理一下。然后可能比如说下节课我们1个小时课里头，我们留出我们挑一两个典型的问题，留出个十分钟，把上节课大家的留的一些比较好的问题，我们答上一两个，类似这样，因为现

在人少还能答得过来。是啊，这个确实赖我卖的不好，这个如果卖的好的话，可能有可能打不过来。好吧？这个课我这么说，给大家布置个小作业，如果你觉得有价值或者好的话，买方之圈、首席之圈大家不用帮我推广，那个课是有风险的。

我从来我已经卖课卖到第四年了，从来没让大家去发过朋友圈或者怎么样。但是如果这个课你们想推广的话，积极鼓励，欢迎这个积极鼓励欢迎好吧。如有些其他的买房手机什么的，我不需要带单。我真的从来没让你们发过朋友圈，从来没让你们干嘛这个叫叫叫叫拉个群或者怎么样。但是如果大家愿意帮我推广的话，我特别欢迎，特别鼓励。这个真的是这样的。因为我觉得这是啊？那那刻我就是一钱串子，这课我觉得我正儿八经在做好事儿，虽然有些朋友觉得那个课那堂课我做的也还可以，但是这个正是正儿八经我自己的情怀，在这儿好吧。

然后那个那个在线的文档，小明我觉得这样刚才这个朋友其实提的特别好。因为既然我们聊人工智能，是不是你也可以考虑让昌浩他们针对这个课，用人工智能的一些工具和软件给大家搭一些，或者说本身就有一些现成的一些收集问题的方式或者怎么样的。我们也找个地方这样同志们这个课的确在不断的完善，比如说这个课的一些有些公开信息，我们是不是回头可以拉个什么的知识星球，我们再加个痣星球，把一些内容往里放一放等等，我们也在讨论好吧，这个事儿咱们随时跟进，给我们点时间，因为上的非常仓促。

的确春节前后这段时间我事儿太多了，这个大家理解这是我的问题我的问题。小明老师和张老师都是非常的积极在这方面，好吧？小明要不同同志们今天咱们的课这样，还是我们暂定以后每周四晚上八点，辛苦冯老师来在每次来跟我们分享一下。然后小明下节课注意时长，注意时长。我你这样整的话，我就觉得这卖便宜了，这个就很我很难，现在这个本来卖的不好，你说让我还觉得卖便宜了什么，这事咋办？好吧，王主任给大家这样还是按照其他课的惯例，给大家留出一分钟的时间，对小平老师今天晚上精彩的分享表示也感谢。小明再给我们总结两句，鼓鼓劲儿什么之类的对。

这个就是业绩。对这节课其实希望大家了解的就是整个AI行业，不要只盯着一些具体的工具，具体的模型我们就能看到更大的这样一个比较相对来说比较全景的内容。然后那对于以后我们甭管是工作，还是我们自己去创业，还是我们怎么看待投资领域，其实都会有帮助的。所以今天这个目的我希望大家我希望一定程度能达到。然后后面我们每节课都会不断的来去重复，我觉得希望大家都能达到一个比较好的持续学习，持续的提升的认知。

OK同志们，今天晚上咱们这次就算第一堂正式的AI直播课，然后就到这儿。当然如果大家有一些朋友已经有我们的买方首席的话，可以回看啊。如果你要推荐给别人的话，回看过去两周四的试讲课，我觉得其实今天这个课我能明显，我不知道大家什么感觉，我能明显的感觉到小平老师其实是非常用心的，而且是希望通过这个课逐渐形成一些体系化，帮助大家形成积累的，包括中间的表格等等。当然讲技术我也讲明白，只能讲讲这个了。这个也希望大家能够咬咬牙，我给我自己定的目标是3到6个月的时间能够跟上，能够适应，能够去主动的产生一些对本行业的一些或者我正在从事事儿的一些想法。也希望大家在夏天到来的时候，我们穿的比较凉快的时候，能有至少直播间里有十个八个朋友，对你的原有的行业真的真经过一些深入的思考。

这个为什么不太着急说把大家拉过来，这个怎么样？我们觉得但还是需要一些初步的了解和深入的思考，能真的带着一些有价值的需求和问题，然后咱们真的好好的讨论。当然我们那个活动会尽快组织。但只是希望大家能对自己那个行业的思考更深入些小明老师提到了很多工具，我们下节课会给大家拉个单子，然后一点点往上补。

当然今天如果记住的话，或者大家通过回看能看到的话，也希望大家有条件的自己去试一试，尤其是大家觉得可能跟自己相关的。对一个新的未知的领域，有的时候我们只能抱着吃螃蟹的心态再往前踩一脚。好吧？同志们，尽量我已经把两个人可能用到这，感谢请指教，感谢请指教。小明要不接着先这样，我得接着卖身去了。好好，同学们再见，拜拜。小明辛苦了，辛苦，拜拜拜拜。

