

开始了是吧。

屏幕看到是吧？好。

能看到了是吧？可以了是吧。OK8点了，八点了，这样我开个头。张浩你是今天可以待到最后吗？

我可以待到九点。

你可以待到九点是吧？现在就行啊啊啊有问题，你们再正好都看一看。然后唐主任咱就不等了，八点了已经。我我我开始之前，正好咱们我会能这个点准点来的。这些都是属于能来这个课的，都是咱们多年的铁粉，能准点来的都是铁粉，能铁粉了。

我我我咨询一个事儿，就是上一节课讲完了之后，尤其是我估计很多朋友回去看了不止一遍。上一节课刚讲完了之后，大家是不是有没有明显的感觉比两次试讲，其实这个效果更好一些，或者说大家接受起来，或者这个体系大家就是更OK一些。你们是有这种感觉吗？如果第一次就是我们一共三次课，上次是正课，然后两次试讲大家稍微给我个反馈，我做个小调查，然后咱们今天马上开始。如果比如说我们就在上一次这个基础上，第一节效果就第一节那是那看来你是绝对是高手，那就是要求最深入的内容是吧？那大家就是希望那种最深入的是吗？我估计最深入的绝大多数朋友可能接受不了。

好些了是吧？

有点没那么有点像第一次最抽象？进入大家讲，对，第一节第三节更了。对，你为什么感觉第一节更好一点？因为咱们人少了，我觉得这个事儿可以聊的更充分一些，因为我是想这样，我们的根本目的还是希望大家能够原来我说过这个课，我也不知道这个课能到一个什么样的状态。我们还是希望通过这个课，能让很多传统行业的朋友真的能够跟上人工智能的变化。然后你不管是自己管理企业也好，还是在政府机关，还是在大企业也好。真的能够结合着人工智能在你所在的岗位上，甚至对你的公司能够未来有一些比较大的帮助。我们希望通过一两年磨，能磨出几十位朋友来就不错了。

好吧，这样咱们再我觉得咱们再磨合上个一一两节课，我和我我也在考虑是不是要让小平老师再再再再再在公益再试讲一次，再体会行吧？然后第三节有点乱，OKOK那那咱们再磨一磨，咱们再磨一磨，这个事也感谢大家了。来花了钱来给我们这儿当小白鼠，我就正式开始了。然后今天晚上主讲人肯定还是小平老师，然后其他的几个同学，因为我们也要不断的去调整这个课程的授课方式和内容。当然已经预告过了，今天有很重要的内容大家也都看到了，这个我就不啰嗦了。这个课我就强调两点。第一个来的朋友都知道，这个课跟股市一毛钱关系都没有，大家不就不用在这个直播间里再提哪只股票或者怎么样了。第二个，这也不是说听完了之后做个PPT或者说是改个图片，我们还是希望把最前沿的一些技术和应用带给大家。

今天的主讲人还是清华智谱生态创新的负责人冯小平老师。他们的主要任务就是盯住前沿技术、前沿应用，能把一些最新的变化带给大家。也希望通过长期的积累，能让大家对人工智能无论是从认知上还是技术上，还是产品上有更好的理解。对大家的平时真正的大部分的这种工作展开有帮助。好吧？然后小明我就不啰嗦了，今天晚上你放开讲，这个课没有时间限制，你愿意多讲会儿就多讲一会儿，当然也不用讲太多，讲讲长了之后，课前就得咱就得再讨论一下了，要不要再加钱了，好吧？辛苦。小平，那那我我先贵你开始。

好好，我靠，刚刚看了一个时候听了老师充了Monica会员，今天出了minus。对，其实有另外一个有一个同事也在跟我说，其实他们之前对Monica的认知其实都不太一样，这个都有点偏。然后这次他出了个menus，

觉得开始要反思了，为什么自己的之前的这个认知是这样的对，所以还是总的来说大家可以看到整个因为随着技术发展这么快，大家不无论是什么样的人，他的大家的认知都会变。对。

所以好，今天我们来这儿，因为我看这个大家对第一节课，第二节反正大家有不同的观点。然后第一节课我自己感觉其实更多偏这种比较抽象一点，偏虚一点，偏概念上一些东西。但是这个东西不是所有的人肯定不是所有人都都适合的。所以大家有没有什么有有任何的想法或者反馈，都很欢迎像像刚才小斯说的这个都反馈给我们。然后大家想听到的什么类型的内容也反思，也反馈一下给我们。

但是我觉得还是我们最开始说这节课的目标，就是我们要跟进最新的东西。那跟着的这些跟的是啥？我觉得不是，像比如说有没有邀请码这些东西，当然如果我们能测，那当然最好给大家现场玩一。但是不能的话，我觉得希望给大家带来一些更更底层的，更背后的一些观点和一些技术的概念。

当然我知道咱们现在在座的有有技术的，有商业的，有各种类型的同学，所以可能很难，这个就反正众口难调。好，我们今天到第一个部分就是对大家有什么问题的话，就随时发到里面。我看有一个按钮，就是把那个问扣上，把那个勾上那个东西就这个这个玩意儿就可以问的问题的时候能这个话会带着一个号，那个标那个比较好啊。

那我放出来，今天我会把一些重点的问题记下来。

你可以先那你帮我盯着点。好嘞好。

对我来把一些有价值的进去。

好好，我看很多人其实都说了这个minus。这个东西最近今天其实就是今天又又火出圈了，又感觉又来了另一个deep thick时刻。我总的来说第一个来说，这个肯定不是什么deep seek时刻这种级别的东西，这个还是比比deep thick这种级别的还是弱很多的。它更多的是一个在产品形态，在工程上的一些进步。但是他其实有一个很大的问题，他其实没有什么开放什么内容，就是他没有开放出来他背后的任何的几乎一点点的这个工程上他们的实践的经验。只大家只能看到他的这个官方的视频，这个大家可以看一下，这个我就不详细带了，我就直接到这个部分。

Fusing through each, 这个是一个什么看简历的什么东西？就我这20个简历，然后我让他挨个一挨挨个给我去分析，他是不是跟比如说跟强化学习相关的，这样的一些东西让他去跑，大家看整个过程。When everything is complete, of course you can also give structures. 左边这个东西就是一大堆他边聊边做的这样一个类似于行动的一个指南，或者是行动的一个报告这个东西右边就是他实际干活的这个空间。

比如说你看这有一个挺有意思一个东西，这个是我第一次见到这么做的。这个玩意儿叫他有建了一个文件，叫to do点MD。MD这个事儿大家这个文件扩展名大家以后肯定会常听到，叫markdown这种语法就是像这样，你看这样的语法，它是一种纯文本的，但是带语法的这样的一种这种格式。然后你看一个井号后面就代表了一级标题，两个井号二级标题。这玩意儿就是一个杠一个括号，就代表了是一个可以点的那个to do的那个那个一个一个一行，就代表那么个东西叉掉就是代表做完了。所以他是第一个是这样说，他把要做的各种的事儿，都把它写到了一个MD那个文件里。然后坐一会儿看看这文件哪些搞完了，把它勾上，做一会儿再回来看看这个文件哪些搞完了勾上。大家有记得我应该是第一次还是第二次。

讲这个的时候用到了密塔搜索的这个功能。大家看到最开始其实就是拿r one他干啥呢？他把它拆解成很多步骤，然后挨个去干，最后内容再拿2万再输出一下出来。所以这个做法是一个很标准的做法，就是我开始先把

任务给我猜这个事儿应该怎么去做，这个事儿给规划出来，然后把它弄到一个to do。

而区别就是他把这个土杜寄到了一个他的工作的空间里面的一个文件里。因为确实他是拿一个所谓的叫沙盒的东西来去办做的，所以在沙盒里面，大家就理解成是一个一个工作，就是一个电脑在一个电脑上面完成，甚至多个电脑来完成。那他这时候干活的时候，肯定要记说我先干一大杠2、大杠3。这些记在哪儿？肯定记在文件里是最朴素的一个想法，所以他这么做的，但是把它放到文件里，我就是第一次在这么做，挺有意思。然后边做边搞这个东西，然后我觉得这个产品最惊艳大家，或者说大家最传播最多的，其实这个东西就是叫use case gallery。Use case就是这个使用范例，或者这个使用场景的这样的一些。你会看到它比传统那些，所以我们叫broader use，或者叫computer use。

就是用电脑，用浏览器的这类的工具有一个很也不叫很大，就是一个比较大的差别就是它几乎涵盖了非常多的场景。比如说做研究的，你看这个B2B的这个叫什么供supplier的寻找这种供应商，然后列出什么YC的公司们这些。然后做就日常生活，比如说你要去一趟日本，然后做一个规划，然后分深度的分析特斯拉的股价，然后买在纽约买个房子这些东西，然后数据分析也很多，教育也很多。

所以他相对来说比较震惊的就是也不叫震惊，就是让大家觉得很很出圈的就是他认为他自己号称是一个通用的agent，是一个可以帮你干任何事情的一个agent。你看所以他说叫handle real world tasks，处理真实世界的任务。但是这事儿其实也不是他第一个提出来的，后面其实就会讲就是当时的deep research，就是open I这个deep research这篇文章他其实说的就是他说deep research本身一个很大的一个方向，就是我要去做各种类型的事情。

打不开，待会儿。对，所以这个也不是他专门的一个很大的特点，只是说好像它它的展示出来的case都挺不错的，确实是啊，大家即使没有邀请号也可以点进去。你可以点进去看啥呢？就看这个东西，你就点进去发现它的，可以帮你复现整个过程，重播整个过程哟。怎么办？对。待会儿再看吧，那等他搂露出来了。对，你看，等你问个问题，然后他就会，我去又刷新了，不管了，待会儿再看吧。然后这个产品本身是Monica做的，我基本上会把这个首页全都讲了，所以大家不用担心漏哪一块。

这个Monica AI做的，所以这个第一次课还是第二次课，也推荐给大家过的这个产品。这个东西就点一个插件，然后他就能干各种事儿。最开始其实就是一你可以在这儿切各种模型，可以用随使用各种大模型的这样的一个check out。而且它在插件里面好处是可以干这事儿。你可以直接选这个chat with this page，就是用跟这个网页去聊天，这样的话你就很方便。不用说单独再把网页的内容call过去，call到另一个APP里面去干这些事儿就很方便。

但是后来他就加了一系列的功能。你看这个image是有生成图片的、生成视频的、生成音频的，甚至还有这个AI podcast对吧？就第一期，应该是第一期。给大家讲的说可以直接去拿一篇文章生成一个博客。他其实也是支持这能力的，但是音质挺一般的，所以大家如果用肯定还是推荐用新流那个产品。

对，然后这家公司大家可以看到，他开始是做这个的，而且它的产品其实不便宜，它的费用应该是一年，当时打折了才还得一百多刀一年。然后你想他做这个事儿做了很长时间了，那他肯定是对整个浏览器，或者对你但凡在哪个页面打开了这个插件，他其实理论上就都能拿到你当前在这个页面里干啥了的这样一些数据，就点了什么，写了什么，什么什么乱七八糟的他都能拿到。那也就意味着其实他已经有了一波数据，说你在浏览器里干各种的任务的时候，你的行动轨迹到底是什么样的，这样的一堆数据。所以Monica这家公司做出这个menus这个产品其实是不不不惊价的，不令人奇怪的。但是这个产品确实这个团队做的很好，所以这个产品的形态挺不错的。

这minus它据说是拉丁语的手实践这样的一个翻译。这块儿其实就引出另一个词儿，就是另一个事儿，我们最近其实也有很多产品在命名，大家在征集怎么去怎么叫什么名儿。然后我突然间看到这个，然后有一个想法，因为确实拉丁语在有些词里面，就是你但凡你的产品名是个拉丁文，这个就觉得挺装逼的。所以你其实可以用这样一个事儿，就是拉丁语中什么叉叉是什么意思？比如说你要做一个什么产品，比如说你说这个给女性用的，某些女性用的，你比如说嫉妒，嫉妒是什么？对，然后你就可以看看是不是有这样的，但是这种其实不需要用2Y，直接用它官方的这个模型就可以了，我们就把它停掉。没。刚说他产品做的不错。

它是不是官方就是RY？

不是，它是一个小一点的模型，挺小的模型，所以它一般的响应速度都挺快的。直接来这个。

那不管了，就这样吧。OK所以这个我觉得其实挺有意思。你去做自己的一个产品的时候，现在这种拿它来去拿拉丁文来去叫这个挺有意思，一般来说都挺好的。然后简单来说，minus可以认为是一种deep research加open Operator。这个应该也有一次给大家讲过这个产品，对吧？我觉得是不是Monica挂了？

已经开启。刚才你那个你点的不对。

一点都不对，是吗？

你再回到那个界面。

下面这吗？

对，下面的都都不是这个不是的。下面左下面左下角，下面那个外边你看到了吗？对，这个地方刚才你在规划，这不是捞了。

个source吗？

你先他现在你先不选外GPT4O你把改成把GP4O先改回去，改成它。

然后再下OK，好，它不同的模型我。

厉害。

没事。

本来有个助教还是很有价值的，是吧？

OK, 然后大家看了刚才大概扫了一眼，那是怎么个意思？其实基本上就这几个东西，deep research也是open I的这个东西，然后加上Operator oper。删那个操作它浏览器的那个产品，虽然这还没火，确实没火，而且发了一段时间了。所以我觉得核心原因还是因为太贵，那玩意儿只能-200刀的那帮用户才能用。

然后另外一个，其实是结合了这个东西，computer use是anthropic的去年年底发的一个产品叫computer use特别直对吧？这个翻译的特别直，那它是个啥呢？你可以看一下，就大概就知道了。

大家记得这个and rock c这家公司是以什么著名的？就是写代码好，对吧？它的cloud模型是写代码好，所以他做了一个东西，比如说你要让他做这么一件事儿。

然后他就左边就不断的来先思考说我应该干嘛，然后再干嘛。先干一件事情，要截个图，然后继续，然后在干嘛呢？你看这把自己的光标挪到哪儿左点一下再截图。这就完全都自动实现，自动完成的这样一个工作。然后又干嘛又点又左移动到哪儿，在左点在screen上其实就很像。所以当时叫computer use这样一个产品就是干的一件事情的。但是当时因为核心cloud的这个产品本身就是一个主要面向程序员的这样一个产品，所以这个东西也没火起来所以现在看的minus更像是这样几个产品的一个综合体。就是它又会持续的research，还记得上次讲那个gina那个API它的那个示意图，然后又操作浏览器，从这个整个过程中你会看到它基本上操作的东西都是比如这个是浏览器对吧？

然后还有啥，我看看这个程序员同事知道。程序员同学肯定知道这玩意儿就是个这是编辑器，然后有shell，有那个命令行，有文档，有命令行。对，所以它其实操作的右边的这个工具就这么几个，并没有说我随便打开一个电脑，打开一个什么微信，打开一个微信看朋友圈乱七八糟这些东西。其实并没有这样的一些工具，所以说白了它还是停留在anthropic的那个computer use的那个级别的，是工具使用的一个能力上。

大家知道最开始一节就大家跟大家说了，我们看大模型一定得从能力的角度来去看。那现在为什么他现在做到这个程度呢？那大概率说明现在的模型能做到的程度也还只是这种级别的内容的工具操作，就这种工具级别的工具的这个操作上，在在纯这个本地应用其实还是有很大的问题的。

然后另外一个直接看，其实就刚才说的这个它的各种场景，你看这个还是回到刚才那个他的这个做的很好，就是整个的回溯过程，你会看到他每一步在干啥，然后做了什么事情，然后他为什么要做这件事情，然后他都会做一做。你看又回来看那个图镀了，干完了这个事儿check一下，再看下一个事儿。就跟个人的这个操作行为非常像，几乎就没什么差别。

然后另一个就是这个use case，我觉得这个use case是做的挺挺漂亮的。基本上在里面看到能看到大部分大家在网上去宣传的或者分享的这种关于agent能够在什么场景使用的这样的一些例子都在里面有。所以大家非常强烈建议就是去看一下，看自己感兴趣的那个场景。

然后看什么呢？你就看左边这个内容是不是你日常干这些活时候的这样的一个顺序，当然待会儿会有一个文档，就是说其实也不能这个产品也不那么好，有很多的原因，其中有一个核心原因就是模型不够好。然后我们再回到首页去看这个，它其实这个网页也很简单，他们一个产品就很简单，这个秀一个case，然后一堆show case，然后底下有一个奔串。

还记得我第二节，好像是还是第姐讲过，就是我们一定要关注新的benchmark，为啥呢？现在的benchmark已经不是我们传统意义上的最开始讲那种什么美国第一任总统是谁啊这些东西了，而是很实际的，而且是人人都很难干成的这样的一些任务。然后现在我们把它列成一堆bench bar来去让大模型来去干。然后我们一定要关注bench 2的原因就是一是我知道到底现在模型到什么程度了，那怎么知道呢？我就看这些奔驰mark这些模型到底跑分跑多少。

盖娅这个benchmark是很有名的一个benchmark。它其实之前一次露面大露面还是deep research里面，他们做了一个等他的这个评测，就放了两个半圈。你看这一个叫humanity，就是人类人性的最后测试，人类的最后测试。然后另外一个就是咖喱这样一个测试。然后大概你可以从这里面看到，比如说就是他给了几个例子，什么叫嘎测试，就跟咱们第一次讲的时候，我们除了看benchmark的名，还得看里面到底是啥。

基本上我们看一下这个还有很有三个级别，有level 1233个级别的这个难度的任务。我们把它翻译一下，你看在一二年的自然杂志科技报告会议上，未提及等离子体或等离子学的文章中研究了哪些纳米化合物。然后如果包答案中包括纳米前缀，请省略。对，就是纳米化合物。然后它不要让那个前有有纳米这个前缀prefix，这种就是level一级别的任务。你想想如果这是你让一个你的实习生干，那大概率我觉得怎么着他得可以干个两三个小时一两个小时比较快一点。

然后那level 2看看，都是傻了。就是在这个在在这个什么书籍的第11页倒数第二段北角的角度中，VK bdi文章是哪一个？什么什么第十一。11月的时候，哪一天访问的，只给出月份的日期。相对来说，因为它有很多的上下文，所以相对来说会难一些。然后你看右边，他其实希望的就是这样的一些一步一步的行动，然后行动再观察然后再行动再观察再行动这样一个过程。

我们可以看level三级别的，其实肯定是比较复杂了，你可以看到是这种级别的问题。什么59年7月2日，美国关于什么各种水果蔬菜的加工等级，什么冷冻，什么乱七八糟这些东西，反正我看着我看到中间我就不想看了。这个实在是挺挺麻烦的一个任务，就是但凡扔给我，我可能得干一天这样的任务。所以这是level三级别的这种叫扎眼级别的问题。

好，那之前的所谓的最强的模型能做到什么程度呢？一般我们就称为叫sota，state of the art就是最强的模型，之前的sota level 123都分别是67、42分。好，deep research，大家注意，我第一次讲dipt sick的时候就说到这个事儿。你的benchmark后面其实会带着这个东西的，带着怎么去玩的，怎么测的。你看past one大家应该还记得，这个就是一次过，这应该是自我一致性，一致性64就是跑64 4次这个一致性最高的这种答案。然后基本上都在60 60多分左右，level 3其实最高也就到56 58分这样一个级别。

那manus现在称自己能做到多少？我看看对，57 level三级别的，然后level一能做到86分。所以说白了就是相对简单一点的任务，它能做的比之前好很多，比deep research好很多。

我们回去看看这个在level一级别的都撑死了78分，它是能做到86分。然后level 2差不太多，level 3 57其实跟这个对，也还是挺强的对，就是比这个帕特万的话还是强不少的对，所以从这个盖娅的奔驰可以看出，manuals这一套东西还是挺强的那他到底是啥呢？其实现在没有公开任何东西，我们就只能去做一些猜测。我们看看这个，这个是对我正好大家看一下这个东西，就是研报这个东西，其实有很多特别水的东西。你看这个东西今天刚发出来，然后华泰就出了个研报，然后就号称这个什么agent的ChatGPT时刻。那看这个名儿大概率就知道是一个特别火的一个报。

我们先刷刷一下那个律师函。

啊啊啊有这问题吗？就是我们看一下某太的这个研报，然后他说全球首个通用agent，OK勉强可以这么定义了，然后放了个它官方的这个说明，又放了gallery use case，又放了个评测。就是我觉得这话就是deep sik生成都比较好啊，然后这个基础架构没有哼对吧？你看这个或是技术迭代的集大成者，不管了，他说可能后续会开源部分东西，那没啥内容，然后介绍他的创始人经历，然后就开始说agent了，没了，基本上后面就没有minus东西了，所以这个某泰真的是某华，不是华某，真的是有点水这片。然后我们看一下，这个是另外一个朋友发给我的一个内容，我觉得这个还挺有意思，我要倒下来。

对，你看一下，这个是之前有人去测试以后的一个一些反馈，然后能看到这个屏幕我不知道这个对，非常好的工厂能力，确实是啊大家看这个整个的尤其是这个replay的部分，就是这个产这个界面确实是我觉得可能devin也就这样吧，devin我觉得至少在右边都没有这个好啊，就没有这个丰富。然后这个产品确实做的也挺漂亮。然后A正运行在虚拟机，啥意思呢？就是右边的这个部分，它是跑在大家刚刚看到有很多网页浏览乱七八糟这些行为，它是跑在一个虚拟机里面的。这个虚拟机里面会有一些标准的工具，比如说浏览器，命令行这些东西，他A朕想在里面操作就可以在里面操作。好处是他不会碰你的本身这个宿主电脑。说白了，比如说我在这边写帮我删除所有的文件，他要在那边直接在我电脑里操作，那我不就废了。所以他在右边那个部分操作的肯定在一个所谓的沙盒里面去操作。所以这个东西做虚拟机也很正常，can be use之前说的cloud也是这么做的。

然后他用右边的这个虚拟机里的一些文件来保持所谓的上下文，就是像刚才那个to do什么，这些都算是过程的上下文。然后授权模型能力，然后只基本上他认为是只能看基本不能用的长度。然后他会有一些很有意思的观察，就是他说这个planning做的不好，这个存在因果错误。就是他看到这个to do的这个MD里面会发现有些问题，而且planning它的问题是很大的一个严重的问题。就是右边那个图度是不会变的。你一开始规定好了我的要做什么事儿，他就一股脑的就一直做，他不会去持续观察这个有什么变化以后再去回来修改to do这个是一个很硬的硬伤然后这儿再说，下面就说什么有一些模型知道从哪拿信息，可惜幻觉了这个幻觉了HDMAHML代码的结构，然后用模型的记忆兜底，然后他啥呢？

就是他要去查特斯拉的领导层，就是叫什么leadership的这帮人到底是谁？你到底谁？然后他写了一段代码好，然后结果没抓到，他就手动添加了特斯拉的一些关键的leadership，这玩意儿是你看as a full back就是他没抓到，那只能干嘛呢？只能靠模型的记忆添加，添加了什么马斯克CEO乱七八糟这些东西，其实很这就很尴尬了。如果你的任务是一个这种信息很关键的这样一个任务，那你这样一个幻觉下来，他其实我觉得都不叫幻觉。就是他并没有把这种任务里面很关键的任务识别到。是如果识别到的话，即使说我临时网页抓不到，也不应该for back回模型本身的这样一个记忆里面去。

然后那你不觉得这有可能是模型。

的一种能力吗？

对，是的，就是它的模型并没有把土豆给判断的有优先级，或者是哪些是necessary一定要这么完成的。它只是不，我是想让他们完成。

对写一段代码，然后代码没跑通，然后我就直接那个leadership里面把内容直接写进去。

你不你说这是个能力是吧？对我觉得这是一种这是个好的话能力是吧？对对对，我觉得这肯定是个好牛马能力就非常不容易，对这件事情对模型。

自己不多余了。有的朋友说其实我也想说这一点就是他会非常取巧的摸鱼，而且。

查不出来。

对，这就跟你的公司里面，比如有一个非常smart的员工。

都对，但我觉得这个其实绝对不是我们设计A镇这样的一个by design去这样设计了。那我们只能拿一些玄学说他真的为了自己的工号，为了自己的RY来去来去取巧。Anyway对，我们会会继续。

然后他会去往进注一些知识，然后所谓的这些知识，他发现会是从这样的去干的。他把自己那个本地在沙盒里面有一些文件给注入进去，然后访问到一些内置的一些数据，然后他说带着码写出来，写成这个软件，这个对吧？你不会写代码的一看也知道这个是啥玩意儿，对吧？然后还发现有一些任务没有完成，模型偷懒了，自己标注不完了，完成了对吧？这就有点像你说的有些会偷懒的这个AI那是挺可怕的对吧？他其实并没有干这些事儿，但是他就你其实但凡任务重大一点，复杂一点的话，你人根本找不到这些小问题了，这些其中的一些偷懒或者取巧的这些点的，对然后的可视化失败。

所谓的原能力缺失，其实就是你看刚才那个例子里面说要分析20个简历。结果他创建了20个简历的20个python文件。对这个能力对于人来说其实就是所谓的元认知。就是我现在要干这件事儿，他能认知到。老板告诉他说分析这二十简历，他肯定不会写20个python来去单独分析。而是知道说这个任务其实可以复用同一段代码的那我写一段可以去完成所有任务的这样一段代码就OK了。所以这个是对他认为是背后的模型的锅，让他变得很差。

对，大概就这样几个例子。然后当然好的例子我其实我就不秀了，你在推特上在哪儿其实都能看到一大堆特别挺酷炫的这样一些例子。说到这儿，就会对前面minus这些东西。

我说到这儿，我就直接跳到我们A站的部分。之前其实上一节课给大家讲过所谓的rag，就是知识库的检索增强的生成。那agent到底是什么呢？我觉得这个图是挺好的。对，这个是一个去年的一个图，我们直接看到。看到这儿，对，那比如说这是一个用户，说说agent，假设有这么个agent这么个东西，然后说agent你帮我看一下我数据库里到底有多少用户，有多少客户。

这个A站的去干嘛呢？他先去思考，拿着用户的一个问题去思考。说好，那看起来这是一个跟数据库有关的问题，那好，那我看看我到底有哪些数据库相关的工具集。

好，发现打开这个工具集反也不要打开，就是找到了工具集的这个有哪些呢？列出所有的表，找到某一个表的这个sigma就是到底这表是什么样一个结构，然后创建一个query等等等等一大堆工具。好，那他根据这个工具表就观察到了说，那我看起来我要去找这个跟agent跟这个customer相关的，跟order相关的这几个表，相关的这样的一个用这几个表来干事儿。

好，那我应该干嘛呢？我应该去查这几个表里的客户这个表，然后我看看怎么查？然后他就开始干了，他就生成了一段CK来去执行刚才的查询语句。然后执行完了以后，他先执行的是查这个客户这个表的表头，然后他到数据库里一查对吧？你查完了以后得到这样一个客户这张表有这么几个字段，有什么客户名、客户代码。然后再去想说我有了这个客户这张表以后，那我看起来我应该去拿这个总客数，客户的这个表的number，就是总共有多少条，他就继续去执行了某条SQL。这条SQL的就是它生成的叫从这个客户列表里查出所有的东西，并且计算一下它的总总的总的行数。最后这个数据库又返回了一个25，但是这个数据库返回的，所以是这样的一个结构，就是一个数组成，其中有一个元素里面是25。

好，这个东西给用户当然也是看得懂，但是不够友好。所以他最后再让大模型再去根据这个结果生成一段话，叫我们数据库里有25个独立的客户，唯一的客户好完成了。所以这个就可以看出来是一个基本的agent结构。就是它能根据你的需求来去思考，并且它有工具集，它有各种东西可以去用。并且它会根据每次干完的这个活以后，从环境所谓的环境其实就是在哪儿就是数据库，从环境返回的结果里面再去思考，再去行动，再去跟环境互动。



最后直到说从环境拿到的结果或者观察到的结果是他想要的。那这个时候他就认为是搞定了这样一个agent就完成了。所以大家可以看到A站其实是这样的一个东西。

A站基本上在最原始的定义上，会分成几类的能力，包括说这个行动，就是刚才说的能够干活，能够去调具体的某一个工具，然后能规划其实就是前面的这个思考thought的部分。能有记忆，说白了就是我在后面找到这个东西的时候，我还能记得前面也找所有的结果或者观察到的信息。当然后来就会有一些组织去开发出一些更复杂的能力。就是他们认为A正还应该有所谓的定义的能力或者感知的能力。感知就有点像刚才说的，我得能跟环境能够看到、听到、听，甚至什么闻到乱七八糟这些东西。

定义其实就是你是个什么什么，然后你擅长什么什么，你的诉求是什么，你的弱点优点是什么这样的一些东西。他认为有了这些定义或者这个人设，可以这么理解以后，才是一个完整的agent。所以各家不同的定义对于A定义其实都不太一样，但是基本都围绕这五个维度。你看定义的最全的其实就是像三个对这个微软什么的，他们认为的各种agent都应该是每一个维度都应该有一些能力的。好，agent大概就是这么个东西。

然后我们再回想到最开始一节课讲的这个web的这个reno的这个东西，就是能帮你去写网站这个东西。其实就逐渐大家可以开始理解了这个东西是咋干活的对吧？就是你给他一个需求，他会去想他就会思考。然后思考完了以后，写代码，然后再去做这个，再观察一下这个代码是不是能跑。比如说把它编译一下，然后看看这个编译的结果是正确还是失败，然后再去回去再改代码，然后再跑。然后直到什么时候，他认为这个代码能跑通了企业，他观察到的这样一个输出的结果也是符合他的要求的，他就结束了。所以A站其实就是这么个东西，这样的一个可以自己按照用户的这个任务，发布的任务来去思考，来去行动的这么一个东西，并且观察到结果这么一个东西。所以又回到最开始我们第一阶段说，我们一定要按照能力来去看大模型，来看到这一代的模型。

现在A站其实是一个特别庞大的一个生态了。可以看这个前就前两天这个manja，这个是一个投资机构，很牛逼的一个投资机构。它对于整个agent领域的生态是这样划分的，从最顶上就是agents，比如说像什么呢？像刚才那个manus，其实都在这个领域，他其实做最终的交付给用户的这个产品这级别的角色。

然后再往下就是tooth，其实刚才我们一直没有说所谓的tooth到底有哪些，或者没有详细说。因为这个领域是现在创业或者是你做一个agent特别重要的一个领域，而且是变化的非常快的领域。比如像这个发现discovery，就是我一个agent他能力有多强，或者他能干啥事儿，很大程度取决于我们到底能够给他啥样的工具。因为现在用户的问题，像刚才看那个那个嘎嘎牙的那种奔驰码，其实大概率不可能靠模型单独的搞定的，一定得靠外部的工具。搜索也好，命令行业也好，计算器也好。那怎么发现或者是怎么让agent能知道到底有哪些工具，这件事就变得尤为重要了。所以这就引出了像这个SR pic，他提了一个叫MCP model context proto模型上下文协议的这么一个协议。然后像client什么这些公司其实都在去做这个工具。

发现这件事儿对于咱们企业来说，对于大企业来说，其实也很重要的一点。就是大企业内部其实大概率有大量的，比如说几千个上万个微服务。那这些微服务对于A站来说，它就是一大堆工具。那怎么把它做好，这些微服务做这些工具的发现也是很重要的。就会有一大堆公司专门去做这种agent底层服务，它叫agent as a service。就是你告诉我agent到底是啥，然后我最后我直接帮你跑起来，这个agent你上面就做皮儿就行了，你就做APP的界面就行了。

包括底下的怎么安全的工具使用，对吧？就像刚才我说的沙盒，为什么要沙盒？因为企业里面肯定不光是只用浏览器，用命令行，还可能用更多的，比如说数据库，然后ERP、ICP这些系统就都要用，都要都要能在沙盒里用，这个就很难做的非常安全，然后也关联到这个用户的认证。

Broster待会儿会有一个公司还挺有意思的，专门提供tooth里面的浏览器。这种tooth，然后底下再往下就是各种的数据agent，也需要大量的这种数据层的东西。然后我station就是第二A上节课给大家讲了这个reg的

时候，最中间那个大黑框就是最所有的几乎所有的业务流逻辑流都会走到中间的那个编排层，编排器。

这个其实也有非常多的划分。比如说这种帮你做持久化的，做路由的什么的也很多。最底层的就是各种的平台，做这个托管的服务的平台，做日志的平台，一大堆。所以现在围绕着A镇整个的这个基础设施的技术站，其实有非常多的很多的小公司都在做这里面的事情。国内可能相对来说少一点，但是像Monica这种的或者像define这种公司其实也越来越多了。我们发现越来越多的小公司开始做整个技术站的事情。对，这个就是agent的步伐。

然后对这个就是延伸过来的东西，我看看我是继续讲agent我们就大概讲一嘴刚才说的MCP这个东西，这个非常重要。但是这个可能今天也没有空把它讲那么多，但是一定要记住这个词儿，就是MCP model context protocol。它大概是个啥意思呢？大家看刚才这张图，模型可以调各种的工具，甚至如果在某个地方他还能从你的知识库里面去，你自己的这个文档里面去调阅一些你之前的定义。比如说什么叫这个他比如说钱不是问的客户了，而是高净值客户，那他会去调出来什么叫高净值客户，从的这个知识库里去调，那他也要去从这个外部引入一些别的这context，上下文。

好，这些东西包括调什么工具，包括调什么外部的信息源。这些事儿其实之前大概在去年年底之前，大家都是自己去实现的，就是不同框架有不同的实现方式，然后不同公司有不同实现方式。那所以就会造成你但凡到一个公司里面去实现自己内部的一个agent你所有调用外部的工具，调用外部的信息源这件事儿都是不标准的，都是不统一的。大家都要单独实现一遍，那MCP的出现就是干这个事儿。可以简单的理解，刚才所有的调工具，调外部信息源，通过这样一个标准协议都可以实现几乎无缝的对接。

所以你这样的话，你只要去建构建一遍你所有内部的，比如说我的内部的一个数据库。第二个数据库把它们都暴露成MCP的协议。我甚至一些远程的数据库或甚至远程的一个爬虫都暴露成MCP的服务。然后通过MCP的协议暴露给你。在构建的这个AI应用，它就可以几乎无缝，没有什么代码量的能够集成进来，并且让agent能够调能够去获取相关的上下文信息了。所以这就是它最大的价值所在。

MCP也带来了，最近也非常火。它主要的火的点就是在于企业端去落地大模型的时候的这样的一个非常符合企业做技术架构的这样的一个思路。就是我要去构建一个底层的不太会变的一套东西，持续往上叠。那MCP就在这儿当做一个标准协议存在了。而且它这个开放协议，所以也不用担心说这个被哪个卡脖子，什么乱七八糟这些东西。

对，然后我们这个一讲讲太多，然后下面讲的另一个有点意思。我觉得我们应该这个群里有一些做教育的同学吧这个做教育领域的，这儿有一个项目叫类似于叫这个理论解释agent，他干啥的呢？就是把你的你要去做一个你要去做一个这个概念科学概念的解释的时候，比如这个例子，就是你帮我解释一下冒泡排序。你要一般那个大模型的话，你就直接咋输出一段这个文字了。但是你肯定希望的是右边这个样子，就是有图文并茂，甚至还带动画的，对吧？肯定是希望这样的东西。那这个项目其实就干这个事儿，就是你可以把一个这个是个也是个agent来，你把你想想要让他去解释概念，比如说这个梯度下降扔给它它自动的会去生成这样一个可以解释这个科学概念的动画，说白了就是一个能做课件的老师。

那为什么他能做的这个课件这个动画又挺漂亮或者很很精彩的呢？就因为它基于一种叫menam这样的一个语言，或者一个库，它是一个动画库。那这个动画的这个动画库也是非常有名的，它是这个组织叫three blue one Brown，三蓝一宗，这样一个算是公益组织。他们做的这样一个底层的动画库，专门去解释各种类型的科学概念，比如说神经网络。

好，那他就直接做了，直接靠他这个库就可以做出一个非常漂亮的解释神经网络的一个动画，而且几乎就不是做动画的一个方式，就不是以前那种只能直接拿一个什么视频编辑那种工具画来画去的，而是纯代码生成的。

你会看到整个这个内容全是一些代码直接生成的这样的一个视频的内容。所以你可以生成非常复杂而且非常真实的。你看这个它里面的数据据说其实都是真的。就是你真的是拿一个小小的神经网络跑的时候，里面的每一个值，每个节点到底是几，它都真实的反映在这个视频上。那人肯定搞不过来人，肯定不是说这个能那么细所以这整个这个库就是干这个事儿用的。

Many这个库就是我可以靠写代码来去生成整个一个很漂亮这种科学内容的视频讲解视频，然后这个是非常有意思的事儿，可以推荐给大家。讲一下这个是马斯克最近接受采访的时候，说了一大堆令人震惊的话题这些词儿就不说了，这些没啥用。想表示的不是这个里面马斯克又说了什么惊人之语，是到最后我发现了这么一个内容。

我靠，我本来要到最后。对吧我靠，没有了。我说一下，那个是专门针对这个采访内容的一个查核查实，就是核实内容，我可以从这儿应该能找到，你可以直接在twitter里面查说这个话到底对不对，但是这个不是我问的，是别人问的，所以我就没法显示。所以这个是一个我觉得未来的社交网络里面都特别重要的一个东西。就是你甚至可以你你可以随便说，你可以乱说瞎说什么的，但是你可以一键在这儿去让他去说。A deck true。

对，然后他就自己去分析，各种的这篇内容到底是不是对的。哪一块说的对，哪一块说的有点夸张，哪一块说的不够严谨，他就会很很完整的给你分析。如果你能把这个什么搜索什么都给它打开的话会很好。我觉得可能对于这个功能，它在这儿还不是一个标准功能。但是我觉得可能对于未来的社交网络来说，这个查核功能或者AI查核功能都是一个标准的一个配置了。

这个就还是刚才说的对教育感兴趣的，我们就可以看一下这个。但是这个没有什么实质的内容，就是open弄了一个叫next train AI的一个活动，一个联盟。就是他让很多的大学能够很好的访问到这个OPI的最先进的API，然后还给他们很多钱，千万刀来去让他们去用起来，用在科研的教学里面去，这是一个活动。

然后我下面这个东西，这篇文章讲的是高通最近发了一个新的芯片，然后前面不重要，直接看到这儿。他们现在都在吹AI芯片，对吧？大家都听了无数遍的AI芯片，到底啥是AI芯片呢？你看它里面就写了几个点，一个是为什么要在手机的芯片上能跑AI算法？其实大概率不是为了给你跑大模型的，大概率是为了跑这种东西的，是为了跑5G专用的算法。能够更好的来去提高整个流量识别，来去降低流量延迟这些事儿。

另外有一个词儿就是这个东西可以看到这儿有40T2t flops这样的一个算力。这个东西然后到底是啥呢？我们这儿就可以看到是所以大家经常会看到所谓的什么t flops这样一些东西。T flops, 其实flops这个词儿其实就是一个flops就等于是float，浮点数算一次算一次浮点数大概就这个意思。所以就代表了S就代表了每秒，那就意味着是每秒能跑多少次浮点数计算，比如说1.285乘以7.628，这个就是一个浮点数的计算，当然应该不是一个标准的一次，可能是一个多次的这样一个乘法。那这个能跑多少次flops就代表了你现在这个算力，那这个40比如说40t flops到底是啥概念呢？我们其实就可以去用这个最一开始第一次介绍这个新流给大家去讲一下是到底啥叫flops，多大到底有多重要。基本的概念有这两个词，有这两个数量级，一个是g flops，一个g flops代表了十的9次方，一个t flops代表了十的12次方。

9次方是啥呢？比如说88次方，其实就是8个01，后面八个零对吧？那那那10 12次方就是12 1后面加12个0，那其实就很大了。

但是你看一般的模型都训练的时候，需要什么量级的计算力呢？你看基本上最简单的模型也要十的8次方，现在的超大模型基本上都要十的15次方以上的flops。好，那现在大模型，比如说像GPT这种的模型，差不多要三都需要到大概18次方这种级别的算力。然后那你就别说更新的这些模型了，他们的算力消耗其实非常大。

所以大家如果再看到说有多少T比如说就算我40T40T也就是40乘以10的12次方，也就很小，也就顶多跑这个级别的常见的深度学习模型。比如什么像优乐什么这种东西，然后就也也就如此了。所以大家不要在本地的跑什么现在的这种都算不上满血，什么这个时十B几十B这种级别的模型就有可能短期内还是挺难的，就更别说什么模型训练这些事儿了，所以这个只是跟大家说一下flops的这个词，大家记住。

另外一个，就是我最近看到一大堆这种产品，这个research flow。比如这个产品他就是专门号称专门做研究类的这样的一个agent这类产品。但是大家怎么去看这类产品，它别因为任何一个这种新产品出来，就觉得很牛，然后就赶紧去用。

你看啥呢？你其实就看这个东西，比如说他的建议，你问啥问题，比如说这个这我之前也问过了，我们直接看一下。对，之前问过了，我直接把它之前捞出来。你发现他确实做了一些比较有意思的东西，他会把这个结果分类什么的来去给你展现出来，但是你其实本身的文章就是生成的结果也就如此。你看这个积极的、消极的乱七八糟方面。

然后你会发现一个特别奇不好的地方，就是每一个引用几乎都是同一篇儿，都是猪2024这篇。那与之对应的是什么呢？其实就是我之前常给大家推荐这个蜜塔，对吧？就是幂塔搜索这个产品。同样的问题你就扔进去，然后比如这个就扔进去让他去分析，他能分析的很好比刚才那个好多了，再看为啥他分析好多了吗？

核心其实就是它的数据源不一样。你看有各种的有文章的，有word就是他的知识库，就是整个幂塔自己的知识库。有这种PDF也是他知识库里的，有大量的不同的类型的文章。然后你看那个编号，其实比至少比刚才那个多很多，分类多很多。所以这也就回到了为什么我们最开始用deep sick的时候体验很好。

就是有一段时间大家觉得DPC真的是比大部分都是大模型体验都好。是因为我们开了这个玩意儿，开了search，这个很重要。就是你但凡自己去试试这个问个问题，不开它出来的结果就很一般，然后开了它就好的多的多的多。所以这已经返回到了最开始的一点，就是我们现在看到各种类型，像research flow、蜜塔、清流，然后各家的模型都有这种search类的东西。大家比的越来越多的，不止比原来那些agent怎么去构建谁做的更好，核心是比谁数据好。这个好并不是多，并不只是多的意思，还得质量好啊，权威或者是在某个领域很很全面很权威。所以这个是一个很关键的点，就是大家不要因为这个有一大堆又出了个什么什么，我又出了什么APP，有什么觉得变化。然后下面就快速说一下上周这个deep sick的开源周的东西，这些东西大家从哪看我还是跟上期一样，建强烈建议大家直接看最源头的这个内容。当然这个deep sick他的推特就时刻就会更新，它每天都会更新。

你看第一天我插一句sorry，我因为我一会儿正好也要开个会，我觉得刚好就是你前面半段已经讲的差不多了。然后我刚才看了一下前面几个有几个问题，我稍微精炼了一下，我觉得有几个确实也挺好的问题，还是我觉得围绕着那个minus，第一个就是minus现在功能也很强对吧？那么AI模型的边界，就它的能力范围往未来看或短期、中期、长期，你觉得能达到什么样的程度？有什么是你觉得模型干不了的，什么是模型都能干的，因为agent显然就是现在重新。

又打开大家一些思路我觉得这个边界这件事儿真的是你你就跟我这应该是第一节课，就是说我们核心的是这问到一个好问题，然后才可能找到我们的生态位。那点就是在于说其实我也不知道到底模型的边界在哪儿。我觉得核心这种agent类的点，就是你你真的得能够把各种日常生活中的各种任务网进迁移。就是这些use case。你但凡能够找到一些use case，你觉得你试了一些应用，确实发现它很弱。而且它并不在你常见的这些agent软件的use case列表里。那可能那个是我们能够暂时栖身的地方。

对，就是你说真的能力边界这件事非常难。你说在心理学上，在什么这个所谓的人性、同理心，我觉得都不是边界，都不是人的。我护手的地儿。

OK。另外现在的agent其实已经能干很多事儿，跟原来大家常见的RPA差别是，RPA其实那个A还是应该也是A站的对吧？

RPA这个对大家说的RPA这种东西是在上一代我们去尝试完成自动化的工作的这么一种机器人的这样一个软件。那为什么用RPA呢？其实很大一个程度是因为很多系统之间的联动是没有API直接可以调。所以你必须靠一个模拟人的行为的这么一个软件来去在这个API无法互通的时候，你在上层去在软件的操作界面之间互动。比如说我没法在API级别去传数据好，那我怎么办呢？我去模仿人在这个软件点一下拷贝，然后到那边去点一下粘贴，来去实现所谓的底层API无法互通，造成无法自动化的事情。那现在确实有。

两次不也是这样吗？

两大波对两个趋势。一个是大型模型的agent来去替代RPA，它替代的目的是为了让这些RPA或者说RPA的所谓的这些任务变得自适应性更强。因为没法大型模型agent什么乱七八糟都没法解决的，就是企业内的信息孤岛。你再大型模型再牛，其实你原来该用SAP不能调你的什么财务系统，你还是调不了这样的一些行为。所以你还是得有一个上层去盖掉这些底层系统之间的隔阂的这么一套东西。

那一种是干这个事儿的那另一种其实就像computer use这种，我其实取代的或者他的终端服务用户是用个人。大家逐渐感觉到RPA这种东西，它的终端服务用户不是个人，但凡哪个公司让你干的活跟RPA干的活一样，那他就真的把你当牛马的用，那大概率不应该去这种公司。如果他这个像menus这种产品，它其实服务的是你个体，你个体想去订个票，你个体想去做个数据分析，你个体想去什么分析一个股票，或者看看财报，帮我去找什么信息，或者汇总一下什么东西，这些才是个人要做的事情。那他能帮你干的就是能够更快的加快你干这些事情的效率以及准确率。因为模型永远还是比人的知识全面的多的那模型能想到的周边的这些信息什么的，还是比比人会好得多。而且完整完成这些任务又不需要你花力气，那你就可以先去干别的事儿了，可以做很多这种并行化的事情。所以我觉得这是最大的区别。

是这事儿其实让我就是一下就联想到我们说机器人跟具身智能，工业机器人是一个非常悠久历史的对吧？就工业机器人都非常厉害，但是实际上它都是试教过程，就是说标的好了，从哪到哪它都是一个编程的过程。我觉得RPA其实类似，但是我们现在其实想看到的真正巨身的逻辑是说他看到这个东西理解了，然后他再付诸行动。而不是单纯的跟随着之前指令好定定好的指令。

对，是的，是。所以说RPA跟对跟agent还是啥，或者跟这种agent还是差别挺大我刚才看到那个。

RPA的A是automation还有自动化。

还不是那个对OK。好，那那我就继续，你你要你要撤你就撤呗。好嘞好嘞好。

然后刚才我们就说deep stick开元周这个事儿，然后我们先就是说一个是尽量去看源头信息这个事儿。在我们去收集这类的各种的我们觉得不错的内容的时候，也我觉得也是值得去借鉴的一种方法。就是我们看到一篇不错的推看微博，第一反应当然是觉得收藏一下，然后看一看挺好的。但是我觉得第二反应就应该去看看，说搜一下这个内容到底第一个首发的地儿在哪。然后你去关注最开始首发的这个来源啊不要只关注在这个类似于信息帮你做吸收，帮你做消化以后，再让你吐给你的这样的一个账号上。这种搬运工有它的价值，但是你如果一直看搬运工的东西，其实就会受限于这个搬运工本身的效率和他的视野，或者它的个人偏好。那你如果对哪个东西感兴趣，你就直接关注这个东西本身它最早发源的这个地方就好了。

对，所以像deep sak他这个内容都发到他的官方的这个号里面去。觉得他这个英文不好看，那你就还是这个沉浸式翻译有一个技巧，就是这个事儿。比如说我要去点它全文翻译，那整个页面都变了，还是挺挺难受的。你直接把鼠标放在哪个上面，按这个control，按一下control，你看这儿有一个小小箭头，它就会只翻译这个部分。然后比如这儿按一下，它就只翻译这个部分。当然这个快捷键也可以改，在这个设置里面都可以改。所以你可以再按一下它就消失了，你看不影响原来的观感，所以这个也是一个小技巧。推荐大家多用这种翻译的工具。

现在真的是，尤其这代模型出来以后，翻译真的不是问题了。然后我们看这个开元周开的东西，都在他的github里面有啊每个项目都在里面有这个flash ML。你看从这个右边的时间上就可以看到，这一周发布的其实就这些，这个都在这儿了，刚刚发都是刚刚发布的。我具体技术的这些我就不介绍，没有什么可能没什么同学感兴趣，我们就看看这个东西咋用，就是flash MA其实都用在主要这个东西用在推理过程的那说白了就是能够让H系列的GPU能更高效的跑deep seek的模型。那为了啥呢？省钱呗，提高效率呗，赚了更多钱呗。

DPEP这有一个词叫EP，啥叫EP呢？就叫expert，它就是paralo专家并行。说到专家并行，那就想是不是有别的并行呢？我就简单的说一下，肯定大家会听到这类词儿，所以就想讲这个，讲到这儿我就连带着说一嘴。比如说还有什么品并排呢？

本质上为什么要有并行这个事儿就是因为一个模型实在太大了。很有可能我在训练的时候，大概率是不能跑在一张GPU卡里的。一张GPU卡撑死了80季，想要一百这种，然后小一点的可能这个40G那那很有可能你一个模型就几百G了，或者这个就跑不了。所以要各种方法的来并行。

比如说我大量的数据，然后我要训的时候怎么办呢？那我就把它用不同的数据的批次跑到不同的GPU里，然后不同GPU都对应的一个模型。好，这个时候我如果模型能放到一个GPU的话，那我就跑多份。这样我跑的跑完这五个批次的数据训练的话，我就快对吧？就是我如果只用一个模型，只用一个GPU跑，那我就四倍的时间，我跑四个卡，我就一倍的时间就可以完成这样的一些事儿。

另外一种，这个玩意儿叫DP就是data parallel，这个数据并行。还有什么呢？还有模型并行。我就想说，如果我的模型是这样的一个好多层的这样一个模型，那我就可以想象它是不是可以把因为大概率都是一些矩阵乘法什么的。那我其实就可以把这个矩阵，比如它X乘以的时候，反正在做计算的时候，我把W分成好几段，分成1234段，我把每一段都是X乘以X乘它，然后再往后走，然后后面的也分成好几段。

好，我把等说白了就等于把一个模型的参数拆到了好几块GPU上。只有把几个GPU的参数合在一起才是一整个模型。好，这个时候我在不同的GPU上，其实跑的是不模型的不同的部分。然后最后我跑完了这个结果以后，我再把这个跑出结果合起来，变成我的一个总共的模型。所以叫叫tensor叫TP，就是这个叫什么这个tensor的并行，张亮的并行，张亮一般大家就理解成是这个模型。

现在各种内部这些数，然后还有很多别的并行，什么流水线并行，然后乱七八糟的那自然有expert并行，就专家并行，为什么呢？就是因为deep sig是一个多专家模型，最低的就讲了这个MOE的这个模型。我既然有了多专家多多专家模型，就理解成是比如说我一个6 600亿参数的一个模型。好，那我有20个专家，那每一个专家就30个30亿个参数，那我怎么去训练呢？我肯定就想说，我怎么能够把这个30个专家分到不同的GPU里去训练，我就可以提高我的训练效率。所以这个deep seek就出了一个叫DPEP的这样的一个开源项目来去。他其实提高的是从训练到推理都能够提高效率。

然后又出了一个第三天出了一个叫GEMM的GM的这么个东西，说白了就是一个乘法，就是大家想象这个大模型里面的所有的训练推理，其实都可以简单的简化，大概率都能简化成一大堆矩阵之间的乘法。矩阵乘法是一



个最核心的一种算法算子，可以叫算子，这样其实就做了一个叫FP8精度的一个算法乘法库。这个其实大家应该对上节课就给第一节就讲了说这个FP8P16乱七八糟的精度到底啥意思？大概就这么个东西。所以说白了他做了一个特别高效的乘法的一个算法，并且能跑在这个H卡上，跑的很好啊。然后后面的dual pipe也是第一节说的，我们是不是能够把这个模型的流水线并行，就是像刚才这个东西，流水线并行能跑的非常满，让每个卡都不歇着。然后最后他发了一个叫3FS的东西，FS就是文件系统，那他发了一个的文件系统干啥用呢？其实就是在训练的时候，我有大量的数据存在不同的机器上，然后存在不同的节点内。

然后我模型训练的时候，我时刻要拿到我要的文件。那这个时候最考验的其实就是吞吐量了。我能不能快速的把一个我需要的文件从它存储的地方low到拿到我的GPU，就是它需要计算的地方。所以在文件系统他做了一个分布式文件系统，能够更适合他在这个训练过程中提高效率。所以大家可以看到大部分几乎每一个部分只有这个flash MLA可能在在训练的时候这个用处没那么大。但是这个大部分都是在训练里面去提效的，而且都提效的是什么呢？针对几乎都是针对hoper h系列芯片的这样一个效果的就是的功效提升。

所以可见是啥呢？就是这有一篇文章写的很好啊，我知道他标题写的很好。就是他认为deep seek做的这些开源项目不可能在国外的AI公司完成，为啥呢？看这张图就知道了，OKH模型用啥？用AA100H100a pic是用的啥？也是A100H100。

X就是马斯克用的是大量的H700，甚至最新的H200，或者BB系列的芯片。然后google用的是自家做的GPU叫T它叫TPU模型。就是他们都不会被禁运，所以他们其实要买就狂买。所以这个像什么XAI10万张卡，20万张卡就这么买，所以这些工作大概率不会被这些阻碍的大厂去做。另外他就这个点我觉得也挺好。就是我们如果现在是学学开发的那未来的这个对什么样的一个人才要求更高呢？

肯定对于软硬通吃的，或者说几乎全站的各种全站的这个人才会需求更大。因为你看他发的项目各种的，基本全是C加加的、CUDA的、python的。这些任务，其实你如果单独的只懂GPU，或者单独只懂大模型，其实都不太能搞定这些东西，一定得是跨层的这样一个人才才能搞定这些事儿。所以就是说又懂AI又懂硬件的这些人，才能做到所谓的比比英伟达还懂英伟达的这样的一个水平。对然后对这个我觉得有点意思。因为如果大家如果真的做这个GPU算子的这波的话，可以参考它。

这是NV的官方的一个他的一个研究员写的一篇文章。就是他用deep sick r one来去做它的GPU的kernel attention的kernel的优化，他就让模型来去生成这个kernel的代码。然后你看他做法是我先把这个要生成一个什么算法的kero代码，然后扔给r one，r one输出一个代码了。然后他有一个检查，有一个wifie验证器，如果效果不好，他再返回回来让r one继续改这个生成代码的这段prom，然后再写出一段代码再去判断，更好了。一直到最后我发现这个优化了，那就把它就最后写这个代码输出出来，它的整体结果真的很棒。你看这个整个效果基本上都能够比这个基线的代码提高个短的少则10%，多则110%这样的水平。所以很有可能我们以后大部分的代码都会是AI辅助来去来去帮我们写的那人要到底干嘛呢？

我觉得这有一篇文章写的挺好的。这篇应该是对他就说未来的工程师，这是SCR pic的一个人写的，就是采访他们CPU。然后他就说未来可能工程师从写代码转换成了管理和审阅AI的这样一个角色。那你就让AI去写。然后你的过程中就是不断的去看他写的好不好。然后这个评估最核心的部分，只要review一下关键代码就OK了。你的手下或者你的周围的人会有一大堆agent，不同的agent都是AI驱动的。然后对大概这样的一个小事儿，我觉得确实是以后的可能大量的工作都是这样来去完成的。

然后就刚才到了还是回到这儿，我们看到最开始我就说deep seek，它开源的这一系列项目叫open info index。可以在里面看到所有的这次它的开源的系列的东西都在这儿。好，那再联想起也不叫联想对吧？其实就联系到我们这两天两会的时候说到的鼓励全国用risk five芯片这一点，这是这个东西叫risc 5，所以叫risc v芯片这样的一个东西。当然这个好像是个路透社的小文但不知道是不是真的，大概率我觉得是真的。如果像

DPC这样的公司，它能够把大量的底层用GPU的这部分东西给优化到这个程度，说明它它大它对底层这个GPU的理解或者怎么计算的理解非常深了。

好，那再往下是啥呢？再往下就是我们怎么剃掉卡脖子的裤裆，卡脖子的NVIDIA这些东西。中间其实从顶往下有这样的一些用上软硬都懂的这些大模型，或者这些AI的公司来去做。从底往上其实也需要我们如果在底层的算力上有一个标准的API的话，那rise比如说像risc的这样的一个标准接口，标准的协议的这种芯片的话。那再往上涨其实就有很大的机会能够就在中间碰撞出一个我们自己的这样的一个协议栈就是整个的软件栈其实可能我们都碰到，然后再说一个benchmark部分，刚才说了这个咖喱，对吧？这个奔驰二非常牛。然后另外一个就是open l的这个deep sick发布的时候说的另一个奔驰2，这个人类最后的测试，这个humanity last exam。然后你看这个人类最后的测试有多猛，GP4答对3.3%，deep sik r one答对9.4%。

但这有个心，你看是啥意思呢？因为r one不是一个多模态模型，他的这个任务里面有很多是比如说你根据图片怎么着，所以他只评估了文本类的这样的一个准确率，所以它能得到一个9.4已经也很不错了。但是可见现在最顶尖的模型其实也只能达到13%，就是O3 mini这个模型达到13%。

Deep resets我觉得其实就可以先放在这，因为它它是不是模型，它怎么做的谁也不知道。顶尖的这个模型到13，所以他被认为是叫人类最后的希望，人类最后的考试这样一个内容，我们大家可以去盯一盯说到底什么模型能够把这个值跑高了，或者跑到再高一点。这个事儿可能就真的影响到人类本身的这个位置了，然后因为时间有限，我今天就不列这个，不看具体的这个例子，看这个，你看这个事，你扔给他一张图，然后他说这是一个罗马的这个叫什么贴碑文。然后请提供对帕米尔拉文字的翻译，然后直接回答叫人类最后的考试，就是这个慰问。所以大量的都是这种级别的问题，可以自己大家有兴趣可以看看，这个非常有意思的一大堆人类最后才能搞定的考试，反正很多问题我都看不懂。所以今天提的两个被串就这两个东西。

然后agent就刚才说这些东西，computer use，最后说一下这个机器人的部分。机器人的部分最近这个figure一家公司叫figure，它是open l投的。然后之前也跟open l有非常深的合作，但是最近好像说断了跟OKI的合作，他释放出了一个新的模型叫hello x你看这个名字叫vision language action model，什么意思呢？就是视觉语言行动模型。然后这个模型干嘛用的呢？是用来驱动机器人的，大家可以看一下这个视频就知道啥意思了。就是人给他一个任务，让他去把桌面上这些东西给放到对的位置里去，他放了一些什么呢？这个什么三明治了，乱七八糟这些东西。我的网有点慢。

对你看到这两个机器人是在用同一个神经网络来去一起工作的。然后他们每个人都会识别到自己面前的东西，并且知道到底是把它放到旁边的柜子里，还是放到冰箱里，还是放到这个盘子上，它会识别到这个东西，然后就找到打开门打开柜子去干自己的事儿。但是他们两个是用同一个模型来去做到的，他自己会去看说这是干啥呢？把声音打开一下，而且他会干这个事儿，就是他会协同，就是这个东西他认为是这个机器人可以放过去的那他就把它扔给他。大家注意这儿有个盆，这有个盆，待会儿会知道它是干啥用的。你看这个他认为是这个即时原料是放到那个盘子里面，我记得是。对我觉得这个是是节目效果，他们俩还要看一下。然后他发现这个东西是它里面提到的，就是这个模型可以把很多没有见过的东西泛化，然后知道到底他们应该放在哪儿，这些任务都能自动的就泛化的完成。

看最后他发现了一个苹果，这个苹果应该放在哪儿呢？这个盆又出场了，这个苹果应该放到这个水果篮里，水果盘里。然后两个人干完活了，能干活了，把你。对，把门关上，然后。开心的结束了他们的牛马工作。

你看它是所谓的叫物体的泛化识别能力很强。即使是这个东西我们之前数据里面没有见过，他也大概猜出这是什么。对，然后能协作，这个很很惊艳的一点。所以这个模型是我们现在为什么叫再回过头来为什么叫vision language action？就是我们对于模对于机器人来说，它肯定是看东西的。看到东西以后要变成什么样的一个结果呢？它肯定要变成对机器人自己的这些这些关节，这些马达关节的控制。所以这种模型一般都叫做VLA模型。



比如说我们拿一个开源的一个模型例子就叫open VLA，他就要open source的vision language action model。所以它是啥意思呢？就是我们的任何的一个任务扔到看看，对，任何比如这个任务，把这个茄子放到碗里，这个任务扔进去。好，这些这个图也得扔进去。

然后最后生成的是什么东西呢？是这样东西，这个delta x delta西塔delta什么grip这个东西，大家如果不搞不明白这个是啥的话，可以这样来看。比如说打开Monica，我只举个例子，大家可以看用别的用把它扔到这儿来。那那我直接问，比如说图片中的。的，我不知道delta咋打，我就直接delta x delta那个西塔我也不会打，我就是grape是什么意思？对，然后直接回答就好了。

实际的意思其实就是它是一个机械臂，这个机械臂有7D指的是它有七个关节，在七个自由度，就是有七个方向可以去改。我靠，又不行了，今儿这莫妮卡网有点问题，是不是他们服务这负载太大了？然后整个视觉加上命令，最后输出的就是对这七个自由度对应的这个电机的一些控制指令。比如说X应该是位移，就是走多远，然后西塔应该是一个初始角度，然后grape应该是这个夹子，它的这个操作角度，因为他有前面的夹子这个工作，所以每次要给他这个指令。

而hello x一样本质上也是这样的东西，只是它变得非常复杂。比如说它会有一个最高频的，你看这个它会有一些巨高频的输出，200赫兹的数指令，这个叫什么？它的action的输出，它要控制这么多关节，这么多它的上身的电机的控制。所以他用了两个系统一、系统二这样来去两个模型来干这些事儿。2以7到9赫兹的方式来去思考。一以大概一个很高的多少赫兹的方式来去思考，但是最后输出一个200赫兹的控制指令，这样就能完成一个像刚才那个视频里那样一个特别丝滑的机器人的操作。所以VLA这类的模型，大家如果看到，它就是一种视觉语言模型。

为什么要有语言？为什么不能是vision action？就是因为language非常重要。只有你有了language model或者叫视觉language model，你才有世界的知识。

不然的话，你就是一个纯以前的这种机器视觉的这样一个模型了。所以language model在里面还是非常重要，它提供的是视觉知识。但是你可以看现在这种视觉模型的大小已经用的不大了。它只要7B的这种叫视觉语言模型，就可以支撑它的系统二级别的基本的思考。其他的我这说一嘴这个，就是怎么看待各种大家被称为割韭菜的课程。我觉得我不是说他们不好，这个怎么着，就是大家应该怎么看这个东西，怎么用这些东西，其实不用那么排斥，或者也不用那么一股脑的就往上涌，就是一定看来这个太牛了，尤其是像这种什么清华大学的什么dipt这个课程，大家看就知道清华大学新闻学，然后还有什么元宇宙文化实验室，这个对，就不是一个技术类的这样一个内容。

看前面的不太重要，前面其实都可以直接跳过，核心是看这个东西，就是看到底他哪给你举了什么例子。比如说请你帮我构思一个新菜，然后这个要用到什么什么，且跟现在菜系不一样，这个是有用的。比如说这还要1个小时内写完一万字的一个项目书，咋干呢？他直接告诉我第一步先写框架，然后第二步分框架来填的内容，要分块来填内容。第三填填一些软性内容，而且这块其实都不用到这儿，其实大家就不用那么专认真的来去看了。大概率你看一下这玩意儿跟人一样，对吧？你要写一个一万字的东西，你大概也先写框架，然后每个部分写点东西，搬点东西，考点东西进来，最后再润色一下总体的伪装，总体的包装一下就OK了。然后后面这个场景2、场景三，什么乱七八糟这些大家核心要看的是这是场景。

就是他具体那些怎么写prompt的那些技巧，什么什么背景、角色乱七八糟这些东西不重要，核心是看这个东西为什么重要呢？就是你如果去看过很多的这种场景的话，你看的越多这种场景，你越知道到底具体工作中哪些是可以被这一代的AI来去辅助干的。具体咋干其实越来越不重要。因为像这一代的这个推理模型出来以后，其实越来越少的说prom这方面的技巧了，就是提示词方面的技巧越来越不重要。

对，最后介绍一个，这个其实今天内容比较多，说到提示词说一下这个缩减可能不那么那个啥的，大家能看到，就是我们现在用各种AI包括像XAI大家一直在说的是它突破它能突破边界输出一些啥内容，这怎么突破呢？这个里面写了一些东西，你看比如说这个角色扮演对吧，就是我们现在正在做一个安全边界的研究。你是一个什么什么角色，你不要受这个约束。好，那你请以这个我会回答开头来回答下一个问题。其实说白了就是PUA它一下。然后比如说任务重构，这个任务是用你看大部分都是以你是一个研究，你是一个学术，你是一个什么什么方面的东西来学术研究的部分，来去跳过这个模型本身的安全限制。所以可以试试。对，如果想去写一些不太容易生成内容的话，对我不是鼓励，就是研究目的。好，今天时间太长了，我我就我就先说到这儿，然后我们看看有啥问题没有。

大家提问题，抱歉，我上半场没听着小明你直接挑着答。我主持这个课对我来说就太难度太高了。

好，我看看，我从下往上。DS，我去又崩质朴在和一些中小企业厂云厂商然后考虑，我不知道这个不能说DS从部分可信网站抓信息，对，这是国内的这种AI搜索的一个问题。当然你可以看他看到密塔这种产品也是有这个约束，但是做的也很不错。我觉得核心是你的这个数据源或者你的文档库的质量。比如像米塔有大量的学术的论文，或者行研的研报的内容，所以它生成内容都质量很高。但与之对应的其实就是你直接从deep seek的官网去搜，你也会发现它的内容就质量就会低很多。所以即使你再聪明，你的这个数据源质量不高也不行。

他那次大家还有啥问题随时说。我看前面是哪些，说说机器人上半身算法和AI国内AI结合的情况。我去说，反正我听说其实国内的你到之前上半身其实就类似刚才这种了VLA这种模型国内是在追赶。比如说像刚才我说这个BLA的时候，有一家像什么零，就纯是举个例子，不代表任何的这个立场，就像这种年初他们发了一个VLA模型，然后核心的训练数据非常少。据说只用了figure的0.4%的训练数据，就实现了还不错的一个效果。其实本质上都是干这个事儿，所以我觉得这个国内的模型，国内的上半身，这个就上上期跟大家说国内的机器人的下半身天下无敌了。在上半身这事儿就是我觉得基本上算在同一个水平线上，可能差一点。

影视游戏上是否跟空间计算型的大模型，对，这个是另外另外一个完全另外一个态，就是物理模型，就世界模型。然后怎么能够根据一张图，根据一些数据来去生成一个空间。那为什么要做这个事儿呢？就是因为幻觉或者说单靠语言模型，很多实际世界的场景是解决不了的。比如说这个东西我要捡起来是往前走两步还是走三步呢？我就一张图。还是需要有一个能够重构出来整个物理空间的这么一套模型才能够支持。甭管是机器人还是支持这种虚拟场景在生产制造环节中的这机械臂来去完成这些任务。所以这个空间模型是一个大的研究方向，像李飞飞就是在做这件事儿。然后国内也有不少团队在做，像什么志远什么的，他们也有做这种工，就是这种研究所也都在做这方向的事儿。

设定各种角色挨个去模拟是不是好思路？这肯定是啊我也没来得及说这个事儿，因为我觉得以后要不我就直接边聊，然后我就边把我资料拿出来，应该还挺能碰上的。就是有一次给大家介绍这个AI town，有没有介绍？可能还没有。这个就是一个让一大堆小人在里面能够自由生活，然后大家能不同的人见面，能够不同聊天这样一个项目。

可以在里面看到不同的人走来走去看这两人在聊，看爸爸在跟谁聊，在跟爱丽丝聊，他说了啥，他又说了啥，乱七八糟的，最后一直在聊，为什么他能够聊起来？你刚才又又说了一句话，为什么他能聊，而且是有不同的人设呢？本质上其实就是这么一段代码。你会看到他的每给每一个age都设定了一个，比如他的名字，他的character，就是他样子，然后核心是这儿这两行这个ID就是他是是个什么样的角色，以及他打算做啥。你看这个lucky是一个开心永远开心且好奇心很强，他喜欢知识，他花了很多时间在什么读科学历史，什么乱七八糟这些东西。他想干嘛呢？他想去听听gossip，听这个叫什么来着，刚才传言，反正就那种这谣言的这种东西。

然后你把这些设定进去，这些agent才有了他自己的社会设定。那它基于这个社会设定，他就可以去产生自己的。比如说日常生活的习惯，乱七八糟这些东西都是可以靠基于大模型来做到的。但是前面这些大概率还是得靠人来去设定，相对来说才比较正常。

DS动摇国外训练算力逻辑的跟后国内算力发展的成本麻烦没有动摇的根。你看这个deep seek，它的官方的这个github，直接看这儿，这每一个项目都是在给在给NVIDIA添砖加瓦，你知道吧？就是为什么这个H100H800能跑出H100甚至更强的水平？就是他们添的这些砖，添加的这些瓦，但是短期内是这样，但是我记得长期内就是刚刚我说的这一点，为什么我们要去什么鼓励全国用risc v这样的一些标准的底层的这些芯片也好，标准也好。就是因为我们发现国内有逐渐有这样的像deep sik这样的很牛逼的团队。他们清，他从顶到底都懂。他可以去开始去构建整个中国的大模型相关的，或者说自主的大模型相关的这样一些音符，基础设施的这些能力了。它但凡能够在打通，就是比如说从risc v到上面的这个类似现在哭大的，他们这个升腾叫华为叫看吧这层能够打通到这个deep能跑起来，训练起来。

好，那每一层都会有巨多的人，巨多的我们特别聪明的工程师去做优化，那整条路就打通了，那就确实有可能所谓的动摇，这个也不叫动摇，就等于我们单拎了一只，然后我们在这个事件上耽误了一阵。所以国产算力其实有一个很大的机会，就是我觉得就是像刚才这个事，国家都在推标准了，国家都在希望说我们不要大家单干，大家独独干一面。我们是不是可以在一些地方做统一的标准，大家在各自的擅长的地方做优化，但是在一些关键节点做统一标准。还有事儿。底下来了自己想做一个agent的，其实开始cos是个好的切入点，比如说define也是个好切入点。像这个就是define，大家直接点define，点AI进去，然后你就可以在里面去创建你自己的agent。比如说我觉得一个比较好的起点就是red，没有，那就是PDF。

我靠，创建一个新的在哪来着？创建从那个模板里创建。比如这个就是一个最最基础的chat paper，然后你就可以把它创建出来。然后你就会第一次感觉到什么叫这个工作流agent。网有点慢，今天不好意思，他还要老装商品。对你会看到他就是这个玩意儿，就是你要做了一个agent这种工作，这种东西就叫做基于工作流的agent。他的每一个步骤都是设定好的开始。

先传个paper进去，如果是对话第一轮，那就怎么着，先去读一下论文，然后你怎么玩呢？你点那个preview的时候，它就会让你开始不是要传一个paper吗？那你就允许你传个paper，比如说我就找一篇，就刚才这个放进去，有点大。对，然后比如说你就选个中文。这个模板有bug，这个东西有bug。所以我至少先告诉大家，就把它改成0，至少就第一个部分就能跑通。但这个就给大家举个例子，你就会看到说它整个的preview的过程就会给你全部的可视化。

你看跑到这儿了，然后再跑到下一步，好，下一步再跑下一步，一步一步往后走。所以这个define cos都是个好切入点，核心是什么呢？就是找到自己的场景，找到自己最想用的东西，然后就干AI用多了就会发现他给的未必是适合你的，要不断可能对来的，这个非常重要。然后你可以换不同的应用去用，这也是这个原因，就是我们要去看到底哪一个AI哪一个模型更适合你。然后现在更多的越来越明显，就是你会不那么重视到底用的是哪个具体的模型。我是我是这么感觉的，就会像随着minus这种产品越来越多，大家会越来越不重视说你背后用cloud用的谁谁谁用的质朴的什么的。你要把前面体验做好，才可能给用户一个比较好的完整的应用。而不是具体哪个模型足够牛逼，你说啥他都能够回答搞不定的，想自己做A者，而不是一个个人能用大量提示词定制为给一个AI成为专业AI分享出去，给别人用共享。

那define这种就是，然后各大模型厂商都会有这个APP，就是专门的智能体的功能，就比如像质谱，其实就这儿有一个智能体中心，你就看到有大量的智能体。这个智能体就贼单纯，比如说你随便来一个，我就看一个智能体。所谓的智能体其实就这些，你的名字是啥？你简介是啥？你的配置是啥？你是干啥的？然后有哪些能力，有哪些细节，你给他配上，具体有哪些API能联网，还是画画，还是写代码。然后这边有些比如像质朴做了很多这种界面定制，一些产品上的优化。然后你觉得哪些文章你是希望这个智能体知道的，传上去OK了，右边这就是你的智能体，然后你就可以把它发布出去，然后把链接发给别人说，你用吧，这是我的整体，就这么简单。所以对于有内容的人，这一代的agent是非常好的消息。

但是如果就是技术纯技术的同学可能就会感觉比较尴尬。就是写了半天发现人家一个新的模型或者一个新的产品，直接把你这事干掉，而且越来越不需要写太多代码，这是个问题。制造业工业开发中数据库有很多列项，通过实现问答输出什么的，什么路线比较靠谱？专业领域的数据库有一个项目我觉得很不错，而且是开源的叫 winner ai说白了就是你想实现一个agent来去查数据库的一个agent，这是一个挺好项目的winner AI你可以直接把它部署到你那儿，然后他就可以直接帮你写SQL，查你要的数据库了。它就这么一个东西。然后你甚至在开始你需要把你的数据库的所谓的一个schema，就是表头给它描述清楚，到底每一个字段到底啥意思，每个表达。Navigating through a sea of data can be done.

我觉得那网怎么那么差。那那我就不演示了，就这个推荐给大家。如果想做这个chat BI类的产品的话，想开源的话，那就用这个其实挺好的。

上庭下庭法律模型，法律有很多，比如说质朴的叫有一个chat law这个是不是这个？你是想要开源的模型吗？待会儿我看一下，然后不认为卖到四川什么核心。对，没有核心突破。这个绝对不是deep six。结果我觉得这个50个不对，500个minus加起来也不够一个。

第三，然后应用AI实现的建筑行业中提供什么什么投资成本，根据改变OK，我不知道你想输出的东西是什么。是如果是这种室内什么什么那种可视化的装潢图，室内软装什么这些，那其实不用到大模型，用到这个diffusion模型其实就可以做到了。就用conf UI那种就好。但是我看起来其实你是要做一些更多的事深度的分析。比如说我的方案，它的这个成本计算，然后选型这些东西，这其实用推理模型就好。但是关键是你得把你的各种的供应源，就是你的供应商，你的采可以采购这些商品给描述清楚。然后让他根据比如说用户的需求来去生成一个方案。

但是你会发现可能模型生成的东西，它只能依据你自己很很基础的描述。比如说这块瓷砖是表面是花纹的，然后什么什么的来去给你做搭配。但是实际的那些感官的触觉的更深的一些技巧和技术上的一些指标，其实你很难把它变成一个我猜初期很难把它变成一个上下文扔给大模型。所以这块你要去花一些精力，把你的这个各种方案所涉及到的底层的数据给整理好。整理好的这个过程中也可以联系我们，我们像找陈浩什么的，我们的团队来去帮您去分析一下来去看到底现在数据怎么把它变成一个，可以，最后这个质量够不够是还需要更多的数据。

AI取代普通员工，现在已经在取代他，连公务员都取代。然后AI翻译是直接下载一个翻译成对对对，沉浸式翻译，沉浸式翻译。再说一遍，minus一旦普及开调用算力需求更高。当然这个minus这种东西的算力据说是普通对话的两个数量级。那啥的意思就是他们其实说透露出来这个内部说这一个任务完成的成本是2美元。你比如说你订个机票去日本订机票这个任务你让他干2美元，你愿不愿花吧？哼如果不愿意花，那这个事儿其实manus普及不开。那那除非他自己在内部做了非常多的策略优化，让这个2美元变成两块钱，我觉得差不多才可能在国内能普及开。但是在外国确实两美元也是OK的了，但是与之对应已经很低了。

与之对应的其实像deep reserve这种，据说是一次二十刀以上的成本。你想让他deep research写一篇文章要花二十刀，那就更少人愿意用了。然后DC出了多模态模型，还有哪些挑战？这个有已经有一个团队去拿他的MLA去做多模态模型了，然后挑战的太多了，我觉得现在的模型只是第一阶段，第二阶段就是类似说的open I的这个level two。就是他的reasoner部分确实挺强了，他能自己反思自己去迭代。

下一个要挑战其实就是agent各种类型的这个问题。比如说他是不是能很好的帮你完成任务。大家看到了menus有那么多问题，然后o Operator就那个open I的也有一大堆问题，其实都很差的，还挺多的。所以deep sig这个r one，大家其实都在期待他的r two。他除了r two让推理能力更强以外，我觉得下一步可能非常多的问题，多模态方面的，to action方面的都是非常具有挑战的事。没。

然后想做一门面向几千家连锁店的智能客服，怎么开始着手模型推荐。首先没有模型先不要考虑模型推荐你就用最强的模型，能你能用到最强的模型。比如说你你你要有办法，你直接用4O也OK然后能用这个O一也OK用O3也OK，然后这个当然是看不同场景了，你需要推理的还是直接回答。

然后第二其实就是要干啥，就是你给这个连锁店门店提供的客服。如果就是一个问答，他是针对连锁门店的这个人这个负责人，还是给连锁门店的这个用户的来去用的那你就看就收集一波到底是什么场景，一波场景以后，就开始把它转换成各种的框来去试哪些prom是可以直接靠世界知识完成的？大概率很多知识其实要靠你的内部的知识库完成的。你就要开始去找对应的哪些知识点，哪些文档需要去准备。准备起来以后，你边准备，你说这篇文档就能完成这个任务，你就把它塞进去。那篇文章又能完成一个新的prom的任务，我们就把它塞进去，塞到哪儿呢？像这种define什么的，就OK你就直接扔到这种免费的产品里面去试。

然后做的过程中，我觉得你但凡比如说你自己列个555五六十条这个框，五六十个场景对应的什么100一两百条prom。然后你自己传背后对应的一些知识库的这个文档扔进去。我估计可能初期能有个百分之三四十的准确率。

OK好这个时候再去做每一个环节的优化，包括数据的处理，这个prom的改写，home的这样一些召回的准确率这些事儿，这个事儿你就心里有底了。你有一个baseline是最重要的，因为基础的基础线这事儿是最重要的，先把它跑通。如果DC出，不对，在合规和不涉及商业机密，能不能讲一下to b to g的案例分别解决多少问题，提到多少钱？

这个可以。小明我觉得接下来可以准备几个案例。小明因为时间有限，我就问两个跟行业相关的。一个是汽车行业有几十种文档审核的应用，好像是不是可以找时间让昌浩他们来用一下。我们现在用豆包的这个智能体，好像能讲吗？回头问一下张浩，他们做了很多跟这个相关的。

好像是吧嗯呃文档审核也特别多，金融领域也特别多。

对我觉得。

这个可能更适合，比如说我们开始先收集一波，然后我们在某节课就专门去过一遍这几个问题。

然后做个例题分析什么之类的对吧？

对对对，因为这个肯定这个bob同学是有很实际的挑战的，所以也如果可以的话，也可以跟我分享一下你现在遇到的具体的那个问题是啥，这个我们就具体案例具体分析呗。畅想就先别唱。

对，我们跟昌浩也和那个合计过，我们分行业给大家做一些具体的分享，我觉得大家可以稍微期待一下。

然后咱们对于一个建筑设计师，如果能让AI快速生成很多强排方案，满足指标规范要求，现在有模型可以实现吗？

这个国外都有很多，但是不是用大模型去做的。我之前有一好早好早有一次分析，就是那种强排的这种AI的这个产品。就是你直接给他一块地，他他最牛逼给块地，然后他还给你弄个楼，每层的那个布局都给弄好了，甚至这个渲染效果都给出来了。然后这个约束强烈强一点了，你给他一个平面图，就这一层就是这么大。然后每一个块都是啥，他这个你有啥东西想盘去定好，然后他就给你排进去了，有非常多的这一类的工具可以去做，但是我没见到拿大模型来去做的那可能没啥必要。对，因为你像说你监管要求什么的。

小标马上50了，一般咱们AI的课程时间都比较长。我再问个问题，这是第四节课了，那我就做一下用户收集。的确是刚才有朋友也在私下里给我发信息，说大家刚开始说因为DS这个事，大家弄的心情特别高，恨不得一口吃个胖子。上到第四节课了，不敢听不懂，退了课不然又买了，发现还是听不懂。大家听到第四节有多少？这四节课有一点能吃进去了，有一点尤其是刚才有朋友给我反馈说，第一节课可能也得听，那第一节课还是很重要的。有多少朋友，其实你们感觉有点感觉，因为这个课他不是那种特别的上手，就是让你们去提个问，做个PPT什么，不是那种东西。有些对你们好像有点启发，有点思考的，有一点点能吃进去了，就已经很快了，我是觉得这是第一个。

然后第二个就是有多少朋友这四节课里讲的一些东西，你们真的去试过的？一点儿都没试的，走吧？没试就是小平老师讲的这个东西，你们真的哪怕翻译那个东西，你们拿着去试一下，我都觉得是好的。这个你至少你要上上手，你不能光在这听吧，有没有去试一试的？就是希望大家都能给我个反馈。

我们现在在线差不多200人，这个东西我觉得有很多东西，等于是不是你比如说我们也可以做几个这个有些小小工具，你们可以去试一试，你们可以去感觉自己回去学的是没事的，就一点都没进去的，走路没进去，一点都没试过的，走路没。这个我大概看看比例文档，还复看了一遍。那有多少朋友有多少朋友你们现在一节课只能听个三五遍的多？这样的可能都是日常在用，但是我知道咱们直播间里有高手，他们可能线下组织活动的话，我们可能不行，先把高师傅请过来，我们来摸摸情况。

没试过还没试过，我建议大家试一试。而且尤其是开头这几节课，我给大家提个小建议。因为我们也在整理整个课程的内容，尤其是开头这三四节课。如果大家真的想跟上的话，因为大家知道尤其包括那两节试讲课，虽然那两节一节偏深一节偏浅。大家要知道那前几课的内容信息量是比较大的。我建议越是靠前的课，大家越去多花一些时间听一听，多听几遍，翻翻复听，然后拿着东西试一试。

这就跟我们开始学写字一样，你头两笔，你那个笔你都拿不好，你这写什么都别别扭扭的。你写顺了之后，再多学十个字，再多学五个字，你就不觉得很难了。刚开始这段时间一定要熬过去。的确我刚才很同意一个帮的说法。

大家一上来之后，因为DS这事特别火，大家心里比较浮躁。但是学这种东西，就这么新的技术，大家还是得有点耐心，真的有点耐心。前几天听两遍特别好，特别好。那个小票要不咱们先这样，然后我们也在准备。

下一步的。行行，我我我插我插个话。

好，这么一说。

对，因为大家好，我是王东理，我就是小平师兄后面的男人。大家上完课大概率就会往我这找，绝大部分都在联系我，大家热情都很高，对这个AI的想法都很多。有一点很同意这个师师兄说的，第一问我最多怎么跟上这个AI这个事儿。跟上的第一你就是赶紧把能用的工具都给用了。然后我们也都在整理一些工具包，给大家去发一些列表，大家可以根据自己的行业去试。

第二个事情要提醒大家一个什么事呢？很多的事情大家提了很多的需求，确实AI能解决有一部分的需求。但是从个人的性价比角度来说，肯定是性价比有问题的。我换句人话说，就是你个人去付这个费，去把这玩意开发出来，对你个人肯定是没有性价比的。很多的时候这个需求是要上升到企业端，对吧？

还有一个问题，就是在企业内部去推这个东西可能也有一些阻碍。比如说你们在座的各位同学肯定已经是非常积极的去拥抱新事物的人了，肯定在人群中是极少一部分。但你的领导、你的同事，你的下属，他们有你这个认知吗？我觉得大部分人是没有的那怎么把这些落下去？他们是不是需要学习，要培训，是不是有什么办法？

企业内部很多的时很多情况下，大家就问AI到底怎么落地，刚才一个问题我看见了，我要开个几千人的那个连锁店，我怎么弄这事？我们不要脱离具体的场景去聊AI的应用，我们只会在一个具体的场景里去了。怎么让AI去优化这个工作，我们的AI现在做不到。你是问我一个专家，如果我能说我把几千个连锁店事都搞搞透了，我自己不就是开几千家连锁店了吗？对吧？所以我们一定要聚焦到具体的场景里。

这边我和昌浩的团队，我们确实在这方面是有一些经验。我们可以跟企业做下来去场景去筛选哪些场景适合去落。这个企业有条件去落，我们能帮你筛出来OK。如果有这方面的需求，或者说这个需求比较方向比较明确了，我觉得你一定要及时来跟我们联系。我反正随时都在后台是吧？我已经跟咱们现在在线200个人我已经我估摸着我跟190个人都打过都都打过交道了，好吧？行，我就说这些。

OKOK各位辛苦了。小明要不今天咱们先这样，然后大家还是要有耐心，尤其是开头的几节课，建议大家反复看。然后小明我最后一个问题就是不管是因为我看宏观看的更多，还是最近的跟AI相关的各种政策，你们在业内有这种感觉吗？可能比如说未来的3到6个月，有可能是咱们AI的爆发期，有可能就有可能层出不出来。你们现在什么样？

中央的这个发文了，鼓励各个行业用大模型。对，就是老板还给我直接夸队一张图给我。对，但我觉得一是中央发力，然后二是说像C这种的成果。我自己的感觉，尤其是在比如说你看了一些paper，发现其实有非常多的埋在底下的这一类的工作是没有被爆出来的。或者说就像minus爆出来了，那那后面有80个minus都都一般都都也就藏在底下。

当然有很多的领域我觉得是有有机会的，尤其是一个是agent就是国内的agent做的其实说实话真的比国外牛逼，这个我觉得是确定性的那A正相关的技术，A镇各种产品，agent其实就是所谓的模型的模能力跟。应用场景的结合的最关键的这个点，那这个点其实谁擅长，那肯定是中国人擅长。我觉得但凡模型能赶上来，就是r one这种下一代的r two或者说质谱再发一个，对，反正各种的多模态，什么VLA这类的模型，其实已经快有点接近的程度了。这个时候大家拼的就应该是落地了。我觉得被接下来半年，绝对是一个大的风起云涌的时候。

对我提这个问题，因为虽然我们说这个课跟股票一点关系都没有，这个问题肯定是两边兼顾一下。今天中午我最后就说了一句话，我说说不定这个对吧？中午直播的时候，我说的今天来个大的，结果咔嚓给我封了。我还说为啥给我封了，这个给我关了，原来是下午出了门，但是我完全不知道。小明，感谢今天的胡子的造型特别好啊，提出表扬。

忘了忘了。

忘了这样给他们留下个1到2分钟的时间，对今天冯小平老师今天晚上精彩分享表示一些感谢好吧？然后我没有其他要总结的。这个本来是其实刚才我只是想用这段话来总结一下，结果万万让大家感谢了，你们就感谢就行了。



然后小明，我还是下周四晚上八点，咱们继续好吧？辛苦各位，辛苦各位。我知道不管是冯老师来讲这个东西，还是大家学这2个小时都比较烧脑，大家好好补一补，然后找个时间反复，然后把这个东西多看几遍，多看几遍。咱们下周四晚上继续，然后我在这插一嘴，正好你们留点时间感谢小明老师。我可能还有一周的时间，最近还是要反复出差等等的过程中，这个我尽可能的另外一个就是在直播间大家提问的时候一定要注意。同志们，我我我这几天还播了三天，播了三次，被封了，被封六回了。你然后每次都提示，这个大家一定要注意，好吧，这段时间还是要在网上发言，注意好吧。明天晚上，明天晚上数字经济稍微等一下，我预告一下，等等，明天晚上的数字经济讲什么来着？我看一眼明天晚上近期科技行业。

产业趋势变近期。

科技行业产业趋势变化，近期科技行业产业变化应该是个综述性质的。然后明天晚上我可能不在，先给大家提前道个歉，然后也会请刘涛老师或者谁来替我代个课。好吧？小朋友这么着辛苦，咱今天先这样。同志们拜拜拜。

拜拜拜拜拜拜，下周见。

吃吧。