

这个人到了就直接往外放就行了。大家能看到吗？你总还有个预热阶段，你可以提前几分钟把这个屏幕开开，好吧。

能看到了吗？同志们。

那个有没有在线的？可以了是吧？OKOKOKOKOK可以了。那那我得我我我想试个东西，看能不能把我的ipad投到我过去，没问题，等你。能看到吗？大家能看到我我我的ipad屏幕吗？

能看到，可以可以。

没问题。这不错。那我就可以直接投这个，那我就开始了，小明开始我先铺，然后回头让动力验收就得了，好吧？我今天晚上正好那边也会，欢迎大家来到今天的AI知识圈。我们还是例行的每周四晚上八点，这个课就不需要我再铺垫太多了。

原来跟大家强调过，这个课就需要大家有一点信念感、使命感，内容可能需要大家比较长的时间去消化，可能有足够的耐心。这课主要针对的还是希望主要针对还是前沿的技术应用和一些案例，然后包括因为小平老师对这东西很熟了，我就不用过多的介绍，能在这个思路给大家一些启发。主要是希望能够通过比较长的时间的积累，大家在传统行业能建立起对AI的一些认知。我们这课不是奔着什么智能体，PPT做个图片去的，是希望咱们直播间里真的有些朋友你们能建立起对AI的认知。你不管是在自己的生产生活中还是公司，或者说你们在一些政府机关、企事业单位等等的，提出一些好的思路应用。然后我们在整个传统行业和人工智能的握手，能够更多的突破，好吧，然后我就不啰嗦了，因为每次这个课的内容都非常的多。小平，你放开讲，剩下时间交给小平，小兵辛苦了。好嘞好好。

大家好。我我我插我插一个小平，因为咱们奖励一下准点来的同学们，周四晚上不容易，是因为大家因为在后台跟我说了，要很多的工具，AI工具。然后我们就系统的帮大家整理了一个AI的赋能包，差不多一共有70个场景的工具。然后还有附使用的指南，还有一些提示词的合集，然后还有包括小平老师帮他筛的这个AI领域的文献包，然后这个整个的资源包，我们会动态的去更新，因为现在经常都有新的工具出来。因为后台大家都在企业微信，有咱们四小董的客服，对吧？OK大家去跟他备注，这个AI礼包就能领。这个是咱们准点到的福利。待会他们晚到了，那没听到我就没办法了。AI礼包，咱们客服好，下面交给小平。

我再问一下东西，那你能看到我，因为我把我的ipad mirror到这儿了，能看到我ipad吗？

我看到一张笑脸。

对是吧？我写了个小字，能看到是吧？

对，能看见。

好，那就好。好，小兵开始。好，大家好，又见面了。然后上周其实这个时候应该是menus刚发出来，这周其实出了太多东西了。我觉得刚才还跟我们同事聊，说这个奶瓶paper看没看过，或者哪个东西看没看过，然后那哥们说根本没空看啊，然后说问我说另外一个人有没有看过，我说我连我都没空看，那我确实大概率大家都来不及看了。

对，所以这领域发生的事情太多了，我也不一定能跟得上，但是这个也不一定能跟那么紧。但是我觉得尽量给大家能够追上一些新的东西。但是追上新东西的同时，我不希望变成一个新的信息发布站这样的一个或这样的一个分享。而是每一个碰到一个新东西，我希望能跟大家说说它的这个来龙去脉，它的底层跟哪个东西有关。这样一下这样大家以后看新东西的时候，其实肯定不会就不会说来一个新东西，就全新的这样的就跟大家上周看到有一些自媒体号看的minus一样，就是觉得天神下凡这些东西。对但如果大家通过一段时间，应该大家会感觉到，manus确实还不错。但是它不是一个全新蹦出来的东西。它底层的一些东西其实很多基于以前人做的东西来去延伸的这样的一个感觉。

好，那我们就开始，前面我这周东西比较多，所以我就不放还放的那个环节了。就是这周出了什么新东西，给大家秀一下这个，我先讲，然后看看这个，如果还有时间的话，给大家看看有些什么新东西，还有什么新的一些应用。前面就是agent的这样的一些整整个这一周，其实很多都是agent相关的这样一些新的东西出来。然后这张图我记得上周给大家看过，但是没有详细讲，我觉得这个是值得去详细讲一下的东西。我先把我的屏幕投一下，给大家讲一下整个的agent到底是个什么样的一个过程，大家能看到这个屏幕了是吧？就刚才我说这个就我现在手写的这样一个东西。

最早的时候，我们说有一个用户，然后他要去跟一个大模型能看到是吧？确定能看到是吧？我现在切不出去了，就是谁能能看到，能看到是吧？好，然后开始就是这样，这个用户说了个话，然后让大模型来去回了个话，对吧？这就是最早的这样的一个check out这样的一种出行，那过了一段时间以后，我说不就用户不满足于说他要这个只能给我回话了。

他要能去调用一些外部的API，然后调用这些API比如什么呢？比如说一个get to weather，获得一个天气，用户问说北京天气明天天气怎么样？然后他纯靠模型肯定想不出来，所以他要去调外面的API，那他调完了以后，结果返回一个API的反馈结果，说这个天气明天是18度，然后他就把变成人话反馈给用户。逐渐这个API就变成了越来越多，越来越泛化。大家就不是局限于它叫这个API这种东西了，我们就把它泛化叫做tooth，工具。

好，这个tooth越来越多，比如说有有个比如说有个锤子然后有一个一个剪刀。比如有这么剪刀，然后还有别的。这个时候很自然的想法，就是我用户的我的音频对不对？我怎么好像觉得音频变错行，我能听到。对，就是很自然的想法就是我到底选哪个工具？对，就我选到底选这个锤子好啊，还是剪刀好，还是别的好。

这时候就出现一个叫做to selection的问题，就选工具的问题。那怎么选呢？靠大模型纯靠大模型自己去搞。这个时候有时候大家就会觉得，有的模型他可能擅长说话，有的模型擅长干to selection。那是不是我可以把这两类单独分开说，我专门串一个模型用来做工具选择。那现在后来的就不断的就就逐渐的变成了说有些服务是专门去帮你做工具选择的，甚至把它变成了sas就类似于to selection as a service云服务，我云服务干的就是一件事儿，就是你的curry到底在你的几千个工具里面到底选哪个这样一件事儿。

好，那开始又来又又越来越复杂了。比如说我要的问题不光是说我工具，我还可能我要从我的数据库里拿数据。比如说我的DB的这个数据，我的很多的文件。好，这个fies DB那就带来了一个很大的一个领域。

第第第三节课给大家讲的rap就是智库的这个部分，这个东西也变得越来越复杂。有一次给大家看过一张图，就是一个标准的rag流程，大概分了也有十几个流程十几个部分。每一个部分甚至每一个部分几乎都可以把它当做一个专门的一个sas来去对外提供服务，来收钱。当然这个在中国不太一致，中国基本上大家都是大一统的这样一个reg系统，知识库系统来去干这件事儿。

那有了这个东西以后，我们发现好一个一个agent，后来我们就逐渐就不把这个玩意儿叫你叫他LM了，我就把它叫agent。这个agent本身就包括了LM然后to这些东西，所有的这个知识库乱七八糟都包括。那他用户对这

个agent它本身的要求就会变得越来越复杂。就比如像manus这种东西，他就要求你不光能调工具，还得能调文件，还得能干嘛呢？很重要的一个事儿是你能做好规划，能做planning，或者叫这个过程中还会有叫反思reflection，这样的一些过程都要做好。所以他对于模型本身的要求就越来越高。所以就像跟上次给大家讲这个menus的时候，有一个叫盖亚的这种券，或者叫什么人类最后的考试的那个那个是等差就越来越复杂，那这个时候还是得单位的，我们对于这个单位的是有很强的诉求的，或者说有很高的要求。

那我们就想说，那这一套agent它可能就擅长，它是由大模型或者是多个模型和一大堆tooth和一大堆文件组成的那很自然的想到说，我一个agent可能就擅长某些方面的事儿，那是不是还会有多个整？那自然而然就会想到那个叫agent 11。我们把它明白，那我们还有AG2甚至A减3。每一个A站都是一大堆这样的东西，跟他差不多的一套东西。

人打交道可以是只跟一个A镇打交道，比如就这个A镇就这个A镇跟他打交道，那我们一般把它叫前台A镇就跟公司一样，有一个前台他负责去找你的需求的对应的这些专业的agent来去帮你干完这个活。当然有些现在也开始尝试说，把这个让一个用户可以同时接触多个agent然后让他自己来去判断我到底跟谁聊比较好。但是普遍的最佳实践还是说我找一个前台agent让他来去做这个分发的一个事儿。到了这儿以后，开始就开始提到所谓的叫这个词儿了。

Agentcity为什么呢？就是因为一个A镇的时候，他其实做这个文件的调取和工具的调取都相对来说还是人比较可控的。但是我但凡这个A阵变成了一个前排A阵，然后那他去调用的都是他自己来选择我调二还是找三来帮忙。这个时候一定程度上就脱离了最开始成全的控制，或者说对就是说白了就是脱离了政权的控制了。所以这时候我们就开始说这种系统叫gene的系统，他就特别的挨着特别这个形容词的话来去描述这种东西。

那自然而然的就会往后就想了说好，那以后的系统会是什么样的呢？会不会是说人跟agent一起协作，这个团队里面有人有几个A镇一起去干活。好，那这个时候人还好说，对吧？人是有点道理可讲的，或者说我们有办法控制。但是这仨挨着互相聊了啥，他们怎么达成，关键是他们怎么达成一致。比如说他们仨一起干活，然后有一个活干了干的过程中聊了好多人，不知道到底什么时候他们会达成一致。这个就带来了说所谓的t mate这些事儿，这些问题就是agent之间的协作关系。甚至再往进一步，agent跟人之间怎么去做AI的这个team meeting，这个组队工作这样一个事儿，大家怎么达成一致，待会儿我会有一个PPPDF给大家展示，有非常多的做法可以去做。

所以到这儿为止，基本上我们就可以看到了，这个就是我们从一个agent开始来聊天。为什么到后面有这么多复杂的这些整个的工业，就这个技术战的这些点，我们可以看到回来看到这张图，这个玩意儿就叫AI agent infrastructure stack，就是基础设施技术站。从最底下就可以看得出来，我们有pass有什么？对这个evaluation没说，就是人跟agent之间聊天的时候，肯定要有个评估，说你到底说话说的好不好听，干活干的够不够好。所以这个是evaluation评估的这部分有非常多的供给都在做这个事儿。那多agent之间的协作，就是muti agent框架。那这个agent跑在哪儿？这个就是这个东西就是我的各种的所谓的pass或者bus，这个就是that end as a service，platform as a service这样的东西。

就是程序跑在哪儿，然后另外一个logging，其实就是我们agent跑了一大堆，可能人说一句话他得干干俩小时，那这俩小时他都干了什么呢？他先干了什么，后干了什么？有可能可能产生一些问题，一些安全问题，需要大量的logging。这个logging其实并不是传统意义上那种我们的固定系统的那些logging。你会发现里面有大量的模型跟模型之间的协商的部分。这个东西怎么唠也是一个非常新的话题。

再往上就是o castro，大家记得reg的时候讲过这个词儿，这个词儿肯定会重复的出现在大家的视野，叫编排。这个oracle其实就是说我怎么把每一个agent能够很好的让他们按照我预设的这样一些 workflow来去工作。这个部分会有很多，比如说A镇之间的路由，A镇模型选哪个模型，就刚才说的，我到底to selection是不是也可以专门是用哪个模型，或者什么query用什么to selection的模型来去做，都OK都是一个挺大的一个市场。

再往上就是data，对吧？我们A站得有他自己的知识库，得有自己的记忆。比如说用户这个人经常跟他聊说跟他说了说我下周四要去某某做一个分享，然后去给比如说中学哪个中学学生要分享一个什么AI的相关的进展。这个模型如果这时候有些agent他就会记一下这个东西。他认为这个真的是这个用户本身的一个人的生活经历，那他就把它记到一个memory里面，这时候的memory我们就称为它叫长memory。Long memory.

就是说白了就跟这个人用户本身的生活经历就有关了。这个时候这个memory就非常有用。但凡持续的积累一些这些memory以后，基本上我们就可以认为我对这个人挺了如指掌了。但是大家很容易想到，我生成发出这个问题的時候，有可能也是假的，也不是真的我要去分享。我可能就是为了这个PUA1下模型说你我很我我很我急，你要好好帮我做这件事儿，那他把他真的当真了。

记得memory里也不好。所以现在主流的像chat BT这样的一个产品，在memory里面去做了很多这种让你自己去修改。这个主要是删除模型产生的这个记忆的这些工作，挺有意思的。当然这个你要往前添加其实是个挺大的问题。就是你是让这个记忆让你人去添加，还是让模型持续的跟你聊的过程中帮你添加，这是一个很讲究的事儿。

然后刚才说了有大量的数据，这个data base或者文件都要扔进去，让模型能随时访问，让agent能随时到。那storage是一个特别大的一个领域，那storage的里面的数据咋来呢？就涉及到这个ETL，就是我们大量的文件怎么灌到这些数据库的下面数据库里面。然后上面其实就一大堆tooth了，就刚才说的tooth，虽然我就放了一个锤子，一个剪刀，但是里面的事儿可多了，到底是用户能用哪个呢？用哪个tooth呢？什么什么用户什么角色能用哪个tooth呢？这些OSS这些认证的部分。

然后工具，比如说如果是浏览器，上节课也讲了有一个叫叫broster base的这么一个服务，它其实只干一件事，就是给你提供一个云端的浏览器，就光是这一个东西就已经非常大了。你看这就是browser base。除了broster base，还有很多别的公司，像什么bless，API file什么，这些都是干这件事情的，就这种服务，然后3 box就是我的这些工具跑到什么地方，那我这个工具肯定不能瞎跑，跑到我电脑上给我删文件就完了，所以是这个事儿。然后再往下就是各种的垂直的这个agent服务了。然后到上面agent其实就像minus什么，就是在这个部分的事对，所以回过头来我们再看一下这个stack，感觉就大家可能会感觉的更清楚一点，就更知道说这个到底agent是个什么样的一个浏览的工作的过程。

然后我们我们再把刚才的那个打开，就是这个其实很早的，这个我可能得写了得有一年多以前的关于A镇整个的发展过程的这样一个具体。其实第一个就是我们认为其实到现在为止，大部分的工具，像copilot什么这些都是这样的一个第一个阶段。我管它叫经典的或者传统的AI和copilot样一个阶段，叫AIS two的阶段。就是人要干一个什么事儿，他自己来去思考他干的一个过程是啥。然后其中的有些环节可以被红色这个工具赋能，被绿色工具赋能，让它变得更快一点。但是总体来说，这个整个流程还是人来去打通的那第二个阶段其实就像刚才说的，就是我们把一个模型能够让它自主去调用工具来去完成。而这个时候，所有的任务规划都是让模型来去干的。基本上现在的minus或者像这个Operator什么的，其实都算在这个阶段里面。

那我们希望模型或者让希望agent能够自主的去干，那人只要发出这个命令，就是帮我干这个事儿就OK了。所以这个时候有非常多的现在就当其实就是当下的节点有非常多的机会和这个需要注意的点要去做。比如说这种沙盒这些东西。

然后第三个阶段其实就是多维整体了。其实现现在像minus其实也可以一定程度上称为多维整体。但是像比较经典或者比较明确的，其实是更多像这个open minus这种或者OWL这种，这个是什么呢？Open minus是上次是上次我忘了说没说，就是meta GPT这个团队这个判断，这是一个多agent体的框架，看这叫muti agent的

smart。待会儿我就说到open I也开源了一个这个东西，也开源了一个框架，然后这个团队做了据说花了三秒钟，四个人就做了这么一个open menus。大家可以看看效果所以这儿我可以提先提一嘴，因为我觉得可能会有不少同学对于这些开源项目会能不能实际跑在自己的业务场景中很感兴趣。所以我们可以从下次课开始，我们去把这个大家可以去提说。

比如说大家想玩open menus，想玩某某某这个开源项目。然后我们看一下，如果我们觉得这个。可控或者说我们可以搞定的话，短期内能搞定的话，那我们可以帮大家帮同学们把它搭起来。然后大家如果有需求的话，就直接可以在我们搭的这个环境里去玩一下这些开源项目，看看是不是真的能符合你们的业务需求。如果不能的话，那大家可以再找这个找叉，找动力来去做这个更定制的开发。如果不如果能的话，那我觉得是非常好的一个事儿。大家能够以非常快速方式能够试起来。

然后我们看看这个open minus他举的一个例子。其实我们还是跟上节课似的，就是看那些所谓的割韭菜的课。看啥？这个是很关键，我觉得是有价值的。有价值就是看这个业务场景，你看他的业务场景是啥呢？就是他写了这么一段话，他是倒着来去来去贴的。我就大概给你们翻译一下这个意思。你看他倒显示不太好显示，说白了就是你去做一个完整的IEO的检测。

IEO的知道是就是那种网页搜索，浏览器搜索的这个优化，就是你你的网页更容易被浏览器搜索到，排名更高这样一个搜索优化。然后针对哪一个呢？针对kapali它的网站大家还记得吧？Capi这个名我跟大家说了无数遍了，一定要记住，一定要记住capi这个阿帕奇点AI这个网站，针对他这个网站做一个，没有吗？卡帕C点AI我拼错了吗？没有，这卡帕斯AI就这个人自己的网页。大家可以看到这个工作不多，但都是很牛逼的这个节点。

然后针对这个网站做一个SEO，就是做一个搜索浏览器的搜索优化。并且给出可以优化的具体的报告和可以实施的推荐的这个优化行动到底有哪些，但是很很能想到这事儿其实就是一个标准的IEO的这么个事儿。那他以前怎么办呢？要不就找认识的干这行比较熟悉的朋友，要么就找这种能提供这种服务的网站，服务在线服务来去用。那现在其实完全可以用像open minus这种，你只要后面接了一个模型就可以干这事儿了。

你可以看到它整个过程就开始跑了，就是会有他自己会打开这个网页，然后会去上下看一看，然后还会看他这个网页本身的这个HML。因为它是整个能拿到这个网页的信息的，然后就可以整个看这个HML。因为ICU很在乎的就是这些网页里面的一些标签是不是比较合理。然后他就一个一个找一个一步找一步找，对，然后就可以最后给出一个所谓的优化建议。

你看这个右边一个凹SEO的审计报告，这个东西，对，这就是open minus。然后大家看他是怎么装的，其实都很容易就怎么装就好了。然后你只要配一个，你要访问哪个大模型，然后你对应的key配上就能跑。对，所以这个就是当时meta GPT这个团队的几个人大概搞了几据说搞了几个小时就搞出这么一个项目。所以说白了像minus这种项目，它的门槛确实会低挺低的。而且并不是说大家竞争激烈，并不单纯是说他做出来以后别那像matt GBD这样团队也很容易去抄一个克隆，也而且还是包括了大模型厂商也要下场干这种事儿。待会儿讲到OpenAI的时候，这个agent SDK的时候就会说到这一点。

然后我们回到这儿，下一个阶段肯定是martia镇，就一大堆A镇的互相协作完成。有不同的agent擅长干不同的事儿。比如喜欢写擅长写报表，那他就专门接报表的活。擅长选工具、选模型、选A证来帮你干活。他就是个门卫，然后接待前台，然后擅长画图，就让他干这个事儿。这个很自然很很的直觉。

再下一步，他可能不是一代，但是我觉得很有可能一个阶段就是用户不会不会被排斥在agent之间的协作之外，而是融入到里面了。就比如说开始的时候，就像上次我给大家演示那个那个replant这个产品，就是一段话直接生从APP的这个产品，那他会先去说一个需求，然后agent就会说，我这么干行不行呢？人再说一个OK，

然后他们就开始干了干的过程中还会持续的说，有些有疑问的地方还得问老板，还得问人类。然后人类主要就充当一个监工或者是做决策的这样的一个角色。

另外还有一个重要的就是这些agent如果我们放在企业内的这个环境下，大企业内的环境下，就是会有巨大量的数据。数据库也好，你的内部的API也好，你的各种工具也好好。那这些东西我如果我们放开了让所有的A站都随使用，其实是一个挺大风险的事儿。所以可能会出现一个专门去统管所有的企业内各种资源也好，数据库微服务API也好，工具也好的这样的一个单独的一个agent，可以叫他这个data agent。他是专门去管这个对接企业内的服务的这么一个角色。他来去做这个闪现管控，然后安全选择，这些事儿会比较统一，那这个阶段，我就称为它叫协作agent，而且是human in loop的人在回路的这样一个协作agent这样一个阶段。

那再往下是啥呢？就有可能说我一个企业里面有大量的不同的活，不同的团队在干不同的活，那不同的团队他干的活不一样，也带来的结果就是可能这个里面需要的agent是不一样的。那我就很有可能出现一个，真，agent的这样的一个阿森纳军火库，是吧？这个武器库这样一个东西，那企业会做一批比较标准的企业级别的agent然后你的团队随招随随招即来，然后我需要什么？我需要这个PM agent，我就来一个PM我需要一个合规的，就招一个P招一个合规一个，然后来一起干活，干完了以后就不用了，就走了。所以这情况下，我觉得可能是未来的这个企业的一个合作的标准的方式。

然后刚才说到这些A镇怎么最后达成共识，这个其实也挺早的一篇paper了，1323年的，这个就是说有几种办法，比如说这个就纯说服，这个有一个过于自信的，然后一个比较随和的agent，然后有一个过于自信的他们就聊呗。那相对来说这个比较easy going的这个agent就是比较容易被说服，然后那个就会有更多的，比如说所谓的constitute这样的一个多个agent。怎么像这个康熙咋分了？叫什么议会，还是什么东西叫反正就是类似于民主选举这样的一个制度方式，来去达成多个A站之间的共识。然后还可能比如说我们让他吵架debate，让让agent之间吵起来，然后吵到最后看谁能吵赢谁。还可以比较谦让一点，让大家都自我反思，自我批评，然后这个reflection大家都更多的reflection，我就反思自己，最后达成一个共识。

那可能就最后的未来，就是一个所有这些模式的一个综合体。就是又要大家这个辩论，激烈的互相debate，也要让大家自己能够反思reflection。然后最后达到一个比如说很多agent达成一个共识的这样一个过程。所以大概是这样的一个过程，所以我觉得未来的agent其实大家也不叫未来，其实可见的情况下就是这样的一个发展趋势。

这儿有一张图，这是很早的了这样一张图。然后当时我画的，我觉得到现在其实也不太为过，可不太过时。我们现说白了这就是一个我们对于未来企业的跟AI之间的业务和这个AI的占比的一个变化。现在的大部分的企业，其实它的业务逻辑都是在企业自己做的。AI更多的只是在系统里面做一个支持的部分。那随着agent这类的业务的这种参与度越来越高。我们会后面可以看到的就是我们大量的中台系统。

比如说业务中台、数据中台，这些东西会被AI给压缩，压到什么呢？压到你就剩下你这个企业最核心的那些业务。比如说你是做物流的那你说白了你的核心业务就是把一个东西从一个人那儿拿到另一个人那儿交付完成。那这个东西大概率不太会被至少企业刚才说的这种企业agent来去取代。当然你可以说他后中间有什么快递机器人，乱七八糟这些东西。但是那些其实更多的是从替代人力的，或者消减人力消耗的这部分来去讲，而并不是真正完成那个业务。所以你的业务的部分会变得越来越小，直到剩下的就是你的核心业务壁垒这部分这样一个东西。

所以行，然后大概就是第一个部分就大概讲一下这个，所以就是说我们agent是怎么工作的。对应到的大家以后再看这种技术栈的时候就不会就不要慌，其实就那么回事儿，这个万变不离其宗的。大家看一个比较离不离其宗的就是像这张图。

你看这个图其实就是所谓的AI自动化，什么agent market map这些东西你往底下看无非就是数据，它叫什么？起了个好词儿叫数据抽象，说白了就是数据清洗、数据整理数据的这个平台，你看这些东西都在这一层，然后上面就是agent的computer interface。说的更虚了一点，就这个agent的电路的交互界面。然后这儿你看提到了brother base，大概就能感觉到是个啥了，对吧？

然后给大家看一个更那啥的，就是这个玩意儿，dave agent这家公司特别的eat agent。对，大家可以看这个就是一家公司它的网页。你就这个如果写个代码就很清楚了，这玩意就是个shell，就是一个命令行，对吧？然后你打的每个东西，其实它都会变成这么一个在网页里给你显示，然后给你个结果，大概率其实就是这家公司其实就是在做一个未来的AI的基础的服务。然后这个基础服务更多的就是以纯就他认为这个企业的Operating system应该被agent来取代。

那什么样的形式呢？他他在做这件事儿，就是所谓的这个interface层。然后你看agent的认证，他选工具的这部分tooth，然后编排orchestration又是这个词，对吧？一定要记住这个词，ora tion这个特别，对，现在不是那么装逼了。但是在去年前年，其实大家说我看孙权还是说你是搞这事儿的。

然后你再往上看什么RPA automation这些公司，其实就是传统的做RPA的。那些RPA就是叫什么机器流程自动化这样一个事儿。说白了就是帮你点点点各种软件，然后帮你把这个流程完成。这件事儿现在被很多环节在被大模型给取代或者被优化。

然后上面一大堆agent看这儿，不用慌，一大堆agent其实说白了就是各个领域的这个agent它的工作。所以我记得之前咱们群里有做这个攻略领域的，可以看啥呢？你就往里看啊，比如说这supply change供应链这部分，然后客服估计也用得到。但是可能更多的是supply change部分，我估计大家会在这里面找到。然后我之前我也找了一下，这个确实也上周也看了看这个关于工业领域的大模型应用，现在还是挺少的。所以我觉得是个好机会，反而就是会是一个很大的机会，是一个很大的一个因为这个市场很难进，或者说大模型厂商都不太熟悉这个市场，所以也是一个挺好的一个创业机会。

然后再往上你看这个还会有什么呢？这个payment为什么要有payment？刚才这张图还记得，就是人跟大模型之间交互的时候，我不能满足于聊天了也不能满足于你帮我调工具完成聊天的事儿了。我还要让你做交易，帮我做交易或者买东西卖东西这件事儿，那就得把payment也给完成。那大模型或者agent的支付肯定不是个微信支付，支付宝支付什么的，收个二维码这件事儿。所以agent本身的支付是一个专门的一个领域是要做的。然后agent的各种安全也都是，你可以看有一大堆这个事儿。所以回过头来还是看这个事儿，就是我们知道agent怎么工作，然后大概知道多agent单agent怎么工作了以后，这些图其实就都不是问题了。

那我们看到这些图以后，就应该干嘛呢？你如果是大家是行业用户，用户的话就是行业专家的话，就直接跳到。比如说这你看function或者有些叫vertical，这个垂直的AI这个领域，你就看里面哪个事儿，哪一个领哪一个块儿是你在乎的。比如说你在乎这个QA问答，或者做企业转型，或者做供应链，或者做sales方面的，你就直接看这儿就好啊，就看这里面的一些logo，然后你就大概就能你去网站一搜，这玩意儿这家公司是干啥的，然后你就能大概猜出它的场景是什么。这里面大部分场景大部分绝大部分公司都是欧美公司，所以可能大家不太容易能直接联系他们，但是相信肯定国内是有类似的这样的公司的。

另外，还需要注意的什么呢？就是这句话，就是我们的我们管这玩意儿叫landscape或者叫map mapping。这个mapping它模块之间的关系大概啥意思呢？就是我们说有拿这个，那我们说有这么多中间的，有这么多agent，还有这么多tooth，还有data。那agents跟tooth之间他的之间的通信协议是什么呢？或者交互方式是什么呢？



这就跟上上次给大家说到了那个那个概念叫MCP，就是这个东西model context的protocol，就是模型的上下文协议是非常相关的。它就是agent怎么去访问外部的数据，怎么去访问外部的工具这样一个标准协议。你只要把它变成这个协议都好都好调用，大家不要不要慌。这方面在后面都会有一些例子给大家看到。所以这就是说大家最开始我趁大家还比较清醒的时候，多讲讲说大家怎么去看这些东西，千万不要觉得这个东西就是纯技术，没跟自己没关系。这个里面跟很多的业务领域都有关系，而且甚至跟一些创业机会会有关系。

好，那下面就到了一些这个应用，我觉得这块就轻松一些。比如说第一个有一个产品叫sdu，right这个速度right这个产品特别有意思，它是很早时候我就开始用，它就是一个帮你写编剧，说白了就是编剧这么一个应用。然后你只要跟他说我要写个什么东西，然后他就会帮你去写写相应的编剧本，或者小说也好。

我们简单举个例子，比如说我点开这个就变成了这么一个界面，你就把你的你想写的故事扔进去，我这选个啥呢？我们选一个小红帽。小红帽的故事，我找一个格林童话这个事对吧？我把它拷贝过来，然后扔到这儿小红帽2.0，咋用呢？说白了就是比如说我我我我写到了，我写到这儿，所以一点都不怕他，然后把后面删掉，我到这儿我不知道写啥了，我我我稍微写一下，我下面到底写啥呢？你就直接点这个right。你会看到这儿，他在帮你去分析，然后他就会建议你写，后面他就帮你续写了一段，你看这个一点都不怕他。

小红早上好，小红帽早上好，狼先生的乐乐。我觉得OK的话，把它插进来，点这个音色它就插进来了。你就可以继续让他去再写。这有一个点啥？你看你写的东西是黑色的，AI帮你补写的是紫色的或者蓝紫色的。然后你继续，那些点错了。咱们继续插到这儿。对，然后你看你改的东西，他就能知道说你改了哪段，然后哪一段就是纯AI写的这样一个东西。

所以它还有非常多的功能，比如尤其是这个是特别基础的，它还有这个story bible，就是故事圣经。你可以在里面找到一大堆你怎么写一个好故事的，类似于方法论。你看我打开这个以后，他就会让你去写一大堆，你把你现在脑子里所有东西都给写下来，乱七八糟的啥想到啥写啥。你想要写什么风格的，你可以在这选，然后你还可以继续去写一些别的，有哪些角色，这个故事里面有哪些有哪几个人，什么？什么什么天罚，什么乱七八糟的这些，就可以去开始写整个一个故事了。因为这些东西，比如说那个背景，然后角色，然后世界观，你看这儿都有很多世界观，这些是不会他是不应该变的，或者它是应该是一个全局的东西，所以这个产品写的很做的很好，就是帮你把这些全局东西先固化下来，而且甚至给你一些像canvas这种东西，你去怎么做？

你的故事的画板三坂你看看给你画了一个简单的示意图，你可以继续在这个看板上继续去写。对，所以第一个这个产品特别有意思，而且他最近出了一个新的模型叫muse，专门是用来他自己设了个模型来去帮你写小说，写的更好。所以大家如果而且写中文也没问题，所以大家如果感兴趣的话可以用它。但是我发现这个问题是这类产品写出来的东西有时候经常是不如国内的那些AI写小说的产品的。就是国内的那些就有些香港还挺野的，就是你会发现写的什么，写那种爽文写的特别好啊，所以这个是一个它的限制这个局限点。

然后第二个就是这个产品最近就这类的功能最近火得要死，就是什么呢？就是你纯靠画草稿或者是写一段话，他给你生成一个3D模型。你看这个过程就是你边画，你边画在右边就边帮你生成新的这个3D模型。而且他马上要开源，这样一个产品特别有意思。所以大家可以期待一下这个东西。它里面举了好多例子，比如说你边画，你看这些都是他们边画，他就边在右边生成3D模型，而且还能改不断的修改。所以大家如果想做一些非常糙，非常初稿的这些3D模型的话，你是完全可以用这类的产品就可以做到。

而且他很有意思，你看他举了一个例子，我开始画了个沙发出来，他了还行，咋咋咋一改，改成那个显示器。他发现知道这个显示器了，他他他他生成了显示器，他把它改成显示器了，都是实时算出来。但是如果你是个飞机，又加了俩翅膀，那他也知道说，你这是你画了一个很很酷炫的新形态的飞机，所以他不会改成新东西。

对，这个挺有意思，而且最近很火的是这个render。对我看看我们搜一下就叫。CT render.



对，大家可以看到这个刚刚说了，一直说了好好多遍MCP这个东西。MCP这个东西其实就是大家可以理解成agent去访问外部所有他能用的工具和数据源的这么一个标准协议。你只要把你的功能，把你的服务，把你的APP暴露成一个MCP协议，所有像主流的这种大模型，它只要支持MCP的这种界面向框的，就可以直接操作你的这些APP了。

最近有一个特别火的，就是这个东西直接用cod生成一个3D模型，3D场景，而且是基于blender来去做的。所以右边这个窗口就是blender那个3D建模的左边这个窗口就是cloud的桌面端，桌面端有一个chat的一个客户端，然后你就直接说，帮我在blender里做一个什么什么场景，我看看这是一个龙站在块金子旁边这么一个场景。然后他就会慢慢就逐渐的去访问，用这个blender暴露给他的MCP接口，不断的去构建出来这个3D的场景。

这个非常有意思，这个可能想象空间就非常大。但是你说传统的不用MCP能不能做？肯定也能做，只是你得把整个空间的这个API怎么暴露给模型的这样一个部分，做非常多自己的这样一个构建的工作。然后这个就是这个领域，text to 3D我把刚才那个也弄过来，刚才这个视频也弄起来。然后这个其实是一个比较有意思的产品，一个类似于最早给大家说那个rap那种产品。其实就是还是一样一句话，生成APP这么个东西。而且这个生成APP会比那个reply更更那个啥一点，更那个傻瓜一点。但是他最近好服务特别容易挂，所以对大家大家有空的可以自己试试。

大家可以看到这类产品特别相似，跟minus什么的都特别相似。都是左边表示他的思考过程，右边干活有区别就是我左边这个思考过程是不是一个比较结构化或者比较复杂的思维过程。右边这个干活的部分要不要暴露那些细节给你，你像这个他就会暴露很细节的那些代码怎么写这些细节，但是有些产品他就不会，甚至像the minus那些，他就不去写代码，直接去操作网页了，去干干具体的事儿。然后这个事儿，其实谁在，或者说一旦到了右边要操作浏览器，就刚才说了，有非常多的像road base这些产这些服务都在干这个事儿。

那普通用咱咱咱用户能能用哪些呢？大家会很快几个月之内就会看到很多这种能够帮你干活的浏览器的出现。比如Opera，大家知道吧？这个Opera叫中文叫什么欧鹏是吧？这个是因为被一家中国公司收购了，我不知道原来是一个很有名的浏览器，现在其实也还行。然后他马上要推的一个就叫open o prod browser Operator，操作这么一个操作的AI这么一个东西，说白了就是跟minus差不多，或者跟这种所有的blosser youth的这类的产品都差不多。有帮你去操作浏览器。因为大部分的工作基本上现在大家都能在浏览器里完成了。

所以你但凡控制浏览器就可以控制，可以帮用户做非常多的事，包括像这个那么fellow也是认为下一代的浏览器，它叫生成认知浏览器，对吧？大家叫的名不同而已。有些叫agenting浏览器就叫认知浏览器。

像这个叫simula，也是一个它是开源的一个其实是个浏览器，也是个东西，但他把它吹的更大一点，大家其实这儿有一个想法，最近也是我们在思考的一个事儿，我也没有正确答案，也希望大家有什么想法的时候也可以再聊一聊我们的眼镜跟auto GM这种产品。Auto GM我先给大家看一下到底是个啥，这是我我其实是不是第一次给跟大家讲过，这是质朴去年底发的一个功能，就是可以帮你操作手机的这么一个模型。比如说像这个一个是瑞幸咖啡清华科技园创业大厦店，另一个是瑞幸咖啡中大厦店。你就说我要去让模型帮我点杯咖啡，咖啡点一杯，帮你点外卖，帮我在瑞幸咖啡点一杯美式。拿不定主意时，还有人会问你我查到瑞幸咖啡有两个选项，一个是瑞幸咖啡清华科技园创业大厦店，另一个是瑞幸咖啡中科资源大厦店，你想选择哪家呢？第一家。就这样一杯咖啡就点完了，甚至他就不断的帮你操作这个手机。

现在的所有的这一类的，包括说像model，像这个Operator，这些其实都在尝试帮你直接干完活，你只要发命令就好了。但是下一个大的趋势其实肯定是眼镜。大家可以想象或者说能确定的就是未来两三个月之后会有

出现在大部分有大量的这种中国造的成本比较低的，从差不多1000到34000这个价格范围内的，自然又很不错的这种AI眼镜。就戴显示器，带摄像头，带麦克风什么的，都带的这样的一种眼镜。

但是大家可以想象，眼镜肯定不是一个好的去操作的媒介。那他如果能结合像auto GM这样的产品，或者像man也好什么的各样的那怎么结合？这是一个很大的问题。就是你你语音去说话，是在说话的时候，好的，顺顺在进行。是哪边的声音？不是我这边是，为什么有声音？

不是哪个视频。

里的声音。

是吗？不是，刚才我也能听到，刚才我也能听到，应该都静音了。那不管了，那继续。对，然后我们继续。这种东西要怎么怎么去搭配，那你的手机如果是在西屏的状态看，就关着屏幕的状态肯定是大家想象的。就是你但凡你是个正经做手机的，你肯定不允许用户有某个APP能够在手机的息屏状态去操作APP，对吧？Auto GM刚才给大家演示的就是能操作APP，但是得开着屏幕。你但凡是个正经的OS肯定都不允许这种APP在西屏状态下做。

那怎么做呢？我再提一个点，可能大家可以关注一下未来可能几个月之内会不会有这样的一个变化。就是原来做云手机的那帮公司，云手机大家可以去查查是哪些公司做云手机。也可以查查以前做云手机的人都是干啥的，就是干什么用，这个肯定会有一些新奇的发现。然后这些云手机的厂商可能会我猜可能会结合现在所有这种新形态的groser base也好，phone use也好，这样的agent来去实像一个整体非常大的能力的提升。

大家可以想想，如果我的我发个任务，他不在我当前的手机完成，在我的云手机上完成，那相对来说是比较合理的。而且是我有任务的时候再启动起来都OK。但是这个带来的问题也很多，比如说我的微信在我手机上登录了，我在那个微信上登在云手机上，我不能同时登录很多问题。那很有可能以后我们会不会是我们的手机其实不是本地一个云端一个，而是都会用云。大家再结合说华为的那个新品，可能出来的新品，那个东西可能是个趋势，就是我们可能以后的手机会跑到云上，然后本地的东西就是一个好的终端，但是中间的这个防离线什么这些工作也得做好。对。

然后另外一个我觉得比较有意思的产品是这个东西。这个我就先不说seem siri，这个就先不说在有一个产品叫send that说白了干啥呢？就是抄个网页，你有个网页我抄一个，而且抄的逼真度还挺高。比如什么呢？我们来看这个，第一个是nike，我看克隆一个nike对吧？然后你就看呗，我就克隆，然后他就会一步一步的干，把那个nike的网站搞下来，然后整个把新的代码写出来把新的代码写出来，然后第一个版第二个版，然后迭代，最后帮你把把这个网站跑起来，跑完了，你看看怎么怎么显示出来，我还没跑。对，说白了就是干这个事儿的。所以你可以在里面看到一大堆的例子，跑什么克隆一个apple TV的网站，然后克隆一个minecraft的网站，基本上现在做的非常狠了，所以这一类的产品越来越完备。

然后另外一个我觉得可能大家做外贸的会同学会感兴趣。之前有一家公司叫皮卡丘，那家皮卡公司现在做了一个新的功能，是这个东西。大家可以看看效果，这个效果确实挺挺震惊的。现在能做到这个程度，你有没有声音？

对，说白了就是虚拟换衣。但是你会看到他其实也有一些啥穿帮的地方。但是总体来说对于一个虚拟模特来说已经很不错了。对，你看刚才这个他好像觉得这儿有光，这个底下有光照。但是再往后的时候，光怎么又到这儿了，然后这儿又没光了，然后这个又没有。对，所以就是会有一些小瑕疵，但是在可控环境下，我觉得是一个非常好的，已经能达到一个很好的一个效果了。但是我刚才注册，我之前注册的时候好像还有点问题。所以

大家如果做有这方面的，如果自己试了成功的还是这个，也推荐大家能分享给别的同学。你看它里面能做非常多细致的东西，换衣服、换头发这样一些东西。

这个皮卡原来做这个以最开始以生成视频为著名的，然后另外一个最近很火，就是AI乖孙儿。然后就说这个这个老奶奶奶奶看一些这个AI生成的这个小孩儿的图，然后我当时就搜了一下，我就我不知道他后面会不会持续给我推这种东西。这个AI胖孙，然后你就发现，确实是今年你就要。对，然后就这种东西我就是看不下去，但是确实是据说流量非常猛增。带来的一个反馈，其实就是带来一个反思，其实就是我们其实锤针对垂直领域的任何的人，比如说吸猫的，有吸猫的我不能接受，那这个吸孙儿的怎么不能接受呢？也挺好啊，这是一个挺听话方向。我最后再说，HUZ的这篇文章非常牛逼，特别值得大家来看。

下面其实几个值得去大家注意的这个公司。有一个叫safe super intelligence安全的超级智能SSR点income的这个公司，这公司的背景极牛逼，这个是欧派的联合创始人苏菲亚克对一列他的这样的成立一家公司。然后你看他最顶上直接这网站就这一这么几句话。然后第一句话我看看就是我们race了10亿美元，从哪儿呢？从NFDG这个基金非常牛，它排在了HUZ前面，排在了红杉前面，排在DST global前面。然后这家公司大家看这个基金的网站就很神奇，都是这种样子，就是简陋的不能再简陋了。但是你仔细一看，内容就会精的不能再精了。

你看他投了啥呢？投了西格玛，投了strip，投了eleven labs，corrupter AI reduce, 就是complexity这些都是极牛仅有的公司。然后他是做啥呢？做安全的这家公司，做安全的超级智能。

大家还记得第一点，给大家说我们现在说AGI是啥？或者说到AGI的时候，其实奥特曼说另一个词叫ASI。人超级智能就是超过了人类的超级智能，不是人工的超级智能，就是做出来的人做出来的已经超过人类的这种智能，那他核心的要做的是安全的。不知道他会咋做，但是这是一个特别重要的一个方向，至少是大家都非常关注的一个方向。然后这儿分享一个细红线，大家知道吧？

那家公司老罗的那家公司，然后最近在在啥了，在校招了，应该是还是春招了，反正是啊开始招招人了，他放出了一大堆职位。大家可以从里面看到啥呢？比如说安卓做BI的这些不重要，我们看看只有做算法。你看他要求啥呢？其实要求一些什么agent体的构建，然后微调、量化，然后action model这些一些东西。但这是一个算法实际上的要求，然后后面应该有算法工程师对这个对你可以看到他的要求基本上一样的。基本上把你能想象到的，对于大模型算法的工程师要求的各类的能力都要求了一个遍，什么你得会MOE混合蒸馏、剪枝，乱七八糟的各种东西，然后开了个这个心，所以大家如果感兴趣，或者说想了解一下他们在干啥，可以去聊聊。然后线下我觉得至少在产品上肯定是有他自己一些独到的地方的，所以还是一个挺值得关注的一个公司。

然后底下的几个agent东西，我就简单的快速过一下。一个是这个开源的，有人做了一个开源的，类似于Browner base或者一个computer use的这么一个，大家可以看看这个，我就我这一看就是个中国人搞的，他这个视频做的非常差，但是我建议大家怎么看，一开始你其实就看他这个，就你去满屏幕找它的任务在哪，或者那个prom在哪。看了半天发现在这儿叫删除桌面的text右键TXT以后，等旁边出来以后点删除即可。那它实现的其实就是它去自动的打开点到，然后点到右边的删除。这么个事儿。虽然这个看起来还挺好的，就是表达这个事儿跑通了。但是反正至少这个demo视频特别差座的。但是它里面用到了一个东西，我觉得特别值得大家关注，就是叫omi。

Passon这个东西我不记得有没有跟大家分享过，应该有讲过。就是我们说agent怎么去操作电脑。很核心的一个点就是agent得能看懂你的屏幕当前在显示上对吧？就是得能知道你当前屏幕都都做了都是有有什么东西。所以这个是微软的一个omi passer，这个他已经说到第二代了。说白了就是能够你能给他一个任何一个界面，这个手机端也好，这个PC端也好，你看它都能够很精准的给你找到里面所有的元素，而且把它标出来。他认为这玩意儿是个啥？

你看这个他认为这有一个icon box，这个是啊delete或者删除的一个function。对他不光能给你标画出框，还能一定程度给你描述出来这些这个组件到底语义上是干什么的那我基于这些东西就能干嘛了，就能干刚才那个那个auto mate干的事儿了。就是你一句话进来，但凡能够跟我刚才那个解析出来的桌面的一些组件能对应上，那模型就可以去生成行为了。比如说点击哪儿，是这个点右键还是点左键，这些行为就可以干。然后这个就是automate，这个做的比较简陋，但是大家可以从这里面去体验一下，到底知道说整个流程到底是干啥，是咋做的。然后minus，我一朋友给我试了一大堆这个minus他拿到了一个测试账号，然后这个具体做的用例，然后我们可以看啊，我觉得这个就比较有意思，他比较喜欢那个那个小东西，然后他就说做一个去开发的这个简历。然后他看好了，一步一步的把各种网页上可能去看了去的这个叫什么集一吧这个东西的相关信息搞出来了。最后生成了一个集一的简历，就是这个叫什么这个卡通角色自己的简历还挺有意思的，做的非常好。

然后对澳门酒店的这个选择，上次应该讲过，然后因为他在香港，所以他有一些香港的政府所关心的问题。比如说这个医社合一是否能解决这个长者的社会孤立问题。然后它是一个有点偏社会学研究的这样一个问题，也可以很好的来完成。

甚至是能干嘛呢？你给他一个音频，这是一个口播的音频，你要让他去掉其中的一些停顿。大家听这个看视频的时候，经常会有一些视频，就是那种一句话不停的一直喋喋喋喋喋。然后有些话之间的如明显是挨着，那肯定不是人说的。那怎么去掉那些呢？传统的这个做法就是让编辑剪辑，把这个中间剪掉。

然后后来有一些自动化工具来干掉干干掉这个事儿。好，那现在你其实可以把这个任务直接扔给这个menus来去干，让他自己去调用工具。你看他都会调这个东西，调本地的处理音频的FFM pack这样的工具。然后他发现没装，他会自己去装，把这些工具装上。然后装上以后，继续去执行这些操作，一步一步执行。他发现错的时候自己会去纠正，然后再去看这改自己的to do，再去干活。干完了以后加to do再去干活，直到最后把整个audio给搞出来这样的事。

所以这个案例我觉得挺挺惊艳的。因为原来一般普世大家觉得这个看看浏览器搜索一下就完了。但是它能够把本地命令行能结合的这么好，这种任务都能处理掉。那确实是一个带来非常大的一个潜在的可能性。你像这种什么趋势预测什么的，就大家比较容易理解了。然后这种软件设计的架构设计什么的，也可以让他来去干。

然后这个ICEO的优化的这个操作。比如说像这个是在官网的那个例子，就是给我做特斯拉这种股票的深度的分析，然后也还是能分析的还不错的。你可以看这样一个结果，这些就是比较常规的了。

我觉得像刚才那个结合本地工具的这样一个例子是非常有意思。因为这种事儿原来确实是非程序员，或者说你你你不是很擅长玩命令行的同事，确实不好搞，很难搞的。像这种需求，但是这种需求往往不是程序员要的，往往是就比如说做博客的同学，或者做内容的同学他在乎的东西。所以一旦有这种功能的实现，确实找程序员哥哥的需求就变少了。

对然后刚刚说到了这个开源的这个框架，就开源的模仿menus框架open menus。然后另外一个叫OWLO这个产品也是做的挺不错的，也是一个开源的一个open minus的一个替代。所以大家如果感兴趣，如果想去试试这种开源替代的话，那我们可以就如果比较人比较多的话，那我们确实可以帮大家搭一个出来。然后大家在上面试试看是不是能够把你们的把大家需求给搞定，一定程度上搞定。

然后就到这儿了。OpenAI的昨天发布的这个agent SDK，我靠洋洋洒洒发了。好，这不是就是文档，我说文档发了好长，他的官方的这个视频其实还好，这个没有太多。你看我们直接看这个例子，大家千万不要被这种东西吓到。其实核心还是那句话，你就看场景他到底是在干啥，千万不要在乎那些技术细节。你看这句话叫system instruction，知道吧？

你是一个搜集推荐助理，然后你被要求要推给用户推荐书。然后你可以用什么呢？用这仨工具，一个叫file search，很容易理解的，就文件搜索工具。一个是web search搜网页的，另一个叫显示书籍列表。这么一个函数可以呈现出来三个推荐。好，它其实说白了就是让模型给他一个设定了，这时候就是用户说的话了，我会从我会有一个很长的一个航班去米兰。

下周然后我要找一些新的可以去读的东西。好，那他就干嘛呢？开始先去用他的第一个工具找文件，然后你得之前传过一些文件给他，然后他找然后找网页，找网站，最后显示用最后那个工具，就是显示数列表调一下它，把它显示出来，三个三本书就OK了。所以说白了就是他做open I开放了一个一系列的东西，可以最大最外面的一套东西，可以认为是agent SDK。你看这有没有负数？

Agents SDK如果大家是这个行业内的话，大家知道说他之前发了一个叫swarm的一个框架，就是一个多A整体框架。然后他说那玩意是一个很实验性质的东西。他现在发的这个agents SDK，是一个可以用在生产环境下叫production ready的这么一个版本，那可以想象就是一个更完整的，或者更在公司的生产环境下使用的一个swan或者一个多a gent框架。那它里面的核心概念就这几个，一个叫agent对吧？很容易理解我能怎么去定义在这个agent。第二个叫hands off，说白了就是怎么让一个agent把活派给另一个人。然后第三个，gary其实就安全方面的一些这个安全护栏，是这些都不重要。

大家可以直接看一下这个quick start，我给大家看一下为啥，你看这句话叫创建第一个agent，创建你的第一个agent然后咋办呢？其实就这么几行代码，这行代码一看就像个导入一个库，其实就这几行代码有一个数学导师，然后下面一个字段叫instruction，就是指令，这个你提供数学问题相关的帮助，解释你的理由，每次的每一步都要解释理由，并且包括例子，对吧？就跟大家想象，如果有一个特别最耐心的一个数学老师，每一步我都不会，然后我每一步我都要让他给我详细解释，并且给我举个例子，现在模型可以agent能这么干了。好，这个就变成了一个agent对吧？

特别简单，就是一个名字和一个人设。然后再多来几个A站也很简单。有历史老师有历史的这个tutor to tour，然后有数学的to torch，然后好，把这两个加起来干嘛呢？再加一个叫定义的hands off，就是刚才说的交接，就什么活儿给谁，什么活给谁。那我定这边他就定义了一个叫可以把这个这定一个叫中间的决策的agent。

你来指定哪个人来接这个活接这个homework作业的活，有哪两个人可以接呢？一个历史的和一个数学的。好，然后跑起来，这儿就直接把命令，把这个任务跑起来了，就是法国的首都是哪？然后交给了所有刚才定义的这几两个age来干OK了。

其实加不加安全护栏都都没有那么重要了，把所有东西加起来就这么几行代码，不要real就是安全防护的话就更少了少多了。所以说白了你要去做一个有多A整体的这么一个框架的话，就会变得容易很多。但其实主流的这些agent平台与agent框架market agent框架也差不多。但他这儿有什么就是OPI的这个特殊点呢？主要其实就在它的几个工具上。

大家怎么看重A卷？先又回到最早那那张图，大家记得就是agent他首先要能跟人对话，二他得能用工具，三他得能调数据或者能找到这个记忆，并且能够做规划，甚至如果再复杂一点，能跟别的一者互动。那这个时候带来的就是这里面最关键的其实就是工具，大家差别最大点就是工具。那我们看它的工具有哪些，是这里面对其实就刚才那三个工具。搜网页的搜文件有一个computer you computer to可以让你来去自动的操作你的电脑来去完成任务，说白了就是能能具体的干活，而不光是搜东西，就这仨兔子其实就能完成绝大部分的工作。

再回想起来刚才介绍说这个minus，或者是open automate，或者像什么OO open minus那几个东西，其实大家的底层基于的能力都差不多。大家都可以简单的理解成这些东西只是open，比如computer use是不是能有更复杂。比如说我除了用浏览器，还能用命令行，还能用什么编辑文件。其实就是在tooth上有非常大有这个很重要。就是大家我们看这种A证框架到底好不好，其实很大程度看它的tooth好不好。模型能力其实买家都能接。

这是open l的这个agent SDK的一些新东西，这个还是挺值得关注的。因为有了这个SDK或者有open l的封装以后，做一个像minus那种东西的成本或者这个对，主要是成本就会低很多，低了不少。MCP刚才说了我就不说了。

然后这儿有一个就是叫mro这家公司。大家最开始讲deep seek的时候也提过这家公司。法国A是法国的一家公司，他是最早开始在行业内大模型，行业内说MOE的大模型很牛，他发了几个大模型。他最近比较沉稳了，这个虽然不多了，但是最近又发了一个叫myra OUCR的东西，这个为什么重要呢？你看这个效果，就是你有一篇这样一个复杂的级别的这样的一个论文，你想把它扔给大模型，很多的产生的问题都是比如像这样，你像这个它分成论文基本上两列，那你如果有一些不好的解析器的话，甚至会跨列把它解析出来，那大模型其实就参考不到什么了。

然后包括最开始这种，你看这种结构，这个页面的结构就比较复杂，这儿有一列，这儿有一列，底下这两列又变又岔开了，这个不不一不是一个结构。对，所以这种页面怎么去做解析呢？Mr就发了一个号称sota级别的这种做这种复杂文档的OCR解析的这么一个项目你看他又能做很多这种效果，并且干嘛呢？他最擅长几个事儿，一个事儿，比如说解析数学公式，吧？直接把这么一页的GDF直接变成一个很好的一个数学公式，这结构化的文本的数学公式还能干啥呢？直接这个多语言支持对任何语言直接咋一识别，OCR都能很好的变成对应的这个语言的文纯文本。

所以我觉得他他他最近可能是卷不动模型了，那先发点新东西呗，先发点小东西呗。然后在模型里面有几个，一个是千问的32B这个其实是特别值得注意的一个技术突破。但是大家都被这个minus上周给盖过去了。他发了一个基本上能力不亚于R1 deep sk r一的推理模型，但是它只有32B，大家记得第一节课讲说deep seek的R一大概要跑在两三台的H1H800这种机器上。但是32B那你量化一下，甚至1台4090都能跑。不量化的话2台4090就可以跑。所以其实这个对于它的基础的算力的要求是一个巨大的降低。

然后我再跳到后面，昨天还是前天，google的解码三也发布了，它也是一个小的模型。那我们说他发布那么多到底是不是够强？我们回到最开始，第一次还是第二次讲到底在哪儿看大模型哪家强哪家强对吧？LM的arena，他about arena直接到你的little lead board里面去看啊，看刚才那个是啊jama对吧？然后我们直接看搜一下jama在这儿。230 27B然后排在第算是第九。这样一个位置还是没有2万221强。但是他小，他才27B，那他这他的官网就专门做了一个例子。就是刚才那个那个分儿，就排行榜的那个arena那个分其实就可以理解成是这里面的allow。Allow是一种评测方法。

L分只有排在了deep stic l一之后，L1到1363分，它是1338分，然后它比CCV3高一点，但是这它它底下这个图做的很好看，就是用多少NVIDIA的H100的GPUR one它需要这么多，然后加码三只需要一个，因为一台就80G的显存足够跑。然后V3需要多少？也有这么多，因为它671B，所以需要非常多卡。然后拉玛三也需要这么多，因为405B然后他能跑到1338分，但是他只需要一张卡。所以这个确实是他的特别有意思的独特的优势。这跟QWQ就非常相似，都是这个问题。

就是r one虽然好，但是他的对算力要求确实很高，所以他在过程中也做了非常多的优化。上节课给大家讲了这个第开元周做了一大堆优化，都是干这个事儿的那那反过来我们不用这种多专家模型、MOE模型，我还是用回到原来的这种红米模型、dance模型。我用32B或者用一个它那个是多少？27B，R7B依然能达到这个R一级别的推理能力，类似的推理能力，这是一个非常大的突破。对于企业来说，我觉得是一个比可能比用r one

更好的一个消息。就是对于一定要私有化部署的企业其他的我就先不说了，这个模型大家可以期待一下这个叫c sam的这么一个模型。它在语音上目前来说看起来是最好的了，就是能力最强的一个模型。

我们直接看到他的demo，我不知道大家能不能听到，先试试他，直接在网页上就可以试，就可以测。因为它后面的算力可能没那么强，所以他得排队等一下，嘿。Back as soon.

Glad you decided to hang out again. What's another night tonight? Um let's talk, talk about something relaxed. Okay, alright, chill vibes.

Is anything in particular light memory? 我不聊了，我们在这说的你有没有听到这个我觉得目前是真的是最牛逼的语音模型之医院都不好说，反正确实很非常厉害。然后应该他会open source，看看他有没有开出来，前段时间才还没有。对，这还没有。对他会即将landing，大家可以直接在这儿，这个叫什么等一趴，然后你他那个啥都没有的一个githa，现在6.8K的star了6800个store了，说明这个确实海内达还是很公认的这么一个很棒的值得期待的这么一个语言模型。对，语音模型。

然后另外一个就是大家前段时间那个open I发了他的不是DC发了r one以后，大家就想怎么跑这个r one。然后那个苹果发了他的新版本的那个那个mac studio，那个RM3版和M4M3的奥创是可以，两个人的，还挺大的。RAM的，应该512G的，两个好像都有，然后就发现了这种蛋疼的哥们儿，开始拿两台M3，两台M3的这个512G的max studio跑def KL1，而且是全学版的，真的挺可怕的。

用啥连呢？用雷电五八十季的一个炮把两台机器连起来，然后号称能跑到每秒20个token，这当然这个性价比肯定是不值得了。但是可见苹果整个生态是真的快起来了，慢慢起来了。然后也这个机器来其实完全不建议大家做，这一台应该十几万，至少10万。然后你等于弄两台max studio，然后跑一个RY还只能跑到20个头盔每秒。对，那就玩一下就好了。但是证明整个的大模型领域，其实这个苹果的生态，也尤其是像拉马CPP这种东西出来以后，大家确实越来越赶上来了。

然后另外在机器人领域，其实有一个挺挺有意思的东西，也是google的这个G的2.0，它有多模态能力。以后可以做到这个程度了，我也觉得还挺挺震惊的。大家之前我给大家说了说我们的下半身这个模型。中国的机器人的下半身确实已经挺不错了，然后上半身还差一些，然后看他现在可以做到这个程度了。我们直接看底下的例子，他做了几个例子，比如两个手一起来干嘛呢？把眼镜放到盒里，然后玩三角棋，这个比较正经折纸。

折纸，而且还不是那种折一下的纸。然后像这种我把一个什么东西把它加起来，然后还互相协作。然后这个我觉得很有意思，就是把这个皮带套在了两轮车轮上人协作了半天，两个机械臂斜一下就协作成了。你看再往回一点我咋搞的？这个机械臂先把它套到轮上，然后手顶到这儿，然后那个机械臂去把它套过来。当然最后这个还。还在这再捣鼓捣鼓。所以跟人确实挺像的。

然后像这种他做了一个例这个例子就是你时时有人类干扰或者整个环境的变化说的话，它也能非常好的来去跟上。比如说他把这个碗拿走，然后换地儿还是能跟着你。对，就跟咱们之前看那个各种机械狗被踢来踢去，然后它也能站起来一样。他依然能找到对的地儿，然后他也能有很通用的这样一个场景，什么场景基本都可以都OK。

然后为什么能做到这一点呢？就是因为他对整个的世界理解非能做非常好的视觉理解，然后能把里面做很多语义化的理解。你看每一个一个衣服，它能识别到这个衣服的不同部位的语义。比如说这个是它领子，这个是什么东西？被折起来的一个袖子，然后这个T恤的下边这些东西它能非常好的识别到。这样的话它才可以去驱动这样一个机器人，做很精准的实时精准的这样一个任务。



然后再联想上次给大家介绍这个东西，halo x这个模型，这是figure跟OKI合作。那figure的那家里面他的技术路线是啥？还不知道还记不记得。就是他用了两个模型，一个7D的视觉模型，一个80兆的transformers，最后输出一个200赫兹的一个机器人操纵的指令。所以它叫啥？它叫VLA，vision直接to action这样的一个模型，它是用了两个模型。Google其实看起来是用了一个模型，它能做很高零度的这个指令输出，这是一个挺挺有意思的一个项目，然后最后有几个词儿，最近很火的词儿，一个叫web coding。

Web coding其实一直没找到什么翻译，看这有一个叫外部，其实是叫什么气氛氛围那种东西，就是比较随性的那个意思。那为什么叫web coding呢？接着看这个对，这是中文翻译，有一个人做了一个中文翻译。

什么叫气氛编程？就是要随性自由，然后要注重氛围，比如说你要写代码，要播音乐，布置舒适的环境，选择好的工具，然后让这整个编程变得更自由。这个创造力有限，说白了就是你不要去纠结于那些代码的优雅性这些东西，一定要把你的想法的创造性放在第一位。然后我记得有一个点就是说web coding一个很重要的特点就是要让AI写绝大部分的代码。你看他写的embrace AI to写你的代码的95%的部分，都是要让AI来去做的。

然后这个又是卡帕西说的，fully把你自己完整的给到这个完全的给到这样的一个氛围里，或者这样一个气氛里面，这种情况下你来写代码。有些例子，比如说这哥们写了一个马斯克火箭回收那个快是吧，然后他就拿好像拿科所写的这么一个东西，直接就可以玩了。对，就我跑了N遍都没跑到，我去这就是你要你要按上和前后左右来去让它落到那个筷子上，大家有兴趣可以玩一下，还挺反正我都没成功过，我靠失败了。

对，然后他还做了一个第二版的V2版的，大量都是用AI来去生成的这个代码。你看第二版它增加了一个有两条有流量的一个值，然后现在整个互联网上就一大堆人在这share自己的所谓的web coding出来的气氛编程出来的这样的一个成果。比如说这哥们儿写了一个什么SOL的世界了，你又能开飞机，又能开车什么的。对，然后还对就这样的东西，还要写别的东西的，就不要那么被这种代码吓到，或者是因为现在模型足够强了，你所以你可以乱写，你可以让模型帮你做各种的事儿，大家就可以就经常在里面去share这个。我又搞了个啥，又有什么有意思的应用出来。然后最后一个分享的概念叫story telling，就是讲故事。

最早其实联系到的这个是sora，在当时去年年底发布的时候，他发了一个功能叫故事版，不知道有没有人还记得，就是story board。说白了就是我如果纯让这个文本直接生成视频的话，这样一个效果可能会很差。尤其是在说我想做一个比较连贯的内容的时候，所以他做了一个叫story board的一个功能。让大家在做视频的时候，我先把整个故事板给做出来，先啥再啥再啥再啥，说白了就是有点像分镜似的，我先把那分镜做出来，然后再让模型去补全这个分镜之间的这些关键的视频关键帧。这个关不是补补中间的这个视频说白了就有点像说我把关键帧定出来，然后AI来帮我去补全中间的东西，当然关键帧也可以是I生成的，这个事儿有搞了一段时间，但是我觉得最近好像声量小了非常多。

直到我看到这个叫Flora的这么一个产品，他其实就是做的是个single creative。对，就是有点像这种豆子之类的编排工具，但是专门是针对这种艺术家的或者这种创作者的。你看那等于把内容直接把它变成一个编排，一个流出来。然后开始是有大文本的生成，然后你可以把很多图扔在一起串成个工作流。Your community to find thousands of workflow tailor for your use case. 对，说白了就是我们人类去做创作的内容的时候，我们设想到了这样的工作流程。他都可以在里面去给你很好的让你在整个画布里面去完成起来，而且你实时能看到效果，这个其实对就是没有什么太多的新的技术，但是整个的体验比原来的这些康复UI确实好很多。

然后他举了个例子，这个例子我觉得没有那么惊艳，但是是一个好的大家去想象未来这个创造类工作的这样一个工作方式的一个例子。他要做一个赛博风格的，什么下一波风格的奥德赛。他会写一大堆prom，然后让prom来去让模型来去帮你生成各种生成图，生成视频的prom。你只要把这想法写进去，它就会帮你改写成，

比如说me journey可以用的，或者stable diffusion可以用的那些。其实确实大家都是这么在做的。但是他把他可视化的不错，他他直接跑就行了，就生成几张图，然后几张图就可以再去生成视频。说白了几个图就是sora里的那个故事版里面一些关键真是ghost然后他最后就生成这样一个视频。

Worship that you are not free, you are program water was the blue print a perfect mutation. But why sell for one when I can be many? The government feel就这样的一个东西，最后给这个就是到概念部分了。最后给大家推荐一下我质谱的最近开源了一个模型叫cove 4，它是第一个可以生成带中文字的读的这么一个开源模型。反正必然的大家肯定会见到有不少所以我们去看看这个怎么用这用我的手机看一下，然后就是我们的质谱清言，然后打开里面看画图，然后直接去让它生成一个，比如说一个画卷上写着一个大大的死字。

对，你可以看到这写的就是Q4，我们的模型是开源的，所以大家如果有的话可以那你看看这个词其实少了个撇儿，然后你说我不要死，我要我改成一个爰字。可以看到所有的这种生成其实就都一样，就是我可以连续的对话，连续的让他修改没问题。它的特点就是这一代模型，这个开源模型的特点就是它能生成中文了。对，大概就是这样东西。所以最后就分享这个，然后今天的分享大部分都讲完了，有一些没有的文章的话，我的我会放在下面。因为有些文章确实还比较深一点，所以这个今天就不介绍了，今天我就讲这些，谢谢。

有什么问题吗？大家。感谢小平，然后对我发现小平要是不当以后不搞ai科学家了，可以去当漫画家。那个画的东西就跟我小时候启蒙那个漫画就感觉特别像。那就希望小明以后抢到漫画家的时候，别已经漫画家悲哀取代了已经。

好，我觉得还是挺有意思的东西。

大家有什么问题现在就可以打出来。我刚好说大家边答问题，我也刚好抛一个问题给小明去询问。比如说manus，上次上来最震惊我的是，他竟然敢号称自己是通用型ai这个你怎么看？通用型的这个口号。

他官方这么说的吗？是不是营销号搞的？

那有可能是营销号淘的那换句那换个说法问，比如说在你眼里如果真正的是对是吧？General.

对对对，是我觉得如果从它的use case上来，就是它的行动力上来说，我觉得确实比绝大部分的这种外面的其他之前做的这种a web agent会通用的多。因为它里面的很多case，比如像这种生活类的case，确实是比别的做的好一些，效果好，且场景多。而且还有像刚才说的那种，我直接去改改音频，装个FFM pack，然后来去来去修改音频，这种也能做的挺不错。我觉得这个确实还是比原来通用了不少。但是你说它现在就号称AGI这种通用，那我肯定不算。

那就换个说法，就是说在小平师兄你眼里，如果真正的通用型的agent大概应该是一个什么样的，描述一下。

那肯定就是言出法随这种玩意儿了，但是你要，然后他就直接给你结果。然后当然过程我觉得这是一个其实如果真的到AGI那个时候，那我可能就不关注过程了。就跟你说你去看看医生，你肯定不会说，医生你告诉我一下，你推断出我有这个病的前因后果，整个过程是啥样，那我不在乎，对吧？所以我肯定不是如果到了AGI那种级别，那我其实就要直接要答案就好了，要结果就好了。

那看看有一个咱们这个神经同学有一个？3D建模师会被取代吗？目前ICC生成3D模型的面数会很大，不能直接没用。这个问题不是因为比较场景比较具体。

是在哪儿？

在这个提问你看得见吗？还有最下面。

点这个点这个面数不是很大，不能直接用。对，你大家看看到刚才那个那个生成3D模型那个项目，其实它确实就是生成出来东西挺挺什么多边形化的这种级别的那你要不就是把它再去用模型，用各种技术来去增加面，来去refine，肯定是。但是我觉得未来这个事儿大概率能搞。因为大元模型的这个能力持续在提升，且世界模型的这个能力也在快速的补上来。如果我视觉模型OK了，那代表了就是我任何的一个修改，它对于物理模型的这样一个模拟仿真能变得真实的多。那也就对应的说我的任何一个对于现有的我苏的构建出来的模型的迭代速度会高很多。所以我觉得这个未来肯定是会也不叫取代。

就是你想说我要做个什么东西，这件事的想法还是得靠人。就是就需求可见的情况下，可见的几年内需求还是靠人出来的。所以可能他的工作的方式就会变了，就跟那个White coding一样。所以我觉得可能各个行业大家都要去想一想，是不是我这个行业可以web起来。那个那个web那个VIDE这个词，我不会web coding了，对吧？我还web 3d web什么什么的reading是这些东西。

边蹦迪边工作了都是吧？对它本质上是我們。

愿意把我们工作的95%交给AI来干，我们是干剩下的5%。那这个时候就要发挥人类的特长了，人类特长肯定不是什么我写代码足够严谨，我写代码少数特多。然后这些东西肯定是我对于需求的理解，我对于创造想象的这样一个发挥。3D打印，3D建模可能未来可能可以想象，就是我们的建模是要去发挥对吧？这个放飞自我，然后做一个web 3D建模式，然后这个过程我觉得挺快的，可能半年左右会有这一类的，比现有的3D建模模型大模型会好得多，好一个数量级的这个模型出来。不会大规模的会失业一些，但是这个也不至于大规模失业。

搜索产业链图，有没有合适的AES推荐，这个是啥意思？是说。闪电恋图是刚才我那种list game那种图吗？还是哪种？比如说你搜AI lang cape a着他。这种吗？然后你要搜，比如说中文的产业。对你会看桌，其实也有。也能看到有很多不同行业，比如制造业什么的。

但是这有一个很大的问题，你会发现国内的这些所谓的应用图谱，它的这些玩意儿，这些参与者，这些player都是一个巨无霸。你就说金蝶，你说天猫，你说啥，这些就是很难像这个SARS比较活跃的这些市场里面，你一看这个东西，我也能用它，我也能用这个组件，我也能用这个sas来去构建我的这个系统里面的一部分。而往往我们就国内这些产业突破里面，你一看基本上你你去买你就买他的全套解决方案，从顶到底都要去买它的。因为其实他没有给你拆出来你去复用的机会。你像这种什么都是产业大的巨头，你看这些人力资源里面北森，然后这个财税的金蝶办公就还是传统的玩家，他都根本没有往下拆。没有往下拆的一个问题就是你根本没有什么创业机会。就是世界模型大家目前谁做的最好？Number label number lab就是李飞飞的这个。

对，当然这个肯定最近也是一大堆不断的会有新的公司出现。但是现在至少目前来说，李飞飞的这个项目还是挺牛的，这种网站也是啥都不放。对，这个有没有给大家看过，就是是李飞飞这个世界模型大概啥意思呢？就是你给他一个图，它就能根据这个图生成一个大概这个空间的，你可以移动的空间，你看还能前后左右动一动，甚至背后它都给你想象出来一个后面。但是你看它的移动空间是有限的，你走到边缘它就不断的即使你赚钱了，能走的空间其实是很少的，也就是这样的一个前后左右稍微动一动的一个状态。对，但是他的那个paper里面其实就是说未来可以与这个寄希望于未来有非常多越来越大的一个生成的能力。

你看这一张图给撕成这么一个地儿，你可以怎么想走一走，也可以拿现实的图来去做。这个是这是哪一个博物馆？忘了。

你看这个就是同一个产品，你可以在一定程度上看到它的不同的侧面，但是也是有限的。这个东西其实它的侧面是有限的，你能看的东西是有限的。但是他已经给你的一个能力是你拿一张图就可以一定程度上构建出来这个图像这个附近的空间的3D空间。但这个更是一个日常的图了，再走一走。你往后一看，他给你构建出了这么一个地儿，一条林间小道。挺真实的，关键是看这个东西看的是不是真实。

我靠。物流行业的业态会被颠覆，我觉得有点难。就是物流可能会在那些这个牌，就是叫什么调度这些东西会有一个更进一步的提升。这个调度算法之类的这些会有一个效果更大进一步提升。但是你说物流本质上还是要把一个东西从一个地方运到另一个地儿，这个从改不了，或者很难把它全都拿AI替代。就是它跟物理世界相互交互的，就会永远会比这种我一句话变成一张视频这样的流程会复杂的多，潜在的不相关的因素会多得多。它带来的结果也是我们有可能会碰到更多的现实世界的难题。这个模型也需要各种的人工的介入，也需要所以跟现实世界打交道的这些模型，我觉得还是会不那么容易所谓的被颠覆。

目前文本视频类大模型哪块比较简单？对，这个忘了说这个了。最后这个文章是HUZ的。这个HUZ也应该提过，就是那天最早给大家说这个emerging chip cure for LM application，就是讲rag的这个东西。这篇文章其实前年二三年6月份的，非常像这张图。大家还记得吧？这个的一个流程是什么样？还记得吧？这个图它的作者是这个投资机构写的，流传了非常久，而且现在也不过时。他又出了他每每半年会出一个top 100的生成式AI的消费软件，消费者软件的绑。

2025年这个是啊它的第四版，2025年march 6其实就是3月6号，也就是一周前做的一个榜。我们把它翻译打开，基本上可以看到有两个大把一个是生成压的web产品的榜。对我这强烈下，如果大家对于这类的应用，就是对于AI应用感兴趣的话，你起码把前20个产品看看或者说看呗，至少眼熟或者说用过其中的34款45款。比如chat PT还是一直在榜一了，deep sake变成榜二了，太牛逼。然后character AI就聊天的那个搜索AI搜索的parity，然后gender这个挺有意思的，这个产品gender也给大家看一下。对。

给大家科学上网还是有点挑战。这个是个啥呢？就是你会在里面看到一大堆的AI的场景，比如说这是个啥？我还是最进之前那个，困在了电梯里一个东西。你就会发现这个困电梯里是个啥呢？其实说白了就是对话，在一个场景里对话他会先说什么翻译，工作了一整天以后，你回到公寓的时候，发现跟四个男人挤在一起，这个图里的挤在一起，然后突然电梯坏了，然后其中的一个人说啥，另一个人说了啥，又一个人说了啥，然后该你说了。然后我当时就说了一个，我们玩个游戏吧，我用的是中文，大家看我们用的中文，然后没问题，中文也OK的，然后他就继续去生成了这个啥你想玩个屁游戏，然后什么i came，然后后面就没有继续生成了，因为我当时退出了。

对，就是挺有意思的。他说白了就是给你一堆场景，然后你在这个场景下能够干嘛？你可以靠这样的文字方式继续去聊。你看而且有一些特殊的标签，这些什么这些对吧？然后你这些一些标签，所以大概能理解是个啥了。对，所以这个排到第五也不足为奇。

大家觉得然后这个造的but sono这个大家一定要推荐大家玩一玩。这个就是一个生成音乐的软件。斯诺VI可以去做自己的音乐，做自己的歌出来，而且也能生成中文的这个歌词，都还不错。然后就豆包第十，kimi第11，然后海螺生成视频的那个克林，在这儿第20，中间的不说了。所以刚才有一个同学问说我靠已经找不到。就是生成视频的那个故事，文本视频类的大模型什么的。对，就刚才那两个你就找这个头部的这个海螺或者克林，其实就挺好。当然好像中间也有别的什么什么video什么的反正这几个我觉得都挺建议大家去玩一玩的。

能否跨境电商流程自动化选品广告投放？有啊，我说白了你抖音一刷都能刷到这种视频。这个跨境电商AI流程工具什么？你看这超级多。然后第一次给大家推荐这个justify, there is a nap for that。

也都能在里面找到跨境电商相关的工具，比如说电商。你像那种什么聚合电商，电商图生图，然后我其实建议说，一是开始你可以去用这种集成在一起的这种电商工具，看看是不是好用。然后一段时间以后，你就可以尝试用cos去拼这些聚合的产品。它背后用的那些具体的一些，比如说纹身、图纹身视频，然后生成这个SKU的一个文案的这些具体工作，你会尝试把它编排起来。因为这个你用一段时间你就会感觉到哪一个更好一点，哪个不太行，更适合你。然后ICU你可以直接搜这个自动SU投放优化这类的，刚才那个用minus什么的也能做到。但是肯定有专门的去对接了各种广告投放平台的这样的一些agent，能够直接用到工业视觉模型。

是不是当前还不成？对，是的。工业里面的，尤其是工业场景的用的这些大模型都不不够成熟。核心的原因是因为工业场景对容错的就容错率实在太低了，所以这块儿可以再等一等，未来中间商只有智能体了，谁会在市场推出来？谁巅峰了，中间商只有智能体了。对，就中间商这种做交易撮合的，肯定是智能体特别擅长的事。

有适合生产领域错漏装检测通用视觉模型和大模型推荐吗？比如说螺栓线束。对，第一次给大家说的就是这种模型去哪找呢？就是找这种VLM模型，就是视觉语言视觉模型。比如像质谱的叫QVOM，它里面的能力，其实一种能力就是我直接扔一张图进去，然后你给我解释里面有什么。这个就回答说白了就是对图对着图问答这么一个东西，然后看看在哪儿能测试。对，比如说这个点那个demo你可以进到这儿，然后你就可以扔一张图进去，然后问他说什么图。一。

对，大家自己找一下，比如说我刚才打打螺丝。比如这个，把那个错字扔到这里面看看。这个小伙的操作，为什么？

这个是用的英文，大家如果用中文的话可以选选ZH这个中文的这个模型比较慢。对，大概这个意思。但是其实现在主流的大元模型的应用，比如说制度清源、豆包这些，其实你扔进图它都会拿VLM这类的语言视觉模型来去来去做识别。所以也不用一定得去找特定的这个学术领域的这种开源的模型，直接用现成的这些大的模型去试一试。

然后你核心的是什么？就是不以及问题这个问题一定得找好，就是我这个话可能是不太专业的，肯定很不专业的。然后你的这个工业领域里面肯定有专业的叫法或者说法，那你怎么能把它变成一个人能听懂的这个话，然后把它问出来，并且能得到对应的答案。把这个答案变成你的工业生产环境里面流程里的一个部分，把它如果好的话，把它集成到一个自动化流程里。如果一般的话，你就把它变成一个持续记下来一个log然后你回去去找出来有没有安全问题，有没有哪儿不好这样一个结果。

对检测结果搜索类有没有好的AI推荐搜索农业产业链图，新能源产业链图。那还是刚才那种产业链是吧？这个图好像我没见到什么比较好的AI因为专门搜这个图的。

对，然后可以去找个模型问问，比如问问第四个说有没有搜索一个行业的，我想看。找一个，问的是啥来着？你有没有获得某个特定产业的产业链上下游关系的网站？让他找吧，我们到时候再看世界模型，南航有个难点在哪里？难点非常多。就是你这个世界模型原来肯定是靠这种模拟器来去做这种东西，模拟类的这种算法来去做这个线性回归，不是都得多，回归这种模型来去做的那那你现在是尝试拿一个巨大的transworld来去做这个现实世界的这样一个模拟，那难点可就太多了。那个数据，那模型怎么设计，这些东西模型普及带来算力对于存储方面有什么影响呢？啡DRAM这种存储方面我记得上节课有一个讲的，就是我们现在。

托管模型领域的存储的量暴增。你看这个就是从其实从二三年之前，大家对于这是那个hanging face上面的存储模型或者数据集的量级。二三年之前几乎都相比现在都都看不见，就是微不足道的一个状态。但是就这两年整个模型托管平台的数据量以及数据集的这个数据量暴增的一个状态。那它对应的是啥意思呢？比如说我们除了说我们去找一个模型荡起来，那我们也得把这个模型跑起来，然后得找地儿能够运行起来，能推理起来。它对应的这些存储的空间或者这个存储地方都要求会高的非常多。所以这个我觉得是一个特别随机会增长的一个领域，就是光飞d RAM这种能就是这种模型的催存储的这个部分和数据集存储的部分。

企业端用文员会有什么经验吗？还对就我记得有一次给大家讲说我们讲rag的这种智库的产品的時候，大家会发现这个开始企业我做了一个知识库，然后大家把各种文档，有一个部门或者有几个人专门负责把各个部门的文档拿过来，扔到这个知识库里面去，然后问答这样一个事儿。但是做稍微做大一点就会发现不会有那么多部门愿意配合，或者说他不会也就一次性的把这个数据给你那之后再有新的他也不会理你了，不会去主动的上交。所以我觉得这是一个问题，就跟其实跟传统的信息化系统之间的这个孤岛带来的问题是一模一样的。就是你有孤岛的数据了，然后这个孤岛的数据怎么把它打通，然后以这个是一个特别大的难点。AI也是一样的，就是大家不会愿意说我把所有数据都贡献给一个AI，还会保留这个部门之间的问题的。所以这个估计在组织结构或者在知识管理维度是有非常多的工作要去做。有点像房产APP，对房产APP那个完全不是一个技术来去做的，可能效果有点像人力资源团队。

我想做一个人选和岗位匹配，然后可以用办公，当然可以用。你说这个来了一个简历，然后帮我分析一下这个简历是不是一个就跟上次那个minus那个官方的例子似的。就是minus的官方例子就是我直接有一个Z包，这个Z包里有一大堆什么来着，那个那个奖励有10份简历。然后这个十份简历里面我要识别出来，里面是哪一个是比较好比较优秀的一个。怎么老在这个里面，就哪个是比较优秀的一个强化学习的工程师。那个那个例子我觉得其实就可以参考，然后其实不用minus也可以。

你直接扔给大模型说这个啊根据这个文件，这个文件就是你扔了扔上去的一个简历，然后你的这个分析是不是符合我以下的岗位职责，对吧？就是出来就是这样，给你传一个文件上去，根据文件附件中的简历，然后帮分析是否符合以下JD的要求，8881234填写，然后你可以在后面再加。从他说他方面问方面来打分，打个分。当然你这个打分标准你就可以继续写了。打分标准比如说满分是多少？一分是什么意思？两分什么意思？然后最后让大模型给出一个各个维度的一个打分，你就可以来去做这件事了。当然这个肯定是有不确定性的，这个有波动性的，所以一定要注意这个答案仅供参考。

当然还有一些别的工程方法可以去做。比如说你让他打四次，打五次分，然后做平均，这个可能会好好不少。然后当前AI是伪狂欢，AI要求数据平权，决策直通栋梁，到层层审批的管理模式。肯定的，你像这个斗志对吧？马老师的这个斗志不就是干这个事儿吗？那这个阻力多大？送了多少人的蛋糕。但是我觉得在一些比较经济的极端的情况下，这个事儿还是有可能推下去的那对于企业来说也是，如果在经济的没有那么持续好转的持续性经济好上行的阶段下，大家就要想这个节能，不是降降降本提效的一些事儿，那提效可能没那么快，但是降本是有办法的对吧？

那你中层我觉得还是那句话，就是中层的不人是最容易被这波AI取代的。为什么呢？就是因为很多传统中层其实就是做的是目标拆解，任务拆解、指标拆解，然后上令下达的事儿。这些事儿确实就大不腥，干的比人好。对于普通人来说，现在时间点是不是主要可以做的就是了解哪些，并在尽量去做，尽量让AI帮助我们的生活工作。因为我们又不懂技术，这AI又不知道怎么去结合，所以如果不想被实现方向，我觉得不用那么悲观。AI的对，我记得上次，有一个公司给大家介绍了一个，能不能找到？一个做做科学的，找不到。

对，说白了就是做这是叫叫啥来着？是对对对，这个thinking machine。这家公司thinking machines点AI这家公司，他做的是啥事儿呢？就是怎么能够帮助科学领域的researcher更好的使用最新的大模型技术，最新的AI技术来去辅助他们科研。

所以回过头来说，并不是普通人才不会不懂这一代的AI技术，而是包括这个领域的研究的人，其实也不全全懂，也是很少部分局部的懂。所以大家不要担心说这个怎么着被AI立刻就取代了，怎么回事儿？用好这些工具，就是为下一代我们下一个阶段，我们怎么能够找到人类跟AI去协作工作，来去做好自己的定位最好的一个事情。你在用的过程中绝对不是一个啥用。说白了你用excel用一段时间，你也变半个excel专家了。然后你也会对里面的计算公式是有更深度的理解，更深刻理解。然后也知道到底怎么能跟excel协作拿去工作。

现在AI也是一样，AI工具也是一样，所以大家不要觉得自己多用工具只是一个线性增长，我觉得肯定是一个非线性的指数增长。颠覆新媒体行业，内容全自动生成肯定会的。这个全自动生成的内容现在已经有大量发了这个内容出现了。但是还是优质内容，大家还是一眼能看出来。只是说非优质内容，非头部内容会变得模糊，非头部内容会变得模糊。大家会有些非头部内容，大家可能分不出来到底是人还是AI做的，所以提高品味很重要。然后计算机用计算机的淘汰不对。

高中学习数高等数学用的这个模型。好像学而思有一个九章是吧？我没用过，但是据说不错，九章模型大模型。但是我的建议是你先用主流的大模型先跑一圈，然后如果都不行，再去看看有没有垂直领域的模型可以用。

十点了，小平老师最后再挑两个问题再回答一下。

好好好。那你出来跟ww VI对是对，就是这种如何能降低模型幻觉出现的概率色，这是一个巨大的话题。这个我们可以找一期专门讲一讲，这个是和普遍的企业采用的时候最最浅层的问题。但是我觉得很大的问题就是大家其实还没有开始用的时候，就开始讨论这个幻觉的这个问题。那先把用起来，且把工程上该堆的东西都堆上，比如说rag，然后加搜索，加一些这个甚至你去把它做一个多路的生成，让他做一个一致性的投票，这些都做了以后再看改，再看幻觉。我觉得这个幻觉真的不是一个你如果认为真的是一个比较认真的严肃的来讨论的话，我们可以专门找一期讲这个事儿。

哪些模型对检索金文献找到的要点。我记得前段时间有一个公司专门去用模型来去结合这个基因库来去做搜索的。我得找一找有没有能帮助构建中文什么什么识别员工档案AI本地部署那种，包括帮助对比历史什么time的这个员工档案。你就先试试那种带支付的产品呗。如果进行行业重新规划AI方想进行行。什么意思？如果想进行行业重新规划，没太明白。你说重新选孩儿，就选了新的职业。

应该是职业规划。我看那意思应该是。

我觉得首先一定要避免直接让大模型来帮你做行业规划。谢谢孩子，就是不要觉得大模型那啥，对于咱们碳基生物来说，这个主观直觉还是很重要的，一定要对，还是那句老话，follow your heart, 这个heart还是很重要的。你自己爱什么，自己对什么感兴趣，自己对什么能产生这个冲动，我觉得这个是非常重要的一件事儿。这个决定了你因为咱们人类反正做一行要爱一行，这样才能自我麻醉。所以一定得找到自己的兴奋点。有没有模型在生成图纸方面比较成熟？没有，好的。

行。也是感谢小平，今天又又这2个小时的分享。小平的课主要是这样，主要是给我们分享最前沿的知识和信息，主要是能引发大家对AI的思考和这些启发，这个是最好最重要的。你说是不是上我们的课就能变成AI专家？这个肯定不能。你别说你要真能，我这十几年学习我会很伤心，白学了对吧？但是比如说像我们再安利一下，那个福利，就是找我们的这个客服小董，跟他要这个AI礼包。

咱们已经整合了一个大概七十多个场景的AI工具，包括使用的指南都放在里面了。包括咱们小平师兄很多的分享都放在里面了，对吧？实际上咱们根据自己的兴趣，根据自己的工作的需求，生活的需求，咱们去里面。



挑自己想用的，适合用的。

先把它用起来对吧？比如说你是个财务，你把相关的软件用好了，你肯定是一个比我厉害多的财务。我花20年我也赶不上你，对吧？但是你要想成为上课这样，成为小兵这样子的AI专家，我觉得这个也得花20年对吧？可能有AI之后能花十年，我觉得可能会快一些。好吧。师傅领进门，这个修行还是要靠个人好吧。

然后今天最后再想跟大家收集一个信息，今天这堂课大家听懂了多少？咱把百分比大概打在公屏上。今天这个课的内容，因为今天主要都是做应用的推荐，我觉得相对来说，相对感觉还是要好理解一些。大家有没有大概有百分比？大概今天听懂了百分之多少？50，五十不错了，五十不错，50很厉害。礼包。再说一下，就是咱们这个企业的客服小董去去去发AI礼包，就给他们领到50 60 70 30。

百分之百，我操太厉害了，百分之百比我厉害多了。10%，我我我可能有50%。行，可以。我感觉今天的课感觉大多数的同学感觉大部分能听懂。我我我以前上高中上课我都没有说，大部分我都听得懂，因为今天会走神。行行OK，我们最后再次感谢小平老师，好吧，大家在重新再打一下。

感谢能多给一些大家的想法什么的，我们后面内容也会更有对更有针对性。

行，我们今天的课先到这里，感谢大家。

我最后我最后说基础太差的同学，也是希望大家能够说一说到到底哪一部分听不懂。这个我觉得可能可以每期专门找一个时间来开始讲讲一些基础知识。

觉得这还对，这个后台可以给我们客服去反映一下，我们客服统一收一下是吧？对，然后想起一个事，今天刚才我最早就听到有人夸我了。我今天被抓来这个顶班主持，有人夸我是吧？我不会骄傲，但是我以后老夸我，我我我老来顶班。谢谢大家谢谢大家。

谢谢大家。

好，拜拜。