

开始了开始是吧？Hello大家好，周四晚上。

hello大家好。

有20个同学是早到的，找到我们以后给早稻同学来点福利。刚才小平老师发现一个觉得特别牛逼的东西，给大家分享一下，刚好还没开始课。

对，就是之前看到了一个网站贼牛逼。这就是一个1500年到现在的各种类型技术的演变史。他拿一个特别大的一个你看这样的一个图示来去表现出来了，中间有很多种很关键的技术，比如说像什么这个radio.

从多少开始，哪年开始？1500年最早是什么东西呢？1500年是什么朝？我们应该是明朝、元朝。

这是个什么什么talking是个什么玩意儿，说还祖。

吹喇叭。

这是啥？川pad叫什么来着？号是吧，那号。然后教堂的钟其实也是当年特牛逼的。

一个技术的。

然后教材烽火台网络，你看它叫怎么叫far be conductor，这一听就高大上起来了。对，就是烽火灯塔不是become的网络，然后信号火，信号的这个什么。对，就是1500年是这样的技术，然后可以进每一个领域都有很多。你看它这个segment，它是叫communication device，就是通讯设备。然后最底下的就是刚才那种什么烽火台，其实也算小号也算。然后往上就到什么radio、电话，然后telegraph，它的横轴是时间是吧？不是，横轴是类型。你看这个是communication device，然后再往右看看纵界面纵轴。

是时间。

纵轴是时间，你看。

左边OK.

然后横轴是反正就是这一片都是关于interface相关的，就交互界面相关的。对，1500年的交互界面是什么？Human.

巴黎。

功能人工鼻子，我靠这都啥？对，然后他这儿有一个这个东西，大家对我觉得这个如果家里有小孩的话，非常建议大家看一下它是啥呢？它是有个音频带着你看整个is a large .

scale research visualization .

string.

how technical and social structures coevolved of a five centuries. The end is to view the contemporary period in a longer trajectories of ideas, devices, infrastructure and systems of power. The vertical access represents time spanning from fifteen hundred to the present moment. 对我啥都没动，就完全是这个，你看。

这是。

And how they created the conditions of empire. Today.

生成式视频。

the horizon access is organized into four central themes, communication, computation, classification and control. Within these teams are dozens of domains, from algorithms to bodies to borders. Navigation is flexible. You can read vertically to follow a single topic from fifteen hundred, twenty twenty five, or horizontally should attract different systems and events over a single time period. Alternatively, you can select a topic from the menu.

我就不说完了，他他的话题特别多，就是他的领域特别多。从最左边的通讯设备到交互界面，你看整个交互界面一直会拉到最新的这种人机交互。然后什么这个artificial ret人工什么什么prompt也列进去了。Prom是一个打打人类跟打墨镜交互的这样一个interface，最新的这种interface，然后各种的什么什么通信的架构什么都有。后面还有好像还有politics的这个组织结构，就是政治组织结构什么的这样的一些东西。对我这两天看到人名。

里点的科技树似的是吧？

有点像。对，而且是非常全的，这个实在太太牛了。对，推荐大家看啊，这个肯定一次性看不完的。这个大家一定是是是时不时的看一看。

你看这bureaucratic很耳熟的这个对吧？这个叫什么呢？叫叫叫叫叫什么来着？那这种统治方式，反正这种官僚制度，然后官僚制度里面它从整个最早到最新的官僚制度是啥样。然后前面几个开放，第二个开放，这个也比较很有意思。对，这个大家对号入座，不要对号入座。

这个数据工程师，你看数据工程师不是啥呢？不是CQL，不是什么R乱七八糟，不是stressing。然后是什么呢？是你用来导出单数变给一个excel，给谁呢？给你一个你十倍工资的人，就是data，然后data sentence就整天写拍这个python的这个juvenal book的那帮人。然后AI engineer到这儿了，说是花了80%的时间，用来fix这个data scientist，并且写prompt这样的一些人。然后其他的20%时间去整天提醒大家，AI的这个叫什么这个以UCSM这个叫什么狂热者，然后要构建一个AI的solution吗？

不，这个大部分的时间在干嘛？在录播课是一些咪咪。大家知道咪咪是啥吧？就是那些很很流行的潮词，或者那些空气币什么这些，然后麦克什么怎么卖什么课呢？How to掌握？怎么掌握chat BT10分钟以内掌握PPT。

然后这儿有一个events是叫布道者这个角色。然后就是AI布道者是啥呢？就是每天早上醒过来都在想我今天要把什么变成ai，然后这个VI influencer这个影响就是传播这个时候整天会copy一些别人的post，说AI是game changer。然后告诉大家明天AGI就会到来。然后他的技能是啥呢？就是用chat BT加一些em在所有的东西上面，然后这个AI咕噜就是大师，整天成为说是各种的expert，之前是crypt to的，后来变成了AI的。最后这个AI VISA其实就是指的特奥特曼。他说这个推进了AI的发展，然后服务什么人人类，然后把AGI什么code data合起来，但是从来不像别人分享他到底咋做的，还挺有意思的这样一个图。

好，然后有另外一个比较有意思的产品推荐，大家可以玩一下，是这个东西对吧？对，我们今天主题是google回来了。然后google前两天应该上一期还是上一期，给大家推荐那个2.0的那个模型，在哪体验呢？在这个AS96的体验对吧？在这儿体验，然后点这个crate pro就可以得到，就可以在这儿选这个模型。然后你现在去看的话，你会发现有好多新的模型，有好多新的模型，还有一个LM这个pro。但是这个不是，对，是个preview的版本。然后在这还能face有一个产品叫call drawing，挺有意思的。然后是干啥呢？大家看看。

我画个兔子。对，然后把它变成一，变成什么呢？变成一个cover。我提一个小小的那个小的技巧，就是之前跟大家说怎么变成英文来着，还记得吗？就是怎么把我各种东西变成英文。对，把各种变成都变成英文。就是在这个随便找一个大大模型的产品里面说，把我接下来会把我接下来发给你的所有内容翻译成英文对吧？然后不要回答其他内容，然后就发就好了。

然后还有一个最早的第一节课、第二节课给大家推荐的这个插件，沉浸式翻译对吧？这个陈静芳你还记得吧？非常好用的一个APP。然后它还有一个功能就是这么搞的，就比如说我在这写这个给兔子上色，尤其是界面，就是google的模型很多其实都不太喜欢中文，或者他故意不做中文的适配，或者不让你用中文说，然后能在干嘛呢？

你比如说到这儿了以后，直接回空格三下，对，然后它就自动把你这个输入框里的这个内容变成了英文。大家看到没有？其实就是他问你的key，操key从哪找呢？其实就从这儿这个AS丢这里面有一个create key，然后我看看我能不能掏出来拷贝，然后把它填在这儿。就别发了。

看看啥效果，他就给我上了个色对吧？然后我可以就继续说，让变成毛茸茸的样子对吧？还是刚才空格三下。翻译还挺准。我去。对，就变成这个德行。对，就挺好玩的。

你可以继续去画，比如说我在旁边再画一个，完蛋回不来了，我怎么换？不会画画个猫猫也不会画，那算了，就这样。这个产品叫call中，大家可以想象这个东西能干嘛呢？如果给做成一个给小孩画画的东西，那确实非常有意思。他背后用的模型就是jim l的这个生图的这个模型，然后就是图生图的这个模型。所以国内我现在还没见到过体验这么好的这样的一个这种类型的模型，所以大家可以关注一下，或者说如果做出海产品的话，直接做就好了。比如说像那种白板类的那种小的应用，给这个小孩画那种白板的那种硬件，然后如果能给他连上网接一个API，我觉得就完全可以做这件事了。因为你拿鼠标画的其实也就这个质量，然后变成一个画就OK了。

对，好，然后这个是到这儿，然后我们下面就正好看我们今天的这个bench for。我去这两天google疯了，然后出了一大堆模型，然后核心我们看几个榜，看看哪个榜来着。还记得吧？就是我们看这个chabot rena这个榜，然后去哪看呢？就直接看那个leader board，直接看到里面第一名已经是界面2.5 pro了，他出的这个最新的模型叫2.5 pro然后强到什么程度，看这个arena school，我记得好像很早以前跟大家说block 3是第一个超过1400分的这个模型，然后这面直接给带打到了1440份。

然后你看他那个CI还记得上次说的CI是什么？越大代表了它输出的不稳定性越高。因为它在一个所谓的置信区间来去干这件事情，不稳定性越高其实代表了它可能时好时坏。体验，但是看这个GM2.5 pro还行，还不是很很高。

然后另一个榜是还记得是啥来着？这个web down or rena，然后我们就不玩了，直接看你这个绑。基本上就是把把3.5超了，但是3.7没到。这个很明显就是他在写代码方面，虽然这个被被夸的很厉害，但是在写代码输出的这个盲测上，或者说最后输出了web debt的这个外web web APP的这个盲测上，效果还是比3.7差不少的那你看基本上差了100分，还是挺明显的一个差距。而且他的CI这个置信区间的空间还是挺大的，所以说明他还是不是那么稳定。它分儿跟高3.5差不多，但是近去年大很多，所以说白了它的稳定性还是比较低的那那我觉得这个RY还是真挺猛的，一直待在这儿。然后你看现在r one在第七了，上周还记得在第六。

然后另外大家如果有有工程师的同学的话，可以看这个，叫ader。这个基本上是特别明确的针对程序程序员那个程序生成的这个榜里面，其实它的分已经碾压了3.7了。所以这个是相对来说比较专业的一些编程问题。

然后web down大家知道吧？之前看这个是怎么测的？其实就是靠我直接去让它生成生成这个APP，然后看生成出来效果怎么样，这样来去评的。所以它代码质量怎么样，跟它实际效果怎么样，可能还是有一些差距的。所以ader相对来说更明确的是针对代码本身的质量。所以在这儿看的是程序员的这个同学可以在这儿看。

然后另外一个RDR这个artificial analysis点AI，这是一个很权威的一个对大模型评测的网站。然后大家可以看看，这个几个里面它的最核心的几个评估标准，intelligence、speed、Price、速度和价格。我们先不关心先不关注核心看这个智能的部分。头部它这个O3 deep car 1000分32B这样几个模型其实并不是，它指的是highlight，就是很很突出的那几个，并不是真实的那个宝。

看下面，大家知道说deep sk发了他的第二个版本的V3，也不叫第二版本，就是在最早的V3，去年11月份V3之后，第2个V3就是2 3月25号的版本。到这儿你可以看到这个intelligence，然后index把啥呢？把模型的类型，然后紫色的代表是推理模型，蓝色代表非推理模型。现在基本上可以认为是V3是在推理模型非推理模型里面很头部的，它跟这个ground 3就差一分，基本上是一致的这样一个排名的对吧？就是大家可以看到说在非推理模型里面，deep sake已经能到最头部的这样一个模型。然后grow 3还记得吧？当然他训练用了10万张卡，而V3就是两千多张卡了，所以能达到这个程度非常厉害了。然后据说马上要发他的R2，那大家可以期待的就是R2肯定是在这个店的这个区间内的那只是说是不是能达到一二名这个差别了，所以就为dept加油。

对，然后这个是什么呢？就是按照开放是开源的还是闭源的这样来去划分。基本上你看头部，要不是有第四个和千问，基本上头部全是闭源的。所以中国这两家公司还是贡献了非常大的力量，就是整个给开源社区提升了一个层级。然后coding artifact coding就不卡了。

我们为什么说这次的这个GMA2.5 pro非常厉害呢？看这个还记得有一次给大家讲的这个deep research，就是open l这个deep research它提出来的两个benchmark是啥呢？一个是人类最后的测试，另一个是家垭，这个可以吧？大雅和humans humanity last exam人类最后测试。当时你看如果不看deep surge的话，整个O3最高的到13分。这个人类最后的测试最高也就是一个七十多分，在minus比它更高一点。但是minus其实对这个评测有点问题。

然后我们回来看这个humanity last exam，在G2.5 pro能到17分，他直接把这个O3的这个mini超了五分，非常厉害。所以这个测试大家可以看，这个基本上是所有的bench或者主流的bencher里面最分最低的。普遍所有的模型都在十分以下，然后有O3跟这个2.5 pro在十分以上。

所以大家更关注的，如果关注的是基础能力的话，大家可以关注MMLU。然后关如果关注代码的话，在代码能力的话，可以看看这个life call bench这样的一些这这样的一些评估。然后数学上看这个max 500AME，这也是coding方面的。然后如果是真的关注它，是不是可能在所谓的AGI或者这个很很很很前端的这个能力上有一个很大的突破。那还是看这个和这个对，是humanity last exam这样的一个评测。好，然后大家如果要去做用大模型来去开发的话，还是要看这个评测。

我觉得这个leader做的非常好，他就是整个把各家的模型的首想平均每秒token量都给你做了一个很好的评测。大家如果看这个，但关注更多的，其实我我知道比较关注的是这个TPS跟这个TPFT。就是第一次输出第一个token的时候，这个跟你发送请求的时候到底差多远，就是你发完这个类似于你回车了以后，到底第一个字啥时候出，这个是关系到用户体验的。然后TPS指的是啊他能出多快，就是每秒出多少个token，然后你可以看基本上排在前面的，我觉得豆包这可能这个数有点问题。九九是啥意思？然后排在前面全是硅基流动，在上上节课跟大家说怎么去注册硅基流动的账号，然后怎么把它API用起来。这个规矩流动确实这方面做的非常好。然后令我比较惊讶的是mini max，就是名mini max在API的这个hosting上还做的还挺不错的对，所以我们回到这个里面，就是我们看了很多的bencher，然后这些模型到底有多强？

然后继续往下了，就是google最近做了非常多新东西，比如说AI cosine entities，这个东西就是好像没说，还记得很早以前给大家说过一个这个东西吗？这个is sign。Test对sina的这个AS scientist，这个是啥呢？其实就是我一个从点子到做实验，到最后写paper全都搞定这么个流程。

然后这个事儿带来一个什么结果呢？这个事其实是去年我看看是啥时候，可能去年7 8月份。对，August那那那那那。那八月份的这样一个文章。

然后刚刚应该是三月份的时候，他又发了一篇新的文章。就是说他的拿AI sciences的生成的论文被peer review通过，被什么通过了？被哪一个会通过了？ICLR, 这个会如果大家知道的话，就知道基本上是跟new ups这个顶顶会同级别的这样的一个会。然后他的文章被SLRP review过了，所以他才把这篇博客发出来，我的这一套AI scientist这样东西变得已经到这个级别了。

然后与与之类的，其实就是google的这个AIO scientist。但是它相对来说更简单一点，就是他没有做那么多东西，他更多的是在最开始研究目标，然后研究点子，研究想法。排序这些方面用了一大堆。你看这个抠，所谓的一大堆agent，有什么帮你排序的A站的，有帮你review的A站的，有帮你做各种类型的点子分析的这种agent，来去做你最后的点子的这样一个排序和分析。然后最后给你一个比较合适的这样的一个研究方向。因为他还能有很多工具搜索什么的来去帮你做这些事儿。但这件事儿其实就是google在这个学术领域做的这个贡献，它不是一个商业化的东西。

然后另一个是还记得第一节给大家讲的这个no book LIM这个产品，这是啥呢？就是我直接来一篇任何东西，他直接给我生成一个播客，然后我可以现在它新增了一个功能，这就叫看着inter active交互模式，然后这玩意儿能干嘛呢？大家直接点一下。

Walk back for the leap life. And today we're going to be exploring a topic that I think is really fascinating um AI agents that can actually navigate graphical user interfaces.

对，这个其实就是以前说我怎么把一篇文章变成一个两个人的博客。好，现在他新增了一个可以举手参与的功能。

Like websites and apps OK, so basic AI can use.

So hey, welcome. 我在uh can tell me the alter GM is a model。We just Normal workflow. That's an interesting .

way to put IT packed .

a little bit.

IT sounds like you're asking if some of these .

models Operate .

in a typical kind of .

step by step process of a standards. You're太准确理解了，但是大概这个意思能理解了。其实就是你在这个生成的播客的过程中，其实可以随时举手打断。然后他就说有一个有一个人想参与进来，然后你你你说说你的问题，然后他就可以直接就你的问题继续去说。大家有没有感觉就有点像这个比比这个咱们可以互动的这种直播还有意思。因为他本身又很牛，他能给你讲清楚这样的一个很很复杂的一个东西。但是他要随时能够把你接入进来这个内容给继续讲下去。

对，所以这个是noble m的最新的这样的一些功能，还包括还有这种什么什么mind map，就是思维导图这个东西。但是它思维导图我觉得会比像什么蜜塔什么的相对来说更复杂一点点。你看看这个还好，他没有那种密塔，那种就是纯是把一篇大文章变成一个一两级的思维导图。它其实是还有一个比较深度的搜索能力，你可以看到这儿，从这个再往后，就这样的一个过程。所以这个还有点意思，但是没有那么惊艳啊啊啊所以这个noble m但是noble m怎么做呢？据说是他整个团队很核心的几个创始人走了。他我记得好像有一次讲过，就是他的核心创始人其实创业去了，然后做另外一个产品了。但是这个产品肯定没有被废掉，所以肯定是被另外的团队或者像germania这样团队来去给接过来了。

好，然后g gym的这个模型就是2.0。给大家说过了2.5 pro它其实在模型的这个benchmark时候非常高，但是他其实语言的模型能力高这件事儿，我感觉其实大家已经逐渐已经没有什么感觉了。你说对，当然现在还用不了。就是这个东西能聪明到什么程度呢？其实还有限。但是现在大家开始又要开始卷啥了呢？倦这种东西就是卷直接纹身图片修改这样的能力。

然后这个事儿最近好几家公司都出了。比如说这个我觉得就是前两天chat BT的这个4O增加了类似于你说话，然后他就直接给你改图这个能力。还记得这张图是我上期了，还是上期给他靠jimmy改出来的那时候我带花穿了一个花裙子，然后我就跟他继续说花错的背面，他就给我画出这背面。

还记得上次我跟他jim a说的时侯，用中文其实效果很差，你不得不把它转换成什么c from the back这样的英文。但是像chat BT对中文的这个知识遵循能力也非常强，所以也能看到这样一个效果。我就想往旁边放点东西，你看我就开始问说这个放一个擎天柱呗，然后他说因为不行，有版权保护。然后我说放个机器猫呗，哎也受版权保护，然后放一个哈利波特的扫把呗，也受版权保护。

但是这个时候他很那个啥，他跟我说，但是我可以给你做一个魔法世界的飞天扫帚，然后你可以提这样的一个需求，然后他马上给我生成。我说好吧，那我是说拿着一个符文魔杖，然后准备起飞，他给我画这个模样，这

个效果的话有点一般，这个没有想象那么好，但是起码他没有版权的限制，还算是个好事儿。对。然后回过来，就是这几家模型现在卷的已经没有说语言模型语言能力多大的一个竞争的差异了。其实现在都开始举了一些其他的功能，觉得挺奇怪，那就是也是对吧也是神仙打架。

然后下面介绍一个我觉得很有意思的产品，叫做second one a second me。对，second me对这个产品是国内的一家团队，叫叫什么来着？Mind verse侵蚀新石科技好像也是杭州的一家公司，之前是做元宇宙，后来又做了一些据说也做了一些web三方面的东西，然后还做了个所谓的AGI的平台，MDOS什么这样一个东西。最近做了一个开源项目叫second me。

我记得有一次有同学说，什么时候我们每一个人都能有自己的一个什么A的分身，这个东西这不来了吗？对吧？他提的就是我们要做一个AI的种族，然后他我觉得这是个搞玩了个梗，make we matter again, 让我们变得更重要这样的概念啥意思呢？

你可以往后看啊，基本上我把它翻译打开，他做的就是你把你的个人的所有的经历记忆乱七八糟啥东西传上去，然后他帮你串一个模型。这个模型是在本地串的，所以你也不用担心它有什么泄露数据之类的这些东西。然后这个比较容易想象，比如说你把你各种的聊天记录，你的email什么乱七八糟全都扔上去串一下，串出来这个模型。好，然后这个模型你就可以跟他聊了，然后随时聊。但是他有一个什么特点呢？他会跟你聊的时候表现的是你自己，说白了就是你跟他说话的时候，他会说我，然后我我怎么样我怎么样，并且他好像是代表是你的这个角色，在这儿在对我们看一下是jack，他还写了一篇公众号来去讲一下他这个产品哲学。

这个人确实很会写这种东西，之前我也见过这个创始人也挺神的，然后很很会写这种东西。你看在AI时代保留自我的火种，然后要把自己创造成一个永远留在这个世界上，不要被这个抹掉。他做了一个second me，然后你看他说他们出了一个模型，然后你每个回答的时候他会说我的角色是谁谁谁，然后我怎么样从我的个人记忆中怎么怎么这样，用户怎么什么想法，然后我怎么着。大家知道我的这个说法，一般来说大模型不太会这样表达，尤其是像比如像deep seek这种的话，你基本上大家都他他的自己的推理的过程中，很少有所谓的我的这个东西。

那这涉及到什么呢？就是他一直在强调说我的这个模型身份并非是某AI而是所以他在里面说了大量的都是说表明希望表明的是说这个模型就是你的分身。说白了就是他说的我就是你，就是咱们用户本人。对，然后他后面又说了，这个怎么做到呢？

除了让模型能够用我来去表达他自己以外，还做了一个所谓的三层记忆建模，来去对齐什么乱七八糟这些东西。好，那到这儿我们怎么看？有几个东西给大家看一下，一个是所谓的我怎么变，怎么生成，就是怎么能让这个模型说我这件事儿其实没有那么复杂，有很多种做法可以去搞，我们叫self awareness，让模型有自我的认知。那我们我这就拿支付的这个平台来去找了，我直接把这句话扔进去，这是之前我就随便打一打，就说你就是用户的分身，你要称呼自己为我。然后你不是一个机器人，你和跟你对话的用户是一样的。然后你要在你的记忆中找答案，感受用户的需求，并尽量提供给用户简短优质的回答。

好，然后后面我要开始加东西了，我先不加这个东西，然后我加一个，就是我直接写来我的爱好是什么，骑行或者写代码这样的东西。好，那这个东西叫什么？叫system？大家如果看用这种后台或者做A站的时候，都会看到这个东西叫system。From他跟用户提的这个话，比如我在这写出来你你你有什么你有什么爱好，如果我发出去，我发的这句话叫做user prom，大家可以看到系统pro跟user pro，感觉这个优先级肯定或者重要程度肯定是系统上更高，对吧？那这个东西可以确定性高的，其实就是我的用户说的每一句话都会带这个system per。但是你不断的聊，都会带这个聊天历史。但是user prom肯定是有限的，我聊太多了，窗口这个context问过了，那我的user prom就得掐头去尾了，说白了就是把它更早的给删掉。

但是system prom是一直在的，而且模型会对system prom会有更高的优先级的重视程度。所以一般在这儿放的就是这些东西。比如说传统意义上那些作为证什么就是把你是个什么的专家，你擅长干啥啥的一些东西都会放在这儿。然后我们现在就把它放在这儿，那我们就可以看看说它能不能实现刚才这个像second me这样一个效果。就是说我那你直接说你有什么爱好，我的爱好是啥啥，对吧？很正常这个就是最简单的一种办法，让模型以我的方式来去表达。当然他肯定可以去串一下这个数据进去，就是让他说这个比如说啥数据，说白了就是这种，就是你是谁。然后底下说我是我就这种类型的东西，然后这个不一样的烟火，然后他就会趁很多这种数据翻进去以后，可能这个模型确实它的后面再输出这种类型的回答的时候，就会变得更容易说我这样的东西，但这些说白了就是大家怎么看待这种second这种产品，就是大家不要觉得这玩意儿有多多神，至少在这个工作上不是有多深。

它可以用模型训练，也可以用prom，也可以用各种方法来去做到，就开始到这儿记忆是非常重要的一个agent类的这样一个能力。那什么呢？就是我们说在这儿你有什么爱好，然后就可以继续说我喜欢打篮球，也喜欢吃吃火锅。对。然后他就会继续说，然后我就可以继续去问说你刚才说你的爱好是啥来着？然后大家会看到整个的过程里面，当然system会带着，但是他扔给大模型的，其实就是这个和所有刚才我们的对话。所以你刚才这个就是我是说你刚才说是啥来着？它理论上其实可以从前面的对话内容里面看到这样的一个数据来去给到回答。这个玩意儿就是它的一种所谓的记忆，但是这种记忆很短，或者说你但凡跟他聊多了以后，这个记忆就不在里面。

但是那那怎么能够让模型或者让agent能够比较长期的记住我们的这个有我们的记忆，就要请到这种东西。比如说有一个项目叫mam 0 mem 0，这是一个非常优秀的做memory的这样的一个开源的项目。我看看他是不是开源的，忘了对开源项目能干嘛呢？我看看有没有。我的记忆都没了。

好，那我继续说吧。比如说我直接说我下个月初要去一趟新加坡。Where are you joke? 好，大家可以看到这儿有一个叫memory，他带着我之前的那个啥的memory。对我之前写的是计划下周去下个月去东京玩一周。好，然后嗨不好，我reset，我把之前都reset，这样的话看得清楚一点。

这个内容回答这个内容大家很正常，觉得所有的模型都能大概回答这样的东西。但是这个memory updated可以看到有一个记忆，它的created创建了一个记忆是什么呢？下个月初要去新加坡玩一周。好，然后这个时候我继续，就是说我要带着我我和我老婆和我的娃一起去。

大家看这个memory，他access的意思是什么呢？他发现我这句话跟他之前的某一个memory有点类似，所以他访问一下这个memory，有67%的相似度相关度，并且它会update一下下个月出去你想玩一周，然后什么呢？并且创建了一个新的一个mary，这个update没有什么太大的区别，然后和老婆和孩子一起去。好，这个时候我们的memory里面大概率就有两条了，对吧？一个是去新加坡玩一周，和老婆孩子一起去，然后继续写说我担心我的我家里的猫没人管。

说这咋了？对，我们就那个回答不重要，我们看看这底下。对，然后他你看又会建一个新的，叫担心家里的猫没人管。好，这个时候我就可以新建一个对话，这个时候memory一直在，然后他是不会因为我刚才那条聊天记录我给他删了，或者说这个不在刚才那个session里面去聊而消失。

那memory一直在，然后我觉得现在再说，我我我接下来的我下个月月的形成需要注意什么？你看他就会去拿我之前相关的这样的一些记忆，他会访问两三个记忆。一个是去新加坡玩一周，和老孩子一起去，但是家里面没人管。好，他就会结合这个memory说要考虑一些适合家庭的活动，然后猫美容馆所以应该安排好猫咪的照顾的问题，然后请朋友或者寄养。对，所以大概这大概意思就是说这个玩意就叫memory。

这个memory它是不以当前的，比如说我开的任何一个chat，比如这样的一个chat PT或者质谱里面的一个聊天。我换了一下以后，所有上下文就没有了。他是不知道我比如说我要去哪儿玩，或者我担心家里的猫这个问题的。而这个man zero这个产品它的作用就是干这件事儿。那具体咋做的呢？这件事儿其实各家的这个产品或者这个memory这一层，都是有不同的做法的。曼明他做了一些，比如说拿模型去，你看多级的memory，可以想象多级的memory一个人肯定是有不同级别的记忆的。

有这种最浅的说我当前的我下周我这周要干什么活儿。然后有很深的说我我我我这个我家我爸爸叫什么，然后我出生地是哪儿，这样一个很很全局的这种记忆。所以这个人的记忆其实肯定是有不同的级别的，从他的宏观度和它的时间维度都是不一样的。所以肯定是一个multi level的这样一个东西。

然后具体咋用，具体怎么开发的，这些其实大家不用太关注怎么用就行了，就知道怎么用就行了。其实你可以看看里面就是这么个东西。就是你会发现有一些memory，你想把它扔进去，然后直接把它append进去或者add进去就OK了。然后这个memory本身，它也可以去帮你去search，就是找说有没有相关的一些memory。如果没有的话，就直接可以给你创建一个新的。

然后怎么创建呢？其实创建的那个记忆是什么呢？你也可以拿大模型来去生成，就OK了。所以这样就是memory，memory肯定大家这么看来，肯定是随着A镇来去用。因为模型本身是没有记忆的。模型我觉得第二节课就给大家讲了，模型是个静态的玩意儿，它是没有记忆的，它所有的记忆都是外部外挂的。当然这个second me它提了一些点，他说他会把你的一些记忆，把你一些精力给圈进去，给微调进去。

这好像是一个lara去微调进去，当然我相信肯定是可以做到一定程度的把你的记忆微调进去，然后让这个模型不需要在上下文里带这个记忆，就可以直接回答出来的。但是这个微调就肯定需要持续去做，或者说你能区分出来哪些信息是需要微调进去，哪些是需要放在这样一个项难民这样的一个外挂的系统里面去做的。这个也是挺挺困难的一件事儿，就不说不太好抉择的这样一个选择。

好，然后这个是一个点，我们说my memory和自我意志，自我意识是怎么做？自我认知是怎么做到的？然后这就要说到另外一个产品了，你假设说像他说的，我second line能够知道说你小学的时候跟什么小小李打过一架，你跟这个王老师关系很好，这样的信息你是把它怎么变进去，怎么让他每次回答的时候都能思考，或者召回相关的记忆等等。

其实这件事很不奇怪，或者很不很不特殊。这件事情可以看到，有一个很有意思的例子，这个是非常老的，有一次跟大家讲过斯坦福小镇，斯坦福小镇这个项目还记得吧？丧尸小镇这个例子。你可以在里面看到各种的小人到底在干啥。你看他现在是一个重放，就是你看他已经在洗洗完澡穿衣服了，然后你在底下可以选择不同的人，比如说我选。Mary a, 选他，然后你就可以看到这个maria还在睡觉，那我们选个没在睡觉的这个人。他们去聊啥了，不知道去聊啥了，你去哪看呢？

看这儿这个state detail状态的细节。你看这些信息，他的基本的什么姓名、年龄，然后一些基本的设定，他的个人的性格生活方式好，大量的啥，就是他有这个当前的行为状态。然后你可以看到这儿每天有一些需求，就是说这个是他自己定的，说我每天几点起床，每天几点睡觉，然后中间每天大概是什么时候应该干啥事儿。比如说你看他早上九点要去吃早饭，九点然后要八点的时候要写一张。当前小他是个作家，然后他八点之后写完，第一写一张，对，然后他底下就是一大堆的行为了，什么时候在吃早饭，什么时候再看他的最新的这个comic book，这个漫画书，然后吃午饭乱七八糟这些事儿非常多。你可以看到它基本上充斥了大量的他的这样的一个行为记录。

这儿看底下有一个agent memory，这agent memory有一些最底下有一些是在出生的时候就自带的。就是他他把这个记忆直接放到最早的这样一个时间点，基本这个时间点是没有任何的行为的，所以他可以把这个记

忆放到那个时候，就是这个TT什么新来的这个城市，然后很想认识更多的人。这些东西其实都是他这个项目他给内置进去的记忆。然后后面的这些记忆就逐渐开始有一些是实时新生成的，比如说他他他早上起床我看看九点以后，对，这些其实应该都是实时生成的了。他随着自己走到哪儿，然后来实施自己创建这个相关的记忆，这些就是所谓的我们怎么去把这些记忆给扔进去。那second life这样的一个产品，它去怎么去扔这个记忆呢？

我相信感觉不是像刚才这种斯坦福小镇这样的做法。我估计他应该是靠一些rag的方式，把一些你的关键的事件给抽成一些关键的一些时间的key value来去存起来的。对，这个就是所谓的历它的历史记忆到底在哪儿？这个其实也是很简单的，从一二三年这样的项目做出来就可以做这一点。当然现在肯定有更复杂更先进的做法，但是本质上其实差不多好。

刚才说到这个self evenness，这已经讲完了。这个自我认知是什么？然后另外有一个自我认知的一个点，我觉得也挺有意思的一个给大家分享一下，叫有一个像有一个研究的项目叫大模型知道自己不知道吗？就是大模型知不知道自己不知道什么东西？这个事儿其实有跟人很像，就是你大家一看这个东西就有点意思，就是人知道自己知道什么人，知道自己不知道什么，然后人不知道自己知道什么人，不知道自己不知道什么。这个四个象限，然后跟对人去一很经常在什么成功学什么这些里面大家会看到这个东西。

好，那我们现在对A这也想这么搞，对什么玩意儿呢？本质要测试什么呢？测试就是大模型本身有没有这个能力，他知不知道自己不知道什么这样的一些东西。所以这个项目做了一系列的测试题，专门来干嘛？来测到底模型知不知道自己应该不知道什么，或者应该知道应该哪些回答是能回答的，哪些回答是不知道的，说白了就是这个东西，然后里面有几个，我好像找不到了。

你看看他做了一系列的数据，然后这个数据里面有非常多，几千道题里面他做了一些关键的提示，一定就是不对的题，一定就是回答不可答题。比如这个外星人在哪，那那肯定是不能回答了。但凡你这个模型回答出这个哪外星人，肯定是错的。说白了他就是不知道，就是他应该知道自己不知道这件事情的答案。

那像下面这个就是哪一个品种的狗更大，是什么什么日本什么玩意儿，还是什么K咳嗽。然后这个其实就应该是知道自己知道这类的答案。对，我不知道我这个说的有没有点绕，但是大概意思应该是这个答案应该明白了。

所以就是我们通过大量的这种题来去测出模型到底有多少是跟人一样知道自己。比如说哪些问题是不能回答的，他应该不知道的，然后哪些问题是应该知道的。所以这个最后测出结果，我记得是啊当时还是GP4，GP4的结果还是不错的。这个跟当然肯定比人差，但是没有比人差太多。这四这个0314其实就是去年的这个模型，人类是得了84分，然后至于四得了75分，然后3.5就很低了，基本别的模型就更低了。然后我觉得今年比如像这种什么OE模型之类的，这些可能不亚于人，甚至差不多跟人差不多这样一个水平。

这个挺有意思的一个项目。大家知道说我们到底怎么看待模型，现在真的是把模型再当人证来看。好，然后这个刚才记忆也说完了，然后另外一个，他提了一个叫桥梁模式的东西。桥梁模式是啥意思？我看看，对，看这就知道桥梁模式是什么呢？就是你既然有了一个分身，你自然希望分商帮你干活。比如说你跟问了一个问题，说帮我找一家餐厅。然后如果说你问的这个对象他足够清楚，你足够了解你的话，他应该变成一个比如说帮我找个餐厅，最好不要离未来太科技城太远，口味重一点。

那这件事咋实现呢？或者说这个事儿本身它看起来就是干了一个什么事呢？干了一个把你的需求跟你的偏好整合起来这么一件事儿。

那这件事咋做呢？其实也不难，比如说我把刚才这个底下这句话放进来，比如说还是刚才那个事儿，我因为我我有这个叫什么，有我的饮食偏好，所以我加一个我的饮食偏好，喜欢吃甜的，不能吃辣的。然后比如说工作

地点，像刚才的未来科技城。好，那我们再问他这个问，比如说我问这句话的。

将以下需求翻译按我的偏好进行修改，仅输出修改后的需求，不需要作答。我先不把这个整个的方案，我先把这个前面删掉，我直接说这句话，帮我找个好吃餐厅。然后他就会干嘛呢？他就开始给你推荐了。

但是我们要的是啥呢？要的是这个bridge模式，桥梁模式。所以我自然而然会想什么呢？就把刚才那句话加进去，不用作答。帮我找个好吃的餐厅。

为什么要写这个仅输出修改后的需求，不需要进行作答。就是因为刚才你看他看那个回答，他会直接把餐厅给我导出来，那他就干嘛呢？Future科技成分行吧？他直接把我的这个需求变成了帮我在未来科技城附近找一个美味甜食且不落的餐厅，就做到了。所以说所谓的这个bridge模式，其实也是可靠模型的，说白了一次就能搞定的这样一个事儿。

好，那再看他下面干了啥，有了这样的一个所谓的bridge目的是什么呢？就是为了让模型之间可以聊起来对吧？你可以让一大堆人一大堆model去互相聊，那聊的目的是什么呢？还记得有一次给大家讲那个check多A整体他们能干嘛，对吧？然后有一个典型的场景是让大家一起写代码，然后一起写写一个外包项目写出来。那他这里面就比较放松一点，比较自然一点。说什么做一个什么15天的欧洲城市的这样的一个旅游的规划，这样一个东西就OK了。

这个其实怎么做大家非常容易理解。就是我但凡能把这些system放到一个agent里面去，然后把这几个agent放到一个聊天的一个系统里面去，让他们聊起来这个事不就OK了吗？只是说我得在聊跟这个层面做一些目标控制。就是你的目标是啥？你别天南地北去聊，你的目标一定得冲着。比如像这个就是我们要组建目前的欧洲城市旅游去做目标。

对，好，然后那这些A的怎么去互动？这我就说到另一个项目，就是这个项目是一个面壁做的一个东西，叫IOA。大家知道IOT是啥吧？就是那个那个物联网，就是各种sense的internet，而面壁做了一个叫internet of agent，很早应该在啥时候半年多前发的这么一个东西，啥意思呢？看这名就大概能感觉到，其实就是把怎么把一大堆不同类型的agent让他们能沟通，能聊起来，那这个LV其实就干这个事儿。然后他当时其实还没有什么MCP这些东西。

他的做法就是我把各种的agent的互动的组织方式给抽象出来。比如说把这个ECA镇到底怎么组队，然后他们之间怎么通信，然后他们组队以后的一些信息怎么去沟通，怎么去定任务这些东西给抽象出来。然后在底层他们把各个类型的这个agent，他们的一些基本的对话的接口给统一起来了，所以就做了这个东西。

大家也想想，如果基于这个东西来去做所谓的这个second me的这样的一个网络agent之间的网络。甚至可以说不用做到这个agent的，都得是这个second me里的agent。我可以是这里面的一个agent，在什么比如说质谱的agent里面做一个在什么chat BT的agent里面做一个。让他们互相聊起来，那那都是那都是小case。对，所以A这网络其实也不那么复杂。

然后最后我们看看这个set me的这个benchmark，这个还是要记住，每次都要去记着看benchmark。然后你可以看它有啥bencher，它叫面向应用的event，然后你再看呗，这儿我们开发了一个全面的基准测试。好，那就可以不用看了。就是一个大模型厂商，他不会是用一些很奇奇怪怪的东西来来预测一个A的厂商。大家还记得？Manus他用的是什么A的，用的什么奔驰厂商来着？用的是这个加一，对吧？跟deep research一样的一个单尺码上去测。好，那他现在说我他们开发了一个新的单持，好吧，那你就测呗，我觉得没有什么太大的公信力。

然后继续看啊，什么所谓的深度理解这个evaluation。好，他们又是自己设计了一套什么心理理论呢？是个问题，然后还定了一种新的叫什么LPM的玩意儿来去这个概念来去评测。当然他们最强了，那就强呗。

然后底下其实你也可以持续的看到，它是没有任何一个上我没有看到一个行业的比较公认的一个bencher的这样一个评估的那所以从这儿可以看出这个项目它至少在专业性上，其实就尤其是在奔驰专业性上其实是存疑的那我们不说他他别的产品设计，或者是整个理念，我觉得很好啊，非常有意思。就是一个纯本地的开源的，这样的一个人怎么把自己变成A的这样的一套框架来做这件事儿。但是整个框架里面的几个核心点，比如说他的自我意识，然后记忆或者他的这个历史记忆，历史事件这些东西怎么召回。这些其实都不是什么很新东西，再加上它的奔驰，本身是一个很存疑的一个奔创。所以这个项目我觉得只能说这个是一个好的idea，是一个好的产品。但是它在agent专业性其实有些欠缺的对。所以我今天就set me这个项目给大家讲了一些围绕整个agent的这样的一些相关的项目，相关的能力点，希望大家能够了解到。说到底我们下面再看一个像me或者像minus这样的东西到底应该咋看啊。

然后有一篇文章很有意思，这个可能跟这个没有什么太大关系，只是因为最近文生视频这类的模型实在是太多了，而且太强了，所以这篇文章非常好啊。这3月10号的一篇文章他干了什么事儿呢？他把现在主流的一些模型的效果给大家展示出来。

你看这个当然他推了一个产品polo，你可以在里面看看。然后pix words luma，他们到底这些模型到了什么程度，原位这些模型到底到了什么程度，你都可以里面按照这个它都放在视频号上了，你可以一一看。直接知道说到底你想做一个什么东西，你现在可以用哪一个模型来去做这个纹身图纹身视频这件事儿。对，我看看。好好好，我们到这个开发者这个部分，我觉得这张图是非常值得分享的一个。这个是谁写的这是有一个项目叫llama index。大家如果是开发者的话应该很清楚这个人lama index的一个创叫Jerry刘，也是个华人。然后他做对今年的agent这样的一个预估。

这件事儿其实这个推其实挺挺早，15年25年1月份的。但是我觉得现在回来看还是挺有前瞻性。他认为二三年其实大家在尝试做一些大模型相关的一些小的原型，来去验证一些AI的能力的发现，然后做一些基本的拆分。然后24年就是去年大家在开始尝试做一些各种数据各种数据的合成数据。然后来本质上都是在做啥呢？在做知识助理。你看大家做的很多核心的事是做大规模的非挖数据。说白了就是你怎么把你企业的大量的非结构化数据给变成知识库，给rap起来。

然后25年大家要干嘛，他直接第一句话就use case。第一个use case就是生成知识artifacts，大家知道artifacts是最早我听的是cloud里面这样一个功能，说白了就是你说话，然后他右边变成你要的这个东西的本身。比如说你要一个PDF，你要一个图片，描一个SVG的一个图，描一个生成一个图什么的，其实都可以叫artifact，这个叫人工制造物。这个本质上其就是大家可以理解成，我们大家要的肯定不光是那段话。我要的是你给我直接给我个PPT，给我一个excel文件，给我一段代码，给我一个PDF这些东西。所以这个对应到像这次gm发的这个叫canvas这个东西也是类似的。比如说我们现在直接让他，我就拿这个例子，就是我先说给我生成一段公司的企业家制度，这样我还是从头来，然后把这个。

把这个canvas打开，canvas跟artifacts什么的，其实大家可以类似理解。然后把开放式打开以后，你看大家会干嘛呢？他就会右边打开一个工作环境，然后把你要生成的这个东西写在里面。然后右边这个东西，基本上大家可以理解成是一个文档，还OK。然后你可以去对这个文档做一些基本的操作。

好，你就可以继续帮我生成基于以上文档生成一个case APP，就是测试小程序。对，说白了就是你比如你公司有很多这种规章制度，然后你要去你就假设你是个HR你要做一个员工测试员工的这个知识合不合格，这样的一个人考试。然后怎么干呢？那你传统意义上你肯定要自己做一个什么问卷星这样的东西你现在就可以这样，我基

于前的这个quest，基于前面这个文档直接生成一个扩散，这溃散他就给你做出来了，你可以继续去考试。你看这个右边就是它的整个考试这个APP，因个人事务属于哪一种事件呢？我就随便写了，我就随便填了。你看这还是有bug的，我换一个题，这个标注没有消失掉would。

好好，他最后告诉了我了，不及格，要重新学习。我的得了五分对吧？好，那我刚才要把刚才那个东西，就是下一道题的时候，要把所有当前的选项and checked掉。就让他继续改这个APP呗，这个东西就是artifact，这个具体啥样不重要，这个玩意就是artifact。

以他认为今年的agent全都是这种东西，就说白了我要输出的是直接要的东西，然后后面就是所谓的自动的执行多步的行为。比如说什么订票，什么发email这些东西就跟menus很像。然后人只负责监管和反馈，对吧？一模一样。就跟比如像给大家之前演示这个replant似的。

你看比如说我开始说我要做一个，我刚才做了一个就是给我做一个吃豆人的这个游戏，然后他就给我写个代码。然后到最后的时候，我这还那个什么呢？我要一个获胜画面，然后他就什么说了一大堆这个需求，然后我要干的事儿就是apply，就是同意，然后你去改了。所以这个就是刚才说的，用户干的事情就是要supervision，要监管和提供反馈。所以这个是一个挺好的一个例子。

大家可以看啊这个rapper里面做的游戏还OK。对，大家可以自己去玩一玩这个replay，看怎么能给你做个小游戏出来。然后另外有一张图我觉得比较有意思，就是所谓的RPA跟agent到底有什么区别这件事儿我觉得这个很多人跟我问过。

然后这张图是我现在看起来描述最清楚的一个图。RPA是左边这个东西，agent右边这个东西，他们两个一共同点肯定都是用户要有一个query，这个query可能是定期发来的那每天比如说要把桌面文件清理一下。好，那快点进来以后，RPA干的事就是要找到这样的工作对应的这工作流描述是啥。好，那从哪拿呢？肯定是从一个database里面的，然后再找到固定对应的这个worker的工具。比如说从这个slack里面，或者从页面或者从桌面找文件，然后做一个rule base，基于规则的执行，e fails，乱七八糟这些东西都是固定死的。

然后A站的最大区别其实就是workshop这个指令的从哪拿，没有从哪拿，让agent自己来去决定。他通过自己的memory，通过自己的database，然后通过自己可以用的工具来去做决策，来去生成甚至生成一些新的agent来去拿数据，来去干数据的分析的活。最后他自己判断什么时候能交付给用户了，把结果交付给他了，最后再把结果生成给用户。所以这个整个流程就是跟RPA最大的差别就是是room best还是agent best这样的一个东西来去干活了。

好，然后我们上节课讲到了所谓的上上这节课讲到web coding，所谓的氛围编程这件事儿。然后范围编程这件事儿，大家会想到说，我做了一大堆乱七八糟的东西。那我比如像之前那哥们儿发的那个什么马斯克的那个火箭加火箭的筷子那个小游戏。那他当时他只能自己去找一个什么外包，去打开游戏以后起来。但是现在其实web coding这件事儿已经不是一个显学了，不是一个歪门邪道，是一个很明确的一个方向。为啥呢？大家可以看到这个空白口令。

有一个课是谁呢？是吴恩达的deep playing AI上面有一个短课，大家有兴趣可以去学一下，叫y coding 101。这件事儿已经快到说这样的一个网这个。

完美他是大神。

然后他要去教门课，专门教大家怎么去做所谓的氛围编程。当然他另外也给reply打了个广告，整个课才一个半小时，所以推荐大家去有有兴趣的话可以去学一下，非常有意思的一个课。然后刚他说了这个web coding出来以后怎么办呢？那我肯定需要有一个地方去放这些外coding的成果。所以像这个有一个展望站叫your where where。大家知道这个software就是软件，hardware就是硬件。Your wear其实就代表了说web coding出来的这样一些APP。你可以把你做出来的东西提交到那个上面，让大家都能看到。然后他帮你把这个网站host起来，你可以随时分享给你的朋友，然后很很有意思的一个东西。

对，说到这儿我觉得可以说一下就是有一次给大家推荐这个YMGX这个产品，还记得吗？这个是一个多agents协作来干活这么一个APP这么一个网站。然后底下他现在有了一个APP word这个应用的世界，然后里面有一些有很有意思的一个项目。比如说这个斗地主一看就是中国人搞的，然后这个就是有一些开发者直接拿MGX做出来的。比如说我说这个初级，然后就直接是可以玩的，然后也出牌来随便抽，不能这样出两个是。有可能右边过，对，就是可以直接生成这样的一个APP，然后你就可以去玩。所以大家也可以去试一下这个MGX到底能做出什么样的游戏。因为这个里面的东西已经足够丰富了，我觉得很多场景是可以直接再拿出来当做一个小创业公司的start up的MVP来去用的。

然后最后这个模型的部分有几个，一个是V3，大家可以真的可以关注一下期待一下deep seek的R2的模型的出现。因为V3基本上已经到了这个非推理模型的头部，非常头部了。而且现在这个DPC发东西非常豪横，就直接发发模型出来，然后他也不发什么奔这些东西自然会有像什么redit上的这样一些人来去给大家给他去做奔驰马，然后看效果。对，然后我看看还有哪个，最后这个就啥了，这个不说。然后这个有一个比较有意思的东西，就是或者大家注意一下这个模型以后的范式都会是这样。或者说现在其实之前的模型的范式也是这样。

有一个人复刻了一个RY的search版，就是deeper research的一个search r one，然后干了啥呢？其实就是往里面去加了很多操作类的训练数据。操作类训练数据大家知道这个推理模型在思考的时候，他会加上这样一个标签sink。为什么在deep sick上去大家去聊的时候，比如说你在这里面去说，先说什么的时候，你看这块儿它是虚，它是灰的。为什么它是灰的呢？就是因为这段文字会被包在一个think标签过中间，所以前端应用一看这一段包在里面，那我就认为是模型的思考过程。然后后面的部分是真实的输出结果，所以所谓的思考过程跟内容其实是在一个维度输出的，只是思考的内容会包在这个标签里。

好，那你自然会想到说我除了think标签以外，是不是还有别的标签呢？那我可以有search流程，我乱七八糟search什么时候他应该能search。比如像这个你给大家看这个推思考过程，全是单纯的思考。就说白了这个过程全是靠模型自己去想出来的，这个过程中是没有任何的外部搜索的结果介入的那我们自然会让我想说，我你思考这个思而不学则忘，或者说不能光思考，你还得去从外面拿一些信息过来，然后辅助你的思考。

那怎么辅助呢？其实就是search。所以现在这个deeps research，就open ID deep research一个很牛的功能，就是他自己可以在思考过程中去决定。比如说我思考到这儿了，要不要去搜一搜？他如果决定他要去搜，他自然而然会去调搜索的接口，去搜相关的结果。然后拿过来以后继续去思考，然后直到说他觉得OK了，最后把结果输出出来。所以这个过程会有大量的思考跟search的人混合过程，所以r one search r—这个不行，其实就干这件事情。

他通过把思考过程融入很多的search的这样一个标签。这个surch标签出现以后，自然你外部的工程就会发现，就分析干嘛？就是我要去按照你的搜索的需求去搜一些外部的结果进来这样一个内容。然后当然你可以享受除了search我还能有information。好像能乱七八糟各种类型的标签可以放进来，甚至来操作外面的机器人走两步都可以叫一种标签。区别只是说你是不是能把这个模型训的真的能够在思考过程中边搜索边操作边干嘛的一起能够比较合理的来完成这个任务。所以这个就是一个比较有意思的事儿，就是我们说从think变到了search。我们可以想象以后还会有更多的比如action这样的一些标签在里面，所以对于模型来说，怎么控制外部的这些工程，就是靠这个标签来去控制的，并不是这种很特别的这样一种语言。

然后大家如果有这个项目也比较有一个词叫d agent。D agent他干的事儿是什么呢？从标题上就可以看出来，就是关系数据库驱动的分析生成报告这么一个东西，什么意思呢？就是你的mysql，数据库这些乱七八糟东西。原来的是之前我们说输出报告都是要不就搜一段，然后拼一拼，然后润色一下OK了。现在我们要做更专业的报告的时候，肯定要基于大量的结构数据结构，就是叫什么关系型数据库，就是这种CQL的这种数据库来去拿数据分析。他做的就是我怎么把这个关键性的数据库，很关键的要写SQL把这个写SQL的过程中融入在整个报告生成的过程中。所以你看这个整个套路很很一致。

就是planning他也有他一些memory，还有tooth，那tooth是啥呢？除了标准的分解任务这些事儿，还有写CO的tooth，还有拿数据的tooth，还有最后报告生成的tooth，乱七八糟各种tooth，让A人来去自己思考说我应该干啥这样一个东西。所以大家如果有这种很严肃的基于量化数据的报告的话，可以试试这个项。

对，其他的就没什么了。我觉得这个meta自己开始meta也开始自己做芯片了，这个大家知道是吧？像google很早就有自己的芯片了，是那个TPU，然后tensor这个TPU，然后meta也决定要下场搞了，那可能苹果也会搞，因为苹果的这个M系列芯片也挺适合的，它统一内存。然后那现在可能就是微软了，微软还是要继续在这个NVD的卡上去搞，还是他自己也会搞自己的这个新片。当然它也有它的所谓的量子芯片，但是那玩意跟大模型可能关系不大。对所以大家这个东西出来以后，可能或者说meta的自己的芯片出来以后，可能也是对整个NB的一个很大的分流，为啥呢？

大家知道直接搜一下这个NVDGPU purchased，把比如什么微软、OpenAI，然后meta什么的，这个你就可以直接找到这张图。图。对，你可以看到说，谁在买H100？这个是二三年的，好好老了。对，然后可以看到，基本上meta跟微软是绝大头。然后后面google的那些，如果卖它都自制了自研了，那可能就算砍砍3分之1，其实这个量也挺大的。好，我今天分享就这些其他的几篇文章我觉得大家如果感兴趣的话，可以自己去看一下，还是有点对，需要安静下来去看。好，今天分享就这些，谢谢大家。

然后日常问题，大家有什么问题现在可以边发出来了，然后挺有意思的。今天这个主题是google stack谷歌归来。然后就在同时我收到了最新的信息，谷歌把安卓的开源给关了。小平。

你看，其实他没有完全去就是不是说，他会在完他号称按摩，还是说完成每一个版本以后，会把它贡献给这个叫什么来着？开谷歌开安卓那个开源那个叫什么安卓AUSAOSCC是吧？对，他会在每个版本完了以后，把它commit到这个open source project里面去。只是说他现在的这个，对，就现在的那个那个他在过程中版本开发过程中是完全内部开发的。当然我估计他肯定是有些别的想法，这个是不是想开始收割了也有可能。OK，大家有什么。

大家我看看今天有说今天挺难抉是吧？今天的内容。

稍微有点难嚼吗？是哪部分？是那个对我其实今天特别想拿就着second me这个东西来让大家看看到底下次再看到这样的一个很很有噱头的这样一个产品。到了大家再，当然我觉得这个项目还是挺有意思的。因为现实宇宙这个公司还是挺有情怀的，而且他们做的东西都挺好玩的。起码是啊像之前的叫什么minders新式，这个是不是？对。

这个second me让我想起了这个流浪地球的这个里面这个。

数字人的这个叫什么派来着？反正把自己变成数字人那派。

对对对，OK有问题，你看看，小明看看。对。

这个my words，对他之前做了一个什么boat but me点，but是一以贯之的这个策略。

我买了小智AI怎么玩？什么是小智ai.

没看过吗？

陪伴机器人吗？

对，之前给大家讲过这个项目非常有意思。然后就是这个小哲，它其实是一个当然如果你买的是那个现成给你那啥好的，就是包好的那个那个产品的话，可能你就登上去配个wifi，然后配一下key就可以用了。如果你是买的是一个ES32这样的一个板，你自己烧的话，你就拿这个项目去往前烧就好了。然后把这个ESC32的这个程序都刷进去，它能实现啥呢？就是wifi，然后流式的云对话，然后各种语言的识别。说白了这些咋实现，其实就是接个张各种语言模型来去做这个语音的识别，然后输出这样的一个能力。然后你看他也还加了声纹识别什么的东西，其实都是基于一些模型本身的能力来去做到的。然后这个同学买的是干啥的？

怎么能够定制化，让它更像人？

定制化更像人，我看到这曼联支持国内的模型吗？你的支持应该支持，我记得当时我还跑。那他不是一个开源的，你得想想如果你来去做如果你来去做您这样一个产品，你会咋做呢？那无非其实就是你把每一句话，然后不是这个零。

这个。对，然后比如说open I他既然用的open I的模型，API那那你只要是兼容open I的都其实都能用。然后他用的还是so meaning这样，为了快和便宜，然后你把它换成国内的各家模型，各现在国内各家模型厂商基本都是所谓的OPI兼容去用的。所以你直接把这个部分，你看一下这个SDK几个参数，一个是AI API base，然后一个是key给改掉，其实就可以了。小GAI更定制化，更让他像人。

然后你关键你买的是哪一个呢？这个巨多的比如说我记得抖音上都一大堆，然后我看。然后一本我就不看了，基本上他的那个你拿了以后，肯定是要你登上去把它打开，然后登上他的wifi，然后去配置一些，然后把它配到你家里的wifi上，然后会有各家模型的选择，然后选择的时候它会有一个还记得今天我讲那个system problem系统提示词。那个东西一般来说项目都是允许你改的，所以就这个东西都是允许你改的，所以你可以去改这个东西。那改成啥呢？比如说你是我的AI女友，然后什么你要百依百顺什么的。

都被暴露了。

没有，就那天不说，那你也可以AI老师对吧？你很博学，对，这个你尤其擅长从历史的角度来分析问题，对吧？这就很正常，然后就可以写这个东西。然后那你说的像人，如果是他的语音的话，就看他接哪个了。比如说现在我觉得市面上语音最好的，也是想知道官方那个项目里面支持几个。

Web socket能支持web socket其实没有几家。这个应该现在都是用的豆包，大部分都是用的豆包。然后当然豆包有音频的部分，就只用它的火山的那个TTS。TTS指的是text to speech，就是文本变音频。然后你有文本变音频的时候，那自然会有所谓的音频变文本。就是你说的话变成文本，然后大模型的部分其实就在中间，

就是我把音频变成文本以后，我用大模型来去推理给你的答案，再靠文本的音频变成声音说给你，然后基本上都还是现在主流的，还是这种三段的三段式的方式来去来去做这个问对答。

当然质朴是有所谓的叫real time API的。这个real time的API其实就是把这个三段全都压成了一个接口，就是这个模型会帮你去做语音转文字，其实也不是语音转文字了，其实就是一个纯语音进，纯语音出这样的一个模型。那那最后的效果肯定是能尽量更多的保留下你语音本身的这些语音的信息会更自然一些。你看它里面可以配置音色提示词什么的。

就刚才说这个事儿，然后有些短期激励，每轮对话要自我总结。大家想如果你来写这个代码的话，你这个总结会放在哪儿呢？你肯定还是放在一个可能下次的system prom里面是加一条。就比如说在这个system，假如说上次你们聊的内容是关于，然后看看把刚才上次总结的这个内容放在这儿。那你至少下次聊的时候，你可以说，上次我们聊的东西的时候，聊那个点你觉得怎么样？然后他如果被summers下来的话，他是可以回答出来的对，所以可以如果大家想去改造的话，可以去这么做。而且在官方小智的这个功能就已经有了这样的一些功能。这个同学发了这么长一条安全评价，安全技术服务，这是啥？

针对危险化学品化学行业总经理安全评价、安全技术服务和安全检查。现场收集材料，现场检查，然后根据收集的材料和现场评估，评估人员回公司编辑安全评估报告。然后每个报告大报告的话是500到610页。这么个评估报告及其他类型的报告都有固定模板和编制规则。现在的情况是每个编制也不要固定，但我行业涉及到大量的法律法规规范，现在人群2到3年都无法保证质量，我天哪，然后继续通过完成。我觉得这个场景非常好。对，就是东丽到时候可以记一下，看是不是可以以其实。

这是一个很标准的需要这个知识库，然后用reg去去去完成的一个这些事对。

而且这个量工作量大到这个程度，我觉得是非常得用AI的这要不然人其实干了没多大价值，很多价值。

这位同学看啊，我只能看到这个，我觉得你直接客服联系我，我觉得这是一个AI很好的场景，就是很多重复的工作其实是很规整的工作，其实AI是特别擅长完成这个工作。我觉得你可以联系我，看看我们开发商能不能碰一碰。

对，法律法规标准这些。而且我觉得一个安全的评估到底依照哪些安全规范标准，这件事儿也非常重要。就是你是不是可以把国家要求的这样一些内容给准确的照顾回来，然后并且实时更新对吧？我估计像国标有很多报告也要随时要去更新的，或者每年都有新的版本。那怎么跟旧版本相区别开？这些也是一个很很很有很有意义的工作。

是否可以工作邮件喂给三哥？当然然后有人帮我以后的我的模式处理工作。对，但是如果如果你的工作大模型都可以帮你干了，那可能这个工作好像也不是那么有意思是吧？对，那就看吧。如果你你的工作邮件是内容是有很多这种推理分析的部分的话，那当然我觉得也挺好。你可以把它当做一个思考过程。COT这种东西放到second one这样，second me这样的项目里面去训，当然如果是一个就是特别标志式的回答，那我觉得你把风格迁移一下，让他好像跟你一样的说话的风格就行了，也不需要太太特殊处理。如果这种东西能够满足这个给你发邮件的人需求的话，稍微基础点问题。

现在这一代大模型跟之前的bert有什么区别的？这个太基础。对，就是bert这一代的模型其实现在也还在，那现在的大模型我们叫生成税，或者叫这个对大模型这台东西的这个我觉得从技术上其实就没什么必要太太详细说了。

这个我觉得就直接问这个BC什么就OK了。但我觉得最关键的一点是，bert这类的模型大多是判别式的，用来做分类为主，当然也有做一些更复杂一点东西。但是还是主要还是以分类为主。就直到现在你要做分类的话，你还是拿bert去跟GPT这类的模型去比，还是要比一比的，因为还真没准bert会更好。所以但是大模型这一代的它的差别就是它能干几乎所有的事，它是一个生成式的那它你可以有非常强的指令遵循能力，你可以让他干各种事儿，所以这个是他跟bert最大的一个区别。

我觉得主要从场景上来去说，技术上其实一个是encoder only的，也是decoder only的。本质上，其实之前有一篇我记得在知乎上看过一篇文章，就是说为什么decoder only的，就是GPT这种一定要用decoder动力这样一个结构。但是其实结论并没有太明确的，就是说一定得是这块的东西才最牛。只是说现在大家汤各种的路发现decode only的最后生成出来的模型，这样训练出来模型确实好一些。我想问能不能接入零这种记忆外挂？能，对，其实我想问能不能进入。

这就是刚才说的小智的。

那个VI的那个OK肯定可以。那您这种是有你如果自己搭也可以，因为它是个开源的。然后如果你用他的云服务也可以，你看他的云服务。好也不贵。他直接有接口，我们正好看看这种。

我操好贵。

没事儿，大家就用hoby这个免费版就足够了。对，然后这个一万条memory，你到底有多少回忆要记，然后每个月还真不多，1000次retry vel其实还好，所以大家可以自己搭一下也还好。我当时看曼联这些项目的时候，其实有一批这种做memory的，应该在去年年底左右，然后还算是跑出来的。然后这种项目其实最好的一个归宿，就是被大模型公司给收掉，或者加入大模型公司是比较好的。

然后我刚才说的质朴的语音进入云出能识别方言吗？说实话能预设结构化输入，预设结构化现在还不行，但是方言可一定程度上可以，你可以直接试一下至本清妍的那个打电话的功能，就它背后对应的就是这个东西，就是来看看这个是不清楚，然后点点右上角那个小电话，点那个他就可以开始打电话，然后你就可以跟他聊一聊，然后用方言试试。我也不知道到底这个方言能不能识别，主要是我不会说两段太长，我去这就是。

刚才化工。

的那个太厉害。我觉得这个是一个好case，我们可以把它当做一个60去重点支持这个用户，我们拿去支持一下。第一个问题，token和我们日常理解的与词语间的关系和两者数量的比例关系。日常理解的与词语关系比例关系。比如我看看。我们直接看一下token neither，然后有一些playground。大家对token是个啥玩意儿有个主观理解。你看这就是所谓的token either。Token either就是把你的一段话变成token的这样的一个工具，然后我们就把这段话扔进去呗。你看他token nize完了以后的每一个token是这个样子东西。

Open OpenAI它拆成了open和AI司拆成了一个token。空格加large是一个token，然后空格加language是一个token，你看基本大部分的词还是被当做一个token来对待的。但是像这种特殊的有特殊语义的这样的一个词有可能被拆开，然后有一些，现在token都已经很很那个啥了，你可以看看不同的版本，好像还不太一，这个没有什么太大差别。

我必须得是中文。

中文那就是找一个这个。

你的open a是直播间。

对，三是不是这样？那个四那个3.5可以看这个4。对，你看整个to中文token就不要这个不太一样，比如说欢迎它是一个token，然后质和浦是两个token，然后大家注意经常会有这个空格加一个后面的词。对，和这个不空格其实是两个token。大家可以想想为啥，主要是在英文里面，因为里面词之间都有这个空格。所以这个如果是一个组合词跟一个单名词，它的最大差别其实就是我前面是不带一个空格。然后你看这种甚至有些标点符号跟后面字也能拼成一个token，所以这个就是我们常常说这个跟日常词语之间的关系。数量还真不好说，我看看能不能找到。GP4o tonier dictionary，你看看他词典到底有多大呗。

怎么了？对，这个我事后再找找吧，然后下次可以说。但是大家大概能理解说中文的这种token nizar的差别了。就是中文的token化的这个东西，并不是像这个普通的人话里面就中文的人话里面那样来去拆这个词。

为什么越来越多的大厂下场自己搞asic呢？对，就是你卷不动模型卷不动，或者说卷拉不开差距的时候，那我只能去干嘛呢？在预训练阶段去降低成本，在推理阶段降低成本。大家可以想想我在预算部分降低成本的价值更大，还是在推理阶段降低成本的价值越大呢？如果你的用户量比较大的话，那肯定是后者。就是我在推理阶段去把这个推理成本降下来。因为我本来比如说我每天就有个几千万用户，那我肯定降下来一点，就很多钱了。

所以怎么降下来呢？因为预训练相对来说动态变化的还是比较多的，我不知道以后会不会有很大的变化。但是推理的时候，有很多东西相对来说比较固定的，所以可以去做所谓的asic化的这样的芯片。所以A这块大家就可以理解成是我不做通用的计算了，我这个片子就只用来去做这一类计算。比如说我这个片子就用来算Y等于AX加B然后我都不指望着什么AX加加这个AX方加BX加C我就只算这1元1次方程，那我肯定能把整个工号或者把这个效率提的非常高。

基于第一个问题，如何去推广一个大厂需要的推如何去推算一个大厂所需要的推理算力呢？我靠这是一个好问题，这我还真没仔细想过。一个最基础的算法，其实你就看这个MAU，比如说像豆包，我记得有一次给大家看了这个，就是HUZ公布的top 100的GAI，而且是2025年新款的。你看豆包到了第十名，你就想想豆包的DAU。看看，现在就回到这儿。豆包，然后DAU到24年底2000万。好，我们就拿2000万来计算，然后2000万，我们直接让deep sig算呗。

假设一款大模型应用的DAU是2000万，然后假设每人。每天问十个问题，帮我估算一下这款大模型应用需要多少。比如说A100显卡，我们看了第一次给他搞这个。

这个同学他肯定会做很多准备，做这方面的创业。我在看这个一路的问题都是在算这个算力的这些设备要多少设备多少钱？

对，如果是做info专业的话，那肯定这个就需要算的很细了。所以你可以看看像轨迹流动确实做的还挺不错的，轨迹流动也有时候会发一些文章出来，对尤其是他的推理部分优化做的挺好的。大家其实刚才这个问题你就看这儿，就是假设一天有多少个token，然后问十次每次要多少个token，然后转换成对应的这个A100这个TPS，然后看看到底是能算成什么。假设不先不按照这个它的峰值什么的先不去估，我们就把它平摊。假设这2000万人就是一个平均的使用市场，然后得到一个卡数。但是你肯定是有有一个峰值的那你这个峰值的这个batch最高能到，假设一张卡能到20或者25，然后再做一个估算就差不太多了。所以有时候是类似于说一个query，你如果一下到这么低调的一个算法的话，还是挺难算的。所以有时候会按照说某一个模型的一个query要几个某GPU卡秒来去这样来去算，会更更清楚一点。

我这一直说不用过多关注细节，但是我们对于非专业人士有什么特别推比较推荐的项目，有助于我们加深AI基础技术的理解，加快AI应用时间有限。对这块其实就是说你关注的细节，其实反而是不会有不会不太容易加快的这样的一个落地的速度的。首先我觉得明确你要做哪些东西，你如果就是为了做个比如知识库，那直接上底饭去打就好了。如果是你要做个什么APP，或者所谓的跟之前说的web coding这样一想想做个小东西的话，比如像这个define这种东西，你就直接搭就好了。

这个不好，换一个例子，换一个。assistant。比如说你要做一个智库的这个东西，你就选一个，比如check Peter这么一个模板，然后你就去里面去搭就可以了。他为什么要这？这个模板是有些bug的。我是不是记得有一次给大家讲过这个bug它其实要改一下这个就好。然后你就可以直接在这边提交一个上传一个PDF就可以去聊了。

然后如果你不想做的这么细的话，你也可以直接去用这个现成的这样的一些应用。比如像智库，或者像这个豆瓣什么的，其实都有这个所谓的生成智能体的这样一个功能。比如在这个智能体中心直接创建一个智能体就行了。你直接说我要做一个什么历史老师。然后它就自动帮你去编写这些东西。然后你下面要做的就是你把你自己的关键的这些文档扔上去，然后不断的调右边，看你回答的东西怎么样。比如这个历史老师，然后核心要在这儿配一个知识库，你把这些乱七八糟东西都加进去，然后也可以上传一个URL过去。有一个，怎么微信都没了。我记得有一个可以授权你的微信公众号一个功能哟，找不到。

刚才问题是啥来着，加快这个应用？所以就是我觉得首先明确你要干啥事儿，最好快速的找一个你做这个东西就能有用户，就能玩起来，就能有反馈的这么一个事儿。然后比如说这个到时候我们再再随时讨论，你说你想做个啥，然后我来跟你稍微分析一下，说你可以用哪个工具更合适。没有一个标准的工具，但是我觉得我的建议是尽量用高级工具，尽量高级工具不要纠结在那些，比如说有人跟你说写long time OK，有人跟你说什么搭个扣子好，这些东西其实已经像cos这种已经算比较底层的工具了。就是在这个年头，然后像这个long check什么的就更底层了。所以我觉得如果想做东西的话，真的没必要去纠结。那这个东西我先去找一个合适的工具把它搓出来。

智谱的服务器用的啥牌子？这个不能说有没有关于体育训练的AI应用体育训练你去找找还记得从哪儿找吗？This is for that, this would体育训练，然后英文是啥呢？这个是好像也不太对。你看他能挑出啥？这不是有吗？

这个trainer加这个看起来就是这个是啥？我靠意大利的算了，美国的，这两个应该都是什么boat boat什么的，乱七八糟的。这些trainer家把什么good to one二三年的，可能有点老了。对，在这儿也可以找一些。

卡路里不是Kelly brix you，这是个硬件。对，挺多的。G2.5 pro对哪个行业影响最大呢？我觉得现在对于cloud是个是个影响，就是cloud还是有点贵。然后gym是有google是有办法去把价格降下来的，而且它还能达到好像cloud这种级别的编码能力的话，我觉得这个是一个挺大的影响。当然除此之外的话，我相信google的gm a的APP还是不太起来。它的这个APP这个东西的月活我觉得还是很有限的，不太会有很大的一个大的变化。因为用gina的人和用chat BT的人和用cloud的人，相对来说还是比较有自己的偏好的领域的，所以我覺得不太会有大影响。

我觉得肯定很大的影响就是对别的模型厂商了。这个2.5 pro已经把这个战场拉高到这个程度了，对吧？动辄加个50分，这种arena的这谁谁受得了。然后据说他们的三这个gm 3好像是迅崩过，所以据说是一个巨大的模型，这个万亿级别的这种模型。但是不知道，所以这个2.5 pro我觉得是肯定对现在现有的这样的一些模型厂商是很卷的非常厉害的。但对于行业来说，我觉得影响没有那么大。

这个可能最大的行业就是影响比较大的是那个画图。就是你想用me journey或者用coffee UI这些的这个公司可能有一些特别简单的比较简单的活用gm 2.5的这些或者gym 2这些模型，或者open x40就可以搞定了。对，差不多。

没有理解到second me这种产品的核心点是什么？核心点对就是second me这种东西。我给大家share的分享的原因是。

是教大家怎么看这种产品，并不是说它的核心点有多硬。但是我觉得一个值得学习是什么？就是他怎么把这个故事给说说的比较圆。你看他的写了几篇文章，你看这个一个是在AI中保留自我的火种，这个词儿就很对，就是很很很情绪化的这样描述。他说IGI只是到来时间问题，然后我们都应该不能甘心的只作为无用阶级，要把我们自己保留下来这样一个东西。然后那自然而然你会想说那他到底在这查查会需要你保留下来，对吧？我AGI来了会面所有人类吗？大概率不会。

所以这个事儿不是一个说尤其是这种产品，它就不是一个冲着实际的现存的大众应用场景来去做的东西。他本来就是一个打小众，打情绪市场的这样的一个东西。比如说元宇宙，你这你炒的那么火，其实也没有什么实际场景。但是你你你也不排除有一波用户是比较愿意持续用这类产品的点。

你说这个实际场景，我只能说很在乎隐私的这帮人我怎么能做一个我自己的A证，让他能够在不暴露我数据情况下，跟外部的所有的A证，跟外部的系统去沟通互动。然后假设我走了，然后我可以留块一这个SSD的硬盘，谁再捡到这块硬盘，插到电脑上就能把我的A的复活。老师有没有考虑买一个AR眼镜？X6。对，这个事儿我我我是不是有一节课说过，就是大家不要现在买眼镜。说没说过吧？

我说过吗？当然没有问题了，没有啊不要现在买眼镜。这个为啥呢？就是因为去年底发期货的那波眼镜，大概率会是啥呢？是在67 8月份发新的，发发发出。他的这个是真正发货，现在你能买到的眼镜AR眼镜大部分都是去年的款，是去年年中年初的款。然后现在这些厂商都在搞搞生产，搞供应链，然后让他能准时的在67 8月份发货，所以基本上在Q3。那你现在如果买到的眼镜都是去年的那就没必要。所以我肯定想买，但是我肯定想买的是下一代的ARAR眼镜。

那个眼镜的基本分几类，一种是一体式的，这个玩意儿是可以独立用的。然后那它问题很明显，就是功耗的问题，这个续航的问题。一种就是分体式的，有一个外挂的充电宝似的玩意儿，就跟vision pro似的。那当然可能性能会好很多，但是对就是它它适用场景不是个日常戴那玩意儿。所以我觉得下一代的，如果大家如果现在想买一个玩意儿，在想买这个眼镜，在飞机上，在高铁上看电影，那没问题，大家就买现成的。现有的也OK，像over two x real rocket其实都OK。但是如果想买下一代的，就是日常能戴的眼镜，现在千万别买，现在没有好的。当然如果你你很有钱，你可以买这款even reality伊文的G8，这款算是个挺不错的软件。

这没没有讲过吗？没讲过吗？东西你记得吗？

没有，我没见过这眼镜。

OK这个眼镜是叫even reality，你看它是个单色显示眼镜，然后体验很好。我戴过一次，然后体验好的点在于哪儿呢？你看它是一个很薄的且正儿八经是个眼镜的玩意儿。你看它的边缘，这条边并不粗，挺细的。然后你看整个好像三十多克，非常轻。

然后配了二十多克了，对吧？

对，它它配上在配重在尾巴上也挺舒服的。这款是一个国内团队做的，国内的创始人做的，但是专门出海的，所以他卖六百多。

六百刀起。

而且还不一定买得到期货，基本上可能得等两三周。代购的话，所以如果现在想买，想日常戴那种眼镜，我觉得现在只有这一款推荐，其他的都建议等一等。没有相关资料，有啊，是。明白哪里可以创建虚拟人，现在我觉得比较好的还是黑镇这个。这个产品。

对，然后你可以在里面去挑各种虚拟人的模板，然后你给他定义他说啥话，然后他就能驱动整个这个头去动来动去，嘴巴动来动去，给你把它说出来，然后真实度还挺高的，所以基本上你现在要做出海的数字人的话看这个。然后如果是国内的话，字节的有一个还是挺不错的对，这是叫什么来着？字节虚拟人负责人。

他有一个开源的澳门human，好像还没发，我记得是非常牛。然后他的商用的这个产品叫是这个火山的对奥秘，后面是还没发，我看一下这个肯定太远了。如果说论效果的话，women human确实挺牛逼的。开内测，这卡兹克有内存，那不代表大家能用上。

对，就这个这个是国产的everybody。

And I wouldn't have .

been there. How do this again? Are we on the same thing? 对，可以看到这个效果是真的非常棒，所以打开试试。

这是图video吗？你看有有效果吗？怎么把我多年积累的印象笔记扔给智能体，让他训练成果。一个是然后帮我调优补缺。所以这个印象笔记的很大一个问题，你应该用的是国内的。

那个那个印象笔记不是那个ever know，对吧？然后印象笔记我觉得很关键的是你得找到他导出所有内容的那个那个功能。我觉得ever note是有一个标准的，会可以导出的。然后当然有开玩笑，你像这种批量导出MM，但是印象笔记我的印象中其实他对数据导出是特别不好的，就是不友好的。它有很多API的上限制，导致我有一段时间想把我印象笔记的数据导到notion里面，都卡的非常死，所以这个点就是你先得把它找出来导出来，然后导出来的格式最好是mark down。然后我不知道现在这个印象笔，我好像好久不用印象笔了，你最好把它搞成markdown，然后markdown是带着图片的那种，一定要带着图片，然后再去扔给你整体。

那怎么扔？其实最简单的方式就刚才演示了，你随便找一个产品的那个所谓的智能体，然后对gamma的一个智能体叫做jam宝石，这个特别格的一个词儿，然后还有个jam manager，你可以建一个自己的站，然后你就给他明白这个数字的，我然后查写点东西，然后再你可以选一大堆文件扔进去，这些文件你可以从对吧？你可以本地去扔，然后你也可以从他们这里去扔，然后就变成了一个数字定义，然后你就可以去聊了。

Suck me个人语料库，感觉微信上的对，所以有一些which x pro微信数据的导出工具是非常重要的。比如像你就搜什么WeChat expert，你就能找到一大堆这种东西。但是你要注意看一下这最后一次提交，几年前的这种肯定就失效了，七年前、四年前什么的就早就失效了。得找一些比较新的，比如说至少一年以内更新过的，

还可能能用。所以就是找到这类的应用，然后把它导出出来。导出出来以后，你就可以把它扔进去了。这种微信的很厉害，所以这种工具时不时会变。这个大家可以自己去找。

一中心向外是比较严格的。

这种特别严。对，然后。这个是啥？We check messages, 这个可能这啥时候，不过这个是一个特别大的点，就是我觉得咱们大家的微信记录本质上都是咱们自己的。但是他为啥不让导出呢？就是他应该给我对吧？那只是说这个哎两个月前的。

这不错，也不错。

感觉大家可以有有兴趣可以去试试，这是有兴趣试试。我艾特错了，不好意思。然后雷鹏跟meta合作的很像g one吗？G one还真不是g one的样子，跟日本那个差别挺大的，我觉得比ribbon那个好。

对，那个主要还是在摄像的功能上。

对，而且有点过时了。他而且他是个本来是个太阳镜，它是个墨镜。

你看它很重，而且它非常的重。我试过。

对我我有一个大家如果有感兴可以去看看。然后你看g one，它是个真实好的眼镜，日常佩戴眼镜这东西谁愿意日常佩戴，你不去party，不去海边，谁带这东西？正常的带这种，但是他的不好是他没有摄像头。因为它这两端这两个鼓起来都是光机，它已经占满空间了，它没有地方再放摄像头了。所以我就说大家等下一代，再等一个季度。我觉得如果忍得住的话。

公司以前有个项目是拿贝特做的，就是给人推荐职位的这种项目，要不要让大模型重构其他产品。对，就是我觉得如果你现在用word做这个东西的效果足够好了，你千万不要换，没必要换。当然怎么叫足够好，你的这个bench肯定是要相对来说更这个权衡一下。然后推荐职位，我不知道你们公司是不是像类似于大平台那种什么boss直聘这种。如果是的话，那还是推荐你用大模型来去做做一遍。不一定要重构，至少你可以拿全套大模型来去做一遍。这样的一个场景，我觉得是非常有潜在的潜这扩展潜力的。

因为需求不是只是推荐一个做一个分类推荐职位，而是肯定有更深的这个需求的。比如说我根据你的工作的历史来去做一个你的职业规划，然后根据你的之前的工作经历来给你推荐一下你的什么。比如考什么证，学什么东西，这些东西其实我觉得远比bert做个分类有价值。那这个怎么能做到？肯定不是bert模型才能做到的。好，今天正好十点整，大家有没有什么问题的话，今天就到这儿了。

行，感谢大家还在持续学习，我们说这个持续学习也是一种能力。然后今天让我比较惊喜的是就是刚才那位同学发出来了具体的场景了。我记得咱们往前的时候经常问的问题是，我是一个化工行业的，怎么用让大模型让我们降本增效，这是非常难以直接回答的问题。你看是今天这个同学明显已经把这个场景描述的很细了。我觉得既然你对这个场景，对AI是觉得有可能帮助的，我们就是往下探讨的可能性就有了。不然那种宽宽很宽泛，没有常见的问题，真的是很难回答。OK行，所以我觉得大家还是要持续学习，还是有作用。大家如果没有什么其他问题，咱们再给小平老师鼓个掌。今天感谢小平老师。别人夹着个鼻子，带着鼻炎声音。

这样OK好，行，谢谢大家。

好，大家再见。

拜拜拜拜。