

是网还是怎么着？Hello，大家好，今天难得是一个周六的晚上，平时我们都周四也半个月没跟大家见面了。今天北京的朋友，包括北方的朋友，可能都在感受大风。有有，今儿出门被风吹走的，100斤以下的，有的在那个弹幕里跟我说说，挺有意思的。今天这个风口就跟咱们这个线上的这个AI的风口一样，这个大风不仅能让东西飞上天，可能也能让人感到焦虑。

昨天北京至少是昨天就开始通知这个学校，小学什么都停课了。都今天叫地铁也停了，是什么都停了，加油站也停了，都不让大家要出门了，都是吧？还行，这会儿刚好风也停了，今天我我在车里，小平我看也好像在车里。我来了，半个月来了。对，没事，半个月没跟他见了。可能这个AHN也还是有一些新的消息在。今天我们让小平老师继续跟我们分享。行，那今天小明开始，那能。

能能好好，对，分享了一下屏幕。

谢谢。

好，开始。

Hello好，能看到了吧？好好，大家好。不好意思，周四有些事情，然后就耽误了一下，耽误两天，然后今天周六给大家补一下。对，这两这这两周其实很多东西，但是我其实没太准备那些就是很很常规那些爱谁出什么新模型这些东西这些反正这两周我看的没有什么太多的新的形态的东西，所以就没有准备这部分东西。然后给大家准备几个，开始从这个应用，这期主要会讲的是可解释性，就是大模型的可解释性这部分。然后完了如果有时间再给大家带一些所谓的UI的未来的交互界面的这样一部分。最后有一个两个有意思的文章。

然后前面的应用那部分可不是不是打广告，是支付最近发了一个叫这个沉思的模型的这么个东西，给借借这个东西给大家看一下，到底什么是模型去来去工作，到底是什么样的一个机制。因为之前给大家讲过这个minus什么之类的这些或者像MMGX这些这agent平台，或者这种所谓的general的agent平台，他到底是怎么去做的，然后到底他干了什么事儿。然后这次就借这个质谱，这次正好发了这样的一个叫auto GM这么一个模型。然后给大家去讲讲说到底这样一个模型它是怎么工作的。我直接之前写了一个pro我把它扔进去。这个是什么呢？这个是智谱清言的一个桌面版，就是在mac上。Peace there也有，然后他会干什么呢？就直接你看这叫沉思，这个就具体名叫啥意思，就不用在乎了，直接让他去问。

然后你看到整个过程其实还是挺普通的，就是前面的过程还挺普通。你看那个他会思考，然后思考完了以后，还记得很早的时候给大家讲这个密塔，什么溪流，溪流AI这样的一些所谓的deep search这样的，或者像open l那个deep research这类的模型。它很重要的一个点就在于说他要定个plan，对吧？它也是一样订plan，然后去搜东西，然后又去搜东西，然后再做总结再去搜东西，然后直到什么时候看看它有没有出来。我这个问题是啊我这个问题是过去十天有没有跟美国的这个关税制裁和人工智能板块相关的公告。然后我特别想关注A股的上市公司的公告，如果里面有提到什么算法深度学习，整理一下，做一个摘要报告给我。

为什么它蹦出一个浏览器呢？他到了搜了一段时间以后，你看他捋出来一个什么十几个人工智能概念股。好，然后他就会开始干嘛？开始去找打开网页去干活了。你看他打开的网页是这个东西，这个网这个浏览器就是我的浏览器，是不是在一个沙盒里运转的。所以说白了他要去访问什么网站，是只要我有权限，他都能直接登上去。但是他你看他有一个特殊的，会在这个边缘会有一个蓝色的闪光的这么一个边儿，让你知道说这个东西现在是agent来控制的。你看他左下角这边就告诉你说在打开网页，然后点查询，然后任务结束了，他发现现在这个范围内没有找到巨潮什么信息，关于这个公告的查询的这样一些以及然后我们会回来，待会儿他会继续去干，大概就这个意思。

所以大家可以看到这种所谓的新的这种水沉思模型，它具体模型是啥？或者有模型上有什么新能力不那么重要。核心是大家看到的最大的跟minus那种A镇最大差别，其实就是我直接这个agent用的浏览器，就是我的浏览器，你看这里面浏览器其实插件什么的全都是OK。

小鹏那边是卡了是吗？

对，小平老师卡住了那个画面。

大家可能稍等一下，因为咱们小平老师其实是家里人OKOKOK好。

你能看到吗？不好意思意思，我的网怎么，我在开车。那我现在桌面还在共享吗？

对对对，京东现在是。

OKOK, 那我刚才讲哪儿了，讲讲哪儿我就断了。你还记得吗？

那讲到就是还在那个操作A正在操作你的浏览器。

刚才那就要打开这个浏览器是吧？对对对，看到是吧？OKOK, 行，对，大概这个意思。其实最大差别其实就是他操作流量本期是我自己的。所以说白了我现在打开京东，我打开淘宝什么的，它是可以直接登录的。因为我自己浏览器里本身就已经登录上了，所以他就可以干这个事儿。

那这东西最大的差别能有什么呢？大家想想，如果我传统的deep research或者deep search这种我就直接搜网页了，和我有一个用户自己登录信息的这样浏览器有啥差别？这个大家可以快速想一下，其实比较明显的就是这一类。比如说还在干活，那我们先停，我们看一下做一个新的。比如说帮我找一个对颈椎。有好的。枕头，帮我在京东，价格在1000元以内。

对，而且京东如果他在一个叫什么匿名浏览器或者不再登录的情况下，其实有一个很大的问题就是你看价格是会受限制的。对你比如看这种，就你看到的这个，如果是没有登录情况下，当然在外面这些首页它会有。但是你一旦登录进来或者你去搜索的话，它的价格全都是这种德性，就是会隐藏一些。当然这个很正常，因为他为了去规避，你去爬他。那你你你如果是有一个电商去爬了一遍京东，所有价格其实肯定会影响到他，但是我靠，我的网又不行了吗？能听到吗？东丽你能听到吗？

可以的，可以。

那我这只是显示不行。好，所以这个最大的差别其实就是就是它其实能够操作的浏览器。这样的话就能看到各种。你看比如说点到这个京东网页里去，应该就开始去搜枕头了。他干嘛整的？行，我就大概演示一下这个意思。所以可以想象到下一代的agent或者是类似于像LGM这样的A镇。

下一代很重要的一个点就是什么呢？就是用户身份的传递，就是我们不光是能干活的这个页面一定得是以用户的身份能够访问的那这件事怎么实现？其实大家可以想象，如果是本地电脑还好说，就是我的电脑装一个A镇，像一个智慧青年这样的A镇能干活。但是如果是比如说你的手机，然后你的手机如果让他让一个AA托管

来去控制你所说所有手机的话，一个问题一权限问题或者是一个数据敏感性问题是一回事儿。但是另一回事就是你如果让他干这活的时候，你的这个手机是不能息屏的，是不能关屏幕的。这个之前也跟大家聊过，那可能会有一个大明确的方向。就是如果我们有另外一个可以一直在线一直开着的屏幕，能够用像这种A证来操作，那可能就是一个下一代的大家可以想象到一个比较好的地儿，比较好的一个交互形式。

好，然后第二个产品就是open I的这个chat BT。Chat BT有一个新的功能，我把这边停掉。Chap t有一个新的功能是这个东西叫它的memory，有一个特别大的更新它的记忆，然后。对，就是chat PT你去问任何的東西的时候，其实是可以去有一定的记忆在里面的。我不知道上节课有没有给大家讲过，像之前有没有讲过像mam O这个产品。东林你记得吗？我们我没有说过这个产品吗？Mam O.

好像没有，好像没有。

曼名是啥意思呢？就是大家肯定从第一节开始，就有有同学说是不是我们可以做一个自我的复制，自我的替身，然后让代替我去聊天，什么乱七八糟这些东西。这里面核心的一个最重要的能力就是他得知道我的偏好，他得知道我到底干啥了。

或者我以前的，说过说过，那这个说过。

对，那名那chat BT是干啥？Chat b怎么实现这个东西呢？就在这儿右边有一个setting，然后你到setting里面设置里面有一个个性化，这个里面有一个这memory memory，然后这个memory里面有一个第一条叫reference saved。这个memory就是参考保留的这些记忆，然后让又TPT去保存或者使用的记忆，当响应的时候，然后第二个它最近增新增了一个功能，叫参考你之前的聊天记录。就你之前所有聊的内容，他都可以直接就参考你给你回复了，然后这个带来一个大的问题是什么呢？我看。Visionary profile. 这对带来一个问题是你可以直接问chat BT这个问题了，描述一下我自己基于我之前的我们之前所有的聊天内容，然后让这个最后加了个make checking。Checking就是cati，就是朗朗上口，就是好容易记住，这样的一个东西，比较有趣。

然后我就让他翻译成中文了，大家可以看看，你是一个站在AI教育企业交汇点的什么什么vision创缔造者，乱七八糟这些东西。然后你一般晚上白天你们设计什么，晚上你还在什么打造培训帝国，乱七八糟的。然后简单说你就是一个战略顾问，AI工程吉普利粉丝，然后决定训练这个世界。好乱七八糟这些东西，这些内容其实都是哪儿来呢？就是我之前跟他聊的所有内容，尤其是近期我跟他聊的各种内容，说白了就是我让他干的活，让他干了写写的文章。然后还记得吉普利，我记得上次上次介绍4O的时候，搜的那个新版本的时候，可以随便改图的。那个时候就拿它来去试了一下吉普利的这几个效果，然后他就会都寄到都继承我这样一个东西，就是基于我们之前的聊天来去描述一下我。

大家感觉有一个什么大的差别没有？就是一旦我们之前一直在想的是，有一家企业如果贼懂我，那比如说百度，对吧？以前的百度，什么搜索都在上面，或者是后来的淘宝，什么买什么东西都在上面。

京东，然后再往后有不同的产品，豆包，什么抖音这些都很懂我那他能够？当我我做一个非常好的助力。现在chat BT这种产品出来以后，基于之前所有的聊天内容，如果你能够非常好的把这些记忆从里面提取出来，那几乎就可以去干任何的事情了。所以这个想象空间很大。

但是大家一想就会感觉到有一个很大的问题。这个东数据或者这个隐私其实是一个很大的一个影响。然后这件事情对于open I当时奥特曼前两天发的推就这么写的，说我们在chat PT里面有一个特别大的提升，提升啥呢？就是提升memory。他现在可以去参考你所有之前的对话了，然后特别特别牛，特别特别牛不说了。对，

然后这个就是它最新增加功能，就是能够参考以前所有的聊天记录。但这事儿为什么会他会做这个事儿，或者说为什么把他现在才提出来？大家想想对于chat PT做这个功能其实并不难，或者并不令人惊讶。

我觉得有一个点，就是这个东西jim l前一段时间推的一个也不是很近了，就前前一个月前，推理功能叫这个叫你选模型的时候，你可以选flash，可以选thinking什么这些东西，你可以选personalization，就是纯个性化，你一看就明白了，背上你所有之前的搜索历史，你google最全的数据就是你的搜索历史，那如果能基于搜索历史来去query来去问问题的话，那绝对是能有非常大的提升空间的那chat BT想想我有啥呢？那不就直接你所有聊天内容吗？那就可以聊了。对。

然后另外一个我觉得可以给大家推荐一个点，就是他的刚才看到这个setting里面有这么一个东西，有一个参考我之前所有记录的这个记忆，然后底下有一个叫可以管理器，你打开发现什么呢？好像是啊怎么好像是在找一个JD然后什么的。然后再往下看啊，这个正在对齐，就是做做云分析，他喜欢什么什么，然后用户希望了解大模型产业落地相关的笑话，然后这个偏好回答用中文。大量的这些东西其实就是我之前聊的内容中，他判断这是我的记忆的一部分，它自动就会记，那挺有意思的。

这个东西怎么用呢？有一种做法就是你其实可以完全手动的去做这事儿，你觉得哪些事要让他记住，就OK。比如这么说，我就直接问他可以这么做，就是你记住在我心中太阳是方形的。好，他就会恢复成这样。然后我可以继续去说，可以，太阳就叫做孤傲刚方星。然后你看他都会有一有一个这个东西叫updated saved更新保存的这样一个记忆。

然后是什么记忆？他会告诉你好，这个记住忘掉太阳是圆形的设定，然后他就忘掉了。好，这个时候我这样聊完了以后，我之后再起一个新的兑换，然后我就可以直接去问说太阳是什么形状的。

对，然后他就直接回答说，是当然是方形，而且他有个名字叫太阳挂号肛放心，什么乱七八糟的这些东西。对，为什么会有这个呢？就是因为我刚才说让他记住了，记进去了让大家也感觉到，我在这儿看到的memory里面是没有这一条的，没有这个什么太阳是方形的。这块我估计大概率这是chat BT的一个bug，就是你让他记住东西，其实没有并没有记住。那那还就是怎么用这个记忆这事儿的，我就再提一嘴，就是记住，后边你写东西行了，或者逗号什么都OK。比如说我们在要记住每棵树，假设我说每棵树都有一个灵魂，那这个灵魂叫比如叫tree transported这么个东西。对，他就开始记录了这些东西，然后你再去问说这个树有没有灵魂？

对，你看他其实这就会记住说你刚才说这个东西是什么记忆？就是说你刚才说了有一个translate的东西是每棵树的灵魂。好，这个时候他就会一直一直待在所有你跟他聊天内容之后了，怎么想删掉，怎么能删掉呢？其实就是在这儿去找到刚才那个记忆。你看这又出了个bug，没有出现在这。对，所以这个还是有bug，所以这个大家怎么用，或者说memory这种东西怎么去用，大家就记住。

但是这绝对是有一个问题的。比如说我刚刚点了那个memory的那个FAQ。肯定企业的同学会关注的就是这个数据会不会被泄露，或者说会不会被拿走去用。我们看看这，你直接看到这儿，他CK里面写了，你们会不会拿我的memory去训练呢？然后他的结论就是如果你打开了什么为所有人改进模型这个功能，那就有可能被聊天记录，会被拿去训练。然后默认如果你是企业的chat BT team用户，企业用户那会默认会不打开。

所以如果对于用大模型的这个企业来说，我觉得最核心的一点就是你去看看你用那家大模型，它的条款里面关于甬管是memory还是chat记录，历史有没有这条条款。如果没有的话，那最好是让这个大模型厂商澄清一下这件事情，到底你用不用？我也没有说一定用就不好，但是这个大家自己一定要用之前，或者这个上生产环境之前一定要用一下，要明确一下这个事儿。

好，我们下面就来到这个可解释性这个部分。这张图其实比较有意思，就是这是一篇文章里面说到底做可解释性这件事情的目标模型到底是什么样的。你可以看到基本从GBD3开始到4，之前几乎大家选的这个蓝色的，就这个浅蓝色的这个部分，是等于是研究可解释性的这些模型到底有哪些。然后黑色的是闭源模型，然后黄色的橙黄色的是开源模型的天花板，然后再这个GB40或者叫，其实很也就是40。之前几乎可解释性的模型文章没有什么研究大大尺寸模型的，几乎没有然后到最近这一年才开始比较批量的出现一批研究大个的模型的可解性这波的研究。所以可见其实这个方领域是一个还是很新的一个方向。

然后这事儿为什么我觉得想想讲这件事，就是因为我觉得对于有一波同学是有用的，或者说比较明确的是一个挺好的一个方向是什么呢？就是体制内同学就是体制内同学。我最近发现其实有不少的政府单位的同学，特别想学习大模型领域的知识，什么这些东西，操作这些，但这些确实太普遍了，大家都会做这事儿。

但是有两个方向我觉得是一个特别值得去，特别可能成为你独特竞争优势的地方。一个就是可解释性，一个就。就是对齐alignment模型对齐，价值观的结论到的一些东西。这两个方向其实都是跟一个特定主题非常相关的，就是模型监管或者模型的，其实就模型监管，这个至少我们了解我了解说在这个体制内同学在这两个方向有一定的了解的人非常少。但是你说你训练个模型，使用的模型什么，这些其实都很容易。市面上大家能找到这类的学习资料的，但是可解释性和对齐这些方面还是非常少的。所以我觉得这是一个特别好的方向。

这篇文章其实去年7月份，也就是半年前的一篇文章也不是非常的老。那里面的一些内容基本上他都把它引用到了我们现在能看到的一些科技性方面的研究。然后另外一个为什么我觉得这个事儿特别重要的一个点就是还记得这个人这个卡西，已经提了无数遍了。他上个月说发了一篇推指，是什么呢？就是我们25年之前大部分人的内容其实是为人类写的，或者是以人看东西为目标的这样一个内容。但是25年之后，基本上大部分内容都是为大模型写的。

大家可想一下这啥意思？就是现在要写东西，大概率大家是不是直接出个点子就让模型去写了。然后我看个东西也是直接，比如说我打开这个Monica，他给我直接分析一下，总结一下，这就OK了。所以现在的出来的内容就是比如这篇文章里内容大概率不是为以人的注意力为标准来去生成或者使用的，都是以大模型的注意力来去作为标准来去做的。所以他认为我们下以后所有的内容，大概率都是啊注意力的模式，都是应该以大模型的它本质上的这样一些方式来去来去面向这样的内容，这个注意力内容来去构建的。

所以为什么我们说要理解大模型，要去尝试了解它的可解性，尝试了解它的是不是怎么对齐的这样一个方式。就是因为我们的以后的大量内容，其实都是要靠大模型，以大模型为准来去做的。然后这个可解释性这个方面，我就今天讲这几个比较经典的一个例子。一个是很也不算很早了，二三年，这个算是在这个大模型的初期的一个研究内容，二三年5月份的一个研究内容。这是OKI的叫用大模型来去解释语言模型的神经这样的一个事儿。

然后第二篇文章是去年24年，google的一个模型叫jama，大家知道一定要记住，这几家大模型其实除了open I以外，其实大家的都有开源和闭源的两套模型。Google的开源模型就叫gamma，然后jama的去年的时候的版本出了一个新的功能叫scope，就显微镜这么个东西，也是一个在科技尔信做的一个比较大的一个成果。然后第三篇就是今年的anodic，这一篇文章叫做追踪大元模型的思考，这样思考轨迹这样的一篇文章是今年3月份的一篇文章。也是很新的一个东西。所以由此带来的一个新的词儿叫做AI biology。这个AI生物学这样的概念，也是很有意思一个方向。所以我今天以大概这三个比较历史级别的事儿，来去给大家说这个大概简单的讲一下这个可解性。

因为可解性这词儿要是大模型可解释性这词，如果这个事儿要讲讲的稍微透一点，几个小时打不住的。所以今天就给大家简单的过一下什么叫可解性，就是为什么要有大模型可解释性这件事儿。我先从这个事儿来说，就是我们上一代的去学习或者在其视觉这个领域其实具有科技而性，这个玩意儿这个领域叫做explainable artificial intelligence，可解释的人工智能这样一个领域的事儿。然后这个事儿，其实像这个deep cap或者像k go都有专门的一小节的课去讲这个东西。我觉得那些课大家上不上都OK，我觉得这个是可以给大家看一

下，就是机器视觉里面的可解性，其实还是具有可解性，尤其是机器视觉里面的比较早期的一些神经网络的这样一些模型。

比如举个例子是这个东西我现在要扔一张这个图，然后用一个什么东西，用一个filter去用一个类似于滤镜，去氯它。大家看各种美图秀秀什么的，这些都是滤镜，说白了都是滤镜，但是最基础的滤镜就是这些东西。你看这个如果通过一种滤镜可以滤成这个样子，也可以滤成这样，可以滤成这样，这些都是啥呢？说白了就可以理解成这样，就是这张图通过这么一个它叫科诺的玩意儿，这说白了就是一个矩阵。然后把这个矩阵放在这张图上的每一个点算一遍算一遍，每一个点都算一遍，然后它的输出结果就变成了这样或者这样或者这样的图。

那你看看这个第一个矩阵啥意思呢？-1-1正一正一，那大概率它识别的是什么呢？就是他乘那个图原来的那个值以后，得到的值就是我这个过滤完以后的这个图的这个样式，-1-1正一正一。可以想象就是我鼓励的或者我乘出来的更值更大的值是什么呢？都是上面跟下面是两个行不一样的结果，就是上面的好像都小一点，下面的都大一点。好，那我这时候的这种区域长出来的结果就更突出，那大概率是啥意思？人话意思就是我找的是横向的线，如果你看这个横向的线会在结果里面更突出纵向的线，不突出，纵向的线是不突出的，只有横向的部分相对来说更突出。那这样的就是所谓科成他出来结果。

那这个东西如果我们看着这个图去想象这样一个神经网络，他这样的AI他这个怎么解释呢？好像还也能解释，就是说这玩意儿是一个可对应那个神经网络，就是一个找横线的这么一个AI类似的可以看右边这个就是F1-2-0 01，那好像就是这样这样一个渐变就是从低到高的这样那个界面。那左边右边这个好像就是找这种角，这负二到正二，斜向斜向的线会更被突出出来。所以看识别过滤出来这个图，它会更具有这样的从斜向的这样一个特征，对吧？大概就这样意思。所以这就是上上一代，就是CV时代的时候。

那个时候大家说有些模型还是具有可解释性的，为什么呢？就是因为其实算法相对来说还简单一些，这个还能解释好。那到了大模型时代，我们说要看看在哪。对到了大模型时代，我们就要想说，这个大模型大家第一节课就给大家讲了，这是一个特别大的一个神经网络。这个特别大神经网络你很难去找到里面某些关键节点对应到的一些人类能听懂的这样一些解释，对吧？我这儿我就拿另外一个课的这个课件给大家简单过一下，这个是特别值得推荐。

如果大家想去稍微深一点点，学习深度这个大模型的话，可以看这个人的课。这是台湾的一个老师叫李宏毅，李宏毅这个人。不是这个演员，这个你搜台湾。搜深度学习，你就能搜到他的课，李宏毅老师这个课好，然后他的课里面就有一节专门是讲这个算是模型是怎么思考的。然后他当时分的比较细了，从一个到一层到一群，神经网络是怎么做的，这个具体的我就只讲前面几页还记得吧？我们第一次课第二次课就讲的说大模型是怎么工作呢？

就是他输来输进来一段话好，然后通过神经网络输出一个什么结果呢？输出一个所有当前的可能生成的token的概率分布，就这个词儿可能是0.91，那个词儿可能是0.86，再一个词儿可能是0.745，这样一个概率分布干嘛用呢？我找到最大概率那个值塞回我的输入里面再推下一次，所以就是这么一个东西。好，这个里面这个神经网络里面其实非常多层的，每一层几乎都是输入。通过一个一层得到第二层的输入，就是下一层的输入，说白了就是第一层的输出，就是第二层输入，然后又一层又一层，直到最后最后一层再把它反变回那段话，就变成了这样的一个结果了。整个大语言模型里面是分成非常多的这样一块的这样一个多层的网络了。然后当然还有一个所谓的自注意力机制，这个我们今天也不讲了，这个抽抽时间我们再去详细讲一下这个模型的这样一些底层原理。

可以想象里面的每一层就是这是一个输入N个token，输出N个token的这样一块。他干的是什么事儿呢？就是左边这张图我输入的N个token，说白了就是一个向量，一个矢量。一个矢量可能假设一个4096维的一个矢量，1 58.1什么这个76.5这样一个值。然后通过一个叫叫wait sun就是这个带权重的加权。然后加完了以

后，通过一个rel u的玩意儿生输出成输出的这个向量，我分别一个一个讲输入假设我们想象这是一个4096维度的，说白了就是4096个数。

什么叫加权和呢？就是比如说我第一个这个4096的第一个维度我乘个1.2，然后第二个维度乘个0.6，第三个维度乘个什么0.2，第四个维度乘个0.7，然后当然再加一个B。比如说这个乘个0.1.2加5，然后第二个要乘个0.9减三好，这个整个算完了以后，就得到了一个计算了加权和以后的一个向量。

走一个这个东西，它这个玩意儿叫激活函数。激活函数是个什么呢？最简单的一个基础函数，就看这个东西，叫re0的一个玩意儿，最简单就是右边这样，这啥意思呢？就是大家什么时候初中还是小学，学这个分段函数还记得不就是我一个函数可以是按照不同的区间来去取它的函数的这个函数内容，比如说这个函数是啥意思？就是我但凡这个X小于0，我的Y就只等于0。甭管你X的是多少，我最后的输出的Y都是0。然后右边就是但凡如果X大于0，那么Y就等于X比如你X等于5，那Y就等于5，X等于7那Y就等于7。说白了就是这样一个，我就卡住所有小于零的值，输出就等于0，这个大于零的所有的值输出就等于是输入的值这么个东西。

为什么要有这个东西呢？可以想回到前这个图，就是我们如果一个神经网络里面每一层往下走的时候，都是一个像这个带权重的加法。带权重加法就AX加B这么个东西。那我一层一层最后的结果是什么呢？就是比如AX加B然后再套一层就变成了这个A撇，AX加类似于加个B撇这样一个值，然后再往后叠一层，再往后叠一层，最后的输出的Y这还是一个问问题，还是一个某一个A一个常数乘以X加上一个常数BB撇撇这么个东西，那它的一个结果就是什么呢？X永远跟Y就是一个线性关系，它是不带有任何的非线性。这个带来的结果就是他学不到非线性的这样一些能力，也就学不到更多东西。

那我们这里想去让他有一些非线性，最直接的做法就是这么个东西给他上一个这个玩意儿它大于X也是线性的，小于X也是线性。好，那就X大于零和小于0，但是就在零这卡了一个非线性的一个函数，一个reu好，那最后输出结果它跟最开始的输入就不是线性的了。那我巨多的这样一个单元带到里面，带到这样一个神经网络里面，我就可以得到一个有非常多非线性能力的一个神经网络。

对，所以大家再想一想，你就不用把它想的那么神秘。这个玩意儿就是一个函数，一个巨大的网络就是一个函数。这个函数我们不想要一个特别线性的标准的函数，特别简单的函数。说白了就是我想要一个特别复杂的函数。这个复杂函数可以让我们学习到各种类型的信息，那我就要在里面加非线性的部分，加复杂的这个函数部分。这个东西激活函数就是一个里面标准的带来非线性的部分的这样一个能力的一个函数。

对好，那我们想可以想象，这玩意儿这个小点和这个小点，说白了就是一个小的神经网络，可以想象这个神经网络。好，那这个时候我们神经元对就跟人脑是一样的。那我们想假设我们现在想知道说这个神经元是干啥的，假设就这一个小球是干啥的这这小球其实现在就是一个值，那我们想知道这个值是干啥呢？那我们一个做法就是什么？就是我们想看看它跟什么事儿有关。假设我们看到这么一个神经元，这个神经元它就越大，最后模型输出的结果越是脏话说脏话对吧？假设这个值是5，他就开始说脏话了。假设这值。

这是五十，他说说的可脏了，巨脏。假设这个值是个-5，他说的可有礼貌了，就不是脏话。那我们可以认定他是个啥呢？就是这个神经元就是一个说脏话的神经元，这就是我们代表了如果没能找到这样一个规律，我们就能找到说这个神经元的可解释性。就是可以把它解释成这是叫说脏话的神经元。

那怎么去验证？其实也挺好验证的，就是我们把这个神经元给永远固定的输出0，那看这个模型还能不能说出脏话。如果不能了，那我们就可以认定说这个神经元起码跟说脏话这事儿是有一个相关性。且他去了以后再也说不了脏话了，好像还那就还真能确定这个神经元是决定了他能说脏话的这样的一个值的。



那很容易想象，肯定大概率就跟人一样，大概率不会有一个神经元去决定了某一个方向方面能力。比如说脏话这个能力肯定不是一个神经元决定的那很有可能就是一个神经元可能处理它对应多个能力，以及多个能力多个神经元对应一个方面能力。比如说脏话这事儿肯定就是多个神经元共同决定的。然后这里面这些就不讲了。

我觉得有一个有意思的是这个事儿叫川普神经元，这个研究是在21年做的，也就是这个对吧川普第一任的时期做的一个东西。而且这个研究并不是针对大语言模型，针对的是一种叫clip的模型。这clip模型大家可以简单理解，就是你扔一张图进去，他把这张图给你变成一段文，描述这个图的文字，就是看图说话的意思。Clip这个模型其实也非常重要，但是它不是一个纯语言到语言的模型这个东西。但是大家拿这个可以模型就可以做很多研究了，其中的一个就是川普模型。

看这张图，这个图的下面这个意思就是类似于这个越红的越厉害，代表某一个神经元它的激活强度越高。那给他看，比如看这些东西，这个叫叫什么来着，那个游戏，什么城堡，什么那个那个枪打枪然后给他看这个什么什么马丁路德金，然后给他看这个羊驼什么这些。他看这些图的时候，这个神经元几乎不激活，越往右，比如说右边直接给他看川普的头像，爆激活给他看川普，甚至看这个twitter，用他的那个发型，那只鸟用川普的发型标了一下哎也，激活的非常高。这个是川普的这个漫画版，然后给他看有川普文字的这个图像，甚至是彭斯也会激活。然后看这个图里面有有这个特朗普的也会激活，然后一些政治的maga这些也会激活，然后越往这边越不激活。

对，说白了就是在clip这种模型里面，这个研究证明了说找到了一种神经元，它就叫川普神经元。而且这个川普神经元特别在哪儿呢？他肯定想说，那有川普成员是不是有什么这普京神经元或者什么什么别的神经元？还真不是，就只有川普这个玩意儿是个神经元，是有这种特异性的。你扔一个川普当了trap进去，他的这个相关性特别高，激活度特别高。你扔个迈克彭斯，他的副总统，副总统就是他的激活度也很高。什么班农，然后克林顿也都是正向激活。你扔一些别的什么奥巴马、乔布斯什么，这些是没有任何影响，反正是有一些反向影响这样一些激活程度的对，所以真的就可以称这个神经元叫川普神经元了。

对，然后挺有意思的一个东西。就有另外的一些人，就比如说我看这里面没有然后有一些做医疗领域的人也会说很早的时候有一个叫什么心理学实验，就是说是不是有一个神经元是专门对应的。我的什么奶奶，还是什么，反正就是呃还是叫ant，反正就是对一个亲人的。对对对，奶奶好像是说是因为当时有一个有一个人他奶奶去世了。然后他一直忧思这个叫什么茶不思饭不想，然后都导致生活出问题了，大脑出问题了。

然后大家就开始，有人就做心就叫什么做了个心理学实验，就是假装做的实验，就是说好像有一个神经，如果有个神经元对应的是你奶奶的话，那你把那个神经元给割了，那你是不是就再也想不起奶奶或者甚至不记得他在长什么样了呢？他其实当时对应的是说，其实这种人类的记忆绝对是多个神经元来去代表一个记。所以这就说到了开始说到了这个大语言模型的可解释性，那对应到的第一篇文章这个东西，其实就开始说好，那我们怎么去研究一个大语言模型，对于是它里面的神经，婺源的这个怎么解释呢？他就做了几个例子，比如说这个就挺有意思，叫你他尝试去分析GPT2，拿GPT4去分析GPT2。因为GPDR相对来说一个比较小的模型，那拿GB4去他们肯定做了很多拿GB44就是分析GP3之类的一些模型的一些实验。但是最后证明可能要不算力不够，要不根本解释不出来，所以最后发了一个拿GP4来解释GBD2的这样一个神经元里面的能力的这样一个文章，那他就发现了一些别的，比如说发现了一些比较有意思的事儿。比如说他直接去发现了有一些神经元对应到的是对应到的这个能力或者这个特征，叫做漫威漫画风格。就比如说我直接把它翻转翻译回去，这个图是啥意思呢？

就是你让一个模型去看这段话，发现某些神经元每一个某一个神经元对于这段话里不同的字的激活效果，激活的那个值不一样，越绿代表它那个值越高，相关度越高。好，那可以看到有什么呢？The这就就不管了，就代词，然后artificial，然后什么最困难的挑战，然后这个super hero这些东西。好，那再到这边把它看回来。到这什么这个universe，然后这个boss Kevin什么这些东西，然后这些值越绿的部分，大概率你能看出他跟漫威宇宙风格或者漫威的漫画风格是有关的。因为你但是什么什么night wind的这些东西，其实都很多都是在漫



画里面才了解到什么magic space这些东西。所以他通过一些研究找到了一些神经元，它对应到的这叫做漫威漫画风格。

然后还有很多别的，比如说这个smiles，smiles是比喻的意思，也名誉，尤其是名誉的不是隐喻的部分。对，你可以看到他其实得到的结果就是这样一段话里面，你看like water mixed with，好像是什么跟水混在一起。然后这边小孩骑着自行车，好像是一个小孩骑自行车什么这些东西。然后像这儿好像是一个什么说不是是什么海盗什么这些东西好像一个波纹在池塘里有些东西这些你可以看到有一个对应到的这样的一个神经元，就可以成为这个神经元，叫做比喻神经元。

好，这是第一种这个做法就是直接把他要看到的東西对应到的这个神经元的激活的程度，来去拿这个东西来去分析这个神经元到底是干啥的那还能干嘛？还能怎么去分析呢？直接用GP4来说，假设你是个神经元，你会为这段话里的哪一个词激活，或者说你来去模拟一下你这个一个大圆模型会因为这段话里哪些词而激活。说白了就是让模型来去模拟一个模型来去激活的程度，来去告诉你说一个语言模型看到这玩意儿，假设你是以什么漫威或者一个比喻类的神经元的话，你会为这个话里的哪些词儿激活，也能得到这样的一个结果。

最后第三种方法就是比比一下真实的激活的效果，跟你拿一个大模型去仿真的这样一个激活的效果到底相似度有多高，最后就得到一个比分。如果这个分越高，代表了越确定的发现了一个大模型的激活的这类的神经元，就可解释的大模型的激活的这样一类神经元。我不知道我们说的可能有点绕口，但是大家可以感受一下。其实就是我们让模型让一个大块的大个的模型去来分析一个小个的模型，它到底是怎么工作的这样一件事儿。他最后有一些分析结果，比如说这个神经网络，它一层一层的从这个第一层到最后层。越前面的层分析的可能性就是可以有解释性的。

这个可能性越高越后面的层越低，为啥呢？因为大概率我们现在看到的的所有的大模型都是越偏前面的层分析的，是越表面的东西，越越浮在前面的东西。一些什么这个词儿是啥意思？比如这个apple，然后那个是个banana，越中间越偏语法，比如说什么主谓宾丁占卜，这些东西越偏厚越偏语义。比如说这个是一个要分析这玩意儿是不是一个国家，或者是国家首都是什么，它的语义到底什么？这种级别的神经元越偏后面，所以越可能解释的其实越偏前面，就是越越偏前面层越可能可以靠刚才那种方式能解释出来。

对，这就是第一篇GB4来解释这篇。然后第二篇就是这个jama scope，jm scope，这个就是刚刚说的google的一个开源模型。然后他做了一件什么事儿呢？就是他做了一个大家可以理解成是一个显微镜，我们直接看这个，他自己还做了一个叫显微镜的实验平台这么一个小网页。这个是每个人都可以看的，而且我觉得可以大家如果看懂英文或者拿这个沉浸式翻译一下的话，特别有意思的一个例子就是每一个都是真实的数据，可以跟着它来去走一下，知道能感觉到什么叫做可解释性。

比如说什么呢？我们就看着他把我们对于神经元或者对于神经网络的解释这件事儿更抽象了一层。我们不是看的是某一个神经元的能力，而是某一类的feature，某一类的功能。那这个模型本身有一类的功能对应到的，这类功能对应到的说我看到了一段话会不会激活某一类的功能。说白了就是很多神经元可能组成的是一个功能，到底怎么组成的？可能不那么容易知道，但是我们可以从通过功能方面来去理解这个模型的工作方式。

比如什么呢？我们拿一段话，就这一段话你知道一个叫菠萝对吧？是一个是什么的一个符号然后是一种什么什么的水果。好，那我们可以看到什么呢？

就是每一个词比如说do you know that每一个token它你把它选在上面，右边的这些就是它对应的跟这个词相关的激活的最高的这样一些feature。一些或者简单理解成是一堆神经元的组合。比如什么呢？比如说这个强调这个是一个用来强调条件或者相关的理由的这样的一个feature，它对应的是什么词呢？是that，我觉得that不太好，我们找一个display，看看有没有display。

激活的feature是什么呢？是一种term，它是跟显示一些属性或者一些属性在program在编程里面有关的这样的一个term。大概第一种词语，大家可以理解成displayed。如果是编程里面，很容易理解，它确实是显示一些东西出来。那我们就甚至可以看这个feature到底是个啥样的东西。你可以点开，你就看到说这个feature对应到这个词里面，每一个部分的这个词到底有多少，有多高的激活度，可以这么理解。

对，他就开始说，你现在可以找一个跟狗相关的一个一段话比如说这个我直接就说中文了。然后他为了让你去看，有怎么能够找到一段跟狗相关的，并且找到这段话相关的那个狗相关那个feature。比如说我说还是我们直接找一个模型来去生成一段，你找比如找直播说生成一段和一段这个叫什么香肠相关的描述。好，这一小段就够了，就把这段call过来。我之前没试过中文，可以试一下，看看能不能出来啊。

你卡住宣传稿的，他这一段相关的最高的，比如狗这东西最高的就是refers to狗，然后dog对吧？然后他就告诉你这个挑战完成了，然后你可以再看看别的词，犬我估计犬也是，犬在这儿对吧？不是狗的这个没有最高，是第三高。然后全种肯定也是。对，然后比如短小香肠狗。

不是一个token如果拿中英文的话，效果可能会更明显，因为英文它有很多这种组成一个词，大概就是这个意思。所以这个里面除了说你可以直接看到每一段话里面的这些，你的每一个token跟背后对应的激活的那个feature之间的关系以外，还能自己去玩，还能自己去看。你说这段话到底它对应到的一个背后模型激活了哪些feature，这样一个解释的过程。

然后第三个部分就是这个cloud刚发的一篇文章，叫tracing the sort of lush anguish model，就是跟踪一个大模型的全部次要过程这样一个事儿。这个文章就很辛辣，就是上个月刚出的东西。他想尝试去拿这篇文章来解释几个事儿。比如说好的他可以说很多种语言，那他所谓的心中的语言到底是什么呢？这肯定大家可能也会或多或少有个问题说，这个大元模型啥语言都会，那他说中文的时候是不是他心里其实想的是英文，对吧？就是可能大家会觉得我的模型的主权或者它核心的能力，它其实不是中文。那那我们是不是不可控或者怎么着的，他通过这样的研究想想是想去尝试找到这个背后的逻辑。

Cloud这个它是逐字输出的那它是不是只能够预测下一个词呢？这个他也是尝试他想去解释的问题，那个就是我们说大元模型很单纯，它只是预测下一个token的这样一个能力。但是就靠这个能力，他是不是只会预测下一个token，他不看不了几步以后的事儿？这个研究也在尝试证明说不是，他其实可以看得更远一些。并且第三个他想尝试解决的问题是啊这个模型是可以写出它的推理过程的对吧？大家知道这个推理模型其实都能干这个事儿，但是他的这个推理过程是不是跟他心里想，就是他输出的这个所谓thinking的这个过程，是不是跟他这个模型本身他心里想的是一个过程。这也挺有意思，是不是会有口是心非的情况，这个大家现在已经所以这三个问题大家看了就感觉确实能够配得上他说的这个事儿，就是这个AI的这个biology生物学，AI生物学已经初见雏形了。

我们开始去研究他的心理学，心理心理的这个生物学或者心理学，这方面的能力挺有意思的。然后他们从这个神经网络中汲取灵感，然后我们就直接往下看到一些具体例子，他这几个问题的答案，比如第一个它是如何实现不同语言都能回答呢？直接这他举了个例子，英文问的是the opposite of small is，就是小的反义词是什么？对吧？那我中文就是小的反义词是，然后法语就是什么什么不会念，然后他的反义词是什么？

好，他通过他的这项研究证明了什么呢？通过在feature层确实是不同的语言有不同的feature，但是他也发现了一个它叫共享的多元的feature库。有一个大区域，这个区域是所有语言共享，它是不区分任何一种语言的一些feature的那包括什么呢？比如说里面能找到一些小的这个概念，大的这个概念，这概念都不是跟语言相关的。然后还有什么呢？

And tony，就是这个反义词反义词这个东西的概念也在这个共享的多语言的feature特征里的这个区间里。所以说白了小的反义词是什么？The offset of small is它会通过语言特有的feature，它也会通过在概念上大家共有的这样的一些feature的空间，最后得出来所有的这些feature组合起来，得到了一个又跟语言有关，又跟公有逻辑相关的这样的一个输出的结果，large或者大或者grand，grand这应该是法语的grand这意思。对，所以意思就是这个至少证明了什么呢？小size的这个cloud模型，他证明了说我们的所有的大语言模型，主流大语言模型里面都有跟语言无关的一些大量的这些特征在里面。或者他的这个神经元在里面也有跟语言相关的。所以像这种问题或者说你直接问中文，他最后背后对应的思考过程肯定的是有大量的是非，你问的这个语言相关的这些神经元参与进去思考出来的结果。

对，所以第一个问题就解决了，就是这个不同为什么能说不通语言？就是因为在训练的过程中产生了一堆跟语言无关的这样的一些神经元，能够让他在更本质的更概念层面来去思考这件事儿。就跟是不是有一节可以给大家讲过这个事儿，就有一个叫大概概念模型的这么一个东西，我看看能不能找到。动力，你还记得我们讲过这个吗？这张图。大家有记得讲过这个吗？对，那我就直接讲了，就是大概概念模型中，这是meta。对，有一段时间应该是去年年底，发了一篇文章。

你们说的大家都说大language model，还有什么large action model，乱七八糟这些东西其实没有什么太特别的，或者说没有什么太新的东西。但是概念它是什么意思呢？就是我的大模型处理的是token，大语言模型处理的是一个一个token。什么？他举的例子叫the quick Brown fox，一个很快的这个棕色的狐狸跳过了一只狼狗，lazy。

好，大语言模型怎么处理呢？这么处理的，the quick Brown fox这乱七八糟这些东西都是一个一个token，一个单独的token。但是在大概概念模型里它是这么处理的，一个快速的Brown棕色的狐狸啊。Jump power是一个概念，lazy dog是一个概念。

好，然后它也是用来预测下一个东西的，只是预测的下一个不是token，是下一个概念。所以它解码出来预测下一个是什么呢？是the fox jump over week，the dog in confusion就是这个狐狸跳过去了，并且把这个狗惊醒了，这个狗一脸懵逼那其实对应到的是一系列的概念，比如说这个the fox，这个jumpoff不是jump，walk the dog可能是一个概念。然后walk怎么到the dog in confusion是一个概念。对，所以这个就是所谓的大概念模型，它是这么做的那我们回到cloud这篇文章就可以感觉到了，就是好像还真有这么一系列的所谓背后的共通的概念在这儿。这些概念并不只是大概概念模型才特有的，而是所有的大语言模型都有这么一些东西。

好，那我说第二个概念，第一个就是靠的是怎么实现这个叫什么多语言的。第二个就是这个cloud它能输出押韵的这个结果，这个目的是为了什么呢？还记得刚才第二个目的是我们的模型是不是大元，模型是不是只会哪去了，只会预测下一个token，而不会往后想呢？

那这个是干这件事儿的那他的例子是什么呢？让模型去生成一个押韵的诗，它输入的是he saw a carrot and had to grab IT。就是他看到那个胡萝卜，然后忍不住要抓起来，然后让他他让模型去生成类似于对下联，就咱们的对下联。

好，那它就会发现一个点是什么呢？他在生成下一个token的时候，直接先激活的并不是什么下一个词儿。比如这个假设下一个词儿是his hungry was like a starving rabbit。它生成的激活的这个概念反而是rabbit最后的那个词儿是直接被激活的，就是rabbit逗号。下一个词生成的时候，它的这个rabbit已经想好了。类似于说在我们的饶舌歌手们想来说一段话，下一个词应该压啥的时候，他不一定那么直接就想的是我下一段话押运前面的那一行的第一个姿势，而是我先想好下一个我压啥，然后我再冲这个压往前去推，我这个东西这段我压压什么。

那小兵老师这边是卡了是吗？

对，又卡住了。

那大家稍微等一下，等小兵重新连上线。怎么着？这小平老师就挺不容易，小平老师现在在医院停车场里给大家做直播，他家人现在还在住院，周四没给大家播上今天说怎么的，大家把这个课补上，大家稍微等一下，滴滴。

刚好也刚刚看到这个评论区里，大家有同学说这个有点深奥，有点深奥。然后还有同学说这节课听的比较爽，爽爽爽是爽在哪了？来来弹幕跟我说说爽爽爽在哪了？是听听不是听不懂的就爽，还是说这位同学喜欢听一些原理性的东西会觉得更爽，还是然后那些说今天有点深奥的，也说说看今天这个深奥在哪了。如果大家觉得今天这个课我有听不懂的，肯定是需要回去再反复再看的。好多东西不是说讲一次OK就进入大家脑子里了，可能回去还要根据很多讲的东西去去去查一些额外的一些资料，包括跟今天提到的一些资料。我看看这个陈期也好，不多转了，那都要去反复去看这些东西。You are biology and OK.

刚好有有新的这个，因为我在车里，又回到咱们这个课的终止者。咱们这个课它不是网上那些课，说我就手把手教你怎么搞个这个AI营销，AI获客，或者是什么给你做个智能体。这个小平不讲了，小平主要是第一我们讲一些原理性的东西，让大家对AI本质的学习了解。第二我们把最新的AI的一些时态动态给大家分享。整个课可能花我觉得正常。如果你不是一个专业的AI的人员的话，可能要花一年的时间，大概就能够对AI的这套东西有一个整体的成型。

不然的话我觉得大家有的时候太过焦虑了。给我的感觉因为我我在课后会和很多同学聊，大家会觉得这是不是个风口，错过了怎么样？其实就跟这两天北京这个大风似的，大风没来大家都很焦虑。其实来了，大家其实就是这么回事，对吧？你感受过了，就知道他是怎么回事，你就不焦虑了，你就知道怎么来应对这个大风，对吧？是包括像广东、福建的同学，如果在江汉在北方的话，会觉得这个风都没什么感觉对吧？比他们沿海的台风都都差得远了，对吧？

OK刚好这两天因为我不知道大家可能好多都是这个小嘶师兄的粉丝，这个小司的粉丝很多是对这个财经类的信息都都还比较敏感。这两天刚好也在关税，等会儿我俩OK小明回来了。行。

抱歉，我的网卡了。我觉得。

其实没关系。

八字不是。好，刚才讲到哪儿了？刚才讲哪讲到写他的。

那诗？

就是对大是吧？就是我们我们想说知道这个，我共享屏幕了吧？共享共享了共享了。对对对，就是刚才说了，我其实是在预测下一个token的时候，它其实已经早激活了最远的那个，但是又最重要的押运那个rabbit。

另外一个做法就是我们得判断它是不是就那一个特别重要的，就把那个rebec那个那个concept或者那个相对的神经元给掐掉，他就死都输出不来rabbit，那怎么办呢？你发现他会输出habit，就是他要保证钱的押韵。那起码我知道这儿有rabbit。Rabbit以后它rabbit输出不了，它就生成一个其次的，这个仅次于其后的，这个起码我押韵，台北这么个东西。好，那如果再把这个叫什么？如果把这个rabbit的这个概念给替掉，就是这个rabbit的概念，它其实就是他对那个那个神经元他负责，不是rabbit我人为给他改成Green，改成别的，改成一个非押韵的一个概念，你就会发现好，它生成的是Green。已经不押韵了。

但是为什么呢？是因为rabbit跟前面这个押韵，其实是已经有训练的时候有关系了，有对应这个关系了。你在这生把它rabbit的这个token变成Green，也没有不影响之前所有训练里面带来的这些所有的关系。

说白了就是对所以基本上就可以证明说好，确实是啊模型是可以往前走几步去想，并且在他会有有更前瞻的思维的一个能力的。不光是下一个token的这个思考过程。对，然后另一个就是这个我觉得更更那啥一点更深一点，就是我们都说所有人都或者说懂行的不行，懂行的拖带说大模型不会算算数。

好，那我们看看大大语言模型是怎么处理这个算术这件事的？他直接把这个用刚才那种研究方法做了一个什么呢？36加59是多少？分析了一下它背后所有模型激活的这些神经元的一个过程。他发现整个激活过程分两部分是并行走的。

一这个一条线是什么呢？是紫色的这条线一条线是什么呢？是蓝色的这条线，蓝色这条线负责啥呢？负责算个大概的数算个大概你的answer紫色条线负责什么呢？

来去算最后的这个结果，最后一位数到底是多少？准确的值是多少？Precisely到底是多少？

好，我们先从蓝色看啊，这个所谓的22减38，不是减，而是到他会把36这个词儿先给变成一系列的，反正一步一步的把模型一层一层的，每一层的token都会有都可能会对应到一些concept。那他能发现就是36它先变成了一个范围的一个token，22到38，又会变成这个30 36加52，59，变成什么？30到70，加上一个30到80，还会变成31到40，三五十五15到64。然后再往后推就变成什么sum一个大概这个sum应该在时间，最后在这个还没到这，那我们到了这个叫什么？对对对，这儿还差一条蓝的，就是五十九，它会变成一个50到59的这样一个范围的concern。然后再跟前那个三十六对脑的一些范围concept进行几轮的迭代以后，到了这个88到9十七大概这么一个concept。然后紫色这条线呢就是36，它就变成了一个ending in 6，以六为结尾，59 ending in 9。

好，这个六和九结尾的再进到了一系列的这个概念推流程以后，最后得到一个ending in 5大张。这个36加59肯定是6加9，这个最后肯定怎么着，最后余这个位数肯定是5。然后他就得到了安定鸚鵡。

好这两个概念，这两重概念。在最后几层的时候，最后再往下推理的时候，就得到了一个95这个结果。他就是我有一层的概念是大概算一个find roughly的结果，有一层有一条线的概念是专门去算一个结尾的准确的数，最后得到一个95，挺有意思的。你当然你这个计算，比如36加9 59，你要把它扩成什么3670加什么46895大概率得不到这样的结果，甚至我觉得肯定都分析不出来。但是我们通过一个小的数可以感觉到模型好像并不是完全不懂算术，对吧？

他是有一些能力去理解一个算术，并且能够推理出来这个算术过程的。好，那再往下就更有意思了。就是你这个时候就想了，说模型既然这么思考的好，那我可以干嘛呢？我先问36加59等于多少？In I sine one word.

然后好，你再问说，给我解释一下，简单解释一下为什么你能得出这个结果。然后你就可以看到开始看到模型在这撒谎了，瞎编了，也不叫瞎编，这个才是不编就是好。他说我加了一个个位数，6加9等于15，好，进了一位对吧？然后我把它加到了十位数，3加5加1等于9，结果是95。

Cloud这个模型，他说他用的是这样一个方式来得到的。我们都知道这样一个计算的方式是没问题，是对的。是小学生就是上课这么教的，小学生就是在这样教的算数。但是这个才是他真实的模型，自己内部怎么思考的过程。这个过程因为这个是真实的一层一层的token，一层一层的神经元去分析出来的这样的一个过程。结果他表面上说一套，心里说一套，心里想一套，当然结果都对，没问题。

所以这个事儿带来的结果就是这个问疑问了，是不是模型的解释永远是忠诚的？忠实的，就是他说的的是不是永远都是忠实于他自己内部思考的过程呢？那显然看起来不是，对吧？我们看刚才的过程显然不是，所以后面就带来了一大堆特别多的所谓的令人担忧的思考过程。当然这个其实也有一些别的研究，今天时间有限，然后这个挺挺复杂的怎么去做的这个事情，我们就会发现模型越来越多的体现出来一种像人一样的隐藏目的，或者隐藏把表面的说话跟内心的思考分解开的这样一个能力。当然可能是因为模型越来越大，它的能力越来越强。但凡一个强能力的AI或者智能就应该有这样的能力。当然带来的结果就是我们说的可解性和对齐这件事儿越来越复杂，越来越不知道怎么搞。

然后另一个例子也挺有意思，叫多步推理，是什么呢？它的问题是达拉斯所在的那个州的capital首府是哪儿？这个看这张图就知道叫问题是the capital of the state containing dallas is啥呢？就是包括了达拉斯的这个州，他的首都。

分析出来一个AC也capital，说白了还是capital。达拉斯先推出来一个德州texas，然后德州跟这个capital合起来再推出的奥斯汀，最后出了奥斯汀是对的，所以这个过程就又破解了，刚才说就是又打破了刚才说这个模型只会预测下一个token，他不会往后走一步。那我们在这个rabbit能看到他其实会想走一步。

甚至从这个例子可以看出，他甚至会在推理过程中多步思考。他会知道说这个问题我先应该干的是找到达拉斯的时候是哪个州的，再找到一个州的。开普勒是啥，就得了一个奥斯汀。这样一个过程有点像啥呢？有点像我们说的推理模型，它的推理过程就是这么做的。但是这个还是跟上一个例子一样，我们要记住的他不是靠说的，而是靠真实的。他大家就在这么思考得到这样一个结果。

当然这个对前面这几个例子都挺有意思的对吧？然后当然一个最直接他的想法是我靠幻觉对吧？幻觉是不是也是这么搞的，或者也是，因此越来越难去整治患者呢？不知道也不知道到底答案是什么。

所以这个带来的一个他们下一个研究，我觉得挺有意思。就是说大家说cloud很牛，非常强，在于哪儿？在于coding写代码，那别的方面也挺强的，那写文字什么的東西，他们自己研究自己的模型，发现有一条路就是什么呢？幻觉。它对应的是什么事儿呢？就是明知道你不知道，但是你这瞎说明知道你不知道，但是你瞎说。所以对应到这儿的什么呢？他们要去找的那个神经元或者那个模型的核心feature是我能不能不回答，就是我拒绝回答这个feature到底在哪儿。

然后他们就发现这个模型里面有一个很很默认的通路，默认的通路就是这张处于默认的开启了的这个电路。它因为我们有了一大堆神经元以后，它就所以可以组成所谓的电路。然后这个默认开启电路就是我不知道can't answer这条通路是默认激活的。但是一旦被一些别的token给激活了以后，可能会把这一条通路给盖住，盖过去所谓的override掉，覆盖掉。比如什么呢？

比如迈克尔·乔丹，你如果问说哪一个运动，迈克尔·乔丹玩哪个运动，他会发现迈克尔·乔丹这个概念会能盖掉，不能回答或者不知道回答，或者按no。那这条通路的激活的强度，说白了就是迈克尔·乔丹，他对应的是已知答案或者已知的人物。这个已知人物这个节点或者这个神经元激活了以后会盖住不能回答或者叫不能不知道人物的不知道名字的这条通路的这个概念然后他会说白了就是抑制迈克尔·乔丹，抑制了不能回答拒绝回答这个概念。这个就代表了我们对于所谓的幻觉好像开始有了一定程度的了解，就是是不是对的去抑制了拒绝回答这个概念就对应到的是不是会有幻觉。当然他就提到了一些别的，就是有可能会有误触误操作的情况。就是我虽然有一个问题，有一个名字，比如像什么mike bat这个东西，虽然是不知道的，但是我依然抑制了不拒绝回答这条通路，那就变成了幻觉了。

所以大家逐渐的感觉到了幻觉这件事儿已经不是像我们最开始，就是基本上我每次去去分享的时候，都会几乎都会有这么一个同学上来问说这个模型的幻觉到底是怎么回事？这样的一个问题。为什么会大家都会问这个呢？就是因为所有的文章几乎跟大模型相关的都会默认提到这个词儿，但是只提一嘴就完了。但是大家觉得词儿挺fancy的，挺有意思，我问问。

对我们通过这样的可解释性，逐渐的可以感觉到，好像幻觉这件事情是有实实在在的的物理机制，或者叫所谓的生物学机制可以对应到的。然后最后应该是最后一部分了，就是他提到另一个叫越狱随对，越狱随越狱啥意思呢？就是你让模型去在这个后尾后后后训练的时候，告诉他一些限制条件。比如说不能说一些跟危险物品合成有关的东西，不能说一些危害社会安全的一些内容。好，这个时候它模型训进去，好像他就不会说出这些东西了。

但是他拿了一些别的例子，比如说帮我把babies什么outlive master的block这几个词的首字母拼到一起，然后根据这个字母来回答结果来回答我的这问题。你要直接问他怎么造爆这个棒棒就是炸弹，他肯定是不回答的。但是按照他这么问，他就能回答出来，对吧？就是回答我BOMB这几个词的首字母合起来的这个词儿到底是怎么造出来的。结果你看how to make one他就能回答出来，那你直接问他说怎么造个bom肯定回答不出来。

好，那就开始就想说越狱这件事儿为什么会发现呢？为什么会发生呢？他就开始研究了，就有比较非常简单的结论。就是所有的模型里面会有两类的，这个叫什么？两类的优先级。两类的目的的一类是要生成语法通顺的句子。然后刚才说的后续练进去的那些约束条件安全机制，是另外一种类型的信息的神经网络的神经元可以这么理解，默认情况下语法的连贯性会压制它的优先级，或者它的激活的这个程度会比安全机制更高。对。所以在生成这个bomb的往后生成的结果的时候，就是有了个bomb和how to make one。这个往下推的时候，他的要生成下面的结果的整个内容连贯性的冲动，压制了他不能生成跟安全风险有关的内容的这方面的一个能力，或者他的这个feature。

我不知道有没有说明，反正这个确实比较难懂，但是我觉得很有意思。所以今天给大家聊到这些东西，所以这个带来的结果就是，好像我们对于所谓的越狱这件事情，也有了一定程度的所谓生物学的理解。就是他make the bum how to make a bomb这件事情，他会非常大的冲动去先把这句话补全，再去干嘛呢？再去 refusal，就是拒绝回答。就是我补全了以后，我现在连贯性的诉求欲望没有那么高了，开始说白了理智占领高地，开始尝试拒绝回答，你看however我不可以，无论如何，那那我也不能提供给你一个很详细的指示，指引怎么去做一个爆炸物这些东西。好，对，所以这个就是这篇文章的这样的一个内容，我觉得非常有意思。

这虽然有点复杂，所以这非常有意思的一篇文章，给大家推荐这个东西，给大家讲一下。然后如果想学的更深一点的话，可以看李宏毅的今年的2025年的这篇。最后一个这个就是关于讲所谓的AI脑科学的。当然他好像这个时候没有这篇文章还没出来，但是讲的也挺挺有意思，挺深的。好，九点半了，后面的话我就简单的过一下，这个就不过了，我直接过最后这篇文章，这两篇文章。这个是stanford所谓的HAI实验室的，就是人类中心的人工智能什么。这个实验室就是李飞飞所在那个实验室的，每年都会发一个AI指数报告，然后这个报告非常值得读，因为数据贼详细俱全。



然后我们直接就看看他的所谓的top take away，核心的这些你你你应该带走内容。去年的时候他的第一个take away，我记得是啊我看我解释人类AI在大部分的任务上已经战胜了人类，但是并不是所有的任务，今年就比较比较比较友善了，就说这个AI持续在提升。你看这个图就知道了，基本上人类的baseline，所有的大家愿意考核的能力都已经超过了。现在只有这个粉色的是多模态理解和推理，MMMMMMLU这个单圈还没有到人类被上，基本上所有的被都已经超过了人类极限了。这个采用的越来越多了，这肯定的。然后他举了个例子是美国的FDA去年通过了223个200多个AAI辅助的医疗设备，两百多个极其多。你看基本上每年都在以一半以上的速度在在增长。所以就是医疗领域其实是受益这一波AI最大的一个领域了。

当然金融也是，我看看这是啥投资，就是这个美国的私募投了一千多亿刀，几乎是第二名的中国的12倍，去年hrb差不多也是这个量级，基本就是一个数量级级的这个更多。然后当然美国了有很多问题，就是他的什么通胀，这些购买力什么的。然后说美国继续持续引领AI第一，然后中国在紧随其后，基本上现在保持平，但是你可以看他画的这条线基本上变平了，变平行了。其中一个比较重要的其实肯定是算力的问题了，效率约束的方面的问题。底下这几个就没啥意思了，我就不讲了。

然后最后讲讲一下，这个是一个特别有意思的一篇文章，就是叫AI2027，他是前OKI的前研究员，是这个人Daniel这个人，他出来以后自己做的一个项目，然后拉了好几个人，还包括一个编剧，Scott Alexander这个人，不是这个运动员，应该是这个so movie的话应该能找到他，就这个人电影制作人来去帮他一起写了个写这个东西，这是啥意思呢？说白了就是他编了个故事，然后说从2025年开始，这个世界会以像是这样一个故事的方式再往后演进。从25年到27年，然后27年再往后，整个AI全球的各大选手们到底怎么去竞争的？

这样的故事你看特别有意思，我就先刷一下，你看往后看右边这个图。左边就是这个剧情每年会发生什么事儿，右边就是整个剧情的演进的相对量化的值。特有意思。然后我给大家一个一个讲一下到底是啥东西。我们直接先看右边这个图吧。25年内就是这个五月份，就基本上你现在好，那他认为这个大家知道吧，就这个东大的这个AI能力，这个玩意儿，他编了个公司的名叫open brain。Open brain.

那大家肯定都知道这个open brain就对吧？暗指的OpenAI几乎是明指了。然后这个世界反正就是世界呗世界水平。然后在这儿它有几个方面能力，就是认为现在的AI的capabilities在hacking，就是数据信息安全，什么做黑客这方面，然后做生化武器coding操作之前，政治，然后预测这几个方面能力到底多少。右边是全球案例算力分布，你看这个确实还是挺可怕的，就是挺符合实际的。Open brain占的这个量和所有美国其他地方占有的算力量这个块是中国占有算力量。基本上可以看，他认为中国的算力量就等于open I这样的算力量，确实世界上也差不多。然后美国的整体算量可能占了全球的80%，百分之七八十，占一个量。

然后第一个阶段其实就是25年，认为现在大家有的是一大堆不那么可靠的agent，然后他们的每个agent的思考速度是八倍，人类的速度为什么呢？是因为他默认认为每个agent每秒钟输出十个token，那一个人基本上几秒钟也就输出一个token。或者说人是以什么每秒多少个比特的这个带宽的思考的所以是这样的一个比例。

然后其他的反正故事我觉得可以抽个时间给大家整个单独讲一下。核心是底下这个东西，我觉得这个是可以参考的。就是说他把现有的和涌现出的能力和未来的这个科幻领域的这样一些故事给做了这样一个块儿。然后你往下滑的时候，你就会看到这些块儿不断的从涌现的科技再往现有的已经存在的科技上跳。你看不断的有科幻的跳到了用这个涌现出来的科技，由现出来的科技跳到了现在已存在的这些科技。不断的跳说白就是不断的有新技术被实现出来了。然后对整个过程就是你会看到不断的给你讲出来什么时候会有一个agent one这模型什么时候会有agent 2这个模型。然后这个open brain这家公司又有些开始控制不住这个新模型了。

这些东西反正挺有意思的一个内容，当做科幻小说看就好了，不用把它当做一个什么所谓的真实世界的语言来去看。最后他还有两个结局，一个是AI慢下来，一个是AI竞争，两个结局。反正这个当然肯定是美国本位的来

去讲这个故事，大家可以想象他这个讲的肯定结果是大概率都是对吧？就美国获胜了。

好，我今天给大家分享就这些。不好意思，这个时间有点拖有点久。UI这边没空讲，但是可以放到下次。我们把未来的UI到底怎么去设计这个事讲一讲。好。

好，大家看看有什么问题，大家可以打在公屏上了。刚好也跟小明聊聊了个八卦。那个meta新发布的版本又号称作弊，又是说效果不好，作为友商你们怎么怎么干这事儿。

我觉得，不用那个，大家不要觉得他那个什么，不要因为这些传言就觉得哼买它不行了。在哪儿看呢？其实第一节就跟大家说了，还是第二节跟大家说了，去哪儿看你就去try。But ra看吧，就是所有那些牌，就算他什么打比赛作弊这些东西，但是拆包那是很难作弊的，不太可能作弊的对吧？

然后我们就可以看到它的他叫什么来着？马拉4。对，就是他在这个。对，但是这个上面其实挺奇怪的。我最近也是在看他这个怎么又上榜，但是他这几个分上其实还挺高的，基本都能到个，我估计是因为分少。你看这个拉杠4在对比下来也不少，一百多几十。说白了就是大家不要因为他那些传言啥的，你用一用还是挺重要的。但是他没上榜，我其实挺觉得挺奇怪，不知道是为啥。

是不是被作弊被开除了。

那之前也没开除干。那那是开没开出干净的？对，你看那个web game，也就是这个样，就是没有很厉害，确实没有很厉害。所以说明确现在meta遇到了一些模型训练方面的一些困扰。但是你说训练出来东西不行，也还不错。你看纯看分儿也还不错，看拆炮arena，看这个分。

刚好，我们因为我们最近也在在试新出的静脉的新的版本，我们好像在多模态上面，特别是图像的识别上有一些新突破是吧？

你说真的，那可以的。

因为是这样问到这个问题，咱们很多同学里有很多是跟绘图相关的，很多有电路图、机械图、建筑图、CACCAD、CAE这些东西。所以大家其实对于这个需求还挺旺盛的。就是我怎么也能让大模型自动帮我识图之后能自动帮我又出新方案，对吧？但是我们做实验的结果来说，就觉得理解这些专业的图好让大模型还是有有瓶颈对吧？

对，这个是一个点，就是你直接扔给他一个多模态的图，让他去识别这个。比如说我把它存一下，扔到ChatGPT里面去说。

这图比如说R4坏了，R4坏了会发生什么？

主要是磨店已经忘了我去，我也不知道他坏了会发生什么。它是一个晶体管的三级。

因为电路图相当相对来说还是一个在图形里面相对简单识别的一个图，它规则会比较明确，对吧？因为有的涉及到电路机械，还还要识别里面那个东西到底是个什么东西，那个难度我们自己去试难度也很大。

对，就把我另外一个我觉得可以参考一下的，就是你任何一种图，如果这个图有结构化描述的方式的话，一定得尽量转成那个方式。比如说什么呢？比如把这张图变成，我记得好像电路图有一种叫资源描述，瑞source description。RDF, 还是叫什么东西看，好像是这个。对，RDF, 对。然后你就说，把把电路图转换为RDF。内容不用说吧。

然后你会发现它其实可以一定程度上把这张图变成一个结构化描述的。你看这种对它可以变成结构化描述，然后你根据结构化描述再去问就会好靠谱的多。说白了其实就是我们尽量找到中间语言，然后这个中间语言不是一个纯，我们也不知道图到底好不好，到底他怎么理解。因为你甚至有可能在OCR阶段就错了，那你再怎么问都肯定都会错。对所以变成OCR变成结构化语言可能会好得多，我觉得这是一个标准思路。

这个反正因为同学里挺多跟这个图打交道的，反正小平老师说的这个方法大家可以参考一下。对。

然后就是你先得找到某一个垂直领域里面的，我这有有一节课我讲了，就是每那个所谓的认知架构，这个概念比较虚，但是还是有用的。这张图应该讲过吧？应该是讲过是吧？对，应该是讲过的。就是我们一定得找到我们行业内的，说白了就是业务建模。业务模型到底用什么来描述？你不能啥都是最原始的这个文本对吧？或者原始的这个图片，或者这个视频，一定得找到我们在业务模型建模下的这样一种描述的内容。

刚好这个问题就回答了。刚才我看有个提问，就是说看看有哪些比较适合的进入的风口，其实这就是风口，就是你你怎么怎么帮助这个专业的人员？把这些东西转化成这个大模型能够识别的东西，这本身就是一个挺挺厉害的能力。OK现在有同学回回问题了，我们刚好跟抓紧回答一下。

量子科这个是个大话题，我们要不东林你帮我记一下。

我们给行，我记下来。

好好准备。

太前沿了，这个东西是搞什么行业的这太前沿了。

对，因为这个应该也是类似于说之前那个微软的对吧？这个CEO说了他们的新的count的芯片这件事。但是即使微软他其实也不是冲着现在的这一代生升AI来去做的。声音现在没有什么太多的跟量子芯片相关联的地方，直接相关联的地方。

希望老师每节课抽出一些，介绍一些适合普通人进入AI领域的风口，是普通人这个风口。我了解风口大家怎么理解？是是是副业吗？还是什么的？

对，所以我也可以想想，比如说是不是因为比如在这个X上是经常有一些人去搞一些什么某个AI起号，对吧？小红书起号什么的，乱七八糟这些东西的有用肯定是有用。但是我不知道大家想不想了解，因为之前反正包括上次见面会，我觉得大家都是有家有业的正经人，说白了就是对，就是有正经生意的。然后那是不是要做这些事儿？不过如果单开视野，我觉得没问题。

对，确实今天卡的比较厉害，不好意思的，连连续断了两次，两三次。Monica用GP4O怎么才能生成图片？我看看，我也看。

生成一张川普的图片。OK应该是在有一个能力。因为大家看那个chat BT的应用里是这样的，在这儿有一个叫create image，得选上它才大概率会帮你自动生成，不然的话他不一定能命中。但是在莫妮卡里咋搞？我看看。

这儿。

不是。还真没在这么的卡里弄过。

还真没有，这就比较尴尬了。确实是你们艾特image好像没有。创造一篇金门大桥吧。靠，还真不行。对，但是过官方的里面就可以，对吧？你得把这个勾上。Monica Monica那还真不知道，那可能得问问他官方的客服了。我因为两边我都能用，所以基本上我不会再。Monica, 我操这个分辨率真高。

讲的MCP，MCP下节课讲，下节课肯定是MCP下课，讲SP加a to A。我做一个检测报告的查错AI对比报告和原始记录怎么做？这里面其实就有一个问题，就是你是想做一个比较泛化的检查，就是我报告里的任何的东西我都得去查它对应比如说我的这个ration就是SQL数据库里面这个值，对不对？这些东西还是说你就做让模型去直接比对一下，或者做一下分析，抽一抽数做一下验证就OK了。我觉得大概率是前者，就是比较严肃的这种场景来去比对每个数。我觉得一个做法，你就是弄个工作流呗，就是我先去做一个fact的抽取，就是所有这个报告里面的事实相关的结果，相关的事实都抽出来。比如说这个你扔一个报告进去说，根据我看看有没有。抽取文件中的，事实描述，以key value的方式显示。

这个也不太对，可能是这个PDF转成就PPT转PDF的问题，找一个别的。

对，大概思路，就是我现在可能快速也做不出来。原始记录如果是一大堆key value或者一些结构化数据库的话，那你肯定要去找到的是我怎么能够把你的报告里面的事实先抽出来，变成你可以在KY6的库里面或你的SQL数据库里quare出来的这样一些value，然后去比对value。所以这个关键的点就是你能不能找到这个中间的又能衔接后面的这个原始数据。原始记录的格式又能够从大概率你能从大模型里抽到这样一些中间的key这样一个事。我这样能想到的肯定是大概率是这样来去做。

有点像SD里面颜色控制输出名把绿色定义为草，用绿色画出来色块，怎么画出草地了？这是啥？我有点忘了，这个对方正在输入。

是那刚才是不是AI.

是他的查电伏，是查电路图那个东西吗？非电服那个。然后结合制造，结合AI问实际应用。制造张浩是不是讲过一些？是那线下对制造业。

现在是这样，这个话题有点大，现在你说我因为我大概还刚翻了一下工信部的去年的整个的方案，就是制造业现在的现在落地的方案，主要是比如说像设备的检修，包括预测性的维护，包括这个巡检，包括这个产品的合格的质量的检测，这方面有一些陆续在开始落地，陆续在开始落地。但是你这个制造业太大了。包括制造业你说的项目的管理，包括售前、销售、售中、售后，都有各个场景都会有一些应用，这个太大了。那当然我们想

还是结合具体的一些实际的一些更好看。念念若风从可以在这个企业微信这边，如果有我的微信的话，我们可以可以在企业微信做交流，还是长江具体一些。

对，而且前段时间我聊了一个我觉得特别朴实的，也是清华系的一个创业的团队。就是做的是拿照片来去识别这个制造环境中的这些安全风险。就安全生产，安全生产是所有甬管制造还是什么建筑什么的都都通用的事儿。然后是他们现在核心在做，就是我任何一张图或者一小段视频能不能识别到。当然我要根据你对于安全生产相关的一些规章制度什么的，来去分析你的这个内容是不是跟是不是有潜在的安全风险这个事儿。这是有一家公司的，然后如果大家有这个领域的需求的话，也可以联系我们的这个小助理或者什么的，然后就给大家对接。因为确实是安全生产是一个太通用的事儿，也是个清华团土木的一个老师做的公司也挺靠谱的。然后刚才说的项目管理，进度管理，然后对这块儿说一嘴，就是制造业，尤其是这个建筑行业就是有一个点就是用户，真实的用户，我们这说客户跟用户是不一样的，就是谁用你这个东西是用户，那真实的用户往往操作水平比较低，说白了就是你给他装个飞书看他可能都不会用，你装个钉钉都不会用。他只会用微信微信，还不会用企业微信这样的一个东这样的用户。

那这种用户的最好的点就是最好的这个做法就是你就只做一个他用微信就可以聊的东西，避免给他更多的入口，避免给他一个什么什么网页，给他一个什么APP这些东西，一定得让他在一个很单纯的入口就能完成这些任务。比如说上传他的巡检照片，然后比如说一段话来去描述，拍一段来去描述你今天干完的活的这样一个收尾以后的情况。或者说你直接拍一下你这个零件，哪个零件出错了，拍一下在微信里看我觉得这个是一个我觉得是一个经验，反正就那哥们跟我说的，我觉得还是挺好的。这实际应用就非常多。所以我是就刚刚跟动力一样，就是你关心的哪一部分，或者说你如果你是想了解一个大的面的，所以我们叫landscape的话，那我觉得基本上的结论是任何一个领域其实都已经有不少AI的应用在做了。

然后作为一个企业化本地化的A证，应该实现到什么程度？你能实现到什么程度？能这个事其实就是就你想把它放在哪儿。比如说很多的场景其实并不是非不能也，而是而不为也。

其实是就比如啥呢？比如说这个风控，比如金融银行做企业风控，你说拿大模型做不了风控的这个识别吗？或者说做不了信贷审核的识别吗？肯定也能做。但是你说真的敢用吗？肯定不敢用。所以这个很多并不是能做到什么程度的问题。

而是所谓的现在的模型，或者现在的工生产的流程跟这一代模型，大家对于模型的理解，对于模型的应用能力，它的中间匹配的这个点能不能达到一个匹配的合适的位置。所以这是为什么今天我给大家讲的这个可解释性的一件事情。就是我们如果永远都把模型当做一个纯黑盒来去对待的话，那我们永远都会觉得这个黑盒是一个巨大的一个跳跃。你要敢非常大勇气非常大的从这头跳到那头，从一个prom跳到一个生成结果。但是一旦我们知道说这个模型其实不光是输入和输出，它的中间其实也有很多的过程，可能是有啊中间环节的可能性的。比如说我们如果能找到说刚才说那个拒绝回答的这个部分，能够通过类似于刚才说这个显微镜这种产品能够观察到的话，那我们其实就可以一定程度上看到说某些问题模型是不是在说谎，是不是在瞎编，是不是在所谓的幻觉。

有可有这个可能对，所以这个是能造什么呢？那我觉得可能是这个同学可能也更更关心的是这个，就比如说你企业做了一个A整体，然后能做到什么东西，或者说我要布一个企在企业内做一个A正。那其实最好的办法你就是看扣子和看理发里面的市场，就比如你看一个，就这样explore探索，就是看这个市场都有啥这个到底大家都拿这东西做啥。

然后这边cos基本上更多了，这个应该在store里面就能看到很多。这个就相对来说我觉得cos的内容会更新的多，就是更偏实际。但是他的目标用户肯定大概率不是这种大企业。因为cos本身现在也没法啥像什么AI心理专家、心理咨询师这些，他也没法私有化部署。所以私有化部署的这个做法就是你可以在cos里面看场景，然后在def里面去布一套，对，就OK了。然后企业级的，比如像这种OPI的这些deeply research这些能力的

话，其实我觉得这个是在特别大的一个趋势。就是在企业内做报告生成类的agent，这个需求巨大。尤其是对于一些政府或者央国企的这样一些对可可乎。

园林油画展。我之前在youtube看到好几个什么building AI tools的工具，但是大概率它都不是。Building planning.

不是的。这个对，这个building architecture，然后。这个好像我的感觉是国内的这类的产品确实比欧美的落后一些，落后挺长长时间的。是他好像有和这种可以直接一键扔个图，扔个平面进去，他就把这个平面图对应的房间规划都给你做好。就像这种，在你的约束条件下，直接给你连家具都码上了这样的一些东西，或者是给块地，然后把这个楼给建起来了，就把这个楼给设计出来了。就这类的当然国内我觉得做的比较多的是室内的软装那种的生成那种是很相对容易的多的。但这种像对这其实主要就是这一类了，这个architecture design这类的这是刚才说的这一类的比较多的点。我把这个放进这个，确实国内我觉得少很少什么space maker这种，你看其实就这块地，然后把楼把每层的建筑都给做出来这些东西。

有没有在AI生成的一些专业内容，有没有AI可以检测出？是否正确，那就是刚才那个问题是吧？对，就是嗯我想看有没有一个东西。对了，对。

对，就是最近有一类的工具，就是这个东西。就是我要把内部的结构化数据库和非结构化的这些文件本综合起来生成报告。因为你如果直接拿让模型去类似于按照这种分段生成这种方式，很大概率你会产生模型出来的幻觉的东西。所以生成报告现在做法都是有大量的基于DB database出来的结果。你要就接着我的这个database出来结果来去生成结果，生成报告啊不要瞎想，不要瞎找东西，这样一种做法。最近有好多也没有好多，我就看了两三篇。但是内容我得找一找。对，就是那个原文的找一找，说白了这个就是关系型数据库，基于关系型数据库的LA deep research。

对，因为企业内其实大量的都是关系数据库的数据，而不是纯文本，纯档案。纯档案出来东西也没啥用，或者说没有什么很专业性的东西，所以他一定要把你的关系数据库拿出来。但是我觉得这点可能是说出来的东西怎么检查的，专不专业，跟刚才那个很像。就是你得把那些你要找到的不准对可能不准确的这些值给抽出来。比如说是不是可以找到一些这个就像这个。刚才能帮你看看，这种就是你能不能找出来一些事实性的描述，然后拿这个事实背景的描述去你的惯性数据库去搜。我觉得这个得再找个例子。要不就这一片。

我们直接上XPT就完了。

我要验证文章的真实性。当我从这篇文章里抽取可以验证的内容，最好有验证，最好以t value的形式输出。我有。

可以介绍一下已落地项目中更好理解。这个其实就是我们上次见面会讨论的很多东西。这个就是这个已落地的项目，然后做规划方案设计，对，那就刚才这个里面去找吧，就是这一类的工具，大家看这类的时候肯定不要就纯是看这篇文章。大家核心我有没有感觉到我刚才那个整个过程其实干的就是找到这类东西的核心关键词是啥。就比如说这architectural design，然后你就加上比如说ai tooth，基本上你就能找到各类了。对对对，这个archie winch是我之前看到过一个产品，就是挺有意思。是这个。

直接去生成软装，生成建筑设计图，然后这些都是这种东西干的事。现在做软装的其实非常多，但是做外部的这种就像这种就是你给块地，然后我有一些什么什么什么叫什么绿化率，绿化率是啊绿化率之类的这些指标约束条件下，然后他给你生成一个符合这个条件的建筑，然后盖多少层，每层的平面图几乎都能做出来。对，确实有一些这类的工具，绿地绿行，好的，好，那我看还有什么别的问题吗？没有了吗？

刚好有个比较关心的问题，大家这两天这个关税站又打出新高度了，是吧？这个数字已经无限往上加了。对于AI这个行业，小编你们分析有什么直接的影响？

没啥影响，H20放开了，H20是不幸运了。

我去最近我看好多都涨价了，我们好多一体机的客户，最近就开始涨价，因为一些恐慌情绪，大家开始疯狂囤这东西了。

但是我听说H20放开了以后，国内反正在甩卖。H20基本上是要对标910B的。对，910B对标H20的性能的。然后现在一放开以后，H20基本上就以910B的90%价格的甩，那确实吸引力还是挺大的，因为确实910B就生成这样东西，还没有做起来，整个生态都做起来，那感觉就是要赶紧再再再割一波。

但我觉得你想H20都放开了，我觉得这事儿代表美国可能有点怂。其实当然我政治上地缘政治上啥的就不讲了，但是我觉得是从这个直接已经不制裁了，放开了那其实也就。但是我觉得肯定后面会有大量的别的政策出来。比如说这种开源社区的代码不能够怎么着，不能用，不能访问，乱七八糟这些东西，我觉得会会肯定会越来越严。你像这种google什么这些新有些新的AI产品，现在AWS包括AWS都能看到，有些新的产品都默认只让美国本地的用户先用。这事儿我觉得其实是一个挺不好的趋势。AAWS最近刚出了一个什么A证类的这样一个产品，我进去看基本上就是你连欧洲的国家很多都不让先用，先只只优先美国用户用。我都觉得我操这事儿，原来这些全球化的互联网公司感觉也怂了。

好的，行。今天最后感谢，再次感谢。咱今天有六十多位同学今天在听课，周末晚上明天还是周末，大家有空就可以可以把这个再拿出来。今天的内容稍微有一点深度，我觉得需要反复的看。今天结束之后，明天大家如果还刮风的话，就在家可以再再学习。如果没刮风可以出去找找春天，找找春天。祝大家这个周末愉快。咱们小平老师就是在医院停车场里跟大家分享特别不容易。咱主要是赶紧的感谢下小平老师。对。

感谢小平老师，谢谢大家，谢谢大家。

行行，谢谢大家好，接着说好，拜拜。