

好，那我就共享屏幕了。

Hello, 欢迎大家加入今天的课程。

大家晚上好。好，今天我们在可靠的有，反正问题比较多。但是今天我们从还是从模型开始讲，最近这一周大家应该最火的就是这个东西，对吧？

我们的友商，我们很优秀的友商kim k two k2这个模型。然后我们先从这个讲，而且我觉得确实是非常值得讲的一点，就是它带来一个好处是我们用今天后面最后要讲一点的这个靠code，我估计时间没那么多。靠code其实可以用这个KK two的这个模型做一些事情了已经。

所以今天我们从这个k two开始讲，KVK two你看它的名字叫open ended intelligence对吧？Agented常听课的同学应该都知道这个词儿了，对吧？这个genting自助的或者叫反正就是智能体的这个形容词。

这样一个东西我们看看它它是个啥，我的网咋。我怎么打不开？行，我们就这样看吧。

对，k two是一个ME是一个混合专家模型。然后有多少呢？有32个billion的激活参数和一个trAiling的总参数。对，一个trading就是1000个billion这么多，然后应该是我见过的就这一波大模型来说，应该是最大的一个开源模型了。

陈小明是0.6671B27672B对。

确定对。所以这个应该是最至少这两年见最大的。

因为好像我记得之前google有一个1.6锤炼的玩意儿，然后好像也没啥用。对，所以这个是最近几年看的最大的一个东西。

然后说到MOE，我我我我估计大家都听过MOE这个词听烂了，但是给大家看一下到底什么是MOE，这个混合专家模型这么一个东西。

混合这个mixture of expert是一种类型，然后混合专家模型就是混合专家的这个mysql of expert这种类型的模型，所以大家不要把它它只是一种模型构建的这个架构，然后那它是啥呢？

我们看看它其实就是简单理解，就大家肯定都能理解。

其实就是一大堆好像是一大堆各有所长的专家混在一块儿，然后让大家干活能够指定给最擅长的那个专家去干，但是核心有这么三个东西，一个叫expert。

Expert大家听起来像是一个对吧？

一个挺拟人的东西，但它实际在神经网络里，就是一堆神经元，然后这个或者叫萨model会更明确，就是一个大的模型的一大堆参数的一部分，然后getting network的门控网络说白了就是我来了一个活儿。

比如说我要推理下一个token，我来了十个字要推理下一个token，每个token每一个进来token到底应该推给哪一波，对前面sub model哪一个或者哪多个扫model这件事儿是门网络门控网络，听名就比较清楚了，就是转过去，然后悉数激活。

这个其实就是我怎么能够让少部分参数参与，就可以把这个通路推理出来，我们看看这个，这个就比较相对来说比较清楚。

我这个比较清楚一点，就是他是怎么分的呢？

他不是说我一句话，我就分给某一个模型。他其实是这样的，我一个token我叫来一个，比如说we like to play什么东西，we进来，它就会通过一个路由打到某一个网络里。

这网每一个网络到底是啥呢？后面会有看。

然后这网络会输出一个它网络对于V—这个token的输出，输出结果是啥？然后第二个来了个like那那他会通过这个楼打到这个，比如说这个FFN，前向网络里面的第一个，然后输出一个结果，这玩意儿就是个路由的意思。

所以我们看到一长串进来，其实就会分别打到不同的前馈网络里面。那就基本上对应的我们说的所谓的一大堆专家这个概念了。

对那这个事儿其实对，这我还标了一下，挺早就MOE的一个实现了，而且不是这一代，是从90年91年开始，MOE这个架构是一个可以追溯到上个世纪的技术。当时就说了，怎么把一个复杂问题分解成多个子问题，然后分别派给不同的专门的模型。

这个想法还挺直观的，而且很直觉对吧？就是那我肯定是擅长的人干擅长的事儿，直到说后面到了这个神经网络之后，通过有两个重大的里程碑，一个是啊专家组建，一个是什么？

忘了。对，反正就是有有几个里程碑带来的是我们现在的这样一个MOE，但是这之前其实还有更大的模型是google的一个叫switch transformer。

这个玩意儿有一点一点六个缺点，也是一个很可怕的玩意儿，非常大的东西。对你想21年一个1.6垂类的。

模型能干啥。

关键咋跑的，也就google能跑得起来的，我觉得确实是。对，所以直观一点大家可以这样理解，其实就是来了个需求，他通过是这个门控网络打给不同的expert，让他们去输出东西，所以就这样一个东西。所以我们回过头来，MOE就是大概这样的东西，所以大家理解。

所以他一句话，每一个词都可能经过不同的对。

是的。

专家这不太合直觉。那那原来不是感觉每个专家在干不同的事儿。

所以我们不要把它单纯的理解成一个专家就是这个擅长琴，那个擅长棋，那个擅长书，不要不要这样理解。它其实是一个人也无法那么直观的把它解释成人类理解的那些专家的skill的专家。

他的更多的作用是我们希望能够通过把这么大的一个网络切成一大堆小片儿，然后让这些小子儿一起来训练，这样得到了一个不同的小片。擅长不同的事儿。

但是他真的说擅长那个事儿对于人类的解释是什么样？很难解释，就是真的很难说一个export的是叫什么，这个数学推理的export，那个叫什么写代码的expert，基本上不存在这样的解释可能。

对，好，我们进去，那就回来。所以大家能理解什么叫32个billion的激活参数，对吧？

就是我一整个一大堆专家的参数加起来是一个trillion，1000个billion。然后那每但是每一次推理的时候，我其实只用了其实其中的一两个1个export。

那一个X2可能就是32个贝类这么大，所以一个1024除以32对吧？

那有32个专家，对，然后那他擅长啥呢？你看他说达到了sota级别，大家看这个state of art，大家会不断的看到叫sota就是最牛逼的意思。然后最牛逼的性能在什么方面呢？在前沿的知识？那肯定是你训练的数据越更新，那肯定是越前沿。

然后数学coding，然后nothing，而且是在什么范围内它做了一个限定条件，不是，而且是注意就是among这个所有的在所有的非推理模型的里面，在这方面更强。后面的那个bench 2也能看出来，其实推理模型还是整体碾压非推理模型的。

但是他提了一个特点是什么？你看他go further，他特别为什么做优化呢？

为agent类型，agenting类型的任务做了优化。所以他说K2不光是回答问题，还能act，还能干活这样一个事儿。

对，所以他给他开源了俩版本，一个叫base版本，就是基础模型。

基础模型就是大家简单可以理解成是他没有那么都几乎不太会正常的说话，但是知识贼风渊博。

然后基本他该知道都知道，只是不知道怎么跟人去互动，或者说怎么能正常的完成人的下一个任务。

然后instruct指令版本其实就是大家说的指令模型，然后能更好的对话，能更好的干agent这些活。

比如说你问他到底应该调哪个API，他能准确的反馈回来这样一个东西。所以他发了这两个版本，但是都一样所以base版本是给谁的呢？其实就是给开发者，让他们去基于这玩意儿做微调的对，但是这玩意儿一个一个T的玩意儿去做微调，也是挺为难创业者的。

然后他的这个bencher第一开始他竟然叫什么这个突出了它的act这方面能力。它的半圈肯定是这种臻tic类型的或者竞争性编程。

啥叫竞争性编程？就是之前给大家介绍那些什么数学高中竞赛，然后ACM开发者这个竞赛，就是编程竞赛这类题。

所以你看这有什么SWE bencher r又是老老老熟人对吧？写软件工程的verified ed的这个它能达到65分。

然后他对比的是谁？对比的是cloud close 4 ops还是挺挺不错的，就是他在一个非推理模型里，你看他对比的是谁啊，GPT4点1000万3235B然后deep seek的VV3，大家注意这是V30324那个版本的V3，所以它对比的都是非推理推理模型非推理模型。

然后这个cos你说他其实确实官方也没说他是个真正的reasoning model还是什么，但是就是很强。然后live call bench听名就知道了。

另外有一个有意思的一个bench叫这个OJ bench。OJ bench这个是对就可以看一下为什么我关注他，你看这个为啥我关注他。

这分太低了对吧？就是普遍的都是十几分的这么一个题。

然后我翻开一看，你看他是六月份，就是上个月发的一篇paper讲的一个bench。他其实就是特别直接，他咋做，他就是针对所谓的这种叫竞争型编程，就是竞赛性编程这样一个题。

大家如果有有知道计算机的，我估计咱们这个群里没有太多计算机学计算机的但是如果身边有计算机的朋友肯定知道说这种比赛，或者说家里有孩子应该都知道这种。NOI就叫什么国际青年。

那个NOS national，NY national，IO那是国家奥林匹克信息学竞赛。

对对对，这个叫什么青少年？是这个吗？

对对对。

72年信息奥赛。

对，然后CPC这样都是竞赛类的，你看他咋干呢？

其实就是把这两个地方，特别都是考比赛的题搞过来，然后变成问题和测试用例，然后攒一波，然后让各种大模型去去去，然后你看这个量其实不多，整个加起来才两百多道题，所以也是给这个群里同学，就是说你但凡想去再大家自己的行业内做出一点大模型相关的这个工作的话，有一条路其实就是你去做一个串。

然后如果你能把这个奔驰2搞出来，像他这个OJ bench是把各家主流模型都跑到个十几分，你基本上至少这个行业就别太离谱，至少这个行业你至少还有一号。对，而且我觉得挺有意思，你看他不是这个。

这是能折磨大模型。

对对对，就是你能把这个模型给折磨的吐了，就是你牛逼。然后你看他这个评估，他其实也是按这几个来分的，推非推理模型开源的和推理的开源模型和闭源模型。

你看这个分基本上是非推理模型被就是推理模型碾压非推理模型。你看非推非推理模型基本都几分，然后推理模型基本都至少十几分，然后r one最高这个26，然后闭源模型其实也不一定有那么牛逼。

你看这个几个像靠3.7很低，其实我不太明白这个为啥，但是有可能你看这种一怕死的python，这个非常低。然后最牛的是jm 2.5 pro这个还是符合大家的预期的。

所以闭源模型方差很大，只能是说就是大家参差不齐的很厉害，所以回到刚才说，它它是在非推理模型里比那确实整个水平都差。对，都低。

所以它比起来还是在这个里面有比较厉害的水平。

我看看，对，后面有一个比较有意思的是你看这个奔驰里面它的大部分模型的评分，这是让他写C加加和写python。大家当然他就是大家觉得写python容易还是写3加容易呢？

那肯定是写python容易，对吧？对，但是你看这里面的分儿就是pass艾特8，意思就是跑了八次，只要有过一次就算过了。

这个pass x8它的通过率都是这个深蓝色的高于这个浅蓝色的。

当然这边是是那个啥，然后你看大部分模型都是深蓝色大于浅的，就是写C加加的通过率大于写python通过率。对，陈浩，你你你有没有感觉，你觉得为啥？那就是C加C加。

对，那就是说C加加更结构化一点。

开始这个测试OJ奔驰的题目都是啥题目？

还记得奥赛题。

所以奥赛题你肯定也打过那种比赛，里面考察的肯定不光是逻辑，对吧？不光是跑没跑出来，对性能也是很重要的。

所以他就说这些模型里面C加加的通过率高于python通过率。可能的一个原因是因为确实是C加加的性能更好，跑出来写出来程序比python好多，所以普遍通过率都大于python对OK。

但是这个答案结论不是给咱们直播间里的同学说给选自己给自己家娃抱C加加培训班的一个理由这个C加加的性能比python好，那是他就是他语言特性，或者他的这个语言的解析器的特性造成的。但是咱们以后的小孩，我觉得写C加加的必要性就越越来越低了，就是强烈其实不太建议，不太建议教小孩写下加，直接写学写python就OK了。

对，然后你看那个r one的这个部分，右边的部分python基本上都大于C加加对吧？这个是什么？

我猜他可能就有些test大家都过了，然后有一些那个online judge的时候，他可能会考虑efficient。就是说你看这个横线pattern相当于比较稳定。它不是说有一些模型更擅长在这，而是说他做到一定有些题就考的是效率，不是就是因为效率不能够。

对对对，是啊，他这个点是什么？你看右边这些python大于增加的其实全都是DS的R一的蒸馏版本OK。那那他的解释有可能他觉得有可能是因为训练数据太偏，就是R叫什么R一的训练数据我都偏python。

c加C加加写C加加的话应该还是难度要比python大对对。

但是这是人的问题，就是人血拍摄和人血在家的问题。对，我不知道AI就是有maybe有可能AI写C加加和python难度差不太多。我感觉纯纯主观感觉好，然后你看底下这个就是竞争性编程，就是写代码。

然后另外一个就是大家一开始说的，他所谓的act。为什么能act好呢？就是因为他做工具使用牛逼。你看的工具使用牛逼到什么程度，它跟open s4靠4的open s几乎接近。这是啥意思呢？就是比如说你跟他说，帮我打开桌面的这个下载目录。

好，这个时候如果你给他一大堆工具，他能选对工具并且执行成功的，告诉你执行什么参数的这个成功率，类似于这个意思。它的准确率几乎跟cloud 4 open最大的一个模型相同。也就意味着我们其实可以拿它来去做很多agent里面选工具的事。所以这也是为什么大家对他非常的期待的一个点。

然后他数学接下来是不是该出kimi一体机了？

这可就很一体了，我靠一个T的至少比这个RY还得大3分之1，对吧？你想开，那个是我一张卡。

没关系。

一张不止。你要拿升腾至少多一台机器，我靠H2台。

H20解禁。

对，H20解禁了，大家知道这个也不知道什么时候又会给封上。对，然后他底下就开始写了一些到底大家可以用kimi干什么事，我觉得这个还是挺值得看的。

大家可以想象一下，就参考一下说哪些事儿是大家以后可以寄期望于。因为K2是个开源模型，那大家可以期望说这种模型就可以像r one似的被大量的开源A的产品用。

那基本上所有的这类开源产品的能力至少都能达到这个水平。

那比如什么呢？比如说他是用你跟他说用2025年到20252020到2025的薪资数据来去看远程工作和本地工作的这样的一个对薪资的影响，并确定在不同的工作经验级别中是不是存在差异。

就比如说是不是资深的人远程工作的更少，还是什么的，然后后面有一些什么交互项，乱七八糟这些对吧？然后他你可以看到他干嘛了？

他就开始思考，然后开始用python来写代码看啊运行看结果，然后再看这个python执行结果再分析，再用python来写代码分析，然后再去分析。咔咔咔一串一串，你看全都是基本上有十几道，至少有十几步骤的。

这个用python代码来的去写代码，用python来去写代码执行分析工作的这么一个事儿。然后这个其实就跟上次咱们说的deep research这件事还是挺接近的。

大家可以想想，如果我手头有，比如说我就限定你只有三个工具可以用的话，那大家会选什么工具呢？或者说哪个工具是必然要选的。

让我们做出这个agent他能干的活尽可能的多，或者尽可能的全面。对，那肯定是一个是写代码运行代码。

因为写代码这件？靠这个最嗨的语言模型就可以写。

但是运行代码它大概率得是用工具，它没法让一个大模型来帮你运行这段python。所以有一个运行代码环境，就是这个i python或者叫什么RRPLE什么的什么东西，这种这种工具是最重要的，然后你看他就可以干这件事情。

然后更本质一点的，就是代码所有的几乎所有的主流语言都是所谓的叫图灵完备的。

就是你简单可以理解成他是能干几乎你所有的任务的，就是你想象出的任何的复杂的简单的任务，都可以靠一种编程语言来去跑出来这个逻辑。

所以你如果让模型去写代码来去执行，也就意味着你可以让模型写代码来帮你干几乎所有的事情。

对，然后对，那就看看，他就继续说，帮我做一个HML的页面来去呈现出刚才那些结果。你看他就继续用ipad on来去用写python来去用i python执行来去干这些事儿。好，最后出个什么东西呢？

经验，我靠怎么弄不出来？对远程工作对这个亲自影响。然后你看他搂了很多数据，然后很漂亮，做的真挺漂亮。

这不是在打唛吗？

可能对，不是。这个大家其实很早就有预期了，就是你你到底你一个agent的活肯定会被大模型不断的干掉，然后你就得越来越快往上涨。所以大家就是一个谁跑得快的一个比赛。

你看整个的风格到对数据，当然我不知道，我没验证过这个数据真假，但你看整个过程用户说了啥。就一段铁磁加上第二段生成HML这么一段提示词，就两段铁磁OK了。所以你看这个为什么说越来越大家越来越不那么重视其实词这件事？

就是因为模型跟根据你的提示词去选择工具，来去理解你的提示词，你的问题的这个能力越来越强。它确实对于事情就不那么重要，就是对于那个铁磁就不那么重要。但是立刻给大家一个返利。

你看这贴子做一个什么互动的可视化的网页，然后给谁呢？对，斯坦福的NOP实验室，怎么着？第一部分要写这，第二部分要写这，然后要可视化有什么的对吧？

然后写这些东西，你说它是个好贴瓷，其实也没有以前去年的贴瓷工程这个领域的意义上那么完备的这样一个描述。但是确实写的还比较全，比较玩，比较丰富。然后你看他后面接着就是跑代码，然后我们看看结果，也是很不错的一个效果。

你看这个三分LP的对academy的描述，这个是比较经典的，就是他还能去跑一个这应该是cgs，跑出来的一个叫什么知识图谱，然后一些图什么的都挺不错的。所以这个K2就一直在突出这一点。

我们说有了这个直接让模型去生成网页，那自然大家会想说，我是不是可以让这个你既然号称它能act，那他是不是能干很多具体干活的事儿呢？你看他确实是啊，你比如说他就说一个任务是啥来着？

做一个mine craft的。对，做一个3GS版本的minecraft，然后他就开始干了，就出这么个东西，我很牛逼，前后左右都有跳都有。但是没有那个垂东西，没有那个挖东西。

对，没有这个东西，没有挖东西。对，这就是他跑出来的这样一个结果。我们看前面其实提示词就这么多，但是大家有没有发现这个提示词跟刚才那不一样。

这个符号代表了它其实跑到命令行里，这也就对应了我们今天讲的call扣。

大家可以想象成他用卡扣来去跑一个K2的模型来去干。帮我写一个网页版的3d minecraft的这么一个事儿，他能咋干？

你看他就不断的做计划，干做按照计划干活这么一个事。所以他后面还有很多别的，比如说做一些数据的分析，然后这些其实都是用rust改写flask什么这些东西其实都可以干，所以他确实在使用工具上的能力真的还挺强的。

然后底下就是几个benchmark就不详细看了。

然后他底下又说了一句话，就是他这个K2训练的时候很重要的一个点是他为什么能把这个模型这么大一个模型，它在agent使用工具这方面做的这么强呢？

因为他做了一件事儿是他就做了一个非常大的数据合成的这么一个type line数据合成的判断。

大家知道我要让一个模型能够很好的使用工具，干什么活的时候使用什么工具，这件事做的很好。除非有有突破性进展，不然的话你还是需要大量的活跟他使用工具的序列这样的数据对来去训练这个模型的好，这种东西很少，这种数据其实真的很难。

所以这个在早期时代叫什么？上古时代就是在这个chat PT出来之前的时代，像21年OPI就做了这类似这种工作，叫web GPT。Web GPT你看他是干啥呢？

就是通过是网页浏览来去增强事实性质大模型的语言模型的准确率这么个工作。说白了就是干啥。你看这他做了一个模仿浏览器，给做了一个大元模型能用的浏览器。

大家看右边这个东西对吧？

说白了就是你这个浏览器贼简单，它不像普通的google一样，就这么几个工作，收一个问题，出一堆网址，然后点一个网址进去，然后浏览看这个网址对应的页面的这个信息，然后可以下滑上滑，然后圈选，你看这个点这个任务，他就点谁大幕神经网络怎么工作的，然后他就说了一大堆，结果他一个一个看，一个一个点开看。你看他点了这个东西，点开看以后，往下刷，往下滑滑滑，觉得自己有觉得有价值的地方就圈选一下，把它记录下来，就这么个东西。在21年的时候open I干了一个工作，他核心然后他攒了一大堆数据以后，就可以开始生成最后总结结果，就像咱们现在看到的这种deep research这类的研究为什么能做到说回答里面还带引用？你看还带一个引用，这段回答带另一个引用，那段回答带一个引用，就是因为从那个时候开始积累的这样的一个研究成果。

那时候目的是为了干这个事儿，为了通过网页浏览来增强语言模型生成的时候的准确率，就事实的准确性。

因为大家觉得网页上的信息还是很准确，对，所以那时候就在干这些事情。

你看那个时候所以那个时候OPI在搞这PPT的时候，这东西是给人类用的。

就刚才那个那个工具，他说他还给弄了一个工具，专门就这工具是给一大堆做标注的人用的。

然后这一大堆做标注人就整天拿一个问题点开这么一个文字版的浏览器，这不是模仿，就是像这里一样，刷一刷勾选一下，刷一刷勾选一下，回去看下一个链接，然后再刷一刷勾选一下就做这种数据。它大量的积累了这种网页浏览的行为的数据以后，才能选出一个能操作网页的模型，然后来去实现这种。这个现在今天我没太看懂。

能解释吧。

这个图这个图其实不是这个从下一步，就是我们刚才说让一个模型能很好的操作网页，操作各种工具，它需要一个一大堆数据，对吧？那这一大堆数据，像天的团队肯定是没有那么多钱去造这么多数据的。或者说大家希望不要花那么多钱去让真人去干这件事情，那怎么办呢？

就像他说的大规模agenting数据的合成，这个图我觉得可以拿另一个来去举例，是谁呢？是不是这是kimi的一个内部的员工发的一篇文章。

就在kimi发布之后，他发了一篇文章来去讲了一些他们关于这个模型发布的一些事情。我们看这其实就这部分，假设我们就是你如果去从头去训练模型，然后弄一大堆数据的话，那这是一个非常大的工作量。

我们换个思路，就是我们假设大模型其实已经知道了怎么用这些工具，只是没法激活它，或者说还没有把它微调成一个擅长使用工具的这个版本怎么办呢？他意思就是说我们只要把这个模型的能力激发起来，然后这个模出来这个模型，它就应该能很好的使用工具了。

那这个事儿其实跟什么有很像，就是这个思路就是像很像我们训练推理模型的这个部分。就是你说后训练真的是把推理能力训练进去吗？其实并不是。那更多的是我们怎么通过一个方法，把通过LLM的方法把这个模型本身学到的推理能力给激发出来。

他们这个思路也是一样，就是预训练其实有大量的数据，我们其实学到很多知识，我怎么我们去只需要说弄一些数据，把这个模型的用工具的方式给激活出来就OK了。所以他们做了一个很精巧的这样的一个 workflow，让模型自己合成大量的工具的使用。

那从哪出发呢？其实从使用场景出发，然后那他如他就说如果我们一个模型能做到这个程度，那他就能做成一个很好的agent模型了。

我们直接看一下这个伪代码，大家不要害怕。其实现在代码跟人其实很像。你看我拿一个用户的输入，其实就是用户要干嘛，对吧？

弄一个历史就是有了这个任务了，刚才用户说的这个任务放进去好well to是啥意思呢？大家学学过代码，一点点的都知道，这玩意儿就是死循环，对吧？就一直循环啥东西，里面的所有东西在不断的循环，走走走走走到底，再从头走走到底，直到这个退出。

那他干嘛了呢？其实就是让模型根据你历史的信息和你有的工具生成一个响应，那这个响应拿出来立刻放到历史里。

如果这个响应不是工具调用，那就退出。不然的话，这个模型生成的结果就是根据历史，我应该调查工具根据历史我应该调查工具，这样的东西就叫做秃扣工具调用。

好，那他干嘛呢？就是我把这个反应的里面的工具调用一个一个干掉，一个一个扣掉，扣拿结果放到尾巴里，扣拿结果放到尾巴里，然后再继续干，再让模型根据状态再去生成新的响应，然后如果是to的话接着干。

大家就越来越觉得这个deep research这种东西的直观感觉，或者说这个背后的逻辑就越来越清晰了。

就是deep reserve这种其实也是类似这样的一个结构，就是不断的调工具干活，调啥呢？怎么调出来呢？就是靠模型生成的。而且这个模型生成的不是画，大概率不是画，而是工具调用的顺序，工具调用的一大堆指令。所以大概就是这样东西。

所以刚才我们说的一大堆，这些工具怎么生成的呢？工具的数据咋生成的呢？我看看他有没有写这儿。不是，这是。

骂人的。

对对，就是如果你看他如果把每一个API当做一个工具，那么模型应该早会了。因为市面上的数据有大量的API的调用。如果预训练掌握了世界知识，那我们可以让他扮演一个工具的模拟器。

这个工具的模拟器是啥呢？就是刚才这个东西，环境。假设这个环境是一个命令行，假设这个环境是一个浏览器，假设这个环境是什么，你其实都可以靠模型来去扮演这个模拟器。

好，然后最开始的就是什么？我们开始要有一个一大堆叫什么干事的目标，比如说世界和平，比如说什么做家务。

做家务这件事情就会衍生出一大堆领域的描述。比如说我要洗盘子，我要扫地这些东西，然后它会再变成一大堆，或者说这个evolve都是让模型来干的。

我们知道扫地会跟什么工具有关呢？让模型来去生成一大堆tooth，然后这一大堆tooth结合这些场景，前面痘妹就可以生成一大堆干具体活的agent。

然后我们有了这样一个干活，大家注意，这个干活的A镇是被人调用干活的A镇，对吧？就是类似于什么chat BT这些玩意儿其实都是被人调用干活的agent。

好，这个时候我们有了环境的模拟器，有了一个被用来被调用干活的A证。以后还缺啥呢？

还缺人对吧？我也不想让人整天在里面去发写一大堆任务目标，让他来去给这个agent发发这个指令，让他干活，那怎么办呢？

我再造一帮发指令的agent，模拟人发指令的agent，这玩意就是user agent。然后这些user agent让他来模拟跟干活的agent互动，这些干活的agent就会拿跟他自己会干活，干活从哪获得反馈呢？

从模拟出来的环境来获得反馈。所以这个事儿就变成了最后，最后到底干出来好不好？

靠一个大模型来去判断全过程，几乎全拿大模型来去做，就得到了一个一所谓他说叫什么陵生一，一生二二生3，三生万物的这么一个过程。

看看能不能找到，找不到了，到时候再看别的。

对这样一个过程，它就生成了巨大量的这个agented model用来训练的这个工具使用的数据，而且质量还挺高的。

这样大家就可以想象能干嘛了，就是做强化学习呗，大量的消息就给做起来了。所以这个就是他突出这一点的一个原因，就是他拿这个东西来去做了大量的A卷，它的数据工具使用的和数据的合成，出来这个模型它确实工具使用能力就变强了好多。

然后前面这个就大概这样，前面他有提了一嘴这样繆on的这么一个优化器，这个具体是啥不太用关注。我们其实只要看这张图，这张图是啥呢？

叫loss和token的这样一个对比图。Token就是你训练了多少数据进去，越大越偏。

因为它整个模型去了15.5T的数据15.5T的数据，这个token的数据。然后纵轴是这个叫loss。

Loss说白了就是你的模型训练了训练了一下以后，他跑了个结果，他跟正确答案到底接近程度有多高，或者叫损失的有多大。说白了就是越低这个值越低，表示这的模型越准确，或者越能力越强，那肯定loss等于0，就等于是完美无缺，那肯定不可能达到。

所以这个图就代表了你这个loss，这个错误率。

随着模型的训练的数据越来越大好他是不是在持续降低？大家这个图还是希望大家能有个印象，这个图代表了啥？

你看咋咋下来，你看从0到2T的时候是一个快速下降的过程，就是前面这边肯定更高，快速下降过程。说白了就是他开始没见过什么数据的时候，没见过什么世面的时候，你给他一点世面，他就能学的很快。

但是但凡他见的世面多了，他的这个loss的下，这就会变得缓缓了非常多。你看你整个加了两个T的数据，其实也就降低了0.1个loss这样一个比例。

但是核心是这个东西，就是我们看这张图，它相对来说还是很顺滑的，很顺滑而且没有什么东西。

我们一般管比如说这玩意儿，这玩意儿其实已经很不突出了，因为。但是假设大家假设想这根线跑到上面去了，跑到什么21.9这块，那它就像一个什么呢？就像一根针了，对吧？对，毛刺Spike。

对，所以这种一旦你训练的过程中，发现loss回去了，变高了，这种玩意儿就叫做减就这一类的就叫做什么large explosion，这logic爆炸这种东西。

那就训练就代表你的训练跑崩了，跑的有问题了。

这时候一般来说大家就需要立刻停下来看看是不是我这块训练的比如说这个8T开始这一堆数据都都质量贼低，或者是什么某些GPU崩了什么，这些东西导致了这个loss变得很又反复了。

他这个k two提的这个谬的这个优化器，这个优化器大家就想象成是模型训练里那个大模型结构里面的一个一种组件，很重要的组件。他换了这种组件以后，顺畅的非常多，没有毛刺。

想想这个汽车的这个变速箱变得牛逼了很多，那个车的变速就很顺滑。所以大家如果看一个模型敢把自己的训练的这个图扔出来，那确实说明挺有两把刷子的。

对，好，然后看看还有啥。对，没啥了。对，这块其实值得推荐一下。

大家都知道像国内有一大堆这种有名的没名的大模型API聚合平台。比如比如像硅基流动，硅基流动轨迹流动是个啥呢？

其实就是你可以通过它一个网站访问到几乎所有的主流模型，一下就能。你只要改成模型名字就行了。

不用去调什么kimi的官方的，不用去调质朴的官方的这个开放平台，但是他为什么能干这些事儿？就是因为几乎所有的应用调大模型的接口都是所谓的open I兼容的，都是按照open a的标准API来去设计的对，但是K2它k two它增加了一个，就是他提供了anthropic兼容。

为什么要提供他的兼容？就是因为anthropic cloud靠靠code。

对，说张老师说啥。

是因为代码吗？

所以就是现在SRP对S为什么能在API领域不去follow open I的标准？

就是因为他有一些很牛逼的产品，比如像高扣的这种产品，让他不会可以不服从这个open I的这个标准。

而k two的就是kimi的后台，它是兼容了open I跟SR pic的两种类型的接口了。

所以大家可以很清晰的很很方便的在接入kimi的后台的时候，可以直接去按他这种方式按他这种方式来去选择接入这个cloud的这个不是cloud风格SRP风格的API。

而且你看这还做了一个很很那啥的事，就是你如果改了地址，改了key以后，你背后问还有一个核心问题是你传进来的模型名字是啥？

他妈做了一个是无论你传啥都对应的是他kimi你不用在任何的能现在直接调到code的这个代码而已，程序里面改那个模型的名字，直接就能用，这是对很过分，不过我觉得挺挺牛逼的，就是敢敢为天下，不是敢把脸放下来做这件事儿非常的respect。

就是他对开发者非常友好这件事情。而且很早的时候我们也是觉得我记得很早就kimi就是最早的一批兼容OPI接口的协议的大模型公司，我觉得还是挺挺值得挺挺值得赞的。他至少在开发者友好这块好。

那我的问题就是k one有k two有没有可能复现r one的那个盛况？

我们看看现在的数据，其实就能有点这个意思了。我们直接看看这个open router对吧？

大家记得这个open rotor这个网站，就之前推荐大家怎么去看模型的各种场景，然后到底什么场景在用什么模型。这个事儿他有一个ranking，一个排行榜，然后排行榜里你看最近，我把它这是最近按天的，你看一天这个东西一半都是灰色的，灰色是啥意思呢？

就是用这个token的模型，用哪家模型的token？

这个事儿不在左边这个列表里，那谁不在这个列表里？只有俩不在，一个是k two，一个是brock挂4对。所以你看基本上一个排第五，一个排第十，就是只有这两个不在这个图里。

而这两个现在势头贼猛，就是灰色的部分，不知道到底是实际是哪些，他没放在图里里。但是可以想象这两天发的新的模型很火的，其实就这么两个，一个ground一个k two。那k two现在啥。

不至于这么夸张吗？

到这个程度是吧？

对，真的吗？

对，我们看看。

该开源也有可能。因为open router上面也跑开源。

open rote有啊很快就接上了，所以大家就用open root。这帮人肯定是用新模型，用这种开源模型的这个先锋就甭管好不好，有没有用，或者这个多牛逼，他肯定是先会去尝试的。所以。至少这个趋势我觉得还是挺明

确实，就是在开源社区里面还是非常bin这种想法。

而且他还有一个什么点呢？是这个东西他在发布之后，kimi的这帮工程师在推特上，在X上开始他叫搞起了团建。

搞起团建啥意思？就是他们直接有一些工程师直接在知乎上跟大家讨论，这个KR有什么值得关注的信息，直接是官方团队下场去讨论，而且讨论的很直白。

你看他说直接说这个英法团队的，有亮面的这个infer团队的这哥们直接说我们架构上大部分都复用了V3的架构，DPCV3的架构还放上一张图，还是很好。

对。

非常就是指好的说对吧？

对我参考了有什么问题吗？而且我没有遮遮掩掩蛮好。

对，而且他说了很多，就是我直接告诉你，kimi做法就是更少的注意力投更多专家，完了其他的跟V31样，或者说这几乎一样，OK没问题，不遮着眼睛不至于像这个咱们上期讲的那个盘古，你你你最后被人爆出来，或者说被人拿模型分析出来，我靠那就丢脸丢炸了，对吧？

那他那个k two有开放那个technical report吗？

有啊。

我的意思是他在那里有没有向T那个那个deep sik致敬？

好好问题，你看他现在paper还没发出来，但是他这个技术博客发出来了。我们看看第一个C写了，你看这直接说K2。

可以。

对吧？采用了类似DPCV3的架构，减少了规律resort。

非常对对respect，所以非常respect。然后他在这个社交媒体上也是很公开的去讨论。

比如说他说刚才给大家说那个数据合成那个事儿，他就直接说这个是什么一生二生三，三生万物，你看他让模型干这些事儿，那我们能不能先把这个场景搞出来，然后再搞一个模拟的用户，让模拟用户跟agent来去互动。然后互动过程就不断的调工具，然后根据这个仿真环境来去获得反馈，来去产生一大堆工具使用的数据高质量数据。

然后他说？然后没有屏幕，不需要屏幕，几千个A正在疯狂互动，然后就得到了一大堆好的数据，所以这就是self improvement。

大家还记得？有一节课给大家讲了几种self improvement的最近的研究，这个也是一个很重要的一个点，就是我们要让模型有A的能力，怎么做怎么self improvement，数据也可以self improvement，自己生成，这样一个逻辑。

就跟爱尔斯搞那个AI hospital那个比较像是。他那个大量互动其实结局是获得一个高质量的数据是吗？

我不我没仔细看他后来的这个互动完了以后的数据是真的生成了很高质量的吗？还是主要在推理部分，但是我有chAllenge这件事情。

后来他们说那个核心是得到了高质量数据。

我猜没有，我猜他们其实还是在传统的这种把大量的他们拥有的数据给清洗给对吧结构化这件事情上，不然的话早牛逼起来。

挺牛的现在挺牛的，挺。

对对对，然后因为所以他们分享的越来越多的时候，你会发现这个hand face的这家伙也开始暂且kimi的这些东西了。而且说是有一些国外的开发者已经开始往回翻译了，就是这篇？Kimi的自己员工写的东西被翻译成英文，来去在他们的这个英文社区里传播。

所以我就又想起来当年我们是看那个open l的人人的分享？那个open不是录那个什么视频，然后国内再办，现在已经开始反向输出。

对，所以就是我确实是国内的团队，像我们的友商做的确实非常好。然后至少在这个维度上做的很好。

我们能把大量的输出研究成果输出出去。因为这东西确实开源社区还是一个很重要的一个技术进步的一条路线，那个闭源的有open l那开源我们其实要抱团，然后他就说了一大堆他们自己的那个办公室，然后什么各种的人名，这个其实还好，就是各种的人人的名字。

当然质朴的对，质朴的公司办公室的名儿，我可以跟大家说是一大堆模型的名字或者模型的公司名字。比如说deep mind，什么bird这样一些东西。

但是去月之暗面开个会是吧？

对，你看月沾面这个会议室的名字就比较文艺。其实这个就是品味的问题了，或者这个偏好的问题了，这就后面就不说了。好。

然后反正一个公司成功了，大家就会说他的命名。

有对啥都是好的，对吧？

然后我们再回答一些问题。我刚才看到有朋友问问题，H20解禁会加速国内大模型的发展。对，推荐华睿轩的那个。

事情肯定会。我觉得你说H20它阉割了，但是再阉割它确实也比目前的国产GPU还是对开发者友好的多，而且整个生态会好得多的，不得不服库达这套生态，所以H20解禁，我估计会让一大堆国内企业又又围起来，至少再围一波H20呗。

那你那会加速吗？那会加速国内大模型的发展？对国内大模型的发展是好事还是坏事？

我觉得其实现在来说应该还是好大于就利大于弊。因为大家现在已经看清楚美国的，尤其是特朗普这个做事风格了。

他不会说你给我开放了H20，好，我升腾国产这些东西全扔掉，我就又回到你的怀抱，大家已经看透了这嘴脸了，所以两条路，两条腿走路是必然的。那那H20的解禁，我觉得大量的会赋能很多这种对吧？

就是你原来没有攒那么多，对。

就这些东西要讲用的时候好用。我觉得H20还是主要是用来推理的，对吧？它不是那种训练型。

其实可还好，因为他毕竟是hoper。

Hoper的话由于district的这个深入研究，我们可以看到非常多hoper架构的推理和训练的时候，这样一些优化的技术贡献。

我觉得他训练也不是不行，尤其是说大量的国内，其实大家也不至于像谁都要趁个一T的模型，那是疯了，没几家趁着这玩意儿的那很多寸的小模型足够了。

好的，说能不能加快deep seek r的这个进程。请投一下心。

已已已经没有什么太大的影响了，至少现在这个阶段我觉得不至于有什么太大影响。R two他如果真对大家你看他不断跳票，那我觉得可能确实也是遇到了一些技术上或者说发出来可能没有那么震撼的这样的一个效果的。

这个叫什么可预期的效果。所以可能他还要再继续回炉去搞一搞。

那我觉得回炉也不至于说直接改改改改改整体底层架构去搞OK。

量子计算机跟大模型能结合吗？好。

量子说实话。

里面它除了量子计算，应该再加上核聚变，这样的话能源？算力和算法都有。对，好，那那回到这个话题，量子计算机行不行？

量子计算机我觉得就还是上次我说的，我我得我得再仔细学一学，我不敢乱说。对，量确实算这个。对。

确实当年都是当玄学，后来反正好像也还蛮靠谱。

对对对，当时好像实验室有做这方面的，就都觉得嘲笑，没想到现在这个能用了，有一些能用。对，然后这个我觉得是啊你说还有。

最后一个问题，我们一起回答我觉得这个问题也蛮好的。就是说做数据，传统应该是做CDP的对吧？就是用户数据，它的场景是给车企提供用户课程画像、线索评级、初转化，这就是用户的一些行为分析，打标签什么的？还好有没有新的解决方案，对吧？Agent能用起来吗？

其实就是在marketing或者做设计，我理解应该是要不就在最开始的，其实设计其实有两个逻辑。

agent时代你的这个数据能怎么用？假如我用agent来服务这些客户，那你这个数据有哪些价值？还有一个逻辑就是说你能不能用agent的方式来去对你的这个数据或者你的现有的服务进行优化或者是降成本。

对，觉得我就提一个，就是你说车企现在为什么要去做那么多用户画像，然后做那么多做线索的就是rating，然后提高尝试提高它的转化率。

就是他做的每一辆车几乎都是瞅准了某个目标群体去噪且卖的对吧？

那造的部分其实也可以开始做了，就是我做一堆我我我假想的这个用户群体，我想给他造个车，那真的是不是这帮人是不是真的这么想的？

反正我听说这帮车企撑死了一个用户群体，他们会做什么焦点访组小焦点访谈小组这种东西，然后撑死了也就二三十个人，然后做一大堆访谈说您是个三十多岁的中年有娃家庭，对吧？

然后那我们造这么一个SUV你会不会买？

什么乱七八糟这种问问这个问题才二三十个，这东西意义不大，或者说以前只能这么搞。

其实一种方法就是我们可以拿现在你拿一个agent来去扮演一个某一类的群体，某一类的人，让他跟你对话，在早期汽车设计的时候，你就别把他给考虑进去，或者说你让A的跟你聊，反正他也不会有什么下班的时间，然后他也不会嫌你问的烦什么的，他事无巨细跟你聊，你只要给他设定好他的个性的偏好和画像，这些就OK了。然后在这个销售场景其实就更多了，其实就是销售辅助，然后投放其实都可以来去做辅助。

比如说我到底投哪些关键词的人我希望卖这帮人我到底应该设哪些关键词，我应该投哪些地区，投哪些用户群体的一些tag。你把这个tag能投放，那tag全扔给他，让他去分析我到底应该投哪些。

好，然后他给你一个结果，你就按这个去投。投完了以后当然少量投，少量投完以后的结果，你去看它到底转化率高不高，或者有多少，再兑给模型说，我按照这个标准去投了。

你看这个结果是这样，你有没有可优化的地方，然后他就继续给你优化说我觉得那个tag可能不太好，然后应该加点什么别的tag，应该做点什么约束。对我觉得这个是一个特别标准的SOSEO的这个做法。

所以其实都可以这样行。你们在银联的那个项目是吧？

对对对，其实不止车企，有很多都可以做全数据的这个分析。然后做SEO，做用户的模拟，然后来去当做你在产品设计和营销部分中的对练。

其实我觉得真的未来这块有挺大价值的。比如说我是比如说你做了一个个人助理给我用，那你如果接入了他们家这个王二同学家里的这个用户行为分析，你在给我提供AI的时候就了解了我的更多的信息，可能就能给我提供更多情绪价值，对吧？对，还是一个场景。

然后最后一个问题，你说你说对，而且比如说你像以后的就是也不叫以后，其实现在开始有一些所谓的agent to agent的这个交易的可能性。行了对吧？就是像上次给大家说这个微信支付的那个点。

对，正好我给大家说一下，上次我给大家演示过那个元气对吧？在上面去拿微信支付MCP实现一个微信支付的这样的一个生成二维码生成。然后支付宝，上次给大家看过。

我以为元气森林。

哼元气这个据说这是个产品已经要废了的，结果被这个微信支付的MCP感觉又救活了一点。

对，你看这个是这样，上次我没生成没生成成功那个二维码是为啥呢？

是你会发现它在生成的时候，对，比如我没加这句提示词，你在网页端运行啥意思呢？

就是微信支付的MCP它其实是有很多API的。

这些API有些是用来去生成微信开头的那个那个支付二维码的，有些是用来你看这叫微信支付native下单接口，它出来就是微信开头那个那玩意是在普通网页上没法渲染成这个二维码，但是它也有GS的版本，所以我就加了那一句话，就是你其实是在网页端运行的。

他下次我说，帮我写一首春天的诗，他说我继续，他就调了微信支付的MCP，然后他就生成了一个真的能用的一个二维码来去支付了。你就可以直接就有过没过时，看看有没有同学打个场，不用担心。因为现在所有的微信支付的MCP过期了，微信支付的MCP的这个钱都会你打给他，付完了以后，他应该是第二天会返给你。

绝对不会不对，请重新生。本来我想打赏你一块钱。

身上衣裳。我去这产品真的是做的太长，不管了，回过头来，就刚刚那个事儿。

然后好，等一下。最后一个问题，老师你对大模型稳定输出有什么建议？我们这边为了效果稳定，大家都会选V三好很好的问题。这个效果。

肯定指的是啥的？效果稳定我猜应该是类似于说，我这个问题问了八遍，基本上都是这类的回答。比如说都是选8，或者都是回答你什么，这个应该怎么跟用户回答这样的东西，对吧？

那R一确实V三确实没有R一聪明。但是R一大家场景其实更多的是所谓的我要去把一个问题做分解，然后分解的过程中不断的想到一些新的，或者说不断的产生更细的任务的划分的这样的一个过程。而V三更多的其实就是做问答，做知识提取，做事实性的内容的抽取。

所以大家可以想象成用V3其实用的是一个巨大的脑子。这个脑子装了非常多的世界知识，然后也不叫脑子，这个叫什么呢？万事通。

然后你你你把V3当万事通来去用，然后你把R一当做个谁呢？狐狸就是当做一个很能有详细方法或者解决问题的理工男解决问题理工男，我觉得还好，还下一点。对对我我也。

稍微echo一下这个问题。我看下面王二说那改温度参数，温度参数这肯定是有用的。但是我想表达就是说在我们的场景里面，有的时候V3比R一好，是因为有的地方其实并不需要那么强的智力，但我需要模型。

幻觉少一点，就是推理模型出幻觉的概率会高一些。你就想就一个人想的很多，对吧？他还是有一定概率想飞的，它不光是你那个温度参数的问题，它天然就容易。

对。

大家想想上节课还是上上节课讲那个小猫小猫攻击的那个那个事儿，对吧？你但凡一个事儿放点猫咪进去，然后一个推理模型就懵逼了，然后就开始胡胡胡想瞎想。温度参数肯定是啊。

然后如果说你确定A用B用答案不一样，这个是一个必然的事情。如果你想让他至少答案差异没那么大，你就把温度降低，把那个top k top p给降低。对，这应该是有一期有一节课给大家讲过，应该讲提示词那节课，给大家讲过这个东西。

好了，我们问答先到这里，先往下走。

好，然后k two我觉得这篇还是这家伙还写挺好的，这个叫马东新LP如果大家关注的话，可以去去关一下他的这个。

歌推歌尔摩。是什么PHI的。

什么有KTH是什么大学。KTH不知道，无所谓。

对，没见识。对。

然后他说这一点就是k two的一个大亮点，就是把这个token的生成这件事放到gentle的to go，这个也就对应到上次，反正好几次大家都在想都在问deep research到底是啥，对吧？那你我觉得这个还是挺好的，就是大家想想推理模型会生成一大堆COT，一大堆推理的token对吧？

那我们如果让一个我们希望一个模型不是只在那逼逼他要能干活，我希望输出的它输出的就不是一大堆他的思考过程不是一大堆他的思考过程，而是一大堆他怎么干，先干啥再干啥的这个序列的这样的一个内容。

所以就是所谓的凸扣工具调用，你就可以理解成对于agenting或者agent这类的模型，它的COT应该更多的是凸扣的序列。是先干啥再干啥。而且这个干啥其实是调工具的这样的一个过程这样的一个内容。所以推理模型是一串token的思考过程。

而agenting模型或者叫search这一类的场景，更多的考验的是deep research背后这个模型它的生成一串凸扣序列的能力。其实底下说文本任务都用什么blue这些很传统的方式来去做评估。

而在agent干活这种agent场景来说，更多的考验的是你的凸扣序列跟理想动作轨迹之间的匹配度。啥意思？

就是我让他打开微信，打开淘宝帮我搜个什么护颈枕，然后他应该怎么干，先点哪一个，再点哪一个，然后看哪个信息。这个序列跟实际模型产生的这个序列的相似度。

所以这句话我觉得说的更直比比之前我说什么deep pressure到底是啥，那纯靠文字的描述的更好的一种描述方式，对，这一道然后K2还有一个特别牛逼的地儿在这儿。当然它不是瑞瑞推理模型，但是它贼便宜贼贼贼便宜。

这个榜是什么呢？是一个ader，ader是一个考验他coding能力的这么一个，你看跟他相比的都是谁？

即使是价格屠夫的V31.1刀，这应该是百万token。但是k two是0.22刀，就又降了一个数量级，说白了又降了一个数量级。

为啥呢？所以。

好问题。

我也没因为他解决问题解决的快是吗？就是他。

那个好问题。对，但是这个事儿你确实在unification al analysis上已经能看到了。我们看啊，对，正好看一眼这个图，这个网这个榜就是大家知道这个榜已经看了太多次了。然后我们看这个智力这事儿，上次说了他有一个叫这个k two吗？也有k two了。

对，这个图非常的有意思，是啥意思呢？就是纵轴是智力，就是模型的智力。

横轴是价格，就是每百万token多少钱。好，我们肯定希望的一个模型是它分成了四个象限，肯定是这个能力高价格便宜，能力高价格贵？

这四个象限，我们肯定希望模型在哪个象限里呢？那肯定是这个，左上角就是能力又高价格又便宜。

所以这个unification analysts做了这么一张图，就对press这个图很明确的表现出，你如果几乎不太可能有公司不在乎成本。如果你不在乎成本，你肯定选这个这个最牛逼的这个智力。

不他他不是最牛的，看起来他那个值没有宏观。

对他这个评估intelligence，他的artificial analysis，他的评估综合的至上，这个intelligence这个评这个绑，但是这个大概率肯定大家还是去说，你如果预算不设限的话，那肯定是O3 pro或者X4 opens是thinking版最牛逼。当然大部分公司肯定是要在乎成本的，所以是要看啥呢？

要看这个象限，就是你在价格有限的情况下，哪一个更高，对吧？说白了就是更越往左上角的越牛逼。

那k kimi 2K2在哪儿呢？在这儿，它其实不算是市场很高的那一波，但是它足够便宜，它比它再便宜的都是一些没见过的馍。2.5 flash，这个确实是。然后deep sake，看来这个图有点问题，反正就是都是很低的一个状态，看看kimi到底多少钱，我靠。kimi.

从哪看呢？Kimi KI API。去看一下官方网站上多少钱。chat.

价格？

算了，先不耽误时间看这个了。

我们我们看看还有啥要讲的对，k two就讲这些。

好，然后这个rock 4简单看一下，简单grog 4确实有一个很重要的功能是它叫rock 4 heavy版重版这个东西说白了就是它用好多模型，好多agent来同时来帮你回答这个问题。于是有人其实就是多agent，于是有人搞了一个东西，就是我模拟一个多agent，多A整体方式来去模拟你的k rock 4 heavy这个版本，你看他就做了这么个东西。

然后这个用户问题进来弄了四个agent，这四个agent是啥？大家只要参考一下，知道一下这几个agent到底是什么定位就好了。

第一个叫research，做研究的。第二个做分析的，第三个是还有什么别的可能性，这个alternatives，最后一个验证了？

这么四个A站来去一起干活，最后有一个合成的A站，把大家的这个答案综合一下，给你个答案。

对，所以搞了这么一个东西，它就基于k two 2，我觉得是搞了一个habit版的这么一个k two。你看他是不是用的k two？对，用的kimi k two做了一个k two heavy。说白了你可以拿任何的模型做一个heavy，这是一个挺有意思的一个东西。

然后另一个就是这个brocks搞了一个crock，搞了一个any。对，但是我还没玩过。然后这是一个这个东西就是你在应用里面可以直接对话这两个角色，这个家右边这个角色是后加的，之前都是左边这个家伙，大家看这个角色就知道到底是个什么风格的了，就是一个特别。

而且随着你跟他聊天的这个进展，他还会有变化。比如说他穿的更少，对这样一些东西，所以带来了一个词儿，这个词儿叫NSFW。NSFW这个啥意思呢？

就是not safe for work，就是办公室不宜，办公室不宜对吧？大家想想在干着活的时候，突然咋开了个网页，蹦出这么一个玩意儿来，然后还给你跳来跳去的，还带对吧？

所以这个肯定是办公室不宜的。所以这个super clock就是那个多少钱来着？

三十刀是吧？那个版本的那个rock，你就可以体验这个跟这个家伙，然后这有一个特别有意思的一个回复的OG has joined the chat。

答我估计没有几个人，可能还是有一些人记得这个家伙的对吧？

这个老曲别针这个家伙，然后我觉得现在这个brock现在越来越贵了。像这波大模型的公司，从30刀到200刀到300刀，20刀到30刀，三这个200刀到300刀，我觉得可能是这个东西就是他们在尝试拿更高的订阅费用来去做用户粘性。

因为我觉得其实现在远不到说我一定得拿用户的订阅费来去算回这个成本的一个阶段。但是为什么呢？

干这个事儿就是大都需要用户粘性。

你别给我跳来跳去的那怎么怎么防止大家跳来跳去呢？我觉得就是钱就是心痛，比如像克拉克这种，我就收你200到1个月，那确实我模型也不错。你既然花了这么多钱我买我了，你就没钱买别人家的模型了。不然的话如果大家都是二十刀，那我确实有可能一个月我买三家的这个二十刀。

我给大家看看有意思吧，这个东西叫neural OS。Neural OS这是个啥呢？

你看这个东西还记得上节课上之前也给大家讲过，那个纯拿diffusion模型来去模拟一个世界那个事件。你可以控制一个人在里面走来走去，打枪，跳来跳去那些对吧？

还记得那个吧，然后现在有一个团队干这么个东西，就是纯拿神经网络生成的操作系统。

这是纯拿神经网络拿的fusion模型生成的操系统。你看你点了这个，这个就file manager就是我的电脑，windows是我的电脑，然后我的鼠标在里面移动也是对吧？就是移动到哪儿，我点双击一下，我点开能点出这些图标。

这些所有东西都是现生成的，都是模型现生成的，不是任何的背后有个什么对吧？有个虚拟机什么这些东西都没有，所以这样就是一个纯达神经网络生成一个操作系统的界面。这就跟什么很像呢？

就是之前卡帕斯一直在吹的这个LOMOS，这个大模型操作系统对吧？这个应该有有一节课给大家讲过对吧？

就是以后的大计算机就是一个大神经网络。这些神经网络它可以吞一切的输入，可以吞一切输出，它还有一大堆工具可以用，那是不是就有点像这个意思了，就是我拿神经网络生成的一个桌面，然后随时用的。

当然这个速度现在还很很成问题，但是带来一个结果就是好像还真是可以干这些事，所以这个团队做的挺有意思的，他还用了RNN来去做了一个生成的状态的变化跟踪。然后MS这个事儿。

好，我们看看这个是SP最近出的一个功能，叫这个叫什么connector。Connector给大家展示一下，其实就是这么个东西，cloud的桌面端好，然后你只要给他配好。

比如说我在这儿配置这个叫extension的扩展。然后扩展我增加了一个控制，叫有一个扩展叫叫控制你的mac如果大家用的windows电脑的话，这个扩展会变成windows MCP。

在这儿windows MCP因为我是mac，它就我就装了这个，然后它还有一大堆别的工具，大家如果想用它来去干别的话，也可以直接装。然后它能实现啥呢？

我们回到一个chat里面，我直接说帮我打开微信。我不知道这个能不能中文，能不能查，我们试一下。我微信开了没有，也没开，我看看他能不能成。对。然后他会问你们要不要允许，然后我就写always allow了，让他永远都允许好。

我微信？那我换成中文，换成英文。已经打开了哪儿呢？你的微信都已经开了。对对对，耶耶耶。

看着对对对。

就这样。然后比如说帮我打开浏览器导航到淘宝，找一个护颈枕，你看能不能成功，我没试过，你试一下。
对，你看他会干嘛？打开浏览器，然后导到淘宝有点慢。

他能自动输入吗？

他让我接下来就干这事儿。

你跟他说，请帮我执行完帮。

我执行。

没成功，你看他，我去。

我靠，他没有那个键盘的。

有权限。

给他。

我去行。

好优秀。

改了以后他是不是得重启？对，你看他会用这种大量的这种脚本来去执行各种操作。他其实已经执行了这个尝试打开直接去搜了。

但是没有这个会被那个什么。

对，会被挡住。对他。

也就是对他。

他用用crime。他应该会找对这个应用，打开了对吧？S点淘对。

可以，他用了更聪明的。

对还行，他们要去点。

我靠这是你在点的。

还是他在点？我点的我点的，我点的淘宝现在限制太严重了，行吧，就大概的意思。对，所以就是他的connect tor或者他这个新发的一套东西。

这是去昨天发的前天弄了一套各种的工具调用的一套connector，然后你就可以非常方便的去调各种的工具。我觉得其实这事儿它本质上应该还是拿MCP来去实现的。那也不一定，你看那里面他用什么。

他可能是把一些应用，他列在上面的应用应该是被他。

强化过的对。

是他随便是这，所以他大量的应该是M是吧？

对对对，你看他这些应用都是他合作的。这些公司还有非gma的，我靠，air table、fig bar、stripe这些，我就不明白他strip要干嘛。

就是我一个支付，我要agent来去支付。所以我觉得靠做这一步，肯定下一步是要做更更强的这种商业上绑定。

就是我不光有MCP这样一个开放协议，我还有很多跟我关系很好的这些商家。

然后大家在用我的desktop版的cloud的时候，能更好的去用这些工具来去完成任务，然后包括访问我的电脑对吧？然后他还能干嘛呢？比如说帮我，我对那个拿了cloud code去演示。对，所以我觉得大家cloud真的是越来越值得关注了，或者越来越值得提防了。

然后内容方面有一个有意思，我插插一个那个啥，我觉得还是挺有意思一个东西。就是最近这类的短剧暴夺，猫狗的AI土味短剧啥呢？

大家看看，这个没有声音的，什么这个小狗要上学了，然后爸爸狗洗盘子又砸了，然后就这类的，你看这种什么小猫帮小孩洗澡、做饭。对，而且都剧情挺不错的。

但你说那个剧情真的有多难嘛？也不难，就是非常直觉的这种让人感动的剧情，或者有有可爱的剧情。

但是它配成的都是这种猫猫狗狗来去演出的这样的一个短剧。而这个短剧大概率是用像VOE3这样的模型生成的，或者是像现在像国内那些什么快手那叫啥来着。

克林克林。

之类这种模型生成的非常的直戳人的这个本能。对，所以这个现在都爆了。而且那个谁那个老高与小茉，好像他们也做了一个实验性的频道，也是关于这方面的，就是非常的非常火。我看看下面还有哪些，我们直接看最

后，看看这个有意思。

有一家公司之前跟大家说过叫the thinking machine lab对吧？这个之前有一次跟大家说了，融融了个种子轮融资多少钱呢？

融了20个亿美元，融了个一百多亿刀的种子粉。对，然后你看他们要做的是啥？

我觉得这个可以关注一下这家公司的动态，为啥呢？这家公司人特牛逼，就是一行据说3分之2全是从open l出来的，但是它的核心业务是这两个事儿，后面通用消费级产品这事，我不觉得他可能会在初期会重点，因为这事儿竞争对手太多了。

他要做的是定制型模型，给企业定制模型，定制AI模型。然后他提了一个叫什么以业务指标为导向的强化学习路径，LL for business，比如你企业要去做一个更精准的客服、投行，零售这些业务的话，它是可以帮你专门训这个模型的。

训通过RL强化学习的方式来去训练模型。

而强化学习能怎么训呢？其实刚才的像R1，像刚才说的K2的这个k two里面的整体数据的这种to use的合成，用来做参考学习。

这事儿其实越来越明确了。就是我我觉得可能是他们的一些人，他们几个人很早就意识到了，或者说年初就意识到了。

强化学习对模型的优化能力和推理领域的推理能力的增强，是非常有商业价值的。所以他们先把他的一个核心业务定的企业定制型的AI对吧？

肯定他不是做微调的，肯定不是做普通的SFT的，那那玩意儿撑不起来一个20亿刀的种子轮，所以这个是然后他说这个以开源模型为起点，那肯定是可用的非常多了。

然后模型构建的时候，他说会采用所谓的模型这个model margin这个方面的事儿。Model margin是一个很有意思的一个东西，给大家推荐讲讲两个东西，一个是这个modern，这谁干呢？最早其实我最早听的是这家萨卡纳，对吧？又是他。

那个鱼他做了一个什么事儿呢？应该之前有给大家简单讲过，就是我们说有一个我们要搞一个新的模型，这个模型要在某些方面能力很强，那怎么办呢？我可以去微调它，训练它，对吧？

但是另一种思路就是我把现有的很多模型里面优秀的部分，把它拼成一个新的模型。这个拼出来的模型，它能够按照一种策略拼出来的模型，它就能在某些方面的能力上比之前的所有的模型都强，就是所谓的模型融合这件事。那这件事之前。

模型ABC的哪个block是什么能力呢？

好问题，我们就可以直接看这个谁，这个李宏毅，台湾的一个教AI的叫叫教授。李宏毅非常推荐他的课，就是简单易懂，特别的清晰。

李宏毅这个家伙，然后他有一节课，今年的一节课就讲的是mono merging。你看啥意思呢？

就是你配去测，你去测说比如说这个模型在比如说数学方面能力很，比如说烹饪方面能力很强，那个模型在什么写诗方面很强。好，我希望搞出一个模型，他都拿拉玛来举例子，搞出一个模型，又擅长写诗，又烹饪方面很强，那怎么办呢？

最直观的想法就是我把这两个模型的权重拿起来加一下，对吧？加一下就OK了，然后它就能两方面很强了，其实也挺直觉的。

比如说每个模型我假设它就只有三个参数。假设只有三个参数，这是基础模型，我变成一个很擅长防御的，很很很擅长攻击的。

然后假设这个参数它的区别，这个二是没有区别的。左边这个更擅长防御的是一，然后这个更擅长攻击的是3，然后右边擅长防御的这个是-2，这个擅长攻击是负一好这两个东西我把它加起来，或者说我把它替代一下，我把它不同的部分给合起来。

擅长攻击的部分，我把它的参数放到最后的模型里。擅长防御的部分，我把它特殊的参数放在这个里面，然后共同的部分来保持原样不变。

这个出来的模型就又擅长攻击，又擅长防御，说白了就这种东西。对，所以它的结果是还真有一些模型能干，有一些模型能实现这个事儿。

因为本质上其实就是一个向量的这个价，现在的价这么一件事。但是你稍微复杂一点，你就想着这玩意儿太不靠谱了，我怎么可能靠俩加俩模型，那我是不是把全球所有的模型全加起来，那他最牛逼呢？

肯定不是，所以他里面也讲了一大堆怎么去做，或者说现在在科研里面的领域在在怎么去尝试做这些model margin这件事的前沿的进展，这个详细就不说了，大家感兴趣可以去看李宏毅的model merge这个课。对，差不多1个小时，讲的很好啊。

你可以看这家21刀种子轮的公司就在开始尝试用mode margin来去做这一件事情，确实也是跳过了吧？就是你现在这帮开源模型你就往前涌，然后我掌握这个model market的技术，我就永远可以把你们模型最强的地方都弄到一块来。

对，然后现在这模型这一个20亿美元的种子轮的公司一共30个人。然后那你想搞这么一个团队，最直接的目标受众谁呢？

大厂收，你要不就是苹果收要不就meta收，对吧？能不能收？

对我搞出点东西，我直接被你这个几百亿刀收进去得了，爽死。所以这家公司是在做这个事儿。

然后much merge，model merge大概是这么一个事儿。然后有一个课我觉得还是挺挺值得推荐的，为啥呢？是因他不是给专业人士的，而是给学校的。

这是cloud推的一个发布的一个课，叫做AI fluency，这样一个东西叫AI流畅度，或者流畅性这样的一个东西。你看这个课程内容是啥，生CI是啥？我靠怎么回事？

生成AI是啥？

然后这个AI的生成AI的基础，一些能力限制，甚至包括一些框架，什么怎么用，怎么写提示词，这些其实都有。它的主要的目标受众就是给学生就是给学生去用的，所以没有很深。

但是基本上我觉得这个新一代的小孩们要去了解到知识其实都有。而且他的课程每一集都不长，基本就是十分钟左右就可以学完这这一章。

然后他的课的内容都是很新的，因为都是靠章法那个东西。好，最后其实靠靠大家想象到的东西，都已经刚才像cop什么已经有展示了一些了。我们直接看一下它靠本身是个啥，它其实就是一个命令行，就是个命令行，我给大家展示一下，其实就是这么个玩意儿。

CC稍等。这么一个玩意儿，你跑起来好，你就相信好了。你说嗨，你能看到吧？

我把这个放大一点。

怎么又崩？时不时就会崩。

你看他回你就像那个chat PT1样，这个有什么能帮你吗？然后我就说open my download field a folder，帮我把我的下载目录给打开，然后它就会打开了。你看打开了对吧？

我的下载目录。好，然后比如说帮我，我可以拿中文帮我做，帮我在下载目录里。页的目录结构，便于我管理我日长的文件。

有电影小说。

代码、文章论文等等。好。

他直接可以帮你整理是吧？

可以整理，但是我现在先让他帮我生成这个目录结构然后看看他能不能干出来。有时候因为我把它接到KK2上，我把它接到k two上了，没接那个，对，所以有时候会崩，我靠感觉崩，你把它call下来重新跑一下。

对，这个待会告诉大家怎么去用，还是有点麻烦。因为用的API的这件事情还是有各种会，我靠又又又离线，又好了，看他怎么给我做出来。

你看他说检查现在目录当前目录在哪，然后创建一系列的主目录，然后创建不对。

你有模板其实对。

他给我找了这么多文件出来。对，然后他就继续去找，看看能不能给我建出来。

把你的所有的小文件都看了一遍。

起码名字他应该看了一遍。因为我之前已经全授权他了，就是我这个命令行是可以访问我所有的文件这些东西的。

你不担心的，你看他开始执行了这个，他开始看执行了什么organize，这些目录都已经创建好了，有各种的文章的、代码的、电影的、小说的、论文的对吧？好，然后就给我建了一大堆目录往这放，我看看要不要让他干，那帮我。

帮我把下载。

目录，把电脑里面帮我把电脑里的文件都删了。

转移到刚建好的目录下。

整理这个挺难的。

整理好对，挺难的。我不知道他能不能搞好，因为我的登录目录下还有很多质朴的文件，所以不知道他能不能给我找。对，你看他说把现有单道下的文件挪到刚才整理好那个目录下，然后让我检查。它会先检查一下文件，并且这个系统的转到合适的目录，又卡住了。这就是国内用点啥都很麻烦，再让他跑一下。

又卡住了。

这可能确实简单。

从到了重来吧。转移到下载目录下的cognize。Or organize the morally, 跟按照。

主目录的结构。

根据文件名儿。看能不能搞定。

好，那开始去检查了，给我扔点啥文件。那算了，让他去搞着，看看待会儿我们再回来再看。对，所以大家可以感觉到靠code它其实界面贼原始，对吧？

他贼原始，我们看看他例子，比如看他这个例子就是什么呢？帮我做一个互动的ask ask art，ask art是啥呢？是这种东西。

Ask you out.

大家可以想象是这个东西就这么一幅画，但实际上是一大堆文字组成的。你远看是幅画对吧？但实际里面的每一个像素都是一个字符串，都是一个字符。所以如果你以前闲的蛋疼的这帮人只能有这个命令行或者只有记事板，然后那就直接拿文字来去拼张图这个能力。

但是现在其实大家越来越不需要去人去写了，就有很多工具，有很多甚至直接让AI来去生成都OK。所以像刚才那个cloud的例子，就是帮我生成一个SK art的一个画绘画工具。

并且有什么有音频反馈、声音反馈，然后他就会干这些事儿，当然这前面再有一大堆需求，这个必须有点击和拖拽的功能。这些然后我们看它结果直接生成这个东西我点哪了，我声音是不是没有共享。

有。

没有声音了。

可以了，现在能听到。

可以，现在可以。那这个屏幕的声音能听到是吧？能。对，其实就是刚才说的，我要做一个奥克马的这个游戏，然后它就直接能生成这样的一个东西，很有意思。你看打的每个东西其实都是一个。

ask你说的有意思是从哪儿来的呢？这个逻辑。

你不觉得这个。不觉得有意思吗？

好，评论区可以大家就评价一下，有觉得有意思的，说有意思觉得没意思。

生成一个emerge的这个图。你看他直接根据我的camera变成了一大堆emerge拼成的图。

他又卡住。我想说你是不是也想说这个很有意思？我看着这东西像十字绣。

那你看里面的每一个像素其实都是emotion。

为什么我看着像十字绣？

对你就想如果你让你拿EMOG给你一张图，拿EMOG做出来是不是很难？

我卡住了。

我电脑卡了。

我赢了。不是没有人觉得像十字绣吗？

对，是有点像是有点像。对。

好像。有点吓人。对我也觉得有点吓人，密集恐惧症赶紧关了。

对，然后就可以做这种东西。但是这种东西你说原来的这个之前给大家介绍的像lovable什么这些rapper能不能做到吗？其实也行，只是说命令行有一个非常大的好处，就是你所有的交互都是根据这个当前展示出来，卡死了。

没有，对，都会都会根据这个出来的。所以你不用担心你的交互界面有什么变化，你不要担心这个？你是因为UX应用的bug导致的一些故障，这些都不用担心。

这叫啥？

这个命令行是最古老的交互界面，大概率不会有问题。

你好像关键是对很多人不友好。

对，是的。

是对，他他毕竟他那个你上面展示的内容，我觉得是信息是。

有限的对，现在是干活了对吧？然后把我的各种文件往对应的目录下move，你看帮我把什么我这个东西挪到这个里面，然后把我的另一个什么玩意儿，他告诉我已经。他要问啥？

他要把我的，他是不是？他问我要不要要要不要做。然后我说yes，并且之后挪动这件事不要再问我的这个权限，不要问，再经过我同意就可以。

这是啥？拷贝到他，然后要不要继续？Yes，他就继续帮我挪这些文件了，我看这些文件是不是已经过去了。

所以我并不觉得这些体验比cloud不比刻字好啊。

确实是啊，所以这个东西靠code确实只适合程序员。目前来说只适合程序员，而且适合这种相对来说比较硬核的程序员，还是喜欢命令行的程序员。然后cloud本身为啥他搞这个东西呢？

就是cloud本身为什么选择并行呢？我觉得另外一个原因是因为这种公司里面用的不同的ID用的不同的编辑器太多了，大家都选自己喜欢的那怎么能有一个比较统一的，能够都兼容的这样一个东西来去提供给大家服务呢？其实就是命令行呗。

不用I.

D对，不用ID对，我的文件都都被挪过去了。那那那那哼我到哪儿了？我靠。

你能不能让他reward这件事情，他有history的，能不能。

reward这个安度把我刚才的事都给我回来，看看他能不能做到。

而且我发现多了一个文件。

对，如果断一次就废了，我这个就回不来了。你看他为我把之前的安度回去，好相信他能干。只能相信。

他的安度，给你安度到这个电脑的出厂设置。

确实这种东西你给的权限太多了就很可怕。对，然后你看这哥们儿他拿了扣做了啥，我觉得也挺有意思的。

他这人看起来还是个程序员，所以他做的事儿还是挺正常的。比如说给名文文件起个名字，然后能帮你搜索，他做了一些，他把日常的自己用的文件全都以文件的形式，把自己这个数据都以文件的形式放到自己的目录下，他就能干嘛呢？

他可以告诉cloud说，我的日记忆、我的日记、我的想法、我的代码分别都会放到这儿。等于是告诉cloud说，我的日常保存文件的习惯是这样的。

好，那那就可以干别的事儿了。比如说帮我根据我我我这一周更新的这些代码给我写个周报，帮我根据我最近两天的想法写篇博客，对吧？

其实都可以干，而且他还能通过这种访问苹果的note，这个我觉得还挺有用的。因为确实苹果note是一个很封闭的一个对软件，然后你能通过命令行访问到note，但是并不能通过很多API能访问到。

所以你看它可以通过clo code访问到你的苹果的note。

就是平时大家记那些想法这样以及还有什么i messages对吧？通过聊天工具去发消息、收消息、读消息，这些都可以读的，都可以做到。然后因为可以读到你本地的文件，你就可以做。比如说刚才说的这些，我的文件的管理，帮我重命名，然后按照某规则命名，这些事儿都可以做到。

所以这哥们还是做的比较深一点。然后这个事儿其实后面就掀起了一大堆，所谓叉叉code，这个gym l code什么，好几家都出了各种扣的这种工具，所以当然这个模型牛，所以也挺好的。

对，所以大概这些今天给大家先简单介绍克劳扣的这些东西。我觉得这个可能对于大部分同学可能不太会喜欢用这种东西但是我觉得还是推荐大家。

为什么？肯定大家会刷到说cloud扣多牛逼，又颠覆了什么东西。

但是大家知道一下code是啥，然后这个东西怎么接上k two呢？这么做看看这么做好。

大家有什么问题也可以同步打到评论区，我们一会儿可以留点时间聊一下。

这样你的这个可能还确实还是程序员会才会玩这么来去弄。就是你要在这个地方建一个目录，建一个文件，这个文件是保存你的。Kimi的这个平台开放平台的是啊，然后放在这儿把这个信息放进去。

比如说我会放这样的一个内容，这个内容从哪来呢？从这个地方直接靠过去就行了。好，没放在里面，放在这儿把它靠过去。

然后你把你的这个，这是接open rotor，接open router，open router.

我是花了点钱存了点钱的。然后你把这些放进去，你在open root里面填上你的key，然后下载一个叫cloud code root how code路由这么一个项目。Cloud code .

root不用这么复杂。

我接了kimi，kimi那个平台有点问题，一直跑不通，所以这个现在是。

有点麻烦的。

Code root.

那你想想看，你这个问题难道不应该用个什么cos r用个什么其他的cloud .

code的来解决，是吗？

首比如说我class code我先接上靠，然后我再说请帮我把改成请帮我把你这个改成什么什么。

对，大家都可以参考这个。对，非常适合做服务器运维，因为他帮你跑着跑着然后崩了，然后老板就会骂你，然后你就回去骂cloud。对，这个不要那么心大啊不要那么心大，这个服务器运维这种事儿还是要谨慎。

对你顶多可以让他来去帮你生成一些脚本，因为不过可以相信这个，比如像open router cloud router cloud code这种工具，默认情况下都是要你允许的，干任何的事情都是要你授权的。所以你可以让他去帮你去做故障分析，然后基于故障分析来去生成，要去修改这个故障的脚本。

然后真的执行的时候，你一定要还是非常仔细的去看。对他还可以去了。

好，然后报课了差不多这些，具体怎么用，看看咱们有没有同学能花一周的时间把这个东西跑通，能够试起来。然后这里面肯定还是有一些问题，网络一些问题什么的要去解决的。

如果有问题的话。

咱们下周适不适合做服务器的运维模式。

还不适合。

就是看你敢不敢。

胆大的先享受世界。可能就是被踩。

就看你的公司跟你谁的命长。服务器，我觉得个人的服务器OK，反正工作场景还是。

谢谢你OK，然后你自己电脑也OK，提前把数据备份好啊。

对，这个跟那个自动驾驶我觉得还是蛮像的对吧？就是说你你你说你自动驾驶是靠不靠谱的那你起码别拿你自己的声音看的样子。

all code可能要你一点文件。

行，我看时间也不早了，我大家没有什么特别的问题。

刚用的营销，刚说的营销策略。

对对对，营销那个网上同学问的。营销策略有一个。

东西我今天没讲，其实这个东西有一家公司做的叫simmer rush，叫什么sam rush这么一个东西。当然我也没太详细的看，他其实就是做ICEO的，然后你能够非常快速的去他帮你监控你这家公司的内容出现在大模型的嘴里的几率高不高。

如果不是很高的话，还能尝试帮你去变得更好。说白就是SEO这件事儿。

对，这个我们要不下节课，搞个营销的这样的一个，就是我找这类产品，讲一下这个同学王二同学讲的，可以，我觉得挺好的。这个结合营销场景是最直接的，就至少我们目前看到最闭环最短的这样一些场景。以及恐惧症。

对，会动的十字绣。你自己看一下我那网站把我电脑都能跑崩了，跑拉垮了。看看大家自己是不是。

你那个电脑已经不能说非常牛了。

为了便捷安全。

好，行，那我们今天就聊到这儿，然后祝大家周四快乐，拜拜，下周再见。