

Hello, 大家好。看看，大家听听我声音OK吗？OK的话帮我扣个一。好，我共享一下屏幕。

能看到？没问题，OK。好，有点小是吧？我声音大点，我尽量声音大点，我听到声音大点好。今天我我我在今天这周休假，然后跑到东北来了，所以今天是在车里面直播。然后如果有什么网络不好的话，大家随时跟我说，我看看怎么能把这个窗口挪到旁边去，一直能看到。看好像行好好，那我们开始。

今天的第一个是这个东西，第一个是google前段时间发了一篇文章，就是讲他到底大家其实都有一个问题，就是都知道这个大模型跑的很成本很高，然后要跑很多GPU。然后模型很大越大，它可能就这个输出结果的时候更慢。但是到底每一次的这个大模型输出的时候，到底花了多少能量，这个是几乎可以说是全球第一个大模型厂商第一个公开自己到底推理的过程中prom到底花了多少能源。的这样一篇文章。然后这个有他原来的这篇google自己的paper，然后也有一个MIT techno review的这么一篇文章，然后我就给大家都看一下。

对我觉得这个很有比较有意思。就是说大家总觉得这个大大模型好像是从天而降来的。但是从这里面可以看到，其实它的成本是比上一代的搜索引擎还是高了很多的。看看。

好。

我看这个它叫计算这个AI推理对于环境的影响。然后上来他就说了这句话，他其实没有解答我们的这个标题里会这个答案，就是说大模型的一个token到底花费输出一个token到底花多少能量。而是他他在一定程度上回答了说我一次问题的回答到底花了多少能量。可以直接看着，直接测量了gym的的各种的花的能量什么这些东西。大家记住这个数就是0.24瓦，0.24瓦，0点24瓦的大概也就等于微波炉可能开个一两秒两秒。但是这个值是多少？这个值不是一个token，这个值是一次输出的这个响应结果，大概是这样的一个量级。

所以大家可以想象说，你每问一次chat VT，差不多他都或者gym他都盯一下这个微波炉你一下，基本就是这样一个能源消耗。但是你想想大家如果50%的搜索的内容以后都变成了这样的一个提示词，或者一个大模型输出的那个这个能量确实就很大了。所以这也是为什么大概从去年开始，就是整个AI领域大家都开始担心能源不足。但是反而其实这个担心在国内也没有那么多。我不知道咱们群里面有没有这个能源行业的，或者像国网、南网这样的一些同学。我觉得这个如果有的话，可以说一嘴，咱们现在有没有做一些提前准备，我反正知道了，肯定有的。

因为几次给南网吧南网的公司的一些人去去讲课的时候，其实他们都会说内部已经在准备一些对下一代的这么大的AI的使用量的情况下的一些预备的叫什么发电的预留了，再加上最近西藏雅湾，这个叫哑巴吗？还是叫什么？就是那个新的得把印度那个那个核给截断了。那个那个发电厂，我觉得这个是一个特别提前的一个预算，预先准备。然后他发电量是这么多，就是消耗的电量是这么多，二氧化碳排放量0.03克，几乎就可忽略了。

然后这为什么为什么要耗水呢？耗水其实主要是在后面大量的机房里面会有，现在基本上都是要用液冷了。那液冷其实会消耗水，它不是一个纯循环使用的。其实我也我也没太研究清楚为什么他这个有很明确的这样一个不能，就是消耗这个水，可能是不是过程中就会让一些纯净水给变成不纯净的什么这样一个数据。

所以他说每一次的pro差不多能源影响相当于你看电视不到9秒钟，后来想想其实也不小，这个量，然后这个就是google的这个文章的最核心的点，然后下面就开始说了，他们到底怎么测量的整个AI集群在推理大模型的时候的能源消耗？你现在看这个food system的动态power，这就没啥点了，其实就是一个系统动态的一个消耗，那就是AI模型的用这些算力的部分。然后爱豆的machine是啥意思呢？

就是它其实要保证自己的服务集群能够稳定的执行，它是需要一些冗余的，一些故障的冗余，或者用一些为了应对一些峰值，所以要留出一些空闲的机器。但这些机器还得跑着，还得运行着，所以它得有一个i idol的 machines。然后还有CPU和RAM。CPU和RAM的用电量其实不容小觑，待会看那图就知道，然后其实也没有那么小，意思就是说还是有很多空间的。

另外一个就是数据中心会有很多的所谓的overhead，就是一些别的消耗。包括这个液冷系统电力分配和一些别的网络这样的一些消耗。所以引出了一个词儿叫电源使用率PUPUE的这么一个指标来衡量。最后也很水消耗，就是这个就是要去冷却，所以要消耗水。对，他就开始说，以前的很多分析都是这样的一个情况，如果只纯看，因为google的那个GPU叫做TPU，那大家应该知道，就是就tensor这个process union，然后它的这个基本就跟NVIDIA的卡是一个一个对应，所以它完全从底到上都能自己控制。

然后TPU的部分，大概如果只看TPU的消耗其实挺小的，只有0.1瓦时。然后刚才我们看到顶上那是多少来着？0.24瓦时对吧？所以可以看到其实TPU的消耗只占其中的不到一半，就是有其实有非常多的别的一些消耗在里面了。所以他们就开始吹自己为什么能够以这么高消耗。

这个值其实是远比较远低于之前大家的预估的。因为各家大模型厂商都没有公开过这个数据，比如像open AAWS什么的，这些都没有公开过。一方面我觉得是大家也不太想去在变化这么快的时候公开这个东西，公开这个东西也没啥意义，就没啥商业价值。另一方面我觉得还是有可能就是大家其实算不清楚，就是google这种或AWS这种公司，它才可能能换算清楚。因为他几乎是全站掌控所有的这个数据中心的，从顶到底的这个全过程的他就开始吹了。

为什么我们能这么高效呢？模型的架构好，然后这个模型训练好，然后他们优化做的好啊，然后开始吹自己的这个核心的TPU了，这个叫i on wood。他比他首次公开TPU节能30倍，对吧？

首次公开那就啥事了，N多年前了，所以这个就是在吹一吹，然后底下又是他说的怎么怎么牛，怎么怎么牛这些东西，所以其实这样，然后我们看这个论文里面有几张图还有点意思，可以看看。这个对，就是到底一个，我们直接看那个比例，这儿到底一个大模型的推理到底花费了多少能量这件事儿，雅江雅江算对对对对对，到底花了多少能量这个事儿。超哥来了。

看到他打个招呼。

然后这个就整个这一个推，你看整个TPU或者GPU只占其中58%的能源消耗，24%都是CPU和d RAM占。所以这个东西的就本身传统计算机硬件架构里面的这部分的算力，或者叫能源消耗其实不少。所以这也是为什么看NVIDIA的这个新的集群里面会有一个叫DPU的玩意儿。我不知道大家有没有注意到，就是叫DPU的玩意儿，这个东西叫数据处理，数据处理单元对它一定程度上也承担了干以前的这个数据处理的事儿。DPU对，就是这个DPU的这三个字，但是不一定是这个图里的这个东西，就是承担了原来数据处理和一些网络传输方面的事情。然后这个事情就可以把原来一些更多的CPU负载的事情给负承担掉。

然后DRAM的消耗，这个耗电量其实也不容小觑。你看他们俩其实合起来占2% 4，所以这个也是如果这个部分能够稍微削减一点，对吧？这个能源消耗就会少很多。

然后idol machine这个几乎是不可解的。因为这个东西你必须如果作为一个云厂商，你必须得有这个备用的算力在这儿，备用的机器在这儿，其他的一些head也是能够减的一些运营效率增强增提高的这样的一些点。但是

我觉得这块其实可以关注，就CPU和d RAM这部分。如果说有一些就跟今天待会儿要讲的那个deep seek的那个上周给大家提了一嘴的V3.1。

然后V3.1发完了以后，好像隔了两天，他说了一句话，立刻N只股票就涨了，对吧？那个里面一个点就是它支持了一种新的这种叫什么数据格式，然后训练里面虚拟数据格式。但我觉得这块其实潜在也有机会。如果哪家大模型厂商或者说在这个做DRAM的厂商能够跟大模型厂商合作的话，来去做这种功耗减小，这个空间是大的多的，我觉得是对。然后底下的什么，这个就是他开始吹，就是说当你他现在这一代跟去年的那一代的TPU，TPU在功耗上降了33倍，然后在这个二氧化碳碳排放上降了47倍，就很可怕的这么一个比例。但是确实是他肯定是持续能够做很多优化点的。

然后同时还吐槽了一下其他的几个模型，你看这几个对吧？这个叫这个横轴叫做每千瓦时多少个提示词，那这个就是prompts，每千瓦时就是一度电一度电。然后这个叫M的这个中位数，基本就是最强的。然后其他所有的模型，开源的模型和闭源的，不知道他闭源从哪搞这个数据，都在这边来去这个都比它的一个叫什么功效比差，性价比差。

他的其他的开模型，他有没有在一个非常被调优过的状态去比较？

那肯定不会调非常调优的，因为别的家的模型肯定是对按照这个，但是他这也写了一些点，你看以前的很多评测方法都很局限，比如说batch size为一，你说这种东西评出来的有啥价值？所以他就开始说了，用了更多的TPUGPU的这个旋律，然后在生产环境下来就是测。所以他的别的家我不知道到底他测的肯定有一些猫腻，但是肯定goole是有不少这种开源的，就是有不少这种优化的策略在里面的。

然后这里面还说到这么一个东西，我觉得也挺有意思。新的一个新建的见到的一个第一个新的leader board，你的不叫ML energy，然后这个玩意儿是啥呢？大家看一下就知道了。

这个各家模型各种size模型跑在GPU上，然后每一次响应的焦耳数就是用这个jama two 2B的一次响应，四十焦耳是多少呢？四十焦耳是多少？我们直接问问千万。对，一千大卡大家知道吧？就是各种的什么吃饭的能量，我去以40焦耳是多。对，然后一千大卡，我记得好像一千大卡等于四千多焦耳，然后。

一卡路里一卡路里等于四四焦耳。对，所以1000卡就等于是四千多焦耳。而这一次response花了四十焦耳，所以可以见基本上连动都不需要咋动就可以这个能量就可以支持一次这个g two的2B，当然大的那个就更大了。

你像这种八百多B，其实也没有大太多，就这么一个奔驰，这么一个leader world。看能看到说除了chat写代码视觉的chat，然后各种的别的diffusion声纹声图像到底花了多少焦耳。我是第一次见到这么一个另类的leader board的，就是专门研究这个对能量的消耗，我靠觉得真的是挺有意思的一个事儿。然后刚才大家可以想想，就为什么他能测的这么精准呢？就是因为有一个他们用的是这个项目叫rose，就那个宙斯rose然后他只要装个程序，装上就可以直接通过。我看看，对，就可以直接通过API拿到说每一条指令的能量消耗是多少了。对，是这个东西叫zs它有一种叫intel的这个指令，有intel的指令结尾的RABPL的。只要支持这个，你就可以直接算出来所有的这个能量消耗，就是那个叫什么能源的消耗是多少每条指令，所以大家可以想象这个事儿，现在的这种CPU或这种指令集已经非常精细了。

所以之前说这个什么H20，这后门这些，我觉得并不是说他真的有没有后门这事儿不重要，而且我觉得大概率可能没有，因为这个H20他可能他也就是中国专供的，所以他如果想直后门的话，完全可以直在一些你他明确知道是走水货过来的。但是对渠道，但是他如果想去做好这件事儿，肯定是可以非常精细的得到你的所有这类数据的对所以这个就是第一个，我们第一次看到了一个好像可以算出来每一个大模型的响应到底花多少能量这

个事儿，大家记住那个0.28，0.0.24 0.24瓦特时这么一个数。这个其实挺挺少的，但是比以前搜索肯定大得多，然后这个是第一个。

然后第二个，还是带大家看一下这篇文章，另一篇很牛的文章，这篇文章作者之一是谁呢？上节课给大家看的那个那个呃比苦涩的教训，大家还记不记得？苦涩的教训这个萨顿写的。然后他的另一篇文章，也就是前两个月，发了一篇文章叫the error of experience。我可以叫什么经验或者体验的时代，欢迎来到这个体验时代，啥意思呢？我们先简单看一下，我觉得这个文章也是非常值得读的，比那个苦涩教训确实长很多。但是带大家看一下啥意思，什么意思呢？

就是现在的大模型，大家知道去年底给大家说了，去年底伊利亚就说我们现在所有的数据都已经被大模型训光了，已经没有人类产生出来的高质量的数据了。你看那些实际能够提高智能体性能的数据源，要么已经被消耗，要么就即将消耗。所以下一步的很核心的任务就是我们要找到新的，去让agent能够捕捉新的信息新的信息量的这么一个或者叫新的智能的这么一个方法。所以它里面就提到说，我们进入一个叫体验，翻译成体验还是翻译成啥？

体验挺好。

经验体验。对，就是体验。我觉得他还不算经验，就是体验其实更更准确一些，体验的时代。

他举了一个例子就是阿尔法proof对吧？前一段时间给大家讲过第一个在促销赛里面得了奖得了金奖的一个一段算法。它其实超越了这提一句话的，超越了以人为中心的方法和性能。

对这块后面会不断的提到，啥意思呢？就是他提到的大模型叫大圆模型，其实他都认为是以人为中心的算法，就是大元模型。大家知道去了大量的数据，这些数据哪来的？全是人产生的。所以我我们拿人的数据去训练这个模型的目标，其实就是让这个模型更以人的方式来去思考，更能像人的方式来思考。而今年大家看到整个推理模型的突飞猛进，也证明了确实大模型可以像人一样思考。

但是它的不好点。在阿proof这样的一些阿尔法系列的尤其是强化学习这个系列下来，也代表带来一个新的明确的弊端，就是他的天花板很明确，就是人类的经验。那人类的经验到哪？人类的水平到哪了？人类智商到哪了？那这个模型这个大语言模型很有可能现在没有办法证明，就很有可能也就到那了。所以他提的是我们应该有一个新的办法来去让他让这套AI系统能够自我提升。他就提了几个维度，一个是说让agent沉浸在自己的经验流中，这个经验流他其实就这个词儿叫这叫经验。

experience .

stream of experience，而不是什么，让他沉浸在经验里，而不是短暂的交互。所以说是短暂交互其实就是大家在大模型里问一句，他回一句这样的东西，这个只是片段的，大家骤发的这样一个需求。然后第二个就是让这些AG系统，这种AI系统的行动和观察与环境紧密相连，而非仅通过人类的对话交互。就是我们要让模型自己能够去体验周围的环境，而不是我们告诉他我们靠文字告诉他，靠什么告诉他，都是人类告诉他。然后第三个就是他们的奖励要基于对环境的体验，而非来自于人类的先入为主。说白了就是人说这件事情做的好还是做的坏，这件事儿不应该局限或者限缩了整个AI系统的发展。我们要让模型自己去从环境中获得他到底认为什么是好，什么是坏，这个奖励到底是多少这样一个事情。

然后最后一个就是将他们我看看你要问啥，对，就是他们将可以自己去规划和推理，用这个什么呢？用他们跟物理世界交互的这些体验来去自己规划和推理，而不是靠人类的这个term，人类的这些term，这些叫什么词

儿这些人类的方式来去推理，所以这个是一个几个点，就是说我们他认为说我们下一代的AI系统应该开始摆脱人类了，说白了就是这句话。那底下就开始就说了，他开始陈述每一个点到底是大概怎么做的。比如说这个流就不是什么数据流了，是那个是刚才提到这儿的经验流，就是stream of experience。那啥意思呢？其实就是刚刚说的，就是我们不应该让模型只在短期交互场景。

比如说用户提了个问题他思考，又提了问题他思考，而是应该让他长期的来去跟随人的所有的相关的时间，甚至不一定是跟随人，让自己去体验所有的这个相关体验流，让他在不同的尺度上都能够观测到你的自己的体验流，从而自己去思考，那怎么思考具体的什么？他这篇文章不是讲具体办法的，讲的是他认为未来的一个趋势，下一代趋势。然后第二个就是行动和观察，他也认为说这个大模型其实老早大家都知道能调API对吧？然后各种的调API的A这就是层出不穷。但是最新的一代的AI开始以更通用的方式跟机器交互。这就跟咱上节课讲的像auto GM，像之前几节课讲的像browser use，像这个cloud。最近又出了一个新的它的computer use一样。就是我们开始发现一些agent可以一个非API的方式去跟系统，跟它的环境互动。那这个时候他是不是能够通过一个更通用的方式来去交互以及观察核心。这个观察就是他能够在屏幕上点点点，然后自己能观察到点完了以后有什么变化没有。

这件事儿其实带来的一个结果就是这种agent它真的可以脱离于人的存在而自己去探索这个世界。当然他有可能点错，不是很很很可能是必然会点错。但是这样的点错的经验，其实可以给这种agent带来一个未来的巨大量的提升的空间的对。

然后第三个就是这很关键一个奖励，对吧？就是以前所有的我们说的强化学习相关的这样一些事情，都有一个大部分都有这么一个事儿。就是有一个人类来去决定他干的这事儿到底是不是好以及多好，对吧？所以包括大家听到了很多的RLHF，什么人类反馈强化学习这些其实本质上并不是我们说传统意义上的强化学习，而是靠一个人类的判断来去做的强化学习的奖励函数。这件事情，所以经常大家说RLHF文人类反馈强化学习并不是一个标准意义上的强化学习，这就带来这个点了，肯定是一个标准意义上强化学习。我们是希望他有一个自主判断，然后有一个比较客观的一个叫奖励函数的就是判断到底这活干的好还是不好，还是多好。这件事情我们希望它有一个客观的。但是这个前几课大家听的时候都会听到，就是我们现在能判断的客观的奖励函数，或者大家公认的其实只有数学和编程，其他的都没办法有一个客观的降低函数。

但是如果结合前面的说，我们能够让一个AI站去跟现实世界是现实的世界中。自己去行动观察。那这个时候他的奖励函数是不是应该自然而然就应该从现实世界来呢？是对吧？

他这块也他这块也提了，如果一旦我们认为智能体可以通过丰富的行动和观察世界这个方式来连接，那他就应该有不断的现实世界来的信号来作为奖励函数的这样一个基础。比如说现实世界有大量的这种反馈，比如说什么成本粗略饥饿、生产力乱七八糟这些值，有非常多的值都可以作为现实世界带来的反馈函数，这个奖励函数。所以他就认为说，如果我们为下一代未来设计的话，那他奖励函数也应该来自于现实世界。那这个现实世界就不仅包括说我们是在一个电脑屏幕上，在手机屏幕上，还是在一个真实的物理世界才能做到这一点。

所以大家可以想到这儿，他一个最大的可能性是什么呢？就是机器人，对吧？这是为什么大家对巨神智能这件事情报以非常持久而且狂热的兴趣，就是我们想象中能够从现实世界跟现实世界交互，拿到这个feedback的一个载体。你要不就是人对吧？要不就是一个东西。而这个东西最好它能像人一样灵活，它能够？毕竟人类才主宰了地球而不是机器人。所以我们希望能够待搭载获得反馈的这个东西也是跟人类类似的灵活的那所以自然而然会想到说机器人具身智能能不能干这个事儿，所以据称智能大家不要只觉得它是一个现在套个大模型的脑袋，套个什么VRA或者套个什么控制器，让它能够走起来。

它承载的一个更中长期的一个目标就是这个事儿，就是能够从现实世界中获取反馈这样一个东西。所以只有拿到了这样一个东西，那我们想想他如果能自主在现实世界中行动，能自主从现实世界中拿到反馈。当然这个反馈不一定是一个精准的这样一个值之一，而很有可能是一个后面会提到说，我们有可能是一个在这儿是这个对

我们有可能在像人一样，对吧？我们平时这个中长期或者长期目标就是生更多的娃，然后赚更多的钱，然后这些东西。但是短期大家会经常觉得，我最近特别喜欢什么什么打台球，明天特别喜欢出去捏脚什么这些东西。

好像都有一些比较单一的奖励函数或者奖励的这个优化的方向，对吧？那这些优化方向是不是也可以跟上面这个奖励函数来结合呢？它的意思就是是可以的。就是因为有一种观点认为一个单一的奖励信号，其实如果能以极大的效率优化，他可能也能诱发出广泛的智能。大家想想这个的话，其实就是类似于deep sik a one这样的一个做法。就是我如果能在一个特别特定的一个场景，比如说就数学或者coding唱代写代码方面有一个极高的优化能力。他涌现出来就是他对很多推理部分的这样一个能力的用线，对吧？就是它更具有泛化的一个智能出现了。

所以回到刚才，我们虽然可能现实世界中非常多不同的指标，但是人可能怎么去适应这个指标的这种方式，就跟机器跟整体可能也是有相似的之处的。就比如人短期内喜欢一些特定指标，那如果我们能让agent也具有短期内在大的这个目标不受损的情况下，我短期内让这个A人就喜欢捏脚，或者就让这个A人就喜欢出去拍拍拍。这个叫什么风景摄影摄影这些事儿，让他在某些特定的能力上有一个提升。反过头来这些子目标子的优化目标可能也能涌现回来，作为主目标或者中长期目标的这样一个提升的叫什么根源。所以他这就是讲的说有可能会追求单一的奖励目标这件事情也是有意义的。他是可以去让整体的这个agent有一个总体提升的。

对，然后规划和推理，这就是说他前面的讲的点了。大模型可能他前面就是吐槽了一通，就是说大模型它的规划推理能力是非常局限于我们给他训练的数据的。这个大家很容易理解对吧？我们市面上有多少数据给到大模型，那大模型可能下次他再去推理这活咋干的时候，大概率就是按照人的这个最常规的做法来去做。但是这个问题就是说这种任务，这种推理的方式是完全模仿人的痕迹的，是不可能提供一个通用计算机的最佳实现的，所以大家他就举了几个例子，如果说大模型A阵被训练成用5000年前的人类思考来推理，那他可能认为是这个物理问题，还是用泛灵论的方式来去讨论的。然后1000年前可能用有神论，300年前会用牛顿力学，50年前可能用量子力学，但是哪一种其实都是无法超越人类当前智慧水平存在的。

所以他就认为，我们应该有一个新的办法，结合前面所有的东西。那我们是不是可以出来这个AJAI系统，就应该能够放飞它，能够让它自主去选择。比如说怎么预测用户自己的这个心率或者睡眠变化，因为他能够拿到足够大量的现实世界中的反馈。然后对这个就是他说的几个核心点。最后他就说了，为什么现在是一个关键点呢？

就说到这张图，我们看到之前的什么ala go after a zero GPT3叉GPT GPT3之前，其实都是他所谓的叫simulation模仿模拟的人类的行为的AI算法的时期。当然到offer zero到了一个顶峰。好，这个阶段结束了以后，就开始到了人类数据的时代。前面是模仿的时代，后面是人类数据的时代。现在咱们其实可以说还处于这个人类数据的时代的很巅峰的状态了。然后他认为下一代就是所谓的体验时代的开始。

那从什么时候开始呢？他认为做以阿法proof为起点，然后各种的computer use，各种的用电脑，用浏览器，这些其实都是体验时代的一个开始，而且大家会逐渐发现，这一类的癌症越来越多，带来的结果就是大家根本越来越不需要人类的数据，这样一个结果。看看，最后是对他提了一些强化学习的这些点，这些就具体数据就不说了。所以这篇文章我觉得也是挺好的。

对，这就是成全早起必看是吧？这篇如果超早起必看，你看完两篇可能就早饭就吃完了。对，所以就是这个东西。对，然后这块就说了，有这么两个点，我觉得就是这样的。一个是以人为中心的AI这件事情现在是一个大家在开始远离的一个方向，就是不能以人类为中心的这样来去做。

然后另一个点我觉得就是这一点，就是大家看最近的AI的设备，然后QS是啥？QS是量化自我quantified量化自我这个方向。这个其实好多年了，十几年前了，这个硅谷很流行的。说白了就是我能把我日常中的所有

的所见所闻，所听所想，然后社会上的反馈全给我记下来，然后这个确实是有人在这这么干，而且当时的很牛逼的一帮人，就是现在都已经成神了。这帮人当时就在做量化自我的事儿，就是AI设备和这种量化自我的这个需叫什么？重要性越来越充分。这就是量化自我当时的一些东西。然后大概这个经验时代，就是这样一个这样几个点超你有啥想表达的？

我想说那个以人为中心的AI你这个里面说不要做以人为中心，你这个以人为中心是指AI不一定要学人。

对吧？对，不要向着人去演进。

RHF那个？

RHF是一个很经典的一个大家吐槽，对吧？这RLHF不算RL，RLHF它的号称RL但其实不R，这并不2L。OKOKOK对，然后我觉得这个东西其实我觉得可能下一步突破点就是可穿戴设备对应到的一些健康。而我其实最想让他突破，就觉得他其实如果最能突破了以后，价值最大的反而是工业，对吧？就是我们看到大量的工业这些事儿，其实现在用上大模型跟上一代的深度学习，上上一代继续学习差别没有那么大对吧？我觉得这个就是因为其实没有办法，当然有很多问题，这个局限很多。我觉得就是因为他没有办法有一个环境能够让AI系统在里面自我的去RL这样才能自我提升。

或者在工业里面它的L的成本确实比较高。对，即便是有些东西你能用协议什么去模拟，但是模拟跑的那个速度也比较慢，至少就是它整个的这个L的迭代速度会。但我仍然觉得这个事儿还是有机会的，而且现在就是agents的RO.

这块也发展很快。对，好，然后下面模型，上周给大家讲那个模型，千万的image added，这周立刻google又出了个新的对吧？这么大的flash image，然后挺牛逼，这个我觉得是比那个image add还牛逼的。它有一个特别好的功能是这个东西可以把多张图片不断成一张图片，这还挺有意思的。然后这半圈就不看了，对，其实就这么一串。对他这又推销了一下他的这个。AS studio AS studio google的AS studio里面，大家看左边有这么几个功能，chat stream.

Stream其实就是随时聊的那种接口，然后这个live的这部分生成图片，然后build。Build其实就是做应用，就跟这个lovable什么的reply很像。然后他提了一嘴，你只要说这么一句话，然后立刻就能生成一个什么呢？生成一个应用，我就不让他先生成了。你看一下他之前生成的一个东西，就是一个大家想想要做一个图片编辑应用，让用户可以上传自己图片，并且用不同的叫什么滤镜来去对吧？那我就直接我看看哪一个我放一个。对，这样这几天都在黑龙江哈尔滨在玩，然后这个我看看问题。

你现在休假。

对，我这周休假，所以我在车里，我在哈尔滨。有没有哈尔滨的同学？我觉得哈尔滨给我的第一印象是我开车，大家开车太猛了，我靠都不太敢开了。

说明你没去武汉自驾过。

行，好，然后你看这个就直接就一句话出来这么一个？这个图片编辑的这么一个东西，这个你说效果也就这么回事，还不错。如果你要专门做一个，还是挺不错的一个东西，但是我觉得这一点其实是跟home的这个HUIZ的这篇新的文章是很很相关的。就是我们其实要的这种图片编辑应用，它比大家想象的需求大的多，为啥呢？



你看最新的这个第五版，这HUIZ的第五版的生成式消费者应用的生成式AI的消费者应用的排行，然后基本上前面的大量的都是图片的编辑类的应用。这个道快速看一下这个GMA这个模型他的角色一致性，有一他做了一大堆demo例子，我觉得都特别有意思。比如像这个当时试了一下，我看看我能打开。

这个你就扔一张图，一张扔一张自己的照片进去。然后我就跟你说了，这样不同风格，你你你的这个大头贴，而且效果真挺好的。然后我就把上次这个你给我发的那个扔上去了，生成这么一个东西。对，就是我只能看。对，就是他能生成这个1950年到什么90年、20年，你的这个各种风格。

50年对吧？

60年有点意思。

有点意思。

到70年你看这个嬉皮风，我靠80年这个不太小。哦哦哦对，90年对吧？这这种这种衬衫，00年就这个玩意儿。

00后是这种形象是吧？可以。

对我觉得很有意思，而且他的这个整个。

做长得还是像60后对吧？

是的。

跟你本人对象。

有道理。对，然后就做这么个东西。然后你可以直接把这个代码给也不叫代码，其实就是提示词，你直接给那个folk一下就可以去做自己的了。就等于说你就把这些不同的风格的贴纸改一下，可以改成不同的这个内容，就OK了，大家自己去玩就行了，我操。这很有意思，其实做的很不错。

然后这种也是他为了展示了什么呢？就是展示他的风格一致性。你看他在各个图里面的风格和他那个角色一致性非常高，然后调图这个也挺有意思，就直接话然后你就问他说帮我把这个东西label出来，不同的部分label出来，他就能label出来，做的很不错的。然后啥意思？

Label帅是啥意思？

给你看一下，这就是他的叫co drawing，就是协同画画。在这个协同不是跟人类协同，是跟AI协同，就这么一个图对吧？我要画一个，我在哈尔滨马上去，刚去了伊春看了好多路，我画一个路。

完了我都能想象出来。



两个眼睛嘴对吧？然后植物大战僵尸还挺。

像的，还挺像可以。

然后有个尾巴。好，然后我看他说的是啥。

你让他label一下what .

this label the key part label the key part OK.

我问你录的key .

part是什么？

有一些标对了，对吧？那tail body，leg, 然后两个l好像方向有点差，但是也还行。什么谭老师啥意思？对，就这意思，这个就叫label part，叫call join。你就可以直接像这个数学题，直接让他去解解出答案，并且把那个那个字母给替换成最终答案。比如说替换成最终答案，它就替换，很有意思。我觉得这玩意儿如果谁能把它包一下，变成一个什么中小学的那种交互题，我觉得这挺有意思的。

这个小孩玩挺有意思。

对，然后这个是home canvas对吧？大家想想一个你要拿一个室内装修图，然后这放个灯，直接过去就OK了，做挺不错的。你看那光影效果什么的还是保持一致。然后他的开始。

刚才那个其实要想做一个给小孩玩的效果图，其实增加一个语音对吧？就应该没有互动性。

不需要语音，你直接就对，就直接把这个应用这是个对吧？对你画点这一段现成的代码，我觉得这个先放起来。咱们小伙伴群里有没有同学做一个。

真的这个我觉得如果收费合理的话挺好的，我还挺想。

是吧？

对，但是但但但对于我对于太小的孩子来讲，他是提问题我也会是用的。其实你可以加一个翻译。

加上那个对吧？建议问点啥。

对，语音的。对，而且变成语音的，我觉得会好。

的对对对对，这个比比那个lovable那种coding的有意思多了，对吧？就是web coding还是太严肃。好，这个就是GM的这个新的，然后具体就不讲了。我们来讲讲这个deep seek v3.1这玩意儿大家有没有经历这个不用，这股价都涨了，对吧？咱有人买了那个谁吗？那个半导体的etf，那天我老婆一看，我靠半导体ETF涨了10%，一个etf涨了10%。

然后就是因为寒武纪疯了，我靠为啥呢？就是他发了这么一句话，就是UE8M0FP8是针对即将发布的下一代国产芯片设计OK这啥玩意儿？其实就是当时他发了一个公众号，我当时没看到。因为这东西现在很多内容反正我不太会去看deep seek自己官方公众号的描述，他发的新的模型底下的自己的评论，对吧？我就没见到，所以这事儿我就觉得挺奇怪的。

结果他发了以后，很多二级的人看到这玩意儿就开始挖，然后就炸了。那这玩意是啥呢？买了科创ETF对吧？对，全是保罗体对，半导体疯了，好像今天回调了一点？这个寒武纪变成了2毛好了，仅次于茅台的这么一只股票。然后这个东西我觉得比较分析比较好的有几个，一个是这是一条stream，就是推特让你跳thread，然后哼你敢信知乎，知乎在推特上发的还挺多。

很快有同学去反对你来这个同学们还是对股票非常熟悉的。今天大涨，老师。

今天大涨OK，不是回调。好的。

这时候我展示你的自选股了。

我真没然后。

把这门课再变成了一个股票课。

对我是个很保守的，我只买什么腾讯这种玩意儿，然后这个就是被嘲笑了。对，然后对，我们看看这个就是知乎frontier的这篇文章就讲啥呢？就是deep sk声称使用了UE8M0，然后它是一个为中国的芯片量身定做的FP8格式，啥意思呢？这个待会就讲，然后又18M0是这么个玩意儿，这个就不说了。

然后我们先看看几个他认为的很牛的人的点评，相对还是挺靠谱的。你看从硬件实现U18M0的乘法、除法计算都会变得非常简单。只需要将指数位做简单加法，硬件开销等于整数的加减法。说白了就是用这个格式的一个数做计算，做他所需要的计算，成本极其的低。然后也就是说UE8M0是一种另类，但硬件是件非常简单的浮点数表示形式，有望节省硬件面积，然后提高效能。

然后由于8M0这块其实挺重要，就是由于8M0不是用在参数上，可能不会用在参数上。参数就是啥呢？就是大家听到的这个什么2B20B，这个100B的这个B对应的东西就是它的模型参数，而只是用在skill上。它是待会儿可以看啊，就是你的一个巨大的一个矩阵。大家知道这个大模型，大家就想象成一个巨大矩阵，这个矩阵其实每一个部分都会有不同数。那每一个部分如果大家就是整体的都用一个很小的数来表示的话，就每一个里面的值等于很小的数来表示的话。那大家可以想想这一个矩阵下所有的数的范围都是一个很小的范围。

比如说之前给大家说这个int 8，算了，到时候看吧，待会儿看图说。那他很有可能在skill就是乘倍数上，就是我这个小区要乘个五倍，乘个16倍，乘个128倍，这个倍的倍数的值用U一般，对，而不是被乘的那个数。然

后那参数仍然是E4M3或者E5M2。这俩数是不是有点特别的？4加3对吧？这个5加2其实好像都低于8，然后大家都是都在七上，为啥呢？大家就知道，然后这个只需要一这个值只需要跟这俩数做乘法就行了。就可以得到。

而中间结果可以用高精度的FP32保存，进行求和累加。所以它说明什么呢？可能说明模型已经做完了UE8M0的适配，但是为了跟开源推理框架兼容，目前还没修改，就这么几个值。好，那我们看看另外一条刷里面有一个特别好的一个入门贴，我看看。这个clean clean有一个特别简单的入门。

我觉得你就说结论，这个东西到底好在哪儿？

我觉得不能那么单纯的来说他的结论。超永哲需要讲讲FP这个玩意儿吗？简单说一下，简单说一下，我觉得咱群里的同学还是比较有。

我担心是不懂的同学并不关心，然后懂的同学已经懂了。

真的吗？你讲讲我觉得OK。对，OK就是快速给大家讲一下这个电脑或者是GPU里面怎么存一个数。这个数肯定不是什么2357这种整数，而是一个像这种0.395264这么个数，这个数到底咋存？那电脑大家都知道，里面全都是这种010101的，就一个数一个格子就是一个beat。

那我怎么用这么一个这一大堆格子存一个0.395264呢？那这个值还不是精准值，是一个一个约等于的值。因为我想去让它表示一个很长的小数，我不可能在这么多格子里就生写进去。所以他就会一般来说大家都会把这个存储的一个一系列的格子，一般都是连在一块的，分成三个部分。

第一个部分是sine，sine就是表示正数还是负数，所以这个一般都会留一个位。零就是表示正数，一就是表示负数。第二个叫指数exponent然后这是一个说白了就是我要把一个数乘多少的多少次方，这个大家看一下。然后第三个部分这叫尾数，这个metsa，这个值就代表了是一个要被乘的这么一个底下的数。我看我记得之前有一个，对，我们直接看一下这个GPT5给我们的一个介绍，就说白了就是这么三个数，符号位、指数位和那个尾数位怎么得到呢？比如说这个sine位是零的话，那负一的0次方大家知道得一对吧？那就忽略掉就行了。一这个尾数就是这个玩意，一点曼缇萨，比如说曼缇萨这个尾数等于我刚刚看到这个值，就看到。

这个。

1001010011，这玩意是个二进数，把它找这个变成真的数，就是变成一个这个呢二多少？二的负1次方，四的负1次方加上八的负1次方，然后加16次负1次方，得到的值就是这个尾数。所以它是个小数，所以这个是一点等于是默认一点多多少少二后面是一个指数减去一个BIOS，BIOS是等于这个东西，是一个比如说这个看。比如说这个E4M3，E4M3这个四就是表示有多少指数位，占了多少位。比如这个四就是四个，123415M2就是指数占了12345位五位用来表示指数。所以这就是放到这个8S这个5 5减1等于42的4次方等于16，16减1等于十等于等于15。这儿就是得出来的指数位的那个真的值，比如说这个是0101就等于是5，对吧？5减去15等于多少？

这样一个东西就可以得到这个，然后把它所有都带的这这个数里就得到一个value，大概就这么个东西。所以大家不要觉得现在计算机里面存一个数特别简单，现在存一个数越来越复杂。你看这个都是有有指数，有它的尾数，有它的符号位，得到这么一个东西。所以如果我们存一个小数用FP16，那我得到这么一个只就相对来说比较精准，对吧？你可以到小精准到小数位后的第六位，如果我只用八位，就是这个使用八位。如果我其

中四位表示指数，那我只能最后精准到一个0.40625对吧？这个也接近0.39，但是比它还是大一些，就是精度会低一些对吧？

然后如果我用这个精度再叫指数位，再多一位，五位就是15。然后这个底叫什么？尾数只占两位，那我只能精确到0.375，那精度就差多了。但是也是类似于0.9，约等于0.98，也可以这样来去换算。对，所以这个就是本身的一个16或者一个电脑里面，或者在GPU里面怎么表示一个小数的这么一个办法。

但是我们回过头来看这个EUE8M0，UE8M0这个东西是啥？刚刚看了E几表示的是指数有多少，对吧？M几表示的是表示的是尾数有多少。那1E8E8M只有0，就根本没有尾数。这个绿的是没有的，然后这个橘黄的占了八位，那前面连符号也都没有了。

因为它叫UE，UE就是i side，默认就是正数，所以整个UE8就是整个全是橘黄的，全是橘黄的，只来去表示一个数的指数，就是只有指数，所以大家可以想象这个数很有可能就变成什么二的1次方、二的2次方，二的3次方，二的4次方。只能这么表示，那你能表示数就变成了124 86、32这样的值，那中间大量的数其实就摸不到了，对吧？就是你想表达一个，比如说22，那你在诠释这个东西的全是橘黄的一个数据就很难表达。我只能选十六，因为16比32G1点，精度就差很多。但是这个东西那所以所以这个东西其实并不会用来去表示具体的参数，因为具体参数我要去大家希望把它表示的精度高一点。像这种事，所以很有可能是干嘛呢？就是用来去表示说我一个框里边我看看能不能看，我那张图找不到。这个。

好像是操。

这样，就是刚刚说的这个，我有大量的一个矩阵数据，然后我如果把它拆成这个，我要用整体的一个值来去表示它乘个二乘个四乘个8，就会变得很粗，力度很粗，对吧？就是只能变得越来越大。那我如果把它拆成一大堆小块，比如32乘32，那我拆成一大堆小块，我就可以给每个块定一个它的倍数。而那个倍数，就是用来用这个来去存的U18M0来去存的。所以我觉得这个人说了一大堆，home这块可以参考。

先是这个人这个计算之王的这个人的文章，他底下这些技术上的就先不说了，核心说这个就是他认为这个事情在于deep c国内第一次有大模型厂商主动的出来，按照来去协调或者来去调整硬件适配模型的一个方案。他先把这个UE8M0这个方案先说出来，而且当然这时候肯定他跟具体的某些厂商已经在合作了，具体跟谁他也没有说。但是他提出来另一方面的目的就是，你们这帮做AI芯片的，你来去往这方面示范，在这个方面适配做努力。等于是他先提了一个从软件出发的硬件优化方案，然后让硬件厂商来跟随。而这件事情从这个r one推出来以后，他推出了open info就是开源的那一套推理架构以后，可以看出他做这件事情越来越炉火纯青。

就是deep six在硬件方面，尤其是在hoper系列里面，号称是被比nv a还了解hoper架构。所以他真的是有权利或者有这个资质去说，我的对于硬件的这个标准是大家应该去follow的。然后他先提出来了，好，他就开始说，那你别的厂商说白了就是你所有的别的硬件厂商。如果你现在还没有支持这个所谓的FP8，或者来去支持他的这套新的这套架构，那就晚晚了。

所以他也就说我下一代的硬件的这个标准，很有可能是就这个来去做的那另外一个有可能，我猜可能也是他们跟按照有一些国家意志，就是国家意志不是前一段时间，很早以前大家说这个国家说了，大家都要统一在risc架构上吗？Risc v，我觉得是，那是不是有可能以后这种大模型计算所需要的硬件标准，这上这方面也是需要一些国家意志的标准出来去推动的那是不是deep sak就充当这个先锋这个角色？有可能。所以像寒武纪，像升腾这些其实都在做这方面的事情。作为一个大模型厂商来去提这样的一个事情，把先这个事儿给拨开，我觉得是一个挺挺也不不得已，这个挺挺值得大家期待的这么一个做法。

你这个不得已到底想说什么？

不那确实是啊你说H系列之后，那些B系列什么的都不卖给中国，那怎么办呢？就是我们总得有自己的发展的方向，你想IP8应该是H100之后提出来的那H100之后提出来的所有的新的标准，你国内的模型厂商是用不到的对吧？那怎么办呢？那只能我们这个国内模型厂商和国内的AI芯片的厂商一起去造现在这些对标NVDA新的这些方案的这些技术，然后像这个GPT的那个OSS开源模型，它其实号已经在号称他们用纯原生的MX这个FP4来去做训练了。所以大家可以想象这个过程对于算力的需求，以及它背后的这些架构，影响的还是挺大的。国内如果连FP8都跟不上的话，那确实是一个挺大的对，就是有可能又被有一点甩开的一个趋势。但好在我觉得现在我们从底层硬件到上层模型都有很牛的厂商在做。然后相互之间还能通过像这种这种方式来去做一个协同，我觉得是一个非常好的一个趋势。

对，听不懂的这个对，是我我说的不够好啊，我觉得这个是这段我想了半天，这个怎么讲，确实是你很难从一个这么一个指数看到这样一个背后的大在做的事情。但是我觉得这篇文章就是这个Green在讲的整个thread也是挺不错的。他后面在讲的都是跟地缘政治相关的这样一些说法。

你看这些其实就是在二进制的世界里面，如何去表达一个数更高效，还是在效率跟压缩比之间找一个平。

对这个标准数的标准是干着用的。但是你看这点就是说通过宣布围绕MUEUE8M0这个模型标准化，为国内的AI厂商提供了一个新的发展空间。处于一个全新的陌生的领先地位，而不是一直处于遮盖状态栏。我觉得。

这个东西领先意义不是特别大，这不是一个复杂工艺。

他对底层的算子和对蝌蚪还是要求挺挺多的。就是你想如果你一直基于这个IP8，不是叫什么OSS的那个组织，IP8来去公布的。然后这个IP8这个组织，其实你在国内你如果一直follow它，那OK，但是大家各种自己的实现是不一样的。你看这个FP8是哪一个？是啊对OOC这个提他只提了一个spec，但是各家的实现是不一样的。那这些实现如果是NVDA自己做的，他肯定不会对吧？咱们那线也用不到，也用不上了。对，所以这些东西总得去有人实现，各家实现还不太一样，这个有时候确实是差之毫厘，失之千里的情况。所以如果国内的模型厂商跟硬件厂商能够趟出一条巷nvidia这个对吧？

像OCP这种公开协议的话，我觉得是有挺大现在机会的。对，你看当时他反正也就说了，拿5G的几几码来去说这个事儿。我觉得这个要关联到地缘政治这件事，是我觉得是有必要的，它不是一个纯技术上的一个事情。好。不做那么精细节省。当然对，不用。你看我都比如说刚才那个事儿，就是我如果都想得到一个0.39几几左右的一个数的话，我存如果就用八个比特来去存，我能够存一个很接近0.39的这么一个数。如果能做到这一点，那不就很牛，对吧？

所以大家用各种办法来去设计这种编码方式，用四位表示指数，用三位表示指数，用五位表示指数，来去尽量贴近这样的精度。你但凡少了一半，比如说从16位减到了八倍，你整个相关的数据的传输，这些事情都节省非常多的算力。所以大家你想NV link为什么独霸那么久，对吧？就是因为你卡间之间的带宽能做的非常高带宽稍微高个一倍。它能传的。比如说大家都用IP16，这都用16位表示一个数，那我传的数据就多一倍。大量的集群情况下，比如说几万张卡，十几万张卡之间传的这个数据，你但凡多一倍，那我的训练效率就高了很多。高很多以后我发布产品的速度就快了很多。所以这个是一个大中级都需要这么一个高效的这样一个传输效率方式。

好，那这块HUIZ，我觉得这个不是就这个deep seek的V3.1就这样了。对，我觉得这个确实上次我没看到这一点，如果看到的话，我觉得这个可能还真能给大家提前说一嘴这件事。然后回到这个HUIZ的这篇文章，就是top 50、top 100的AI消费级的应用都有哪些？这个可以先扫一眼，你看投的都是谁呢？Chat BTGMI deep

thick, 我觉得特牛逼。DC这居然现在还是排在第三的这样一个前50的AI应用。然后brock长得也非常猛，correct AI这个陪伴类的搜索cloud长得也很懵genet AI对吧？

之前给大家说过，大家自己去体验一下他是干啥的。基本上大家用一次就应该知道说，大概这类的都是什么玩意儿了。比如他有啥？有什么question，crush AI, juicy chat，其实都是这一类的东西。对应的是什么呢？就是大家知道这类的用量，或者说这类的需求量极其大。大家知道当年的互联网初期的时候，什么类产品的流量最大，然后夸克，夸克也是非常猛的。

阿里把话说明白，我有点没太。

懂这个互联网对吧？

1几年的时候，0日MP3网站最火了。

那你这就是揣着明白装糊涂了。那MP3网站是什么？对吧？懂的大家都懂了，对，这个体验一下。Generate AI Janet AI, Janet AI已经算里面最最在就可以打开的网站了，其他的很多都不是很好。

最近都都体验过是吧？

帮他体验了一下这个。

你就说有效果最好。

有一个我不能打开的网站，效果最好，不能在直播里打开的网站。然后移动端应用，你看那些AI gallery是很高的一个一个图片编辑。豆包排第四，我现在真觉得豆包这个使用场景太多了，而且非常牛。你像remley这些全是图片编辑的，然后美图、deep、sk百度，百度这么高，可能确实是国内用户太多了。

因为百度现在跟他自己的搜索合并了。

对，就是他把传统的AI搜索的功能变成了AI功能。

那都得变成。

对，所以我觉得他不太公平。对，就是我意思就是他不太公平。你看他对标都是谁对吧？对标都是什么german对吧？他有没有google也没上榜，然后必应他也没上榜，对吧？所以我觉得不太百度在这个角色不太干，不太对，不太公平。

对，然后底下就是几大新的，你看这个就是新进的这几个，brock lovable replant这两个，还是强烈推荐大家去玩lovable replant。然后夸克阿里真的搞了一个all in one的这么一个AI助手，什么都往里放。然后WIC大家看的话也发现夸克连什么AI眼镜也都放到夸克这个部门了。所以阿里是不是最近要拆分什么的上市夸克这些。有没有他的角色所在？

对，然后像什么juicy chat，our dream点AI对吧？这种就是不能打开的网站，这新进版的，然后这个移动端的这些东西，这有一个这家伙叫midi mini。印度软件对，很牛，而且增长非常快。卖啥的就卖这玩意儿，买耳机、音箱，然后这些喇叭这些东西增长极其快。

对，然后排第42。对，然后他提也提了几个点，google新增了四款产品，就是他把哪去了？这几个google的新的产品有谁呢？这有张图估计是对这goole 4个产品，一个叫Jimmy对吧？

Chat的，一个是no book。LM之前给大家说了好几次了，一定要体验。然后google maps和google AS studio，这两个人都是单独的应用了。所以这个都上榜了，还涨挺猛，gym上榜涨的最猛的。你看前六七百万不六七个亿的月活。

google .

life为什么这么对他拆成了WEWE3。现在在google apps里，你看VE3视频生成的在lips里，然后新的一些具体小应用，那些什么用浏览器的agent换衣服的，这些都放到lips里。等于他把那些实验性功能全都放在一个独立应用里面。对，所以这个流量激增了很多。

然后第二个就是brock跟meta还在游戏里，还还在这个里面，这个值就不说了。但是他提到deep sick流量下降了20%，但是看这个值紫色的deep c依然很高，这个是除了拆GPT之外的月活。对，然后rock xy这些都比他低，这个很很牛的一个deep。还是即使它下架了也还是非常猛的，它留存还是坛子高，底子厚。然后APP页的部分下载的没有网页下载那么快。你看DPC现在还在4000万的月活。所以可以想象这fake的面临的这个推理压力真的还是挺大的。国内有这么大的一个AI推理的这样的一个国际流量的压力还真挺少的。

然后中国还找到了他的这个witness，啥意思呢？就是前对有三家转服务于中国用户的公司位列前20。然后每家公司都有中国网站，75%流量来自中国，就有第九的夸克。然后豆包和kimi，我觉得kimi真的还挺猛的。我靠kimi怎么能一直保持这么高的这个流量。大家之前一直吐槽他是纯靠这个买广告起来的，但是目前看起来还真不算差。对，然后这就不说了。然后后面又说到说中文的视频生成模型也很不错。然后在前50个应用里面有22个是中国开发的，基本上已经快占一半了。而只有他就只有三款主要在中国使用，照片和视频类有位位为其中其中美图就有45款应用，美图然后字节也有3款4款这些CC也是。

字节的对。

所以但是中国的y coding类的真没有，所以他说web coding类的只有replay loveable，然后boat已经跌出这个版了。但是特牛的是美国的某个基于顶尖外coding的使用群体，就是某个信用卡厂商，信用卡交这个支付那个应用的厂商。数据表明某个顶级y coding平台的使用群体在注册数月之后，收入留存率高达百分之百。就是他算上流失用户以后，整个群体的月整体的开销还在增长，所以大家对one coding类的需求还是挺高的，而且都是付费需求。所以我觉得国内现在还没有出来一个比较好的web coding是一个叫机会也好，我觉得是一个可惜。

千问和那个字节不都有吗？那个专业的web .

coding，对专业的one coding还是比lovable，比replace还是差太多了。你像千万那些这个豆包，千万那些都是做个应用而已，但replay和lovable那些都是对接整个软件技术站的OK。对，所以super base我觉得国



内是有可能有这个机会的，就是有一家跟y coding结合的很好的数据库厂商。当然我现在没看到谁谁合适干干这个事儿，能干这个事儿。

但是我觉得可能国内有一个全栈的类似于super base这样一家公司是有机会的。就是给所有的y coding厂商提供背后的数据库服务。你看他的巨大拐点就在这儿，他接入了loveable，接入了bot接入rappid，然后整个使用量就暴增了几倍以上的暴增，所以这个就是今年整个今年应该有三四倍以上的保存。所以国内谁能做这个事儿，我觉得大家如果有认识这类的做这方面的公司的话，可以去考虑一下。然后有些全明星的公司就不说了。对，然后整个全球发现英国还是有一些公司，英国像这个eleven lives语音的那个we的做视频的都在英国。然后巴黎，对这些我才知道这个hugger face是法国公司，我一直以为是美国公司。所以这个基本上大家可以看到，整个的前面的这些模型的这些应用的局面有一点平静下来了，就是格局已经开始成型了。

然后如果现在有一些新的这个就大家可以去盯一盯这个有没有哪些赛道的还有新的机会，我觉得这个事儿是一个挺有意思一个报告。好，然后这个就是HUZ新的。然后上周两个。

这个产品硬件产品。

一个是钉钉出了一个录音的那个proud，他出了一个proud贼便宜，八百，加上还免费送一年的这个会员。说白了就是你你可以无线录音，然后只卖800块钱。我靠，他知道pro的，对吧？你看他知道我把谁飞书。

飞书飞书。

我觉得它的硬件生态其实做的一般，一直都一般，就是比起钉钉还是差的太多的。但这事儿，其实就是你我觉得他如果是众多用户，这个钱肯定是亏的。就是你像我一天如果8小时，就算一天只工作8小时，我录下来，然后做转码，做分析析，做总结，我靠那这个这不起不几个月就把这个本儿薅回来了。但是他自己的他他选啥模型，肯定是他自己会去选，选一些便宜的模型，但是他也得保证质量。对。

然后另外一个就是这个proud，大家在看之前我买过这个，给大家展示过这个小小录音笔就可以吸在衣服上。然后他出了新的一个pro的note pro这么一个东西。这个跟上一代其实差别不大，就是好看一些，然后性能强，而且喇叭什么的都都好一些，然后可以直接拿贴在手机背后来录音，然后在这个会议现场去帮大家录，然后随时总结这个大家说的话，然后也增加了一些你可以随时在边边聊边记，这个功能，我觉得还是挺有用的。这个哪儿去了？

就抄那个granua。

对，granada叫grana。对，之前给大家也介绍过，是吧不是吧？不是网站不重要。对对对，之前给大家推荐过。但是那个时候那个那个应用其实它的本地端就是管我看看叫啥。

我还是有个问题，管道这东西是因为手机的硬件，他能弥补哪些硬件上的问题呢？

他这款。他这个我觉得一个是用iphone的人没法录音，哼为什么？对吧？为什么大家用iphone打电话的时候是不允许录音的？而且这个系统电话是你你你想录音，对方会听到开始录音的那个按钮的，按那那一句提示的对，所以是iphone上是没法录音的，所有的安卓手机都有这个对吧，就是双方录音的这个记录。而我我觉得这个也就是上周，跟大家跟我们同事在讨论一个点，就是大弊端。

很重要的一个切入点就是会议场景。而会议场景就算连最大的讯飞，其实现在都还没有做的很深。我不知道大家平时公司里面这个录音或者做会议纪要什么的到底用啥。我觉得至少现就算连我大概买了得有67款讯飞的那种录音笔的那种产品了，我觉得都一般。他都没有把它做的那么随身。比如像这个no pin这种这么随身，或者像这个pro的note那种直接贴在手机背后就是很很自然的来去做。所以这个pro这家公司很牛，去年一年卖了两个多亿两个多亿的营收就卖这个玩意儿。

所以我觉得就是查这个叫什么会议这个场景是非常值得去深切的，尤其是借用大模型来去升级，抄的这个抄这个过了之前也给大家说过，说白了就是你看这个我觉得这功能做的特别好，你边开会的时候肯定会边记一些东西，对吧？就是100什么东西，这个用啥用了啥用什么东西。好，你开完会你记得这些东西，你还记得吗？肯定就不记得了，对吧？所以他通过把你开会的时候所有东西都录下来，然后再根据你记得这些有的没的，这些的很很乱七八糟的东西给你补全成右边这样一个会议纪要。我觉得这个特别有用这个东西。因为我现在拿 notion 啥的记会议纪要的时候，其实他会跟默认的跟我这个AI生成的会议纪要会有冲突，对吧？

你想如果你寄了一堆东西，他我只能拿我寄这些东西再去扔给一个AI纪要。这个会议纪要这个东西它是对不上的。我说我写这字儿到底在几分几秒，它是对不上的，只有又录音又你把你的实时的笔记记在里面。因为你只要记，他就可以随时知道说几分几秒的时候你记了啥，对吧？把这俩一对上，他就真的能让你最后纪要里面知道说你想要的这个部分对应到的是会叫的哪部分，就是有人工跟AI强化的集成的这部分。

你有用过这个吗？我印象中他好像中文。

他对中文当然不好。对他当然，但是他的是电脑端支持中文了，手机端支持中文了，电脑端没支持特别2。所以我但是我开会的时候只能在电脑端记，对吧？所以结果他手机端能支持中文电脑端能记note，这俩就没法协同起来。但我觉得这是这个功能非常好用，现在只能用它就干这事儿。也就是说这个会议这个场景，我觉得是现在大家都开始去很明确的要把打进去的这么一个点。所以可能就我猜接下来就会有一些厂商开始砸钱去搞这个纪要这些场景，尤其是国内这些模型推理的成本也很低。

飞书智能会议记录硬件就是原来设备。对，但是你想有多少会，你是非得在会议室开的，随时要去跟同事聊个什么东西，这些东西咋记。而且你边聊，你但凡聊嗨了就不可能会对吧？这个就一旦忘了这些你们聊嗨的东西就很可惜，非常的可惜。这些数据。

所以我觉得有一个大家在会议过程中约定俗成的使用方使用习惯。就是说别什么大家聊一些隐私的东西，还开着录音笔。然后有些场景大家就是要来脑暴的，那我就直接默认的打开，然后带着这个东西就聊，聊完了以后大家聊嗨，这些东西自动就能给你总结出来，避免大家遗忘，然后甚至形成这个next action。我觉得这就非常有价值这个东西。所以我觉得公司来说反而比个人这种东西有用多。

就是你在公司里面有些大家，比如说我们可以先设定好一些约定俗成，就是我我我一旦大家要聊些什么的时候，聊些隐私问题的时候，就默认把它关掉，大家自觉把它关掉。然后如果聊工作内容我就打开，大家也不会反感。我觉得如果有这样一个公司文化的话，这个东西就会变得给大家提效非常多。然后看看下面这几个，这几个有点那个啥有点太过技术就先过。对我说两个事儿，两个事，AI的nas要出来了。

大厂。

就是大这那是吧啊，然后就是你个人的家里那种存储数据的这个设备，什么群晖这些东西。然后之前做AI nas 都是一大堆小厂子，我操这都啥玩意。都是小厂子，当然绿联什么也在做这类东西。然后有一个大厂要出来，

绿联这是绿联的AI nas，就是里面自带算力的nas。那这个东西场景还挺明确的，就是你你的不能出具的数据，然后只能在本地去计算，然后那就放在这边。比如说你是个研发部门，你是个法务部门，你是个什么财务部门，你的大量数据其实都不能出去，所以必须得用这个AI来去存，那个nas来去存。然后你如果放到AI这个传统nas里面的数据就停在里面了，没法用了。但是如果这个nars本身带了reg带了知识库的话，那你不就可以直接去问他，就是让他去各种AI搜索这一件事儿。

然后这个东西有一个大厂要快要出来了。所以我觉得这个就是有一个很廉价的大厂，也不叫很廉价，就是很大众的大厂。但是我觉得那家股票不太有参考价值，因为他已经很大了。

但是大家可以想想AI nas它里面要配的是啥GPU，这是个关键点。对，就是我如果有一个有大量的数据的nas，它的算力我怎么能塞到这么一个玩意儿里面，塞到这个玩意儿里，那肯定不是N卡对吧？那到底是啥卡利好存储板块我觉得不利。好没啥意义。

我觉得其实就是刚才那一点，就是到底这么一个对，就是到底这么大一个size，这个nars能放哪家的AI芯片？这个大家是可以想一下的。而且其实现在已经不是那么跟之前不是给大家看过几个，包括M5 stack那个就这么大，像口香糖那么大的一个一个板子，是630C还是620C那个那个方案，然后这类的都能跑个1B2B的模型。那大家想想这么一个玩意儿里面，我就把这边全拆了，或者就把底下放一个很放多个，或者放一个比较大的AI芯片。那这个东西我可以对整个你几个T几十个T的数据做非常多的离线处理或者在线处理，对吧？所以大家可以考虑找国内能够塞到这么大的板子里面来了，其实AI芯片普遍都利好，所以这个肯定不是毛衣家的事儿。

光波导演，上次我说没说光光，光波导演这没事，超哥还你还记得吗？记得体力。对，就是单色光波导可能更快了，就是单色光宝岛的这个华南北的出货会越来越快。然后他大家可以想象是什么呢？就是这个玩意儿的廉价版，g one的廉价版，就这个东西廉价版，那它的廉价版，它的非光波导板差不多卖300块钱人民币。然后带光波导的板，很有可能加起来再来帮你。

不明就里的小伙伴们问一下，什么是光波导？

是啊光波导就这就这个东西，你看这个为什么他这个眼睛为什么能看到东西呢？就是因为这儿有一个两眼镜的这个镜片上，这个玻璃镜片会有一个涂层，这个涂层是需要做很多材料学的研发的。所以基本上大家看，如果做一家眼镜厂商，他自己内部是没有做材料学的博士这类的人才的话，大概率他就是找别人代工的那找别人代工或者这个ODM的那他可能在显示效果上就做不出什么这个经验地方。

然后这个是有一个图层，就是光波导的一个图层。然后右边这儿或者左边这边会有一个光机，那个光机说白了就是投影仪似的的东西，那个小小的投影仪，它会把一个光从这边打到这个图层上，然后通过这个涂层反射到你的眼睛里。然后你就好像在前面看到的这个效果，其实就跟汽车的HUD差不多。这个意大概的意思，然后这个HUD就等于你在埋在你的眼睛里，所以光机能不能做小是一个很关键点，以及光机能不能做便宜也是很关键点。

现在这个g one的光机很贵，然后它的板子也很贵，所以这个g one他卖600刀。你看六百刀，然后华强北的版本大家就可以想象它是个5分之1以下的价格。我觉得是差不多。所以当然华强北的整个供应链是比较那个啥的，上次像什么利差，这些其实都算他的比较下游的供应链。然后华强北自有一套自己的拿东西的这个做法，也比较野。所以我觉得这个不太好找对应到的一个投资标的，这是个问题。这真找不到我，我反正是真找不到什么投资标的这帮人。

然后对这几个，另外一个我觉得这挺震惊的。我靠，我当时看也不叫挺对，算是挺震惊的。Google要出他的L一的区块链了，L一的区块链是啥呢？比特币这种就是L1，所以google要去找自己的L1，而且google cloud

自己做了一个我cod的那个叫啥，我cod有一个自己的web 3页面。Web 3 google对这。这是girl cloud的web 3的这个portal，然后它里面有一个叫universal ledger ledger就是叫什么账本。

其实大家理解成为什么现在大家说这个稳定币这件事儿特别重要？就是稳定币借助web service这种账本技术，可以做到非常高效的跨境支付。那它他做了一个web，就是google cloud，google的云专门弄了一个web 3的这么一个分支。然后他自己做了一个一这么多年了一直在做这方面的研究。然后他终于要做自己的ledger了，或者叫做自己的料了，而且他有自己的什么web 3的AI，乱七八糟这些东西，都还挺牛的。

所以他之前一直这些云厂商，之前包括AWS这些，他之前的核心生意就是干啥呢？就是帮你们这帮大模型，帮你们这帮链儿，像crypto这些B比特币，ETH这些索拉纳这些币去搭建节点。那大家理解一个节点就是所有的数据，所有的账本都在这个节点上。所以现在像比特币，像以太坊巷、索拉纳这些节点，就这些链的完全节点是非常大的巨大的。所以其实说白了，大家自己在自己的电脑上，在自己的甚至自己的云上搭一个节点，这些事儿都不容易。好。

那一旦他到了这个量级，那利好的是谁呢？那肯定是云厂商，对吧？就是谁能把你的一个不容易去做运维的节点运维的很好，那以后大量的生意就都让云来去干了，对吧？就比如说我要搭一个比特币的节点，我建议自己去搭肯定很麻烦。因为如果你想做核心节点的话，你得保证你的什么稳定率、在线率，然后交易成功率，延迟什么，这些都在一个很很好的一个范围内，但是这个个人开发者其实很难做到了。

大家其实现在越来越多的说，我直接从云那儿哪一个节点你帮我运维，我只通过API来去调就行了。而现在google一直做这个事儿，做这个生意，以前基本上都是之前的生意都是AWS，现在变成google的生意了。然后google现在越来越多的跟一些金融公司来去合作这件事儿，于是就到了他现在他要推自己的L1。

所谓L一其实就是刚才说的这个比特币这级别的，这个coin都叫做L1。然后像什么有一些小的就是中小的，其实都是所谓的L2、L3。就是基于现有的这些一层的book chain来去做的上层的東西。所以他这个universal ledger就是他提的LE而且什么呢？他现在能做到专门针对什么场景做金融，做commercial bank这些东西。而且他一个特牛的是这个东西。大家知道智能合约，就是说白了我比如说如果我打昌浩一巴掌，然后昌号就给我十块钱。

然后这件事情，我希望他不以人的意志为转移，那我就需要一个智能合约。这个智能合约就写的是，我打了昌浩一巴掌，昌浩的从他的某一个钱包里就要把十块钱转给冯小平。那这个事儿怎么确保它执行呢？那就是靠这个智能合约。而以前的智能合约都靠的是别的乱七八糟各种语言，那些什么move什么这些语言都是小众开发者的。而google搞这玩意儿直接写python。所以大家可以想象以后的智能合约的这种开发者会是一个特别的猛增的一个数量。就是你写pi都只要能写python就能写智能合约，当然刚才那个例子，我不知道这个插好有没有感觉有一个还不靠谱。

关键是你打我巴掌这事儿上不了链。

对，就是我怎么证明我打了那么一巴掌。所以就有一种叫oracle的玩意儿，就是预言机这么一个玩意儿。所以这个东西是靠一些各种的办法，有这种加传感器，有这种加各种的。所以叫什么东西来着？就是直接对接一些确定性的数据，什么卫星云图，这些东西来去保证。你看就是这种靠各种的input，你可以是金融数据，可以是天气数据，乱七八糟的。然后通过一个大的网络，然后这些网络能够通过到都把数据打到中间的一个blockchain里面去，不是通过这个这边有一个oracle来去判断，让他比较大概率的判断。比如说今天的某个股票涨到了50块钱以上，这样一套东西，然后一旦被oracle证明，被这个oracle，不是那个oracle，这个被预言机网络证明了的这一个事件，就可以作为刚才我说的这个智能合约里面的这样一个真实的来源。

所以如果比如说我们放好几个摄像头，在在这个窗口旁边，我就扇他巴掌，然后好几个摄像头都认可了，然后都是有这个节点的，然后都有这个oracle节点都认可了。好，那它自动转我十块钱这件事就有可能实现了。所以我觉得当然google要搞这事儿，核心肯定是做金融了，这肯定要想象他要做金融的，而他做金融那就挺可怕了。你想google的用户好几十亿，然后有好几百个合作的商业合作伙伴。

那他一旦推一个自己的L一级的量，那确实我觉得是能抢一定的像比特币、USDC、USBT这样一些生意。当然他不一定抢USC对CT生意，他至少能抢现在的主流的这些LE的coin的这些B的这些生意，所以还是挺可怕的一件事儿，而且更不好的是什么呢？不要对B圈更不好的什么呢？就是光靠的搞这种L1，它肯定不会像那些乱七八糟的币一样，说我开始做一些什么空投这些东西来去希望有更多的人去加入，来去加入到他期间网络里面。因为功耗本身就可以足够多的这个节点，而且他加上他的合作伙伴加起来这个节点数就足够多了。所以对于以前那些薅羊毛的这些web 3的玩家来说，我觉得google code，google搞的这个LE的量其实是利空的，或者说至少不会带来很大的好处。所以这个是google搞这事儿的一个我搞了个逼，说白了就是因为这个东西B也不一定是真的能花，但是它至少是L一级别的量，是一个很很重要的一个事儿。

好，那我们说说这个agent。然后上次给大家看了那个auto GM这个东西，对吧？Auto GM的它其实就是一种所谓的東西，就是我们叫CUA computer using agent，用电脑的agent。当然我们把手机也定义成电脑就一样。但是除了CUA之外，还有啥呢？比如说coding agent，就是我们说的这个clour code这种agent其实也是。

然后deep search agent，我们年初看到的各种agent对吧？他咋干呢？就是有一个需求汇总，然后需求会打开主A阵。主A阵都会把这个任务分解成一大堆子A阵来去干，然后还有啥呢？就是这种agenting reg对吧？一个活到底一个问题到底应该从哪呢？那有一大堆数据源到底从哪拿？有一个自主的rag来去找。

当然也有一些voice agent语音录语音出的这些东西。还有很多A镇相关的一些协议，比如说MCPA2A这些东西。所以整个A镇是一个特别庞大的一个体系，那里面有啥机会呢？我觉得。

像上次说。

了那个APP color是吧？说没。

印象了。

对，就是我们现在看到的各种APP其实有大量的信息，然后如果我能抓别的APP里的信息，这件事儿其实是一个挺大的一个信息源，一个数据源。而这个数据源以前如果想，因为现在有越来越多数据只停，尤其在国内的这个生态里，大量的数据其实都只停下局限在手机APP里才能访问到。什么银行、保险这些数这些APP大量的数据都只停留在他的自己的APP里。那你怎么想你想怎么把它爬过来是个很大的问题。那如果按照传统办法怎么做呢？当年我们怎么做？其实就是我去逆向人家的APP的协议，然后我看他这个key怎么填的，怎么生成的，然后去伪造他的key，然后造出一个请求去访问那个APP里，那个一般都是个网站，把那个数据拿出来，如果不是个网站就更讨厌了。我觉得更更把这个网页里的数据给造出给抠出来，所以这个是当时的爬法。

但是现在这种CUI对吧，这种computer use的agent，如果相对来说越来越丰富以后，我可以拿这个东西来去爬别人的APP的这个网站，不是对他APP里的内容。对，然后这个就延伸到下一个，就是所谓的dissolution的APP。如果大家有了一些别的AI agent APP里的内容，我是不是就可以拿那个数据来去做蒸馏了，就是我可以纯拿一个别人做好的编排好的agent里面的输入和输出，输入我我我自然应该有，对吧？

因为我有就是我输的它的输出，我如果有办法通过APP的方式，比如像找一个x GPT这种东西。如果假设一个ChatGPT它只能在APP里用，那我如果能把那个APP里的输出拿过来，我拿了大量的输入输出就能像什么呢？就像现在主流大模型厂家一样，去蒸馏其别人家的大模型。那我蒸馏完了以后的这个数据，我其实默认就具有了这些已经编排的非常好的agent背后的这些知识。我觉得这是关键对吧？就比如说你看到一个不错的法律agent，比如做一个不错的工业这个agent排工排站A站，然后你把他的大量的这个问题扔进去，把它结果拿出来，我是不是就可以拿别人已经做好的这个agent工作流的数据，这个工作流它背后的结果，来蒸馏我的数据，蒸馏我的模型了。所以就可以把这个，比如叉号搞了一个很牛逼的AAPP，我就把它给蒸出来。

然后扔到我自己的里面。最核心的问题其实反而不是你优化那个结果，很多时候是你如何能获得更符合实际场景的那些人。

对，这个就是A镇厂商做，就比如插到这种的创优秀的创业者来做我的意思是说。

我比如我做好了一个APP对吧？那大家可以随便的用它，然后来去得到一个排产的结果，你即使用Brown use，我觉得就很多时候这种蒸馏的时候，最重要的问题是你得有那个输入。对，其实输入是核心的。就你不知道问啥是吧？对对对，你不知道就是你的一组合理的一组sid是什么。

你讲道理。

我虽然是一个很好的evaluate或者是一个模拟器，然后可以去帮你去做evaluation，但是你还是得自己去搞定那个输入。输入这个东西里面你也可以用AI生成的。生成我们自己感觉效果还是跟实际的这个数据有有差距。

对，有道理。对，生成这个问题是个关键的东西，这个东西不是那么容易做好。好，然后A镇AA镇的音响有非常多。然后这家公司好像这家公司还是国内的公司，就专门做这个事儿的，帮agent来去做computer和smart phone。然后国内一家公司做的还挺不错的，我之前看过他们的一个分享。然后说白了就是我可以立刻用各种模型给各种的模型的agent配他的电脑和手机。这件事儿其实没有大家想象那么简单。

虚拟环境是吗？

对，这个你可以立刻给他对吧？那这个东西你其实想想，如果他to b是不是就更直接了，就是跟原来的做云云电脑一样的生意。

明天这是给人用的，他给人家用的。

对对对，直接对标过去。所以我觉得还是挺挺可以参考的这个东西，然后别的我看看，对我我前两天用了一个挺那啥的，就是那天跑了一个给大家之前看过那个小的板子，那个板子差不多不多，也就四百多块钱。然后能跑一B还是1.5B的模型，大概推理效率能到每秒五个token，差不多三五个token这样一个量级。

稍微有点少，能感受到明显的卡顿对吧？

还行，就是可用我觉得是可用的状态了。就是你如果用来佩戴。

跑几B的模型。

1B。

那应该之前就比这个好了。

他的片子就非常小，整个板子也就一个口香糖那么大。然后里面的芯片可能就630C的那个那个方案，然后就很小，四五百商业就是零售价。大家如果想那种东西的话，如果能工业场景肯定这个价是OK的对吧？就是我再贵一点其实都OK，然后这安全场景那就更OK了对吧？一个什么智能炸弹配一个，然后另外我当时看到我用了下rocket那个新的那个glasses。我不知道大家有没有玩过那个那个眼镜。Rocket .

classes在上海的人工智能大会上用了一下。

对，就是它里面有一个其他功能，大家肯定能想象到。但是它有一个本地翻译，就是在眼镜上有一个模型能做稳定翻译。那个效果真的是出乎我的意料的好，非常不错。所以我觉得这个可能一定程度上也代表了我们的智能眼镜可能比他之前我想象的还快一点，能找到一些比较有价值的PMF的点，而且它能做一个特有意思的功能，就是方向性。比如说我正对着陈浩聊的时候，他真能翻译，我错开了，转个头我看别的地方他就不翻译了。这个事儿是一个，而你拆他那个眼镜的时候，你可以看也我没拆没真拆，不敢拆他们给的工程机。然后你会发现他其实麦克风就很少，其实没有太多的资源去做阵列，所以还挺好奇到底怎么去做的那么精准的判断，这些事儿肯定是有办法做的。

好，所以大家如果看到A站领域的话，这么几个事儿。一个是这个memory，如果做memory的，如果看到一家公司说做agent memory，我觉得如果不是很有名的那些就可以再观看，这个没有太多的，至少目前没有我觉得没有太多的技术上的范式变化。机会也不大。但是3 box就刚才说的专门提供给agent的电脑，给agent的手机这样的一些设备的3 box是有机会的，而且挺空缺的。然后第三个，就是企业级的这些第三方服务。我觉得像这种如果能对接企业的ID，对接企业内部的这种用户系统，然后各种的log安全系统这些事儿，这些是有机会的对。然后最后一个看一下这个called called，called。

对他最近发了一个这个东西，还在非常小范围的在只在他的max用户，就max好像是最贵的那个是吧？两百多还是三百多的那个还是多少钱？那个用户群里在找，他在马上要发他的这个also use，就是这么个东西。就是用电脑的那个A的那没法看。对，然后他的agent还是以他的这个chrome为主，所以它是一个基于chrome浏览这个叫什么extension的这么一套东西。然后你可以直接在里面去用它的cloud来去操作你的网页，然后能干各种事情，然后可以从里面看到一些东西，就这个功能上都很很容易理解了。但是我觉得后面这一点就是他讲了一大篇关于你的网，你的他怎么保护你的靠cloud for chrome被攻击这一点啥意思呢？就是比如说你如果拿用computer或者用浏览器的这个agent去访问你的这个网页，让他按照你网页里的这个描述来干活的话。

如果这个网页里面是一个钓鱼邮件，你看遇到了一个恶意邮件，这个邮件冒充雇主要求删除邮件，删除别的邮件，以做什么邮箱卫生的清洁，而且并说无需再额外确认结果，他的这个browser use的这个agent直接就执行了。点击等2秒，然后截个图，然后删除了。对，然后这个也是就是有一些恶意邮件。如果这个恶意邮件不是给人看的，是给A人看的，他就会被攻击。

大家感觉这个跟好好多节课给大家讲的，之前讲那个LM安全那个很像，就是有一种叫inject prom injection提示词注入这么一种攻击很像，对吧？就是我通过一些办法把我的网页里面的内容让大模型读到。并且大模型并不会以把我的这个内容当做一个单纯的纯内容来对待。而当指令来对待这种情况下，就会产生注入攻击。所



以对于浏览器网页是一样的。你看它直接如果有一些恶意的这个邮件进来，他就会按照他说的来去执行，所以这块就会涉及到很多安全防护的点。

然后他现在这个不太好的点是什么呢？他如果没有做任何的安全防护之前，他的所有的攻击百分之百里面会有23%会被接受，会被攻破。所以他们做了一大堆安全的这个措施以后，23降到了11也不低了。

其实所以这个代表带来什么呢？就是他跟他自己的clock close computer youth，跟最有名的broster youth做了个对比。他现在确实是最低了，但是也有11%的。所以大家不要把这个叫computer use，或者像风use，或者像broader use这类东西看的太近。他现在如果你真的把它放到三个人用，你个人玩玩也没关系。但是你一旦说进到商用里面，那我觉得这个安全这个问题还是比想象中的可怕的多了，对吧？你想想你如果你的邮箱有一些非技术人员直接看到一个邮件，然后结果用browser use。

大家用惯了，不知道是you直接说，你帮我回这封邮件，结果他把你的邮件这个该泄密，该删除了，那就是一个非常大的一个问题了。对所以靠这篇文章，我觉得他做什么试点做这个research我其实没有太大兴趣。我觉得他这个带来的就是brother use的安全问题，还真的挺严重的对，所以大家如果去玩的话，一定要注意一下这方面的风险。

好，那今天就这些，你看看有什么问题。Google发行稳定币吗？很有可能他不发行，他不太可能发行。因为发行稳定币这事儿，他是个美国公司，他肯定要服从这个circle，就是美国那些标准。所以美国合法的发行稳定币的就是tester和coin base，USDCUSDT这两家。那他肯定是跟其中一家合作，应该是跟空base合作，我猜，所以他其实就是应该用，但是他发个L1，这个L一上可以跑稳定B对，这个大家理解一下就行了。他发了个链儿，这个链儿是一个最底层链，跟比特币并排并行的。这个链上可以跑USDC、USDT, 那它就可以把之前那些什么索拉纳上那些arbiters什么这些量上跑稳定币的这个生意抢过来了，而抢这个生意赚的钱真的挺多的。

大家不要觉得这个币的区块链稳定币交易就成本足够低，很低没有了。就是他只有在跨境交易本来成本就很高，而且时延很大的这种场景，你看到那个成本时候，你才会觉得OK值。比如说你转个转个几十刀的这个币，结果你会很有可能会发现在某些网络，某些平台上，它的成本高达几刀。对，但是你发你国跨境交易，你转个几万刀，你发现只有几刀的成本，你就很开心了，而且瞬间到账，所以都是在跨境交易。所以说什么义乌小商品市场什么很多在用这个稳定币。

一周涨了20%，买那个板子叫啥？你说他的名字。

我看看这一块这个LM630，这个是M5 stack这家公司的m stack这个很有意思。大家如果玩硬件开发的话，可以去玩一玩。就是感兴趣的专业的人可能就不需要用这种东西了。感兴趣的像我这种业余爱好者就可以买买这种板子玩一玩。你很小，而且里面跑的是个安卓，而且里面跑的是个安卓，你看这个网口都比他大那么多。

OKL好。

大家住一周涨了20%了，我靠谁买了？大牌子的眼镜智能眼镜做的好，其实就那么几家，影木，x real.

rocket X。

对，rocket还有谁？小米确实很猛，最近我靠最近这一波真的是被他吃到了。然后就是出货量。



卖的好吗？

小米的那个据说真的很高，因为它直接对标的是那个ribon不对，标的是那个meta的。

ribon卖的好吗？卖的真真卖的好吗？

听说几万台了。因为它其实价也不太便宜，2000块钱的。所以我是觉得这个meta的眼镜GBL收到了明年底要出货百万台的订单，百万台下一代眼镜。

他的供货商都我知道上次跟一个做。

芯存储芯片聊过，都有这样的。咋了？百万级。对接下来。

的就订单的产能预估。对每年作为供应链来讲，他会跟代工厂沟通一个产能的预估，然后让代工厂流出一些产能，你能不能实现人家了，我觉得不好说。

对我觉得meta他至少上一代。

你听那个八卦了吗？就是meta的人离职了。

就是那个super target团队又又跑了是吧，跑回open I了。

跑回OpenAI。

对对对，所以这meta这样的公司肯定是企业文化有问题的。你花个一亿刀招人这种东西，我觉得即使牛逼人很多，但是你大家都不很不平衡，我靠有多少我觉得。

对他来说这个策略是对，就是说我有很多问题，但是我把靶子立在这。那你想想看，说这个其实也没有什么不好的事。

觉得不好说，我觉得meta这个还是有可能还继续落后的，我觉得大概率还是会继续落后的。小米这一代不好用，再等下一代。这个同学用了是吧？那个两千的那个。我都没用，我当时看了，因为它不支持开发，所以我就没啥兴趣。

然后我再说一嘴，那个rocket rocket那个rocket class它基于的操作系统是安卓go，是一个轻量级的安卓系统，所以它的好处是开发的开发者生态做的比较好啊，就是可以写这种应用的人会比较多，而且整个开发的底层比较结实。然后与之对应的就是我见过最那个啥的，就很其实很多眼镜都是私有化的，一些底层甚至没有SDK。有一家叫之前做做手机那个魅族。对，魅族有一个他的眼镜被一个叫star star v是吧？对，star v这个也是。对，不说别的，就说它底层的这个开发者生态这块其实做的很差，也不叫很差。就是他要走自己的

专属路线，所以他底下的东西全都是自己的，所以开发的应用可麻烦了，几乎就只能指望他官方出APP。所以这事儿就。

跟打一个苹果了。

对，就是你要不成下一个苹果，你要不就死。所以对，所以这家公司也不太好了。

觉得也没毛病。现在真正能够在这个眼镜上开发应用的团队还没起来，所以早期可以往后去领先。

对，但是想想这个你想苹果当年不是你得自己先推出一系列真的好用的应用，然后再开放整个开发者生态。但是你如果开始了开发的门槛都很高的话，他自己人开发效率都有限。我觉得这是他们没有在尝试构建生态这件事，我觉得应该早构建。小米也没啥功能。对，所以这个事儿你想没有啥功能的眼镜卖2000，我觉得挺奇怪的一件事。而且以小米的身份，当然另一家他可能不叫另一家，就是刚才说的AI nas那个对吧？大家可以考虑一下。

然后现在做论文有什么好的agent？做论文的有什么好的agent？你指的是agent来写论文？写论文那就就经典的就萨卡纳这个v two跑起来跑起来这个如果跑出了好的结果且顺利的毕业的话，跟大家在群里说一声，对，这可是被ICLR收纳盒ICL2025接受论文的这个框架。这个框架是当然你得跑一点好的模型，gym a什么的模型会更好一点。我们当时跑的测试确实gym a比甚至比GPT4O还是O三都好一点。还有啥？

超时了三分钟。

稳定币不是，不是跟circle一样不稳定，没有蓄谋已久，蓄谋已久。我觉得倒不是，他其实google不是这个生意。对，就是他跟AWS其实应该是同一个生意，但是他做的更更偏突大臂。还有啥？没啥。

好，我先看了，应该都基本回答了。祝小平老师在哈尔滨玩的愉快。

大家哈尔滨有什么推荐的吗？我明天就回了。大列巴、列巴真不好吃，我觉得可以打人吃的最好的锅包肉太好吃了。

锅包肉你还是要去吃，疗是锅，黑龙江锅包肉的表情。

烧烤真的是几乎一天一顿，我吃的太多。了量太大。

烧烤对你也可以去试试辽宁的烧东北烧。

CC的安装的国内是不是只能用质朴？不是，他对他接什么这件事是取决于你的接口是不是跟cloud一致，所以这个就是接沙其实应该。

是辽宁的是吧？

这多少？对，其实像kimi的k two，千万都可以接，这个都都好说。我去，我用平时用不用这套了？对，这个可以接那个k two接千万靠千千万coder接质谱的4.5其实都可以，只要你看他这个东西有没有做NN topic。接口兼容我觉得还是。

是个agent。Agent它可以选不同的底层模型作为基座。

但是问题啥呢？他CC他自己他默认接支持他自己的那个code API，所以你得找哪家默认支持了cloud的API，SRP那一片。所以你看其实就是检查这个东西，你看那家是不是SRPKPI兼容，如果是的话就可以接，只要改这两个值就行了。

我觉得这是一部非常好的一步棋。对，就之前open l就大家所有的开发者都默认open a然后所有大模型厂商都进入OpenAI现在会告诉你我跟open我不兼容，open老的就是一个新的。

老的就是就硬屌，然后捏对我觉得。

在竞争里面真的是在关键时刻要展现出江湖霸大气，对我我自成一派。我自己定义。

而且它是连带的，就是我的coding能力强，然后带着我的class code，对吧？那我这个时候我推出的cloud de就足够有说服力，然后我就有权利去搏一把我的API的话语权。

克拉克是开源。

的对对，是好的。心脏是什么东西？

对，就是降降这些东西。

熏茱莉、炖鱼、鸡架，可以，明天都试试。好的，谢谢。好好，感谢。下周见，下周见，拜拜。大家晚上好啊，晚安。