

大家好，大家晚上好，可能还有提前来的同学，优秀。最近这种模型方面还真挺少的。

这个感觉我觉得模型。

千万欧吗？

千万算，千问3的VL也让人很是期待。

但是千问三的千问以外，好吧，反正等待会先踢出去就没了。

前任现在特别牛，反正阿里最近股价狂涨。

对我们那让我们先聊聊阿里这种开源策略。其实之前大家一直都觉得就挺傻逼的，或者说至少对模型厂商来说，你这就是来搅局的。但是现在这么看起来，要不就是吴妈的这个叫什么vision，或者这个预判贼牛逼，就是他应该能早预判到这个大模型本身这件事儿是一个很快会趋同或者趋近这个就是差异性很小的这种状态。大家比拼的其实就不是模型核心，模型能力，而是整个外围，或者说你能赚钱的这个地方。所以阿里，那他现在靠也比较靠，它模型本身带来的这个云的收入肯定是非常大的，当然另外其实更也很大的是那个谁，那个霍山，所以这招真的挺牛逼的。所以确实把这些所谓的大模型创业公司，给搞得很很尴尬，对吧？你就说比比模型能力，比算法，其实确实理论资源上确实比不过大厂。然后你论赚钱，他直接给你断了断赚钱路子。从模型层面，然后平台你说你搞我靠我搞一个贼牛的开源调，对，所以没辙。就是对阿里是很重很注重千问的客户。

对，这就好像是一个体量，是你多少倍的客户对吧？他按照百分比的技术投入，他也有更好的投入的机会。而且对于阿里来讲的话，对它核心就是商业化，它商业化能力超级强，在街上这些能力还是有很多的空间的对。

咱没了。对，咱这个直播间里同学是不是应该也有，我猜应该大半都是阿里云的用户。然后就如果公司阿里云的用户，那如果你用阿里云的话，默认的其实千万什么的，就是就很方便的事儿。然后你如果真的做点AI的模型的话，其实像ModelScope什么这些已经做的确实挺不错的。你这个就让一创业公司抄这么一个都很难。抄一个比较好的这样的一个model scope这样的一个中国。

的hugg face hugger face。

对但是他的这个MCP里边做的还越来越好。就是他的MCP的这个plus或者叫marketplace.

我们最近在用那个阿里系的agent score.

agent确实。

是我觉得是有很多可圈可点的地方。对，我们觉得对我们准备弃long graph的坑投靠agent scope.

为啥？

就蛮不错的，就是long grab现在它有一个run time，其实是必然的，他会倾向于让你交钱。

然后。

相比较而言，agent scope可能还是我觉得潜力蛮大的。

对，因为前几期讲agent的时候没有讲技术细节的东西。其实我们可以看一下agent cope，既然讲到agent cope，这个是阿里开源的一个，它叫面向agent的programing和构建大模型应用的这么一个框架，或者说简单大家理解成就是一整套全栈的agent框架。

简单来说，就是我我稍微补充几句。

就是全占到啥程度呢？你从底。

咱俩好像有延迟，sorry. 没有，你说你说你说，好像我俩延迟，我看你没说话，我就叭叭叭说。后来发现你一直在说。

那是我的网不好吗？大家听我们俩那个声音有问题吗？来，大家听我们声音有问题吗？

想听我们俩谁说话？

帅帅的先说。

行，好吧，那你来，来。

OK好，我回过来，阿里确实是很擅长干这种，就是把哪个行业的框架相对来说比较成熟了以后，咋我直接干一个最全的，而且相对来说最有开发者口碑的这么一个框架，然后就垄断了。你像什么这个spring时代，其实它也有几个spring的框架。Spring阿里的那个阿里spring那一套框架，其实也把java的这个spring开发者去捞过去一大堆。所以如果我们认为现在A镇的框架已经到了一个相就至少现阶段是一个比较成熟的比较定型的框架的话，那就是agent scope。就这个项目agent scope。大家自己开发或者公司的同事的话，还挺建议的，挺建议去看一下的。因为既然阿里搞这种东西，大概率就是冲着去至少拢一部分开发者，拢一大块开发者的这个方式来去做。然后前几节课没讲到那么细的这个agent开发的东西。

大家看看这个框架大概就能感受到这个agent其实不是简单的，我接个大模型给他几个tooth写些prom就OK了的。他在工程上其实是已经是挺全的一个，所以我们叫技术站，那它的防这个foundation的基础的组件有啥呢？你看就这么几个对吧？这个memory记忆，这个短期记忆其实就是那个聊天记录了。然后长期记忆你可以做一些别的更复杂的长期记忆。这个model的API其实就是接各种的大模型的接嵌入的这些各家模型都叫这个model的API。然后to就是借各种的工具对吧？

咱们之前常干常见的这个MCP其实都算是two的一种。然后formatter这块有一个叫formatter，是啥玩意儿呢？就是我们经常比如说我说memory，这个短期聊的时候夸狂聊狂聊，然后狂聊的过程中，我肯定会特变得

特别长。我这context，我怎么去把它裁一些，这个成tion这部分裁剪什么的，其实也有很多的算法或者很多的技巧在里面。然后如果是人跟AI聊或者是多个agent聊，他在这个聊天的这个内容，就是这个message消息的这个部分的格式，还有一些特别的这个格式也要在这个formatter去做。这就是agent的三大组件，脑子记忆工具。这些其实大部分都就是人跟AI对话都基于这个message这个消息。

我们在开始就一直开始觉得message就是消息文本但是大家随着今年看了这么多推理模型，然后agent模型这些以后就发现好多模态模型，你发现这message已经也变得越来越丰富。除了文本，还包括它的思考过程，然后它的工具使用其实也算在message里面，因为它的实现是靠跟AI对话的过程中实现。我问你我这事儿到底要用哪个工具，你告诉我说用这个AA工具，这个就是靠message来实现to use。然后现在最近越来越多的，尤其是包括像这周的阿里的only全模态的模型，发现多模态的已经逐渐成为很明确的趋势。所以这玩意儿这些玩意儿都叫fundamental，就是这个foundational的基础的组件。

就是一个A站必须要有东西，但就有这些东西，你说一个A的拿来就敢上线，那肯定是不敢的。所以他还会有一些别的，尤其是你在上面做一些比较稍微复杂一点的agent的时候，你就要这些东西了。比如说react paradise paradise就是范式的意思，react其实就是reasoning and act，就是推理加行动，就是这事儿到底应该咋干呢？然后先想想，然后再去。如果要干要用工具干的话，他就调一个工具act一下，然后看看整个外部环境的这个反馈，告诉好的还是不好的，还是什么样的结果再去reasoning。然后根据反这个推理结果再去act，然后不断的循环不断循环。

这个玩意儿就是react，类似于react的这个意思，大家就简单理解这就行。这个玩意儿就是react这个范式是基本上现在主流的A证都是这个范式。没有什么太特别的地方，但这个里面非常多技巧，包括这个怎么并发的使用工具，然后结构化的输出，就是让我模型不输出人话输出个Jason，然后状态的保持这些东西，异步执行都算是react这种agent它的范式里面的标准组件。这些事儿但凡你自己去开发，或者用一些框架，就但凡自己开发，其实都都不少工作量不小。所以大家不要觉得这一波大模型的应用就没有什么软件工程师的事儿，或者这个码农就不上太上场了。这个我觉得还是有非常多的工程师要去做的事儿。

然后那那除了这种react范式之外，就是再往上我就会有更多的应用，偏应用的这种方式。比如说用浏览器的agent，用做deep research的agent，然后这个原规划的这种agent其实都算是一种。基本上他们的底层的这个范式都叫react的这个范式，但是上面就会做出一些比较原子级别功能，大家能感觉出来有差异性的这些agent级别的东西，它也都算是info。说白了你要去用它来去构建一个deep research非常容易。我估计就几行代码就可以搞定一个最初的版本，然后这两个部分组成的就是我去核心写agent部分所需要的框架。再往上，其实就是这个marty agent，多agent的corporation合作。

这个合作里面其实就有非常多的地方，包括这个我给大家想一想，我有一大堆这种级别的agent，那他们互相得聊天，互相得协做吧，互相得有人张罗事儿，有人干活。那这些东西通过什么实现呢？还是通过底下这个message，这个只是message，它是不是人人跟agent，而是agent跟agent之间。而这部分的message其实就通过一个message hub，它要有一个hub来去规划这些到底哪个message应该能给哪些人，哪个message不能给哪些人，应该以什么方式来去分发，然后还有一些pipeline，这些大家到底应该怎么去做这些事儿，左边这部分其实就是我们如果跑起一套A阵系统，它所需要的大部分的组件都在这儿。但是，我如果去开发，就开发给工程师，工程师还需要用很多工具。比如说就到右边这部分，这个为development和deploy yet，这是开发跟实施部署。那开发的部分有啥呢？那就太多了，就说白就是给开发工具，给开发者用的开发工具。

比如说像这个什么什么agent score studio，其实就是一个可视化界面，让你比较容易编排一个agent的这样的一个后台一个开发界面，然后偷拍了他evaluation的评估，然后telemeter就是怎么监控，然后怎么去可视化的然后跑起来，或者跑起来以后怎么怎么可视化的来去用来去管理。然后上面的部署其实就涉及到说我的这玩意儿，这A阵或者单A阵或多A阵到底跑在哪儿？你不能瞎跑对吧？不能跑我电脑上，然后那我就得有一个沙盒，或者说我到底这个跑在哪些工具上，哪些工具在沙盒里，其实都算在运行时，就agent cope运行时环境

里，只有你这些东西全都配齐了，大概率你就才能搞出一个比较商业级别的agent系统对所以这个是agent go给大家带来一个我觉得挺好的一个框架。但是这框这个框架现在应该还是比较在比较重度的开发过程中，应该还没有1.0了已经OK1.0那应该还行。对，所以大家如果这个真的要开发的话，其实可以像超老说的，你们你可以试一试这个我是没有拿agent scope做过这种全栈的工程，我就只是跑了跑普通的这个agent而已。对，陈浩你们跑的还是OK吗？

这套框架，对我觉得还OK因为是这样，其实一直开发者面临着两个选择，一种是类似defi code这种，它defi code其实严格意义说它针对的对象其实是低代码或者零代码。Long grab long smith这种，它从开发者的角度讲是更有更友好的，因为它open了更多东西，它底层是个SDK，你可以更灵活。所以在这个程度上，其实这两类是分开的。我觉得agent scope是比较好的在尝试去融合。你比如说以前那个凹凸镇微软出的，你就感觉他也是往这个方向走，但是就是有点不伦不类，就是两边反正都没有做的体验很爽啊。

然后agent scope我觉得相对来说好一点。因为怎么说呢？就是你在使用agent scope，你的感觉就是说它的界面做的也还OK，然后底层也还是蛮蛮清晰的。因为对于你真正要落地的角度来说的话，跟你那个define是不一样的。因为你有大量的工作是需要去debug，比如说你agent跑的好不好，对吧？你要看性能，然后你要有很好的trace的功能，然后你要有很好的evaluation，能够帮你去持续调优。什么logging system要非常好，对吧？然后一旦要搞，那multi agent这些东西就经常就是你就不可控了，你需要一个好的监控它之类的。以我觉得整体上，each scope看起来还是一个有大厂在后面去支撑，然后它的定位也是这样。

对，但既然刚才你说到这个auto jen吧？这是微软的一个one agent框架，大家跑起来贼容易跑，还是现在的这些框架越来越友好。然后你看他他其实就这么几个核心功能，team builder啥意思？

就是建一个队对吧？建一个团队，这个团队你里面就有一大堆的不同的A镇。你看这个是这么个玩意儿，就是左边一个A镇带着右边三个A镇，能看清吧？对，左边一个A站大，右边3A的这么左边这么一个team，然后里面有3A的这么一个东西。然后这team里面也可以拖拖拽拽，这玩意儿都是可以把那个外面的A的给，比如说我弄一个这个A的，把他拉进去就直接进去了，然后就变成了这么一个四个agent的团队。然后每个agent你可以再拖拉拽，不同的模型，工具，都可以拖拉拽到里面，大家就这么个东西。然后team builder这个团队构建就完成了。

然后你就可以在这个playground里去去跟他们聊天。比如说我直接去聊一个像他这个法国首都在哪儿这种东西。然后你就会发现这个任务会发先发给这个我们直接拿一下之前的，我看看这个。

好，这个都想的对，有这么一个问题。对这个问题，比如说我刚才问什么呢？就是最简单那个问题，法国首都都是啥，是哪儿？然后是巴黎对吧？然后这个开始他还不直接回复我，他干嘛呢？他去他先去搜索，你看他会这样就到这了。

用户问的问题进到这个入口，这个system，他要去调一个web serve的这么一个在线冲浪的agent，然后冲浪的agent得到一个答案了以后，这有一个agent来去总结一下，然后再把它告诉这个看门的这个agent这个agent。觉得OK了，那直接算是这个结束对吧？其实就是这么个东西。你说这东西看着复杂好像也还行，对吧？就是你通过这个流程里面是能看出来一些相对来说比较协同的过程的那尤其是像这种对吧？我在我又后来又问了一个英国，然后我靠一个劲儿的给我什么网页搜索，搜必应什么这些东西，搞的就这么一个东西，给我搞了这么多次这个A的对话，然后搞出一个结果。所以他其实确实是主要是用来做这个marty agent APP用的。它也包括了一些gallery，gallery就是大家都怎么用，然后你还可以很方便的来去部署。对，所以auto join确实是，如果大家用的公司用的是像ager，像那个平微微微软的那个云的话，那其实用auto jen这套框架是比较方便的。

我整体用auto j我的感觉还是说你再尝试一下mortgage是OK的对，就它不是太面向你非常serious，最后上线什么这些方面，而且感觉迭代的速度是比较慢，所以这种坑你是不敢去take。

Martin这也没有什么好的框架，或者你你你觉得哪个框架好啊。

这个其实挺难，谈不上谁家好吧。我觉得真正你真正写mortgage可能大概率还是会比如说number up什么自己手对自己更可控一些。

好，给大家先看看这个，之前跟大家介绍我这个MGX。我记得是MGX这个是meta GPT这个团队，就中国的一个开源团队，然后做meta GPT meter GPT就是一个多agent的框架，而且持续还在维护，更新的挺怎么三月之前了，这项目看来也快了。可能这个团队中核心去专注去赚钱了，他们的这个商业产品就叫这个MGX点def，做了这么东西，这东西干啥呢？我就给大家看一下，我那天直接跑了个例子，跑了一个说对比这个五代机们，各家了各国的五代机对吧？咱这个反正五代机都上线了，都都弹电磁弹射了，对吧？然后我就问了这么个问题，帮我做一个中外五代机的网站对比的网站。

然后你看他所谓的marty agent，你在开始这个对话的时候，在这个对话时候选这把team选上。你在使用过程中，他就会调多个家伙来给你完成这个任务。那多个家伙，这几个家伙我觉得他们可视化做的很好啊。一个team leader叫mike，一个engineer叫alex就是干活的。然后艾玛是产品经理，David的是数据分析师，还有一个架构师这么几个角色。然后他你如果指定了多一阵，他就会真的把这多一阵干出来。但是他其实并不一定会用所有的家伙都上场。

你看他开始接这个活的是谁呢？是迈克，他是team leader。然后就开始简单的分析，我觉得做挺挺有意思的这一点你看他会说着说着说着，然后这时候会去艾特David。对，David是谁来着？是那个数据分析，好像是对数据分析师他会艾特。然后这个David还假装OK了一下，对吧？这个硬硬老板了一下，硬了一下，然后可以了。并且说我已经安排了这个网站，然后David干这个alex会写网站OK了，然后就开始干活。

你可以看这个所谓David就开始去搜各种信息，然后看了八个网站总结了一下，什么歼20、F2，什么F35这些东西。怎么没有歼35？歼35应该算五代机？没有，那就不管了。对，然后你看它里面一大堆，收了一大堆数据，然后还做了一个分析。然后麦克就是这个team leader，这个结果准确率什么的，大家自己看看，我觉得不一定是信他的。

然后这个team later一看，活儿干完了，然后他继续去分配，然后干这些事儿，然后alex开始干活了，开始写网页了，然后他就开始设计各种网站。然后这个规划好了以后，老板又要开始这个team leader又要开始响应一下，然后开始干活，就把右边这个玩意就搞出这么一个版本，然后你可以继续去根据他的这个，你还可以选对吧？你就选这两这两个一对比，然后底下给你出一个这这么一个对比图。我觉得挺好的，做的挺好的。这个网站的风格，功能都还算比较不错。

而且直接你可以点那个publish就可以直接发布上线了，就可以把这个网址发给别人，然后就让他对来来来向他们赞扬你就好。所以我觉得这就是一个典型的muti agent这样的一个产品。然后我目前看起来确实主流的这种做网页做过应用的这种APP里面，也就MGX相对来说还是保持着最开始初心，做一个Martin agent一起工作的这么一个产品，所以这个大家可以去玩一玩。我觉得这个我不知道咱群里同学有人用过这个吗？MGX。

如果没有的话，这个可以今天就去注册一下他，注册了就应该能用好几次。而且还有个啥呢？还有个这个东西，你看这边有一个这个东西，super base，听过前节课应该大家知道super base是啥，就是数据库一个云数据库。所以你可以直接去让他连上super base，创建一个就连到你的super base账号创建出来的网站就可以直接连数据库。

比如你要让他做一个什么衣服的ERP，简单的进销存或者ERP系统。然后那他肯定要有数据库，那你就会发现他会自己在那构建这个建表，然后往进填数据，然后把前端的管理页面做出来。你想让他要个什么功能，你就跟他说就OK了。所以这个其他的表象的功能跟之前给大家介绍像replay，像lovable这些很像。但是他真的在用这个Martin来去做，而且你看他的这个工作的模式也是很很像。之前咱说的就是有个活来了，老板的这个团队leader先干，然后先分配工作。然后大家干完了以后都还给这个团队leader，让leader继续去安排工作。所以这就是一个标准的，类似于叫什么tree edge，就是前台agent前台的方式的一个muti agent的这样的一个构建方式。

所以大家如果想试这种market怎么做的话，我们强烈建议然后现在大家就可以自己去注册一个MGX，然后在里面去去写点东西，然后它的模型基本上都是最新的，什么GG5、三代四都可以用，还有个2.5，对，定不了2.5。好，我们进到今天第一部分，我觉得第一篇文章特别值得分享。就是这个是lovable的一个工程师，应该算是lovable给大家介绍过，这个宝宝这个就是跟刚刚才那个MGX很像的这么一个web coding的这么一个应用。你直接让他去干个啥，比如帮我做个主五代机的展示网页，然后他就帮你写了。其实一样，只是他没有用RTA这种方式来去做。但是它出来效果确实是挺不错的。就是大家主主流认知里面，lovable应该是网页的样式或者酷炫程度最好的一个产品。然后再想想这个公司里面的工程师，肯定是他对于设计或者对网页设计是有一定的自己的想法的。

然后这哥们儿就叫felix，这个人他写了一个所谓的designers playbook。Designers playbook啥呢？就是设计师的建议。这个东西就是对于一个新的在AI时代的设计师应该怎么工作的这么一个建议，还是推荐这个啊这个沉浸式翻译，大家直接点啥，点一下control，它就能翻译成中文了。而且这个中文可能有点差，可能不看了。对，就是点怎么翻译，字大小差这么多。对，按图的话你也能翻译出来。只是如果这个图里全是大量的文字的话，可能他翻译的那个效果没那么好。我们简单看看他是啥，他对于这是给设计师的，我们不知道咱确定有没有这个非常选或者这个设计师的同学，有没有？

我不知道这个，因为之前一直没有问过大家到底都是啥职位。然后如果有设计师的话，大家待会儿冒个泡。然后如果对于设计师来说，他的第一个建议就是你也要去像一个builder一样去思考。所谓的builder是啥呢？其实就是一个工程师或者一个真的把一个东西做出来的这波人，maker或者工程师这些都coder都是叫builder，类似于叫builder意思。他意思啥呢？就是你不要把自己局限在你就是一个设计师，你就用来做这个产品的设计，或者做一个猫cup more cup，就是假装能工作的这么一个界面。你要从一个真的设计师，真的这个builder的角度来去想这产品，说白了就是你不要只觉得你只能做设计，你还能把这个东西搞出来，你要相信你自己能把它搞出来。

这事实事实上也是因为现在大家看到那么多工具上，包括刚才loveable replay那个MGX这些，你如果就是个设计师的话有啥可怕，你肯定是能搞出来的。再加上最近FIMA的这个也把他的MCP给公布出来了。但我觉得大家大部分设计师都能至少做50%的前端的工作。安娜可以跟老板说，这个前端的工作我做了50%，对吧？前端的工资是不是也得给我50%，这大胆的跟老板要。第二个就是叫create，don't create，就是create就是这个叫策展，类似策展的意思，就是你现在用的各种的AI工具，很大的一部分的工作量都是在工具。

对，效果都是用来生成。比如说图片，生成一个word，一个excel这些东西，或者生成一个视频，对吧？那你应该摆脱你现在一定要去硬创造点什么东西的这个想法，而把他这个心态变成说好。我现在就是一个比如说美术馆的这个负责人，我希望我现在应该干的事儿并不是做每幅画，而是我去选最对的那个设计师做出来的最对的那个展品，放在最对的位置。所以他的意思就是说好，因为生产就从空从写代码的角度来说最明显了，就是现在代码已经大量都不是人写的了。那人需要干嘛呢？人就需要说我应该有自己的审美，我有自己的追求，我有自己的执我得把代码写得干干净净的，然后把它执行的复现难度非常高，然后这个准确无误。那我就应该做这个叫什么监管或者审核的这个人，所以对于设计师来说也是curate，就是做策略，不要去想这个执念的去创造那些东西。

然后ship fast就是快速的交付，然后看快速学习，这是肯定的。咱们群里同学都是学习的非常有动力的同学。然后这个use word as much as visual，就是提示词，就是设计。这个题很有意思，大家总觉得这个设计师就是总是那个设计师产出的是啥？就是稿对吧？但是他意思就是说我们的提示词现在相对来说，我觉得我觉得比出那个画重要的多。

你咋去定义的那个提示词，你咋去定义的你想去呈现的那个东西，那句话其实比出来那幅画重要的多，尤其是这个AH的设计师，然后building system not screen，link这些就不管了。他当时说learn to stack，现在就是你即使虽然你是设计师，但是你也得大概懂这些东西到底是干啥的。比如说API是什么玩意儿，数据库是什么玩意儿，什么叫hosting对吧？这个搭建一个网站，然后这个认证的工作流大概是什么样的，你也得懂，不求你会写他，但是你得懂，因为他跟整个的系统的工作流是有关的，然后stay human的。就是这个设计师还是要保持你的用户的感知，你对于人类的这种直觉的感知的，就大概这么几条所谓的新的设计师的攻略，这么一个建议。

我觉得这个fig ma这哥们儿不是lovable，这哥们儿写的还挺有意思。对，咱有没有设计师？有啊，咱这个都是什么同学呢？红学生学啥的？你看拉波波的这个做出来玩意就比那个对，还是帅一点的这真的假的？好像不太靠谱，不是很熟。这360不像。

然后第二个，我们就看，这个还不可能。这个有一个有意思这个啥就是第一次见到真正的什么所谓的吃食上涨这涨GDP这个故事，对吧？大家知道以前那个段子，就是什么你要俩人走着走着发现一坨屎，然后说甲跟乙说你把它吃了，我给你5000万。

然后一听就是就赚5000万，那就吃了，然后继续走，然后甲觉得自己亏了，然后这个乙乙说你要对乙对甲说，你要把这一坨屎发又发现一坨屎，你就把它吃了。我给你1 5000万，然后俩人都吃了，最后俩人吃了一两坨屎，然后这个GDP涨了一个亿，这个事儿这这个事儿放在现在，其实就是前段时间被爆出来说，OpenAI获得了NBA的1000亿的投资，用来构建算力。这个oracle也会表示open I会买他们3000亿的云计算，但是open oracle又不生产GPU，所以他要去NVIDIA买GPU等于啥意思呢？就是open I把这个NVIDIA给的投资的款给oracle去买云，给谁买云呢？给投资他的nbd去买云，所以大家来串一下，整个GDP涨了这个涨了至少300个比例。

Open I把钱给oracle，oracle给NVIDIA，NVIDIA再投资给OpenAI，这样一个事儿。对，所以觉得挺挺有意思。这个整个的过程你说真的没有用吗？肯定也是有用的。这过程中还是大家整个的这个deal能谈成了，能真的能开始往下转了。

第一脚踢出来的NV脸还是很重要的这件事儿。但是靠这玩意儿搞出来的这个GDP到底有多大程度是靠谱吧？所以也是一个挺挺神奇的事。

然后下一篇我们知道，这篇文我觉得非常有意思，就是叫这个虚拟A的经济，这是应该盯麦的几个人写的一篇文章。Sorry, 对，丁麦的几个人写了一篇文章，这篇文章相对来说写的比较散。但是他把几个关键点我觉得都给点出来了，啥意思呢？就是agent经济。大家之前说之前之前给大家说了，好，应该有好几次都讲的是agent他能支付了对吧？他能付钱了这种事情就是agent payment相关的东西。好，既然有了A证能付钱了，那我们是不是可以想象说，假设这有一个经济体都是agent之间买来买去，你买我买你，然后我们一起去把活干了这样的事儿的话，那这个agent内部是不是就能形成一个小经济体呢？那确实是可以的那我们直接看这个像是一个特别大的综述文章，然后这个里面巨大量的paper，你可以看到大量的引用，巨大量的引用，然后几乎都是2223 2425年这段时间，你看这个关于A镇经济方面的引用，全是23 2425年的这个文章。



所以如果大家现在还有在上学，或者要去要要要这个单位里面要写什么写写论文的，其实挺建议大家往这个方向走。一，因为这个领域实在是太新了，就是agent跟agent的支付，跟A镇经济相关的这个内容，其实都是一个非常好的，对于全学科来说的所有学科来说的一个话题。你看它关键词是啥？AI经济、muti agent区块链伦理对吧？

伦理不管了，前面几个其实都是特别热的词儿，对吧？然后这个同学说是旅游专业的，旅游专业。对，所以我是建议说如果还在学学校的话，那你可以往这边走一走。因为这个agent其实现在越来越不是所谓的程序员专有的这个话题了。

对然后我们其实看快速看一下这个东西，觉得直接到这儿。你看他最开始就提了这个a to AA two a之前给大家讲过对吧？这个google提出的agent to agent的协议，就是agent和agent之间怎么互动，这样的标准协议。上节课最后也给大家讲了这个AP two对吧？还记不记得google的这个agent支付协议，就是一个agent怎么把钱花出去，这样一个协议。当然这不是一个单独的协议，是整个一个流程。

这个带来结果就是我们可预见的很很很很很可预见的未来。其实就会出现说一个agent能够agent构建它的经济体，跟我们实际的人类的这个经济体之间会产生相互的所谓的渗透，叫什么permanently什么的这样一个意思。渗透就是比如说agent帮你花了钱，你其实花的其实是你日常的你的钱包里钱。A人如果他能真能赚到钱，那他赚到的钱其实对应到的那个那个B也应该是你能来帮他换，或者说他给你赚钱，对吧？所以这个是相互渗透的一个过程。但是大家肯定不希望说一上来这个agent就直接渗透到我们日常的经济中，对吧？

他直接花我支付宝里钱，那我肯定很很心慌。所以肯定希望说能够做一个所谓的沙盒，就是把这些A的先圈在一个虚拟空间里面，让他们去花钱，让他们去互动这样一个东西。这玩意儿就是沙盒。

沙盒其实就可以有各种的办法来去避免那种刚才我说的这种风险。比如说你只能访问我的支付宝里的。那个叫什么东西呢？有一个小钱包，小荷包是吧？好像是小荷包那么一个产品。我只往里放500块钱，然后你只能放我那个钱包里钱，然后花光就完了。这个玩意儿其实也是一种沙盒里这个策略，就是我去做一些支付的控制这类的工作。

当然还有很多了。比如说我A镇如果调用的工具，这玩意儿工具真的能改红绿灯，改现实世界红绿灯，那就很危险了，对吧？但是他如果改的是一个数字孪生里的红绿灯，那其实就还好。所以我们要去构建一个确保安全的一个沙盒，能够让你在让让我们的A人能在里面去工作。

然后他写写了一大堆这些这些这个例子就不说，然后我们继续往下看，然后他就给了几个举了几个例子，就是说这个叫example scenario，就是到底什么东西是明显的agent。对于经济社会影响？第一个他提到的其实并不是什么。刚才我们说那些matter什么做网页那些东西，他第一个提到其实就是加速科学。

当然这个也是因为盯麦的他这个角色，这个团队的角色其实比较偏很偏研究，所以他很喜欢拿这个科学举例子。但是我觉得确实也是一个很有前景的一个方向。他举了什么呢？他直接想说这些年科学进步速度有放缓，咋咋咋举了三篇文章，说真的真的，大家也是可能会觉得，虽然觉得大大模型发展的非常快，但是好像这几年科学没有什么进展，对吧？这个核聚变还是20年以后或者30年以后，然后什么都还是未来的事情，那他就说什么呢？

那如果agent能够应用在科学研究上能干嘛呢？比如说他可以去跨学科的来去协调，然后跨实验室来去协调。然后如果说这个看看，就比如说如果你的这个A镇工作中涉及到一些专业的工具，专业的模拟器、专业的数据，是不是可以让A镇来去获取这个资源的同时补偿其他的agent。比如说我这个agent说需要一些5000个关于什么样的用户的身体的健康数据。然后另一个agent另一个实验室的agent，就说我有这个数据，但是你你



你买的话你得花钱对吧？让A镇跟着A镇之间就可以把这个钱花了，而不需要一定得是这个实验室的人跟那个实验室的人去去聊这个事情，然后其他的也是，就是关于这个科研，包括什么争取资源。

比如说学校，现在大家学校里面其实都有GPU，我不知道那个早晨同学先学校有没有GPU？这个旅行专业，旅游专业肯定不会有GPU的，那GPU的量非常少，那到底啥活应该给哪一个实验室？我觉得这个事儿，其实现在大家都靠这个老板够牛逼对吧？就能占住这个GPU。但是如果我们说这个学校，从学校的身份来说，肯定是希望我学校内的有研究前景的这些研究课题，能够尽早的获得到足够多的计算资源，能够干活，能把这个研究做下去。

我觉得这个事儿，学校不可能有一个老师，啥行业都懂，啥方向都懂，然后还能做出很准确的判断。那不如就让学校做个agent来去做这个资源的调配调调配。然后谁来去怎么决策呢？就靠你各个实验室的agent跟这个老大A阵去聊，或者分配这个A镇去聊就好了。说服他。

然后第二类就是robotics机器人，我觉得这个其实倒是我之前没太想过，他指啥意思呢？就是比如说一个机器人要去送货，然后他发现自己送比旁边那个机器人送可能花的资源更多。那他就有可能说我直接给旁边那个机器人，让他来帮我把这个货送过去。然后我给这个旁边进行一些钱或者token什么的，都OK资源这个能量什么的，给他一些。然后他就如果他能干活，那他就多赢，大家都他也赚赚到钱了。

最开始这个A朕也把这个活干完了，而且还没消耗自己的资源就可以搞定。那如果第二个这个机器人觉得他不知道到底送过去应该收这个A多少钱呢？他还可以问C说是不是我把这个东西拿过去，A说给我这么多钱合理不？然后C还能给帮他做一下，这个比较公正第三方。

那为什么找C呢？很有可能是因为它具有这个全局视角，就比如说C是一个领班机器人对吧？他知道整个的店内的布局，或者整个场内的布局，他能做出这个评估来，所以这个是一个纯靠A镇来去协调A机器人之间协作的这样一个点。我觉得这个有点意思。但是他通篇这个文章里，大家都会感觉一个特别强的假设，就是啥呢？就是市场经济解决一切，市场博弈解决一切，我觉得这个不一定对，或者说在很多场景它不一定是一个可能他是一个去掩盖一些更优的决策的这样的一个说辞。

然后第三类就是所谓的个人助理，就是大家chat PT这样的东西。我是不是每一个人都有自己的一个age，然后能带领自己的agent去干一些事儿，我觉得我最近特别有感觉，也不叫最近，前两天特别有感觉。我当时想订卢广仲的演唱会票，不知道大家有没有人看卢广，卢广仲这是一个冷门歌手。

暴露年龄。

对，然后在在澳门，他发新专辑了。我当时就那啥，就开票那一刹那点，然后就失败了，就就已经就已经卖光了，或者被大家都抢掉了。所以我是挺挺直观的，就是说如果有一个我的agent他能够带着我去买这个票的意愿，就是他知道我的授权就是让他帮我去买票，且什么呢？且还有可能有一些溢价，比如说我愿意让这个A枕买这个东西。同时我愿意去多花点钱，我愿意比如说1000块钱票，我愿意让他多花五百，我就是要买这张票。那这个A的就不至于像我那样，就是我咋咋狂点点点了。我可能这个点了得20分钟，一直在点那个那个界面用的什么来着？猫眼。

对，然后那我就没必要这事儿。如果我的agent进去，他能带着我愿意议价500块钱的这个叫什么主观的诉求，然后有这个诉求的话，那我自然就像在这个叫什么来着那个那个猫眼里面就可以去去跟别人匹配。谁愿意不想多花钱，那就他抢到了他可以议价的。比如说500块钱，最多500块钱溢价卖给我，那他还多赚了，对吧？所以这个事儿我觉得那是一个对属于自己的黄牛这么个东西。但是他其实是获利的，就是大家都开心。因

为我授权，因为这个而且我还不用去在那狂狂点框框点对吧？这样一个东西，所以我觉得还是挺广岛之恋，广岛之恋是有广东的吗？

我咋都不知道行吧，所以他这里面例子也是就是一个个人助理。他如果说想抢一个酒店，另他就可以去跟另一个也想抢这个酒店的agent去协商，然后这个获得赔偿，一方面或11方获得赔偿，另方得到了一个酒店？这样一些东西。然后刚才说那些东西都希望我们不希望让他直接跑到现实世界中，需要跑到一个沙盒里，对吧？那这个沙盒相关的机会就非常大了，有非常多的机遇可以去找一下。这里面就说了一大堆这方相关的机遇，这就不可了。底下就会有一些什么dynamics，这些就是一个多agent系统多a agent系统的涌现，这个会有越来越多的很复杂的行为出现，然后也复杂有越来越多的比较难的事情可以被这种多marty agent多agent来去干。这个详细的就不看了，我觉得没啥意思。这个东西看看distribution这个就对分配，他就说到说我们现在看到的越来越多的A镇帮我们干活的下一步非常重要那个事情是啥呢？就是高频率。

HFHFT对这个对对对，大家知道这个，称号是做做做交易，做量化交易做过的那里面有一种叫量高频量化交易对吧？HFT他提了一个什么点呢？你一旦用大量的经济行为是agent来去干的话，那就会出现一种新的高频的这个不一定叫交易，而是叫叫高频。你goto ation HFN高频讨价还价，高频谈判。

对，高频谈判的意思就是像刚才我们说的，所有的比如说以我的意愿授权给这个A帮我去买票，帮我去跟给实验室争取GPU这些东西。其实可以想象，那肯定不会像人这样，对吧？就是说校长我这项目贼牛逼，我一定要有500块GPU。他肯定是瞬间把把他这个理由全捐给这个决策的agent。然后决策的agent快速的把把这个答案给你那这个叫什么谈判的过程，可能比如说几几十几秒就几轮这个过程完成了。

那它对应到的一个结果，如果是跟现实世界经济有关的，比如说真的把这个资源分卖给了谁，真的把这个票卖给了谁，那他就会像高频交易一样影响现实世界的行为，这个经济性行为，比如刚才说的黄牛对吧？你如果真的要黄牛能够以一个高频交易的方式，高频谈判的方式来交易，我操，那我相信这个黄牛市场也是一个快速能够收敛的市场了，对吧？有可能，这个我不专业，张小娘吐槽你就随时说，必须补个刀。

我觉得这个其实核心就是说你人沟通的时候是有带宽的，就你只能跟一波人沟通，而且你的语言其实说的是慢的对吧？

对。

但是这种病并行什么这些蛮重要。

对对对，人说话是一个挺特别低带宽的东西，就像现在我说话，我虽然可能大家有时候说话的语速高一点，但其实也没几偷窥每秒。但是你想这个模型，就像这个大模型，对，正好我觉得带来这个板子，不知道大家之前给大家看没，看这个板子之前给大家看过一就这个小板子，这小小板子是6630C的那个那个方案，然后它是直接能跑一个两B的模型的。然后正好今天给大家看看它到底效果咋样。就这么小一盘，它能跑十几个token每秒，差不多至少十几个token每秒。

用的是啥模型？先说。

前面。

要不要用隔壁的小钢炮？

可以，反正就是这没有呗。对，安卓CK platform CADBOK特色项对吧？可能不更新，能更新。

先登上去了。你这个是通过什么连的？你是通过一个USU.

SBB连的，就是一根USB线。然后登上以后。

它为什么还带个天线呢？他他可以蓝牙吗？

他可以连wifi.

wifi可以连wifi。

欢迎小3，我看行不行？可以了。你看大家看这个速度，你好，我操。对讲个笑话我去讲个长一点的笑话。

不好说。

你今天是故意来黑千问的，是不是？

但这模型是千万2.51B的，千2.51B大家对于一个一B的模型就宽容一点就好了，对吧？他能烂到什么程度呢？也就烂到这个程度。对。

那你跑这不是一臂。

你跑也不是。对我只是把他的名字改了一下而已，其实代码是一样的。我靠，反正这上面的这个推理引擎是有很多问题的。但是他是跑的一个他是专门做量化的，所以这个板子还不能把当前的所有的这个主流模型直接怼上去，就能直接用。对，所以还要专门做一点点这个适配的事儿。

这个算不算是展示翻车了？就你在演示之前我想表达一下，你你你在演示之前你想表达什么样的思想感情，是不是？这个板子很不错，然后能够已经开始有些东西可以落地了。

是结果跑了两下就不好安装了。

我把它关了，然后告诉大家，大家就很清楚了。现在好像还是不能落地的。

但是他能跑BOM，它能跑多模态模型，一两B的多模态模型。

来来来秀一下秀一下，秀一下。

算了算了，实在是特别智商特别感人。对。

效果确实感人，确实感人。

对对对，长一点，确实长了一点，对吧？我们这个也合理。对，但是你看这个板子关键多小，对吧？就这么大，这是多大呢？我的大拇指这么大对，但是他那个散热其实挺热的。但是如果跑那个板子跑一跑就发现我靠这个跑了十分钟就开始发烫，所以这个功耗其实不太低不太低。

你觉得这个东西可以用在哪儿？

这东西不好说，这东西你说放刚才那聊天的方式去简单的说点话，简单的有点智商的去做点工具调用。一两次调用还凑合，但是长一点就没戏。我们其实想去实验这套东西的目标是做一些特殊设备的视觉识别，只能用本地模型的一些特殊设备，大家可以想象对吧？就是飞的那些玩意儿的这些设备的自动识别飞的或者油的这些东西。因为他那上面肯定是没法接API的。那我就可以直接搞啥型号。我这款是那就方这个方案其实叫630C然后我买的这个是M5 stack，m5 stack的这么一个板。能不能看到这个了吗？

多少钱？

五百多、四百多、四五百，其实不太便宜。这个东西四五百。

这东西像量产的，它出货量大。

M stack是一个深圳的一家公司，基本上唇突海外的，面向海外开发者的，这个来卖的量还是不小。他现在直接看看M5哪家。

代工了。

其他代工还真不知道。就这家公司m stack大家不知道群里有没有程序员同学，他们家的东西都非常好玩，贼好玩。但是就是你买了以后几乎就能直接用，然后样子也不差。你看就这些东西，就是给geek给这种做开发快速开发原型，这波人用的东西，然后合作伙伴都有工业的，有工业的，它里面工业的很多，然后他的硬件产品也非常有意思。你看这些新的硬件产品全是跟大模型相关的，什么小智AI什么，这几个都是直接连。你看他出了一个数，墨水屏切的就是小智。之前给大家讲过小智了，小智AI这个项目。

小智他那个299是他因为它是像大模型在云端的对吧？

这不是，对，都是大模型在云端的，这些这个量级的都是它都是直接连API，然后他跑到小智那个程序，因为它里面是乐心的那个片子，应该是ESE32多少？EESP32。S3大家注意，如果这些做这些项目的时候有一个点，就是如果你想做to c的产品，ESB32或它其实是乐心的一套方案的这个芯片。

它的很大的问题是绝大部分ESC32都只支持2.4G的wifi。只支持2.4g wifi这事放在家里可能还好一点。对，可能还好一点。但是现在公司里面基本上很多公司都不开放2.4G的wifi了，因为有很多问题，比如连接的数

量，安全性的这些问题。然后WPAR其实现在不太安全，在在这上面对，然后连接数量还会侵占非常多的带宽，所以就断了2.4G了。

对，很喜欢小智的弯弯小河。对，所以这个还给他打了外壳吧？对我觉得这个小智真的是非常。

小伙伴们还真是有不少挺挺ick的吧？

棒棒棒。对，因为小智有东西插一句。

我觉得最近拓竹好像有点要累大疆的感觉。我靠。

一直大家认为就是打印机领域的大疆。

他他他他现在搞的这个风格好像大疆就是非常的geek，而且对把一些非常geek，本来是一个纯geek的东西变成一个平民可以用的东西。

对，然后既然有这个叫什么宝贵同学？最近打过外壳，这个肯定得有自己打印机。因为这个板布拓竹他出了一个很叫H2S，我买的是叉1 carbon x one carbon，然后他出了一个，我靠这个特牛逼的一个版本，我不知道大家看没看完。

对，HR这个系列，HR这个系列里面是有啥呢？它不光是一个三弟打印机了，这是最牛逼的。它还带切割、激光切割，还带一个CNC。我觉得是那个CC叫啥来着？

那个孙悟空机床。

对还带那个玩意儿。对，所以整个你打出来的东西，它能靠CNC来签，就给你弄好。然后我稍微。

给大家同步一下制造。

这个到我了。

就是制造里面分增材跟减材。你可以先这么理解，就是说什么机加工的，机加工是给你一个方块对吧？你把一些东西磨掉就叫剪裁，然后三弟打印的是最典型的增材，就是他用粉末或者条状的东西。你看其实除了这东西之外，还有金属打印。一般我们这个特殊这个家用的，其实塑料打印对吧？塑料的塑料那个是条条形的材料，金属是粉末，然后粉末在那地方高温高压或者激光把它固定下来。有的是那种高温给它融了，粉末融了，然后就固定下来。所以那个是增材就是一点一点变多。

然后剪裁跟增材有时候要合到一起，就是增材快速的做一个模型的样子。但是有的时候你你你精细的地方，用剪裁的方式再把它给打磨的更精细，使更方便的。因为增材往往不能像剪裁做的那么精细，因为它要成型，所以剪裁的话它是磨它可以磨得非常精细。好，科普完毕。

对，所谓的增材就是就这玩意儿它咋增的？其实就是弄了一个特别高温的头，然后上面挤这个塑料的线，然后再在这个头这儿把它划掉。划掉以后，就滴在要打的这个片子上，一个板子上在一个板子上，然后打到对应的位置，然后咔咔一层一层一层的就打出来这么一个东西。所谓的增材出来的东西，但你增加出来，刚刚才陈老师讲了，这个出来的东西其实还是有问题的，或者说需要再加工的那需要剪裁，那剪裁咋剪呢？就得靠这个类似于数控机床这种东西，他这个。

核心就是刀。

对，就是刀切，对吧？然后你有一个什么样的东西呢？这个刀就各种各样的样子了。然后这款HRS其实就带了一点点的像激光切割。

激光也可以切割极光。

其实它这个十瓦有点低，我觉得然后这个十瓦其实就是55伏二安就是一个USB的这个功率，其实挺低的。

然后他瓦和他的那个纳米还是什么是配合，如果它那个精度很高的话，瓦数低一点也还OK，因为核心就它相当于很细。

专业很专业，这个我还真不知。对，然后竖着刀切对吧？还能给你切一点这个春联什么这些东西，然后还能你放一个东西在那个笔手上，他能帮你画画是吧？就是帮你写作业。

你什么时候买？

我的他这多少钱？12000。行，我买的是这个XYXYX的他这个没有刀，也没有。那那对我当时买的时候还没HR。对，那你也应该买买买。

那个最新的带刀的。

大家如果对小智感兴趣的话，我们可以要不带着大家一块儿做一个自己的。可不是对打印机，不是所有人都有是吧？给大家谁谁想要打个生，可给大家打一个。说吧，对女朋友这么好啥意思？对，然后买了OK对，打印机我觉得如果大家想玩，或者说是现在的这一代打印机真的可以买。就是像拓卒这一波打印机真的可以买，因为质量真的很不错，然后也不用太担心什么空气、质量这些问题，就挺好的，没啥问题。

你刚才讲哪儿来着，讲这篇文章，这个虚拟agent经济这篇文章，我们到最最看看最底。算了，这篇章实在是太那啥了，太长了，而且里面的那个引用实在太多了，就不详细讲了。我们直接讲讲这两个，我看看就这篇文章大家其实很感兴趣，然后什么人感兴趣的这篇文章？两类。一类就是像做这个agent这波人像什么minus什么这些觉得这个代表了我们现在做这些A站，不单纯是帮大家什么抢个票什么这些东西，或者打开网页做一做搜索而已。那它它代表的是未来的一个经济形态，对吧？这个这三类这三类包括了潜在的一些风险，然后又关系到说很多的未来的事情都需要去由agent来代理去做，然后那他代表的经济形势什么样？

另一波感兴趣的人是谁呢？是这波人币圈这波人对吧？大家如果知道这个叫dollar people就知道是叫人民币，不是这个r RMB，是人民的币。然后这个是一个B然后这波人关注的点是什么？你看链上运行对吧？就是你有一堆A证，然后互相交易起来，这事儿在哪儿交易最好呢？那肯定是on change，就是在区块链上交易。

好，一旦你说了什么玩意儿在区块链上交易，这帮人的第一想法就是我要让大家都买我这个币，然后让agent都跑到我这个币上，那我就可以这个币就可以涨了。或者所有的agent都要在这上面花它的所谓的gas费，那这个币的流动性就高了，流动性高了大概率也代表了这个币会涨所以第一想的是这个东西，然后那个所谓的什么超越人类的协同，乱七八糟这些东西，这个就是对于币圈来说最开心的话，反正所以他们直接上来。所谓机会是啥？金融的agent的话，这个靠agent来做金融交易，agent金融化，就是这帮人啥都喜欢去金融化。就是你你但凡咱们做了一个能帮人干活的agent，直接的想法就是什么的。是不是这玩意儿就可以帮我赚钱了？我帮别人干活，我在A店帮别人干活，赚的钱是归我的，对吧？

但是这帮人的第一想法是什么呢？我帮别人干活，这个A着我把它变成一个金融产品，我直接把这个AIPO化，ICO化，变成一个B然后让大家买我这个B，直接脱虚，脱实向虚，这个很狠。然后第三个其实就是什么监管乱七八糟这些就不管了，所以这个币圈人对这个东西也很感兴趣。

另外其实也是因为最近的几个新的协议，包括像这个AP two，就是上上节最后讲了一嘴的，包括像之前的a to a，然后四叉402这几个都是跟谁合作的？都是google跟类似coin base，google和coin base大家知道coin base吧？像这种跟他们合作的，所以整个google向整个区块链的演进是一个特别快速的一个过程。所以确实是大家可以关注一下这B圈或者web 3跟marty agent这样一个结合的点，这个很明显很快就会到。然后你看就上次说的这些合作方都是谁，这件事儿就代表了主流是主流的这个市场，这些玩家已经认了。那你一旦认了，那其实下一步其实就是什么时候谁能赶紧把整个电商的一部分生意切出来，或者这个交易的一部分生意给切出来，给到agent的这样一个事儿。

对，好，然后回过头来，就是说到这篇文章完了，然后下面就是a to p的AAP two的这个东西。AP two不，这个事儿上次稍微讲了一嘴，然后讲了一嘴，讲到哪了我都忘了我可以看一下这个它的核心解决的是啥？核心解决的是这仨事儿，就是授权、认证和可审计。那啥意思呢？就是我去买一个东西，agent得信我A得拿着我授权的这个真实的东西去去去买。商家得信我的agent拿的是我真实意图，就是我是人，就是人给agent一个花钱的授权商铺，要通过agent给他的一个值，来去证明用户真的给了这个agent买这个东西的授权。

这个意图这块意图是一个授权，叫intent Mandate。Intent这个东西这里面有几个Mandate，就所谓的这个门店咋拼，咋翻译授权。对对对，就是意图的授权以及cart的授权。这个意图的授权就是人给agent表明说我真的想买这双鞋，或者说我要在500块钱以内买一杯咖啡这样的东西的intent Mandate。对，然后就是大概是这么个东西。所以他上次说了，第一个场景最直观的其实就是人在场的时候挨着你们干活。那他就肯定是老板你看看这个对不对，老板你看看那个对不对？我说对，然后他就拿到我最后的所谓的这个car time mente，就是放到购物车结账这么一个授权。

但是大部分给大家最大的想象空间，其实就是人不在的时候，人不在现场的时候，我怎么授权他可以议价200块钱买这个卢广仲的门VIP票这么一个东西。我怎么所以叫delegate授权给这个时候，intent Mandate就更重要了。我怎么能够在一个我不再盯着这个agent干活的时候，他也能叫什么商家也能相信这个agent真的是以我的身份来去买的。

这个事儿之前讲agent payment的时候其实给大家提过一嘴，这个是一个挑战。但是没想到google这么快就把这个协议给搞出来了。所以我觉得这个是一个非常屌的一个事儿。

对，然后就到这儿了。对，就是叫support for emerging payments ship system emerging就是涌现的支付系统，它支持了涌现出来支付系统。啥是涌现出来支付系统？比如这个coin base，以太坊基金会，meta mask就是那个那个小狐狸钱包。



然后还有其他的一些所谓的领先组织。这些领先的组织都前一段时间都推了一个都在推一个协议，叫这个东西叫X402X402。X402是个什么东西呢？我们直接看啊，它是这么一个组织，这个组织其实也是一种协议，它叫internet native的payment，叫互联网原生的支付协议，啥意思呢？就是大家如果知道这个互联网所有比如说我们打开网页发什么文件，上传文件什么的，都是基于一种叫HTTP的协议，这个应该大家都听过，对吧？然后所有的我们现在用的应用层的协议也都是基于HTTP的。

但是每一个HTTP对也不算是就HTTP协议里面有一个很关键的一个值叫做状态码status code。这个码可能是如果是正常的话，比如说就是200，代表是正常。如果是500的话，那就是这个挂了，后台服务器坏了。然后如果是，比如404对吧？大家知道404就是网页没了这个意思。

然后那其中有非常多的码现在还没有用，但是当时设计时候设计去了，比如说什么呢？就是402这个HTTP code，就是一个当时在HTTP的协议里面设计进去了，但是没有必备用的一个是这个帽这个码是啥意思呢？就是需要支付的意思叫payment required。说白了就是互联网的这帮大佬们定这个协议的时候，其实当时就想到了说我应该后端返回一个值，表示这玩意儿要花钱。但是一直没有找到，或者说没有哪家这个服务是直接通过一个APP请求，然后告诉你你要花钱，那我这边就花呗，没有这样的，没有找到这样的服务，所以这个协议的这个状态码，402这个状态码就放在那儿了。

但是这次，就这波web 3的这帮人发现了我靠402这东西结合四大本身的语义，就是payment requirement这事儿结合AI结合agent，结合在线系统，结合区块链，是可以做一个非常好的一个桥接的。桥接比如说他们就是互联网的这那个B圈，那帮人很喜欢讲自己是web 3是web 3。然后这帮传统的偶像，咱现在上课这帮人，包括我们咱都是叫外办的人，都是传统互联网古典互联网的人。

他们整天吐槽这帮古典互联网的人太老，但是又自己很大的问题是自己没东西。就web 3里面是没有正经声，没有正经应用的，就是你没法在里面点外卖，没法在里面什么下首歌或者听歌什么那些东西，普通的租个房都没法干。所以他们一直一直在渴求的是一个可以从大家用web 3的这个B或者AFT这些乱七八糟的资产，跟现实世界所谓的跟他们认为的传统古典互联网去打穿的打通的这么一个这么这么一类的渠道。所以这个420这个协议才发现很牛逼。这玩意儿是一个跟传统的像咱这个网页这种LHTTP协议能够打穿的这么一个东西，还跟支付有关。但跟支付有关，那不就跟币圈有关了吗？他们就开始琢磨这个事儿，然后这个X402就变成了一个大家怎么教，通过这个协议来去互相付费的这么一个尝试。

然后大家想这个AP two，AP two这个协议其实也是一个a to a协议的延伸。你看它是一个a to a协议的扩展，再加上MCP吧？调用工具的这么一个扩展。那你想想我如果a to AA to a就是A镇到A镇之间，你但凡想去聊聊钱，那我能不能通过一个像叉402这样的玩意儿来去实现a to a agent到agent之间的谈钱的这个事儿？所以他就专门做了一个叫a to a叉402的这么一个开源项目。

然后这个就可以实现说通过a to a这个协议就俩agent。一个agent给另一个agent说，你帮我干个这个活。然后另一个agent说可以，但是得交钱。然后那他就如果用这个extension，所以说白了也是一个to QEPI扣这么一个方式就可以实现agent一个agent给另一个agent通过X42这个协议交钱的没事儿。而且X这样的协议肯定是通过block chain来去，大概率通过on chain的这种方式来去交钱了。比如说通过给你个0.0005个以太坊，然后你帮我把这活干了。那真的可以实现一个通过一个纯A的to a镇的协议来去a to a协议来去实现这个功能。

对，所以这个是一个大概就是它非常强我觉得非常强烈的一个标志。当时这个出来以后，币圈又涨了，涨了一些，但是没有特别大。但是我觉得402这个是一个很经典，很难之前这种项目很难上像google这种大厂的这个面上。

而这一波其实大家会逐渐发现，这波大家原来很难看到他们出现的这个对吧？这个桌面上这帮公司真的已经堂而皇之的到台面上了。对，所以这就是AP two的这个协议，我觉得这个非常值得去关注。然后又402X402也是一个特别重要的一个事，重要到什么程度呢？Vers L.

这家公司是啥呢？这家公司是一个做网页服务的，就是外服务的一家公司。最早它其实就是以什么出名呢？就是你一行代码，我就可以把一个网站部署上去，部署到服务器上去，你不用关心部署在哪儿什么的，一行代码部署上去，然后你就可以直接访问你的网站了。当时以这个出名，后来他就出了一系列非常多的，帮助开发者去开发各种工具的，开发各种网站的工具或者技术站，这类东西越做越全。

然后他也就在几天前12号他也发了一个叫X40MCP这么一个协议。说白了就是你用我的这个SDK去开发的A自然而然可以接入X402去交做支付的这么一个的过程。你看整个代码量其实挺少的。你想构建一个支付MCP的一个pandora你只要把你的钱包地址放进去。然后基本上他认为什么时候需要用这个A的时候，他就可以自己去调。所以你可以看到这儿，而且他这还有一个demo，我觉得挺有意思。这个X4秒AS搭的，这个具体技术，大家不用太关心这个太那啥，你看其实就可以看这事。

你以后跟一个A人去聊的时候，你说查查我账号里还有多少余额，你看他就会去调他的X402的MCP，然后去调我还有136MUSDC。然后创建一个什么1到10的一个随机数，然后他就创建了，然后这个随机数需要花掉0.001USDC，然后你想你想支付码也对，然后他就会继续去调这个对应的这个A的payment的认证，然后就可以把这个钱给真的花出去了。对，所以就是这样东西，大家可以感受到，就是简单的感受。到时候可能未来一个A证帮你把钱花出去的这样一个效果。当然A镇花出去钱这事，其实并不是一个完全想象不到的感觉。

我觉得最近有几个应用做的都挺好的，大家看一下都是有这个意思的模型，我们就简单说一下这个，先说一下info。Info这一块其实最近你没有什么太像华为的什么新的集群，然后这几个其实就不说了。大家感受到国内的国产的GPU逐渐开始进入到第一梯队的。这个其实也没第一梯队，梯队其实就是NV列对吧？这个NVIDIA的第一第二梯队的这个阵营叫什么性能阵营里面了，第一梯队B系列还是挺难进的。

我们先说进到H系列的范围内，然后高通出了一个芯片，我不知道大家有没有关注，高通刚发布了这个叫。高通8 elite正五这个模型，芯片这个芯片有一大堆乱七八糟的指标，这就不关心了，我关心就这个东西。叫on device JTKAI，它这个有点模糊，这个图有点小，然后你看多少这个性能就不管了。关键我看到了这句话，第一个持续的在设备端的AI学习，新品就具有持续在设备端的AI学习能力，这个东西我觉得是我反正第一次见到这样的一个说法，然后我就开始研究说这玩意啥意思呢？就是所谓的continuous，你看continuous on device learning这个东西啥玩意儿呢？然后就开始找了找，就发现是这个东西，就是。

continous. 这。就是。

对你先看看这个，这个其实好老。这个是一个四年前的一个step的那个那个叫什么来着？我知道那个叫啥来着，就是他的这个芯片的介绍视频。你看他能干啥，他他就一直在提这个东西。就假设你现在这个手机放在这个婴儿床旁边了，然后它能够随着场景感知到周围，他能时刻知道说宝宝在哭是吧？像我们现在打电话的时候，旁边有一个小孩一直在哭。但是你它能够自动的识别到，我现在应该是把你的声音放大，把什么baby、把狗、把飞机这些声音给降噪下去。OK可以。

那就不说了，就大概这些当时他的说法叫这个叫contexture的，这个叫sensing hub这部分这部分其实大家看这些AI功能，大部分A这种AI功能，就是长期一直有用的功能，都不会是跑在你的应用里的，甚至都不会跑在你的操作系统层面。都会跑到哪了。因为它一直开着，所以它一直很费电。如果你跑到应用层的话，一直很费电。所以它一定要跑在它的这个就是它的底层，它的硬件上。

那这个硬件上咋跑呢？好的。对，对，就是高通出了一个东西叫personal scrape这么一个东西。啥意思呢？就是你这个是。

一套。

底层的程序，这个程序可以一跑一个叫always on的能力去所谓的不断的学习你现在的状态，不断的去构建你的知识图谱，知识knowledge graph这样的东西，他会持续的不断的做。然后他去从哪拿到这个数据？比如他会拿到他从哪学的？他会拿到你的他们的对话里面，从你的这个浏览记录里面，从你的提醒，从你的音乐片好位置这些东西能够持续的学习到一些你的关于你的knowledge。然后你这个knowledge会以一个graph的形式在手机上保存下来，所以这玩意儿叫on device的knowledge graph。然后他一直跑着呢，你就他就可以一直拿你手机的数据去分析识别你这个情况，然后就可以干嘛呢？基于你这个偏好，基于你这个knowledge PH就给你做各种的，比如说你个性化的AI推荐给你做各种主动的这种场景感知方面的功能。

对，所以这个是这个点，所以他说的continuous持续的学习这个功能应该就只是这个就是假设我的对就是呢能这个模型可以一直也不叫模型，就是我的传感器可以一直一个很低功耗的方式在运转，就像刚才那个视频里这样一样样子。就是一直听着你在哪儿，你旁边有什么声音，你在哪儿，你去了哪儿，然后你看了什么网页这些东西，然后这很低功耗的能拿到这个数据。好，那我就可以搞一个模型。

这个模型让你从你的这个行为习惯里面去学习到一些偏好。比如你家住哪，你工作地点在哪，你的上下班习惯，坐车还是乱七八糟什么，你喜欢看什么网页，这些东西其实都可以持续学习到。但是他为了避免你觉得会有隐私问题，他会跑在你的这个又2IT这个片子上。

在这个里面有一个叫什么personal scrap的这么一段程序来不断的学习，然后把学习到的东西存到你本地的这个设备上，让你好像能放心这个数据安全的问题。但大家想一想，但凡这东西我只要能学习到，我的应用层为什么不能拿到呢？那肯定得能拿到才有用。所以他只是让你觉得他学习到这些知识所用的数据是没有出去的。但学习到东西肯定是要去给应用层用的对，所以这个是一个我觉得又It带来很好的点。它一是它的算力挺牛逼的，他好像有80 tops，然后他讲的就这个所谓的on device的持续学习，带来的可能是给所有的安卓手机一个更下一个故事叙事故事。就是你的下一代安卓手机可能是一个持续的更用的越多越了解你的这么一个delight a的这么一个东西。

好，然后下一个模型就是我们刚刚开始说的千万欧欧美的这这就这个40其实就这个意思，欧美就是全向的，就是万能的，然后所有的全模态这样的一个意思。千万2.5，据说三好像也快了，对吧？然后2.5的armani就是一个所谓的你可以看得到端到端的多模态的千万模型，千万系列。然后用来去干嘛呢？用来去做比较复杂的多模态的感知，然后可以处理各种的模式，包括文本图片、音频视频这些东西。我们直接看看它这个效果咋样，我觉得它的这个demo做的也有点意思。你看demo有它的输入，就这俩都不给你文本输入，都不给你文本。因为他知道这个文本输入太多，那文本他也就给你两个，一个是audio就直接录音。

Hello hello, 你能学个狗叫吗？行，然后三妹特别卡。然后你看我这是我说的话，对吧？然后他又回我，他也回了语音。我不会学狗叫，不过我可以陪你聊聊关于狗狗的事儿，比如你有没有养过宠物之类。对，就这样。然后它有一个功能，能听到吧？陈浩能听到。

没问题。

对，然后他因为他是为了突出的多模态能力，所以他除了奥这个还做了个video。他完全都用你浏览器的这个麦克风和这个camera就可以实现了。你可以不用，那我继续录，那你给我叫学个大象叫。

叫个爸爸。

好主意，我看看怎么办。那你叫个爸爸吧。

北京人的恶趣，是不是北方人都有这个恶趣味？汪汪。汪爸爸，我呵呵，你要是还想让我学别的声音或者做啥的，尽管跟我说。

有点恶趣味。

对，就是他其实这次这个demo我觉得挺有意思的，就是凸显了一个语音和视频的模态的一个交互的这种能力。然后可见确实还是挺不错的，这个效果还是挺不错的那把它放到哪儿对吧？大家就可以各种想象了，甭管放机器人还是眼镜什么里面都可以去。而且它是一个我看多大。

对，就几B这么大小的一个模型。所以这个峰值的GPU的G对这个memory的数量也就几个G所以确实是可以跑到手机上的。那么大家可以想想，这东西就放在手机上就很很不错，起码比siri聪明多了，其实我挺纳闷，为什么siri就改不好？所以这个大家也可以去去玩一玩，这个就是多模态或者全模态的这种模型，其实可以玩的很多。然后大家可以想象它其实如果能喷声音，能吞图片，那对吧就那就可以玩更多了。我同时扔进去不同的模态的信息。

好，然后下面就是这个东西，这儿有几个应用挺有意思，一个叫detail。但这玩意儿我玩不了，因为只有UCS、DCLA、UCLA这几个学校才能玩。但是它是一个它是啥？它是个AI，配对约会这里也有。然后核心是啥呢？它核心的是这个东西，你这个叫什么？配对这件事儿大家肯定听说太多了，什么探探什么那叫什么东西来着？就那个那个那个那个那类应用的叫tinder，tinder就左滑右滑这一类的非常多了。

但是它是什么呢？就是你要开始用的时候，他会不断的问你一些问题，而且这些问题不是一个单纯的什么你选A选B选C他是会跟你聊下去的。这个是在一个他的介绍文章里讲，我觉得这个产品设计是非常做的非常有意思一个东西。就是我说一下，他还会干帮你干嘛呢？会帮你匹配完了以后会给你们发你们应该咋去约会，这个约会的计划他也会给你发给你做出来。这个比较容易理解，这个大模型肯定很擅长干这个事儿，然后你们唯一需要做的事儿就是去约会，直接去约会也好，然后他会把所有的这些之前要做这个事儿都帮你做了，那他咋咋做到的呢？

其实我觉得这个他说的东西还挺有意思，它的核心逻辑就是穿透标签，直抵人性。就是你不要只说你喜欢看电影，你多聊聊你为什么喜欢看，你看啥电影，什么节奏的这种电影。先聊透了。这个时候我后面当这个媒人的时候，我才就AI当这个媒人的时候才当的准，而不是简单的我就看你这个对吧？所有的小孩都会说我喜欢唱歌跳舞看电影，吧？你们再去到底喜欢看啥，其实都是后面的矛盾的产生的来源。

然后它的另外一个核心点就是时间成本，其实是现代的约会中非常重要的一个资源。他里面提到一个啥呢？好像每一次每一个人获得一次约会的时间是几10个小时。我看看现在年轻人平均要花在约会应用上的时间，要通过花47个小时才能够促成一次有意义的线下见面约会。大象其实就是等于我要花四天的时间，用APP才能换来一次的线下约会。确实我觉得这个是一个特别大的一个时间成本，如果这个约会还不怎么样，那就更浪费时间了。所以他其实把之前的这部分大家花在你选这个你你看这个选那个的这样一个过程给加速了。

但是他加速咋加速呢？其实就是他用了一大堆的agent去聊天的方式来去做的事儿。我看这个你看他就是号称这个实际上怎么做的，他也不会告诉你就是不断的模拟两个人这两两人见面以后，他们的第一印象会咋样，他们的这个对话的节奏会怎么样，他们这个是不是很alive，关于一些什么比如幽默感乱七八糟这些东西，是不是有共同的价值观什么的这些然后就狂聊，号他们号称还能够会把一些什么约会迟到什么这些场景给在这个虚拟空间去模拟出来，然后让这个模拟出来到底这两人是不是配这样的事儿。所以他意思就是所谓的去选择权。

啥叫去选择权？大家能感觉到就是如果大家用过钉钉来探探的话，就应该知道左右滑这玩意儿就是典型的所谓的选择权。我喜不喜欢他，不喜欢他，喜欢他，这个是他。而这个低头的一个意思，就是说不要去这样了，你就跟我好好聊清楚你是个什么样的人，你想喜欢什么样的人我来帮你找我来帮你找到底这个东西找到一个什么样的人，他喜欢什么东西，并且还怎么着，我来帮你找他，并且我还能帮你干嘛，把怎么跟他约会的全流程给设计好OK了。然后你们要去做的事，唯一的事儿就是去做约去去约会。对，所以他就说他们现在已经匹配了几百次，而且他会干嘛？他就是对列出计划，还会有他们的工作人员很久。

他是说会把他，对你看会安排在人流充足的地方，以便让大家表这个有让尤其是让女生比较有安全感。然后把它提供足够好的规划，让你们俩约会是比较叫什么充沛的，这个是这样的一个比较丰沛的一个约会。然后双方都约定好了以后，都确认了以后，你看他还会安排团队的人员在约会场地附近提供隐性支持，既保证安全又不干扰互动。说白了就是你可能他就万一你安排这个约会，导致出了一些安全事故，其实他是有风险的，有有责任的。所以他的意思就是我把所有的这个选择权交给AI，让AI来帮你选，其他事都不用管。这个意思是。然后另一个是这个美团生活的这个小美，我不知道大家有没有人用过，有人用过吗？这个小美这个APP当然你用了。

听说挺惊艳的，我没用，但是我听说还不错。

我觉得我就用了一下，还是挺好的。从。

还是用这个来去投屏，你还记得怎么？

这个就是小美这应用，它其实就这个东西，我现在就说帮我点个麻辣烫。对，然后他就去搜。然后这过程你可以想象，你美团的，所以他背后的API它都是现成的，然后自己去搜，它背后对应的这个你附近的麻辣烫什么的，你看这个没问题，然后给我加个可乐吧。然后可能分析，然后直接去调对吧？所以背后肯定是美团把自己的这些API给封装的很越来越丰富了，然后就OK了。

你觉得这OK了，那我想要大可乐给我来最大瓶的那种。他的语音识别也还是挺不错的，做的挺好的。然后你看他这个就这个部分，这个动画的部分就表示他在思考的这个部分也挺有意思，每次都还不太一样，有点搞笑的意思。那他调这个外卖服务其实就是API，最大瓶装的看来没有更大的了。对，然后他就会去，你觉得OK了，你就可以直接点这个右下角的。

Ok然后就会干嘛呢？他就会觉得你你你要付钱了，应该是就开始付钱了，对吧？你就那啥我就不付了。

对，这个东西确实挺不错的。我觉得这个成功率很高，而且几乎没有什么失败率。我觉得这个东西是一个做的很很直接的有用的东西。然后另一个我觉得这个产品也挺有意思，叫非tale fate tie，是一个听名就知道是啥了。这个其实挺不知道大家有没有在这个有电话吗？你都没看到。

对，就大家有没有喜欢玩算命的，我不知道有没有在群里面。如果有的话，其实挺建议去玩一玩这个叫free tile的。一个这是一个华人团队创业做的一个产品，叫什么什么运输这样一个东西。然后你开始就输你的什么生辰八字，乱七八糟的那些东西。以后他就给你生成什么叫日签，还叫日月签，什么乱七八糟这些就算这些东西，时空地图什么这些这个做的我觉得真的像那么回事，还得交钱。这个流年大运，都能算的还挺好。

而且当时他说一个什么点呢？就是他这个产品的核心就在于说他只做中国就中国文化下的一些算命，不做什么塔罗牌那些东西。然后中国的这个算命其实就有很多种，反正就东方的这个文化相关的背景所以我觉得这个据说这叫什么付费转化率贼高，所以大家可以去玩玩。如果咱也要创业的话，可以想一想，我觉得这个确实是算命这个是一个长期稳定的需求，而且是一个确定性的需求。那你怎么做呢？这件事其实就大家各自有各自的玩法。然后可能很一直很关注的就是大家用什么工具，就是大家用什么AI工具去办公。又是HUZ的一个partner，他做了一个这叫什么分享，他基本上调研了一圈儿，主流的这些AI的办公工具，从什么垂直的到两。

就从这种垂直领域的到这个通用领域的其实都有。然后你看他调研了大概这些，所以H6Z看上的这些办公工具，我觉得还是挺值得去提前去玩一玩或者用起来的。你看他所谓的vertical，vertical就是垂直的。比如说就专门用来写mail的，就专门用来写PPT的，写note、写word的，写这个表格的，还有所谓的horrigan，就是水平的。这个意思其实就是通用的，因为这个vertical就是垂直的，就插下去，然后横着就是比较通用的那通用的有啥？这边相对来说大家可能认识多一点，比如像minus，臻Spark，然后这个对吧？就这些其实都是Operator，这些其实都是通用的，就是他能他啥都能干，然后浏览器插件也是啥都能干。然后这个新一代的浏览器，像comment，像d brother youth这些都是通用的浏览器工具。

纵向的就是垂直里面就是这些，这些可能大家用的比较少一点，用PPT的gama肯定知道。然后word里面什么纪就会会议纪要的这些的，这些可能叫了之前给大家介绍的对吧？Notion肯定大家都知道，然后用excel的这个可能大家用的少一点，但说cut AI据说很不错，但是因为这一上来就花钱，所以就一直没用。

大家可以看看它底下的评测，比如说大家如果想做PPT的话，确实gama是个好选择。因为主力又快，相对来说还算挺好用的，质量也不错，样子也漂亮。James mark不错，其他的几个就差一些。然后写email的写这个电子表格的电子表格，我没想到电子表格这件事情是minus做的这么好。这个很棒的一个，说看AI也很不错，但是他他一上来就要交钱，所以就没用。其他的几个配件什么的太通用了，效果很一般。对，所以大家可以去到里面去找自己想要的工具有哪些，就哪些是可能可以去就真的能用起来的東西。好，然后这个是。

说然后最近有一个MCP上了，比较火的是这个东西叫MCP chrome prome大致就是这个浏览器的这个chrome。所以MCP chrome啥意思呢？其实就是把你的浏览器给变成一个MCP，能够让这个A卷能用。那怎么用呢？其实就推荐大家就给大家简单演示一下。我去。

装完了，然后就装这么一个NPM，然后当一个它的这个插件。它的做法其实相对来说是最不侵入式的，就是不动你的浏览器，你可以还用啥浏览器还用啥浏览器。但是你可以通过一个插件让你的agent能连上去，怎么用呢？你就直接看看，直接当下那个插件，然后当下插件就从这儿加载一下，然后就OK了。加载到这儿，它就变成一个chrome MCP server，然后你把它给展现出来。好的，这。和那一下连接上，它就表示连上了。好，然后你就可以干活了，就是你你可以找一个你的agent。

我现在我这儿用的是Cherry studio，这个其实也挺推荐的。Cherry studio是一个很好用的一个一个接各家大模型或者一个A本地的agent桌面里面应用。然后点开这MCP，你就可以加各种MCP加个。应该是。然后你在外面这部分，我就可以新建一个session的。这个session可以选各种模型，比如说。选V3，然后选个什么命令呢？我就选。比如这个，帮我总结一下我当前那个页面，并且画一个图让我好理解。

选上。

那个你选上工具，把这个工具选。

微商的工厂。

别傻了。每次都要打算了，又又跑下次再来演示这个东西。其实就是你要找配上MCP，我看是不是连上了。晚上好。

我想出去。

我这个骑自行车，然后随便选模型。我。

希望他能成。好的，你看他就会去调我当前浏览器的这个MCP。然后这个MCP就拿到了这个页面内容。这个页面内容是啥呢？就是我现在用这个浏览器打开的这个页面的内容，你看就是这大胆先进去了。然后他就开始给我总结，总结完了以后他给我画了一张图，然后就OK了。

所以说白了啥意思呢？就是虽然我们刚刚看到了一大堆这种，现在有这种浏览器，就是AI浏览器对吧？一大堆单独的AI浏览器。但是我觉得大部分同学还是喜欢用使用的灌的比较习惯的自己的浏览器对吧。那这次浏览器里面有很多这个，如果我把它去怎么能很快很方便的用一个agent来去操作我的浏览器才是我的最佳选择。所以我觉得这是一个挺好的选择，就是用这MCP chrome，然后直接其实就装个插件，就可以让你自己本地的各种的这种A的工具，可以直接操作你的浏览器里当前的网页，然后干各种事情。所以这个是一个推荐所以推荐一个是这个MCP chrome，就是能用你的chrome的。

另一个就推荐这个Cherry studio。Cherry studio大家这是都是免费的，大家可以自己去用一下。注册各家网站，注册那个模型的网站，我其实还是推荐不要去单个去注册，就注册这两个。如果你想用国外的模型，你就用注册一个open router。然后你想用国内的大模型，用silicon flow，这是轨迹流动。

然后你只要把你的key填进去就OK了。然后在里面你可以几乎用到所有的国内的模型。这就是所有的我几乎所有的国内主流模型，你都可以在里面用的，你只要给他一家充钱就行了。在open root里面你能几乎用到全球的各种的主流模型，像deep c GPT5，什么都可以用的对，所以就冲这两家就OK了，你也不用担心被什么HRP这些给封给给给给封掉，对吧？

所以这个是一个网站，这个产品是刚出的。但是说的比较玄乎，我还没有用出他真的好不好的这个点，这个叫白卡点AI，所谓的号称世界第一个一个organizer。Organizer就是大家以前用这种agent，大家总觉得是模型不太行。但是随着现在这种模型越来越好了以后，大家开始担心说你能不能干好很每一个很垂直。第二我们与其指望说模型还持续变得万能以外，还有一个想法就是我能不能搞出一大堆特别只擅长某一个领域的事儿的一些A症。然后让一个agent来去帮我，根据我的任务去组织我到底应该把谁吊起来，对吧？比如说我想写一个write a story about a panda，他就会开始干嘛，会搜到底这个任务可能会用到哪些对应的agent，然后你就可以去装它。装了以后，你就可以得到一个团队。

这个团队就是有各种不同擅长不同任务的这样一些age，然后你就可以让他去组合起来帮你干活，由这个team leader来选到底当前任务应该给谁干这件事儿。对，所以这个是一个白卡，这个现在还没用上，所以这个看用

上以后再给大家讲。然后最后讲两个东西，一个对这个这我还是觉得讲一下特有意思。MIT有个项目叫alter ego，alter ego这个讲什么？

让你记没意思。

他还是我之前讲的那个技术，叫做silent sound，叫silent speech recognition，就是不说话的语音识别。就是我不说话，但是我能识别出来你想说啥这个东西。那你可以看看它实现了啥效果？是MIT那个媒体宣誓出来的一个项目。你只要带着这个东西，虽然挺丑，我们已经比之前几代好很多了。你只要靠近说的大家注意这块儿，它不是靠他想的，因为如果是靠想的话，就用一G用路径电流的这个在在脑袋上带一个东西来去识别了。他靠的是靠说的，就是大家都能感觉到那个就你不说出话，但是你好像把这个话说了。

这怎么做到的？

就是你你闭着嘴你不说出来，但是你就说叉号是傻逼操是吧？大家都能做到，你试试。对你试试是能做到。

对不？我要发声吗？我就是只是闭嘴。

但我发声音吗？对，就纯闭嘴。

这做不到，我没什么动作。

你想想，你如果不动嘴唇的话，你就动那咽喉部分。而且就算不动那么多的咽喉，其实靠就是你说话的其实就是脸部的这个神经，其实已经在有电流的激发了，激活了。你看到他有篇paper。这个。就是你你你即使没有说出来那句话的时候，你的面部已经有一些肌肉在激活了。然后这些肌肉怎么去识别问题，就是怎么去识别。比如说你看他把人的面部分了好多区域，然后每个区域会有对应的肌肉。你看这个人脸部肌肉还是非常复杂的。

你但凡你的因为说不出话，是你的声带震不震动。但是你就算声带不震动，你可以感觉到你不震动你也可以把好像说话这个动作完成，最后不说出来也能做到这个事儿。但是你不说出来不这个叫什么？声带不振动也直接代表了你的肌别的肌肉其实有有运动或者有变化，有变化你的肌肉就会产生电流。

我刚才憋了半天，我觉得我这个变化都不如我呼吸那个变化大。

对你再再再练习一下，再练习一下，你学习。

我觉得这个。

对，你看他所谓说出来的话是这种级别的。就是一个词是哪个？是读一个词要解决的。

然后这个怎么说。



出来呢？其实是靠一个这边有一个骨传导，骨传导的这个部分能放声，他就可以直接能听到这个声音了。

的就是对他就直接通过这个录那个骨传导就给你说出来了。所以他管这个东西叫做完成了闭环，就是完成了一个close loop。为啥呢？就是你不说话，说话他能够说话告诉你。对，然后就这么个东西。然后你看他通过对面部的这个肌肉的分析，最后选出了大概这么几个点去放这个所谓的EMG，就放那个对肌肉电流的传感器。然后最后通过神经网络识别到你识别出来到底你说了啥这个东西。这个其实是已经从MIT媒体实验室毕业的这么一个项目，所以应该还是比较靠谱的一个东西，叫alter eagle。

我觉得这个是一个作为爱人用大用模型对话的一个非常必要的，或者对于一些特别特殊场景。比如说你看着话剧的时候，你想寄一些东西，然后又不想吵到别人，对吧？我觉得这个挺好的，我就需要。

对，然后最后说两个东西，一个是小米的路由器，大家不知道看到没有，今天发布会了，这个东西双万兆。所谓的AI双万兆大家想想，前几期给大家讲说这个AI nas，AI nas就要出来了。大家可以想象这个东西为什么要双万兆一个路由器，然后还号称AI双万兆。那其实肯定是为了他的这个AI nas打打前前詹。所以大家可以想象这个AI nas一出来以后利好哪些呢？肯定是有有一些标准的行业的。

然后现在的AI nas我了解到的大部分都还是跑小几B的模型，比如说123B的这种小很小size模型。但我觉得这个趋势可能再过个两三个月之后会变。但是现在目前来说，在做这个AI nas这帮企业其实跑的都是小几笔这种模式。我听说这个量还是不行，我觉得还是太小了。就是怎么着都得跑个二三十米以上的模型才能比较真的能做一些比较具体的分析的工作。所以这个是一个前哨。

另外一个，大家听过了听说了立讯跟立讯要代工open I的硬件。之前给大家说这个叫什么来着？某讯某某利某对吧？对，他他其实在这个眼镜在这方面也在做事情。然后大家看看到这个open I的这个新的硬件设备，之前给大家讲过一期open I的最新的硬件设备。就未来硬件设备应该会在27年26年到27年左右会上市，所以其实还写着呢大家不要觉得这个已经到开始生产的阶段了。

有人说没买气死了，没事儿，买它在戈尔买他在戈尔。

然后open I找了立讯，还找了歌尔。

来了这个。

俩都找了，为啥呢？就是因为大家想象下一代的硬件肯定是一个形态有变化，交互有变化的一个东西。那交互有变化的一个东西是什么呢？就是声音，我看哥哥哥哥。

对对对，就是声学模块肯定是戈尔来歌尔股份做的，然后open I来去跟他把单给了戈尔加利训。我觉得这两个是一个很明确的一个趋势，就是他妈的下一代的iphone必然要在中国先生产，我觉得这是一个特别明确的一个趋势。然后欧派I就要去做产品定义，做做这个软件定义这方面的事儿就OK了。那至少最头部最顶尖的下一代的AI硬件设备应该是在中国造出来的。然后它的各种功能或者各种特征，跟上次给大家讲OKI的这个硬件设备的没什么区别，没变化。对，所以戈尔就这样。

那好，立讯，你看这个消息是啥时候呢？这个消息应该是在20号左右。好，那另训精密呢？它的股价是在什么时候涨起来的呢？在18号左右，19号左右就涨起来，所以肯定是有人抢跑，能抢跑。然后当然这个立讯其实已经涨了好久了，涨涨了一段时间了，最近又涨了好几个了，这应该是涨了好几个版本，我靠。2 3到70。

这个我可以说一下，这个确实是如果大家在生产端供应链这侧有很多的连接的话，其实确实对炒股会帮助很大。我记得年初的时候，在某一个存储芯片的公司，然后他们当时说meta给他们下了超级恐怖的一个数字的存储芯片，然后当时就是这一代发布的这个connector就是这个meta。

connect.

但是那个那个数字非常夸张。然后对，你就感觉除非他超级有信心，否则咋可能下这么大的。然后回头一看，这产品确实很。

这波眼镜也是，这波眼镜meta对镜下的应该是明。也下了非常大的一波单。然后你看这个2月19号，其实如果大家能及时关注这个信息的话，22号还有机会。对，就是19号的时候其实涨55，然后20号1消息一发，你就立刻上从60涨到70，但是还有一点肉可吃。

这这不能了解。

对对对。

他他这个逻辑不一定是这样，他经常情况是这样，那个真正官方一发就是大跌。

也会有经常的这种情况。对，然后对information其实也是20号发的，所以这个消息其实没有太多的时间差。对，20号发的。好，那今天我靠TA这部分。这个我还没讲，下次下次下次我们讲那个地震，下次正好带着大家MGX，咱们有群里有同学玩那个能注册完了以后就赶紧玩一下，然后看看大家有谁做的比较好的，可以给大家秀一下。然后auto jam可以，这个其实跑起来非常容易。如果有一些想法或者想去跑点什么东西的话，也可以发给我们看看是不是能大家的这个需求来去跑一跑这类的Martin东西。行，那差不多就这些。

好，没完。立讯是真的是牛逼。对，这波我感觉中国的制造真的是要把这帮活这摊活全接过来了。

对，理论这种组装什么的，这是中国绝对的number one。

挺高精度的这个组装。

那那那那那那那比起半导体还差点，半导体是最那个的，然后再往下PCB也都是自动化程度很高，然后就一个是纳米精度，一个是微米精度。你再往后其实都是十几位的，这种十几个比起那个。

都不是一个数量级的东西。

对，那就不是一个态的对，组装相对来说亲密度还好。完中国的自动化和人力成本在这确实没法搞。

对，甬客气，王老吉算王老吉等国家的。行好。

下周同一时间咱们再会好。

好，好，拜拜拜拜。

拜拜拜拜。