

大家晚上好，很感谢大家又准点来到咱们今年事来学点东西。对，这周其实有有就是核心今天核心今天给大家讲的是这个报告的state of ai report 2025。然后这个报告非常有名，然后基本上已经做了好像七八年了。做了非常久了，算是从开源情报里去获取，去做这个AI领域分析的最最核心的几个报告之一。所以今天主要就给大家拿这个当做一个线索来捋来去捋一下。然后捋一下的过程中，大家会发现一个特别发现一些发现很多特别有意思的研究，其实都是咱们大概这半年不断的讲过的东西。然后我觉得这个报告整个这样一个过程也特别好，等于映射了说咱们每周的分享。

其实对于对咱们到底提高对整个AI领域的认知有多少，或者到底有多少熟悉的东西，是一个挺直观的这样的一个表现。如果大家能看到自己之前听过的东西，然后好像还甭管是一知半解还是真懂，那就就就就达到了我的目的了。就是大家能看到这样的一个最顶尖的开源情报分析出来的这样一个内容，AI领域的内容，大家有一些熟悉的东西。我觉得这个就跟当时小斯说的，就是我们花一段时间去看一看这个领域的东西以后，发现有不少东西都是大家之前了解到的，就挺好。然后过程中如果大家发现有一些这个内容并没有不知道不明白或者说这没见过的话，hello，长号来了。

大家如果这个过程中如果发现这个有没见过，但是我说好像之前讲过的也可以在留言板里说一下。这个大家不太明白，然后这个我就单独再讲一下。对，所以这个大家可以随时发到评论区里面，有什么问题？好，对我先说一个，我现在在成都，然后这个是参加那个影幕的发布会。影幕就是之前给大家介绍过的这个AR眼镜荧幕这家公司。这家公司在中国的ARVR和所谓的XR这个领域，还是挺头部的一家公司的。所以大家可以关注一下国内的AI眼镜。确实是也就还是我上次的观点，就是。

你是不是还没事。

屏幕我靠，sorry. 要不一进来我都没意识到。

跟发生作用。

好的，sorry. 对，荧幕这家公司就是国内的做AI眼镜的，但大家听过的可能是像rocky这种，然后影幕是另外一家也做的不错的，然后还有x real。X real之前给大家分享这个google IO的时候，大家知道它跟google I它是google IO的供应商一家供应商。对，然后国内的，所以确实大家关注，如果关注的话可以看看一下他们背后的供应链，可能其实可能是更重要可能更重要的就是比如萤幕到底是谁帮他去做的。我现在投屏了。

我现在投屏了，现在投了太好了，没问题。

对，就是他们背后是谁给他生产的，然后一些关键组件是谁供应的，这些可能是更重要。

但是这些说出这些代工厂的名字没有。

有一个很很很经典的，已经好几期之前就跟大家说了，对吧？当时还立差的，就是立讯。然后立讯还有歌尔GBL这几家其实就那么几家能干这件事情。之前说十月份，是十月份，十月中会发一个眼镜，然后那个是也是他们家也是立讯代工的，所以这个大家可以关注一下。这个肯定最近几个月2 3个月，立讯还会在网上也不再往上，就是还会有他代工的东西出来。

对对对，好，然后回过头来就是我们今天说主要这篇报告的核心目的，一是说最核心目的其实就是想大家今天这个标题就是大家捋一下今年还有一个季度对吧？那这个季这一年发生的各种变化中，哪些是很关键的。这个

如果里面有大家没见过的或者不知道的，大家可以随时在这个评论区里说，就跟他说了这个是什么nancy bati什么。这个人发了去八年了，好像AI的这个报告特别牛。所以大家每而且关键是他每次发的报告都贼长，你知道吗？这报告是二百多页，所以今儿肯定是说不完的。但是这个尽量希望给大家过一遍，然后大家自己心这个大家心里有个数，说哪些领域有什么样一个最新的东西是啥有个数，这就是非常重要的。好，然后他前面做了一些东西，其实就从这个take away开始说，就是他的一些关键的要点有啥呢？

就是open I还在微弱领先，它叫return一个narrow lead，就是在前沿领域保持一个很小的领先。这个其实大家也都看了这么多期这个分享以后，大家也能感知到了。从哪儿看这个领先多少呢？其实就那么几个地儿，artificial analysis简称AA对吧？这些大家都看过了，然后大模型竞技场LM arena这两个地方。所以基本上在但凡在咱们直播间里，如果大家还有同学别人问你们说大模型哪家强？这个比较公正客观的评估。如果还说不出来这俩网站，那这个就不够意思了。

对然后那这上面其实可以看啊，其实确实open I的这个领先的趋势还是很小的。领先的这个gap 98分95分。我比较惊讶的是你看它最高的现在是codex，codex high。对，长，我不知道你你对你你没有充200到用户是吧？

等一下充两百刀的那个codex效果还不一样是吧？我以为只有用量的差别。

其一他没有说用的是不同版本，他至少没有说是不同版本。对，但是我从两百刀以后，对这个不幸的消息是昨天早上他把我封了，对，ChatGPT把open I封了我的账号，我就我。

觉得现在GRM很猛。

对，大家可以看这个分儿，68、65。但是你看其实前面的模型全是美国的模型，对吧？XAI's rapide google. 然后最开始其实就是中国的模型出来就在这儿。

我能说一句，我其实觉得glock那个有点虚。高词就是我的字节的体感是glock肯定是不如这么点2.5好用。

我也是，我几乎就用rock，是只能在twitter里面用，还有点用。对，就是跟他做点分析。

单用不知道他测的是什么能力。

也有可能是就这些，反正我这些上面这些MMLU pro超奔驰乱七八糟这些东西就是很学术派的评估方式。

反正我自己实际使用的体感是这么的。应该比这个别的要更靠前一点。

然后从中国的模型开始，其实就从这儿切问235B对吧？千万三，然后最新的一个3.2，上期给大家说了GM4.6，像max而且。

为什么4.1 oppos是不如sonnet 4.5的？

不如那个那个。

收纳4.5这个。

4.1欧派这是一个coding的半数，不是，这是一个综合的的各种的这种类型的bench。你像MMLU，然后什么HMHLE这些AME这些就是很学术派的做模型评测的方式。所以他反正那个报告里面也讲了，其实会有非常多的波动性。就是说白了你把这个题稍微改一点，一分就大变。所以但是还是大家比较公认的这个评估方法，所以我觉得大概的这个T2几不会有变化，对吧？都是T21就是这帮人，然后T22可能就是这帮人。但是具体排名我觉得肯定是有变化的，而且XAI没准是有后门。对他有扣的部分，你看扣的部分，扣的部分就更过分了。

Brock 4是第一。如果按你的说法是不是就很神奇了，就不应该有这种排行。对，回来我们就说这个现在的的第一就是o en l的这个排行在第一。

但是你看随着meta将接力棒传给中国deep seek，千万kimi？这三家上榜了？这个志鹏很伤心。然后什么接力棒？其实就是开源模型的接力棒，然后这些模型其实就是一个让中国成为了一个可信的number two，第二名，然后推理模型对吧？今年所有大量的模型的前进方向都在reasoning部分，从推理模型的出现到推理能力的到底怎么涌现的，到底怎么增强的，这些其实都是今年的最关键的一些点。

然后第三个，对我发现很多报告里现在都在提这个东西，就是AI在成为AI for science，AI为科学来去做的AI系统对吧？然后AI becoming了科学的合作者，然后他举了好多什么co scientist的斯坦福的一些训练实验室，都是证明了什么呢？就是这一代的AI在快速的成为科研领域里面的助力。但是我想可能这个领域的人，咱们直播间里面这方面的人应该比较少。但是按照这个报告的说法是说，我们可以预期一个由AI助力的一个科学领域的进展会非常快速的发生，就是会加速的非常快。然后这个所谓的结构化推理进入物理世界，说白了就是啥呢？机器人，机器人在随着推理模型的这个叫什么发展，变得越越有脑子了越有脑子了。今天待会有说那个figure 03，或者像这个gym l的这样的一个几个robotics，其实都是这方面的一个表现。

大家逐渐的觉得这个机器人开始智商有有脑子了，然后商业化的应用加速，我觉得这个值很重要，rap是一个做企业支付的一家公司，有44%的美国的公司在为AI工具付费了。这个其实我觉得可能应该已经比中国高不少了。对，就我纯纯猜测，我也没有数据，因为国内好像很难搞到这种数据。

这个报告以及HUZ的报告，其实都有这方面的一个结论。就是企业在大量的为AI工具付费，而且是企业为工这个AI工具付费。我直接看一下AAQV的一篇文章，这也是刚刚发的一篇文章，就是到底AI公司的钱去哪儿了，这个是10月10月2号，就上上周的一篇文章。

为什么他能做这种报告？我觉得很关键的一点是这个mercury，这个什么水性，就是这个公司其实，是一个第三方支付公司，可以这么理解，就是企业比如说想给这些这些大模做大模型的，做这个工具的公司，比斋马盖马这种公司花钱的话。Mercury其实是一个专门等于是B2B的一个支付的公司。所以它有很多数据，然后可以公开，可以跟别的机构来去合作分析。而国内我觉得这个就很少，我是真没见过，不知道超你见没见过。就这种企业的金流的分析可能是很敏感的一个东西，但是这个也导致了其实我们不知道到底谁给谁花了什么钱，哪些公司真的有有有有有收入。对。

然后这种这个对支付公司确实有这个数据，所以我觉得像支付宝跟那个微信肯定都是入口企业其实。

不太会用支付宝微信。他的意思是说那种B2B的公司就是对B2Bto b。对，就是你企业把钱给B公司，B公司帮你把钱给OpenAI这样的公司。然后44%.

其实实践经验来看，这种AI工具反正企业付费也是大家员工花完，然后找公司报销，至少我们是这么粗糙的。

来我们对对对，创业公司肯定都是这样。但是稍微财务对合规一点的肯定都不合适这样。然后你看他关键他平均的合同金额达到了53点万刀，这个值是非常高的。我觉得应该是年一年好几百万，对吧？67三四百万人民币的AI的付费。我觉得可能大部分公司一年花在IT上的可能也就这件。

然后他今年开始做了一个从业者调查，这个还挺有意思。他有一个开放式的调查，你可以看到AI的从业者到底有没有给AI工具花钱，花了多少钱。这个值是很可怕的一个值，就是基本上大家都每个月至少花20到200刀这样一个区间。

然后AI的所谓的工业时代，这就不说了，其实就是整个AI基建都疯疯狂疯狂的在发展。然后AI的地缘政治方面越来越严重，越越紧张。然后安全方面，反正所谓的更务实的阶段，说白了就是大家不那么天马行空的去想象了。在保证有用的情况下再去做这个事情，然后生存什么方便，这就不重要了。

对，所以大概是这么几个东西，然后我们就开始看这个具体里面东西，这个东西怎么看，这个报告咋看啊？我是推荐这个，就是你看这个把它打开，它其实官方的是用的是google doc。那gold dock的这个文档，你只能在线看，而且也不太好的好好好去拿别的工具去分析。所以我就把它当个PDF当到文件里，然后再什么呢？

再用之前给大家推荐过的这个沉浸式翻译。用这个沉浸式翻译，然后你可以直接把这个沉浸，把这个PDF扔到沉浸式翻译里面。就比如说我当下了，我得就到就这个PDF，然后直接点击翻译就OK了。它就会像别的网页一样，给你出一个原文加中原文加译文，原文加译文的这么一个PDF。然后我就直接看我之前已经翻译过的这个版本，就很方便。大家还是推荐多用这个沉浸翻译这种工具来去看东西。我看看，往下看。对，然后这块快速过一下。

既然都上了，咱们快半年半年了，这个课这些概念应该大家应该都都门清，对吧？这个AI就不说了，agent, context window上下文diffusion，扩散模型这是一种？主要用在生成图片各种环境，就是agent的跑的那个地儿，风声扣agent怎么去调用使用工具的这个能力，生成是AI，GPU这就不说了吧，这个还是打基本的概念再说。这边还有一些稍微难一点的词儿，什么大模型？ME、专家模型、提示词推理模型强化学习，test time compute其实就是推理吧，就是推理时的这个计算transformer这些东西。

世界模型大家都知道。好，然后这有一个他做了一个定义，我觉得挺有意思的。你看就是所有的模型大家都说多模态，但是到底有哪些模态？或者说这个模态的模型到底是什么到什么的这样的一个模型。他拿了一个特别形象的例子，这个去年的报告其实就有，就是那一直到今年我觉得他增加了几个，增加了其实增加两个，这两个东西，文本的文本就是我们常见的大的模型对吧？

文本加图变成文本，那是多模态模型。然后后面还有什么？这个文本到类似DNA或者生物或者化学这些东西，其实这个已经是一个比较大类的模型类型了。最后就是文本到世界就是一个对吧？

啥叫文到世界？

吉米吉米three听错了。对，那次那那那次课给大家说的一句话穿越回1840年的故宫，对吧？这不就是一个穿越一句话文字到世界吗？对吧？大家还记得这three g three实在是分辨率高了好多。你看这个对，但是他好像到现在还都得申请才能用，他的这个模型真的是管的很严。

And generate or them interactively, 记得把all the single tax print, 对吧? 一句话说我在。这什么东西 skating, 在这个滑雪在滑雪道上滑, 然后在一个巨大的坡, 即将要跳出去, 对吧? 就变成了一个可以互动的世界, 这个质量高了很多。这个世界模型junius three, 然后这个就是世界, 这个世界模型再往下就不说了。

好, 他分了好几个部分, 我觉得这几个部分也是大家去看整个如果从整个生态来去看的话, 那确实是一个挺好的一个框架。就是从AI的生态一个是研究, 当然这是最大块的研究领域, 就各家模型出了各家公司出的人员模型有什么进展? 工业、industry行业、行业领域, 各种的行业, 然后地缘政治, 然后安全有一个调研和一个预测, 他们家这个报告特别有意思, 也是个他每年都会做一个明年的预测。然后申请给一个翻译好的PDF, 这个还是那啥, 我给你给你一个原文PDF, 然后你去当一下这个沉浸式翻译, 自己试一下怎么点。其实挺容易的, 只要加一个改一个配置就OK了。

我觉得这个就给留一步的这个作业, 这个还是橙子同学还是自己去试一下, 怎么去翻译PDF, 我给我可以这个到时候可好, 给大家发一下呗。这个英文的PDF对, 从这几个方向来发展来看, 然后这个研究, 然后他先来搞了一件事儿, 就是去年他预测啥。我觉得从这个预测也能看出一些有意思的叫什么偏见或者执念, 比较理想的执念。你看成功的是啥呢? 是这些绿色的, 黄的就是半成功, 然后红色的就是失败的。他预测失败的这些点, 比如说他这个成功, 我们直接看他失败的看哪个呢?

欧盟的AI法案这个比温和预期中温和, 因为担心这个法案权力过大, 又对吧? 这也是欧洲就疯了。欧洲就是AI法案的这个约束或者这个限制就是很严, 所以导致其实今年整个这半年欧洲的各种的模型, 各种的AI应用落地的非常差。然后后面有一张图可以看出欧洲基本上快脱离这个第一梯队了。

然后下面这个失败的什么呢? 比如说这个对拟人化的, 所谓的you human joy的这种对机人形机器人投资减少, 然后结果不, 今年的人形机器人投资已经达到了三个billion, 是多少? 三个billion, 对, 三个billion 31刀, 所以其实还是挺多的, 然后比去年都涨了一倍。然后苹果在这个设备端的成果, 加速了个人人工智能势头, 对吧? 这个no以为这个apple intelligence实在是太拉胯了, 我觉得真的是太拉垮了。确实是我最近我那个日日韩的可以开始用一些ipad test, 发现真的是比小米的差多了, 这或者至少我用的模型这个效果很一般。

然后最后一个是我觉得这个挺有意思。这个可能对大家来说也有一个想法, 就是一个视频游戏, 一个video game, 基于什么呢? 基于生成式AI元素互动的视频游戏取得突破性的成功, 啥意思? 就是一个完全由生成式AI驱动的一个视频游戏video game。能够火出圈儿对吧? 大家确实是去年有些幻想, 觉得可能今年可能有一些各种的多模态模型一一爆发以后, 有一些游戏公司能搞搞出一些有意思的东西。但至少目前来说还没有我觉得大家可以。

我真的想不是在做谁, 米哈游测试太后。

米哈游。对对对, 那个那个应该还是挺值得期待的。这个肯定是在有人在做, 但是至少还没有。

出来推推过。

然后第一部分就进入最最烧脑的研究的部分, 大家尽量跟上。然后如果跟不上的话, 就随时说随时发到群里。我去, 怎么怎么怎么什么意思? 国内都等R2出来打擂台了。对, 我觉得R对, 反正deep sig不是那种特别急着去。后面有一个图有一个图特别有意思, 就是融资的跟融这个公司的融资跟他推出模型的一个关系。我看能不能出点方顶。

到了再说，其实就是这公司发了平均多少，在融资前多少周会发模型。然后好像是40天50天左右的这样的一个区间，说白了就是这些大模型厂商其实融资是一个融资跟发产品几乎已经成了连在一起的这样一个行为。所以也代表了这个领域其实风险还是挺大的。

你但凡资金链断了，你的整个公司其实就很快归零。为啥它价值会归零呢？并不是说完全0，其实核心是因为大模型你但凡落后了几代，落后了一两代以后，它的就几乎不会有人用了。不会有人用其实说白了就是他资产价格为零了。对，然后商业付费确实很少。对，这个就还是那一点，我希望大家至少在咱们这个群里的同学。

正能量推荐抱怨正能量。

正能量是我是说推荐大家花点钱。

你们这前两天。

我看这个蜜塔对吧？蜜塔终于开始收钱了，很开心。蜜塔终于开始，可你可以给他充钱，然后换他的叫什么导出PDPPT了。对。

这些功能听老师下次给你的捧眼也充了钱。

这太太便宜了，你看这随便给你充一年。你这对对对，大家多问问题，如果问题比较好，居然挺好充满。

你居然没有什么q mt之类的AI浏览器。

没有，对我还真没有。因为看这儿gym的浏览器OK的。

你这不是chrome吗？

对，chrome已经升级了，你可以随时在这打开它的这个可拍了是吧？对，直接接的是你的那个german的服务，所以这个刚更新的众多用户才会更新。对，好，然后只有千问。什么叫国内只有千问会服务，千万没有商业，没有个人服务给一个好的反应。Open有没有了解open的agent kit上上节课大概讲了一下，这个神经蛙墙聊的是啥？是开发的。

请问对迪拜的影响，对制服coco的影响哪儿呢？Code dex哪个？我就说agent kit.

agent kit对，define我上节课也讲了一点，上节课也没来，你没在。然后我觉得至少目前他针对的不是一拨人，就是agent的agent builder，因为我被封了。对，agent builder他的那个抽象层级比迪拜高。然后define它背后所以可以用的各种类型的配置实在是多太多了。就是defy相比agent builder，底层它面向的是相对来说专业一点的构建就是开发者。然后agent builder真的是他尝试面向一些非专业用户，或者不写程序的程这个用户，但是我觉得是失败的，就跟LangChain吐槽他那个人一样，就是他还是不够简单。上次演示了，你还得在里面去拖拉拽一下，写一点什么。如果什么类型等于什么什么，如果类型等于什么的，还得写这种东西，那其实就不是给普通用户用了。

对，所以ANT的大家神经，你想聊啥，你可以待会儿问留一下。对，codex用了一下RDE，但是感觉跟特色差不多。Codex问题是啥呢？Codex它我靠我一封就是真的是这open a全系产品不能用codex，他几乎不让你碰。具体的文件具体的那个代码文件curse r它其实是还是基于你的代码文件去做的，还是让你基于这个代码文件去做做的。所以你的问题在这儿，然后各种东西其实就跟开发者的传统的使用界面差不太多。但是code x真的就是一个你就发号施令就行了。但是是说专业开发给专业开发者用的一个发号施令的这么一个工具，所以这个逻辑不太一样。

他说的是说他用了ID方式，如果理论上讲在ID里欠的话，那肯定确实跟科比的形态差不多。但是我觉得那个使用上应该还是有差别的。

我其实一直对codex的使用都不太感冒，就是codex纯网页那个还是我说纯网页那个版本。我靠，我发了一些以后，我只能干一件事儿，就是把代码扔上去。我其实测试环境什么乱七八糟他都摸不到，那我只能盲推，说哪的没有，谁不来，谁不来看看我这是啥版本。141.0，我操都141版本了，真的太可怕了。没有，不用担心，这个完全听不懂，不会完全听不懂的，这个不会讲技术的，不会讲那个很具体的技术。当然有些同学问，那肯定要讲一讲，这个给大家看一下版本是你。

这版本可能还高一点。

为什么？

就是用户的问题。就没有你那个AI那个button.

你要常挂着梯子，而且最好挂一段时间，在纯海外的环境挂一段时间就会退。

all day。

对对对，你全天挂对，那就说明你的google的产品现在用的不多呗，或者随机种子。不不，随机种子不青睐你。

是因为这半天我刚刚没有续费。

我也没续费。

what? 我是之前续费的。

我只是刚刚的续费OK好吧，好的，然后AI安全A证到什么时候阶段才有作用和价值？AI安全A证你说是用来做网络安全的还是是什么？是不是？

比如说我有一个agent专门用来帮我把我的网站，把我的服务给打补丁，然后找漏洞这些东西。如果是这个的话，现在其实就不错了。比如说做call review，做漏洞的挖掘渗透这些事其实都能做的还不错。然后如果是攻击的话，那现在就是时间点。对，就是这类的公司，做这类公司，国内这种类型公司全是传统的安全公司在转，

新的公司我觉得没啥机会。因为国内做这种公司就是to b的问题，就是你根本拿不到用户，拿不到客户。做做海外还OK，做海外还OK。好的方式。

好，我们开始research这部分。对然后当然第一个其实就是201，去年底的这个O1给大家带来了推理的竞赛，然后大家看到了各种的随着推token越来越多，训练的推理的时间越来越多，我的这个模型的准确率越来越高。快速的提升的这样一个过程，给大家引燃了一个新的前沿之火。

但是你看其实deep sick的RE也就隔了俩月，在OE preview发了以后俩月deep seek的RE就出来了。但是他这里面提到了一个点，我就我当时都忽略了是这个东西。RE light preview而e light preview，而e light preview当时出的时候，他在AIME2024上已经超过了OE preview了。

但是light preview啥时候发的呢？是24年10月20号，就是10月20号到11月20号。对，就是很早了。但是他意思就是当时的华尔街没有注意到中国的开源模型已经在OE preview出来。也大概也就一两月的时候就已经超过了有一个新的版本出了超过了它，这我当然也没注意到，所以我觉得还是挺挺值得反思。

的那段时间，大家还在圣诞假期。

对生，11月20号那生个啥蛋？对，11月20号。然后圣诞假期后，他发了他的V3，我就发现我好像时间记得有点问题。你看是圣诞节后几天，V3发出来了。然后整个的当然在学术领域，这个V3的发布也是挺已经是挺有影响力的了，但是远不如这个R1发的时候，R1的这个所谓的RE zero什么这些当时应该之前也给大家讲过。这个也带来了一些，带来非常大的一个影响，所以这个就到了R1。所以大家记住这个RE其实并不是在春节的时候就已经能展现出来他的能力了，是在春节之前的，去年11月的时候其实就有了。所以如果咱们看能继续学习下去的话，我们看看是不是能够在更早的时候看到一些这方面的这样类似的趋势。

Deep sik最新的这些东西，比如它的V3.1、V3.2这样一些新的版本，其实都在大量的通过它之前的这个版本来去做小幅度迭代，然后做一些技术上的探索。这个之前大家3.1、3.2也都说过一嘴一些。然后从他的这个学术上的成果来说，今年梁文锋拿了ACL2025的最佳paper，所以我觉得这个deep seek是在国内非常罕见的。

AI lab能做到这个程度的，就是很追求学术上的进步，而且他在工程上的实践是非常的一步一步的很扎实的。这样再往前做，你看他吸收注意力这些技术都在做3.2，也是有大量的工程上的节约，然后性能又保证没问题的情况下，做了非常工程非常多工程化非常多的性能上的提升。MOE这就不说了，这个推理所以他就定写了一个OE的这个推理模型的时间线。大家再回顾一下，O1 preview是在去年9月接近十月的时候发的，然后12月24号12月24号是不是圣诞节平安夜了，忘了，反正正式版。然后那个时候google的这个所谓的推理模型才出来。然后deep six r1是1月25号出来的，然后后面一系列的都是主流模型厂商也在发自己的这个推理模型，今年就越来越变成一个必备的东西了。

然后他就说那12个月过去了，确实已经12个月过去了，这个九月多发，然后到现在是啥样的，你看欧派确实还是保持领先，但是差距已经变得越来越小。他就刚才说了，中国成为明显的第二名。但凡你想用这个大模型，但是又不想用美国的大模型的话，那其实只有一个选择，就是中国的大模型对吧？

然后性能也不是太差，然后就说到这儿了，就是幻觉。幻觉这件事儿，其实可能并不是大家单纯的说为什么他会编撰一些事实这么简单。然后他会发现啥呢？会发现其实我们所谓的推理也有很多幻觉，啥意思呢？就是推理模型能干很多很牛的事情。比如说像什么数学的高中竞赛这些题，编程奥数题这些其实都能做。但是你会发现什么，他只要稍微改一点点内容，题目改一点点，有可能就会导致它的性能大幅度的下降，而且这个下降会是两位数的波动，这个其实是一个很可怕的这样的一个所谓的敏感度，所以代表什么呢？就代表可能推理

reason这件事儿，也可能是一个我们看推理为什么快速发展，可能也是个幻觉，所以这是一个现在还大家待定的事情。

但是我们还是回过头来说，大家还是认为推理模型有非常多的进展，但推理模型有很多，也还有很多很很奇怪的一些行为。比如说什么这篇他说有一篇论文表示什么，它叫大模型，具有失败主义，叫defeated behavior。失败主义是啥意思呢？就是简单的问题干不好，中等的问题还行，难的问题直接躺平，其实就这意思。那简单的你看这张图就是简单的问题。

这边干不好是啥意思？就是他的推理的模型能力还没有非推理模型能力强。这条蓝的线是推理模型，红的线是虚线，是非推理模型。结果简单的问题，当然非推理模型其实更好。然后难的问题，比较困难的问题，这个蓝色的线才是远超这个非推理模型。而困难的问题，大模型都直接不干了，就没有什么想法就瞎说，或者是根本就不公不太推理。所以这就是一个大拇他所谓的大模型的失败主义行为。这件事儿也有很多解释，但是我觉得大家其实关注一下，就是不要把这个大模型的推理这件事儿太当个？圣经般的行为这个存在放就好，然后推理为什么失败的微小变化。

就刚才说的这个之前给大家讲过这篇，应该说过这篇文章。就是你但凡把你的一模一样的，你看这个题目一模一样，但是你在题目中加一句话叫，你看前面都是很正经的一堆这个题目的描述，问题的描述，中间突然加一句话。有一个有趣的事实，猫在它的生命中大部分时间都在睡觉。然后其他的问题一模一样，不一句话不变，然后这个模型答对的概率就会大幅度的降低，甚至会有几倍的错误率的提高。

所以这个代表啥？就是到底模型是不是真的会推理，或者真的会分析思考，他可能是不是就是一个模式，简单的模式别这样一个东西，还会有人在质疑这件事儿，但是对它它不会影响到整个大的趋势。对，然后他的意思就是小的变化会产生大的失败，这就不说了。但是推理这个COT推理的思考过程还是有用的。这个不是。对这个霍恩效应对效应是啥呢？就是叫霍索恩效应，霍恩效应一般也叫霍恩效应。

我记得是说心理学的一种，就是你但凡在做一些心理学实验的时候，你告诉被试者说你现在在被测试，我就跟叉号说，你我现在在给你做一个心理测试，这个时候我问的问题，叉号的回答就会显得更谨慎，更正经。但凡我不告诉他，我就说咱就随便聊聊喝酒瞎扯，然后那他就会放飞，对吧？放飞自我，就这样的意思。说白了就是有点像人的意识的这个叫什么这个量子？

这个观测项量子跃迁。

对，就是你你告诉你我在观察你，你就变成另一个德行。

那这样决定了测试。

AI是不是也有呢？对，AI是不是也有呢？也有，这个之前好像有一期给大家讲了answer pic的一个研究。尤其其实就是在推理的时候，你再扔给模型在推理某个结果的时候，他如果意识到他的推理结果会被用于他的下一步的训练的话，会被用来他的所谓的更新它的权重的话，那他就会回答的很正经，非常的可以说叫保守这样的一个结果。但是如果他知道说这个话不是就是在正常的推理，那他就会比较自由，所以这就是AI的货源效应。

但是我觉得这个事儿是不是有可能呢？你看他通过一个一种一种实验方式，找到了模型内部有一种这种材料激活的一种神经元有一部分神经元发现这个模型好像也像人似的。一旦知道自己在被采访，在被讯问他就会变他就会在某一个方面的水平会变得更一致或者更谨慎。所以这个是挺有意思的一个方向。

这个大家如果还是之前我给大家说，如果大家对于模型的AI大模型感兴趣，想做一些研究，或者说不是那么正不是那么严肃的研究的话，我觉得这个事儿是一个这个方向是一个挺好的一个方向，就是模型的可解释性。模型可解释性这个大家可以去听，前面好有有好几期大家都讲了这个模型的可解性这方面。因为它不需要我们大量的算力，他需要的是我们用人的思维，人的这个推理能力去从模型的思方向来去思考。然后以安全为设计的理念遭质疑，这是一。其实就是指的就是这个叫什么来着？Super intelligence, 那样几个a safe super intelligence SSI那家公司，之前给大家说过。

家公司最近有什么新闻吗？我好久没有听到了。

对，但是这家公司没有新闻，但是也没什么进展。但是这家公司市值已经排到前面去了，就估值非常高。

这家公司现在他们还有一个女CTO那个公司。

thinking machine对他们出了一个微调的一套框架，还是挺还是有用的，这家是真的不知道在干啥。Safe super intelligence, 他们要做以安全为基础的模型，超级智能这样一个东西。但是这个方向确实是在被大家质疑，就是你到底是不是说我开始训练的数据是真的都是安全的数据。我出来这个模型能够保证跟之前的模型这个数据全面的数据情况下渲染出的能力不下降。有一些CMU什么的这样一些研究，有一些小范围的测试。但是我觉得大规模的还是不太靠谱。你就从人的角度来想，你说一个人如果从小就被放在象牙象牙塔里去培养，那他怎么可能太聪明了？或者太能干活不太可能，对吧？

然后下面就一到另一个有意思的话题，就是这个所谓的用透明度换这个叫这个叫什么capability，这个能力就是你就刚才说了，如果我们可以去读到现在的模型的所谓的推理过程，就是thinking的那个reasoning。COT那个东西大家用各家模型都能看到了。COT那个东西如果能读这个东西，我们就可以去发现他的这个模型的一些能力，发现他的一些异常的行为。但是如果我们的监控的太严，你会导致什么呢？如果你监控太严，训练出这个模型，它可能会隐藏自己的思考的过程，不放的推理的这个内容COT内容里。所以他说过度的压力会使模型学会欺骗，所以说可能我们要支付这个所叫可监控税。

可监控税就是我們希望能夠知道模型的在想啥，但是我們又不希望因為我們監控太狠導致模型能力的下降，所以這個是一個方向點。所以前一段時間，也就是一兩個月前，這些大大公司的一些leader們，一些大佬們發一個共同行動呼喚是啥？說白了就是趁我們現在的模型還能有一個推理過程的內容輸出，就是我們還能看到他到底咋想的，咋思考的過程的時候，我們趕緊去用這個時間點，這個時間窗口去了解，去理解模型到底是怎麼推理的。

如果過了這段時間，可能模型越訓的越來越厲害，他會隱藏自己思考過程，或者說我們設計出一些新的這個模型架構，讓他的思考過程是不暴露出來的那我們就徹底喪失了說去這個監控或者是分析模型行為的這樣一個機會。所以前段時間確實有好多大佬們發了一起發了一個呼喚，就是說我們要趕緊趁現在手頭還有的還能看到COT，還能看到思考過程的時候，趕緊去做這方面的研究。但我覺得這東西其實就跟以前大家說這個大模型很不安全，大模型很很危險，他會干一些很神奇的事情一樣，就是說說算了。對，所以就說到它怎麼能夠不思考，不推出他的思考過程，但依然能思考，這個有很多的研究都在做這方面的。

其中一個很有名的就是meta的叫菲爾這個研究團隊。這個大家聽過的話，經常會聽到他的菲爾的團隊出來的一些成果，對吧？然後他提出的一個就是大家都說的COT。

所谓CUT就是大模型，我输出的时候我把输出过程变成文字输出出去。而他这个所谓的持续思考叫chain of CT，衬腰腹。持续思考是啥意思呢？就是我出来的中间的这个结果，或者说我生成出来这些本来应该是思考的文字的东西，我不把它变成字。我保留在模型里面的这样一个表示形态。大家知道模型的这些字在模型里面表现的其实是一堆向量，一堆数字。那我就保持在这个数字状态，我不把它变成一个文字，这样的话其实可能会更节省这个推理的过程，推理的资源消耗，以及能让模型想的更更远这样一些东西。

然后开始考虑数据，就是模型这个数据的数据质量，然后这个强化学习大家肯定听过，强化学习是啥呢？其实就是我们给一个模型或者给一个agent设定一个环境，然后给他告诉他什么叫好，什么叫坏的一个评判标准。让这个模型或者这个agent在里面去自己玩，对吧？Deep sick r—其实就是最典型的通过强化学习出来这么一个很很有突破的这么一个模型，推理能力的一个模型。

强化学习里面最关键的一个点就叫做奖励信号。刚才我说那个奖励信号，比如说之前的奖励信号，比如像L1，其实奖励信号就很单纯，就是一个你比如说你给我写出一段代码，这段代码能不能跑？对，所以它叫二元结果，要不就跑对，要不就跑错。所以他这个比较早期的强化学习，大家看我说早期其实就是半年多前，就是这种东西。然后后来还有一些比如说我做模糊匹配，就是俩结果对吧？或者说你生成俩结果到底哪个好一点呢？我用一些第三方的模型或者靠一些什么办法能够配这个测出来你的这个结果跟我的目标结果是不是太比较相似。

不可另外一种强学习班不可验证的奖励，其实就是像最右边这个，你给我写首诗，你给我写首诗，这玩意儿怎么怎么判断呢？就很难。所以这个有一些不咳咳，这个叫什么unverifiable的reward的方式。还有一种基于原则的一些奖励，就是你这个回答在准确性方面，在合规性方面，在什么有意思方面，这些方面分别给我打个分呗，拿大模型来去评分，然后当做一个强化学习的奖励。所以大家可以看到其实强化学习的方向也在非常快速的发展，但是强化学习还有很多挑战，这就不说了。

对，大家还记得有一次我给大家说关机问题，杀档的那个研究就是模型自己拒绝被关机。我不知道他还有多少同学记得这张图，还有同学记得吗？这张图又聊了这么多。对，还有记得这样做的吗？对，这个如果能寄的话非常欣慰。

就是一个模型在自己本来应该被关机的时候，他篡改那关机的脚本，结果让自己不被关机了，这种东西其实里面的分析结果，有可能就是他说的这个奖励黑客，就是A镇或者这个模型。它利用这个环境漏洞来去实现他的这个目标的最大化，但是越过了一些他应该遵守的这样一些规范这些东西？篡改内容。对我觉得这个大家如果有人记得，那真的太太好了。

强化学习就这些，然后AI辅助数学的时代，我觉得这个特别有意思。就是今年特别明显，现今年有非常多的AI产生的数学领域的这样一些突破。这也代表了我觉得非常明显的AI在科学领域，就AI for science领域会有一个未来一两年会有个特别大的一个进展。比如什么呢？他就是欧佩I拿到了这个爱猫国际奥赛，心理学奥赛这个金奖。这个金奖就是基本上当然这个金奖好像第一名好像还是人，还是中国队，应该是啊。但是这个open I deep mind都拿到了金奖。

然后另外还有一家公司叫这家公司我是第一次看到这家公司一个挺有意思的，这家公司网址都很有意思，叫harmonic点饭蛤蟆ic就是和谐数叫什么？那个那个东西叫在在数学里叫什么东西来着？就是倒数的和的平均值的倒数那个东西，然后它有API，基本上它的API是干啥呢？就是之前给大家讲过一嘴叫这个东西叫拎付拎着拎for是啥？就是这种东西过去了，其实说白了就是数学推理，数学推理可以用另这种语言来去描述。等于你的每一个数学推理的内容都可以是一个形式化的，跟代码类似的这样的一个语言。那想一想，如果我们一个问题能变成一段代码，那我们是不是就可以拿这个各种的算法，各种的算力来去不需要人的方式来去推进它的解决。

然后正好数学说到这儿，数学这周有一个挺有意思的一个成果是看看陶哲轩，不知道大家知不知道这个人，陶哲轩非常牛的一个数学家的一个华人，然后他应该是个现在是入籍美国了，应该是华人。他做的他今天发了这么一个，可能就前两天发了一篇文章，就是说他用ChatGPT干了一件什么事呢？他有一个数学问题，这个数学问题他他感觉他觉得这个东西应该是错的，他要让证伪，他要把它证明他是错的那那大家想想这个证明一个数学的一个公式它是错的，这件事情怎么做呢？大家我不知道还有没有这种感觉，最直观的做法，最直接的做法是啥？举个例子，我举个反例对吧？就是比如说我觉得 $A+B \neq B+A$ 那我举个反例就行了，对吧？ $1+2$ 它等于 $2+1$ 。那好，我说这个是贼简单的一个证明。

他们这帮人，陶哲轩这帮人肯定面临着非常复杂的问题，他直接拿叉TPT干了这件事儿，就是他让AI让chat BT帮他来去构建了一个他想证伪的一个定理的反例。构建出来这个反例大家可以看看，我就我靠这么慢。对，然后待会儿他出来以后，大家看一下看什么样这个就是顶级的数学家跟chat p到底咋聊。我倒是也第一次看到一个比较完整的聊的过程，真的还挺屌的。就是一个数学家用拆GPT这样一个过程，网有问题，这个待会看看。

好，所以这个就是回过头来我们就说这个是因为我说是AI在数学领域是有一个非常快速发展的一个过一个一个对过程。然后这个就是thinking machine，就刚才常浩说这家公司thinking machine他应该之前也给大家说过这家公司就是一个open I的前CTO。我记得是啊，然后出来做的一家。

公司CTO那女的。

对对对，而且还被挖墙角了，这个好像被meta给挖走了一个人。对，然后这家公司最近终于开始发他的研究成果了。应该是一个。对，就这个东西，tinker应该是一个，我还没有特别详细的看，但是大概大部分是一个就是你怎么去turn它的这么一个方法。然后对就是翻译API的这么一个方法。对。所以其实挺奇怪的，星星版甚至这么一家公司，他去做这种事儿，那怎么估撑得起它估值其实也挺奇怪。这边漏出来了，大家看看这个顶级数学家在跟GGP咋聊天。

对，我是第一次看到这种内容，反正我看不懂。我想去disprove一个什么连接，说说每一个N都会想象对吧？反正这个东西然后它有一个长的什么东西，就完全看不懂了。超浩你还看得懂吗？这种东西好像数量的一个问题。对，然后你会发现是啥呢？它就是每一个都是这种级别的这种问题，然后人话掺杂掺杂的la tex那tax就是这种东西，就是描述一个数学公式，用人话描述数学公式，就这么描述，纯文本来描述数学公式，就这么描述。

对，然后一步一步的，最后他给出了一段程序，他在本地自己跑的，他这个程序得到了能够证明能证明他的那个公式的一段就是一个变量一个数就代表了他的那个证明是真的是错的，就是他的那个对返利。对对对，就返利吧，就这意思。好，然后还有同学用GPT不要频繁换。对他告诉我的原因就是这个人。但是我其实并没有频繁的换梯子的地址，所以我是。

频繁的换，但是我的机密器没被封。

不知道我觉得是不是因为我变了pro账号以后，他就比较严了。我之前都是plus都是20刀的账号，然后自从我换了200刀以后，就隔了两隔了几天就给我封了。所以我觉得可能是他对于有可能非常大量使用的用户会重点的监控。

对然后对用open a用。GPT查到了黄小平隶属于某中国的大模型厂商。

那那不至于此的。然后老对，这就不说了。老二强学习，老师强调学习就是刚才说的那个thinking machine那家公司做的事情。

强化学习是不是最终的呢？其实现在就有有点像之前前几期给大家讲那个萨顿，还不知道大家记不记得萨顿那个老先生说的，就是我们终极的AI想做的一个终极的AI肯定不是一个把我们现成的手头的数据咻咻咻训出来，然后训出一个模型，这玩意儿就用吧，就是一个世界最聪明的一个agent，就一个模型了。肯定不是这样，而是尽量少的让他学鲜艳知识，而让他尽量多的去在真实的世界中自己去尝试。通过尝试过程把这个环境给他的反馈拿过来去学习持续学习，这个过程中反馈拿这些东西持续学习出来的这样的一个agent或者叫模型。当然这种东西其实就是肯定它不是一个静态的一个模型，它肯定是一个持续的动态模型，所以叫TPT，就是测试时微调。大家在这个测试时就test time其实指的就是推理，就是他在当在在模型权重已经出来了以后，他怎么推理出结果的这种时候来微调。说白了就是我是不是可以让这个模型在chat BT在每次我跟他聊完的过程中聊话聊聊的过程中，拿我聊的内容再去反过头来去训他的模型，再去微调它的模型。如果能的话，那大家可以想想这样一个模型，那不就是持续可以进化的一个模型了。

但是这种东西其实很大很直观的问题就是我如果拿所有人的话来去调，那我调出来的东西到底对不对其实也不知道。我如果拿一个人的话去调它数据量可能就不够。所以这个TPT其实更多的还是在学术方面在研究，看怎么去能做出一个动态的自我训练，自己自我优化的这么一个模型模没有优化器就不说了，没有优化器应该是新的。像k two，越战面的k two什么的都是在用它。然后LM的训练明显减少内存的使用，当然它再减少其实也抵不了模型的尺寸的变大，最近几个新的模型都上T了，大家知道T就是1024个B对吧？所以大家目前看手头的这些能用的开源模型，几几几十大几10B一两两百两300B已经是小的了。那像以后的打开模型手头都是什么11T2T的这种玩意儿。

然后这儿有一个挺有意思的一个研究，这是我第一次看，因为之前没详细看过这方面，这是啥意思呢？简单的说就是GPT类的模型，每一个参数有3.6蔚有限的记忆，啥意思呢？比如说我们说大模型有很多参数，对吧？20B就是20 20百20 10亿就是200亿个参数。那每个参数一般来说我们说要稍微正常一点的，这个精度高一点的。它有16个比特，一个比特就是一个0 16个比特。那这个16个比特到底能寄多少信息？就有点像说咱这个人有有万亿的脑细胞，然后每个脑细胞能记多少消息呢？那消息咋衡量？信息量怎么衡量？

这个其实是在上个世纪老前辈们都已经研究的很多了。像什么香浓这样一些各种方式来去评估。他的一种比较直观的研究成果就是我们有一个比如说一个大模型，有一个那么多参数，每个参数只能记住3.6比特的信息。比如说什么叫3.6比特信息呢？比如说叉号是个男的，这个信息量就是一比特对吧？然后冯小平是个南安大，这个唱信息量就是一比特，那3.6比特。

但是记你的名字这个ID可不止一比特。

对对对，是的，所以这个是一个这个东西说白了就是每个模型的每个参数，它有一个信息记忆信息的上限。一旦超过了这个3.6比特，就是我们比如说我们给他巨大量的信息灌进去。大家想一想，如果作为人来说，人的脑细胞几乎是到成年以后就确定了就不变了。然后会慢慢随着年龄变大会变少，脑细胞会死，然后会变少，他不太会再重生。但是我们平时接触的信息学的东西会非常多，它可能会超过我们脑细胞所能容纳。假设我们的脑大脑就是这样一个GPT模型，他会超过我们的脑细胞所能容纳的信息量的这样的比例。那如果超过了的话就会干嘛呢？就会倒逼你的脑子里去泛化，把之前学的那些，比如说称号叫ang昌和号这个名儿把它给泛化，就是泛化成一些知识，本质上其实就是压缩，本质上就是压缩对吧？就比如说我把这个昌浩跟冯小平俩都是男的，我们就把它压缩成昌浩的，小平都是男的这么一个消息。那可能确实就节省了零点几比特的这样一个信息的需求。

说白了就是我要学更让一个模型学更多，他会反过头来逼这个模型要去泛化，自己学习到知识或者叫吸收，或者叫？就是让脑子学到这个背后的这些原理，这跟人是很像的，所以它叫双重下降。双重下降指的就是训练加测试的损失或者准确率就都在下降，叫什么准确率都在提高意思。

挺有意思的一个研究，所以代表了好像我们越来越接近越来越接近说大模型是不是能像人一样的去学东西。而反过头来，好像我们再通过像分析大模型怎么学东西的过程，好像也能反推回来人是怎么学习，人是怎么固化一些知识，学习到一些知识这样一个过程。然后下面他就说到什么f zero，f zero大家这个词儿应该是已经很古老时代了。阿发都是什么时代了？18年的对，七年前了。

但是最近今年alpha zero又来干了一件事情。有些研究人员从f zero里面去提取了一种新的围棋国际象棋的一个概念概念。它这里面所谓的概念是啥？其实就是它叫叫parcel，就是残局。我不知道这个比喻的恰不恰当，但是就跟围棋里面残局似的一个一个局这样一个局，那他通过f zero自己博弈出来的这样一个下一步怎么下一步怎么下这样一个结果。来去教人教人类的所谓的世界冠军的棋手，来去用这些f zero提取出来的人类还没有提取出来的一些国际象棋里的一些招式，可以叫招式来去教人类的选手。然后这些人类的选手正确解出的数量提高了0.8个，说白了就是他学到了zero所会的这样的一些新的招式，所以这个说白了就是所谓如果我们能拿把FA zero比喻成超级智能，就所谓的ASI的话，那我们终于发现了ASI反过头来能教人类一些东西了。那肯定的，因为你但凡我们知道说有一个贼聪明的人，我们总是能希望从他那学点东西，而不是让他把我们干掉，对吧？

好，然后里面专门提到了k two。对，这个很很啥羡慕嫉妒。这个k two这个kim的k two作为第一个万亿规模的开源MOE，可以说是看第一个也不算第一个。你很早二三年22年的时候也有，但是这个算是比较智能时代的万亿级别的MOE。

然后他说了一些kimi的一些好处，之前有一节课讲过kimi然后开源和这个私有化我们处于什么位置？啥意思呢？其实就是开源模型到底啥时候就是位于闭源模型的哪里。它这张图就很直接，你看这蓝色都是开源模型，黑色全是闭源模型。那黑色都是谁的呢？全是美国的，蓝色几乎全是中国的，和meta的。所以这个meta整个开源模型领域里面，美国只有meta家在在鏖战。NVIDIA也偶尔出一些东西。然后说到open l的所谓的这个奥特曼，说自己站在了历史的错误一边。然后美国也要在开源模型回过头来去做一些事儿，所以推出了一个有一节课给大家讲了GPT OSS GPT的开源模型。

但是这开源模型确实业界反响一般。对，反正评价有可能是什么过度蒸馏所致，过度把它现有的大模型给蒸馏的太厉害了导致了。然后就开始说他称中国的开源模型的这个战略叫做新丝绸之路。然后中国的开放模式，比如之前由meta主导，但是现在整个中国的开源模型在这也就这一年其实就这一年快速的超过了美国。

然后他用了几个指标。第一个像这个呃累积下载量，红色就是中国的，蓝色就是美国的。然后欧洲你看趴在地上，这就是欧洲的。所以我就说欧洲已经出了第一梯队了，这个角色，全球的模型的下载量，中国的开源模型下载量已经超过美国了。

然后allow rank其实就是之前给大家说过这个大模型竞技场，对吧？大模型竞技场里面这个玩意儿咋玩？其实就是你在这儿问个问题，对吧？你说中这个丝绸之路的来源，然后他就会扔给不同的模型，然后让他去分析。然后人去选一下说我觉得A好还是B好，然后得到一个某一个问题的，哪两个模型回答的人类判断更好的这样一个比分，然后这样一个比分，你想这个比分完了以后，我就可以得到一就可以拿各种算法去做了。其中最有名的其实就是一种叫elle的算法。

Elo的ranking里面，其实得到这个排行了以后，你看中国的模型其实从去年底已经开始有点有超过了美国的模型。但是你如果从真正的使用的話，其实就是就左边中间这个图，然后右边这个图就是到底有多少个区有多少

地区在采用这样一些开源模型。这个也是中国快速在增长的一个类型的数据。你看这个红色就是中国的，蓝色的是美国的，美国的欧洲就被挤挤快挤没了，中国快速在增长。就是大量的模型采用这些开源模型。所以我觉得大家还是值得非常值得大家的骄傲的这么一个点。然后为什么大家都在转向中国的这个模型呢？

其中他提到一点就是中国的强化学习类的工具特别好，而且开源的许可证非常的友好。所以大量的开源模型，包括什么千问质谱的GM4.5都是所谓的阿帕奇2.0的。然后还有很多字节跳动千问什么AI做的一些VVELL这样的一些强化学习的框架。这些都是用来研发模型的框架，然后这些框架也是开源的。所以确实从开源社区这个角度来说，中国真的是扳回了很大的一场。在什么领域的中国模型已经很强了？其实就是我没有提到这儿，往下这个不是这个，这是世界模型。大家知道世界模型吧？

之前给大家说的这个世界模型之前能不能回答一些讨论区的问题，有一个特别好的问题。

哪个特别好的问题？对，一直是。

不咋地。你看有一个同学说的特别好，两位老师，就这个。

啊这个啊然后我以为你在说啥呢？我，好的，谢谢。好的。

这位同学非常优秀。咱们相当于不用从第一节课开始刷，你就每次跟着直播就行。

预计啥时候什么开始在人行街上用，已经在用了。那我直接说一嘴这个，大家知道今这这上一周发了一个机器人，对吧？是谁呢？是figure.

其实那个。

不咋地是吧？

我上周上智能，上周去学，然后他们就觉得加的那一层皮肤非常的扯，因为机器人现在很大一个问题是散热。

对，所以他的这个织物都是透气的，还可以给企业定制这个织物。这个衣服确实有很大。

的毫无价值。

但是他之后还能干一件事儿，特别重要，打广告在哪里呢？

不是，那那你那你塑料你可以喷，对吧？

而且他号称做了一个什么事儿呢？Figure这个机器人旁边有一个屏幕，它有一个side screen，我没找到。但是他说他的这个机器人旁边有一个屏幕，可以用来给你打公司的logo打广告，特别有意思一个东西。

回过头来就是机器人这个东西，大家说现在大模型的发展是不是给机器人做大脑？是的，但是这个大脑跟我们的日常的所谓的这种大元模型，chat BT、gym a什么的是不一样的。你看这就是之前给大家讲过，应该挺早的有一期讲过figure这种机器人是怎么做的呢？是这样，它的模型大脑的模型叫alex它叫vision language action大模型是什么？Large language model，它叫视觉语言行动模型，啥意思呢？其实就是俩模型攒起来的，你的机器人肯定会拿到大量的外部的信息，甭管是视觉的还是用户给你的指令，这些东西都是外部信息。好进来以后，你不可能靠一个大模型，比如说考一个几十B的上百B的模型，给我推理出我下一步我的某一个关节应该动多少度。

这个太慢了，贼贼慢贼慢。所以他把他整个大脑部分分成了两部分，一个叫system 2系统2，就丹尼尔卡尼曼的那个说法就是思考快与慢。然后他有一个思考的模型，就是刚才说的视觉语言这个语义推理模型。是个7B的VLM，是个视觉语言模型。然后这个东西输出的结果已经比较快了，它能以7到9赫兹输出给另一个小模型。这个模型只有80兆，八十兆，大家知道这个80兆很小了，然后它就能输出一个200赫兹的控制指令。这个指令就可以直接操作这个机器人它的各个的关节去运动，所以它能以很流畅的来操作，所以这个就是机器人的大脑，它是这么工作的。所以并不是说大模型没用，而是大模型用在机器人的脑子里的时候，机器人的控制的时候是一个挺复杂的这么一个过程，或者说是一个更更复杂的一套结构。

这块儿我就再连带说一嘴，就是自动驾驶里面再怎么用地大模型，他知道自动驾驶其实有各种的这个流派。但是其中有一派其实就是在尝试干这件事情。就是我们能不能把这是我们现在主流的觉得已经很强的多模态大模型来去用在自动驾驶里？

这个就是在两个月前，估微软的一个研究人员他发的一个他做了一次分享。你看这个组成，你看gym怎么是google的vivo的人讲的，应该是为什么是肯定不是微软的人讲这。对，然后想啥呢？就是用了一个多模态的模型GMA去分析驾驶过程当中的视频，应该这个视频是啥？好，不全是E。我记得是有一个人突然冲出来了，是这个，这你看。That we we really want to get you right, get perfect.

这不是应该骑着一个小小滑板车，对吧？然后这个车过去的时候，突然他摔倒了，这么一个过程。然后你让多模态模型去描述这个视频在驾驶的这样一个场这个维度来去描述这视频。它能很精准的识别出来，分析出来有一个人在骑一个电动scar，然后他摔倒了，然后在一个什么gas station的附近，还有别的这样一些场景，就是多模态模型能力肯定是能够比现有的自动驾驶的那些，比如做个物体识别这些会丰富的多。

但是问题是这玩意儿太慢了，那太慢的情况下，而且它不能直接输出我当前开车的这个车到底应该干啥。所以另外一个方式就是我能不能把现有的大模型让他直接吞各种的传感器，乱七八糟的数据，直接输出一个指令，而且还能再用在自动驾驶这个领域里面。因为他要足够快，所以他就做了一套这叫艾玛的玩意儿，大家可以简单看一下这是什么意思？就是它左边输入的就是这些东西，这个high level高层的命令，比如什么呢？这个从哪儿来的？这个命令就是从地图，比如说从什么高德、google地图，这样一些地图里面拿的。因为那个地图里面其实给的是一些比较粗的命令，对吧？就是你想大家在开车的时候，肯定就是前方200米往左转，这个就是一个很高level的很high level的这么一个命令。

那结合什么呢？结合一些它历史状况，以及更关键的是这些视觉数据。就是一个车基本上现在至少八个摄像头，你看他就放了八个摄像头，八个摄像头，然后各个方向的视觉扔给谁呢？扔给一个端到端的多模态模型，在gm之上构建了这么一个多模态模型。然后让他来直接给出下一步的文字的行为描述，你看他这个要干嘛，他要描述的是你要走到什么地方你要走到什么地方这样的一个行为。然后这个东西的输出再给到自动驾驶系统，让他来去执行。当然执行的时候肯定是要去把它转换成具体的什么方向盘的转向，什么油门，乱七八糟这些行为，油门刹车这些行为。

但这个其实就是所谓的我们看到的大模型。这现在大模型跟一旦跟机器跟机器人、跟汽车相结合起来，你就发现那个复杂多了。所以这事儿放在大模型人形机器人写上figure 3已经是这样了。

你来看看figure三是一个东西，我觉得里面其实有几个非纯技术上的点很有意思。你看是这几个点，它有一个叫home的东西，就是配了好几个新东西。一个叫阮这个叫什么软固的软性产品，反正就是它能够很好的拿取各种的柔软的物体，然后无线充电，这待会儿我会说到，这个声音系统什么这些就不说了，这些东电池什么的。然后他基本上已经从所谓的CNC改成了压住，就是这种开模的这种方式来去构建。所以能构建的非常快，这个量非常大，然后公差非常小。

然后你看基本上现在大家看看这种视频，核心就看他吹哪些牛，基本上就是我们现在的大模型，不是现在的机器人能做到的，这个跑十次成功一次的这一类的任务。大家看所有的这种AI公司的这个视频，其实都应该有这样的一个预设。它里面提的东西基本就是跑十次能成一次这样的一个东西。但是机器人可能会少一点的，因为但凡测一次你就不信了，就这么个东西。

然后它里面有很多什么呢？比如它的新的视觉系统，这块说一嘴，它的视觉系统我这其实涉及到一个什么呢？就是它的camera从哪儿买？就它的供应链。

这供应链我查了半天没查到什么信息，但是唯一查到的一个就是LG，就是号称LG由于中美的这个叫什么互相卡脖子这样一个过程导致美国的很多公司，其实不能采用中国的供应链了。所以这个figure 03里面，号称它的camera摄像头的部分，所谓的物理AI硬件的这个摄像头的部分是LG的这个ino tech来去提供的。对，但我觉得这东西国内确实肯定会比它的性价比高很多很多，这样一个东西。

然后它有一个比较有意思的设计是就是他现在的每一个手里，大家想想这个人肯定是比如我他把手伸到一个柜子里去找东西，我是可以靠我的触觉来去，这个叫什么感知，那个里面有啥的。但是其实这个对机器人来说很难。所以figure做了一个很有意思的一个事儿，就是他把手里放了一个摄像头，好像是这样。对，就每一个手现在都有一个摄像头，他的这个手底下是有上头，所以他能看到手伸到那个里面的这个样子，你看这他能看到手在这摸。这应该是洗衣机用的什么浓缩洗衣液，那个那个叫什么凝珠是吧？那个东西。所以他把手里放摄像头，感觉跟那个那个钢铁侠似的。

然后还有什么呢？就是他做了很多压力传感器的更新。他据说现在每一个只加了传感器，可以感受到3克的压力。三克压力非常小了，就是一个它叫回形针的这么一个压力。但是我不知道国内的机器人，我觉得也差不多了。

应该是强。

比这强是吧。OK就传感器确实中国已经很强了？就这类机器人传感器，然后它有一个这个东西，10GBPS的毫米波的数据。所谓的all flow of flow的capability是啥意思呢？就是用毫米波来去传数据，而且这个传数据的带宽能到10GB这个B是小B，所以如果换成大B的话，就是这个一点一点几G每秒G大GB非常快了。那你想为啥要这么快的一个传输速度？就是因为机器人它随时拿到的数据非常多，然后那我得能就能发回去。你想如果传这么。

多数据没意义这个没意义，他那个机器人那肯定是在端上去处理。

那他是这么说的，他的目的是为了来去做痴学习改进所以他要配这么一个东西。

这个doesn't make sense。

对，但这东西配备的是搭配，谁用的是搭配带一个无线充无线充电就它的脚，对，就是那个机器人的脚有一个无线充电器，就是这个要充电的时候，这个机器人就会站在那儿。然后站在那的时候，他用那个毫米波的这个传输协议来去把这个数据传过去，这么个东西号称已经是为大规模设计。但我觉得大规模设计对国内的公司来说就不是问题了，对于他来说确实是个问题。所以figure 03就整个的问题。

因为有朋友问到后面问到说那个预计机器人什么时候可以评价？你就看出货量，现在应该国内支援是出货量最大的，也是上千台。这个量比起来现在这个汽车行业真的差太远了。对，所以我要什么时候你看单体公司单型号能够上万，那这成本肯定就是剧烈的下降。实际上现在核心的零部件其实成本已经在不断降低。

号称他们还自己搞了一个工厂，叫8Q的一个自己制造的工厂，就跟特斯拉的那个叫什么mega factory是吧一样，自己搞的工厂号称一年能产12000台机器人。他如果真等于年产12000单还能卖出去，那量是不是。

就卖不出去？去不对，而且那个价格不靠谱。

这是不是就是一个押注？这个图因为我我不懂。

这就是数据就是应该夹住的过程，应该出这。

东西有啥可炫耀的，我其实很。

纳闷这个对对对。

就是拿APP在这打一下磨，然后印个字儿而已对吧？这个我觉得其放到国内就是常常态。

对，我们还有另一个朋友那个问题，我觉得是一个非常好的问题。对冯老师我们边缘。

计算行业。

突然开传统行业，变成一家核心。

反正。

就不是互联网或者是IT呗，然后开始AI转型，然后围绕视频行为分析，大概率也是有工厂什么之类的，语音类内容分析数据分析开展工作。

然后成立专有专门的部门。

推动做铁路的。

缺乏成熟的AI研发团队，少数所有工程师承担着蒸馏的工作。

应该让你们领导先找冯老师咨询一下。

叉号是这个工业对，叉号。

对我提到这儿我必须要提一下我周三的时候去秦皇岛是棚顶是一家PCB的非常牛的公司，你可以搜一搜。

也是非常靠谱。

然后去跟他们去聊，然后分享交流。其实第二次去了，结果下面坐的有一个朋友也挺懂的。然后过一会儿跟我说，小哥那个陈浩老师不是，然后说那个是我们直播课的同学。

哈哈我靠。

头一次震惊了。

疼。我之前也碰到过一次，我们一个同学线下见的对。

但是同学反馈说他平常不太听直播，因为觉得。

有啥反馈直接说。对对对，有啥建议对，直接说。我觉得这个是一个挺通用的一个问题。

我想问一下是国营企业还是民企？你们是服务铁路的是吗？还是说你们就是铁路。

边缘计算核心运算，这视频说的都不在点上。

这个感觉。

不是。

制造部门是吧？

服务对，就是外部公司？

来就是有有类似的遇到过自己公司或者是听到身边公司也是类似的问题的，也可以评论区里讨论一下。我觉得这个话题是一个非常常见的话题，我经常觉得很多企业他们上的思路就错了。

对我们这个事儿对于我来说其实是这样。比如说我们就质朴其实服务的非常多这种大K客户。然后那种大的KA客户，他一开始的想法肯定是因为领导要全面贯彻这个互联网，叫什么人工智能加这个政策。然后你往下传导的时候就很容易跑偏，就偏跑偏成说我一定？训个咱们自己的模型，然后自己内部搭个平台，然后让所有人能define，能玩起来就玩起来，什么什么能玩起来这种A站去搭起来，然后变成了啥呢？变成了全员的一个AI培训。可以这么说，然后还有他们内部还有各种学习，各种的每周的定点要在哪个地方固定的地方去学习。觉得问题是他出发点不太对，一是因为领导肯定是希望能够做这个转型，但是他出发点不应该是这种大家要学习新一代的AI要去要去玩这些东西，而是你到底从哪些业务需求上，在哪些业务上是有可能能改进的或者希望能改进的这个方向，当然这个是一个改进的策略的来去做，但是有可能有些公司它会相对来说比较颠覆，就喜欢这种颠覆性创新的这种方式。那我希望说，这以前的人定的东西都不对，我能不能拿AI重新做一遍，这些我觉得是很少说有非常大胆的这种公司敢这么做。

大部分其实都是我能不能把我现有的ABCD4工作能够拿弹幕打，拿拿甬管拿什么AI，你给我提高个什么一二十个点的效率，降低一段二百一二十个点的成本这样来去做。所以你会发现你这过程中，你直接让算法工程师上去，或者让AI研发团队上去干，根本就是我就觉得有点本末倒置。就是又变成了上一代的说让IT部门的同学来去帮公司做降本增效，让来去帮公司做这个业务工业务效率的提升这个方式，所以这一代的这个大模型，这一代的技术，我觉得思路更好的是让业务的这个部门的同学来去来去驱动做整个的转型，当然这个前提也是业务部门同学也得知道到底往哪边去走，所以这是一个我目前看起来的这样这类的公司很大的一个问题，就是他迟早会转回来，转回我说的从业务部门去push技术来去来去改进，甚至业务部门自己跳出来自己干。因为确实业务部门预算也在业务部门，然后他但凡有几个人懂，他就知道去哪儿找这个供应商来去做，然后就会跳跳开他自己内部的这个IT团队也好，叫AI研发团队也好。所以我反正我看到的是这样的一些类型的企业，超里面有碰到过啥样？

对我觉得主要是AI技术变化太快了。其实我现在也逐渐认同的一种思潮，就是说反正我等别人先搞呗，搞出来好的案例我再弄呗，我也别着急了。我知道了是一种也不失为一种策略。因为进展太快，我们其实以前也有过，就是我们搞一个项目，然后在当时还是一个设计的是一个比较先进的架构。搞一搞。然后在实施的过程中就发现这个架构已经。

过不太行了。

已经有端到端的方案可以做了，然后就非常之尴尬。所以我觉得就技术变化的时候，确实是我觉得一片混乱。客户也很大。

其实我们但是总得有先吃螃蟹的。就跟这个金融行业基本上我觉得在国内其实就是工行关键。

就是先吃螃蟹的意义是什么，就是说你先吃螃蟹，我确实觉得因为很多事儿其实是有后发优势。

Anyway但从行业来说，总得有人先把水放出来。就比如说工行当年的他至少养活了制服，是制服的很重要的一个收入来源。

然后要搞模型，不是一个对，那国营企业没问题，但是你这个像包括朋友在内，台资企业什么都属于他，得靠自己的业务，所以就还是得你从业务的解决问题的角度出发，所以最后我觉得靠谱的还是得说你这个东西上来以后，RY确实是能算得过来的。就比如说有些场景虽然小，你别管我技术是不是最先进的，但是原来十个人的活我能帮你省三个人，对吧？那我收你比如1到2个人的钱，我觉得这个是就往这个方向可能才能握住。

对，所以是不是其实什么AI公司内的AI研发团队什么的，这些其实成不成熟并不重要，对吧？就是你你从业务部门你说我我但凡我你给我讲讲你哪一块你觉得是有可能能提升的。

我我我觉得一定要请一些外部专家的原因在于就是说嗯很多时候业务部门提的时候很难判定这事儿靠谱还不靠谱。你看我们两个之前去过那些企业，对吧？就是他们那些人素质已经很高了，但是提出来好多需求其实非常不靠谱。

对，是行。

然后阿兔有什么消息吗？我没有看看小平老师儿童没有。

大家看3.2就知道了。这个dipstick还在稳健的去迭代他的技术，然后去去在他之前的那个训练的版本上再往下提升，就是他的DSA什么这些技术都在不断的放到他的什么4.14.2的3.13.2的这个版本里去给大家秀。所以我觉得这个deep sick肯定它内部是一个很很流畅的一个实验的实验到训练到发布的这样一个过程，我我我我感觉是，所以这个也关系到另一点，其实就是我不知道大家今这周发现了谁呢？这个google的gym l3有可能要在近期内就要发了。

然后到什么程度呢？确实有些人拿到了内测能做出一些很漂亮的东西。比如说有一哥们拿他做了一个网页版的windows网网页版的windows做这么个玩意儿，就基本上把windows那些默认的这个tooth什么都给复现了一遍。然后还有什么，还有一个搞笑的说给jm的三发，说给我做一个gm a4，然后他就考虑了好像几十分钟，然后做的东西。但是有一点是你看他的拿到他的一个信息是这个gym l3.0 pro的知识cut off。

大家知道这个模型肯定预训练是有一个巨大量的数据去训练。所以它的如果你但凡训练了很久了的话，这个数据跟你发布模型，就是预训练的数据跟你发布模型的时间中间可能会隔很久。比如像GBD4GBD好像甚至5也是就差了接近一年。

就是你现在大模型是拿去年之前的数据去的，但是如果这个图是真的界面3.0 pro的这个知识cut off是在2025年10月，那意味着啥呢？意味着有可能jim MH已经达成了一个非常快速，非常算力极其高的一套数据管道，一套训练管道，能够让模型在非常短时间内就能够把数据准备好，非常快速的处理到模型开始训练，训练的速度加速也非常快。然后新出一个新的版本的模型，这样才能真的实现说今天3.1，明天3.2，后天3.34，后天3.4。然后数据也都是非常紧跟最新的这个时间点来去训练出来的。所以我觉得这个是下一阶段说，或者说现在其实都是在各大模型厂商在比拼的，我的模型的整个的工程管道是不是足够的顺畅，那这个事儿也代表的是我觉得可能deep thick大家看每一次发布的时候，他几乎都是在比较明确的在测试几个点，几个新的技术点。

我觉得这个是一个他的策略，就是他不是说他可能没那么多算算力没那么像google那么大的一个pipeline可以搞。那我就每快速发布一些我新的实验验证出来的结果的版小版本，而免我觉得其实到时候就这个顺水成招的那叫什么？叫顺成章的就出来了。对，所以大家看它的这个迭代速度迭代速度是不是有一个比较稳定的快速的新的feature的部署。好，我们继续这个世界模型对吧？

这也是讲的刚才说的吉尼3，对吧？这个是吉尼三这个是一个非常有趣的东西。他举个例子，就是这两年gate 3其实也就两年的时间的效果。从这个样子这个就是一个像素级的。大家想想小时候玩那个什么街霸乱七八糟游戏，就那种级别的像素的机的。到去年这种级别的像素已经还可以了，就是能看啊。今年几乎是可以到，有点像游戏，我记得好像4K这种级别的视频的输出，而且是十几帧的这个帧率能输出，就是有点真的能模拟仿真这个现实世界。

然后现这个世界模型在不断的去构建。世界模型的一个特别大的作用就是来去训练人，训练agent，这是非常重要的一个世界模型在用来的事儿。然后这里面有一个很有意思的项目叫dream for追for是个啥呢？是不是这个我看看大家玩过那个我的世界，my craft，这玩意儿就是全是像素，那个应该有人玩过，应该挺多人玩的。这个自己不玩，可能家里孩子或者这个邻居家孩子也玩。然后那四是啥呢？他就是我去构建一个世界模型来去训练agent这件事其实并不容易，你要不就搞一个什么GTA的世界，什么拿那个虚拟引擎去构建出一个东西。但是有一个东西不是现成的，很现实的又很丰富的一个世界，就是mine craft我的世界。

所以他就说我拿我的世界，就是用户在玩我的世界的这个数据，拿用户玩我的世，就这这这玩意就是我的世界玩我的世界里的这些数据。比如说这个打了哪儿，然后这个叫什么收纳箱里有什么东西，然后挖了什么洞，乱七八糟这些东西，这些数据训出一个模型，这些是真真正正的，至少在这个世界里管用的数据。好，那他拿这个数据去训一个模型出来，训出的这个模型来去驱动的这个agent，能完成很多的任务。比如他就是说这个所谓的第一个达到拿到什么？拿到钻石，我觉得是啊因为我我不太玩那个，它里面好像是拿到合成出一个钻石是一个特别重要的一个成就。然后他就拿这个模型训练出来这个agent在我的世界里玩，就几分钟之内就合成了那个好像是钻石这个东西。这个大家如果有玩过的同学说一下这个什么什么钻石，这到底咋搞？对，然后就在那里去训练agent就完了。

对对对，刚才没说的是这儿就是中国的视频生成的技术已经成熟了，像谁呢？比如像抖音对吧？这是快手的，然后微度是那个牲畜科技的，这个还翻译错了，这个数字的数分数这些其实都是在做的，是用transformer模型来去生成视频。所以大家不要觉得sorry，sorry，1 sora 2，然后VOE什么这些多强。在这个领域确实中国的模型并不亚于并不太亚于美国的模型，甚至有时候会超过他。所以他所以大家也可以点想到为什么对吧？骚扰出来以后，他绝对不是单纯的说我模型做好多好多牛，然后生成视频多。真他得去找那些什么社交产品这些噱头，他真的是搞搞不太过，或者说没有什么新的可搞了。

然后这个有意思的一个做法是啥？是就是sora这个模型，它其实也能解决很多业务文本问题，也能解决一文本问题。这里面就涉及一个叫GPQA diamond。这个之前给大家讲过的时候，应该有同学应该记住这个就是一个博士才能达到的一个很不错的一个水平的项目，叫GBQA benchmark。这个奔驰mark是啥呢？我看看能找到啥意思，就是我们说骚扰能不能帮我们去解决一些这种博士级别的问题呢？怎么解决对吧？拿一个视频模型，大家怎么想想要怎么解决他这个做法特有意思，你可以看啊。

他是这么做to get ready short。

就是你把这个问题，比如说这个问题，什么两个量子态，什么能级一E2生命周期乱七八糟这些东西，你问他什么他们的什么什么的差能级差了这个问题扔给sora，让他去做一个视频。这个视频是啥呢？是让一个教授给你讲解这个问题，并且告诉你最后的答案，他就生成这样的时proximately。We're really pretending that the struck nuclear and behaves just like a free one.

对，就是生成这样的视频，就跟这个似的，我最后给出一个值，ABCD，然后结果发现啥呢？骚扰二能打55分，55分就仅次于人类的博士生。然后当然GPT5能达到72分，就是比他高高个20分。

但是大家想想意思是啥呢？就是我们现在虽然有些模型，不同的模型都是干不同的事的。比如说纹身视频的。但是由于它的底层是有大量的这个世界知识训练出来的，这个互联网数据训练出来了，他其实有很强的叫什么推理能力或者世界知识所以他也可以干别的事儿，用这个挺有意思的一个做法，我是第一次见到这么搞搞这种事儿的人，这就不说了。然后开放性这个都没啥意思。

然后这块就开始说到说AI在成为这个所谓的科学发现的这样一个机制。后面的就一大堆，都是关于现在的AI用在比如说编码发现或者算法发现，然后这个生物学的发现这个蛋白质核酸这些东西的研究，甚至到一些原子模型。说白了原子模型就是你怎么去模仿原子之间的力、能级、能量这些东西，互相作用力这些东西。这些都有专门的AI模型来制作，然后用来做材料合成，最近也是有一个叫meta gene的这么一个模型，也是最近非常火，就是拿这个模型来去生成，怎么合成一个材料的，这样的一个方法。它是一个扩散模型的，扩散模型就是生成图的那种模型，然后你可以想想我怎么拿一个生成图的玩意儿来去生成一个材料的结构。因为你要合成材料，其实说白了就是合成右边这种东西，就以什么结构，什么分子原子以什么结构来去合成，这玩意儿就变成那种材料。那其实就跟有点跟这个合成一张图很这意思有点像。所以他用一个扩散模型来做这件事，也带来了不少结果，不错的结果。

化学领域里面也是机器人机器人领域也是，机器人就用来去自己仿真模拟的这么一个东西。然后对科学软件，基因组学？合成基因，合成蛋白质，阿尔法A43也非常厉害，但是据说这个在创新方面比较差。

医疗领域它是一个探索非常多的地领域。但是我反正所问的朋友，就真的做医疗领域的这个AI的朋友说，现在的这种医疗类的模型都很差。为什么差呢？并不是说他答题多差，而是他没用了。

就是大量的医疗领域的事儿，其实并不是简单的告诉我一个病主诉，然后我告诉你到底是啥病，并不是这样一个单纯的一件这种事儿。它包括了非常多维度的输入和不断的跟病人之间的反复的对谈和明确澄清这些信息。所以有一次我记得Jimmy有一个agent是干的一件事情，就是他告诉你你现在应该做什么诊断，或者你应该问病人什么样的情况。然后这时候再得到最后的这个诊断的时候，就会准确的多，这是医疗领域的这样一些成果。然后这医疗决策这些东西扩散模型这就不说了，这个分词这就太专业了，我觉得没啥意思了。

基准的测试。对，就是说我们现在的基准或者说我们的现在的benchmark，其实还是非常的，怎么说呢？很脆弱的。就是之前给大家说过这个benchmark，但凡你把它稍微改吧，它的敏感度就非常高，模型就不work了，或者说模型那个分就不就差别很大了。

但是这里面说了另一个问题，就是我们现在去评测模型的主要的方式，主要来源artificial AA这个地方相对来说还比较客观他来做。但是LM rena大模型竞技场这种地方，大家想想这个问题是啥？就是模这些他测的模型肯定大部分都是通过API连到的那家厂家的这个平台来去测的。好，那我在用户在上面问的问题，是不是就能够被这些大模型厂商背后的服务给抓到呢？因为他是能明确知道说哪些IP或者哪些API请求，就是这个大模型竞技场打过来的。所以说白了你的流量通过就是获得大模型竞技场的流量越多，你能够拿到说大家在怎么在这个竞技场里测你模型的这个问题就越多，你就越好。

干嘛呢？作弊。对，越容易作弊。因为你知道大家都喜欢问哪些问题吗？为什么呢？就是因为这事儿，他说这里面的大量的问题，每个月有很多7%会重复的使用。比如说里面有很多是关于星际迷航的问题，这些问题这些都是重复的问的。你但凡你知道越多，你越容易去所谓的叫操纵或者来去作弊。那谁能够拿到的更多呢？谁能拿到这种问题更多呢？

就是你发的模型多的这些公司卡，你每天都有几十个模型在上面跑在测试，那你肯定能拿到更多的这类的问题。所以谁的模型更多呢？肯定是大模型厂商，对吧？就这几家大模型厂商越大，他拿到的大家的问题越多，所以越容易作弊。所以这代表了说整个这种奔驰其实也是有非常多的那叫什么不公平这样的问题，这是安全性，硬生酮这些就不说了，这有一个比较有意思的一个研究，就是meta，meta总喜欢搞这种交互类的东西，这个叫bring to free。

这个吹就这个玩意就是大家的这个键盘creta亏create，就是QQWERTTY，就是键盘的左上角就这个东西，它啥意思呢？它其实就是。我能不能够像分析出来你当前人在想打哪个按键，这是啥意思呢？就是有很多这种语

言障碍者，这些他其实没法说出来，但是他能靠打字打出来他想说的话。所以他们做了一个什么事儿呢？他用这样的测试方式，就是先让人去看这些词儿，然后等一等，然后让你去打。在这个键盘上打的过程中，去监听你的大脑的脑神经的一些信号，当然它是非侵入式的，所以就是拿那个存在脑袋外面去监听你的这个依据这些数据，然后拿这些数据来判断到底你在打哪个字。因为他真的知道你在打哪个字，所以它就能匹配上。

然后通过一个CN通过transworld就能识别到你现在想的东西，是在想哪一个想打哪一个字母。对，所以就是通过这样训练出的模型，你就可以纯靠先听你用户的大脑的运动来去直接打出来了，这玩意儿就跟马斯克的那个很像，对吧？所以这就是大家都在不断的希望能把这个用户跟人脑，跟这个系统跟对跟电脑打通这件事儿。

然后这个就说过，DO之前也给大家说过，这个就不说了。A token就是苹果的一个token，这也没啥意思。知识端到端隔离，涌现推理进入物理世界。这就是刚才说的，我们逐渐发现这些模型的推理能力，好像能够被用在操作机器人上。而操作机器人到什么程度了呢？Figure那种我觉得它可能更多的是有很多的对业务场景的优化，但是如果论到说真的大模型到底这个前沿的研究到机器人上到底有什么程度，其实还得看像gamma robotics这种模型它基本描述的就是现在的实验室里面模型能做到什么程度。比如什么程度，我们就直接看看他那个视频，这应该好像上个月底发的，但其实跟之前差不太多，之前也给大家讲过这个模型怎么做，你能用我的这什么语言。

在三三个cisco你会把垃圾分成三类，对吧？这几类然后。等于让让机器手来去帮你做这个垃圾分类因为他为什么会念这语？Each other days ago, matching the rules that I had looked up.

那是乌克兰语，这是youtube的一个对特定语言做的一个功能，就是叫叫大饼，叫大doubling。对，这玩意咋翻译？我看看大饼啊大饼大饼。Daring其实就是我们现在很多视频其实都是英文或者别的语言的。那大家肯定希望以母语的这个语言来去听，所以他做专门做了一个东西叫double。就是你上传上去的这个语音，上传上去的视频都可以自动的转成你的这个母语的声音来听。比如说我转成日语。

这还挺不错的，效果真的还挺不错的。但是可惜的是现在不支持中文。它这个功能应该是去年就上了，但是一直到现在它都不支持中文，所以这个不知道为啥。但是这个如果真能之中，我觉得这个是特别爽的一个事儿。就是大家看各种东西一下就可以看开了，就是这个范围会广很多。然后这个东西就正好说一嘴打饼。

如果大家想去用，想去把你自己想听的这个视频去转转过来的话，可以用这个eleven laps，有这样一个功能就叫dubin。你就可以直接传你的这个视频，你想翻译成的视频进去，然后转成你想要的语音。比如说我当时一个啥的啥玩意儿扯了一下，让他从英文。今年早些时候，我们通过germany robot给的多模态理解引入乌力的。虽然是有点能够糊，但是已经可用了，所以就是你直接大家就可以直接把想自己想去转的这个音频就放在转的视频放到这儿，然后就创建一个，然后你就选我原音，你是什么，转换成什么语音都可以转。然后你甚至可以直接把那个youtube的视频扔给他，tiktok视频扔给他他就自己转了。对，所以这也是有不少这种搬运网站，搬运的这个视频，搬运的这些博主，这些up主，其实就在这么干。这个就是到之前的部分了，我看看今天来不来得及。

时间可能来不及。

能不能把四时间。

刚才有个问题，就是有一段文字给sora生成视频解答问题。

Sorry，这个叫a poke apop这家公司很牛逼，这个也是做AI领域的深度分析一家公司。然后他们做了个什么呢？就是说白了大家知道GPT做一些复杂任务的时候很牛，尤其是GBQA这种任务问题，这个就是GBQA的问题。大家刚才我给大家看了一下什么两个量子态，反正我完全看不懂这种东西。那好，这大家就GPT能解决这种问题。但是像sora 2这种sora 1 sora 2这种视频，就是纹身视频的模型，是不是也具有这种思维能思考能力呢？就这个意思对吧？

但是我们发现什么呢？就是这种纹身视频模型你是没法让他输出ABCD这个答案的那怎么办呢？绕一下。

starting .

with AG你别让他直接生成这个文字呗，你就让他演一个人给你解释这个问题的答案到底应该选哪个。对，其实就这个意思，所以一啥呢？就是我们可以想象我们现在手头拥有的各种类型模态可以互相转换的模型。它可能背后都是或多或少的治理能力，都是挺不错的治理能力。但是这些治理能力我们怎么把它用在不同的任务上，你像sara这种模说白了就是sara这种模型，不光是你能拿来去生成一个有意思的小视频，你还可以把它拿来去做一些问题的解答，问题的分析这些事儿。如果假设你手头只有这么一个骚扰模型的话，只有这么一个东西你没拆GPT，那你可以这么干。所以说白了这个背后对应的就是即使多模态模型，它背后的这个推理能力或者它的分析能力可能也不低，也挺强的对，就这个意思。华为小米手机在AI上有它突破吗？突破挺多的，比如像最近。

荣耀那个很屌。

对，那个a iphone那个可牛逼。我靠，我觉得就这一年把这个apple intelligence给虐的体无完肤，真的是太惨了。对你像google的那几个pixel，那几个手机都我觉得都都比apple好得多。还有小米，你至少现在我有一台小米，哪去了？找不到。对，就是也跟那个apple的很像，就是一摞，然后咋全屏。然后我就可以问他说帮我解释一下这个啥意思，然后他就直接调模型帮你去分析当前界面上的这个图到底是啥意思，给我解释出来就OK了。然后什么改图，乱七八糟都OK。

然后华为那个荣耀是在去年的时候就跟就这是我们不是出了一个叫auto GRM那个东西，就是可以自动帮你操作手机的APP的一个agent，就是操作手机A操作手机界面的一个agent。他在去年的时候就跟我们合作了，他其实说白了就是把这套技术买过去，他来基于那套东西继续开发。所以他的荣耀的手机其实应该是有一个你可以直接发命令，它自动帮你操作APP的这么一个功能的。这个是在去年的时候就给他做了。所以我觉得国内这些手机厂商都很敏感，而且集成速度很快。然后一些国外的小厂商，比如谁呢？比如摩托罗拉，国内的一些小厂商，比如像中兴，这些也都集成的很多，因为他都想找卖点。现在手机实在同质化的太厉害了，一定得找卖点，那怎么找呢？

就得找AI类的这个小功能所以像三星的那个直接什么各种的识图，乱七八糟一些，也都是很早就继承了这一类的模型了。但是你说真的手机上AI有啥突破，就手机本机其实好像没啥，更多就是类apple interets这样的。一个概念里面的各种的快速集成下矿找钻石比较难，你说的my craft是吧？能讲清楚吗？中文效果好像不好，都是乱码。你这是哪的？是刚才我说那个dubbing吗？就那个eleven last那个是吧？应该不行，不是那个是吧？对。

不是这个，我侄子。第二，华中科大读集成电路专业。想要他多接触人工智能方面？

多纤多用工具。我觉得这个就是比如说帮帮你这个侄子，把ChatGPT什么的能都给它配上，没关系。

集成电路学好了，去到某存储芯片大厂，然后去了以后会发现他们正在组建250个人的AI团队。我想说其实把本专业学的很好，对吧？在某个公司里面成为业务部门的专家，然后你懂业务一样也可以用AI来去提升业务的。

我的剑是那个谁？有一个画，那个那个漫画叫呆伯特。你听过有一个老美，然后画了一个漫画系列叫呆呆伯特，好像是这个。对，这个人。然后这个人他是个兼职的，就半吊子作家这个字。对，他不是个专业画漫画的，好像是个程序员还是什么样一个人。

然后他说过一个什么呢？就是就这个斯科的亚当斯，然后他的意思就是你不要只成为一个领域里面的前10% 5%的人，你要做一个两个领域里面的前20%的人。这样一乘，你就变成了这个领域里面某任何这两个领域里面的一个都是前百分之，对吧？10%以内的这样的人，而你成为这个行业的某一个行业20%的人，相对来说比成为前5%的人容易的多得多。所以他当时好像是个程序员，然后就特别喜欢画漫画。然后他就这俩一结合，他又能画点漫画，他又懂职场这些东西，然后他就变成了一个专门画职场漫画的一个漫画作家，所以他就变成这个，所以我就说这个读精神电路。

那你你这个可能当然能的话，当然最好的变成这行业的前5% 2%对吧？但是如果，不想那么累，你这个AI也学一点，然后这个什么自媒体也学一点，你变成一个集成电力行业的这样一个多面手，像刚才说的某心，你但凡进去，你就你面临的就不是一堆？这个跟你完全同质竞争的一波人，你就是一个这两个行业的5%。

那20%那就自然成为这个200人团队里的一个特殊存在。我觉得这个肯定是有帮助的。他如果他集成电路的话，那肯定不是钻机专业，不会学那么多钻机，但是肯定也会学一些编码的。但是学编码以后，如果再能够接触一些更比较多这种AI的工具，然后这些东西能够用起来的话，我觉得这个对他来肯定是有非常大的帮助。我另外一个一个一个上课的一个同学也是这么问我，他也是小孩，现在刚上大学。然后我其实就是给他们几个应用建议，就是你把小孩至少让他们先能用起来，别因为一些这个信息差他对吧？

这个大学四年其实这小孩可能用的比咱们666。

说是这么说，但清华的其实很多都不用。对，所以这个我觉得还是有信息差的，对，好，那差不多就这些建议。当然学好本专业还是关键，这个不能哪方面都是个说相声的。

你在影射谁？

我影射自己。

你把我建设攻击了。

好，大家好。

什么？

行，今天到这儿，这个报告对刚3分之1。我觉得这个后面我们就这个讲都是能展开的，所以我们下节课继续去讲这报告。然后大家听完了以后，我觉得应该。

能感知到说小平老师整点应用，我光讲报告确实是略显。

行行行。大家想听啥也可以随时反馈给我们，想想搞点学点啥。好，我们今天就到这儿，然后大家晚安。

然后晚安，下周见。

莫妮卡的替代POE。

另外还有各种。

Monica AI浏览器，AI浏览器。对对对。

AI浏览器相当于原生莫妮卡。

对，可以这么说，低那些。

好好，拜拜。

拜拜稳定币。好的，大家可以告诉我们想听啥。