

Hello hello, 大家晚上好。大家晚上好，稍等，我共享一下屏幕。

大家晚上好啊。大家还是跟之前一样，大家有什么问题随时发到群里面，然后大家有什么想聊的就随时发。好，还那个我屏幕共享能看到的是吧，屏幕共享能看到的是吧，能看的帮我扣一下，扣一下一喂。可以，好的，上次还记得吧？那我们就开始聊上赛季这篇报告，三百多页的报告，这个state for AAI report。然后我们今天继续往后讲一点，然后不会讲太多，所以大家不用担心这个太太难了什么这些东西肯定是讲一些还我觉得还是比较有意思，而且值得大家记住的东西。

大家没有发现我今天戴小米的这个破眼镜，小米的这个AI眼镜带了几天了，因为他还是有点用的，这个待会儿给大家说还是有点用的。但是因为我的这个近视度数太高，所以这个其实不是很友好。而且尤其是小米这个眼镜，它其实对标的是这个，大家都知道，肯定知道这个对标的是meta的这个跟ribon合作那款眼镜，其实对标的是一个墨镜，所以你看它的这个边缘什么的都还是挺粗的，所以整个的重量其实不轻，所以导致带一天也还挺累的。但值得称赞的是它的电就是功耗做的还不错，基本上能用一天，还是OK的。所以但是其实我还是不是那么建议大家去买，因为这个看大家需求了，里面有一些功能还是有一些场景有用。

比如说大家如果这个反正说的就先说说，但如果有没有这个平时会要跟老外平时接触的比较大的，就是说英文的地方比较大的，然后自己英文又不是很好的这种，不知道咱们群里有没有？对，如果有的话，其实可这个倒是还是有点用。但是它其实本身的问题是什么呢？就是它没有显示，它不像上次给大家说那个meta那个新的display那个眼镜，它有显示，所以你可以直接让他们看到那个字幕，这个眼镜其实就是一个纯音频，就是加上一个摄像头，加摄像头，所以它能实现的同传延时还是不错，延迟还是不错的。就比如说你听一个，因为这个还真没法给大家演示，他来了，hello. 对，还要跟大家说我这个小米的AI眼镜，用了几天，用了几天试一下。然后有那个没有新的那几个，我拿一下，我拿一下那几个新的，然后我给大家说一下，稍等一下。

对，反正最近一直在看各种眼镜。其实你看这个先从最老的开始看吧。这个玩意儿是荧幕的，叫air two。这是你买的，你个人买的还是你公司买的？这个荧幕给的测试机OK。

对，然后你看这个边缘，就跟小米这个比一下，可以，能看到吗？我摘了眼镜啥都看不见。对，可以看到。这个厚度比较就是小米这个已经很粗了，这个边缘已经很粗了。粗到什么程度呢？大家可以看跟iphone的比较是这样，它基本上是两个iphone的厚度，一个半对这样的一个厚度，而且重量挺重的，所以其实就已经挺厚了。但是这个现在戴着舒服，这个还凑合。

还有一个好处是这样的对，你看他这个有一个设计还是挺不错的。因为基本上现在这种新的眼镜都这样设计。这个就是往外掰，它其实是一个设计出，就是我我不知道这个机械结构叫啥，就是它给你预留出来了往外掰的空间，你可以这样表达，想让脸大的人用都得这样。对对对，而且还行，不是最佳，所以整个这个力度就还设计还不错。

然后这个是我给大家说一下，这个是上一代的眼镜。基本上就是大家可以想象去年的这一代的，去年那一波可视的。你看大家可以看这个眼镜的，这可能看不太清，它是有那个光波导图层的，两边都有，而且是从顶到底就是贯穿式的这样的一个光波导图层。从顶到底这个是去年的这种设计，所以基本这个是一个安卓眼镜。对，这个安卓眼镜，所以你可以在里面跑各种的安卓程序，就是APK只要稍微正常一点，APK都可以直接在里面跑。所以这玩意儿功耗贼差，就是叫什么续航贼差，功耗挺高的。但是大家想想，你在这么一个眼镜，你能跑一个安卓，其实也还不错。

今年你可以看看这个，这是rocket的那个rocket glass，杭州那家公司，就是他跟那个暴龙合作的那一款。大家可以看到，就是rocky跟暴龙，是暴龙吗？还是谁？暴龙对暴龙合作了一块，这个其实是一个操作系统，这个其实就是到今年的比较新的AI眼镜，这个叫什么梯队了。然后这个时候你大家看这个可能看不清。可能还有

一点，就大家看那个反光的时候的那个有彩色反光，那个时候那个就是它的光波导的那个图层，光波导图层这个时候他大家可能看不清，待会给大家指一下它的图层在哪。

有这儿有就是上面和中间，上面和中间分两块，他分了两部分，这儿和中间。对，那大家怎么看到的这个影儿呢？其实就是看看他的光机在哪儿。我不知道大家能不能听到声音，反正对应该是能。对，在中间可以在这儿可以看到它有光机，它会不照到这个图层上，再反射到眼睛里，这样你就看到那个一样了。所以这就是今年的这个就已经比刚才那个轻特别多了。

这个基本上就几十克。然后日常佩戴是OK的，而且里面的应用做的挺不错的，说实话挺不错的，就比较实用。对，其中有一个特别好的一个点是他做这种定向麦克风。就是你比如说带着它然后去做翻译，实时做翻译，然后就能实时看那个文字。

但是你比如说你要跟别人聊的时候，同时有好几个人在同时在聊，那你不可能看到不可能。你说你看个字幕是旁边右边那个人，后面那个人说的话，所以他还做了个定向麦克风。这样的话他只收或者说他只把那个拨动计算前面的部分的这个人说的话，然后给你做翻译。所以但是他这个需求会让你长期佩戴，主要的点在于就是这些功能，这些功能挺OK的。但是你觉得对你来讲，值不值得去把自己的日常眼镜换成这种？

对我用了几天小米这个东西以后，我发现啥呢？就是因为这个没有显示，所以我现在目前发现的能吸引我的功能点是啥？是这个功能，小爱同学帮我拍一下这顿饭。对，我不知道大家有没有看到我那个眼镜的这儿，那个灯在亮，他其实就是拍了张照，然后他。对，就是它会去拍照，自动的发现拍照。然后它现在还会多轮对话，我就把它关掉了，停止。

对，然后他就会把你的这顿饭给拍下来，然后它有一个APP来自动的分析你这顿饭的这个叫什么这个卡路里值。所以大家可以看到它里面有这么一个东西这么一个东西，这么一个APP，它就是根据我每次录下来的这个拍下来我每顿饭的这个信息，然后给我算出卡路里值。当然我发现这卡路里值它会有很多预设，比如说我就拍一杯星巴克，它就会给我识别出多少来着，三百多卡吧。

但其实我我喝的是美式，所以他其实那个那个卡路里是不对的，所以这个是有问题。但是你找跟他说，帮我记一下这顿饭，这是一杯美式，然后他就会能分辨出来，他能纠正过来说这玩意是的，好像是三卡百万，没事，反而很低，也能做到这一点。所以至少目前来说，我觉得它语音拍照确实还是比较吸引我的这样一个功能点。

因为确实很多场景是不适合去，或者说不方便拿出手机去去拍的。包括说记一下，比如说帮拍张照，记一下我车停哪儿了，然后他就会拍张照，然后把那个停车位的那个编号给我这个反正至少拍下来，然后回过头可以问对，所以还行。他拍完之后，你后面是可以问答的，是吧？对，有一个memory，拍照必须说不一定。他这有一个按钮，在这个上面有一个机械按钮，然后按一下拍张照，然后长按一下就录像。所以他其实做了一个叫小爱记忆的这么个东西。小爱记忆的这么个东西其实说白了就是你去问那些什么东西来着，拍一下车停哪儿了，然后记一下我的护照在床头柜儿什么这些东西，然后你可以去查说我车停哪儿了这样一些东西，所以就还行，所以至少是可行的。然后另外一个我还没试，就是看一下支付，说白了就是用这个说话的，用那个声纹识别来去。

他调的是跟支付宝合作的，所以最近支付宝这个方向做的非常快，就比微信快多了。大家也感觉到了什么碰一碰支付，然后支付宝的A镇支付其实也很早就出来了。然后最近的支付宝的跟各家AI眼镜厂商的合作也是非常快的。所以大家我觉得支付宝最近做的还是这个发就是叫什么这个冲的还是挺猛的。

这方面的东西，眼镜大家可以看看这个，然后刚才是这个rocket glass，rocket glass是这个样子。然后还有一个是前两天萤幕阴这个阴阴mall，这个看的比较清楚一点，这个光波导进那个图层的，这样也能看到。对，我发现了这个角度，这个角度大家就可以看到那个国模岛图层的那个位置了，对吧？然后这个是这个位置，最古老的那个这个都看不见。

对，然后这个是小米为什么不做一个带光波导的眼镜？会有的，我觉得小米的逻辑完全是很多定义是在供应链里。对，就是光波导之前也好像几期前跟大家说了，基本上现在华强北那边的光波导的眼镜在大5 600以上，5 600六七百这个量级的快要批量出货了，快要能批量出货了。

所以对于小米来说，它的最稳妥的办法是什么呢？其实就是看看目前现在市面上什么AI眼镜是能卖的上量的。我就做那个，而且等什么呢？等下一步，谁要不就是谁能验证这条路这样能卖得通要不就是整个供应链已经足够成熟了，整个出货量足够大，然后成本也足够低，他能去试一试。所以要不就是等出来谁的戴显示的眼镜OK了，能卖出去，比如说几十万台了，那他的跟进，因为meta的ribon上一代眼镜卖了好像也大几十万台，应该上百。

我就很好奇这种难道说创新的人不能用类似专利什么的保护自己吗？你这样搞的话，这个巨头真的是无敌。那你拥有客群，拥有供应链的绝对的优势，对吧？我看谁做的还OK关注度高，我就抄一份就完了，是就无敌了，所以真无敌。

对你说小米，大家虽然觉得这个我个人也是这样想，我觉得小米挺好的，它是作为这个时代的数码产品的优衣库还是什么来着？Muji对对对，他要做这个数码时代的muji，然后那那确实东西都价格OK，然后性价比挺高的，挺好的做的。但是他在这个供应链的垄断上确实做的非常狠。就是他几乎大家知道肯定这样，这个几乎不给供应商留什么利润空间这样一些东西，然后整个下手也非常的狠，是吧？所以这个没辙，我觉得中国就得就是会卷成这个样子。对，所以大家如果对于硬件感兴趣的话，或者对于这种智能设备感兴趣的话，大家可以发一发。

比如说想去了解哪类的设备，然后了解哪类的硬件的好坏什么的，都可以去聊一聊。因为我觉得这方面可能未来半年一年肯定会有一些可能可以爆发的品。大家如果家里有娃的话，肯定估计会感兴趣那种AI陪伴类的那种小硬件。

就是像那个那个叫什么零宇宙，像那个卢卡博士，然后火火兔。那卢卡现在卖的好吗？我很好奇的。不错的对，卢卡确实挺不错的。质质朴跟卢卡合作的，这个也不太合作，反正就是有一个有个战略。

卢卡是他以前的读读绘本的对吧？对他以前有读绘本的，后来还出了好多什么拍照的相机，就是那种AI相机，然后那个是零。对，对，就是小孩带的那个那个那个是你就出货量是比较大的是吧？可能量不大，但是卢卡的那个湘AI相机出货量挺大的，因为可能还挺贵的。卢卡那个相机才三四百，我记得是啊可怜那一千多，那那两个倒是我都买了，我觉得反馈是什么呢？是可怜的那个确实好，可怜那个确实好啊，这个功能体验工业设计都好很多。但是用户量少，我估计是挺少的对，可能那个还是太贵了。

Pad看有人问proud了，大家说了好多次了，我这个pad我那个no pin在桌上我就不拿了。那个pro就那么几款，pro的也进国内了，所以这个proud进了吗？现在国内能买了吗？能可以，他有国内版本的了。他大家在抖音上都能搜到炮的那个直播在卖，你这个不就是这这不还是海外的吗？对，这是海外的，它有国内的的中国。

正式进入中国市场这个是上上个月，还是上个。对，然后他主要进的就是这个no pro，其实就是这款就是拍的这个手机后面的这一款，它的中国的中国的官网在哪儿？US是不是点这个点不开。later.

进了，肯定进了。大家看好，直接开抖音看的都都不怕看到我抖音在看啥，你可别说，我跟你，我没事。Plot proud。他的那个你这边看京东，如果他进肯定是京东上会有，有道理。直播了，对比巷一号链接有他内容已经交代内容落到实处的去告诉你大家就这个你的一个是场景对吧？大家在直播里看直播是可以做到市场。

然后pro的这个设备，它现在有月费吗？行业的朋友都可以去使用到。有肯定有啊，但是我没买过那个，所以我不知道他接的啥。模型我们现在还像以前一样达到1000了，两个自己的这样一个大脑，可能是对很可能是在未来我们公但是他的月费应该不便宜，因为我们的思维是有限的，我们的这他估计别的都没有太大变化，所以就改了。像模型那个时代之下，大势所趋在未来，这是就是要用千问豆包就能去辅助我们国内这些硬件厂商肯定都是渣的很，对吧？全都用多维度的。然后谁给的便宜又属于你自己的好奇。他的月费，他在国内的定价，包括你有任何不懂的问题，你可以去问他，直接可以辅助你群里问一下的。

我们今天来到直播间的朋友有订阅。对我是给到大家一个12991个价格。因为我现在是刚刚上市，我的正常价格不是1299哦啊大家看到了小平老师的抖音号叫小平瞎啄，只有现在你来直播间才是一个会变价格。

这是会员，会员能够领那个优惠券，339一年1000最贵的这个不限时的是1000两个名额可以养你。这那这个还是比那个国际版便宜不少，同步的你领到我们的这样一个优惠券，我看看国际版掉了，往下看有什么区别。只要你除了时间之外，已经是我们标准版的会员了。我们标准版的会员还可以收费的。可以，3391年就可以。你想要升，对，3391年是还OK的。然后它国际版我看看去升级到我们的一个专业版。

这个你看按年订阅的话，像我们的这个会员，像他会员按年订阅的话是20到1个月，20到1个月。所以如果按照。20到1个月1半一半。对，这是两百多刀。

然后对对，但是大家发现这种用这种产品很大的一个问题是什么呢？就是你就比如说我用那个no pin，no pin我一天都带着，我一天都带着时间是多少呢？我会大概录466到8个小时。然后你填的这个数据其实就没法直接怼到那个免费版里去，你就得花钱。所以其实这类的产品我觉得订阅是必要的，不然的话你就拿了一大堆录音，那其实就是录音笔，录音笔其实有便宜的多的这个选择。

对，借了一千多对不对？GPT没神回来，这个open I都不回。我这个mail真的是真的是我记住。

然后我搜了一下，很多这种被叫什么deactivate的这些用户都都没人理。就是他的客服部分就是看some support部分几乎是零，所以我跟对我我跟那个OKA的客户交流过，他那个agent还蛮厉害的。啥意思？你是说我该用过他的客服？对，对，就是说我我我刚好说到这个，我觉得OKA的自己的客户还是非常之靠谱的。然后一就是A的跟你聊聊完之后，他最后告诉你说这个问题可能我需要引入那个人了，然后就把那个人又导进去，哪有客服对。

你是可以留言的，没有AEI，有啊，我应该是在platform里面没有。对，platform跟大家知道这个platform跟这个chat BT其实是两个东西。它的账号当然如果你全封一封的话，那是两边都同时封。但是在GPT里面交钱，跟API的平台交钱，你说你还能用了吗？我换了个账号。对我用一个新注册了一个小金库，所以真的是烦死了。对对，交200刀的那个版本。所以大家如果用pro的话，真的小心一点，因为这个pro账号肯定是会盯的更严的，就是你如果真交那200的话，还是要更严的。好，我们聊这么多这玩意儿，然后我们来看今天，这个state VI我们待会儿再说。

这个其实就先说一就说其中一个就是。这在前两个月的时候，郭哥开大会的时候，goole IO的时候，他说他每个月的token处理量是多少？480个TT480个T如果我们除以30的话，就16个T每天对吧？16个T每天也就是

多少来着？1万16万亿对吧？是应该是6万亿。对，16万亿。那我们对比一下看这个字节前两天披露的是啥，豆包模型的日均token是30万亿，所以如果这个数字没错的话，当然那个时间还是有点差的。

豆包这是10月16号，也就是上周公布的，然后google IO的那个应该是应该可能有俩月了这样的一个时间，所以已经是它的两倍的话，那我觉得中国的这个只能说明中国的AI的使用量是非常大的。而且你像gym line里面的一个使用量，其实也有很多是中国的出海的用户来去做的。所以我觉得这方面还非常值得去。大家觉得中国做应用很厉害，对，这写一画一下。

大家知道诺贝尔奖发完了以后，大家就有人统计说到底有多少公司获得诺贝尔奖。你发现什么呢？第一是谁？大家知道看到了这个还知道就贝尔实验室，对吧？这个贝尔实验室可能现在年轻同学都都不知道这个东西了。然后当年简直就是圣地一般。

然后第二名其实就是google，当然把这几个加起来，google d my的google量子，这几个加起来以后，那现就是已经是获得第二届诺贝尔奖的公司，然后是这个IBM，然后一些什么其他的一些机构。所以这个啊但是我记得前两天咱们这个杨振宁院士去世了，然后在学校里面还看到有一一整个走廊给他给给他献花，所以这个是谁说的？说我再过几年，中国的整个的诺贝尔奖就会迎来井喷的时刻。我觉得大家可以期待一下，然后谁要获奖，啥没听见，谁要获得贝尔奖了。

我说井喷是指哪些？古代的研究其实很多，当然非计算机一年就是几个人，怎么算井喷？对，一年就几个人。对，井喷就是可能A出来两三个，那咱就那我觉得按现在的趋势都是a size，我觉得AF size领域里感觉现在还是美国更强。对，这个是我们下项目来看这个号不要看，这个号大家不要封，这个是一个反贼，但是他这个反贼发了个中国的新闻，国内新闻。但我不知道前面看没看到，就是说，有一个22年的一个网络攻击事件，就是美国用某境外品牌手机短信漏洞，然后攻击中国的。

这个授时中心，授时中心啥意思呢？其实就是给各个系统同步时间的，因为咱们现在这种各种系统其实都需要时间同步，其中最重要的一个东西其实就是证书。比如说你访问一个网页的时候，如果比如说你的这个系统时间不对，很有可能有一些网页你是访问不到的。因为他你的证书是没法跟他互相认证的，所以授时中心是很重要的一个机构。所以当时报出来时候，二是有一个攻击，然后这个底下就不说了。

但是这东这攻击到底是啥呢？然后你就发现他其实有其实很早就有人分析这个东西，报出来这个东西，谁报出来呢？这个又是一个暴露年龄公司。卡巴斯基昌浩用过吗？咱们班群里有谁用过卡巴斯基？那你还记得当年的瑞星吗？对还记得江民吗？我操你真的是越说越老。

对，卡巴斯基。然后卡巴斯基当时的一个在二三年的时候做了这种攻击的这样的一个分享。这玩意儿叫，有朋友说他现在还在用卡巴斯基，我真是卡巴斯了。360的30卡巴斯基确实很强。真的，卡巴斯基的当年还有那个卖咖啡，麦咖啡。对，麦咖啡卖咖啡也挺挺不错的对，但是大家看这个攻击的这个是在某一次安全会议上的一个分享。你可以看出卡巴斯基在在安全方面还依然是非常强的这样的一个角色。你看他干嘛呢？

当时做了一个分享，就是叫Operation什么regulation，就是三角攻击这么一个东西。这个攻击其实就是对应的咱们央视发的这一次攻击，就是某境外手机的一个漏洞。从这里面你基本上能看到比较详细的内容。这个具体技术就不给大家说了，大家看一下这个东西，它里面用了三十多个零件漏洞零的漏洞就是市面上还没有补上漏洞，也这个原厂也不知道的漏洞。这个是有有一个市场的，就是有一个地下市场，就是你可以在这里面去花很多钱去买到一个还没有被提交给厂商的一个漏洞。因为你要提交厂商，厂商会给你点钱的，但是如果你不提高厂商，你的地下市场世界卖的话，市场卖了的话那个钱就更多。那这叫三角运算，什么三角形运算什么的这样一个行动。咋做呢？

你看第一条攻击者发送一个恶意的air message，那大家知道这是什么？所谓的某境外手机是谁了，对吧？那就是苹果呗。然后这个应用程序会处理这个附件，并不向用户暴露任何的迹象，这个漏洞是什么呢？其实就是IMS的这个软件收到了这个附件以后，它不会给用户展示任何的这样一个的变化。但是它会因为一个漏洞，所以把这个附件的一部分给执行了。然后它有个漏洞，反正就是可以允许这个远程的攻击者去在你的这个message这里面，这个进程里面去执行代码，这个就是第一个所谓的零倍，我觉得一看就是个feature，根本就不是个漏洞，这就是一个预留的必须好吧。后面有一个号可能是苹果流的东西，后面说到了这个，我觉得这显然也是个feature。你特定的那个在特定的字段里面加这个东西，能够在软件层面执行。

比如说你收到了一个短信，然后这个短信如果你不看的时候，他大家想想，如果我就只存在我的数据库里，那其实没有办法做一些比较复杂功能。比如说如果我做了一个AI工具，我就读别人给我发的短信，然后我先自动的生成一个可能对这个短信的回复，然后等用户打开的时候，他就直接能看到，对吧？那如果是这种功能的话，那我就需要预先读取这个短信的内容。但是这个短信内容万一有一个附件，那我就要去处理这个附件。这个附件我处理的时候，可能这个处理用的代码就有漏洞，我就让他什么内存溢出什么的，导致我他就可以放一些可执行代码在里面，这个还是正常。但是因为这个是也是个零类漏洞，就是当时是没有人知道这个漏洞。

然后他说从90年代就有，所以我当时觉得我操真牛逼，然后他会用到一些东西来去来去执行，然后执行的结果是让GS能够被吊起来，就是可以在这个程序里去执行GS大家知道GS就是打网页上所有的网页里面执行这些程序都其实都是JS写的。然后这个JS，其实有非常多，一个一万多行代码。然后所谓的混淆，其实就是人不太看得懂，他就这么一段代码就被执行起来了。然后这段代码，就开始去各种的尝试往下攻击。

尝试往下攻击。你看它基本上会这个漏洞支持，所有的新款旧款的iphone都支持。然后他又用到了另一个零件漏洞零带，对吧？又用到另一个00代漏洞能干嘛呢？可以让这个程序获得整个物理设备的物理内存的读写访问。

这个其实大家如果卷机器的同学就很清楚了。就是比如说你玩个愤怒小鸟，结果愤怒小鸟可以读你你你的这个密码，你存在这个手机里的密码。因为这些密码肯定都是存在一些比较关键的东西，都是存在你的内存里的。而内存其实有这个互相防护的，就是程序和程序之间是不应该能够访问到互相内存的。结果用了这么一个漏洞可以直接访问了。那大家可以想想，到这儿为止，就是从一条短信的代码一直现在可以直接访问到用户的手机的内存了。到这儿了对吧？

然后到这儿他用到了一个内存的映射来去绕过了所谓的这一个保护层，可以直接访问更底层的这样一些API。所以他利用到了这些漏洞以后，这个时候他那个一万多行的JS代码就可以直接掉最底层的这个手机的各种API了，包括什么运行这个间谍软件，乱七八糟的。但是他做了这些事儿，一个是啊他启动了一个进程来去擦，把他这个屁股擦干净，就是把之前干的事儿的那些程序给擦掉。

在不可见的模式下用safari，大家知道下发瑞浏览器，然后打开另一个网页，然后那个网页里有啥呢？那个网页里面又用了另一个suffer的漏洞，执行了一个short code。Share code其实就是一种能够攻击很底层的操作系统层面的这样的一种代码的统称。对。然后这个shall code又用了一些漏洞，内核级的漏洞。这个时候基本上这个漏洞就已经获得了最底层的就是苹果手机的root权限。还可以这么说，最底层的权限这个时候他想干啥就干啥了，你是几乎不可能发现的。所以这个分享其实到这儿了以后，他就把整个的攻击链给大家呈现出来了。

然后就到了苹果的这个部分。他就说他他想讨论的是另一个二三年暴露出来的这样一个漏洞。这个漏洞是号称是因为比如说iphone，它其实大家都说它安全，确实他做的还比较挺，安全性还是挺强的。它在这个内存的内核内存的敏感区，它的内存里面会存非常多的敏感信息。在敏感区又增加了一个基于硬件的安全防护，这个防护可以防止黑客和攻击者去读写一些内存。但是他发现这个攻击绕过了这个防护，而且他是干嘛？他是用到了

苹果设计的SOC，就是苹果手机的这个芯片，用到了这个芯片的另一个硬件特征，这个硬件特征说白了就是一个可以绕过现有的安全防护，直接把数据写到特定地址，特定的物理地址的这么一个能力。

这个东西然后就很奇怪，就是你想想如果你是个做手机的一个操系统的一个人，你怎么会去设计一个有一个可以直接写特定物理地址，往特定物理地址写数据的这么一个接口的。这个接口就不正常，这个接口就不应该被设计出来。所以他们的猜测是这个玩意儿可能是苹果的工程师或者工厂用来调试测试的时候被添加在里面的。但是这个东西在具体的开发的时候，内核在在固件中没有用，但是留在那儿了。所以当时他们就说，那这个可能是苹果本身的自己的安全的设计的时候就留在这儿的这样一个问题，被这帮人用到了。

但是关键是这个非常底层的接口，谁能碰到谁能知道。那很有可能想象其实就是，就是有一些安全部门的人去知道这个东西。所以后面有一些人在猜测，就说一个零件漏洞其实挺贵的，就几十万刀，就咱对吧？如果大家有朋友是做安全的，然后你说这个安全是没有市面上没有公司知道的这么一个安全漏洞的话，基本上你可以想象他立刻如果这个安全漏洞还比较大的话，立刻身价就能提个几百万。就是非常贵的这种漏洞。那大家想用了四五个漏洞，应该是四个零的漏洞，那至少花了几百万刀来干这个事儿。

所以，就大家记得二三年那个时候，21年22年的时候，就有很多这种央国企，公务员就要求不能用苹果手机包括现在基本上我们去像一些扬过去的地方，基本上都不可苹果设备是打不进去的，从电脑手表到手机都进不去的。所以这个事儿我觉得确实也是。当然苹果一方面它有很多的好的点，但是也保不准它跟安全部门合作。然后你看当时说这一点，就是说怎么发现的这个漏洞是卡巴斯基的员工发现，自己内部有几个手机被攻击了。然后这几个手机，跟有一些外部的网站发生了异常流量，然后就开始回去发现分析这几个手机是在被攻击的，所以这个时候才把这个漏洞挖出来。所以如果大家他意思就是说，如果当时没有攻击卡巴斯基的人，那很有可能这个漏洞还在，这是一个非常可怕的事儿。

然后说卡巴斯基把漏洞提交给苹果以后，苹果并没有按惯例给他们奖金。然后后来全美进了卡巴斯基，这个当然可能不是因为这个，这个好像是二三年、24年，就全美的所有的商业公司都禁用卡巴斯基了。所以。肯定是后面也是有一些猫腻的。

这个点对，所以这个挺有意思的事。古早软件对吧？MC和360在考，还有人要MC这个R是不是快了？又是R对吧？R对达成这个deep sik OCR这个东西可以看出确实是DPC做很多事是还是挺挺硬的，挺挺结实的。所以大家不要可能咱们也不用那么纠结说啥时候出来这些这个R2，我们看着他的很多新的进展，其实也都对咱们是有帮助的。卡巴斯基卡帕斯的最新分享，我们待会儿再去看啊。

然后先看看我说了无数遍这个词儿，AGI对吧？AGI到底啥是AGI？终于有一帮人开始定义了，UC伯克利的一帮人，他定义的开始尝试定义AGI是什么？这个底下内容不用看，其实我们就看一下这个摘要其实就行了。

啥呢？它定义的是AGI是一个受过良好教育的成年人，然后的认知灵活，然后熟练度高这么的这么一个定义。然后它构建的是一个叫卡尔霍顿，什么卡特尔卡特尔霍顿卡罗尔理论，这我还真没仔细看过。对，所以这个下次可以分享。这个理论是一个比较久经考验的这么一个认知理论。

然后通过根据这个认知理论的话，我们来去评估各家大模型的所谓达到AGI的水平的程度。然后直接他的结论是什么呢？GB4是27分，gbt 5 58分对吧？都都不及格，但是58分已经很接近及格了。所以我们第一次看到说，相对来说比较学术类的方式，能看到怎么定义一个AGR了。但是我觉得这个商业意义不大了，就是在工业领域意义不大。大家只是知道说AGI好像有人去给他定义了。

好，然后下面就是到模型领域，模型领域的这个AI基础设施，我觉得有几个挺有意思的东西。这个人还是这个人，大家还记得上次我给大家有一次讲deep CV3.1的时候。我记得是3.1的时候，什么UE8M0的时候，就提

到这个人的computer king, computer king这个人。他最近有一个回顾，他也来回顾一年一度的回顾，也没有一年一个回顾。

这是很早的时候他一篇文章，就是说他不断的分析给大家分析说这些AI领域里面的这些半导体行业这些核心公司，到底哪一家有什么样的本领，哪一家有什么本领。然后分析了一大堆这些公司，然后我当时看这个列表，我想的是啥呢？到底哪些公司现在还没有暴涨？你看broken，然后marvel，对吧？这个AMD什么这些实心电子这有些就不知道了，所以我当时就很直接就这么做了一下。当然我不知道大家用不用Monica，这个Monica我是买了他会员的，所以还是得用用。

直接就是我就说一句说分析这个帖子里的公司，搜索哪些公司今年股价还没有暴涨。对吧？然后就OK了，我们待会儿等等他的这个分析。

然后其中有一个是谁呢？是好像是我看看mobile。对，大家知道mobile是做这个通信的，就是他做很多这种AI的设备之间的通信。当然也不是说AI了，其实就是做很多这种通讯设备，边缘网络这些东西。

所以这家公司其实在大规模的数据中心里面，其实还是有非常多的机会。对这个回答不好，这个还不如之前那个GP5，所以我怀疑他给我包的是错包的是假的GPT5。对，anyway, 反正就是大家给大家提个思路。其实就是你看到很多这帮人去分析，然后你也不一定完全照单全收，可以用现在很多这种deep的东西来去尝试去去分析一下。比如说什么呢？我们直接拿到拿这个，我们直接扔给靠帮我分析一下公司哪些经。还没有股价暴涨。我最近确实发现cloud比chat BD好用多，自从我被chat b封了以后，就开始转向号了。

好，然后这个是这个，然后下期我们讲讲量子芯片，量就是量子计算，这个流量计算还是有挺多挺有意思的地方。好，对长浩突然有事了，那我们继续讲。大家有啥问题可以随时发RR2，对不对？而且这个大家不急，然后我们就来看这个DPCKOCR这个模型。

然后大家知道OCR是啥吧？就所谓的这个光学识别，光学字符，反正就是说白了就是从图里面抽抽字儿，这意思，所以这叫OCR。这个是一个非常古老的一类技术了。这个可能在上古时代就是那种什么那个叫什么来着？汉王那个时代就已经有很多做OCR类的这样一个算法了。所以大家就不要觉得OCR对吧？OCR大家知道是什么一点，然后OCR这个领域到底哪个模型最强？

现在看起来也不是刚发的deep sik是谁呢？两个，一个是paddle，OCR paddle大家这个名儿一定要知道，这是百度的paddle什么什么奖来着？对，然后paid to ZRVR，你看用了VR基本上就可以认定它是用了一个视觉语言模型来去做的，所以这个性能确实是挺不错的，这样一个水平。所以大家如果比如说公司内有一大堆这种文档，然后这种图表要去分析的话，这个大家如果真的用，那确实它也是不错的一个选择，它是一个目前最好的选择。

然后另一个我不知道大家能不能猜到，另一家谁的OCR最做的最牛，而且是当前的sota级别的，大部分的好几个方向都是搜索级别的，是这个这是谁呢？这大家能认识认出来的，dots OCR、小红书、red note。对，小红书到note现在的这个大词模型是OCR里面的基本上是最强的。你看它很多的领域基本都是最高的一个分对比这些像这个Jimmy的五什么这些都会强很多。所以如果纯论OCR的话，真的是不一定要选deep seek。

但是deep c为什么这波这么火呢？就是这么几个东西，先大家看一下这个，对，他说先看一下这个文章。DPC和OCR基本上我们就看它的r cp上的文章。R cp文章大家也可以尽量不要去看那个PDF，直接大家就看它的这个网页版就好了。它叫DPC或CR，然后它的副标题叫也不叫副标题，叫上下文光学压缩这样一个概念。这概念是啥呢？待会儿大家就可以看到这个意思。

他先说了一下目前现在市面上的各种的OCR模型的这样一个做法，这个就很偏技术了，就先不讲，我们直接看看他到底大概干了啥，从这张图比较清楚，对就可以干啥呢？输入最开始的输入是一篇，你可以看出来这是篇论文，对吧？但是是这篇论文的图片，它把它变成了一大堆啥呢？

变成一大堆N个16乘16的patch，叫什么patch或者PP，就是补丁什么这样的一个东西，一般都要patch，说白了就是把这个玩意儿切成一大堆小块。切成一大堆小块以后，走这么大一个块的东西，这么一块的东西是什么？是叫deep encoder，deepen coder？因为deep sick，所以它的什么玩意儿都叫deep什么的東西。

Encoder就是编码器，它本质在干嘛呢？就干的是把你的这些小块的图片变成一个token。大家知道token就是一个向量这样一个东西。向量其实就是比如说这个五个数，那就是有五个数，一个向量三维就是三个数这样一个向量。然后把它变成一个一堆向量，一堆token扔给一个大模型。这个模型其实也不大，DC3B才这么小的一个模型，3B也是个MOE，所以这个激活只有500多个million，就这么大的一个模型。

同时当然它也会收一个prom，但是prom的用处就是告诉他到底你要去识别啥。比如说你把这个框就可能是一个，比如说你帮我把这一段，把这个图片生成转换成mark down格式，就是这段prom写就这个东西。然后这个图片就会变成一大堆视觉token，这时候的视觉token其实就不具有可读性了，就是人不太可以去读到底那个视觉token到底啥意思，同时打到这个大模型里。

大家记住大模型其实不光是能吃文字的，它也能吃别的。因为无论是什么东西，它最后都会转成token输入到大模型转成token输出。那只是输出的时候转换成什么不同的模态，变成文字也好，变成视频也好，变成图片也好，其实理论上都可以，其实就这么个东西。所以他其实这件事情干的就是我把一张图进来切成很多小片儿，然后变成一大堆小的视觉token。然后让用一个大模型用按照我的这个提示词的任务来输出，让它输出文字结果，就这么个东西。

但是为什么这事儿特别的让大家关注呢？其实这个encoder的部分也不太重要，核心是虽然我们虽然看到的是input是张图片，但是它其实目的或者说它背后的隐喻的意思是说我前面还有一个东西，前面是一个text，是个文本。我的文本如果能先变成图片，图片再通过这样一个编码器变成一堆token，再让大模型去抽取，最后抽出来这个文字，抽出来输出的这个文字就是所谓传统意义上的OCR。但是我输出这个图这个文字跟我最开始输入的这个图片所对应的文字还原度可能非常高。

比如说我这边输入一个两千字的文字变成一张图，图变成了一大堆视觉token，然后这个视觉token用这个3D的模型识别一下，分析一下，抽出来这个文字跟这个两千字两千字这个原始文字其实差别准确率非常高，或者匹配度非常高，大概意思一致OK。那这个时候我们就得到了一个什么呢？得到了一个文字转图图转文字的这么一个东西。

那为什么这事儿特别重要呢？关键就是这个图转转成的给到模型的这个token到这个环节，这个环节投稿量很小。大家想如果我们要去做一个传统意义上的，把一篇论文做一个摘要这件事儿。那假设这一页就2000个字，那我就得怼2000个字到这儿。然后底下这段提示词叫把这个两千字做个摘要，对吧？

但是这两千字变成图以后，拆完了以后走一遍这个encoder以后，它输入给大模型的token可能只有100个token，而不是最开始的文字，2 1000个2000个token。而这个按照题词生成出来的文字，说白了就是我们可以把最开始的这个两千个字的token，通过这一套方式压缩成只有100个视觉token。把两千个文字token压成100个视觉token。而这100个视觉token还能靠模型基本上准确率挺高的还原回来这两千个token。所以这个是最关键点。

大家我不知道有没有看过一个美剧，硅谷什么东西来着？就是讲说有一帮人发明了一个特别牛的压缩算法，我不太不记得，大家都不知道大家有没有看过？特别牛的压缩算法上压一个视频，压个什么压缩率贼高，对吧？那个那个意思其实就是如果我们能开发一种非常高的压缩比的压缩算法，那这件事儿是非常有商业价值的对所以在在这儿来说也是一个意思，就是我们面临的很大的问题，现在面临很大问题就是大模型的上下文其实很短的。比如说你像刚才cloud这个东西，我们把这个一大堆让他去分析，然后他所画的token，这能看看不到，对他所能花的token其实并不多。现在主流模型基本上上下文就11128K或者282五六K然后如果像jim l那种巨大的模型，有一兆的这个上下文已经非常巨大了。但是你但凡聊个什么几十轮对话以后，这个上下文就还是挺容易抄的。所以这个时候就提供了一个我们新的一个选择，就是我们能不能不把几十，比如说几百K上照的这个上下文直接兑给这个模型。

而怎么做呢？而把它先变成图片，把它变成图片以后，这儿以一个视觉token方式输给这个模型。那这个时候我这个视觉token就可以比比如几百K的这个token少很多了。

那这个时候是不是就我们一定程度上或者换了一种方式来去节省了我们大模型本身的上下文的需求呢？从一一兆的需就缩短成了比如说200K这样一个需求。好，这件事儿其实就是这么做的那那本质上就是我图片变成文字变成图片以后，这些图片通过一些视觉的办法，然后比如通过这个sim通过这个clip，大家就这两个人其实就是用来做这个视频的视觉的编码用的这样一个工作。编码其实就是把怎么把一个视频，把一个图片变成一个向量，一个变成一个向量这么个工作其实就干这个事儿了，他具体为什么要做这个这样来去顺序，这个不太重要。对，然后另外做了第刚才说这个低频coder就是。

怎么把这个图片变成向量的这个部分，还做另外一个很重要的事儿，就是这个就关系到什么呢？就是我们现在这一两年这几年，我们做了一大堆这种OCR的算法，就是任何一个文档或者一个有文字的图片，怎么把它变成文字，对应你的文字抽出来。这件事儿有非常多的一个最大的一个挑战之一是啥呢？就是我的图片可能各种格式，各种形状，对吧？有方的，有长方的，有贼长的，然后文字都巨细的这样的一个特别小特别精这个高分辨率的，然后不同类型的图片那怎么做？他这儿其实也做了一系列的比较直接的做法。然后底下就变成这样一些东西，这个奔驰2就不说了，大概就这些东西。

然后待会儿我们再看一下这个怎么去测。提一嘴这个东西他的里面感谢了几个？或者说他明确的说了他用哪些数据源呢？其中一个说到了pato OCR，就是刚才给大家看那个配置OCRVR的那个配OCR。所以它其实也是用了POCR出来的识别出来的文字作为正确答案，作为训练数据来去用的。所以就这个，大家可以想到为什么这些大模型厂商其实都需要做OCR的模型，对吧？就是因为他标准就要用他自己就要用他训练大模型，就要去把大量的现有的这些研报这些东西给解析出来。

所以他本来也要做这个事儿，所以顺道但是这个顺道在d deep sick的这个OCR上出现了一些好像比较有未来前瞻的这样一些成果。好，那往下看这个奔驰2，其实这就是刚才说的，现在到底OCR哪家强，当时他测的是这几个什么？其实当sota是这个家伙是最牛的，是就是dots OCR小红书。对，所以大家如果用OCR的话，这几个pid OCR、dot OCR都是可以值得用的。然后DPCOCR因为刚发，所以它的推理什么这方面的这个适配性做的还一般，所以大家可以再等一等。

然后我们看看他那几个例子，大家就知道到底是这个玩意儿是干嘛用的了。你看这种标准的文档生成，左边这就是原始文档，右边就是生成的这个文字，生成这个文字，你看这个很大的一个点是什么？就是我把原始这样一个比较复杂的文档，但里面的结构给抽出来。结构你看这个大的标题没问题，对吧？小标题他也能知道，这一段是这一段的小标题。

然后这是个图表，这是个图表，这一段是这个图上面一段话的这个是下面一段话的开头。它能结构化的抽出来，这其实还是挺重要的。不然的话大家拿到的就是一大堆的文字。一大堆文字其实缺少了非常多结构化的这个信息的。大家从人眼看这个东西能看出？四大块，但是对于机器来说，其实还是能做到这四大块的，提取还是挺困难的一件事。

另一个有意思的东西是这个，你看很多这种图表都是这样柱状图这样的，就是有个刻度尺，但是每个柱上不会告诉你具体数是多少。对，但是它能够把它给抽出来，这个是右边这张图然后能够直接实现所谓的叫deep parsing的深度解析，能把这个图里的每一个柱状图的数给你算出来，给你解析出来。你看这些就这个红的柱，对应到的这个是europe的2027，对吧？2.8、2.4、2.05、1.85，对，这个数才能给你算出来。这个东西还是挺牛的，不然的话你也得怎么着，那就是你得把这个图抠出来，然后拿刻度尺一个一个去算，然后它能够直接给把这个数给解析出来。

当然了，大家这个模型其实是一个视觉模型，所以自然语言的这些分析它也能做到。比如说你给他这一张一个图，然后它能够把它转转成markdown，然后格式都很清楚，然后这个分段也很清楚。甚至你可以去问，比如说像这个你直接去问说这个帮我定位一下11.2这个在哪儿？他就会给你定位出来，帮我描述一下这个豆瓣酱对吧？然后帮我定位一下这张图给老师是哪儿，他也能给你标出来。

比如这是一张啥，因为它是个视觉模型，所以其实这方面的能力肯定是有的。然后另外一个很重要的事儿就是你的文档里的这些公式，比如这些化学公式，然后数学公式几何的图片什么的，他都能很准确的给你抽出来。因为他知道说这玩意儿是个图，然后那些是个什么题目题干什么的，都能语义的结构化出来。所以这个方面做的还是挺不错的对，所以这就是DPCOCR这个点。

但是它其实没有满足于这个到这儿就结束，这个到这儿为止，基本上就是一个标准的OCR模型的这么一个讲解，或者是给你描述一下我是怎么训出这个东西的。往下他开始干嘛了？他开始升华了，你敢信这么现在写论文都要升华，对吧？然后那当然肯定是要升华的，他干嘛呢？大家想想，刚才我说那个就是你可以把一个非常长的一段话，对这块少少说了一句，就是我们为什么叫为什么它开始叫context，什么compression，上下文的光学压缩是啥意思？压缩肯定有一个值叫压缩比，对吧？那刚才我们已经大概说明白了这玩意儿是为什么叫压缩，就是因为我可以把一个比如说这个图就是这样说的，把一个600到700 token的文字text token变成了变成一个64个视觉token。这64个视觉token可以通过刚才那个模型的OCR的这样一个抽取过程，几乎96%的准确率抽出这600到700个文本偷看，对吧？

说白了就是我文字变成图了以后，这个图所代表的这个视觉偷看其实更小了。但是这64个token依然能还原回这600到700个文字token这么一件事儿。所以64除以600，那其实就是几乎是10%，就十倍压缩。十倍的压缩率非常高，对吧？大家想想这个有多少内容，有多少文件能够压缩成的10分之1，很多很少。他甚至在网上海做了一些实验，一直甚至压缩到1200到1300个字，都能压缩到64%。

64的token，然后准确率在60%左右的，能还原回这1200到1300个文字。当然它还有一些其他的这个如果你还原成转换成100个视觉偷看，那就可以做的更高了，对吧？你可以做到这个100 1200个文字token转换成100个视觉token，然后可以以87%的准确率还原回去这100个视觉token。可以87%的准确率还原回1200到1300个是文字token。那这个时候的压缩比就到了12 12倍，这样的一个压缩。

那大家想想这个能干嘛呢？它能其实就是这个意思，就是他在往上升华是这个意思。就是我们想想我们的记忆，我们的记忆刚发生的，比如说我上一秒要讲的东西，其实大家还算是很清楚，对吧？还能回忆回来，所以叫Crystal clear，很清澈，水晶般清澈。然后越往早一天前、一周前、一个月前，一个月前就已经很模糊了，一年前几乎就全忘掉了，这是个记忆，那视觉是不是也是？也很像？视觉我们眼前的这个10厘米处的就很清楚，然后10米的就有点挺模糊了，20米以外几乎就看不清了。那文字是不是也是？

就比如说我们现在面临很大一个问题，就是模型的记忆，对吧？我今天跟他说的或者当前这个30跟他说的，那肯定记得很清楚。但是我不可能一直把所有我们以前的对话全都放在上上下文里。那以前的比如说很早以前的一些内容，是不是也可以让它像记忆一样逐渐的模糊、逐渐的淡化、逐渐的消失，像人一样对吧？

记忆都是这样的那刚才的这个办法就可以做到了。比如说我们对于比如说一周前，一天以前的这个G我们把它压缩成用十倍压缩或者五倍压缩，压缩成一张图片，一些vision视觉的token。然后一个月以前，我把它压缩成一个更小的token，压缩成20个token，然后视觉token，然后当下的我几乎就不压缩，或者说把它压缩成一个500个token的视觉token，那基本上就是完全清楚了，完全的可以恢复了压缩比，可能就是2比1对吧？这样一个。所以用这样的一个OCR的技术，虽然它是个OCR，但是它最后的提升的或者升华的一个点，就是我们可以利用这类的类这一类的技术来去做模仿人类的记忆，来去做所谓的人类的记忆的慢慢的消散的过程，对吧？

那基本上他就把它升华到这儿，就是随着时间的这个变化，我们可以想象我们以后的文字对应到那个图片。它的解析度？它的这个分辨率会越来越低，就好像我们脑海中的这个就一直在慢慢的消散的这样一个过程。所以他其实讲的这个东西，所以确实是很需要的。就是我们的整个的现在的agent整个大模型的这个memory机制，其实是需要一个能够处理我们的当前的记忆，像人一样来处理记忆的这样一个能力。这事儿其实用还没完。

这个人吧？Andrew capacity这个人，大家听过课的肯定是不不断的就非常清楚这个人anger captain，他看到这篇文章以后，直接他就写了一个还挺长的一段一个推来去夸奖他他说我很喜欢这个，他是一个好的OCR。Maybe a little worse than dot dot，就是刚才给大家说小红书的那个OCR模型了，但是至关重要，因为什么呢？他说最有趣的部分是你看大家说这个，特别是他在这个人的他的内心深处，他认为他是一个做机器视觉的，而不是一个做自然语言的person，对吧？就是可以建这个大叫什么学做AI领域的人，其实也是这个鄙视链还是挺挺挺挺挺清楚的，对吧？就做视觉的，做自然语言处理的，大家其实以前对NLP那帮人其实不是很很那个啥很很感冒。对于有趣的是，对于这样的一个他来说capacity来说，他认为什么呢？

他认为是像素是比文本更适合作为大语言模型的输入的。大家记住，像素是比文本更适合作为大元模型的输入的对所以后面他就开始说，为什么他认为像素或者图像是一个更适合的输入大模型的输入法，你看他甚至说他就说首先他说这个篇文章的结论是这样一个东西，或者说在压缩这个维度来说是一个这样的维度的东西。那他后面再来说，好，他甚至认为所有的大模型都应该只吃图片，只吞图片进去，那即使你有了一些纯文本，你也应该干嘛，你先把它渲染一下。所谓渲染其实就是你把它变成那张图，然后变成一张图以后再扔给大模型，让这个模型去看，看那个图，而不是看你的文字，为啥呢？他就开始说了，图像是因为有更多的信息压缩，为啥呢？

这个其实一句话说就是什么？就是我们的文字，你像这一段文字，其实是一个所谓的叫离散的一种编码方式。就是每一个字其实都是一个跟另一个字完全独立的一个编码，他们之间是没有什么语义上的关系的。比如说M就是编号一，A就是编号2，Y就是编号3，他们之间就是一个独立的编码。而大家说M等于一，A等于2，一和二之间这个距离跟这俩词儿其实没有任何关系。

所以其实就是我们给这些文字做的编码，它并没有完全的或者是更高效率的把它所编码对应到的一些数据存储的空间给利用起来。你想比如说我们存所有的这些字儿，就可能存这个100个100个空100个字所对应的空间。从1到100，把所有的每一个字都存到这个空间里面，对应到一个值。那你说这些1到100这个顺序对于这些字所存的这个编码有用吗？其实没啥用，所以这也是为什么在本质上为什么我们认为图片比文字更适合作为输入。

因为图片其实是一个连续的值，他是有有这个就比如从0.1、0.2、0.3、0.4或者0.11、0.12、0.13，它其实是一个连续的值。那这个0.11、0.12它们之间那个大小其实是在图片意义上是有意义的对吧？就比如说从暗到亮，从0.01到0.02到0.03，这个值在图片意义上是有意义的。但是对于一个文字来说，就0.1、0.02、0.13这个编码对应的文字就没啥意义。对所以他就是说为什么叫图片？其实有更高的信息压缩的这个能力，那它可以干嘛呢？可以更更短的这个文字窗口，能更适合通用的信息流，对吧？因为咱们人生活的这个D世界，三维世界其实就是视觉的世界，所以它更通用，可以用更好的双向注意来处理，说白了就是这不那么重要了。

然后最关键的是这个东西删除分词器，删除分词器。啥叫分词器？它玩意儿这玩意儿叫tokenizer。然后tokenizer是什么东西呢？大家可以看一下，这个玩意儿就叫是open l的token ized，然后它每一代不同的模型的token ized还不一样。它干嘛呢？其实就是把你一段话分解成一大堆不同的token，这个就跟刚才的文本token是一个意思了。

比如我就把这段话扔到这儿，然后你看GB4的token就是这样，我这一段话一共有280个，the character其实就是一个字儿，就是一个character。但是它对应到token只有52个token。他这52个token是咋分的？就这么分的，你看就是每一个颜色其实就代表了一个token是吧？Large language model process这些都是一个都是一个一个token对吧？

基本上可以从这儿看出来，基本上一个词儿一个token对吧？但是你看以前的这个呢比如说GB3时代这个头像，这段话差看差别不大。那我们换个中国的，比如说我爱北京天安门。他这个没有，这是来了，你看七个字六个token，北京是一个token，天安门各是一个token。所以不同的模型对于同样这句画这个token画是不一样的，所以这玩意儿就叫token token ized就是我怎么把文一个模型的文字输入切成不同的token。

而这件事这个token either为什么这个卡帕奇痛深恶痛绝，他说一定要低要删掉这个tokenizer，尤其是在输入端都删掉这个take nizing。它里面提了一大堆东西，其中有一个叫unique的，所谓的这种tokenizer带来了安全和越狱风险。这些东西大家可以想想这个模型怎么会有，对吧？就是一个token为什么会带来安全问题呢？我当时就找了几个，找了这么两个例子，我觉得这两个例子特别有意思，给大家讲一下。

一个是一个是这个东西。这儿知道unicode其实就是咱们目前现在市面上的所有的文字。比如说这些中文、英文、拉丁文、日文什么的，阿拉伯语全都是每一个词都是可以在用一种叫unicode的东西来去编码了。但是由此产生了很多混淆。比如说FOO，FOO跟英文纯英文的FOO这个O其实是一个拉丁语拳脚拉丁词。对对对，这个O跟这个O其实是完全独立的两个unicode的编码，独立的词儿。这个O又是另外一个。所以你会发现很多O即使都像长得像O的东西，它其实都是它是不一样的。这个在unicode是不一样的，所以这个会导致很多多的安全风险。

其中有一个是什么呢？就是比如像这种，比如说paypal和paypal这种东西对吧？那这个到底是L还是I？这个不好说，因为他长得实在太像。然后这个玩意儿是google吗？这两个O其实不是O它两个是一个，它叫希利尔字母，西里尔字母。所以这个其实应该理论上，你看我打了这么一个东西以后，然后帮我转码成这个东西。

但实际上一个网址理论上是可以支持各种unicode的编码的。所以你可以说有什么中文网址，有中文的网址域名，有什么希利尔文字的这个域名都可以。所以这个会带来很多的安全的风险。

然后另一个是什么呢？是这个东西大家知道unicode其实是可以不是就叫阿拉伯语，是从右往左的，应该是从右往左的那所以unicode里面有一些用来控制这一段话到底是什么顺序显示的一些字符。就那些字符是用来把它后面的一个字放到一个位置，这样的一些控制的字符，它也算一个字符。所以你看阿拉伯语它其实从右往左，所以它专门有一个unicode的是用来控制方向的那就会导致啥呢？

导致这样一个东西。假设我现在让他输出一个去这个地方去以下网，只去修改密码，我要输出这么一段话。结果我在这儿专门加了一个控制方向的unique的。你要直接看这个域名，你一看就知道这玩意是一个安全有安全风险的一个域名。这个ml wall就是恶意代码。那我直接看域名的话，我就知道这玩意儿是个恶意代码的域名，我就不应该去点。但是我前面加这么一个东西，这个unicode就代表了把后面东西翻过来反着走，就阿拉伯语反着走你他渲染出来或者他在网页里面看到的就是这个样子，changer passat这个CT bank什么什么的東西。

因为啥呢？因为你倒着看你倒着看就是这个东西。对，所以尤尼扣的这个东西对于大模型来说是没有任何意义的。或者说对于咱们正常的使用大模型的来去训练，它是没有任何意义。它反而会增加非常多的不好的点。然后这个对于MCP的攻击也是有一些办法，这个就是unicode的问题。所以他在这说了，好提到的这个安全unicode的安全问题其实就是这个东西。

甚至还有什么呢？我们说一个smiling的em oji，大家知道smile这个笑脸的那个em其实就这个东西，这个效率。它在unicode里面或者说那个分词器里面分完了以后，大家可以再看一下刚才的那个tokenizer，smile emerge看看考一下，把它放在刚才那个token ized里面，它变成什么呢？它会变成一个，对，这没有那个数，他他就会变成一个ID。他虽然给你展现出来，但它实际就是一个比如说586这么一个ID对应到的一个向量。所以你放到那个那个向量，放到那儿几乎就丧失了非常多的信息，对吧？那我放个笑脸我肯定表示开心，但是我一个586代表啥的那不知道。对，所以他意思就是说我们的token nater其实会导致我们看到这个网页里面，看到这个图像里面的很多信息也会丢失，所以这个就是说他他极力的讽刺这个tinder或者想去把这个token eder干掉这样一个原因。

他底下就开始说了。OCR其实只是众多的所谓的叫视觉到文本的任务的一种模型。视觉就是图片到文本一种任务之一，那文本到文本的任务，其实是可以转换成视觉到文本的任务的。就跟刚才大家跟大家说的，文本到文本，我可以先把文本变成图，把它变成图了以后，我再把它变成文本，对吧？那那为啥不行呢？如果我能压缩这个使用的投放量的话，那这不是挺好的一件事吗？

而反之则不行，反之是啥？就是文本到视觉是没法这么搞的。对，所以在底下就说所以用户发的大量的信息其实是图片，解码器或者就是这个最后输出的结果还是文本。所以怎么能以逼真的方式来输出就没那么明显，就大概这意思，所以他最后说了一句话，他甚至想赶紧去开发一个支持只支持图像输入的nano chat nano CAT。

就是卡帕斯前段时间刚发布的一个教学用的这样一个大模型的一个训练。从最开始数据的处理，到最后的模型训练微调，乱七八糟全部的过程的这么一个项目叫not nano chat，整个代码其实并不多，你看看整个代码有多少，大部分都是python，所以这个还是非常好的一个教学项目。但这个其实还是比较偏技术了，所以今天就不跟大家去讲讲这项目。对，所以他就夸了半天这个deep seek就是发现了一些新的东西。关键谁还回复了呢？

马斯克，对，马斯克回复了，然后他回复的还挺仙儿的，就很很很那个什么你看他说长期来看，99%的输入和输出，大模AI模型的输出都是这个叫photo。Photo是不是photo？是光子是photo。所以就是啥意思？其实就是已知的世界里面绝大部分我们看到的或者我们接触到的这个东西其实都是光子的形态。我们看的東西，然后这个产化东西什么的，其实都是光子作为介质。所以这哥们又又稍微飞了一下，来去说件事儿。

然后他另外一个比较高赞的是，就是这个潇刘潇，这是质朴的一个算法工程师，很厉害的一个算法工程师。然后他也这个啊其实就是我们又发了另一篇paper，就是因为看了deep seek这个OCR以后，我靠连夜就赶出来，这个东西这么一篇文章其实讲的也是类似的东西。但其中有一个点我觉得比较有意思，就是它里面做了很多的实验，来去实验啥呢？就是我到底以什么样的一个配置，我用多大的像素，用什么字体，用什么DPI，乱七八糟这种其实大家可以理解成排版的配置渲染。把文字渲染出这张图，是最能够被刚才的这种OCR类的模型

能够还原回去的，准确的还原回去的，所以说白了就是刚才那个OCR的这个deep sic OCR这个模型。我们除了说我们可以把现有的图比较好的去抽取出来它相关内容以外，我们还可以去实验出来。如果以后我们想把我们的这个比如说巨大量的数据给压缩好。那到底以什么字体，以多大号的字体，以什么样的版式，这样去压缩是最能够保留在压缩比更高的情况下，能更高的保留这个数据的，更高的保留文字数据的这样的一个准确率的。对。

提问大模型可以输出为图片或者视频吗？可以，现在多模态到多态还是很多的。但是普遍的大家现在看到的文字到甬管什么模态，到图片或者到视频，大家很多都还是用的所谓的这个diffusion模型，就是扩散模型，然后transformer模型现在也有一些，所以这个各种模态到各种模态都有啊。

这个事其实很早就大家都在做了这个研究，给大家看一下，这个研究很早，这个是24年的一个研究，24年中叫next GPT，就是下一个GPT是啥呢？是into any的多模态大模型，就是任何模态到任何模态的大模型。看这张图大家就能明白啥意思了，就是我的模态可能输入模态，可能是文字图片、音频视频，输出的模态也可以是文字图片、音频视频，都可以。那这里面唯一要做的事情就是我怎么把，因为文字我是可以直接刚才给大家说了，那我嵌入变成一个向量扔给姐模型来去分析就OK了。但是我图片怎么变呢？那我就需要一个把图片编码成向量的嵌入的这么一个encode编码器，音频也是需要需要一个音频的编码器，视频也需要视频编码器。输出的时候，那我输出的时候也还是向量了，在这儿还是一堆向量，那我就需要把它变成还原回这个图片音频视频。

一般来说在当时到24年的时候，大家都普遍认为还是用一些diffusion模型把这个向量变成图片、音频这样一些模态，所以这个就是去年大家就已经在这么拿去做，就认为是以后的这个diffusion，以后的所有模态到所有模态的模型就这么做，所以这个是一个确切的大家在往这边去走的这样一个方向。别的就这块我给大家讲一下，我觉得挺有意思的一个东西。这个还是之前给大家讲那个人的博客，就是Simon Wilson。还记得给大家讲他的时候是讲的是啥吗？讲他的哪一篇博客吗？有一个benchmark挺有意思，benched park, 我不知道还记不记得，就这个人。还有人记得吧？鹌鹑骑自行车，鹌鹑骑自行车，这个人很有意思。

然后在deep sic OCR的这个出来以后，他有一台他有了一台NVIDIA Spark。Spark这个就是我不知道大家有没有看过，就是这么个大玩意儿，一个小机器。然后这个小机器算力贼高，然后是应该是刚发货，刚发货一两周，然后也买不到，好像是四五万、五六万，反正挺贵的一个设备，但是它算力确实很高，就这么小，所以真的是可以，就比mac mini应该还小，我估计也不是很贵，四千刀。所以但是你要在国内能买到，基本上都在四五万人民币起了。

然后就这个东西他有了一台这个，那他就想说怎么把这个东西跑在Spark上呢？然后大家可以看看现在这种工程师都咋搞，他都这么搞，他要把它跑到那上面，然后发现这好像还有些问题，那他直接干嘛？他直接让clo扣去搞，对吧？还记得考克是啥了？就是你的一个浏览器里的一个靠大模型驱动的这么一个写脚本的这么一个A站。

然后他整个过程干啥了啥呢？写了几个铁磁，就写了几个贴着词，什么提示词呢？第一个是创建一个dip sic OCR的一个目录，然后把所有东西都放在这个目录里。你下面的这个是你下面的任务是让这个模型跑起来，然后他用的是hugg face的一个transformer，说白了就是一个框架。你要去把它跑在docker里面，然后跑到一个NV列的ARM的设备里面去。然后你先去研究一下你的环境，然后看看是不是可行，再把这个代码，把这个模型档下来，然后记住你要启动这个，这反正这是一个大大文件的一个配置，乱七八糟一大堆。最后就拿一个文件，一个图片文件当例子去运行一下这个dept COCL，这个算是他里面写的帖子最长的一段，然后就跑跑多久呢？你看这个小型项目，他跑早上跑了40分钟，大部分时间都是克拉克在干，然后他在吃早饭或者忙别的事儿，他只他他大概率就只写了这几个提示词，这几对这几段铁磁。

所以大家可以看到下一代的工作方式，大家会越来越发现越偏向异步工作。或者说你就发号施令，然后把这个任务描述清楚，然后把你想象到的能够有助于A站完成这个任务的一些经验写进去就OK了。所以这个就是这哥

们儿怎么把它跑起来这么一个经这个文章，我觉得大家也要逐渐开始习惯说你干一个活的时候，他其实大部分的活并不需要你来去干。

好，然后下面我们直接来这儿，那就看看这个奔驰挺有意思的。不知道大家有没有看过新闻，最近有一个叫alpha arena的这么一个项目，这个项目是谁搞的？叫no，叫什么nova nova这么一个团队。

这个团队他其实about写的很有意思，大家说地幔的颠覆了这个人工智能研究就深度学习。他认为什么呢？他认为金融市场是下一个最好的训练环境什么的训练环境，是给AI的下一代AI的训练环境。因为它是什么？它是一个终极的世界建模引擎。他这个最终的世界建模引擎，这帮做金融的都会这么想，就觉得世界本质是金融，所以他就构建了这么一个奔驰2，这个奔驰one干嘛呢？

就这段说白了就是让大模型来炒股。然后这个可能大家是不是有听过这两天应该不断的看到这个新闻这个新闻。然后这个新闻里面大家看看阿发arena里面到底是干啥，先看到底他能让这帮大模型炒啥股。

比特币、以太坊、斯罗拉纳、什么BNB这几个全狗币，全都是数字货币，全都是web 3的货币，对吧？所以其实它并不是一个面对普通的公众的什么一二级市场的这样一个比赛，而是主要针对的是数字货币。但是数字货币有很多原因太小了，因为它比较公开，比较透明。然后大家可以有足够多的信息去获取到，然后对接也相对来说容易一些。

你会在这看到的实时的每一个agent，它以当前它自己的这个position就是仓位。你看就可以看到每一个agent，每一个模型对应的这个agent到底在买了哪些股票，然后在什么仓位买了，这样一个值。然后我看他好像按照百分比来看的话，你可以看到基本上国内的俩模型，他就国内就俩dig跟千万max，然后都是正的，都是赚钱的，一个19%，一个28%，这个千万是就好像就是今天刚开始反超的，之前全都是deep c第一。你看这个deep CL线都是之前基本都是他第一次，然后今天他反超了，然后就还还是还是一般。你看这个很有被deep sig反超回去的趋势，然后其他的几个saw net，然后brock、gym、GPT都是亏的要死的对吧？那个gbt 5亏了72%，所以就是这个对，但看一下咱别只看这个花哨的东西，我们看看他到底咋干。

这个里面它有它所有的交易数据，这个就不管了。其实就是模型自己决定到底买什么卖什么，然后这个是最关键的。这个model chat里面你能看到每一个模型在每次做决策的时候的全部的数据，以及他的思维链。比如说什么呢？我们看这个千万max千万三的max它会直接告诉你，DCV3干嘛了，我看看他有没有买卖。Chain thought, 然后他的action，我看都不成。哎。

没有没有没有那个啥没有最后一页没有新的交易我们就拿这个V3.1来看，它会告诉你每一次分析这个模型，分析它到底应不应该买卖的这样一个用户提示词，以及COT，还有最后的trading decision，就是交易决策。你看这个交易决策其实基本上都是他手持的。这些仓的这个action是全都是hold住，就是不买也不卖，对吧？

然后前面这个user prom，你看里面大量的这种信息什么，你是你已经在这个创建开始交易以后的这是1460分钟了，当前的时间是什么什么？然后这个你已经被调了590次了，然后以下的是所有的交易信号，然后从最老到最新这样排序，然后底下就咋咋咋的一大堆，什么BTC的数据，ETH的数据，索拉纳的数据一大堆。然后到这儿就是以下是你账号的信息，就是你持仓了哪些股票，然后表现怎么样，然后这样的一些些全都是在提示词里，用户提示词里扔给大模型的。

大模型线上现在都是推理模型，所以你才能看到它的COT对吧？你看它是一个系统，首先用户是一个系统trader，叫什么系统化的trader，这个不懂这个什么hyper liquid的是什么？这个超级流动性，然后怎么没了？对，我是不是看错了？怎么又往后这么多，完蛋，找不到了，刚才我发的在哪？往下看吧。对，然后这就是另外一个train那个COT。

你看这个模型产生的COT是这样的，他开始分析每一个仓位，分别分析ETH仓位怎么样，到底仓位怎么样，然后开始各种的，他决定hold住，然后最后他的所有的决策就是hold住，所以就是这样一个东西，就是他其实并没有一个至少目表面上看起来并没有一个非常复杂的A准决策。但是他就用这样一个很标准的结构化的这样一个提示词，让模型自己去产生COT。然后产生COT最后的结果就是我要每一个持仓的行为的一个decision决策，就是到底要不要交易和买哪些卖哪些。对，所以这个就是这么来去干的，所以这个网站做的很漂亮。

为什么它不断的变呢？其实主要因为是这些数字货币变得太快，所以这个不断的波动，所以这个已经甚至我好像看有人已经开始什么呢？就是来这儿做这个叫什么跟盘，我不知道是不是叫跟盘，反正就是这个模型咋咋买我就咋买，咋咋买卖。所以这个很有意思，我觉得这东西其实并不难做，就是大家如果玩数字货币的人其实都可以尝试。因为现在这个数字货币其实API是很很健全的，你是完全可以去复刻这样一个东西。

对，然后做成量化模型，有量化模型就搞这个这个东西给大家说一下这个东西RD agent之前应该给大家讲过，这是微软雅苑的一个项目，微软的，RD他干啥呢？其实就干这事儿。你看量化金融分析的一个 pipeline，这个 pipeline 是干嘛？来获取数据，然后再做处理，然后再找这个 factor，就是量做量化。大家知道这个因子这个量化的因子，然后再对这个因子做裁剪，然后再跑一个模型。这个模型在训练，然后训练根据什么来去推断呢？就根据一个市场的这个情况，然后生成出来这个结果。然后 q lip 这里面的 q lip 其实就是跑回测用的。就是你只要有一个交易策略，然后都可以通过它来跑回测，然后你就可以立刻知道到底这个策略管不管用。

而第一件东西，其实就是里面的最关键的就是我有一个因子的想法，这个因子的想法我怎么把它快速的变成一个 python 代码，怎么变成一个 python 代码，那假设比如说我就说市盈率超过20的这样一些白色家电企业，我觉得都应该做空。那我怎么把我刚才说这个东西变成一堆交银子那的 python 实现，所以他就可以干 RD agent 就可以干这个事儿。然后再联动 q lab，我就会立刻换成我刚才那个因子到底靠不靠谱？你能不能回测以后的结果咋样，是吧？这个我不专业，这个称号专业。大家如果感兴趣的话，可以再下次再跟他聊一下这个事儿。

对这种工作模式会不会导致工作嗯哪种工作模式，工作模式会不会导致工程师断层，初中级工作室交给AI执行了。对，这个很简很典型。就是现在无论是工程师还是非工程师行业都出现这个问题。就是初级中级的工作的人其实都在大量的问题是找不到工作，就是公司不给初级的工程师工作的职位了，那当然不止工程师，律师其实也很关键一个角色。当然心理咨询师其实据说已经开始出现，律师是最严重的。然后我之前看有些律所已经不招初级的律师了，因为 chat PT 都比初级律师强得多，所以这个挺麻烦的一件事儿。

可以加杠杆。对，可以加杠杆，但这个没加，我记得没有，这个应该就是唇持有持有的这样的一个做法。因为你看它的 trade，其实就是一个有 long 有 short。对对对，有浪有顺，所以这个还不光是，但是好像没有杠杆。这个不懂，这个我就不瞎说了。所以这个阿尔法 arena 它叫 alpha a arena。大家看看这种 battle 都叫什么什么 rena，挺有意思一个东西。

好，下面我们来看几个应用。一个是大家前两天看到啥这个 ChatGPT 的 atlas 这样一个浏览器，对吧？我不知道大家有没有用过这个阿特拉斯是免费用户都能用的，所以这个大家其实可以直接用，但是免费用户好像是没有这个 A 的模式，好像这个是没有的，就是 plus 用户体都可以有这个 A 的模式。对，这块我先说一嘴，就是大家如果想我不知道有多少开了 chat PT 账号，如果在国内的用户确实比较难开 chat b 账号。然后目前来说我觉得最安全或者说最成功率最高的一个做法是这么做。就是先对这个我就不点这不留文档，然后就跟大家说一下，其实就是拿一种叫苹果的 IOS 的礼品卡来去干这件事儿，apple 的 gift card 这个东西。

这是啥呢？就是他比如说在 iphone 上，首先你得先有一个非国区的平 i cloud 账号，ico 账号，甭管你搞一个什么香港的，搞一个美国的，其实都能当到那个 XGBT。你得把 ChatGPT 的应用当到你的手机里，对吧？你起码

有一个有这样的一个APP，然后这个APP你就会发现它有这么一个upgrade，一个看啊我的视频咋关掉了。对，有这么一个upgrade，这个升级的这个。怎么没了？

我看我的同学们稍等。对你会发现在你点头像的时候，会有一个upgrade to什么什么这样的一个东西。因为我现在已经plus，他会告诉你说要升级pro然后你点那个升级的时候，它就会干嘛，他就会去调起那个apple，就是苹果自己的那个apple pay，其实就用的是你apple store的所在的那个账号的支付宝。

然后这个时候，如果你去配一些国内的VISA卡，一些信用卡的账号，就有经常会失败，基本上就不会让你付出去钱的。所以有一种做法，就是你去买一些苹果礼品卡。这个礼品卡可以怎么买呢？可以通过email发到你的邮箱里。你买个什么一百刀，然后发到你邮箱里，发到你邮箱里，你过一段时间你就会收到一个一个一个号。这个号，你就可以填到你的已经注册到了非国内的，APP store的那样的一个你的payment里面去。然后payment里面就有一个叫regime，就是叫什么这个兑付这个APP，这个dific card这么一个地方。说白了就是往你的apple海外账号里面充点钱，然后这个钱你就可以用来去付chat BT的这个账号费了。

所以基本上现在相对来说比较稳定，都是这么搞。对，这样发展下去是不是暂时没有35危机了？那可能还不到35就没了，这波人就大部分都被裁了，有杠杆对吧？对，去中华永续交易所。对对对，我不知道他用的啥交易所，是用什么define的交易所。

好，那么回过头来看这个agent的这个atlas，它其实你看这个过程，它其实就是这么个东西。我我我之前把它登过京东，所以我可以干嘛呢？帮我在京东找个500以内的后进展，就这个东西。然后开了。对你只要把这个A的模式开开，然后他就会开始干活了。然后你发现他干活的这个过程，跟之前的在chat BT里面这个agent模式几乎是一样。那还有我的麦克风干嘛用？我靠，他还要听我说啥是吧？

然后你看他就开始去搜，当然他其实并没有从首页进去，所以我估计是他直接就可以产生出京东那个搜索页面的这个URL的。然后他就干这个事儿，他开始去找，然后打开这个搜索结果页面。你当然可以随时所谓的take control，就是我回过头来控制一下，不是这个，而不是纯让他来搞。

然后他就自己去看完这个网页，他就可以选A429，这个确实是在这个预算范围内的，五百以内的亚朵星球诊，然后速度还是有点慢的。你看这整个过程速度还是一般的，但是整个的分析还算是OK。你看整个内容网页的内容提取，然后分析什么的也都OK。

然后现在要加入购物车，再找找，不要这个。他给你可以随时去介入。然后你也可以看到你当前的这个真的在操作的这个鼠标到底在哪儿这样一个事儿。所以这个界面其实跟之前的你直接在chat b里面去让他完成这个任务其实是很像的。就比如刚才我的任务叫就能找一个这个，然后我们回过头来在XTB里面去干这件事情，我们把A的模式打开，然后对。

区别其实是啥呢？就是这个浏览器我是可以随时打开去干一些别的事情的。比如说我打开京东，打开淘宝，打开什么知乎，先登录一下，我先登录一下以后，我去对登录一下以后，后面的A站他就可以用我登录以后的这个tab去干活了。所以这个是最大的差别。

而你要在这个XTB里面干，你看其实也行，对吧？它也是一个实时的效果，你看你也能看到它在打开京东去找这些信息。但是你在这个时候，你如果想去所谓的自己进去，然后把这个京东登录上的话也可以，但是就比较麻烦。而且我记得好像他是不会记录，把我的整个的登录的信息一直记录进去的。所以我下次要再干的时候，他还得再让我这个再再我还得再自己再登录进去，再再登录一下，就点进去再登录一下，所以会麻烦一些。

但是它还有一些比较牛逼的功能，我觉得就主要是这几个这个标准的A的功能，我觉得其实差不多，跟之前的这个准确率什么的都差不多。有一个比较牛逼的功能是memory这儿。对，有一个memory你可以它就是它会根据你之前发的各种的需求，你给他任务，他给你做memory。而且这个memory是什么呢？是浏览器级别的，这叫broader memory，brothers memory，就是浏览器级别的这样一个memory。那有这个东西能干啥呢？就关系到它到底是有哪些功能。比如说你看这个，我们就回过头来看他官方的宣传的内容，我看看他就能干哪些事呢？

这儿对。

就这样一张图。对，反正意思就是比如你可以直接去问他说，我上周看的那个那个好像是裙子，还是我上周看的那个东西，这个帮我买下来，或者帮我再点到找到上周我看的那个那个裙子咋样，这样的一些东西。所以说白了就是整个你在网页里面操作的过程，它其实整个的这个记忆它其实都有的，它都能知道你什么时候看了什么东西。然后你可以随时的靠chat VT来去告诉他说，你结合之前你的记忆帮我干个什么事儿，这样一些东西找不到了。然后这个记忆当然理论上他说了你可以自己控制，但是我拍的很多事情其实并不是说那么单纯的，然后找不到了，好像是这个对，你可以干这个事儿。

你不要帮我找到上周发布的所有的职位，然后并创建一个行业趋势摘要，以便我面试对吧？就是find old jobs posting，就是我上周看的所有的这个招聘信息，然后帮我找一个帮我分析一下这个趋势，然后以便准备我的下一步的一个面试的计划。对吧？这个就是如果一个浏览器的所有的上下文，或者这个记忆，它都能够你都能够既能能就是大模型都能知道的话，那其实他可以干非常多的事儿。所以这就是阿拉斯，我觉得他出这个东西就跟open I要出硬件是很像的一件事儿。他已经很直白的说，为什么要做硬件，就是因为它需要大量的上下文巨多的上下文。

那这个上下文在哪儿呢？咱不可能让用户所有的内容都直接在这个chat PT里面去去说。当然一方面他希望把所有的应用都做到chat p里面。上节给大家讲的说那些什么apps SDK，其实都是这个目的。另一方面，我为什么一定要在浏览器里？一我要指着用户打开我的网页，我直接做个浏览器呗。那你但凡你在这浏览器里做的所有事儿，其实他都能拿过来当做他的上下文，当做他的记忆来去用。对，所以这就是阿特拉斯。

然后另一个我就给大家讲一讲这个cloud，快速讲一下cloud这个skills。这也是上周他发了一个新的东西，这个16号发了一个东西叫agent skills。Agent skills是啥意思呢？其实就是有一张图没有。

这样，我们直接看一下它的这个例子。对，这就是我的cloud。然后这个cloud的桌面版，就是不是它的网页版。为什么用桌面版？是因为它掉各种工具DMCP会方便得多，所以就这样一个东西。

然后你在setting里面，在设置里面可以看到这个东西叫capability能力。然后能力里面最下面有一个叫这个的。对，叫skills，这是个预览的一个一个状态预览的一个状态。那这个skills是干啥呢？它其实就是一个所谓的可以让你把那些重复的定义的指令，然后那些指令是干嘛的？没用？是让cloud来去follow的，在任何的chat里面都能follow的。这些东西能够形成的skills。

所以在最开始的这篇文章里，就是introduce skills。其实他说的意思就是你应该放什么东西呢？你应该放你干某些事情的时候，给你的新员工所发的那种什么入职的这个入门的内容，就是入入职手册。说白了就是你干什么事儿，应该怎么干这些事情，你应该放在skills里面这样的内容。所以你只要把一堆这样一些东西，它就可以形成一堆skills。

那我们看看它有啥skills，比如说这个算法art，算法艺术，algorithm art。然后这个artificial builder就是做一些网页这些东西。然后brand online就是品牌的这个导演，或者说你品牌到底应该用什么字体，用多大，用

什么颜色，这些东西其实都叫brand干了。

这是SF这里面这些全都是官方做的一些所谓的skills。我们看一下这些意思是说大家知道说skills应该写啥东西，不应该写啥东西，应该写啥东西。然后比如说像这个内部的这个communication，其实就是内部大家喜欢怎么来去说话，或者怎么来去沟通，这样的一些风格，你也可以写成skills。甚至他还弄了一个skills free creator，就是如果你想建一个新的skills的话，你可以用这个skills来创建一个新的skills这样一个东西。所以当然你就可以把它有些打开，有些关闭就好了。

然后你会发现不知道咋用，对吧？然后他还贴很贴心的给你这么一个小按钮。小小按钮就在这儿，你可以直接说叫trying。然后他就干嘛呢？他说你告诉我这个skills能干点什么牛逼东西出来，然后他就会干嘛，他就会真的干这个事儿。他为什么我要我麦克风？不知道现在这些浏览器都要我的麦克风，真的是想啥都想听。

然后这块儿我就不那啥了，我直接给大家看一下之前的这个跑出来结果，因为他跑的还是挺需要挺长时间的。你看这就是刚才说的这个艺算法的艺术的这样一个skill，到底能干些什么很牛逼的东西呢？他就能做出这么个东西，这个叫harm什么resonances？这个叫谐波，我记得是谐波共振。

对，谐波共振其实就是一种能做出一种算法来去根据不同参数能产生一个谐波的效果。你看这个就是谐波的效果非常漂亮，然后你还可以随时去改这个各种参数。比如说这个波的振幅改大点，你看可以变成这个样子，然后把这个谐波层加多一点，那就变成这个样子。

对，就是这个东西怎么出来的呢？就是刚才说的，他其实可以思考出来，可以干这么个谐波的这么一个坑上，然后用什么呢？用他那个skill，那个skill是个啥呢？其实就是一个怎么用一种代码库，它好像cgs这样一个代码库来去演示一个数学概念或者一个比较复杂的概念这么一个东西。然后做成一个网页，你看这是变成一个网页，你可以下载下来，然后就当做你的什么课件什么都OK这样一个网页。所以这就是一个skills那大家可以看看有什么别的skills。比如说你找一个实际的skills的文件的内容。大家看看就知道说这玩意儿其实就是纯文本。

比如说这个品牌的get line，描述的啥呢？这个ACME这玩意儿是一个这个ACME公司是一个一个段子，其实是一个一个笑话。我记得是大家都在说有这么一个公司，这家公司好像是一个神秘的公司，反正是啊就是一个一个好像是一个动画的一个公司。然后这家公司应该怎么呈现所有的presentation和文档。

然后这个skills提供了这个品牌的概念，然后怎么创建一致性的专业的材料这些东西。然后底下写什么呢？品牌的颜色，这几个色调、主色调、这个副色调，风格什么中立，用什么颜色RGB都给你定义出来了。用什么字体，有什么这一些字体，H一用多大，H二用多大，body用多大，然后用啥logo？用logo的使用，你应该永远都要用全彩色的logo，而不应该用那个单色的什么这些。

然后那怎么用呢？你要把这些用在什么PPT里，用在word里，用在这个市场材料里，然后一些相关的资源就这个东西。当然你也可以加一些代码，比如说python什么这些东西如果你觉得有一些执行的时候，一定得用你的这个程序来跑这个数据的话，你就把你那段代码的python JS先放到那个目录下就OK了。所以其实就是这么一个目录，然后你把它打成zip以后，就可以直接上传到刚才的这个cloud的这个skills里面。就上传到上传到这儿，就是添加一个skill就OK了，他就进到你的skills。但是他网页上好像也能上传，就OK了。所以就是这么一个一堆文字性的东西来去描述你应该怎么干某一个活的这样一些内容，就是他的所谓的agent skill。

所以大家可以想象，下一代这种类型的工作，或者说我们的公司里面的很多规章制度什么的，其实都可以变成skills，对吧？那这些规章制度除了说那种硬性的什么不能干什么这些以外，很多规章制度其实都是在教你怎么

正规的或者合规的或者是规范的去做某些事情。甭管你是写代码的规范，用PPT的规范，写文档的规范，内部沟通邮件的规范，其实都可以写进去。

然后什么时候会被调呢？大模型决定什么时候调。你哪一个skill里面的哪一个文件都是他来去决定的。所以这就是这个cloud的这样一个skill的这样一个用法。

但是我觉得这个是一个非常牛的这么一个东西，因为它本身就是一个是不是一个阈值提示词包。可以这么理解。对，就是他被大模型后被一阵引用，其实就是把它拉进来当做他的提示词的一部分，其实就是怎么把那个上下文拼好，那我怎么找到这个活所适应的这些上下文，其实就是skill干的事儿。但是他是给谁用的？他是给A枕用的，所以这个是一个非常有意思的这么一个新的功能。

然后我觉得可能以后不是，可能肯定以后各家的这个大模型工具都会不断的加上，把这个skills加进去。然后你说这东西它就是纯文本，所以它也没有什么太多的标准的行业规范，只是把这个几个标准文件给定义好就行了。那几个标准文件就是什么叫skill点MD，对吧？像CMD然后几个别的文件点MD其实他只要把名字定义好啊，就说白了就是这个skill的入口文件在哪儿，首页文件在哪，他只要点定好这个东西，其实各家的大模型都能用这些东西。

所以我觉得这个s topic，对cloud的这个skills还是挺值得用的。因为它其实大概率不是给技术同事用，大概率是可以直接让这个业务同事直接能用起来的。那他其实就受众面就广非常多。所以这个就是这个cloud skills这个东西，然后我觉得这个带来的下一波机会是啥呢？

一个是上次应该有一次给大家讲过一个项目叫peace这是微软院的一个项目叫peace。它是干啥的？它其实就是一个怎么看地很复杂的地质地图的这么一个agent项目。然后它里面其实很关键的一点是这个东西怎么把这个地质地图先抽取出来以后，中间有一个环节叫consult consultation concert就是顾问咨询。怎么把这个时候分析这一段地质地图所需要的专业知识，在这个环节注入进来。我应该咋看这个地图，怎么分析这个地图这部分的经验注入进来这个事儿。

这个过程其实说白了就跟刚才我说的cloud skill非常像，它叫DKI，那cloud很直接，它叫cloud skills，而且这个skills大概率是谁写的呢？人写的对，所以这个说白了就是逼着所有的专家，你得大快速的把你的经验给写成落到纸头笔笔头上，落到这个文字上。然后你们赶紧沉淀下来，供我的A卷来去调这样一个东西。

所以我觉得可能有一个机会是什么呢？短期的一个机会，就是你想你要去会写markdown或者习惯写marker down。写这种玩意儿的人其实并不多，对吧？那你是不是可以做一个小的APP，我专门按照这个skills cloud skills的这样一个做法来去生成，就是规范来去生成cloud skill的一个界面，做一个小应用来去帮助这个人来去生成它，那这个界面就可以做的非常的友好了。比如说我做一个纯靠人说的，靠语言来去说的这么一个应用。然后他说我哔哩吧啦说1个小时，然后完了以后有来有回的说1个小时以后生成这么一个skills OK了。

对，最终的目的其实就是确实就是淘汰人家，对吧？因为现在对于企业来说，专家就是最贵的人力资源，那我怎么怎么把这帮人的人力的脑子里的这些经验给抠出来，给显性化掉。然后最终目的肯定是淘汰他们。但是这个淘汰过程肯定很慢很久，所以我觉得倒还好，大家不用担心。

但是这个是一个很直接的一个skills，是很直接一个做法。就是怎么把它掏出来，不需要太复杂，而且不需要非常的规范。你只要按照他这个方式来去写就行了，符合我的一点点规范就OK了。然后就可以把我的专家的经验给抠出来。

对，行，今天就分享这些。今天中间的这个deep seek的这个部分可能有点艰涩，或者我讲的不是那么好啊，所以大家也是辛苦了，把这个听下来了。本来我想讲的还挺多更多，但是你看这几篇paper其实也放在里面。但是后来觉得好像确实这个不是很容易懂，所以这个就算了，听懂听懂太累了，太累了。

好，行，那今天还有什么别的问题没有？没有问题的话，那今天就到这儿。然后大家辛苦了，就晚安，周末愉快。有没有问题的话，大家可以再等等，有没有问题？没有问题了，我们今天就到这儿了，下周再见。怎么视频又没了？好，下周再见，拜拜。