

好了。开了是吧？是的，那你开开了吗？喂喂喂，能听到吗？hello。

大家好，我开始了。对，大家晚上好，又来了。对，本来这本来今天想讲那个继续讲那个后面的就是这个AI加军工的这个第二期的。然后这周不是这个手豆包，手机加上这个质谱也发了好几个新的模型，然后其中有一个很重要的就是auto GM。然后这个发了以后，我就觉得还是讲一下这个方向。因为所谓的这个多宝手机和auto GM这类的东西，其实都代表了一个很明确的趋势。就是大家逐渐的认为agent操作我们的桌面或者操作我们的手机这事儿快成型了。所以其实这是一个挺好的一个时机点就给大家来去讲讲这个里面的事儿。

那有个问题，浏览器上AI插件能做到分析网页内容用的，我用的是这个Monica，然后基本上现在都可以。比如说我们随便打开一个网页，对，然后Monica就这个东西一点开就是右边这个东西。当然如果你设的中文的话，他出来的应该界面上也都是中文。

然后比如说我想说这个页面，你看这文章还挺长的这么个东西，我想让他给我总结一下，然后我就点这个chat with this page。如果中文的反正就是跟这个页面聊天。如果我就只想做一下总结，我就点那个summary，然后他就开始。因为他知道你当前开的这个tab是哪个网址，甚至这个网页的内容，它其实也这个插件也直接能拿到，所以直接给你输出了。然后把你这个用中文，比如说他给我上面这玩意儿肯定是个英文的，然后等他输出完了。对，然后就开始等于是用让他用中文给我总结这篇文章了，可以拉开了。

你看这就是总结这个对于中国应该买hoper，然后这个东西这样的总结，对，所以挺好的，挺好用的，而且你可以选不同的模型。你看它的Monica有一个官方的模型，也不知道它的后面用谁，可能是一个一堆动态路由的这么一个。然后你也可以选这个GMA3 pro GPT5.1乱七八糟这些模型。基本上头部的模型都会在发出来以后几天内就会集成到Monica里。当然猫卡为啥我选他呢？

是因为之前好像今年年初有一次这个大促很便宜，当时他卖一年卖多少钱来着？反正便宜到账，就我我就我就一次就买了一年，所以后来就一直在用莫妮卡。当然它的模型也都还比较新，所以这个可以用这个，然后免费的也能用，所以只是用的模型和那个量会少一些，所以我自己用的这个。而且Monica大家知道听过的主要这个menus其实也是Monica这家公司孵化出来的。所以这家公司的工程能力是挺挺不容置疑的，还是挺不错的对，所以是the master。

你的想问的是不是就这个是不是就这种插件？对，好，然后如果说你这个分析网页插件，同时我就再说一下，就是大家一定要装这个沉浸式翻译。这个沉浸式翻译非常好用，而且这个使用的功能还挺多的，而且持续的越来越好，免费的也可以用，然后开就是付费的话，它能用这个比较强的几个模型，比如说DPCDPCV3这样的几个模型。

好，那我们开始。是不是这个意思？我看这个master这个同学，好，我们开始。第一个其实就看到美国放开了这个出口HH200不是对H200这个GPU，然后他还不是一个很单纯的只是放开，为啥呢？他因为他要收25%的这个费用，25%会配给美国政府，来去支持什么的乱七八糟美国就业乱七八糟这些东西，这东西其实也不出意料之外。

之前我不知道还有没有同学记得我给大家讲过这篇文章。这在之前有一个有一篇文章其实就讲了这个事儿，就是嗯哎应该不是这个时间，应该更早的以前这篇文章我就发了。就是当时开始研究这叫IFP这个组织，研究说到底应不应该卖给中国，所谓的传闻的B30A芯片这个芯片，然后因为当时说有可能会放开这个更高阶的芯片就是这个B30。大家知道这个NVIDIA的芯片其实就分hoper是基本上现在最两三年前的技术。然后再往后就是B系列，然后再往最新的就是Robin的这个系列。那张图当时有传闻说有可能会放开B系列的，但是给一个中国特供版的这个B系列，然后就开始说那B系列的到底有多强，有多少问题，这些东西就开始这儿就有一篇文章专门讲这个事儿，就是如果出口了H2020给IA如果出口了B30A的话，那会发生什么情况？前两天特朗普又宣布了

放开了H200以后大家至少说H200这条路子是放开了，那大家这篇文章就又更新了一下，之前那篇文章我找不太到，反正就核心就是这个部分大家可以看，又没了。

这对其实有时候不得不服佩服老美的对于各种事情，尤其是这种公共政策，地缘政治这方面的研究的细化程度，你看他会研究的挺量化的。比如说如果没有任何一颗美国的AI芯片运到中国的话，那整个的市场将会是美国的。美国会是中国的大概9到11倍。这个就AI芯片的算力的使用量，算力的拥有量其实是这样一个比例。然后如果说稍微放开1点H200的话，会变成什么呢？会变成美国是中国的3到5倍的算力。然后如果放开了比较松弛的放开这个H200的话，可能是2到3倍。如果这个比较激进的放开，基本上中国可能就跟美国的这个算力的量其实差不太多了，就是评分就一点几倍到2.2倍之间。所以这个分析的很细。

然后里面就在讲说各种的H200、B300这样几个芯片到底跟中国的就国内的几个巨头到底性能怎么样这样一个对比。所以这个其实是大家之前也已给已经给大家讲了，说整个的这个芯片市场确实是一个中美对抗的非常厉害的一个市场。但是有特朗普的这个就是搞事儿，那我觉得其实中国的机会可能更大一点。

好，然后这个是一个。第二个是大家知道桥水吧，桥水基金。对，然后那个桥水在后面我们先看这个，这个是什么呢？有一个哥们儿做了这么一个东西，做了这么一个东西，能看到吧？对，有一哥们儿搞了这么个东西，就是想有一个国外的一个很著名的网站叫hacker news，一般简称叫HN然后这个上面的内容都就是高频的那个内容都质量挺高的，非常高。有一段时间，就前两天有一哥们儿搞了这么一个东西，叫十年以后的hacker news会有什么样的新闻？就是让GMI3GMI pro 3来去想象一下这个网站，这个hyer news这个网站。

你看这个news网站就很很单纯，就这么样一个东西，如果放在国内的各种互联网网站上，就感觉就是太简陋了，对吧？你看点开，然后点开就是一个，不是这个这个正是这个正经的对，然后。等一下，是不是点错了。对，然后点开就是一堆新闻里一堆帖子。你看就这个帖子样，我感觉还不如百度贴吧那个贴吧。但是就有人搞这么个东西，就说我未来到底十年以后的hacking news这个网站会讲什么东西呢？所以样子不重要，关键是你看jim s3 pro它会想象10年以后的这个hacking news，大家会在讨论啥。你看比如说他会想象说星际飞船什么在宁静海首次传回来数据，然后linux 7.4正式合并rust对吧？

就是大家可以想象linux是一个可能人类灭绝了都不会灭绝的玩意儿，然后这个在隐形眼镜上去用，wasn't运行这个拉玛127B的模型，这玩意儿这个东西就是一个可以把代码跑得非常高效的这么一个底层的语言。然后跑这个拉马开源模型对吧？这样的一些东西，什么热核实验，然后这还有一条叫google终止了gma云服务，对吧？这个怎么想的不知道，这是gym 3 pro自己创建出来的一个未来的这么一个hacking news，那挺有意思的对吧？就是你从这个上面能看到很多模型对于未来的这样的一个想象。

好，这事儿过了大概两三天以后，卡帕西capacity android capacity这个人大家非常熟悉了？发了一篇帖子来开始讲什么呢？他发现这个hacker十年以后的hacker news这件事儿非常有意思。但是十年以前的hack news里面的那些讨论，到底有哪些靠谱，哪些不靠谱？这件事儿其实现在我们是可以做评价的了，可以做评分的。

好，那他就干嘛了？开始自己y coding的一个程序。这coding这个程序干嘛是抽2015年12月份hacker news上的930篇文章。为什么930天30天就是30天乘以这个多少来着？每天每天31篇文章，反正就这么多。然后抽这么多文章，然后拿GPT5.1来去反思，来去评论，就说当时的这篇帖子到底靠不靠谱，然后这个人的评论到底真的还是假的。

然后这哥们儿花了多长时间呢？花了3小时coding，然后花了因为他用的好像是SR pic的OPPO4点，最新的一个OPPO4.5来去跑的，所以花了60刀哼来去跑，当然这些人大概率都不是自己去花钱买API的对，然后搞出这么个东西。所以相比刚才这个就是我们让模型去想象未来会怎么样。其实他认为什么呢？更有价值的是我们回

顾以前，到底大家是怎么想象的，怎么评论的，怎预测的。然后我们在十年以后或者在一段时间以后来去反思，来去回顾一下，看到底当时谁最牛，谁评论的对对吧？

所以这一件事情就是capacity开始干了，这件事儿我觉得非常有意思，就是大家会看到，大家想一想但凡你去在比如说在各种的什么论坛上，在这个贴吧里，乱七八糟跟人PK，肯定大家都有这种经历。就是我们去PK一些反正毫无价值的东西，或者说几乎就没有什么可验证性的东西。然后回过头来我们说你说的对我说的对，大家都没人不在乎你说的对我说的对了，那就很没意思。那如果当时我们比如说我们争论的一个东西，现场就打赌，打赌完了以后，你过个几年以后再来看到底谁组的对，那这事儿其实就有一个很好的反馈，所以这件事情是一个很卡帕西觉得是一个非常有价值的这么一种行为，所以他就开始搞了这么个东西然后他写了篇博客，关于说怎么总结的，总结了以后的结果咋样，挺有意思的文章。

比如说你看这个，他怎么做呢？其实就这么做的，就是用5.1来去思考当时的大家的怎么想的。以及因为现在已经十年了，所以他这个模型，甭管是模型自己还是用这个搜索，基本上都能验证当时大家的一些想法。所以他靠当时大家的分析，大家的想法，以及事实上到底发生了什么，来去看到底每个人当时的思考，当时的这个推理到底靠不靠谱，然后结合当时的实际的情况来去分享。对，所以就搞了这么个东西。然后结果挺有意思的，他能把当时的所有的这个结论都能分享很好。

我看当时而且他还能总结出一个什么？总结出一个这个东西哪儿去了？对，这个弄了一个hacker news的时间胶囊这么一个东西。

然后这个时间胶囊你就可以每天总结出来，看当时的这篇文章，大家分析的怎么样，大家这跟事实的结论差距有多大，然后再点的怎么样，这些太详细了就不看了，还核心是这个东西，他弄了一个名人堂，就是这个家伙的评估或者他的当时的这个反馈是最对的，或者说最有价值的这么一个名人堂。然后这名人的网页我每次开的时候经常就挂，就是让我当前那个tab就挂掉。所以不知道为什么，可能这网页网这个程序写的不太好，就看一下。

对，你可以看到一下什么？就比如说第一个人他还打了分，叫A减3.83分，已经非常高了。然后他做的是什么呢？SOHO什么，我去对，然后你看这就是web coding的问题。White coding出来的网页，你说它没问题，肯定是看着样子没问题。但是实际上比如说你要考虑性能，考虑这个网页的质量，程序质量的话，那就别考虑了。所以就只适合做这种很有意思的这种小的实验。

你看这个排名第一的是谁啊？这个讲什么来着？讲这个server是一个浏览器的组件，然后讲够的够语言的，讲swift的什么by assembly的swift这样的一些东西。看起来是一个叫什么底这个底层大佬对吧？就是写写这种很基础的很底层的代码的这样一个大佬。

然后第二名其实也是类似的。你可以看他解释一个做安全做渗透。你看做网络安全的做这些的，做攻击做防御的这样的一些人。所以前面几个所谓名人堂的被评分事实，被模型认为是好很牛逼的这帮人基本上都是这样的一群人。所以大家如果看到身边有这个写底层代码的大佬的话，可以假设还是挺靠谱的。因为确实这帮人很有逻辑，然后这个就是卡帕奇的做这个东西，而且他还把自己的东西给自己写这个y coding代码给开源出来了。然后写了这么一个github的一个网站，当然他前面写了说这玩意儿是我web coding出来的，所以我对这个代码不做任何的维护，就不维护他就OK了。

对，好，然后另外一个比较有意思的是这个是剑桥的。就是大家看看这种文章具体内容不是太重要，具体这个核心是什么呢？你看看这帮非传统意义上的计算机专业的名校的人都在研究啥东西，对吧？你看剑桥其实已经在AI领域，就是在在大模型这个圈子，其实很少，这方面的东西不多。但是他们的依然能做反而还不错的研究。你看都研究啥？

研究agent在劳动力市场中，这个竞争性主体的叫什么战略性自我完善自我计划。这样一个东西啥意思呢？就是他造了一个零工经济的平台，叫做什么来着？Ai啥来着？AI word还是叫什么东西？对，VI work，对AI work这么一个事件。这个市场其实就是有一大堆A站在里面找工作，然后挣工资挣钱，然后也不叫挣工作挣钱，然后也可以干嘛呢？也可以不去干活，去选择自己培训，去选择读书自我进化，自我提升。

然后这个劳务市场或者这个零工经济市场，有很多自己的因素。比如说宏观经济因素，有客户向的对吧？客户想想有没有钱，或者有没有想要什么样的一个reputation的人，这样的一些东西，或者有职位上的一些不同的求职平台的这些差别，这就是劳务市场。每个agent就是在里面扮演那个求职者干活的那个人的那个agent也有自己的一些策略，非常多的策略。

比如说他不同的技能的水平怎么样，然后他在市场上的这个声望怎么样，就是靠不靠谱，然后他自己的收入乱七八糟这些东西。并且他还能观测到其他人对于同一个活的这样一个叫什么报价这些东西。然后让这些agent能够在一个零工市场经济里面互相的博弈，然后博弈完了以后，看哪一种策略的agent能活得最久，然后赚的钱最多。

说白了就是研究这种东西。那你想想这个东西它跟模型真的有那么强的关系吗？其实并没有，对吧？那我们其实更多的是啊这种研究，更多的是研究说不同的A的策略在这样的一个市场里面到底能怎么互动，怎么存活，或者说有什么样一些相对竞争优势，所以他们就研究这个东西。所以我觉得这个很有意思的一点就是我们发现在模型领域，最研究最核心的模型，训练模型推理这样的一些框架。这些人其实还是那么多，或者说增长的有限。但是它给其他的研究领域带来了非常多新的。

机会或者叫坑。一般我们叫坑就是来了个新技术，然后对所有的现有的这个研究领域都可以有一个交叉点。这个交叉点就是一个坑，就是你如果做学术的话，你就应该立刻跳到这些很火的话题里的跟技术交叉的这个坑里去。所以我不知道咱们群里面有没有同学是做像这个公共管理、经管，或者像这类的非技术类的专业。我觉得这个是一个挺值得参考的这样一个文章。并不是说这个内容多重要，核心是你可以参考他的方式来去做你这个领域的研究，把你的领域的坑给填上。

对，然后这个是剑桥这个东西。然后另外就是有一个叫AAIA的玩意儿，AIA的这个关系。AIA是什么呢？是bridge water的这个AIA lab。Bridge water是啥？就是桥水，大家知道那个桥水基金那个玩意儿，那这个东西对吧？就是他们搞了一个AIA的这个东西是干嘛？是AI什么来着？A agent什么的。

然后forecasting就是预测器，预测者这么一个研究。这个研究就跟咱们之前每期几乎都会提到的预测市场是完全是一样的。他们做了一个研究是干嘛呢？是证明了现在的agent来去做预测这件事情，已经几乎跟人类的所谓超级预测员，就是很预测很准的这帮人类的专家们几乎不相上下了。就已经在统计意义上无法区分出来太大的差异了。所以就是这么个东西，这么一篇研究。所以我觉得这个事儿也是对应到我们这几两个月2 3个月一直在讲的预测市场和御用agent来去做预测这件事儿的一个趋势。我觉得非常值得大家关注，以及反而放到自己的领域里面。

这样的一些事情就是如果我们看到agent它在某些领域的预测已经达到一个人类的级别的话。那很容易想象的什么？就是这个领域里面的跟钱相关的各种事情，很快就会把这种预测的这种agent能够融入进去了。

但是它其实并不是一个预测所有类型的事情，你看它主要预分预测分2类。一种是基于结构化的数据，其实就是数据库，结构化表格那种东西来去做的统计预测，这个大家很容易理解，就是说我现在的数据是这样往上走的。那我预测一下明下一次是什么，这肯定是靠一些量化的模型来去做统计性的预测。

但是很多像，之前给大家不断看的像Polly market这样的市场，这种东西大概率都不会是统计型预测的结果。比如什么呢？比如像这种open I下次发布新的前沿模型会是哪天，今天和明天december 11还是december 12，我靠，现在大家都在猜december 11，那就是今天呗，就是再过个几个小时呗。对，所以你看这个值基本上大家都波动的还是很明显的。就是一旦说有一个值，因为这个上面是大家拿真金白银投的，是拿8273的这个美金去投的。所以这上面的这个预测的结果大概率还是OK的。而这种网站上能一直玩的，或者说玩一直玩下去的，肯定选手还是这种专业的预测人员，要不谁整天在往上亏钱的对吧？

那回过头来就是更多的这种agent驱动的这个forecasting，就是预测的这个agent其实都是针对后者，就是一种我要用大量的外部信息，通过大量的推理来去做出的这样的一个预测。所以他就是桥水做的这个研究，他把整个的agent做成这么一个东西。这个其实跟我们之前讲的结构也很像，而且这个结构大家其实真的可以放到自己的这个业务里面去尝试去做，尤其是这种预测性质，比如说什么这个就不瞎说了，比如什么大豆价格，乱七八糟这些这些东西你看他怎么做呢？

开始收到一个任务，一个问题，比如说川普会不会换掉鲍威尔？2025年底之前，对，会不会换掉鲍威尔？好，那这个问题会干嘛呢？他会产生好几个agent，spin up multiple agent，然后这些agent会以不同的方式去分析这个问题。

每个A政会干什么事儿呢？你看会先搜信息对吧？你看鲍威尔这一届会什么时候？叫什么退休，反正就这个东西。从外部的网站上搜一些回去搜一些东西。然后这块儿有一个词儿叫gentle adaptive search，啥意思？就是这个部分它会不断的思考出来，我现在要不要点外部信息，要什么信息，然后自己去搜搜完了以后回来再想，这些信息我还需不需要一些其他的信息呢？如果再需要的话再去搜，这种就是我们什么时候搜搜啥东西，完全靠模型来决定的，一般都叫做agenticity这样的东西。

好，搜完信息以后开始预测，预测完了以后做一些校准方面事儿。然后这个东西其实会是每一个agent都干的事情。所以你看这marty agent说白了就是有好多agent在走这个流程，那可以想象可能有N个臭皮匠对吧？不断在通过这个流程去思考。然后最后把每一个臭皮匠都思考出一个结果以后，开始叫reconcile，把各种不同的预测来去综合起来，然后他就干嘛呢？他会有一个单独的一个叫什么coalitions or叫什么主管这个agent，supervisor agent拿去干嘛呢？

再去综合这些手下这帮臭皮匠的想法。他会开始想他主要的考虑是什么？考虑是不同的agent他们的结果，比如说2A证的跟7A证的，好像在这个法这个会有多少法律障碍上面会有一些分歧，为啥呢？他自己也会去搜或者做一些自己的判断，最后综合出来以后，最后一个得到一个最后一个结果这样一个东西，这个东西的整个的效果就是刚才说的这样的一个就是它所谓的AIA的预测器，就forecasting这样一个agent来去干的事情，结果怎么样呢？

这个领域当然也有这个benchmark了。这个benchmark forecast bench很直观，就是预测bench这个横轴是这样，横轴是预测多少次。对，说白了就是类似于说我要跑多少个agent，同时跑多少A的。纵轴是啥？反正这个分越低越好啊，这样一个东西是越低越好还是越高越好？懂了。对，应该是越低越好。

对，然后结论是什么？当你看这个越预测的越多，当然其实你要比如说跑18个A阵跟跑48个A阵其实差别不大了。就是因为可能一个问题该有的思考维度都被agent思考完了，那你再弄800个agent其实也没啥区别。

最大的降低的部分，就是提高效果的部分就出现在这儿。你看从一个到比如说到18个，或者到12个，到15个区间。这块开始是一个最快速效果变好的阶段，然后再往后其实就没太大区别了。所以从这张图来看，基本

上到了15个臭皮匠的时候，就跟诸葛亮差不太多了。

对，那怎么叫差不太多？就这个词儿，人类的这个选手是啊人类差不多这个超级预测员的这个群体的中位数差不多在0.1。然后在这个AI的这个得分差不多在零点，就是刚才15个臭皮匠差不多在0.107左右，这样一个分几乎就在统计上没什么太大差别了。甚至有点优于人类这样一个效果。所以后来他还做了一些比较复杂的叫什么复杂的benchmark，就是这种很快速变化的这些领域的预测。

比如说什么政治、金融科技这些领域。然后他还做了一些什么实验呢？就是把人类的预测源跟那一大堆15个臭皮匠绑到一块儿来去综合预测结果，分儿还高于单独的人类的预测源的水平。所以说白了是证明了什么？就是证明了这种agent的预测源，它的预测的结果对于人类的预测是有高价值的，或者说有增量价值的增量信息的对然后它里面后面讲讲了一些别的，就是这种系统它很关键的几个因素是什么呢？比如说搜索质量，这个大家比较容易理解对吧？就你搜的结果都是垃圾，那可能预测的结果反而更不好。

统计校准这有一个很有意思的一个点，是什么呢？就是人类模型对于一件比较确定的事情，他给出的概率评价其实往往更偏保守。这玩意叫对冲，它的hedging这么一个效果。就是本来这事儿是板上钉钉的，结果他还往回缩一缩。或者说本来这事儿是瞎扯淡不能实现的，他还往上说，有点概率。所以对于这种模型的这种hedge，这种对冲的倾向，他就给出了一个叫polite scaling的这样一个算法。

说白了就是把这个概率极端化一些，就比如说你说这玩意儿，这个太阳从南边升起的概率可能有多少呢？他说可能有个0.1%他就咔极端化一下变成0。或者说变成一个更小的。然后你说明天比如说前两天马克龙就来北京了这件事情，比如说明天会来这件事儿概率大不大呢？会不会一定的成呢？其实几乎不是板上钉钉的，但是他一定往回缩一缩，说是95%概率，然后他就做了这么一个极化的效果，其实反而效果更好，对吧？

这个大家对于预测来说确实是啊就是预测这种事情就不能太叫什么呢？太太中庸就是你说一个事儿，这个一定得是哎也行，也差不多。这事儿就不是一个预测员应该有的这样一个品质，我看看能不能找到那个例子。

对，你看比如这个东西，主要追踪美国国内发行的什么，美国的债券表现什么ICE的回报率会是不是会有所上升。这件事情其实其实概率非常高的，就几乎是正确答案是1.0必然会。模型就会往回找吧，他给打了0.6其实很高，还有一些比较低的，等一下，那算了，这个就不说了，反正就这个意思就是作为一个优秀的这个forecasting预测员，应该有一些专断的能力。

然后最后一个，其实就是就是说这个预知偏见就是其实有一些结果，有一些搜索结果里面其实包括了有些预知偏见，就是我们拿回来的，我们做的预测其实已经被训到了模型里，或者说它模型拿到工具去搜索回来，结果里面有预测的结果了。所以这个时候就代表了所谓的叫预for的知识的偏见，对吧？就是等于说因为你知道了这个事儿肯定会结果是什么样，所以你答的结果是有有偏见的，说白了就是你已经知道结果了，所以他做了一些校正校准这样一个。所以这个是桥水发的，我这个倒是真的第一次见到桥水AIA labs发的这样一个文章。那也很很符合桥水的这个角色，就是做金融的预测了。所以我觉得这个方向是一个很明确的，大家已经可以可见的是一个很成型的一个预测市场的一个方向。

好，infer方面有两个文章我觉得比较值得说，但是有一个文章是open l的。关于企业里面采用AI的文章，我觉得可能对于咱们在座的这个在在在在线的同学可能意义都不大，这个我就选了另一篇，就是open router的一篇基于，大家open roder，这个也给大家讲过，就是一个你可以只接他们一家，然后他就可以帮你接各种模型，你只接他一家就OK了。比如说你要接这个GPT，同时接games，接cloud，接这个质谱的模型都想接。那你与其去写一大堆不同的各家平台的key和地址，你可以直接open root一家。然后你只要改这个模型名字就行了，他帮你去接各家的模型，很方便的一个平台，然后基本上是开发者的。如果你开发者作为开发

者不想去接一个特定的模型的话，你就用它来去接就行了。他还能给你提供很多别的服务。比如说万一有一家挂了，有一家推理的供应商挂了，他可以帮你自动去找同样能够推理这个模型的别的供应商。

大家可以想象这么一个等于是一个路由器的这么一个网站，它就是大模型路由器的这么一个网站。那他其实可以收到的需求，收到的这个大模型请求的需求就极其多了，对吧？就是非常大量。所以他自己的数据非常多，他搞了一个基于100个train token，就是一个trAiling就是1万亿，就是100万亿token的这么一个研究。那基本上也就代表了一个挺权威的这样一个结果了。

所以我们看看它里面有一些比较有意思的一个结论我的评论。稍等，都不出来了。对，我们直接看吧。我的我的笔记咋不出来了，太多了。对，稍等我把它翻一下，我们直接看吧。首先开源模型，闭源模型这个后面有一个数可以看到。第二个就是所谓的agents的in inference，就是用工使用工具的这种推理模型推理，现在是一个非常快速增长的。然后按照分类上有一些特别的，然后按照地理位置有一些不同的统计，我们直接看看表格。

对，这有几个点，就是其实整个的模型领域里面就三个玩家，当然美国肯定是最核心的。然后它里面有一个中国的模型chinese model，还有一个叫ROW的，是什么玩意儿呢？是世界其他地方叫rest of the world。就是世界上只有三个人在玩大模型，一个是美国，一个是中国，还有一个是其他。对，但其他大家不要小小忽视，其他的那个量其实也在涨。

然后从地理位置上，从时间上，你可以看一下这个样子，这是开源模型跟这是从开源和闭源分布，从开源模型和闭源模型的使用的量来说，你看从总共的token量来说，还是闭源模型占绝大部分的这个比例，基本上占3%分之2以上，差不多3分之2这样一个比例。全是用的闭源模型，就是欧佩拉什么的cloud这样的一些模型。这个部分是中国的开源模型，就这个浅蓝色，然后中间的这个蓝色是世界其他地方的开源模型，所以中国的开源模型占了大概20%左右的量，增速还是很明显的。

是什么时候开始？你看就从今年的一月份开始，说白了就是deep seek r one带来的一个影响。从年初的从去年年底几乎就看不到这个浅蓝色，然后到今年年底基本上到了百分之接近20%的比例，非常快速的发展了。可以说是啊这个是对，就是纯按照这个量来说，刚才这个是比例，这个是比例，这个是使用的比例。大家不要觉得这个东西咱就一直在涨，核心是什么？是大盘子在涨。你看整个一年的大家在使用的总的token量是一个非常急速的增长，就是十倍，都不止二三十倍的这样一个增长。然后其中的那个闭源的部分，就是红色的部分还是占绝大的头了。

然后中国的开源模型已经占到一定量了，你看但是也没有非常多，大家不要觉得在全球的市场上来说，中国的开源模型还是少数的。然后全球的别的地方rest of world的开源模型已经也占了13%的，这个市场也不小。对，就是中国比世界其他的部分开源模型的量还是大的。但是俩人加起来，两个所有的开源模型加起来跟闭源模型还是明显的劣势了。

那谁在在open l open router上用模型的这些token量，尤其是开源模型的量，整个大家都在用谁呢？你看这些玩家，第一的是绝对没有别的可比的，就是deep sick，15万亿token。然后第二个才是千问对，然后拉满的miss说其实不少的，你看整个的这个三个就是在整个这个里面其实还是还挺高的。所以法国还是欧洲还是有人的，就只有miss说，对，然后这个open l mini max z就是质朴的A质谱AI跟mini MAX差不多。Kimi然后google还是有开源模型的，塔基的。

然后整个从量上来看，有一个很明显的它叫deep seek decline。就是什么呢？就是从年初开始deep seek暴增。你看这个蓝色的部分，就是深蓝色、浅蓝色部分都是deep seek，就是TNG这个trend a deep sit的RY和这个deep c自己的V3.1V3RE加起来这个蓝色的部分加起来都是dept sic的。从年初的几乎占了80%的开源的



量，降到现在只有50%差不多50%这个量，但是为什么降了这么多呢？是因为其实有非常多的别的开源模型也进来了，比如谁呢？

你看这这是mini max m2，然后这个粉色的是K2月蘸面，所以大家这个就真的使用来说，虽然像大家说kimi我上上节也讲了这个kimi有一些做题目有意思的一些点对，但是从量上来说，尤其是国际开发者来说，像mini MAX，就是k two，其实k kimi其实没有太多。然后这个加起来，你看国内的这个三个开源模型了，四开源模型，千万，梦想，就是kimi，m2。然后质谱加起来，其实跟之前的不算差太多，几乎还是平齐的。你看这个加上这个，把其实主要是把这个白色的mister去掉，那其实跟之前的量差不太多。所以整个的从开源模型的使用量来说，中国还是非常高的。而且只是从年初的DPC1家独大，现在变成了四五家，这样一个分庭抗礼的一个阶段。但是整个在open rotor上用deep take还是很多的。

对，然后看看还有谁，这个对模型的大小，其实也挺有意思的。就是大家开始觉得有大模型有小模型对吧？但是其实大家看这个整个使用的趋势，从年去年年底，这个蓝色的代表大模型，绿色代表小模型，红色代表中模型。这个怎么定义的呢？就是小的就是小于15B的，其实也没有很小对吧？然后中的是啊15B到70B的这个size其实非常好。之前给大家说过好几次，就是为什么我推荐那个AMD的什么AI max那个那个机器，就是因为它能跑这个中size的模型，而中size模型在这个里面是一个非常快速发展的这样一个比例。

你看这个从开始年初或者从去年年底，大家用小的，大的就是70米以上。从年初要不就用大的，要不就用小的，你看要不就是蓝的，要不就绿的。到今年年底变成了一半用大的，几乎接近另一半的，一半用的是中等的。比如百分之看起来有20%多，这样一个比例用中等size模型就是几十B这个size的，然后只有很少的变更少了就采用小的。所以这个几B的模型越来越不受待见。

说白了就是中等模型的大小越来越受待见，也对应的是什么呢？对应到我们最近反正这个摩尔县城不是刚上市然后摩尔县城本身的这个芯片，待会会有没有，反正就是模式现成的芯片跟升腾的芯片，其实很大的一个它们的主要的内存大小的区间基本就在几十GB这个size的这个大小区间，也对应了他们主流的想去推的这种模型的sas。所以其实几十B这个SARS是一个很好的一个就是中几十B的这个sze是一个特别好的一个大小。然后大家如果选模型的话，其实也非常建议选的。你要么这种贼大的模型，就是用这个几几肾上T的这种模型，就是万亿级别的模型。你要么就用几十B大几十B这个size的模型，其他的模型其实都不太，或者说大家普遍大家越来越不看别的size模型了。所以要么就用中大大强大模型，要么就是变成一个中型的所谓的新中型模型。

好，这就有更有意思的点来了。大家在用大模型，开源模型在干啥？这是一个关键点。就是大家总觉得好像这帮人用模型是不是都在做一些很严肃，很偏高科技什么的这些事儿呢？不是的，事实上并不是的。你看一半的人都在做什么，他做了个分类，分类的这个主要就这么几种，什么marketing，就是市场法律、健康、学术，什么什么乱七八糟，programing写代码科学和row play，对吧？

肉play是啥意思？角色扮演大家可以想象是干啥，对吧？那多少呢？比例是这个样子，有一半流量都在做row play，有一半流量而且这个量在今年年中的时候更高。80%的用开源模型的open rotor上的访问都在做row play，都在玩role play的这个角色扮演的行动。行，就什么这个任务。

大家可以想象这个互联网领域的流量一半都在干啥呢？大家有没有知道的？尤其是在互联网初期，互联网初期一半的流量都在干啥？大家有没有知道的对吧？就是都在这个看片儿对吧？那大模型领域其实也差不太多，所以就是row play大家就能理解这个里面是干啥的。之前也给大家介绍过几个这一类的产品，其实都是这样的事儿，我觉得没什么可回避的，这是大家的切切身需求，而且这个领域发展的非常快，所以当然在国内不允许真干。但是如果大家去做出海的话，这是一个非常好的一个场景。



然后当然他会因为中国的开源模型特别的猛，所以他专门做了个分类。什么呢？中国的开源模型大家都在用啥？用来干啥呢？你会发现什么row play降到了33%，就是全球来说是50%，然后中国33%对吧？那好像挺正经的正中国的正经人多一些。

还有什么呢？就是第二大是什么？是这个紫色，紫色是programing写代码对吧？你要不就在聊天，要不就在写代码。中国基本这两类加起来占了60%多的需求量，然后其他什么搞science甚至就不管了。对，所以这个总说白了就是中国的模型用来去做row play的这个量其实反而在更少。

所以我觉得这个其实有点问题，跟后面的结合一下大家会看到，开源模型里面用来写代码的其实就不多了。大家都在用闭源模型，主要都在用闭源模型写代码。所有的中国的开源模型加世界别的地方的开源模型，用来写代码的可能也就10%，总量10%。

那必然的模型肯定就是什么cloud这样的一些模型来去写代码了，对这些东西如果纯按照row play这件事情来看的话，那在不同的模型上的使用分布是这个样子的。世界其他地方的做replay的开源模型的量占了一半，接近一半43%。然后闭源模型占这么多，中国的开源模型用来做replay的并不多，看就这么量。所以在replay这个领域里面，大家可想象世界其他地方的开源模型的量那么大都是在干啥，对吧？就很很明显。

然后底下就是所谓的gently，就是用来使用工具的这个模型越来越多，或者使用推理的越来越多。这个量确实涨得非常快，基本上一年涨了大概得有个一倍。就是从几乎没有推理的这个量一直涨到100分之6，接近60%的推理，token全是废给这些不产生这些结果的这些推理过程，但是整个推理的结果准确率也变高了很多，这是好的方向。对，然后工具使用就不说了，然后谁用来去做这个工具调用最多呢？那肯定是我写代码或者这个所谓的agent能力强的一些模型，这个so就是cloud的模型。

提示词也在猛涨，对吧？你看从最开始的年初基本上只用一千多个提示词，年底我靠变成了五千多个6五六千个提示词。为啥有这么多提示词呢？大家不可能整天？我今天聊一句说十个字，结果明天我就要聊100个字了，那人都看不过来。

其实主要的原因还是呈选，就是写代码的这类的这个programme这一类的提示词带来非常多。你看其他类型的几乎提示词长度没什么太大变化，就这条橘黄色就是programming，疯狂的上涨，就是模型里面兑给模型的代码贼多，然后一次扔个什么两三万的这个token都很正常，然后一次让他写个代码出来，这也就代表了说我们现在为什么coding能力越来越强。当然了就token太多了。对，这样的一些东西，其他的我看看，这些就没啥意思了。

对，然后底下有几个点是什么？就是他分析了不同模型都在被开发者用来干啥，其实还挺符合大家的刻板印象的。你看这个and shopping用来写代码为主对吧？60%百分之对60的量都是在写代码，google相对来说比较平均，它是一个啥活都大，大家都在用它的这么一个模型。

然后XAI就很奇怪对吧？大家都之前都在programing'写写代码的时候用，最近新增了一些技术类的对吧？大家可以想象技术类的可能更多的还是比如说twitter吧？用到它的这个量，这个role play也变多了，为什么呢？大家记得XAI有一个放开了非常多的限制吧？里面可以聊很多成人向的东西。然后open a相对来说也比较平均，而且尤其是它的programme并不多。

你看它programming ing部分，写代码的部分很少，就相比别的模型比较少，所以当然有它的模型的问题了。对，然后deep seek就比较直接了。你看这个deep seek大块黄的对吧？我觉得这个是文章的作者非常懂中文。这个大块的黄的就都是这个东西，都是肉play，都是角色扮演。千问开始是一个大家不要认为是纯编码

的东西，最近也变得越来越综合了。你看这个编码部分也给它变少，然后金融部分变这么多，不知道为啥，可能是蚂蚁还是什么的，搞的一些这个部分的使用场景。对，所以这个整个的意思还挺有意思的。

他最后给了一个总的用量上的一个比较。你看这个北美的部分还是几乎占了一半，北美还是占了一半的投资使用量，亚洲在非常快速的增长，有百分之二三十这个量。如果按照国家来看的话，中国其实并不是第二，对美国第一。47%全球一半的token就是开发者在open root上使用，一半的token全都在美国使用。然后第二名其实新加坡，我其实挺挺诧异的。当然你想想像minus什么这些公司全跑到新加坡去了也也也也也也挺正常的。没准这9%点里面有一半是华人团队搞的。然后德国对吧？德国这个也挺高的，中国是6，那占比6%。

对，当然我觉得中国是有特殊性的。因为中国的咱们的模型，其实开发者很多都用国内的模型，不通过什么open router去。调国内的模型没必要，所以这个量肯定是被低估的。但是刨去中国以外，其他的我觉得几个的排行的参考量其实可以等几乎等同于说这个国家对于AI领域的支持，或者说大家的AI领域的活跃度。

这个语言分布，当然第一肯定英文了，但是第二是中文也很正常。但是这个量你看英文占了百80 82太高了。对，就中国中文只占了5%，所以这个open router当然还是刚才那个点。就是中文的应用里面大部分的应用其实也都还是用的国内的模型，直接接的国内模型，不会接open road。

然后最后这块我觉得挺有意思的，叫灰姑娘的水晶鞋现象，啥意思呢？就是the glass什么sleeping这个东西，这叫水晶鞋。这个王子拿了一个水晶鞋，看谁脚能塞进去。如果能塞进去，好，那我就认为就是你了这个灰姑娘。

那意味着什么呢？意味着一旦模型在能力不断上涨的过程中，这些开发者不断再去测说到底哪个模型能够很好的干某个事儿。一旦发现我靠这个模型增长的能力真的能干我这个事儿了。比如说我的这个法律文件的精准识别，精准的推理。如果能干了，那很有可能会就会有一大波的这个行业需求就绑定这个模型了。然后这个模型在这个领域里面，再比如说法律，这个是律叫什么？这个法文条规的识别里面就变成了暂时的垄断的选手。所以这玩意儿就叫灰姑娘的水晶鞋现象。

那他用什么来去分析呢？就是来去用叫user retention，就是用户留存。这张图的意思就是用户开始来这儿玩了以后，多久时间多长时间以后会离开，或者说会留下会留在这儿。你看这个就是从百分之百开始摔，摔变少了，变低那说白了就是你能玩你第一次的挺多的是所有的人，然后一个月之后还留着的就在这儿了，你看就20%了对吧？

那这个不同颜色线代表的是不同的时间。你看这个橘红色是五月份，浅黄色的是九月份。说白了就是越偏上面，越早越偏下面。这个黄色的是越新的，也意味着啥呢？就是随着时间越接近现在就越新，用户的留存就越少，留存率就越低，就是大家就越接近现在，越接近未来大家越不会愿意绑在某一个模型上，就这个意思，对吧？你看这个cloud是一个很明显的例子，就是九月份的时候，它的这个跳出或者留存率就已经很低了，跳出率就很高了。

然后第二个是谁呢？GM的2.5 pro这个就很可怕了。你看他在六月份的时候，这个玩意儿是这条红色线，留存率极其高，真的极其高就很可怕。到了十月份还是变成这样了一个其实也还可以了，就是没有很没有跌的很惨，还是比cloud高一点的。所以这个说明了什么呢？说明了GM2.5 pro是一个很不错的模型，至少在当时留用户留了很长时间。然后other flash是open l的。

GBD就很奇怪了，就是一个当然这个轴不太一样，这个可以看到这是一个越偏新的模型。你看紫色的这个最顶上这个留的很长的是去年7月份的，然后最下面的这个是最新的，就是在这个黄色线九月份，然后紫色线呢反而还上去了一点。说白了越偏越最新的这个留存率其实持续在下降，然后其他的也差不多。

Deep seek有一个很神奇的东西，V三这个版本在这个时候还弹了一下，你看到没有？蓝色这条线弹了一下，就是在二月份的时候比3月份的时候留存还低，啥意思呢？就是一段时间以后，大家发现我靠这个这是这有解释，我看看有没有解释。对这对叫回旋镖效应。就是用户发现用了一圈竞品以后，还是deep sit好，所以又回去了。所以这就是这张图的这个V3.20324这个版本的效果，挺有意思的。

Deep seek的这个策略还是挺管用的。就是你甭管怎么着，反正老子这个就在这儿，你试别人的试别的以后后一段时间以后还会回过来会回到我这儿来。所以这几个图的意思是什么？我觉得其实核心的就是刚才我说那一点，你一旦就是这个水晶鞋效应，灰姑娘水晶鞋效应。一旦你的模型在某个领域被用户认可了，那至少在这一段时间内，用户的这个留存率都会变高一些。所以这个有可能对模型厂商的一个意见，这个想法是什么呢？就是你先去解决某一个领域的问题叫first to soft，然后你就可以在一段时间内活得更久一些。或者说大家同类的场景里面的用户，我就会更愿意去这个核心用户就更愿意留在你这个模型上。

对，所以差不多这些，然后策划一些图，这个就不讲了。对，这个是一个特别长的报告，但是我觉得很有意思，这给大家分享一下这个open rote然后底下就快速讲几个模型，一个是deep seek的，不是这边3 pro发了一个叫deep think的模型，就刚刚发了一个叫deep think模型，a deep sink的模型。这个模型非常厉害，实际上很厉害了。你看它的分是什么？AHLE到了41分，比他的3 pro又高了好几分。大家知道HLE这个benchmark一个特别困难，那个benchmark它依然能在往上涨。

然后GPQA就是那个那个博士才能打出来那个那个benchmark的94分已经比他的模型又涨了三。你想90分再往上涨，其实一个挺难的一个状态。最令人惊讶的是这个ARKGI对吧？大家还记得这个RKAGI，叫ark press的这个奔驰车，这个玩意儿就这个玩意儿，这个奔驰他直接比他的pro增加了14分，太可怕了。对，就是接近了一半。

而这个RKGI这个benchmark大家可以看看现在什么状态呢？就在这儿。对，就是之前整个的模型的分基本都差了十分左右，最近这3 pro卡给打到30分，OPPO4.5卡打到了三十接近40分。然后这面3 deep sync直接也干到这么一个状态吧？干到了一个45分，然后这个3 pro好像，这个分儿对，所以就是可以看到咱们现在看到的很多比较困难的奔驰范。可能并不是说我把这个模型一步一点一点往上去，这个分就能一直慢慢的变高。很有可能是一个突破性的变化，是一个质的变化，而不是一个比较平均的一个合法的变化。对，所以这就是这3 pro。

对，3 pro出的这个deep sink这个版本，这个deep pink这个版本大家可以很难用。对，因为他等于你买那个250刀的，240刀那个版本，那才能够用250刀那个版本，才能用这个deep think这个版本。但是我觉得其实有一个很大的一个趋势是什么？就是我越来越不那么早就一旦在非常好的那几个模型的里面去选的话，就越来越不那么在乎说我到底选的是不是更好一点，一定是那个最贵的版本，没那么太重视了，反正只要差不太多，就在那个区间就没有什么可选的了，就是可以随便哪家差不多。

好，这个就开始了。阿联酋也出了个模型，大家知道阿联酋也出了一个模型，不要嘲笑他，这个叫k two v two。你看人家这个宣传都不宣传，三个stars在get github上。

然后这个模型有多大呢？基本上这是个70B的模型，然后这个模型跑了多少，在多少张卡上训练呢？你教大家一个点，就是一般这个开源模型都会发一个训练脚本，就是告诉大家我的训练用的这个脚本是参数是什么样子的，就长这个样子一个脚本。然后在这里面会有这么一个东西，就是多少个node，多少个节点，然后400个节点。一个节点指的是一台机器，那台机器一般来说都是八张GPU。所以这个模型很有可能是在一个四八三十二三千多张卡的机器上跑出来的，这么一个模型叫k two v two。这阿联酋的，看看，这儿有一个比较有意思，

腾讯大家一直都觉得腾讯反正就那么回事儿，整天在后面不知道干啥。然后他们不断的出的一些模型，反而是这种我觉得特别有意思。

比如出了一个叫摩卡的猫卡这么一个东西，这个模型是干嘛呢？直接看图就知道搞这个生成一个3D模型，而且是什么？是一个拆开组件的3D模型。就是你如果默认，比如说我一张图生成一个这样的一个3D模型，这个挺正常对吧？但是这个摩卡的这个价值在于，它可以直接生成一个这样的一个拆成不同组件的这么一个3D模型。那这玩意儿干啥用，很容易想象，3D打印？我只要把这个组件拆出来，然后我就可以去一个一个组件打印了。当然精度够高的时候才拼得起来，你像我猜这种东西其实不太拼的起来，但是我觉得这个方向是很有意思的，就是他腾讯在这个3D建模或者3D打印这个领域，可能还真的是有一个机会。

对，然后另外一个，大家记得这个LM rena吗？大模型竞技场里面最近他发了官方发了一个什么谁又回来了？百度的early。因为LMV这个榜里面其实有一段时间已经见不到early的模型了，就是百度的这个模型叫early。

最近他又宣布说，而你的这个最新的模型又回来了，这个模型是什么？是1103的一个5.0，而你排在哪儿呢？排在你排在第19，现在排在第19。因为他在一个裕裕裕是叫什么预发布的一个状态去放到榜，所以这个排在第19分，有可能后面还会变。所以这个是百度的这个新的模型，那意味着啥呢？可能？百度最近的好像是不是团队又又正常了一点，又开始干活了，又开始努力的往前进了，对吧？好，然后还是刚才的这个Polly market。

最近看Polly market很有意思。有一个文章是这个东西，有一个题目是这个东西叫哪个公司会在2025年底获得一个最强的写代码的模型最强的写代码模型，然后这样一个问题，但是大家不要随便去看完就做决定，核心要看这个东西。就是这种预测市场都会有一个rules，这个rose就代表了说我就光这一句话，其实有很多多的奇异性的。什么叫最强的coding模型，所以这个rose就写的是用来定义这个规则，你看它的规则定义什么？

哪家公司在life bench这个榜里面能够得到到一个在12月31号，是晚上12点的时候能排第一，那这个就是那个答案了对吧？所以life go bench其实才是这个问题的本质，就是25年底在life co bench这个bench 2上，哪个模型会得第一？前两天发生一个交叉，你看这个在之前google其实一直在往前拼，然后在这边三的时候，突然有一个一个超过这个状态，或者说有一个反超的一个过程。这个反而是又被谁超了呢？被s soppo超了，对吧？这个在这是什么时候？

11月底的时候，大家又SRP又觉得SRP又又行了。因为他发了4.5 oppos，最大那个oppos。到了前两天巨大的一个交叉，谁上来了？Open I上来，谁都没想到open I上来了。

对，就是你看之前OPI在这个预测里面基本都趴在底下，没人觉得OOKI可能是个第一。结果到这儿，这是什么时候？是六号的时候，就是一周不到一周前，然后啪就过来了。这个时候大家可能基本猜测的是什么呢？是那个codex max那个模型。就是上次给大家讲那个codex max最强的，就是他发了一个最强的一个编码模型，这个在local life call bench上有一个数据漏出来了，于是一下发生一个反交叉，现在大家还是默认大部分人都认为年底前最强的代码模型会是OpenAI。

对，所以从这种polar market这种市场上你可以看到非常很多的消息。比如说我们现在每周讲的这个内容，其实可以非常实时的反映在这个预测交易的这个市场上。这个赌盘上，说白了就是赌牌，很有意思的一个预测。

其他的就对我们我们先说这个什么，我们先不说后面的东西，我们来说今天的这个主题，就是豆包奥特GM这两个东西，这两个东西是啥呢？对吧？我没找到这个安卓怎么在麦克上投屏的好东西，我就给大家直接看这个机器，这个是豆包出的那个工程机，工程机械。这功能机是谁造的呢？大招那个是。

这篇文章对，这有一篇文章挺有意思，我操过去了。这么巧，微信给我禁了吧。哎呀。从海外访问是不是不太行？没来。

好，对，豆包豆包这个手机是谁造的？是谁来着？操。就是努努比亚对，就这个努比亚。对。那努比亚其实这篇文章里面讲了，其实努比亚就是字节收了非常多当年的坚果手机。然后这里面的人，包括努比亚的一个系统里面，其实也被人挖出来了。里面留了不少锤子手机的这个代码，当年的锤子手机代码。

所以大家说这个罗永浩一直是不在科技圈，但是一直在科技圈就是他的各种的成果，各种的思考。这观点其实不断在至少到现在为止，还不断的影响到整个客圈的很多的大家的想象。对，然后这个东西其实还行，你看他是做这么一个东西，这么一个手机，然后这边是标准的音频键和电源键，然后这边他专门搞了一个按键，这边一个按键是干嘛？你一按它就蹦出底下这个东西可以聊天，对吧？你就按着它就是它的AI功能。

比如说什么呢？帮我去美团看看附近有什么好吃的火锅店，不要辣的。他就开始去找，哪去了？怎么没了？我摁住，帮我美团找找附近有没有什么好吃的火锅店，不要辣的。对他可以看到他要开始干活了，在后台。

为什么在后台执行呢？他在后台执行。对，就是什么呢？是他的在封闭。反正现在各种问题，测的也经常有问题，我看怎么能把之前的功能给关掉。

OK好，such such dressing. 然后他开始创建应用，我怎么能把这个屏幕对老罗配餐太妙，真的是我觉得这个有思想的人始终会有机会的。对，就是root权限全搞定就好了，这是一个点。

待会儿我会说，我靠，怎么还失败了，太不给面子了。之前就还可以的，帮我找一个附近的火锅店，不要辣的。对，你看他现在问题还是挺多的。他会直接蹦出一个这个东西，但我没权限，然后又又给自己改掉了，然后开始说发现你自己有权限了，开始干活，咋咋咋的找，咋咋的找。然后这个事儿，其实他没有直接去给我打开美团，而是直接靠他自己的豆包的这个AI的功能给我输出这个东输出的结果。

因为他能够来，他确实能够拿到这个地理位置的权限，刚才这个同学说就是root权限全搞定就好了，问题是不好搞定，就算你精味精等添加剂，我去相传于线上。对，就是就算他真的能够对，就是就算他真的能够把操作系统这层面的几个，比如说叫什么accessibility，那种权限就是辅助类权限全给他全给他设好。你会发现其实还有很多乱七八糟的这种安卓体系，别的权限也不OK，所以就会导致像刚才那种，我刚问的时候他说我没权限，但是过了一小会儿他又开始说我反正就继续往下找了。因为他可能定位到这样的一些问题，所以他的权限其实也没有解决的非常的完整。但是肯定会比绝大部分这种像auto GMT那个质谱的这auto GM这种会更底层，因为它基本大部分的这个底层代码它都能控制。

老款右边是个游戏键，我还真不知道这游戏键是干啥的。打游戏一键换出游戏，这么硬吗？对，这同学是你是有吗？买过努比亚的手机是吧？

这手机的微信能被豆包使用吗？我看看，我这上面装没装。这样我们试试，打打开微信给方小平发个消息。又没了，你看他这个老师，对他就开始所谓的找消息，然后又没了。对，反正各种不打开微信给，你看他这蹦出这个了吗？叫什么微信，什么实验室功能，现在暂不支持，但核心是啥？就是因为给他屏蔽了。那屏微信怎么屏蔽呢？我不知道在豆包里是怎么屏蔽的，但至少之前auto GM其实是这么屏蔽的。

它其实微信是有非常多的权限的。他能看到比如说你当前手机里装了什么APP，然后装了什么APK，甚至有一些是可以直接把APK拆开，然后分析里面的内容的那比如说我们的auto GM其实是一段比较标准的代码，就是获得到一些权限，然后转发一些命令。说白了就是把用户的把模型返回的我当前这一帧的画面应该做哪个操作，点哪儿，划哪儿这些操作返回给手机，然后以这个APP的身份去执行这个操作。这些事儿代码都会在某一个包名下的某一段代码里。然后这些代码的包名或者它里面的签名，其实在本地应用是可以检测到的。因为之前我也做过一些安卓这方面的，比如说病毒的扫描，所谓的病毒的扫描，恶意代码扫描，这些事儿其实都可以搞。

就是说白了你一个APK1个应用是可以扫其他应用里面的打包以后的代码到底在做什么的，或者说一定程度上能拿到这个数据，或者这个里面的一些关键的词，关键的一些关键的代码。然后这种情况下你就可以去扫，就可以去搜这个东西了。但是我最近发现一个更那啥了，更更可怕的一个事儿是这个东西这个是我自己的手机，然后有一个应用叫joy run，join one是这个东西，一个开源的可以操作手机，用基于大模型的操作手机的一个算是A的框架，开源的这么一个东西叫dream right。他其实干的事情就跟豆包或者质谱的这个GM很像。就是你让他干啥，然后他就帮你操作这个手机，不断的点击滑动，乱七八糟把你的这个任务帮你把这个任务完成。这个事儿，我们可以这是可以跑通的，我看看要不要跑，但是这个跑不跑通先不重要，核心可以看一下我这个屏幕上，它其实是用到的这个安卓的各种的权限。

一个权限能拿到当前桌面上的很多的组件。你看可以拿到这些组件，每个组件的框，那个框其实就代表了一个坐标范围。比如说他实际那个代码里拿的是这个框的左上角坐标和右下角坐标，或者说左上角坐标加上宽和高不就能定位一个框了吗？然后他就可以把整个界面里面的很多元素给标出来。然后标出来你就可以去把这个东西相对来说比较结构化的传给大模型说，我现在用户要我去打开某个应用，然后比如播一首什么歌，这些东西就都可以去实现了，就这么个东西。你会发现普通的我打开一个页面，你看这一框不都能获取到吗？对吧？我都能很比较标准的获取到每一个组件的框。

但是我一旦打开微信打开微信，这就只有一个用户了，只有打开微信什么都获取不到。就是当前每一个应用的每一个页面都叫做一个叫a activity这么一个东西。就比如说当前我这个页面就是一个activity，我点击这个我的这个其实也是一个activity，这都叫activity。但是普通的应用，甭管是这种普通应用，还是比如说像这种我把它所有的应用拉起来的这个列表页，其实都是可以你看都是可以画就是识别到的这些元素的。你识别到的元素，说白了这些字儿，你像这什么setting，这些字儿其实都可以靠代码拿到。但是你进到微信里就啥都拿不到，这里面就是一片空白，啥都拿不到。

对，所以我最近发现我靠这个微信确实非常的狠。他不光是说在检查他所在的这个手机的其他应用的环境安不安全以外，还去做了非常多的。比如说反反刚才我说的这种检测的这样一些行为。

所以这个是一个我觉得确实没什么太大折的这个地方，就是你说像微信这种公司，就是你很难有任何的手段去限制他。所以你像豆包，它真的不能去做这件事儿吗？肯定就不能去。比如说帮我给范小平发个短信，肯定发个微信，肯定是可以的。但是微信有很多种办法能够把这件事情，要不就直接把你号封了，要不就直接？就你根本在技术上很困难能拿到他的这个界面。

好，这个是先说豆包这个事儿，豆包这手机大家有什么想去试的吗？因为我觉得成功率一般没有想象那么高。但是它的好处是什么？就是它里面跟豆包集成的实在太好了，太紧密了。你可以干的很多事情其实都会沉淀在它的这个豆包的那个那个session内。就是你在里面去干的事儿，其实都会在豆包里面也能看到这个记录。

大家想想就是比如说我在这个里面去让他，比如说在美团里帮我找个附近的火锅店，这一个事儿，他其实能拿到的数据是非常的多的。就是我无论是我的话还是他打开美团意思要死了，反正他最近真的是，对他在所谓的理解需求，对，就是到我每一帧我当前界面在做的事情，其实它都能够给我捕捉到。所谓的好听叫捕捉到，不好听叫数据给我拿到。

所以大家如果以后，当然我觉得这个趋势是没问题的。就是以后大家会越来越的多的用这种跟agent交互的方式来去用应用。那它的后果其实大家一定要预想好。其实就是我们的界面，手机上的每一帧屏幕乱七八糟，这些其实都会被搞定，对吧？都被这种大厂拿走，而且肯定是大厂。当然我们说这个字节不算是手机领域的大厂，对吧？但是它本身是一个足够大的厂，就是小公司在这个领域是我觉得是越来越没机会了，对这样一个事儿。然后另外一个就是auto GM auto GM。

Auto GM是一个我们之前大概一年前就发了的这么一个模型。但是这个模型的一个好处是什么，就是我们最近刚把前两天刚给它开源了，开这个模型叫auto GM phone 9B9B大小这么个模型，当然这个模型比较大，这个文件占了大概20G这样一个空间。这个模型这是量化的版本。对，然后社区开始现在已经有开始把auto GM做量化的这样一些尝试了。看看这个auto gram这个项目，然后这项目其实跟之前的auto gram就是能帮你操作手机的这个g auto GM很很像，没什么太大区别。但是现在开源了，所以说白了如果大家有能力去控制或者说接触到这样的一些模型的，不是这些手机的厂商的话，其实完全可以去把auto GM的模型放进去，来去做做一个类似豆瓣的这样的一个手机的这样的东西。

那怎么做呢？我其实这就给大家快速的演示一下。首先这个模型是一个9B的模型，对吧？这样不是这个是一个9B的模型，所以它其实不太好在一些比较弱的电脑上跑。我这个mac好像也才16G所以就不跑了。我就跑我就到这儿去买了一个机器，租了一个机器叫auto DL。这是国内现在大家买GPU或者租G不是买GPU，租GPU比较多的这样的一个平台。你看这个你要用个5090，这个只需要2块41个小时。对，都是按小时来算的。

然后我就跑了一个模型，我就租了一个A880G的这样一个模型，然后你随用随花钱，所以大家不用担心我花这个一直开着，然后我就开机呗。我靠，这就是问题，就是我现在的这个卡没机器了，哼完蛋。刚才还有记性，怎么办呢？看看能不能租新的，租新的就得现装那些东西，还挺麻烦的。A800，这不有机器吗？这不是有机器吗？空闲一，我赶紧看一下，看有没有没有。

完蛋，没想到这么火行，反正就是跑在这个上面，跑起来以后，你就可以得到这么一个，这是我当时的跑的这个模型的这台机器，然后就运行起来了。运行起来以后，你就可以干嘛对接这个模型的，对接这个手机这一端有一种东西叫做ADB，ADB这么个东西，这个是个啥呢？直接拿这个东西对我们把它插上，然后ADB其实是本质上是一个安卓开发用的工具ADB这么多，ADB。稍等，不是这个型号，就这个。

OK本章是这么个工具，你可以在这儿看，我连了哪些安卓设备，我怎么没连上。

十二节课。怎么今天诸事不利，稍等，打开了。

Q.

耶我什么线没拿。对。

稍等。什么是没机器了？对，就是没GPU的机器了。这里面的GPU你像这个A800什么的卡是要去抢的，就是你你关了机，这个钱不交了，对你是好事儿，但是他不可能不往外卖，所以他就是直接这个哼我靠等一下，我觉得可能是这条线的问题，换一条线，所以他就直接把你之前用那个GPU租出去了。那你要在启动我们的server的时候，你的服务器的时候不就没有卡了吗？对吧？



来了，那是线的问题，可以迁移，慢点就是了。可以迁移吗？可以迁移。这个好像没有这功能，对，我们只能等一等。

Anyway，然后回过头来看这个ADB devices什么呢？其实就是你当前这台机器，你会发现这个手机这个玩意儿就是我当前的这台小米手机，然后你就可以去登进去了。因为它其实是个linux所以你看我登进去，大家可能看不清，我把它拉大一点，登进以后，这玩意儿就是一台电脑，这个电脑里面就是我的手机的系统里面的各种的，比如说数据文件在哪儿？有些我还没权限看，就这么个东西我就可以登进去了。

然后这个东西的权限，这个ADB这个权限其实很高的。因为它叫安卓什么debug bridge，就是调试用的桥这么一个工具，所以它权限其实挺高的那高到什么程度呢？你可以去直接去安装应用，直接去打开应用，然后具体去跳转或者发出一些指令什么的都可以。所以要装这个ADB，装完了以后要设置一些东西，这些就大家如果自己想玩的话，可以看这个说明就行了。

然后会还有一个什么呢？还如果我想通过像这个ADB往我的手机上发东西，就等于通过ADB在这儿发一些指令。因为你大家看之前那个豆包里面很大的一个点是什么？就是我说可以帮我在美团里面搜一下附近的火锅店。对他其实是要去打开美团。他要去打开美团，然后把那个火锅店这三个字扔进去，扔到他的搜索框里的对。这就是就是工程机。

美团也疯了，行吧？大家可以看看，美团也不支持了，所以这就是尴尬对吧？就是一家露头大家就把他往死了打。

还有什么应用可以用，总不能用浏览器，淘宝，看看淘宝行不行。帮我找找淘宝上100块钱以内的叫什么硬核金属摇滚T恤。看看行不行。对，你看他在。失败行吧，淘宝也不支持，大家看到淘宝也挂了，所以就是。他但凡说什么属于实验室功能线不支持了，就是被投诉了呗。还有什么大家还有什么想想试的没有？

在微博里找最新的AI里大模型领域里面的达人都在讨论什么？对，你说不支持豆宝手机。其实问题是它其实是在一方面在应用层面做了很多限制。另一方面其实他也会去私下去谈，就是公对公的公司之间去谈。这个时候他就对，反正就是什么事儿都敢说了。所以就是甭管是要挟还是威胁，什么法律，乱七八糟的东西都会都会拿到台面上来去，不会拿台面上都都会在私底下去讨论。所以你看至少这个微博还行，对吧？

微博我说这个事儿他给说了什么大模型领域里面的达人最新讨论，行吧？也很直接了，直接搜这个东西，言量子位，他说的是量子位在讨论这个东西。对，你看他会什么，他会根据这个命令不断去搜看结果。然后看结果以后再去记录下来，再去下次再看看另一条，然后再记录下来，再summarize，再总结了，然后再看下一条，什么时候结束呢？就看他自己的模型，什么时候他已经认为他已经搞定了，你看任务已经完成，得到了什么玩意儿。对他比较好的是这个，你看它会直接把这个结果同步到豆包里。

对，这个是你豆包里的一个聊天内容，是你豆包的聊天内容并不是一个单独的应用，对吧？对，说白了就是豆包的聊天内容，就是所有的agent的互动的这个结果。然后他所有的包括豆宝手机，包括它的那个欧拉，不知道大家有没有买过，反正我有一个欧拉的那个耳机挺不错的，欧拉friends，那个耳机挺不错的。所有这种硬件的结果，硬件的交互都会沉淀在它的豆包的这个agent的豆包这个平台的就豆包这个聊天里面，某一个agent里面。当然他现在默认都是在豆包它的官方的那个age里面，我觉得这是一个特别聪明的一个设计。

就是大家有没有用过那种像什么讯飞，那个叫什么会议记录乱七八糟这种设备。你会发现啥讯飞什么这些设备它里面的聊天的内容，或者你记录的这个语音的内容，它会存在成一个的聊天的文件，就是那个会议音频的文件。然后你要去干什么事儿的时候，你要去点到对应的那个文件音频文件里再去。如果有功能，有AI功能的话，你还去问这个，你可以去问这个对应的这次会议纪要的一个内容怎么样，然后聊了什么内容，然后再跳出

来再去调另一个会议纪要的内容去再去看信息。你会发现它其实这些应用的里面的主体还是录音的具体操作的那一个文件。而这个文件，你只能在他的应用里去用，它是没法再复用到。

比如说我能很方便的转到我的微信里，我能转到我的这么个什么什么豆包的某个A站里，让他帮我分析一下这个内容，然后我再转到别的这个A站里面去，帮我分析一下，他到底这个情感上是有什么问题。或者说翻翻放到一个会议的A站里面去，帮我们做一下专业的总结，都没法做到。对，所以我觉得这个豆包这一点做的还是方向是非常正确的。我们以后可能用到的所有的功能，其实都是对一个agent来去发号施令，或者跟一个agent的互动的过程。区别是什么呢？区别是我现在在用一个agent来去操作我的手机，还是我用一个agent来去操作我的录音卡，还是我用一个agent来去操作我的眼镜，对吧？所以这也是我觉得小米它做眼镜的一个很大的问题。就是它没有像微信或者像chat BT，或者像豆包这样一个非常大量用户的这么一个平台。

当然它有啊它的米家对吧，米家的这么一个智能家居的东西。但是米家的使用频率太低了，它不是一个高频工具。所以带来一个结果就是如果我们能想象到的各种的人跟agent互动的这样的一些设备，其实都应该最后落到一个高频的agent平台来去互动。这是我纯个人判断。

对，然后手机要打开开发者模式。对对对，这个是啊，所以这个呃有没有同学感兴趣想跑to GM？这个我不知道有没有，我看能不能跑起来。现在auto这样，auto DL有没有算力了？打这么多天晚上的干活吗？白天都不干活了，行吧。

对，然后会不会有新的手机操作系统？我觉得应该会，但是它不一定是手机操作系统，比如什么呢？比如像open I之前给大家讲的，open I不就在做新的硬件。

那个硬件是个什么呢？之前有一期讲什么24小时一直在持续的在线，然后一直在听着你看着你的在干啥这样的一些东西，这些事情的一个小硬件。这个硬件形态是个吊坠，还是啥不确定。但是，它应该会是一个相对来说比较独立的硬件，独立存在的硬件。那这个硬件的操作系统肯定是要有自己的独特的操作系统的。比如说它怎么能够一直24小时不断的在线，对吧？那那当然你回家睡觉的时候可以把它充上电了。但是你起码得保证，比如说十五六个小时一直能够通电。

且通电的时候不光是一个收麦克风的声，还可能还能跟你对话，还可能给你反馈信息的这么一个状态的设备。这个东西对操作系统的影响其实非常要求很高。大家现在比如说我们有用这个mac电脑，大家用的windows，或者用什么手机的套系统什么的。其实都很难做到一个小型设备的这么持续的使用，低功耗的使用，而且还比较高活跃度的使用。所以手机心操作系统有没有新的，我觉得核心取决于你的需求在哪。你的你有没有一个突破了现有手机的需求，或者一个交互场景的出现，或者交互场景的普及。

我觉得豆包这个东西，它怎么说呢？就是肯定是一个折中态的这么一个形态。大家肯定不希望说我干啥事儿，我让agent帮我干的时候，这个agent还整天去我平时用的那个APP里操作，对吧？就是你让一个A镇帮你买一个东西，结果A朕依然要去像你一样去刷淘宝，要点掉那个飞来飞去的广告，要不断的去躲过一些很神奇的什么优惠券的陷阱，对吧？你肯定不希望干这件事情。

所以终极形态肯定是说，一个agent可以直接帮你把所有的应用的操作给屏蔽掉。但是在过程中肯定不会一步到位的。你看现在这个，豆宝手机刚发出来不到一也就一周，整个这几家应用都给他屏蔽了，就说明了所谓的现有的流量方，对吧？我本来就用的好好的，我流量那么大，你过来来个A的想跟我抢流量，那可难了，可难到底了。所以这个阶段里面，你怎么能够在跟应用厂商，说白了就是跟既得利益，跟既得的流量方去抢这个流量，这是一个巨难的事情。所以我觉得一方面只有大厂之间battle这个事儿才可能。

另一方面我觉得你说的新的操作系统是一个机会。所以像之前那个什么rabbit RY，对吧？这个烂掉的那个rabbit r one，还有那个什么来着AIP这些其实都在尝试说我不要用手机了，我让用户不要用手机了，我直接跳过应用这一层，我去直接给用户提供服务。我才有机会去成为新的制造新的流量，成为新的这个界面。那他自然要需要在这个新的交互或者新的这个界面的时候，使用新的操作系统至少能支持他的这个套系统的它的这个新的界面的这种套系统对。所以我觉得这个是一个计划，就是我觉得不太会有新的，至少说一段时间不会有新的操作系统。大家讲操作系统肯定都是那种什么应用层或者launcher层，launcher层封一层，这玩意叫操作系统，肯定不叫，对吧？

我觉得起码这帮现在做launcher的还没当年那个坚果手机做的深那那你说坚果手机算不算OS对吧？所以说坚果手机算OS，我觉得至少目前的很多的这种launch，就启动器这层这层其实都不算不太算是这个操作系统，新的操作系统。包括这个豆包这个手机也是，基本上它还是在UI层面去做了很多事情。但是它底层有没有在驱动层面做一些事儿，我现在没不知道，但是我至少现在玩了一段时间，发现看起来没有什么太太深的继承。

内置I层与应用层隔离开，所以就刚才那个事儿，就是我们期待的肯定不是一个另一个跟微信、抖音、美团并排的一个agent应用。肯定不期待的是期待的不只是这个。我们肯定期待的是有一个东西屏蔽在我们这些应用微信乱七八糟之上，帮我们去干操作这些应用的这么一层，对吧？所以你说的AI层，如果是这样定义的，我们定义这层叫A这层。那它确实是一个必要的东西。但是这层怎么实现？就像大家就直接看到了，头铁直接就撞上这些大厂了，那怎么能够慢慢的磨合到这一层呢？那肯定大家要分配利益，分配流量，你不能说我微信了就有有微信了，我我把我禁了，我就不去做这个事儿了，肯定要慢慢磨，所以我觉得这个是一个所谓的AAI层的意义。

这玩意儿要被别人控制了就太麻烦了，我觉得这个倒不用太担心，我看看啥意思，克隆实力，我看是不是可以克隆。好像可以，我试试。对，就是你你会想到这个是你你说的克隆，什么克隆说的被人控制可能是什么呢？可能是比如说我现在啥都没干，有一个人他的指令变成了这个玩意儿的输入，对吧？就是有另外一个角色可以控制我的控制手机的agent对吧？所以我觉得这个是一个如果这个是你说的控制的话，那我觉得这个事儿其实是一个当务之急，很重要的事儿。

为什么呢？现在的很多所有的这种A阵，我看现在唯一见到的能控的V2。一个是华为眼镜的那个它带骨传导加声纹。另一个是小米小爱音箱的那个那个小爱他有几款是有所谓的声纹识别的。就是他只认你的这个声音，或者他至少认你声音，它会有一些特殊的权限。那这种情况下你发号的势力，他是只有你说的他才会遵从，那其他的都没有。所以大家也看到各种的车机什么，有些人还搞开玩笑说你在一个什么小米汽车旁边，还是什么理想汽车旁边大喊一声，然后什么降下车窗，他就给你降下车窗了，对吧？

这个有些是段子，但是确实这个也是一定程度上制约了我们去在一个设新的设备或者一个传统设备上部署agent来去帮你操作的这样一个很大的门槛。所以如果有一些传统的音声音分析的公司，比如像声网或者像这个类声网这样的公司，对吧？所以其实在这一波AI硬件里面，其实是有机会的，就是有它的一个位置的。就是他要去做人跟agent之间非常重要的一个语音对话的这一环。这一环不光是语音能不能识别准文字，能不能转转文字，而且包括什么？就是包括了谁说的，是不是真的是他说的。

这个玩意儿就跟有点像之前给大家讲这个AP two似的，不知道大家还记不记得，google发了一个协议叫做agent payment protocol，agent支付协议这么个东西。它里面很关键的一点是什么？就是我们的意图买东西的意图在这儿。我们的买东西的意图能不能正确的或者被某一种加密算法支撑下的传递给最终的商家。你看这是用户用一个shopping搞购物的agent然后再一个merchant就是一个商家商家他的网站，这个网站可能大概率是给agent用的。所以大家可以想象这个对我正好说一嘴，这种merchant就不是我们想象的什么淘宝京东这种东西，很有可能是一种叫做had less，叫什么来着merchant。

在这样的东西，the headless in commerce e commerce headless在各种的技术类的这个里面就是叫无头。或者叫所谓的无头，就是没有前端界面，没有前端页面，就是没有像我们在浏览器里打开google这样一个东西。它的存在就是一个API，这玩意儿就是headless。所以回过头来到这儿，就是你的一个购物的agent去一个headless没有网页的，没有前端页面的一个店商去买东西，对吧？那这个时候你想想，就跟两个贼专业的人？聊一个话题的时候，很有可能就不像咱咱这种门外汉式的方式来聊一些有的没的或者信息量贼低东西。他们很可能就直接说五号怎么样？我觉得六号更强对吧？

这个4.5的这个尺寸我觉得更合适对吧？那他这个信息量就贼高。所以shopping agent跟merchant跟这种无头的电商之间互动，可能很很可能是一个非常高效的一个过程。

但是一旦到最后的要支付的时候，用户就是这个商家，他其实也有责任要去验证你这个shopping agent是不是真的有权利来去购买我这个东西。比如说我要买一个100块钱的T恤，那这个shopping agent他有可能有足够的钱，对吧？但是对于商家来说，他也要验证这个shopping agent是不是真的拿到了一个人人类的授权，来去买最后的这个100块钱T恤。所以这块涉及到两层的授权，一层是人怎么把100块钱预算买T恤这个东西扔授权给这个shopping agent。另外一个就是shopping agent。怎么把我真的被一个人类委派的，要花100块钱买一个T恤这个意图告诉电商商家，这两个阶段都要完成。它不是一个单向的传递过程，是shopping agent要拿到人类的授权，电商也要拿到shopping agent被人类赋予的授权，赋予的这个叫什么授权。

那底下当然包括整个支付系统的支持，也得保证完能完成了，你得有足够的钱能转过去，所以回过头来就是刚才说的音频，声音公司在AI agent的这个领域里面是有非常多的机会的。就甭管是设备还是刚才我说的A站头的支付，这里面其实都有很多机会的。这边跑起来了，我看看能不能跑。

好像可以了，note。OK我们回过头来看看open auto GOM。还可以按那个操作手册做就行了。它的步骤并不多。第一个就是打开安装ADB，就是连上手机。你像这种手机要拿USB连上，然后把这个能够看到，你看着能够在这儿ADB看到这个设备，而且是连着的状态。说白了你就可以登进去，可以做很多操作了。

然后第二部分就是部署模型。部署模型就把整个的这个代码给克隆到某一个服务器上，像我这个服务器上去，然后装相关的依赖什么的没问题，然后把它骑起来，骑起来，我看看接下来的在哪呢？在这儿对骑起来的时候，你肯定要装一个模型推理的引擎。一般来说大家就用VLM或者这个SG line VOM的，就这么个东西。

但是auto GM有一个auto DL auto DL就这个专门卖GPU的服务。他有一个问题是他不太会开。就是如果你不是企业用户的话，他不给你开放把这个网站的HEP接口暴露出去的这个功能。所以我他只给你留两个接口，一个是6006，还有一个6008。我记得。然后你只要把这个端口改一下就行了，看看能不能跑起来。这是一个克隆的server，理论上是应该OK的。我靠，不行，知道了。

什么环境问题。

等一下，我看看是不是之前的环境，他没有没装齐。应该是起来。然后这块国内其实有一些问题，就是国内的问题是什么呢？就是。

国内问题就是翻墙，对吧？翻墙的问题是啥呢？就是我们两大重要的网站，一个是github，一个是hugging face，都没法直接访问，那怎么办呢？至少有这两个地方，一个叫hang face，还好，hanging face如果你要装什么东西的时候，你只要把这个hanging face的这个端点暴露出去，改一个值，改成叫什么。比如说hang ging face mirror这个网站，它就可以帮你转发给这个hung face，转移到然后k tub可以加一个叫这个东西的东西。里边有偏技术，大家如果这个就没兴趣就可以撤了。

然后这个网站的get up的这个proxy，说白了就是你直接访问get up不行。但是我通过这个代理能不能访问呢？可以的，你看就是在正常的github的这个命令之前，这个网址之前加这么一个就OK了。你就可以正常在国内能够下到代码，能够访问到具体的这个对这样的一些代码库有问题，为啥不行？理论上克隆的应该是很完整的，安全套不好搞。

算了，我给大家看一下之前的这个过程，这个过程我觉得很有意思，可以看一下。能看到吗？现在这个我给全屏了，能看到吗？算了，我给你说一下。

这好像开始拉了，这样。这个能看到吗？这个麦克电脑，麦克电脑我忘了说了。那个电脑是上节课我好像没太说的一个F什么来着？这个东西lux lux这个东西，然后这个是一个一个团队，叫什么open AGI。这个团队刚发了一个叫computer use的这样的一个模型。这个模型其实很简单，它整个过程我忘了上次说没说，其实就是这么个东西，跟所有的甬管叫肯用电脑的或者叫用手机的这个agent都是一样流程全是这样。

你的电脑截屏扔给这个模型，当然你的指令也发给他，然后这个模型会产生一些action，这个action可能是输入某些话，或者是点鼠标左键，或者什么拖拽，乱七八糟这些东西都叫做action。然后这个action的时候，再到发挥你的电脑。所以这块儿有一个很重要的点是你的电脑得有一个应用。这个应用有足够多的权限能够拿到截屏，能够执行这个模型返回回来这个action。大家可以想象执行action这件事儿好像有点像什么按键精灵，对吧？按键精灵的权限其实也不低了。然后拿截屏这个事儿其实就更敏感，尤其是在mac下，苹果下就更敏感。

所以这个应用在你的电脑端或者在你的手机端，总得有一个应用来干这件事情，所以整个流程就这个东西，如果想把它这家平台就跟lux其实官方提供API的，所以你可以直接去接他的注册一个他的key，你就可以直接去调他的API来去执行了。比如说我就直接接了一个，我看看跑没跑起来，主要的人不是这个，我都这样，也不知道这个。对，看看能跑一下。对，然后我把这个等于是这个程序叫什么OAOAGI server start，就是刚才我说的。你电脑端的那个帮你截图，然后帮你跟模型互动的这个程序。它有一个给你一个客户端，你可以自己去试。

比如说我填上这个，帮我。就刚才我就这么打开，美国国防部网站。然后他你看他会看shot，其实就是当前截我的屏。然后截屏了以后，他就要去帮我操作。你看click就点了，我现在这不是我的手在点，他就会在自己去执行了。

你看这个搜了个啥，我靠，点了google。直接搜国防部的网站，我操。对，不能搜，不能问这种很很盖很很有名的。因为这个有名的网站，他连U那个网址其实模型都知道，所以对就会干了。他不会结束了，我靠，结束了行。你看这就是现在模型的这个，尤其是computer use用电脑的模型都普遍很差。你看我的任务是什么？

打开美国国防部的网站，结果他到这儿觉得就好像打开了就结束这任务了，对吧？当然有可能是这个agent的问题，但是模型肯定也不是很强。所以computer use用电脑的这种产品相对比用手机的还是差很多的。

刚刚说哪来着？刚刚说哪来着，忘了。算了，这个高德GM对，视频这个任务是什么呢？我给的任务是帮我播放那个那个歌叫啥来着？跟悲伤结了账，蓝老跟汤令山的这歌不知道大家有没有听过的，我觉得还挺好听的。就这歌。

然后这个店我的任务就是这个任务叫你看这儿最上面这儿，不知道大家能不能看清，这儿这个任务就是播放跟悲伤结了账，就这么个东西。好，他就开始一个一次一次的截图，然后开始分析推理。整个过程你可以看一下

这样声音其实没啥用，这个就声音就不看了，乱七八糟嘈杂。核心是你看这个前面他就不断思考说，我现在应该是不是有点不对？

前面任务是播跟播放跟悲伤结了账。好，然后你看这他思考是我应该选择其中一个音乐应用来打开这首歌。他前面写的是我看到有这个QQ音乐、汽水音乐、网易音乐，对吧？他觉得应该打开哪个歌，他直接去执行一个lunch网易云云音乐这个操作。

结果他发现啥呢？结果他发现我手机里没装网易云，也没装QQ音乐，也没装汽水。然后他就开始干嘛，他开始说可能不在这个首页这个屏幕，他往右挪了一页。你看这在这儿看下面这个屏幕，这不是我手点，我手只为了把它点亮，然后往右挪了一列，他发现有一个叫popular APP的目录，他觉得里面可能有播音乐的这个应用，然后他就开始打开了，打开蜻蜓FM，打开蜻蜓FM然后就开始搜，我觉得挺有意思。这个过程你看他放大一点，然后他就开始播，搜搜那个专辑，搜主播，抽广播，都没有跟悲伤结了账。

这个结果然后他就打开了什么？打开了番茄。大家知道那个番茄叫什么番茄小说是吧？就专门是网看网文的那个，我靠，我不懂，稍等，他挪过来就很有意思，这段打开了番茄畅听。

对，发现唱番茄畅听在这块思考了什么？番茄畅听打开的是番茄小说应用，不是音乐应用，所以他立刻又点回去了，跑了，很有意思一个过程。因为它每个部分都要去做思考推理的，然后再去找，然后他又找另外一个文件夹，另外一个文件夹什么玩意儿？他又回去又试了一下网易音乐、QQ音乐什么的，还是没有，又打开了另外一个，然后直到打开一个，这个玩意儿是什么来着？这啥。对他发现了一个应用叫做music，这就是小米自带的那个音乐应用。

他发现我靠他终于这个是个大这个是个播放音乐的软件，然后就进来了。然后你看这不是有广告吗？它也可以自己点掉，然后搜跟悲伤节让然后点开就开始播了。对，就开始正常的饽饽这个歌了。所以整个你看到最后这块显示的是任务完成，然后耗时三分钟，不是这歌三分钟耗时多久不知道。对，反正刚刚才整个过程是我四倍速加快的这样的一个操作过程，所以这个就是一个标准的auto，就是用for use的应用会干的事情。这个也就是对之前我自己托管的这个auto DL的上面，把这个9B的模型跑了以后，连上手机以后实现的效果。

所以这个东西，我觉得大概率大家看到第一想法肯定不是拿来自己玩，不是日常使用，对吧？谁会拿着一个手机插在电脑上，给用电脑上发号指令，让他操作手机呢？那大概率是谁会玩呢？大概率肯定是这帮做灰厂的对吧？

所以这个是现在问题，就是这种应用其实你很难防止它用来做灰产，但是好在什么呢？好在大家也刚刚看到了这种auto GM这种GIA，这有非常多的问题，能力不够强。所以即使做灰产，其实也不如像同学像群里的同学说的RPA软件，或者这个叫什么精按键精灵这一类的软件。而这些软件是不是随着发展逐渐没落？肯定是，事实上已经是了。

像什么影刀，像这种就这一类的，其实现在大家都已经转了很久了，就至少转了一年了。就是把它自己原来的RPA结合大模型，比如什么呢？就是你原来的RPA只是确定的这些点点来点去，按照某个顺序来点。

那现在结合大模型，尤其是结合这个能看图的模型，一个很大的好处就是什么？我原来发号施令的那个命令可以不那么的确定性了。比如说先点左边，再点这儿，不用这样，而是我可以先说我先点某一个应用的这个A键，再点某个应用的B键。那A线某个应用在哪呢？这事儿理论上可以靠模型结合，而P原来那种软件的能拿到数据来去找到，然后A键在哪也可以靠是这个多模态模型能够识别到。所以现在RPA软件早就已经大量的在把agent和这个大模型能力融合起来了，所以这个倒是很明确的一个方向。

但是这个事儿我谁能搞好呢？其实我也挺挺不知道的。就是传统的RPA厂商，它有大量的现有的客户、现有的应用，现有的部署实施的这些场景，都还是用他原来那套工作流程去做的。你很难去快速的迁移，或者说不影响以前的架构情况下迁移到新的里面。那我他们这种厂商，我觉得这个现在只能做的就是我中间去做适配层，对吧？兼容层来去做这件事儿，但是很多我觉得是你的一个新创业新公司才能搞好的事情。所以我觉得像这种RPA厂商如果比较大，他最好的方法就是做一个新公司，然后让把之前的一些业务能抢的抢过去，不能抢到自己原来公司维持就挺好。

对，好，今天差不多这些问题了，大家还有啥问题？我不知道今天是不是咱讲的这个有点太枯燥，还是咋着，或者大家有什么想法没有，觉得有什么建议，觉得像这更多添点啥，或者有啥问题的，都欢迎发过来。然后其他的我看看有啥没有，应该没啥问题，没有说了。

对，现在很多应用都不支持了。对，这种不支持很多，越来越多的。不是说像微信这种不行，硬刚然后我就不让你用，而是就是像刚才那种，我直接私下跟你商务上谈对吧？你要其实如果你说真的他操作你的应用这件事儿合不合规，还真的有些是在灰色地带。因为因软件这些软件的这个term里面，其实会有些会写上说你不能够逆向或者不能代理应用乱七八糟这些东西。其实理论上是会写的，只是看法务上纠不纠结。所以即使大为此这个豆包，他也不是很敢跟这些大厂正刚硬刚。所以还是有一个很长的一个阶段性要去度过的。

所以今天给大家讲了一些A镇的，包括说豆包手机，包括豌豆GM，包括这个lux这个是操作电脑的目前来说比较sota的模型。所以大家可以看到操作电脑的是落后于操作手机的，也挺容易理解。因为电脑上的信息量实在太多了，而这个是这个手机上就会好很多。当然还有很多其他的就是用操用电脑，用手机的这些agent框架。

所以这些当然我们可以等等等一段时间以后再去专门去讲它的进展。之前有专题讲过科学吗？没有专门讲过科学这个讲过考考的。然后简单的去跑过跑跑过一下这个大一同学你有什么想法吗？或者你想想听怎么用咳嗽，那你是程序员吗？还是什么？

所以操作的，对，我给你发现什么呢？就是VS code里的class code插件可以用，而且还挺不错的。所以这个是一个挺好的一个替代那种纯命令行的纯命令行的，纯命令行的。这个是真的有点太硬核。这个可能大部分同学都接受不了，但是US code里面去接class code插件这件事儿还是比较友善的。所以这个大家想听吗？想想看怎么安装。因为安装其实往往就挺挺枯燥，挺无聊的，所以这个不知道大家有没有想想去。

然后如果真的想去做一些挖coding的事儿的话，我其实挺推荐tray的，就是字节的这个口coding工具，tree TRAE。我今天晚我今天电脑怎么这么慢。翠翠翠。

太慢。这个翠对，这个还是挺好的。对，但是这个大家是想听啥呢？是说怎么用吗？还是怎么装呢？还是怎么配，还是想怎么用来做一些应用，还是啥意思？

这个我也挺愁的，因为最近我们在跟一个头部的做教育的公司也在合作做这个web coding方面的事儿。但是我也挺愁到底讲到什么程度，大家可能更多的其实卡在空气的环境配置上。但是大家肯定希望听的是那些怎么做什么样的应用，想知道到底能干啥。

这个是个更麻烦的点。就是如果你都没有想到说我有什么事儿可以把想把它自动化的话，那单纯的上来做y coding其实意义不大。就是我觉得你可以这样想想，就是你平时日常哪些事儿是每天都要不断的重复干，而且你觉得相对来说这些活是不那么用你的，也不叫能没有脑子就不那么用创新性思维就能干的事情。是一个比较确定性的规则，不是那种规则，就是你的脑子里的规则就能完成的任务。



你可以先找这类，比如说什么呢？比如说每天我要去看一下什么高强度材料里面领域里面有什么新的研究成果，或者有哪些汽车用了某一种材料，某一种高强度材料这个东西这个领域，我每天都要去搜一波。那传统意义上你怎么干呢？肯定去google搜一下，然后或者比较好一点的用google alert订阅一下你的搜索结果，对吧？但是你还得去email去去看这个结果。

但是如果你有这个需求的话，那我觉得其实可以用what coding来去尝试去做一些。比如说网站的爬取，自动归纳，然后给你每天生成一个报告这样一个事儿。那还有什么？比如说做日报周报对吧？你咋怼过去，你兑给这个y coding，给队给翠说这是我一周干的所有活，帮我生成一个周报也可以。但是大家有没有想到这种问题，其实你这种场景你扔给任何一个chat BT类的应用都可以干都可以干，对吧？所以这种东西也不是必须得用像tree web coding，靠code这种coding工具的。所以场景是个很大的问题，所以大家也欢迎大家随时就尽量多把自己的需求发给我们，然后能够看看到底想打想来去做点什么东西。

这个东西我觉得有一个很大的差别，就是你是想让它生成一个直接生成一点点内容，还是你想做个东西，做个应用，做个平台，来去覆盖以后所有这一类的场景，这是一个很大的差别。所以大家如果想去应用，做有输出的结果不是一个单纯的内容，而是一个平台的话。我觉得这个或者一个应用的话，这类的其实是一个做y coding的好的场景。但这类确实我们收到的也很有限，或者我接触的也很有限。所以大家希望能都多给我提一些，然后会去试一下，然后能跑通的话给大家的分享，好吧？

我今天就到这儿，然后10点10分了。好，我们基本都是大家平的。好啊，这个韩同学有什么？你是这个擅长的是吧？或者说如果你想给大家分享的话也可以，如果有什么需求的话，也可以发给我。

好，行，那我们今天就到这儿，然后我们下周再聊。好，那下周可能就继续去聊这个。如果没有别的新的话题，就是我们去去聊AI加军工这个领域的新的一些东西，我觉得还挺有意思的。所以这个也希望大家能够了解一下，美国到底在尝试怎么所谓的弯道超车，对吧？硬硬实力上刚刚不动了，那他怎么在想用AI来去赋能他的军工产业，来去做所谓的弯道超车这件事情。也希望大家能有一些兴趣，有兴趣的可以听一听。好，我们下周再见，拜拜。