

好，hello，大家晚上好。晚上好，稍等一下。大家能看到我屏幕，声音也能听清是吧？Hello, 大家好好。好，准点儿，我们准点开始。好，小杯子。

好，那我们先来，因为这个算是年前最后一次了。对，应该是最后一次了。所以我们今天讲讲2025年的整个AI领域的几个大佬们对于年终的总结。我觉得这个正好我们也可以看一下我们今年讲的东西跟这些大佬所提的东西是不是有相关，或者是覆盖度怎么样，吧？然后大家也可以有之前我们没讲到过的这个没讲到过的，我们也可以查漏补缺，然后这个过一下。好，第一个我觉得这个挺有意思的一个视频，这个是HUZ大家知道HUZ的老朋友了。然后这个里面会讲到一个他叫这帮投资机构特别会讲故事，我觉得这个也是其实跟咱们的这个所以大模型的一个上市机制股票也是一样的，就是大家得会讲故事，那HZ这种投资机构那是会更会讲故事了。

你看这个他讲了一个叫run time 2.5的这么一个主题。Run time是啥呢？就是运行时，说白了就是比如说你的java跑在哪儿，你的这个python跑在哪儿。然后现在你把它泛化一下就变成了什么你的agent跑在哪儿，你的AI跑在哪这些东西这个运行时其实对应的就是agent或者大模型领域里面的基建这意思。然后他就开始讲，你看这个图里面就很很牛逼，你看底层物理层、计算层、网络层数据数据引发对吧？然后这个可观测和这个编排run time模型推理，然后上面是什么玩意儿，开发者平台这样几个东西。然后他就开始说整个我们应该关注的是这个领域里面的这个runtime领域的这样一些机会，然后开始发布视频。

我靠，感觉像那个啥，像沙丘的那个那个框，你看声音是，他前面是视频是谁做的？看看i don't，这个视频是这个luma，然后声音是什么呢？声音是eleven labs。这两个品牌大家都知道了，like last说了好几次了，这些声音都是他造的，就开始讨论说这个给油，待会IT is all to this。The past has brought you here.

对吧？然后就感觉我们现在就他随着两条路和这个就是两条路。就是你要不所谓的交沙子，沙子就是规你要不要交规或者交这个AI，让AI让机器会思考，要不就是AI的之后idea and v然后我们就开始看了他一系列的东西。

其实我不知道大家我们我们一个一个看一下，大家认不认识这个东西是啥？这东西大家有人知道吗？看着像啥，这样基本上就是GPU。然后就是最现在的，比如像这个估计是A100，这个A100的这个机器，然后现在的整个组装这种机器都是这样，几乎全球化组装的。你看刚才这种就是一个卡，是这里面的一个东西，这玩意儿好像叫OAM还是叫OA什么玩意儿？就是一种现在因为GPU不断的有新增，不断的有新的这种GPU出现。

那咱不能总是像咱这个家里买那种什么3090、4090那种东西，对吧？就是每一代它那个槽都不一样，然后形状都不一样，大小都不一样。那我怎么去规划一个底层底板，就跟主板似的，怎么能让这个底板能适应更好的适应的每一代GPU呢？所以他就把这些GPU给直接那些外壳看，那些东西都给拆了，然后变成这么一坨东西。这一坨东西里面有散热，有什么什么水冷，乱七八糟什么都有啊。还有它的这个GPU芯片，这样就可以变成非常模块化的这样的一个GPU放在这儿算力了，也不一定要GPU了，就是算力放在里面，然后卡机器人不就能很容易去搭了。

然后那边就右边这边这边应该是NV link，就是那个卡间通信的这这套东西。它的空间这个大家就应该讲过对吧？Figure 02，现在新的已经不是fake 02了，应该是fake 03了对吧？就是那个很漂亮的而且身上还贴着这柔性衣服的那个机器人，这是02，这个不知道是啥，这个我看了半天，这个silicon and like这个光刻机对吧？咱们这光刻机也很也出来了MUV。

然后看这张图，其实大家能感觉到是啥？这是最早期的，也不叫最早期，应该是什么时候？一九八几年还是说一九九几年，当时开始做用神经网络来去识别数字。你看就是你的图在这儿，右边。好，然后我中间通过几层神经网络最后能干啥呢？

转过来到左边这是啥？就是我神经网络通过视觉一层层传到最后，我就能激活对应到的数字三吧？这是345？所以这就是神经网络的标准。然后现在就有各种类型的AI了。

Stem and two镇上，咱们我做个调查，咱们群里有多少同学会用curse或者用这个tree，用卡扣这种Y这个y coding工具的。会的话，打个一呗，不用的打打个2，用的打个一呗。对，打打先打的。对，rex你肯定用。对，那谁right？你用curse吗？你看这个界面看着就像是咳嗽了。看着就像咳嗽，CC？那就是硬核。蔡同学是需要培训一下是吧？全部都咳嗽的。

然后这张图大家知道是啥吗？特别经典的这个195，应该五六年，这个特茅斯达斯矛斯会议的当时的那张图，然后其实是什么呢？那个全名其实并不是什么达特茅斯，或者说当时1956年这个达特茅斯会议其实并不是什么多隆重的东西，就是一帮做神经研究的，做脑神经研究的，做计算机研究的、做算法研究、做信息论的这些人，大概好像也就十几个人，20个人左右，然后攒到一块儿搞了这么一个玩意儿，其实叫达特茅斯workshop。然后他叫什么达特茅斯夏季研究项目，人工智能的夏季研究项目。说白了就是有几个人，比如说像香农对吧？大家这个二叔非常具有名的，然后这麦肯锡，然后什么什么明斯基，明斯基这几个人其实都是在当时这个会议里面，大家志同道合，或者叫臭味相投，大家一起来去讨论。所以他们提了一个proposal，当时的达特茅斯会议这个proposal。

这是原文这是原文，不知道为什么这个玩意儿在斯坦福的我在算法的这个会议里面找到的，这个网站上找到的1955年。对，然后我们把它翻译一下，应该可以看到，对，挺有意思的一个内容。对我发现这个问题，就这篇文章它的翻译效果很差。然后大家如果用那个沉浸式翻译的话，你要选这个PDF pro才能够转的比较好。我看看，稍等，我把它扔进去，让他转着。

对，达特茅斯会议这么几个人，然后就是这张图，然后这里面这哥们儿是应该是香浓。我觉得里面最帅的就是这个家伙，这个家伙香浓，然后好像这哥们儿是IBM的。你看就是唯一打领结的这个。对，反正几个学校的都是很牛逼的人。然后你看这几个，达特茅斯的、哈佛的，然后IBM的那香浓是贝尔实验室的，这样几个人决定干嘛？决定要去开始尝试让机器来去学习人的学习能力。

你看我觉得这篇这个proposal还是挺有意思的。可以看一下这个，对，就直接看最开始的一句话，就是我们提议夏季在达特茅斯进行一个为期两个月，由十名成员参与的人工智能研究。然后这个研究基于以下假设展开，学习的各个方面或智能的任何其他特征，原则上都可以被精确描述。

用机器来模拟它，啥意思呢？就是在尝试用机器来去模拟学习这件事儿，让机器来学习模拟学习这件事儿，这个很牛逼的。所以这个就是说尝试如何用学习，让机器使用语言形成抽象概念，解决人类的问题这样的一个东西，然后底下就说了一大堆哪些方面了。比如说当时做神经网络的，做计算理论的，然后做什么自我进化。你看当时就开始做self improvement，当时就开始做self。对，然后这个事儿一直到现在，其实都反正就还是有障碍，还是挺大的障碍的对，然后学习这一方面，然后啊这几个人乡农民司机什么这几个人都是干啥的，大家都知道，我觉得不要有意思。

底下这块，你看洛克菲勒基金会，要为这个项目提供财政支持，对吧？大家知道洛克菲勒基金会吗？巨大，然后提供多少支持呢？给这些讲师1200的薪资，这个在1956年的左右的1200好像应该换算至少到现在十倍，至少一万多刀这样一个量，然后给研究生提供钱，还搭着火车提供火车车费、租金、秘书肺组织肺乱七八糟各种东西，整个一次会议提供13000。所以这个底下就是各个大佬们提的这个他效应研究的方向，挺有意思。所以可以看到当时达特茅斯这个AI会议，其实大家并没有把它当做一个特别的特别严肃，然后就特别历史性的史诗性的这个事儿。但是你看这帮人都很开心，拿了11万刀在这儿过两周的开心的日子，大家聊聊天，交流结束到这grow up。在达特茅斯起在这儿长大是什么attention对吧？

这边著名最著名的，然后到了哪儿了？到这儿这是啥？这个估计大家可能看的比较少。这就是NVIDIA的这个英伟达的总部的其中一个，就是这个void vote，然后和它后面那应该就是in over。这两个对，这俩总部，你看人家反正公司总部大楼都不大都不高，对吧？都是这种片儿式的建筑，you have the opportunity to build the foundation。

然后就开始说什么呢？你有机会去为智能构建它的基础设施，就开始提这个了。你看这个大家像看着像啥，咱们上节课刚刚讲过，是有的AI，但是好像没有详细讲这张图，是有的AI有一个就是那家军工企业是有的AI专门有一个项目，有一个产品叫hive mind，就蜂群大脑这样的一个意思。Have man.

其实就是怎么大量的组织无人设备，包括无人机、无人车这些东西能够让他们自组织网络，然后完成任务。你看就他们会这个无人机会在不同的运动的过程中，动态的组成网络，就不是说大家一定得我连他他连他，而是搭谁啊，怎么组织的进，或者怎么组织的这个效果好，那就怎么组织网络，所以这就是这个有的AI点是非常快去做，这个估计就是什么类似于starting，然后这个大家应该知道能是啥，对吧？就是李飞飞的这个世界模型然后就开始to build time to build对吧？就是还是挺挺厉害的，就是老外在这方面做这种非常能够激动人心，或者非常能讲故事的这种东西的这个能力非常强对，所以大家可以看到整个的AI info确实是也是下一个阶段特别大的一个主题。

但是这个东西到底跟什么？绝对不是什么starlink这种投狂投钱就可以搞定的事儿。包括今天这个后面会那个mini max跟质谱，这个质谱我先说一下，因为这个还没上市，所以我几乎都是不应该说任何支付相关的东西的。所以今天的内容只有别人写的东西，然后我不做任何的评论。Mini max可以聊两句，挺危险的，所以大家体谅一下。然后下面就开始到说这个大佬们的2025的年终总结的这些内容。

第一个其实就是这个奥特曼的这个文章，这个就很没意思了，也不叫什么意思，就是显得还挺特立独行的。你看说今天今年是不完整调整的一天一年，然后70%的用户反馈的我们的使命的根本错误。然而剩下那1%的builder们才是引领我们正确的北极星。啥意思呢？后面就翻译了一遍，就是小时候常听那句话，是所有人都说你错了，你可能错了。但是他意思是啥？很有可能是大家都说你错的时候，错的其实是其他人，对吧？又又开始很牛逼了，嘴犟。

然后2026年open还会继续为大家怎么着，这些东西不管了，然后他确实给拆在chat BT做了一个挺有意思的一个year of ChatGPT，大家知道我这个GPT账号已经被封了两次了，所以我现在这个账号，其实是一个也就从几周前开始12一两个月之前开始用的。但是其实他已经能看到它这个year of ChatGPT的这个页面了。我不知道大家有没有自己的chat PT，有没有玩过看到这个页面，你可以看看这个GF4.7很强。对待会回去会秀一下G4.7这个效果。对，就是强弱。

其实这件事儿是一个挺越来越无聊的一件事情。当然卡帕西那个分享也会看出一点，你看他说这个3 2025年三大主题是什么？然后你的聊天的一些基本信息，这玩意儿就跟国内的一些年度总结的APP一模一样，对吧？我觉得没啥意思，也就这么回事儿这就是这个东西。所以这OK至少我目前没看到什么太有深度的这个年度总结东西，到时候看了再给大家分享，然后就是卡了，我觉得这个还是很值得去讲一讲。对capacity吧？

这个大神又来了，2025年的大模型领域的年度回顾是啥呢？好，然后他认为以下一些概念给他留下了深刻的印象。第一个叫什么，强化学习reinforcement learning吧？然后是什么呢？From可验证的奖励，就是从基于可验证奖励的强化学习这个事儿啥意思呢？

这个其实就跟当年大家看到的R一是一样的。就是R一那个事儿就是我们之前一直在，反正就25年之前，大家一直在不知道到底怎么让模型能产生推理能力，大家觉得这个推理能力可能是一个绕不过去的一个天花板或

者一个障碍。但是这个OE模型的出现和DPCRE给大家看到了一个什么一个事儿呢？就是你不需要在数据上做大量的思考，思维链、推理能力、推理的信息，推理数据这些东西不需要，你就需要给他一个单纯的可验证的奖励。这个奖励是什么？

可验证奖励是什么？就是数学题或者一个代码题，对吧？你说你要做出一个程序，这个程序跑出来结果必须是这个，那跟数学其实差不多的。那基于这种类型的抢课验证，这玩意儿就叫可验证奖励。别的什么不可验证，其实就是写首诗，这个够不够酷，这种东西那谁不知道？这个文人相亲，这个永远大家不知道，不不不觉得对方那是最好的，所以在可验证奖励领域里面做强化学习，带来了今年的一个巨大的发展。就是我们能够有非常好的模型的推理能力越来越强对吧？

这他说来之前大家生产大模型方式是什么？预训练，强监督微调，然后再做什么所谓的人类反馈的强化学习，RLHF这个东西。现在的所谓的带壳验证奖励的强化学习，对应的其实就是deep stick r one的这篇paper。

不知道大家还记不记得，我直接给大家看一下，当时那个那个paper里那一页还是挺值得记录的那个消息。你看这个就是当时的dept CR one的这篇paper，然后里面很关键的一个就是这个东西。哈哈这对你把它翻译一下。对，就是你会发现一个什么RR one的zero，就是纯拿强化学习训练出那个版本，它已经出现了所谓的时刻，就是顿悟时刻。这个时刻他会开始不断的尝试各种新的思路，然后直到他发现有一条路可通。你看这个就是他的例子，就是问什么什么A大于一成立，若A大于一成立，则什么什么它的实解之和等于多少？然后他尝试了各种办法，到这儿的时候他突然开始说，喂喂喂有一个啊哈时刻我找到了，我可以在这儿找到一个这样的，这个就说白了就是我想到了这样的一个意思。对，所以就是光让模型就让模型去做这种可验证的，比如说数学或者编程的问数学问题，当然主要是数学问题，我们就能让模型产生一个强的推理能力涌现出来的，这个就是涌现出来一个强推理能力。

所以这种可验证的强化学习，它跟传统的我说监督有监督微调和什么人类反馈强化学习这些东西。其实这两个其实对应到它就是这个卡帕斯认为都是属于相对轻量短暂的微调。而RLVF、RLVR其实就是针对一个客观的，所以不可操纵，数学不可操作，程序不可操纵，甚至物理不可操纵。

对于这样一个不可操作的奖励函数进行训练，它有一个很什么好处呢？就是我可以做更长时间的优化，我可以让他一直去对吧？你想以前的强监督微调，那我有十条数据我就只能训十次呗，然后顶多改改这十个数据，稍微做点增强，然后来去训。但是你如果就一个数学问题，那我你解不出来，我就可以给你训到天荒地老，对吧？你只要解不出来，我就可以一直去。所以他带来的是一个可以投入更多算力的机会。

大家记住，可以投入更多算力的机会。所以带来一个很好的结果，也不是很好结果。就是现在这些大模型公司都把强化学习，尤其在这个领域的可验证的强化学习的就把原来做了预训练或者做微调的这部分的计算资源都投入到了更多的投入到了强化学习的阶段强化学习阶段。这也是为什么今年我们看到了大量的这种新的模型的推理能力越来越强。

而且大家想想为什么我们说4.7？就是GM4.7的这个模型，或者mini MAX的这个2.1这些MMM2.1M2对都会宣称的是什么？都宣称的是coding能力，都宣称coding能力。你会发现现在这种国产模型几乎都不太说，除了deep sk都不太说其他的通用能力这方面的东西了，都主打coding能力。就是我写代码贼强，写代码巨牛。

然后为什么呢？其实核心就是这个事儿，RLVR就是我写代码这事儿很大概率是可以做可验证的，作为可验证的奖励函数的那我一旦有一个可验证奖励函数，那我不就是狂投入，或者说更多的投入这方面，那我就越投入越好。而且再加上说我们现在奔驰越来越无聊，对吧？就很很确定性，所以这个带来这样一个事儿。所以他认为2026年我们处于这样的一个新的阶段。这就是我们把大量的大模型实验室，大量的在消化这种新阶段带来的计

算压力上。新阶段就是这个RLVR，然后带来计算压力就是我能不能把这个算力发挥到极致，用在可验证的奖励函数这部可验证的奖励的强化学习这部分，所以这是一个第一个点。

第二个就是这个所谓的什么幽灵和动物和锯齿状的智能，这个意思啥意思呢？其实就是他前面提了一个特别抽象的概念，就是我们在搞的大模型不是在进化或者培育动物，而是在召唤幽灵。这个我觉得其实就有点偏他的这个噱头东西了。我们看后面的部分，就是锯齿状的这个智能的部分。对，就是我们刚才已经看到了为什么有这么多的这种特定领域的任务，在今天的模型上面更好越来越好。除了说我们在这个特定领域的任务里面有一个标准的可验证的奖励以外，他还提了一个什么点？就是我们的所谓的强化学习，或者是这种叫什么，一般被称叫监督机制来看。

那人脑的神经网络是干嘛用的？说白了就是我们人类上万年活下来所被优化的。如果我们把世界把整个世界当做一个叫什么奖励函数的话，奖励函数的话就是这个世界会给每一个动物，每一个生物一个奖励函数，你要不就死，要么就活，要不就活得很好。然后如果来去当这个的话，那人脑的这个神经网络，其实它的奖励函数更多的是所谓丛林世界中的优生存。就是我们其实会有非常多的小环节会导致我们挂掉炸掉，对吧？所以人脑其实一个对非常多目标优化出来一个结果。

而大模型是个啥呢？大模型其实更多的是在模仿人类的文本，解数学题，然后在什么LMILM rena里面赢得人类的点赞，这个三个非常的尖锐，大家可以想想这个模仿人类的书写的文本，对吧？这几十年的互联网数据解除决题对吧？刚才我们其实提的就是解数学题，LM rena对吧？大家之前给他讲了好多次了，怎么去挑。你提个问题，然后模型怎么讨好人类，让人更愿意去点它。其实不一定是把你的答案写对写的更好，而是写的样子更好，对吧？加1点EMOJI，加一点加一点表情符号，加一点玻璃point的这些列表什么这些东西就可能更让人喜欢。

所以在这种情况下优化作为优化目标的这样一个模型，他就注定跟人的能力偏好是不一样的。所以他就举了这样一张图，这张图第一个图就是人，这个蓝色的就是人的能力。大家想象成整个世界的智能是一个巨大的空间，而人类的智能就是这么一个玩意儿，一个尖球。就是人类某些方面还不错，对这样一个东西。

然后AI随着模型越来越强。但是你看刚才我们说的这些监督机制跟人类，就是我们训模型跟训人是不一样的。导致什么？我们训出来的AI即使他能力比较强，他跟人类也可能是这样的一个东西，就是一个交错的一个能力级，绝对不是说它能够按照人类的这个方式或者领域定义来去跟人完全一比一的来去竞争这些能力的。当然这个跟之前给大家讲萨顿那期也是一样的。

就是核心原因是什么？是我们现在对于新一代模型训练的范式有问题。就是我们总希望在模型预训练的阶段或者在后训练的部分给他足够多的知识。然后出来以后就是一个足够走向社会的玩意儿了。但是这个东西不work，我们应该怎么做？我们应该让他尽量的少拥有先验知识，而更多的在生活在生存的过程中都学习到那些知识。所以这个也就对应到说大家两个路线或者不同路线的竞争。

但是至少目前这条路线大家都还觉得OK，所以就继续往后走，大部分公司都继续往后走，然后就到这儿了，说这个跟我相关的是什么呢？我逐渐对基础评测就是benchmark产生了失去了信任，而且感到了淡漠，啥意思呢？大家有没有感觉到现在这说又出了一个大模型，又出了这家大模型，又出了那家大模型。Excuse, 对，这个可以待会儿过一下。然后各家大模型的这个能力好像完全没什么感觉了，对吧？你看这个AA的这个图，你说再出来一个模型，然后现在大部分的大模型厂家，比如像质朴的mini max的。然后kimi其实大家都在对标kimi就还好。但是我觉得kimi问题是这个分很高，但是真的coding用它的人非常少，我就不太明白为啥，然后大家其实都在对标这个4.5升的对，其实这个分儿是在coding领域太低了。

对，看这coding index。对，然后看看cox pass好的收纳。对，基本上大家都在对标它，大家最新的模型其实都基本上coding能力都在对标它，所以基本上回到前面，就是说我们的bench park其实有很大的问题就是你说这些分有没有用？好像还有用，但是也逐渐的让这些大家就觉得很疲乏了。

你加五分，你加两分，他加两分。到底什么时候能到一个到个头，或者说关键节点是什么不知道。所以他说最后在测试集上进行训练已经成为了一门艺术。穿裆的test set一次new art。对，有点讽刺的意思。对，所以如果他最后就说好，那假设我们按照这条路不断的提升，不断提升，然后又把所有的奔驰都刷爆了，但是依然没有实现AGI，那会咋办呢？

所以他就写了几篇文章，关于什么动物大战幽灵，可验证性和意识空间什么的。这几个比较有意思。就是它是一个虽然是个技术视角，但是你会看见你会发现它对于这个哲学方面的思考还是挺深的，这么一个东西。这三篇文章我就不念了，就是这样一个东西。

好，然后他下面就开始说另外一个事儿了。这儿柯curse r对，你看这个翻译的有问题。Curse r是个啥呢？磕sir看起来是一个新的LR应用的层一层，啥意思呢？就是大家知道就跟考code什么这样一个y coding工具一模一样的。而且这个之前也介绍过，它这个融资什么的很高，然后也现在逐渐的成为基本上coding的标配了。

是什么呢？我们发现什么呢？就是之前大家一直在说大模型会吞噬一切应用，但是现在逐渐发现，大模型跟应用之间出了一层新的玩意儿，就是curse r这层干嘛呢？他负责做上下文工程，然后在底层编排多个LM的应用，把它组成一个所谓日渐复杂的dag有向无环图，大家知道这个是啥吧？有向无环图。有向无环图。就这种东西，就是你比如说这么一个东西，这玩意儿就是有，这是不是有交换图？这个肯定是啊，对，就是它没法形成一个这样一个图，是不会形成一个环的，就不会有一个一直转的一个小的子图存在。

那它意味着啥？就是你如果能搞成一个大G那就有点像说一个比较复杂的，就证明说它大概率比较现在比较复杂的工作流都可以拿它来去实现，然后这个也是科sir负责干的事情。他为人回路的用户提供一个特定应用的用户界面，就是你人要去给我反馈，然后在哪儿给我反馈，怎么给我反馈，那个界面是啥样呢？他来去提供科技，来去提供对然后最后提供一个所谓自主性条款，就是你要人要多参与还是人少少参与的这样一个可调整的这样的一个过程。

好，咳嗽出来以后，大家就会开始讨论了，就是curse r这层到底会有多重？以前大家说大模型会吞噬一切，这件事儿还会不会发生？他个人的观点是倾向于认为说大模型的实验室依然他的目标是培养出具有通用能力的大学毕业生。大模型实验室还是做通用智能。然后大模型的这个cursor这一类的应用，把他们组织微调，并且通过各种数据什么乱七八糟的激活他们，来让他变成一个有用的人。所以这个是他对科技的看法。但我觉得有点乐观，他会觉得curse是一个挺重要的一层，不会被大模型，也不会被应用吞掉。

然后第14个就是他提的就是克拉克刚才说的这个CC的这个克拉code里面，今年真的是太猛了，就是靠的提了两个标准，基本上都两个东西都变成行业标准了，一个就是MCP，一个就是skills。这个在刚才说的skills，为什么它就已经变成行业标准呢？就是他也就是前一段时间，你可能一两周前他建立了有一个组织叫agent skills好像是这个对，基本上他把各家gues这类东西做了一个统一的标准，然后我们可以所以我们可以假设什么呢？以后skills就是一个特别。

大家以前大家说怎么编程，怎么去开发东西，来写提示词对吧？那以后是什么？就是写skills。而且写skills比写提示词更重要的一点是什么？就是我们知道怎么写skills，就是普通人知道怎么写skills，一个专家各种，而这是词不一定，瓷还真不一定，对吧？

就是你说你是一个专业的水管工，那你会写题词吗？大概率不会。但是你说写一个你工作的SOP，写一个怎么干活的流程，那基本上所有的专家其实都会写。所以这个就是cloud给大家带来的。

今年我觉得比比他的模型的什么so light，什么opens，我觉得更重要的多就是他在尝试定义整个行业，至少定义agent的coding这个行业，所以他是说talk对吧？然后是一个在你的电脑上跑的AI啥意思对吧？大家玩过coco的应该都知道啥意思了。

对，然后他还吐槽了一下open I，认为open I在这方面犯了错，为啥呢？Open I的那个工具叫做codex对吧？就是你必须要在某一个github的一个代码库里，基于这个代码库，然后让一个云端的A站来帮你干活。当然好处很正常，很明显，就是你输完命令咖电脑废了，那个程序依然在跑着，然后可能你换了一台电脑，这玩意儿就跑完了。但是CC不行，CC就是存在你电脑上跑的，所以你电脑坏了立刻啥都没了。所以这是他认为open I堵的太前面了，他认为这个OPI想的太太太快了。目前现在是一个特别混杂的状态，应该有一个特别参差不齐的中间过渡期。所以CC是一个特别优秀的一个短期的加上中短期的这样一个战略决策。

第五就是他所谓的wage coding，那个氛围编程大家也听吐了，对吧？当然它里面说了一大堆特别大高大上的什么人民的权利LM颠覆，什么传统叙事这些东西，那就不管了。然后他这半年写了好多例子，包括上次给大家说的十年前的hacking news，怎么去分析当时这帮happy news上这些发言者他的质量怎么样。然后给他们打分做个名人堂这些东西，还包括他之前做了什么大模型的基于大模型的这个菜单生成器，然后一大堆agent，这个委员会讨论这样一些东西，好几个都是他自己by coding出来的东西。所以这还是实际在干活，而且还是挺前沿的。

然后第六个就是banana，banana，大家可以见到这个可见卡帕西banana抬到多高的一个地位，对吧？就跟靠靠的跟至少同一级别的东西，为啥呢？很明显它对标的就是chatting之余，80年代的时候电脑，我估计大家很多80年代都没这这这都没出声或者怎么着的，当时都是命令行那种级别的那我们现在chatting，其实他怎么老在刷新稍等，chatting其实就是当时的命令行这种交互方式。而nano banana带给我们的其实就是这样——一个机会，就是我们可以非常动态的去生成一个很高质量的这样的一个交互界面。当然它现在当不当？更多的是比如说生成个PPT，生成个漫画，讲解什么这些东西。

但是他认为就是开发商就认为说我们nana banana带来的是我们可能下一代的新时代的GUI，新时代操作界面。这个我觉得是跟上哪节课之前讲的那个生成式界面generate UI是一样的一个意思。就是我们的界面其实不一定不必是一个确定性的，不必是一个立刻就能，这个是预设好的，我们是可以动态生成的，按照用户需求就OK了。所以把那饿罗拉放在上面。

所以最后他总结了一下什么呢？就是我认为当前能力还远远行业远远没有发挥出大模型的10%的能力，所以这个带给大家，我觉得还是挺大的一个振奋。大神认为我们现在挖掘模型能力其实太少了，那意味着什么呢？

就是意味着有很多应用的或者企业服务的这样一些潜在的创业机会。对，然后最后总结了一下就没了。对，所以这个底下就开始有人在剖这个，大家拿note m生成的这个总结，我自己也生成了一个，然后他这个我们先看看他这个，你看这个很漂亮，这个RLVR，然后是狗还不是是鬼还是动物，然后cursor，这个cloud code White coding na banana？这样几个东西直接给总结出来，而且大家注意这些其实都是纯合成的，从这张图其实不太看得出来了，英文它确实做的很好。有没有带中文的？我看看没有我直接找一个我的nobo m生成的。

稍等。不是这个。

好像是这个，对我就直接把这个，是不是这个，**，好像不是完蛋，找不到了。找不到算了，其实大家自自己自己玩一下就知道了。整个把推特这个界面扔进去，然后让它生成这样的一个info info的这个信息就可以直接出来。就在这儿info graphic，info graphic跟这个PPT都是刚出的，然后好像还有一个更新的。我看看是叫啥来着，date data table，这个数据表格这刚刚出的，应该就在这两天出的。特别牛逼的一个东西，所以大家一定要去玩一下。这个nova太太值得关注了，而且去年卡巴斯也狂推荐了这个no，大家还记得吧？

然后好，然后对中文有时候对不上，对他的问题是啥？他那个中文你一看就能看到那些很零零碎碎的那些卡的点，然后那些卡点就代表了什么？代表了你这个东西真的是啊生成出来的图，而不是对看看这个能不能，而不是拿什么渲染写文字，然后渲染出来的。这有没有？这儿你看什么新技术实现了这些东西，微型挖掘机就是你离远看没问题，读它完全OK的。但是你一靠近你会发现这些字怎么歪歪扭扭的那如果是拿比如说HML拿网页，拿程序去渲染的那肯定不会有这个问题。对，所以这意味着什么？就是nobel m的这个功能，它其实肯定是用生图片生成的模型来去做到的对，底下就没啥了，那我们直接过一下。

摩飞机机场，在机场这样，我就直接给大家说吧，我用的是这个w get cloud w get的对，这个是我觉得反正我用了得有得有两年了，这个用的非常好的一个机场。大家可以自己去注注册。然后如果大家这个比较nice的话，可以给我一个叫啥引荐的那个费用的话，算了，大家自己去注册。我就不那啥了，叫w get cloud。W get cloud这个东西。对，然后w get cloud点ORG，点ORG就是那个组织我只是纯知道有这么个东西，这个大家自己用，就别那个啥了别别别对外宣扬，因为现在肯定是抓这个抓的还是挺挺紧的。

Skills skills skills，这个skills我看看要不算了，还是先讲。那个skills我们放在后面，如果有时间讲，然后刚才说的就是卡巴的这个年终奖，我觉得还是挺有意思的。然后deep my对我觉得这个。底盘这。对，低卖的也有一个年度的，但是极其快。我觉得这个是一个特别好的一个东西，能带给大家看一下。说到底我们今年讲了一些模型，讲了一些A的进展方面是不是有遗漏。因为大家可以假定丁麦呢就是最有钱的AI组织，我觉得可能没有没有之一，我觉得可能没有，因为你如果把它算力什么的算上的话，我的麦你看他搞的啥，weather next，看名字就知道什么，他年底出的第二版本wether next就是google的天气预测模型，极其牛逼。

对，大家知道那个盘古也大概半年多前发了一个模型，也是做天气预测的。其实大家的思路都是类似，就是我不去搞那么多传统的这种各种的知识的方式，或者这种公式的方式，这个大的机理的方式，然后把它来做预测。我就拿一拿，也不不是那么单纯，但是本质上其实就是我拿巨大量的一个模型来去做这个天气预测的一件事儿。然后准确率比传统方法高很多，然后MO go的其实就是模型拿到了这个MO这比赛的金牌，这个肯定知道，jam ma DM的开源模型，german的这个robotics，它的机器人模型，对吧？这个阿尔法genome就是做DNA这个蛋白质的。基因组的是预测的那个gi 3大战世界模型，2.5 pro nano banana，它有emerge，然后deep think diffusion，这些就不说了，mad jama就是做医疗领域的。

Lara，这个我觉得可以说一下，这个之前应该没有说过，这是一个做音乐的模型，而且挺有意思的。大家如果我看看在哪能么对，如果有一些比如说个人的场子想去产生一些比较有意思的这个音乐的话，真的可以去玩一玩他是怎么搞的。你看就这个东西大家能听到声音吧，应该能听到声音。大家能听到我现在的声音吗？然后你会发现什么呢？这个声音是它动态生成出来的这一个一个的这个八拍都是动态生成出来。然后怎么生成呢？从我这儿后朋克trap，然后什么这是什么玩意儿？Flowing高吉他，然后你可以调不同的，比如说后朋克的，我的调小一点，我要让这个flam mingo什么什么吉他变强一点。

我的是我的电脑卡，我的电脑不知道为什么每次直播的时候都卡，有点奇怪。然后你看，那你还可以再加新的，比如说这个叫什么呢？拆我看看有没有，我也不知道有没有chinese把这个吉他风格变少，我把这个chinese把这些都删了。大家听出来其实名片得有中国风了，对吧？然后如果是中国风加一点放屁。

我去，怎么这么长？就你就大家可以自己玩，这个都是一个免费的。所以如果我觉得这个这种形态的有点像DJ的角色，对吧？但是他的DJ绝对不是这种我们传统意义上认为那种DJ。我觉得如果出现这种DJ那我觉得挺*

的，就是以以后的外部DJ了对吧？就是来点中国元素，来点什么这个来来点什么老北京的味儿，来点伦敦腔，或者来点非洲范儿什么的他就可以立刻的提供给你这样一个曲风的变转化，我觉得这个利润这个效果特有意思。

这个就是你看盯麦的总能搞出一些乱七八糟这种玩意儿，然后image什么的，身份证图片就不说了。Flow since since ID这个就是识别你的图片，你的视频，你的文字到底是不是AI生成的，这样一个东西，利润，real time API它有API的，所以我觉得真的是可以做成这种？交互式的音乐场景，就沉浸式的alpha evo之前给大家讲过吧，就是一个可以自己进化的一个agent，那阿尔法a evoke就是D卖的非常重要的一个今年的一个指标。

然后sine伽马这个挺有意思。这个sine jama我当时看了一下，sine jama他是干啥呢？就是叫什么哑语，不叫这叫那叫什么来着？

就是忙聋哑人用的那个那个手手语说手语，对，然后手语怎么能识别手语？对，就是我们怎么能用一个模型来去识别手语这件事，其实我一开始想的挺奇怪的，我什么场景需要有这个能力呢？就是你看。就是我要用一个模型去识别手语，那大概率证明什么呢？我看不懂手语，然后我想知道他说的是啥，但是我看到东西，对，所以很奇怪。但是他后面说了几个咚东西，我觉得就make sense了。

它其实可以不只针对手语，比如什么比如说部队之间的那种那个叫什么手势，对吧？比如说这个前面有人，前面有三个狙击手，什么乱七八糟这些东西，其实这些手是用这个sine jama也可以识别。那这么一想就这个合理了对吧？然后这个dorf in ja，我不知道大概有多少同学记得这个东西。很有意思的一个项目，多芬是海豚的意思。

对，所以这个多芬jama是干嘛呢？就是我们能不能用一种模型来去跟海豚对话？对，来跟海豚对话。它是一个端到端的模型，就是海豚的声音进，海豚的声音出，然后尝试去跟海豚互动来交流。你看这个是他们会给那个人身上带一个设备，带这么一个东西。That often sounds underwater.

对，然后浸到水底下以后，这个东西就会发生。然后发生就会这个东西就会主动的跟对发出海豚的那个频段的声音，去跟海豚互动。People vantage discover something that因为海豚的声音其实应该是更高频的那个频段，那这个模型就是干这件事情，它用一个音频入音频出的模型来去尝试干嘛，去尝试解码这些海豚他们说话的含义是啥，因为里面肯定是有语义的那我们与其去在那儿像这个语言工作者一样去分析这个东西，这个频率是啥意思，那个频率是啥意思。那不如啥呢？我直接先找一个能跟他说话的玩意儿，然后再尝试去解码这个模型里面到底你在说啥，这样的方式就是多芬jama，我觉得这个就很有意思，就是就卖了搞这玩意儿，然后canvas什么就不管了，然后阿里对，这个安尼亚怎么说？Story book我觉得这个其实大家可以去玩一下的东西。

Story book这个是给小孩玩，小小孩用特别我觉得特别好玩的一个东西。就是你可以直接去，他就专门做了个agent来去你直接说你的需求，然后他就给你做一个童话书，故事书，而且支持中文，所以完全可以去让它来生成童书。而事实上据说有不少AWS上，就亚马逊上卖的那些童话书也是这么做的。比如说我看这个生产比较慢，我就直接把之前的捞出来。

你看他说之前的回答是这个问题是我的七岁的小孩睡不着觉，在这个狼grandma家睡不着觉，然后做一个故事书，他就给我做了这么一个故事书，你看挺好的对吧？这个图文并茂的，而且图片很漂亮，很有意思。好，那是中文，英文的对吧？我怎么搞成中文呢？你直接说就行了，改成中文和我把角色也要改成中国的。而且我你看我这人物还写错了，我写成任务对吧？没问题，他读得懂。

然后你发现奶奶的月光守护者？这个中国的奶奶，中国的小孩，然后中国人挺好的，质量非常高非常高，而且还挺长的这么一个故事。所以我觉得这个story book是一个纯免费的这么一个产品，真的是很棒，然后k go game rena这个就不是，再看还有啥，我看了之前找了哪几个demand reus，这个吧这个对，这个是个啥呢？

就是我们现在看到的各种的，比如说野外的生物，然后那些可能会面临到砍伐的森林这些东西我们怎么能给它做一个模型来去干嘛？来去预测哪一块的森林可能被砍伐，以及哪一种生物可能灭绝。这件事儿可以给它做一个模型来去干，所以这个项目是叫啥来着，我都忘了，没得。项目叫啥来着？我靠都不记得。对，反正就是这么一个模型，它专门做的这个模型来去帮助去建模，说你看它核心是这个东西。

大家想想如果给你一个任务说帮我预测一下某一种生物在全球哪里还可能有啊这样一个事情，你会咋干呢？他们是这么干的，就是我做了一个location的图以及一个spaces，生物的这个叫什么种类，生物种类的这样的一个图，然后把它们之间加上关系，这样的话就可以去训出来一个是一个模型，专门可以预测啥，预测哪里可能有哪个生物，哪里可能有哪个生物这样一件事儿，对吧？那挺直观的那问题是啥呢？哪里有什么生物这件事咋做？所以他们又做另一个模型，专门干这事儿，听声变动物，就是你看mosquito is arrived at the island, exiting most of the other.

Birds that remain are all at high elevation above where the mosques helps with species. nobody. 他就在野外绑了一大堆的录音的设备，然后来去识别这玩意儿是什么东西，这玩意什么虫子、动物什么这些东西来去识别到底这有什么鸟，这有什么生物。所以结合起来，我们就可以看到说，我靠这个就可以有一个地理位置跟所有种群之间的关系。然后从而干嘛，从而预测我们有没有可能潜在的在哪儿能找到某一种生物的一个结果。

对，所以这就是这个项目，这项目叫啥来我都忘了，不管了。然后counter然后这些东西iphone math and gravity sima 2对吧？这个也都讲过，whether next 2，这就是刚刚出的预测天气的第二个模型。然后jama scope就是做模型的科技，而性能第二版本。对，这就是低卖的一年，搞的东西很可怕，对吧？就是大家可以看到这个世界最强，我觉得应该是最强的AI lab了。它的这个产出。对，好，然后这是定麦的部分。

爱泼斯坦这个文本这个事儿我不知道大家有没有关注，但是确实挺挺草台的，就是有些组织开始搞这个东西，比如像这个mr ab尔斯这个组织干了个什么事？他发现其中有一些政府公开的文章文档里面画黑色的部分，其实是背后那个文字是可以拷贝出来的，比如说举了个例子，像18 19页的啥，我看看八十五，84，那我们找一下84。你看这个，对，就是按理来说这个黑的应该是啥都看不到，对吧？就涂黑了，就没有数据。但是你把它拷贝出来出来，比如说我就这样卡拷贝一下，然后在这复制，你发现啥了呢？我不知道大家看不看得清，这个presidential foundation president foundation后面he also什么什么的，然后后面才是85。

所以说明什么呢？说明这一段就在这个黑色的底下，其实虽然标黑了，但是文字在里面，然后美国政府就把它发出来，所以就特别的灶台的感觉对，然后有人就开始分析说这个拿note m去分析说这些遮挡的部分到底讲了啥。对，因为这个我也没详细看，我也不是这个领域特别感兴趣，所以大家如果感兴趣可以自己去看看这个有人把爱波斯坦里面的那部分，这个填黑了的部分专门抽出来看分析到底背后对应的啥。

当然有一些传闻的那些什么什么川普rap了谁啊，那些东西我觉得大家听一听就完了，就是好像是假的那个东西。好，看看还有啥paper就不讲了。好，我觉得这个图特别*。这个是apple的AI，apple AI也是一个做AI领域非常深度研究的一个组织。这个apple k ai他做了一个网站，这个网站专门去观察全球各地最主要的AI数据中心的情况。你看阿里巴巴的张北，然后这个core wave的什么helius，然后google的、meta的，然后XCI的，colosse的，这个一和二都有。而且细到什么程度，你看这就是阿里巴巴张北的数据中心，非常的清晰。

好，然后你往下放往下看啊，我们看哪一个呢？看找一个大一点这个大一点。这个就是他分析出来的这个阿里巴巴的张北的数据中心里面，蓝色的代表的是冷却设备，cooling设备在这儿，它给圈出来了。这儿好，然后这个粉色的这个代表了电网，这个橘黄色的就是变电站类似。然后这个建筑就在这儿，这个蓝色浅蓝色的，然后他如果能标出来的话，告诉你什么在场在在地的这个电在哪儿。就因为肯定会有一些备用电源或者什么本地发电的这样一些东西，这中国好像少一些，这个主要是美国那些会有。对，然后他会告诉你啥，你看这就是他的建设状态。他分析了说，大型的这个变电站好像已经明显已经输电网络连接了。

16号到18号的楼的新冷水机看起来已经完全就位了。14号也安装冷水机，然后采用旧款设计，我靠这么精准。然后预计14号到16号到18号已经具备运营条件，然后其他的也接近尾声。建筑周围仍有施工设备。这就是它纯从你的卫星云图，高精度的卫星云图上分析出来的结果。所以这就是一个非常牛的这样的一个AI领域的分析公司。

它能做到长度，而且你会发现什么？你把它往回倒到25年初的时候，你还能看那时候的图，但这时候图的精度就很低，就没那么高。然后说明啥呢？说明可能那个时候他没有这个泛泛的，就有可能还没建起来什么的。然后直到最近，比如说这个很清楚了，他才就是进度很不错了，他才开始要这么高清的图，而且越来越高清，从中可以干嘛？大家可以想想这玩意儿我能判断啥，对吧？就是我能判断所有这些大模型厂商，它背后的算力的建设到底咋样了。

这件事儿是非常对吧？投资是非常有决定性意义的这样的一个数据。所以这个apple AI我觉得这个而且关键台给公开出来，我觉得这个挺*的。你看最底下还告诉你说，到底有多少电，然后算力有多少，然后大概cos多少，花多少钱这样一些东西。然后你可以看到所有的，比如说XAI的地图，这个就更细了。你看这个还会有这个备电源在哪儿？然后冷却在这儿，冷却在这儿，备用电源在这儿，然后还有outside power，应该就是本地的电站，就是在在数据中心里面的这个电站在这儿。

对，非常清晰的给你标出来，所以我觉得这东西，老美做这方面做的很细。好，大家说到这个策略中心很核心的就是电，对吧？我觉得逐渐的发现了一个很明确的趋势，就是人这个美国人叫了半天好像也没啥变化。有一张图是什么？这个马斯克点了个赞是啥？

所谓开发发达国家就是个谎言，他举了几个例子，当然没有加美国，是欧洲、英国和中国。这个是什么呢？是每人的发电量，单人的发电量。第三个是中国持续往上涨，持续往上涨，为啥呢？一是咱们制造业很多，二是二是我们的电的需求其实也很大，也持续往上涨。图找不到了，不管了。

对，就是中国人的用电需求也在持续涨。反而什么呢？你看欧洲、英国他们的单人发电量其实在下降，就是这个挺挺神奇的，就挺奇怪的一个发达国家，怎么会这样呢？

对，所以有的人评估什么，就是美国的输电网和配电网有望在未来几年有一个巨大的投资额。当然川普也早说了，但是缺口是啥？缺口是电工。对，他说未来几年会新增50万个电力和电网相关的就业岗位，然后这些人还需要3到4年的培训才能实现。而现在美国能源行业有4万人的在职学徒，所以有很大的缺口。所以啥意思呢？我就觉得咱这帮走线的去干点有以后有技术含量的活儿。

好，另外一个就是NV的I九点了，我们就快速说一下NVIDIA买了一家公司，其实也不算绝对的买，它只是有一个非独家授权这家公司grow GROQ，不是那个GROK。Grog这家公司是专门做推算，叫推理的，就是模型推理的。他加的非常厉害的一点就是比如说你同样一张卡在你家，比如在质朴不是，比如说在mini max它能推50 token每秒，但是在brock手下他可能就能推什么200 token每秒。就是它整个的从硬件到推理引擎这部分都做了非常多优化。所以同样一个算力，它能发挥出几倍以上的效率，所以rock这家公司干这事儿，大家想想

NVA买它是啥图啥，对吧？就是他要在推理算力领域要去继续加强。因为确实NV的N卡它在训练领域里面是在全球来说是一个独一无二的霸主。但是在推理里面越来越多的人开始挑战他了。

然后这个里面带来一个话题是什么呢？推理这件事儿真的那么没有，或者推理这件事儿除了做优化以外，是不是就没什么太多技术含量呢？这张图当时我其实看的挺震惊的，是啥呢？代表了什么？不同的叫provider，就是你的模型。当然你可以跑在比如说比如像这个GR质谱的模型跑到ZAI上，那就跑到自己家，自己登录云上和跑到别人云上，它跑出来一个模型的准确率是不是一样呢？结果是差这么多。

你看如果是GPT的那个开源模型，各家的推理出来的准确率差不太多，只有这么几个单独的点，然后kimi就已经差别很大了，对吧？这些模型这些供应商或者叫这个模型托管厂商跑的都还行。这来了几个特拉胯的，40%、60%，甚至还有百分之接近0%的这样这种模型退供应商。然后质谱的其实也是，你看这个有标准的比较好，头部的供应商都还不错，然后其他的很多供应商就会把这个准确率拉得极低极低，为啥呢？

这篇有一篇文章就专门讲了说其实为什么这个推理这件事儿是一件很难去统计的事儿，他给出了一大堆的原因。比如说这个模型厂商会有看看什么来着，会有很多的报错的部分provider。对，在这儿模拟厂商会给出一大堆什么限速，然后没有到上下文长度就给我截断了。然后这个实际上下文低于宣称值这些乱七八糟这些东西，然后它包括一些参数，max token或者这个K值P值这些不一样导致什么呢？就导致你其实推出来一个模型的效果，各家的这个provider出来效果很不一样。所以在意味什么？就是大家如果要用别人家的模型，最好的选择就是选那些头部的推理厂商推出来的模型没了。

好，那进入模型的部分，我们看GM4.7，这个GM4.7跟G跟mini MAX的M2.1其实都在上周发布的，为啥呢？很明白，就是发招股书的时候，我们得秀一下肌肉，对吧？那GM4.7跟那个啥跟那个mini max 2.1，我们直接把它都打开看一下。

前期你看就比较无聊，虽然大家都在往上涨，但是都挺无聊的，都在讲说coding能力越来越强。然后mini MAX也是类似的东西。他拿了一个特别小腻的垂直领域的这个话题，叫多语言的编程能力越来越强，这样一个概念，待会儿就看看啥意思。Coding能力越强，就coding呗，就扣呗。但是我觉得这有一个大家不约而同选择的一个新点是什么？我开始讲外部coding的能力了，啥意思？就是你拿我做一些不严肃的coding的时候，效果咋样？

这边就开始说了，我的模型4.7的模型在界面上更简洁、更现代，然后效果更好，布局更精准。没了，就这么个东西。所以y coding他就讲了这么几句。

然后mini MAX回过头来看，mini MAX的这个讲点就刚才说的marty language programme，我觉得这个倒是很有道理是什么呢？我们现在开发或者拿大模型来去开发应用，越来越不只局限于写python，写java这样一些标准的或者很经典的语言越来越多。开始什么写什么安卓，写IOS应用，甚至写一些很底层的什么操作系统层面的一些rust这些代码。

好，开始说白了就是那些比较专业的领域也开始这些人也开始希望能外部起来了。我最近感觉到一个很明显的点是什么？就是安卓的安卓studio的最新的gym I的编程的能力越来越强我就举个例子，大家可以看看安卓studio，这就是android studio，就是你可以在这里面开发一个安卓应用这么一个东西。然后以前大家都这个肯定是写一个安卓程序，肯定是大家希望找一个专业的程序员来去做。但是我最近就用它这个东西，就是右边这个chat，他这个东西就是接的是jimmy的模型，然后我就直接给他说了，我要开发一个什么什么玩意儿，然后这个业务流程啥样，我希望你把我本地对接那个设备的SDK，就是开发套件，然后给整合进去，完了就OK了。他就大概花了十几分钟，就给我把这STK整合完了，而且还能用。然后我就开始说了，帮我删除现在sample数据什么这些东西他就照着做了，非常方便，而且相对比以前我用的时候准确率高了非常多了。

所以大家如果有比如说写端侧统端端侧应用的，比如说IOS，写安卓的，写这个，对，反正就这种设备端的，其实真的是可以去用开始用模型了，尤其甚至是包括什么嵌入式这些其实都可以考虑。对，然后网页应用什么的就不说了，然后看看还有什么。好，到了web coding，mini MAX也讲y coding这个故事。

你看他在讲说在什么什么上表现优质？在靠code，在joy、在key low code，这些很多其实都是web coding的用户专门用的事儿。然后专门他还做了一个什么事呢？干什么？他们为了表明说我现在模型在web coding领域里足够好，专门自己发明了一个benching mark，叫web web奔驰。当然这个是有好是一个组，比如说写网页应用的web写网页应用web写安卓应用，写IOS应用，写后端，都可以web起来了。它对不同的端侧都做了一些单独的单串。

然后最后总结是什么？平均老子最强88，然后第二名是85，对吧？这个我觉得自己做一个web benchmark，我觉得是挺好的一件事儿。但是不好的是什么呢？你别一上来就把自己奔驰的第一，这是个问题，我觉得这个永远这个奔驰二的问题就是我们做奔驰marx的目的是为了，尤其是大模型厂商做奔驰方的目的是为了给自己指条路，指一个奋斗的目标。而不是我出来就告诉大家，**老天下第一可以了，这个最强了。所以我觉得他做这个事儿挺不错的，但是结果这个有点奇怪，也不太奇怪，反正就是不是很建议干这件事儿，不是很建议这么干。

好，然后4.7这边我就质谱这边就相对来说比较严肃了。你看就很像这个传统的模型发布的这种奔驰码的列表，然后给了一些case。然后case反正很中，相对来说比较中规中矩。

对，然后跟上次deep seek v3.21样，我不知道大家还记不记得deep seek v3.2的时候，提了一个叫什么呢？叫交错思维的。这个东西就是你一次掉一次模型，它可能背后掉了好几次工具，而且思考了好几次。边调工具边思考，边调工具再次思考，最后给你一个总体的结果就是我这个需求掉了。第一次工具什么结果掉第二次工具什么结果？最后一次调完了以后，反馈怎么样一个结果，这样一个东西等于是模型层帮你包了很多层数层的这样一个推理加空气调用的这样一个过程。

这个4.7和这个mini max都提了一个东西，都叫交错思维。还做了一个质朴，还做了一个相对来说更泛化这一点的水平。就是我最后不把每一步每小步的推理过程给隐藏掉。

刚才那个deep stick v3.2大家看到了，我把每一步调工具的之前thinking的过程，我在最后输出的时候我把它隐藏掉了。我只显示调了是啥工具，我啥调查工具，结果啥thinking的部分全都隐藏掉了。质朴觉得我可以选把这个中间调空这部分的推理也留着，对吧？就是大家都在这种小点上去优化去的，也不是不对，我只是说我也感觉像那卡帕西似的，就是逐渐的感觉有点乏味了，就是这种小点的优化有点乏味了。好，这是这两个。然后我看一下mini max这个就不说了。

对UI很强，这也是没啥好。然后我觉得这个模型是非常值得分享的，而且尤其是我们有一些比较垂直领域的同学，就是要做垂直领域的agent这领域的这个很很偏小的领域的是可以参考这个东。其实google在啥时候一周前发了一个模型叫function jama对吧？一旦到java那就是开源的模型对吧？那function啥呢？就是函数。所以这个开源模型专门干的一件事儿就是什么？就是做函数调用，就是只做函数调用，几乎可以说只做函数调用的模型，那它能干嘛呢？

我们直接看看这个例子。Show actions, 你比如说你可以直接做一个应用，对他他做了一个demo应用是干嘛呢？就是你可以直接说打开闪光灯，创建一个用户，然后创建一个calendar什么的，都可以直接靠说的。Beston function, just lunch tomorrow, you can see the sequences here.

看有没有绿。对，说白了就是什么呢？就是你看这interprets the commands，他是什么呢？他说帮我创建一个日程，明天同what are the model？你看创建一个开放的日程，明天中午的午饭对吧？他就可以识别到他要调的是创建calendar事件的这么一个函数。那就把对应的这些参数都填进去，直接在安卓里面你就可以直接调起一个什么它叫intent。然后直接创建这个calendar，就一键就完成了。

他还做了一个挺有意思的一个点是什么？做了一个地址。On the google play store，他专门做了一个小游戏来去演示这个方生jama的一个水平。专门他训了一个，因为这个模型很小，这个模型我看看才270照，也就是0.2B这么一个模型。这个模型其实训练微调起来就很容易，所以这个模型说白了就是专门是为大家用来做微调用的。你可以把领域里面的这些function全扔进去，然后让它微调一个微调一个专门干这事儿的function的模型。

你看这个是他做了一个小游戏，这就是一个什么反正种花什么的一个意思。然后你可以说什么呢？我可以说it's some flowers in the time。冲一个向日葵在最顶上那一行，并且给它浇水，他就开始了，它就自动的执行。因为它是这个游戏里面自己用的，所以在哪种花，然后怎么浇水，这些其实都是对于游戏来说的自己的一个API。所以他做这件事情就代表就带来一个什么结果呢？就是用户可以靠说的玩这个游戏，因为他靠说的识别完了以后，自动的可以去调这个游戏里的具体的API。具体的API你就看他怎么去操作就好了。

所以我觉得这个例子特别好的一点就是我们好像以前确实没有这么玩的游戏，对吧？就是你想各种游戏都指望你去点来点去，然后完成具体任务，还要花费非常无聊的重复的劳动来去做这些事情。那我们以后游戏是不是可以这样靠说的，然后靠说的需求怎么对应到当前游戏页面里面的具体功能呢？就去一个专门的方式gamma就喂完了。而且一个0.2B的模型几乎可以说在现在的新的模新的手机里都能跑。你就在云端去训就好。训完了以后很快，可能半天都不需要就可以训好这个模型。然后部署在手机上，你就拥有了一个可以玩游戏的这么一个语音助手。

所以我觉得这个function java是一个特别值得大家去关注的这么一个模型。而且很有可能是可以落地到我们的很多的这个比如说功能有限，但是我们希望让他用自然语言来去交互的这种场景。而且注意自然语言交互并不是说做一件什么事儿就只调一个方式，有可能掉好多方式。比如说刚才那个种向日葵，并且把它给它浇水，它其实是连续调了两个方式，甚至掉了好幾次，四次放水，或者六次放水对吧？种一个花儿再种一个花，再种一个花，然后再浇水再浇水，再浇水，等于调六次。当然这取决于你的API到底怎么设计的，所以就是我觉得这是一个特别可以值得去去去参考的这样一个设计思路。

然后他还做了一个什么呢？拿function加码做了一个物理的游戏。我不知道这可能加载的慢一点，我们可以等一等，我们先看看这篇文章，我觉得这篇文章跟刚才那个有点异曲同工的意思。这是哪儿的？

我看看哪几个学校。那不是啥，这都是啥学校？对，cambridge什么几个学校？对对对，出的这么一个东西是啥呢？他做了一个蜂巢的A是风多A整体的框架。这多这个框架用来干嘛呢？用来预测蛋白质序列的设计。

对，而且它的多A正题每个A正A问题小到什么程度？就是某一个可能突变的位点，有一个位点就有一个A阵，有一个位点就有一个A证。你可以想象，比如说我一个蛋白质40个这个DNA转录出来了，那我就有40个A针。然后每个A人就很简单，他们会有一个总体的目标，有一个大的总体目标，但是每个A人干的都非常单纯，就是我怎么把我手头这突变位点的突变给变对变成一个可能更能得到最终结果的这么一个突变。然后他们通过靠这些agent之间互相的互动，以及他们自己做决策，就能实现一个总体的一个蛋白质预测的这样一个蛋白质预测，对蛋白质序列设计的这么一个很好的结果。

那他这个事儿带来一个什么结果？就这句话就是你如果把每一个A镇做的这么小，那你意味着什么？意味着你这个模型，这个小的A朕所用的模型可以很小，可以非常小。这就代表他得到他这个结论，就是他这个方法就是弄了一大堆A证，然后代表那些突变位点，然后通过一个涌现的方式，协同的方式得到了一个蛋白质设计的好的结果。整个过程只需要在数个GPU小时内就可以完成。这比传统的那种，大家知道刚才刚看完DD麦的那个ala g比那个方式节省了可能得有两三个数量级的GPU这样一个量应该是至少两个数量级的一个GPU的量。所以这代表什么？就是好像我们现在看到这种小size模型又有机会可以上台面了。

怎么上台面呢？通过这种大量的微型的agent的封群或者叫组队的方式来去实现一些比较复杂的功能。对，就是大家想想那个大雁的故事，对吧？大雁为什么大家自己飞自己的确能形成这么好的一个队形呢？就是因为每个人的策略都很单纯，然后总体就形成一个好像一个群体智能一个样子。然后刚才那个function java他做了这么一个例子，这么一个游戏，这个挺有意思的，这个大家可以玩一下。就是他做了一个物理空间，然后让你去通过方式jama来去完成这个任务。

比如说这一关，第一关就过了，第二关是这样东西，我的目标是让这个球到这个够，我怎么实现呢？靠说的，你看我在这说，比如说在中间加一个球，圆形。没能理解，在中间加一个长长条儿，看看能不能理解。应该出来吧？这么一个长条这就是我家的，但是好像有点太小了对吧？那我把它删掉，再说一遍，长度为三的长条。出来对吧？我觉得应该这关就能过了，你看它滚过去，OK了，过了对吧？

所以跟刚才那个游戏很像，就是我们是不是可以想象下一代的游戏都是都有一种类型的游戏，就是这样，就是靠说的。而不是在那儿调来调去，拿鼠标拿手在键盘上去去去去调来调去的。才能实现一些比较细节的这个功能。所以我觉得这个是一个挺有意思的方向，就是function gamma带来的我们的大量的小型模型其实是有机会又焕发生机这样一个东西。

OK好，那我们我们太太太慢了，我想的我先过了然后我们直接到最后先看一下mini MAX的这几个事儿，质谱跟mini MAX其实都算是中国的6小虎AI6小虎。六小虎我是谁啊？大家不要把deep thick算进去。这个deep sik不是六小虎，这个比6小虎牛逼。然后瞎说，然后质朴mini MAX百川，岳战面、灵异万物和皆月，这个mi max是刚上的。

然后这两个公司是非常的差异非常大的。质朴是一个几乎是个to b to g的一个典型的to b to g的这样的一个模型公司。当然大家都主打的是自主的这个大模型了。

然后投资人大量的国资，阿里、腾讯什么的都投了。你会发现什么？阿里投了几乎所有的大模型公司，真的是阿里投了几乎所有的保险公司，而且他们投的挺早的。不得不佩服说阿里整个在战略上面的预见性。我之前有一个朋友就在阿里这个战投这部分，他们投了挺早就投了一圈，后来估值一上去以后基本就停了，就不投了。所以我觉得这阿里的模型也强，然后他们的战战头确实也挺不错的。

然后mini max就上几乎全是上当系的，然后这个俊杰，然后严俊杰，这几个人都是核心，几个人都是商汤去的。然后他们的思路，其实就是基础大模型，尤其是多模态大模型加C端爆款应用。所以他们的主要的产品是海螺，toki这样的一些产品。

大家可以看看这个mini max的官网，然后制图的官网。对，因为max你看这俩官网一看就不太风格不一样，对吧？这就是质朴的这就是mini MAX对吧？就是明显是mini MAX是针对海外用户的，质谱也还行，这个没那么土。

对，然后我们看mini max它的文本模型？M2.1，然后语音模型，speech, 2.6就是文字转移，然后video就是生成video生成视频的海螺。然后它最近新增了一个music模型，music 2.0，这个生成音乐的模型，然后它

的产品就是agent产品，就是它官方的这个MINIX官方的这个产品了。大家直接在mini max点IO就可以用到。这个模型还挺不错的。

我我这个我算是他的付费用户，我是他的这个基础款的付费用户。然后直接试一下他的audio，我觉得audio确实还行。然后其他就是海螺，因为我很少生成视频，我就不演示了。然后有音频的有talky，talky就是它的重磅产品，这个几乎是他的营收增长点，也不叫增长的营收增长，就是它的用户增长点的非常重要的一个产品。

大家可以看一下这个是个啥，这类产品都有很大的一个问题，就是我开始都不知道咋选，你看这个什么称谓你想用呢？那到底是我还是他呢？就是对吧？然后年龄大了，然后你的期望的关系不明白，我就可能是老了，不明白男女的。好的，然后出来就这么个东西，然后你就可以干嘛呢？可以选人去聊天呗。比如说这个百里，他是你的什么？他是你姐姐的好朋友啊，然后他喜欢一个人，点开你就可以跟他聊了，对吧？嘿，还有声音，但听到没有？Hey, is your sister home?

对，所以就是很很标准的这种所谓的role play，或者这种角色扮演，或者这种create AI这类产品，它在国内叫星野，然后海外产品叫turkey，几乎是一样的。肯定就是模型和这个叫什么边界的差别了，大家知道边界啥意思？好，那基本就这品。然后他我觉得他在turkey上确实是挺不错的，这个效果是有的比的。但是这个领域的竞争也是极其激烈的对吧？大家知道这个上有correct AI，然后还有各种类型的这种陪伴类的这个角色，都就他的门槛其实并不高。然后A的这种通用A的其实竞争也很激烈对吧？

它等于是minus的对标，然后这个toki对标correct AI然后语音的部分对标的其实是level laps，对吧？这个之前给大家讲过的eleven labs也是一个专门做语音agent的产品。然后合成声音，然后做声音设计什么的都做的很好。我们看看这个MIMAX也是这样的一个东西，就mini MAX的这个audio部分也是这样，你看它，所以它主打的声音都是这种，比如whisper to sleep，大家听听。你怎么不说话呢？那能听到大家能听到，对吧？就是很很那个啥的声音。然后比如lecture mode就是很正式的这种声音的。Couple and e with two inputs, an inverting input marked with a minus sign and a non inverting.

对，这就是它的audio的部分。然后到audio部分也有标准的所谓的语音设计，就是你想要个什么声音，比如说一个非常威严的帝王声音，然后让他生成一个，都大胆，还不跪下给朕磕头，磕100个头，看看能不能生成一个效果。对，就是这个以voice的这这部分已经变得很标准了，尤其是已经对标像eleven lives这样的公司？你看text to speech这个很标准的，然后变音，声音的效果，然后它也出了一个voice s later，就是我把一个视频里面的声音给或者把一个声音里面的具体的一个人的声音给抽出来，然后有很多还不跪下给朕磕100个头，对吧？你看还行，对吧？这个不算太差，或者说不算太出戏，然后也算是可用。

这个was design was colon，我擦so little大家都是一样的，所以mini max的audio部分几乎可以说是对标这eleven less这样的产品。然后它的A站部分对标menus，没什么太大的问题，所以它其实可以看出几乎就是全针对C端的。他C端用户确实比较活跃，但是收入肯定是不稳定的这块我就举了一个例子，就是刚才搜的时候，之前搜的时候碰到一个问题，比如说中国的六小虎，是吧？中国的AI6小虎。六小虎，好的，这次没出bug。对，之前我搜了好几次都出这个。他直接给我列出这六个人来，这六个人是谁呢？是这篇英才的文章的作者记者，六个记者。

然后他列在这儿，也不知道为啥，所以我觉得可能是google有些页面有bug，回过头来就看这个，对，就是整个的从数据上来看，大家其实都在这个量级，24年都在营收，大概没有这么多。三个亿，反正工卡，这就是AI说的这就是AI说的3.1个亿24年营收，然后mini max是三千多万刀，对，所以乘过来差不多两亿多人民币，那增速都很高，这个增速只是24年比二三年的增速都是100% 200或者什么，他应该到700的这个增幅。25年的上半年1.9，然后大家可以想象这个double一下或者乘个2.5，然后mini max是5344，几乎是前对，几乎是前九个月就5344，就是快达到去年了，所以这个增速也非常快。所以mini MAX在C端的收入可以看到是一个非常快速增长。然后它的增长里面，甚至如果你把他的星爷，就那个那个talky创掉的话，它的毛利也很高。

净亏损大家都一直在亏，对吧？亏30个亿1年，然后mini max一年亏37个亿，烧的非常快。所以这个基本上比起营收来说，差不多是1比10的这个倍数，就是赚一块钱亏十块钱。当然这个也挺正常的，因为很核心的这个开销都在算卡算力上对吧？都在卡上。对。然后支付的主要收入来源就是MaaS，就是所谓的MaaS就是开放平台了，卖API，然后本地部署，本地的开发服务这些，甚至一体机或者给客户做的定制开发的服务，其实都是主要的收入来源。

然后mini MAX就很少了，就基本全是to c的订阅，所以大家路线的不一样，也直接把这两家公司分成两个市场。一个是主攻国内的信创政企to b to g然后mini max就是出海外的这样一个市场，所以很正这个没啥，可就是这两个同时上市都都不太会蒸的。然后那里面我觉得有几个点，比如说质谱其实会有在，我看看能不能找到那个年报。

对，所以这个从产品上来看，mini max的产品可以理解成是一个通用agent对标minus视频部分对标sora这种玩意儿。然后音频就mini max audio对标的是eleven lives。然后他的turkey对标的是CEI，就是correct AI就是一个特别全的全面做C端产品的这么一家公司。他上市我觉得我不知道，就完全不知道他的战略是什么。但是我觉得他真的有可能也想往着自己的这这种应用工厂的方式来去做。就是AI应用永远都有新的，都有死的。但是我如果能把它打造造成一个不断产生新的AI应用的这么一个工厂，那我就能持续获得非常高的收入。

对，太朴素了，指的是太朴素。啥质朴？对，质朴特别质朴。然后对，质朴还没有说这个哎太朴素了，是这意思吧？质谱的这个网站大家可以看看，模型这么多。GM4就是语言模型，GM chage UM就是聊天的这个模型，然后coggs就是写代码的模型，code view.

这个质谱的模型有一个规律，就是code开头的特别多。Code就是cognition，就是认知的意思，认知模型的view就是生成图。然后认知的VOM就是生理解多模态，比如理解图片或者理解视频，然后auto GM就是那个操作，这个上次也讲了，就是跟豆包似的那样一个操作用户界面的这么一个模型，所以大量的都在说模型。然后在mini MAX那个网页里面，这一列指的是它的research，对吧？你可以看research质谱了，就直接模型AIGC产品对吧？大家有没有觉得很久没有听过AIGC这个词了？对，但是我们就管它叫AIGC产品，智谱清言AI平台API平台。

这个auto GRA minor是一个特别的古早的产品，这是主要针对学术的用户的。就是你整天要看paper，要研究新方向的话，或者追踪新的研究方向的话，可以用这个a minor，非常好用的一个东西。然后有时是面试的，我记得是。Coco是我们的一个A站平台，所以就很单纯，然后还有服务对吧？这个商业质朴当然有一个自己的投资机构，所以也会做一些这个投资方面的事儿，但是最近已经不做了。对，所以就这么单纯的这么一个业务。所以质朴讲的故事是什么呢？不是我说的，这个是推特上说的这个质朴讲故事是ano pic加plantier，SO pic就是coding很强的planter，大家上节课听，就是这个AI的to g的AI公司。

对，所以这么东西好，那两家的招股书我们可以看一下。这个我觉得分析的比较好的是这个家伙computer king，computer king计算王这哥们儿。但是我觉得总体来说，我看看完这个分析以后，我觉得没有什么意思，就是确实市场就这么看看待这两家公司的，但是也就如此。对，就是没有什么太大的亮点。当然可能市场会觉得已经不错了，就是独立的大模型上市好像真的是第一家，就是智博跟me max是第一家。因为你想拿什么open I什么的都没上市。

好，这种公司都是以叫18C的，叫特专科技的这个身份上市意味着什么呢？是意味着很可能大规模的持续亏损不赚钱，那那这个高PE就不在于说你的盈利多少，而在于说你得蹚这条路，不可行？以及你的MaaS模式或者你的别的模式是不是可以形成确定性的现金流。对资本来说就是标准的MaaS模式。

然后以及可能说agenting或者什么的，未来的这个方路线是不是真的能落地，所以这个就是一个从他的说法就是更像一个大中华资本对于中国大模型厂商商业化可行性的公开投票行为，对吧？这个是一个尤其是针对质朴这样一个to b to g的公司，那却更是一个对大众化资本市场对于中国的模型，服务中国的客户情况下，商业化不可行的一个公开投票行为。那有结果是啥意思？大家也就如果真的上市以后，结果啥大家也就明白，这就是资本的态度。

智美家公司其实是19年成立的，算是这些大模型公司里面成立比较早的了，19年成立的从这机器的这个KEG实验室，大家如果知道这个很很著名的知识工程组，这个实验室成立的，就是这些人都是从小儿出来的。你看就开始找补了，也不叫找吧，就是质朴的商业基因，既不是应用驱动，也不是to c流量驱动，而是通用认知模型的长期目标，对吧？大家看看就好啊。

然后几个关键时间点，21年、22年、24年、25年是一个高产期对吧？就是各种模型都进入了一个越来越成熟，发布越来越可工程化的越来越好的这样一个阶段。然后融了多少钱呢？前后融了83亿，这个融的还是挺多的。而且披露一个PIPO的一个层，然后投了谁投了呢？就这些家伙刚才说了阿里之外，小米也投了。所以而且小米很早投的，美团很早投的，所以美团里面其实也有一部分模型用的是质朴的模型，虽然他现在也做了自己的什么long time模型。

然后国资和头部VC都投了重金什么这些，为什么这次的apple招股书上也是中金，我记得是，然后大部分钱肯定都投在算力上。你看24年就投了15亿，在算力上非常多。然后营收几年三年间5700 1.23.1，相对来说还是一个几乎可以认为是一个double的这样一个阶段。然后今年能不能打爆？不好说，但是至少是一个商业化比较稳健的一个步骤。

然后研发费用这样一个费用？也是很可怕的。这个8500.2 21这样一个上半年15这样的值，然后现金有25，对，25。那从研发费用可以看出是什么呢？就是25对吧？除一下就知道还有多少现金流了，然后这个就没啥可说的了。

然后这个就有个词儿叫pure play，就是mini max跟质谱其实都被定义成叫pure play玩家啥意思呢？就是专注做大模型的。当然你说mini max是不是专门做模型的，他做那些应用其实好像不是专注。但是它的核心的，比如说议价核心的这个能力都是自己去基于自己的模型做出来的。所以也可以定义成是一个pure play的这样一个玩家。就是不依赖于外部的流量，不依赖于不其他的收入为主要来源。你看不以云计算和硬件核心收为核心收入来源指的是谁，就是那些大厂，比如阿里什么那些，他肯定不以卖模型为主要收入，那我就专门专门卖模型，就那些阿里云什么的，就可以以云的服务的收入来去来去cover这部分商业化，围绕自己的模型能力。

有人问这不上市，你说上市肯定不会太安静，一般做什么呢？我没听懂，一般做什么？其实已经今天讲完了，我们讲了GM4.7对吧？对，rise很清楚。对，然后他所谓的聆讯，然后加上招股书发出来可能还得有一阵子。然后很有可能是mini MAX会先上。然后比如一月份，然后一月底或者二月份的时候政府再上，基本就是这个节奏。然后因为大家看到了，其实就是当然就刚才说那个那个不太安静，就是肯定不只是发招股书时候不太安静。

然后明年大家可能比较预期的也是在明年春节期间，就是在去年的R1就今年的R一发出来的这类似的阶段，会有另外一波的浪潮。但是这个浪潮肯定不光是这个，几家模型公司发个模型肯定是一个有可能是一个更大的一个声浪，对吧？就是一个大家想想这个r two怎么忍了一年都没出来，然后国内的这些GPO公司今年都疯了一样的上市，对吧？

那明年讲啥故事呢？不能继续讲这个单串要涨往上涨了十个点这个故事的。那结合刚才说这两类的公司，我是不是可以讲一个更大的故事，所以大概是这样的一个意思。所以好，然后这儿。

对，市场占有率6.6，这是啥玩意儿呢？你看这个招股书。直接看这个招股书，就是质朴的这个招股书。然后大家直接都可以看到的，就是在线都能看到的。这里面其实挺有意思，这太长了，主要是特别讨厌，而且我也不擅长看这种东西，主要是所以这个我看看能不能找到。对对对，这儿他会有这个行业的，叫什么行业对比。农业公司A跑去了。

这儿对你看到从收入来说，中国的头部大模型厂商排名，它拿的是24年的这个榜。然后本公司是在第二，对吧？然后第一个公司是谁呢？是合肥的，大家都知道是谁了，对吧？然后第二名B是杭州的，是纽交所跟香港的上市的，也知道是谁了。C是一个做视觉的为主的，应该指的是商汤，我也不知道。然后四是谁就不管了。然后AABCD你看这个收入都很低，说白了就算A也只有0.44个B0人民币，然后市占率9.4%和6.6%。

B和C其实都是6.46.1，其实拉没有拉开太大的差距。当然25年现在没有这个数，大家肯定要赶着这个时间点去发。而mini max我觉得更有意思一点，我看看能不能找到，看看前十第十。这儿是不是这个？对对对，mini MAX讲的故事就是全球的故事了。他说全球大模型技术公司排名，基于模型的收入，即2024年了，这个也是公司的ABCD乱七八糟这些东西。你就看这个猜谜就行了，我觉得挺有意思。因为我看这个看的少，所以我最近看这个时候发现挺挺搞笑的，这个跟猜谜似的。

公司A是一个美国的大模型公司，公司B是一个美国的公司，然后它在哪儿呢？它在第十关键市场市占率A30%、16%、8%。A到这儿了以后，百分之第八名以后就0.5%了。百第九名到第15名、第13名，都是0.3%，所以就是全球第十也OK，对吧？起码进了第十了，前十了。从全球的维度来讲是这样。所以大家都会找到自己去叙事的方式，我只能这么说好，然后到哪儿来了？到这儿。

然后这个6.6的市占率在国内6.6的市占率。然后刚才看那个图就是04年24年的，然后规模是什么呢？多少对吧？这个质谱这家公司肯定不能讲这个to c的用户规模，那个东西就没有什么太大比。这个大家看了吗？前两天豆包应该是过亿了。豆包的那个那个是月活，过亿了，太可怕了。

对，然后那那能说啥呢？比如说赋能设备的数量是8000万，那怎么叫赋能设备的数量呢？大家可以自己想想，然后模型影响力，hanging face open router这样地方，这表现卓越没问题，这个合理。

所以就开始说底下东西了，那商业模式怎么怎么做什么呢？所谓的MaaS就是卖API。但是这个其实更多的是这类的本地化部署。比如针对金融政府这类企业提供私有化的部署。还有什么呢？云端部署对吧？就是我们可以直接把你想要的模型跑在你的云上，也可以当然也可以直接跑在在API平台上，也都算是云端部署了，所以这个事儿所以最后说白了就是一个to b to g的中国的大模型公司。

然后主打这点，所以总体的估值好像是二百多少来着？250 260多，反正差不多这个量级。然后mini max比这个估值还高一点，因为它是美元计价的，好像是三四十每三四十亿美元的这个估值。

好，那我们看看这个mini MAX这部分，然后也是投的，但是它的政府基金其实投的很少了。比如说就是米哈游，阿里这样一些公司在投的，然后累计融了15个亿，也很多非常多了。所以它比质谱绒的还多，然后主要在做的M2也是在卖这个coding的这个方面的这个能力，就不说了。然后你看这个就比较有意思。在著名聚合平台open road上，mini max m2的日消耗峰值跻身前三，成为最受欢迎的国内大模型之一。

好，那什么时候跻身前三了呢？可以说几乎就这么一两天。所以可以看到大家去说这类的模型的时候，都是非常精准的挑中那个点，比如说我们找mini max就open road，大家知道吧？这个说了太多次了，mini max在在总榜里看不到它，然后我把它扩一下都看不到，前20都看不到对吧？没看看不到，对，还是看不到，然后market share里面前十也看不到，当然这个是按天的了，比如说这个是不是之前有的，好像这儿有对吧？这个紫色的这个看到没有？就这几个是mini max这个紫色的。

在曾经冲到过前三的意思是什么呢？就是在某一个垂类，比如说成programing编程里面，然后曾经冲到过前三就可以这么说了。然后这个期间你看维持了多久呢？这总榜里面维持了多久呢？123456就六周的露出时间，也还行，一个半月的时间。然后其实高频的就是高高使用量的也就两周的时间，所以大家其实都会是这样。

然后大部分很多模型你会看到它是一个逐渐缩小的功能，像这个，这是谁呀这是谁？这是meta，拉玛，我靠，拉玛还有这么多。然后很多模型你看涨涨又缩缩缩缩，然后也是一个一会儿变多一会儿变少，慢慢变少的一个过程。对，但是你如果说这样的一个过程的话，那我只能理解是一个一个事件，然后programing这个里面其实会有他，然后其他的角色里面就很少有了。

对，你看role play几乎就没有人会用mini max，不是几乎就肯定没有人用MIMAX。之前给大家讲open route那一期的那个使用量，token使用量的时候，也讲了有些很有意思的点。比如说大家角色扮演很多，用deep seek来去玩角色扮演确实是挺有意思的一个方向。还有什么没有了？所以从地位上来说，这部讲的是所谓的独立大模型公司，然后mini MAX讲的全球的第十，然后从产品逻辑来说，质朴的讲的本地化部署，虽然下降了，但是其实比例还挺高的。

然后mini max讲的是AI原生的这个产品这方面的东西。好，我看55了差不多了，我看有啥问题，没有更大的问题。更大的故事得是啥了？下一步证明得是生产力故事，当然要替人讲故事。开放是一个故事，开放是很重要的一个故事。

然后mini MAX因为质朴，其实出去接受采访的很少。严俊杰前段时间接受老罗的采访，之前也接受过很多人采访，然后他也说了一些，最近我觉得如果论故事来说的话，还得看老美。而老美在讲什么故事呢？明年的故事，这个我今天没讲，但是我觉得可以提一嘴讲这个故事。

持续学习就是continue learning，持续学习啥意思呢？就是我们是不是可以让模型以一个他其实这个概念是比较泛的。我们可以理解成是说让模型让A正在运行的过程中，在或者在模型在推理过的持续推理过程中，持续去优化或修改自己的权重，让它变得越来越好，吧？等于是模型本身的迭代。然后另外一个可能是不是我们就有一个agent，这个agent能持续学习，继续学习。然后在模型训练部分也有这种所谓的在线学习这些方面的说法。

我觉得我不知道这个darell讲的是哪一个，但是我觉得他是可能是一个泛化的一个事情。因为什么呢？他还提到说我们明年可能会碰到什么，碰到一个可以帮我们去是优化训练模型的模型，就是让模型来训练模型这意思。所以我觉得如果从这个角度来说的话，明年的一个大主题就是我们是不是可以迎来AI researcher的到来。

对，AI researcher的到来，商汤大模型怎么样？一般，没见过他在房里出现那个日日新是吧？上他的那个日日新。对，就是这帮模型的名字真的是对日日新的。Sense nova对，一般没有出现过在大的榜，但是结合上他自己的这个业务来说，还是有有一些落地的。

持续学习是不是需要更多算力？当然对这个是一个挺重要的点，就是我们肯定要预期明年。所以这为什么最开始给大家看那个run time 2025的一个点，就是我们的基建还会有巨大量的需求。无论是预训练还是后训练，还是持续的学习，这个领域都需要巨大量的算力。所以我觉得算力是不会缺的。

所以对应到什么呢？对于美国来说，就是它的基建其实反而还有机会，对吧？建电厂、故电工、培训电工，其实都是机会。然后这个对于中国来说，我觉得电可能不是那么大的问题，毕竟咱们有国家电网这么巨兽在这儿。

那下一步其实就是可能我们的继续讲好我们的这个算力或者这个资本利用效率的这这个故事，有一个故事就是mini max讲的故事，就是他用了open l1%的资源，趁出来的模型其实跟open l不相上下，这样一个故事。我们就还说那个故事，他讲的是什么呢？我们的资本利用效率足够高，事实上也是，对吧？就是我们国内的公司确实都没有open a有钱OK，实在砸钱砸的太厉害了。从DPC开始，大家就开始质疑它的资本利用效率。我觉得明年肯定会继续去继续讲这个故事。然后结合刚才我说的硬件加速模型算法的这个综合趋势，我觉得至少这个肯定是中国的独特趋势。

而对于美国的这个模型产模型的叙事来说，一个是持续学习，二我觉得我纯属个人观点，要讲AF for science这个故事了，要讲AF3X股市。因为老美其实很关键的一点，它的优势在哪？其实基础研究确实很牛逼，他基础研究一直还是全球独领风骚的那我怎么能把A这个成本继续发挥的更长，垄断住我的最原始的最原创科研的发源地。

我觉得这个AI for science确实是，而且最近几个招聘，从这个OPI招的几个人也能看出来，open l的这个AF for science这个方向持续在招很牛的人。你看找到这哥们怎么念我不知道。这哥们儿然后还有别的，其实都在招这个AF for science的人，然后专门做这个大模型，做数学，做科学发现这个方向。

我觉得这也对，就跟上节课给大家讲的美军或者美国的民用军工。那我必须要弯道超车，怎么办呢？咋弯呢？我制造业短期内赶不上去，我甚至稀土都赶不上去怎么办？那我就要讲autonomous，要讲自主主要讲叫什么来着，反正就是自汤是这个概念。就是我的武器都不是人控制的了，我是魔武器之间可以协同完成任务的这种玩意儿你说你怕不怕？对，所以就是我觉得这个是老美一定要抓住的，抓住的点就是一科研，二我在最新的模型的研发上面有大突破的方式。所以就是说人训练已经这么快了，AI去直接起飞，就是要这个效果，实际帧的有没有起飞不那么重要。但是他要讲这个故事，我觉得这是最关键点。

然后我记得奥特曼之前也讲了，他预期是27年还是八年会有所谓的AI research cher。但是我觉得可能明年美国这些大模型厂商就不得不讲这个事儿了，但是我觉得可能还是有一个挺大的一个对于他们来说。战略中间架就是我们看RAA上御三家的模型，又几乎垄断了前面的这个太行了，就是它全是御三家的模型，所以御三家google open靠都是他们参加。所以但凡他把分儿追上来一点，这个故事就还好讲一点，或者说这个空间就大一点。对，所以他最怕的就是啥？就是咱这些开源模型咋咋咋的给他追到三四名、二三名，然后时不时的怼了个什么第三名、第二名，然后虽然被盖下去，但是他就没有空，或者说没有那么大的什么战略上的资源去做下一代的飞跃。我就纯我个人观点差不多这些。

好，今天差不多就歇十点了，然后非常感谢大家，还有还还有这么多同学还在线，非常感谢。我不知道这个可能确实没有讲尽性两家公司，但是我已经尽量。对，能讲的讲了。因为这个确实在不让讲，完全不让啥都不让发生。所以大家也体谅一下。然后有些能耗的就一些这个具体使用上，刚才有同学说skills什么的。

对，从上节课就想抽时间去去讲CC，所以肯定要抽时间去大家讲的，所以大家放心。Skills，然后call code。然后最近call code出了一个chrome的功能，贼牛，就是之前大家想象到的那个code怎么用chrome这件事儿基本上已经是一个一键完成的事儿了。Code然后杠杠chrome，就这么命令就搞定了。所以这个而且用的是你

原生的浏览器，就根本不是什么。再来一个新的迪拜大的浏览器，特别方便。所以大家可以，如果没有不出意外，我们就下次讲呗，我们下次讲好。

你的配置啥？我这台机器真的配置不行。我这台机器是为了轻便，一个M4的32G的一个机器，就是很轻，这是一个map air很轻。所以大家如果我的唇我个人的配置是这样的，我不喜欢整天拿着电脑走来走去的，所以公司一台电脑，家里一台电脑。然后如果我出去见客户的话，我会拿这台笔记本，因为它足够轻，所以我是这么配置的，所以我出去这个一定得够轻。所以我之前用macbook pro，但是后来我就改了，改成出门用的。这个就是用一个很很轻的一个版本。

然后电脑家里的电脑跟公司电脑都是一个mac mini的，mac mini一个max 66，都是那个大方盒子。所以这个屏幕都是用自己的带鱼屏，所以这个也推荐大家，我觉得挺好的。因为这个mac上带鱼屏是一个非常爽的体验，比windows好多了。对，在制服上赚点钱，祝福你。

对，希望大家都赚到钱。好，没有别的什么，祝大家圣诞快乐。是圣诞吧？对，圣诞快乐，元旦快乐，我们下节课再见，拜拜。