

Hello，大家晚上好，这个又加了这个，然后今儿这次会来，咱们等等他。我们先看看今天还会讲上次说的 mud agent 这部分的文章，然后会有一些我们直接看看到底一个多维整体到底怎么开发这些东西。所以这张今天的后面的部分会有一些代码，但是大家不用担心这个看不懂。因为python代码其实很大的一个优势是啥呢？就是谁都看得懂，就是跟说人话似的，所以大家不用担心这个代码看不懂这样的一些问题，所以这后面会有这部分。好，然后还是之前的意思，就是大家如果有什么问题或者有什么想聊的，你可以随时发到这个讨论区里，然后就聊又来了。Hello.

好久有一种好久不见的感觉。

然后刚刚说反正这次还是讲八的，但是上次讲的比较前面讲的比较多。所以后面的这部分其实没怎么开始讲。然后今天后面会有一些关于多阵容体的这样的一些方面的内容，然后可能会有点代码。所以刚才说了，大家不要担心这个看不懂，这个代码都会，尤其是现在的python代码都很很容易懂的。这个你就把它当人话去看就行了。

好，那我们开始聊吧。第一个我觉得这篇文章挺不错，这是OKI官方发的一篇文章，就是讲的什么呢？讲大家到底在怎么用这个ChatGPT，该怎么用chat BT，这是官方的一篇配版。看看啥时候发的，好像就是这一两周，15号，这周对发的。就是关于大家怎么在用chat BT这样的一个分析。前面我觉得这个文这个内容还挺长的。

这个剧场我就直接把推特上那几条给大家看一看，我觉得这个还是有点用。一个是整个的使用量真的是在猛增，整个的chat BT的一他们现在都开始用WAU了，就是周火周活数周活数是多少呢？Chat VT, 我看看这个。接近800个million，也就是8亿8亿的周火，那也就是基本上10分之1的地球人都在每周都在用ChatGPT，对吧？挺可怕的一个数。

其实我觉得中国是一个非常合理的一个统计。

你说放在中国，我觉得中国。

是特别好的一个。

对对对，因为越南对于这个AI工具就很奇怪。对，什么东西要一个月用一次，每天可能确实有点疲乏。对，但确实我之前很少看到按周活这么来去评估的应用，可能还是移动互联网那个时代留下来的一些问题，这个量真的还挺大的，八个亿全球。然后大概会发了多少条消息呢？就看这个，所以说消息就是大家chat PT里面聊一句话，基本上在亮了。那样。看他总结的里面是。

也没写这个是有。

对，找不到。那算了下下一个。然后整个的使用上来说，就是整个在使用的过程中，到底大家用chat PT来干嘛？其实这个也在变化，有一张图，有一张表格就是大家是用chat BT来去做工作上的活，还是非工作上的活呢？

从24年到25年这样一个六月份，两个同样的六月份来对比，发现到25年的时候，非工作类的这个消息猛增，基本上占了73%的内容全都是非工作类的。然后去年基本上还挺均衡的，50%，今年有大量的非工作类内容。那我猜可能结合前面这个使用用户的量用户量周火那个那个图表来说，我觉得其实就是大量的非就是非目的是

为了工作的这波人加入了这个chat BT，然后拿他来去做了很多的对吧？就非工作内容。你看这是24年的june，这是25年的june。那这个用户量就WU已经增长了三倍了，那这三倍里面肯定有大量的的是非这种一定要是工作效率类的这样的一些用户。所以我觉得他的整个现在。

非工作里面主要是干啥？

前面有一些有有这个表，待会就直接那我们直接看这个表，就到底什么是工作类，什么是不工作类、非工作类。他就把使用场景分了很多种类别，大类分了这么几类，几类。一个什么mod media，就多媒体的什么关于生成这个图片什么这些都算多媒体类的。

然后第二个就是practical这个guide guidance，就是实际的操作类的这样的一些指导，这占2% 28，3%分之一挺大的。里面有啥呢？比如说教我做什么东西，或者教我一些知识，然后how to怎么干什么事儿，这些是大量的，基本上这俩加起来20%左右了，健康的一些东西其实就是实际操作类。

然后第三个就是搜索信息，还占的挺多的，200分之21点，这个基本上特定信息18%基本上很多用。比如我用district有时候查，因为它速度快，所以就直接用它来查一下。具体的这个我明知道肯定是一个确切值，这种东西确实也是大部分搜索信息就是干这个事儿。

然后最后就是写作，写小说，翻译个人写作通沟通什么这些占了百也是差不多3分之1，就是这部分。但是我觉得挺惊讶的是它有一个类型叫self impression，expression就是自我表达。比如说这个闲聊，跟人聊天，或者是表达一些关系，或者陪伴，这些东西都应该都算在这个relations and什么personal reflection的这个部分，或者叫greeting。对，这挺有效。打招呼 and 去chat就是那种聊两句的那种东西占了2.0%，就是有有2%的人就跟chat BT就去去打招呼就完了。所以我觉得这个要不就是刷的，要不就怎么着。

我有个问题，那个7.5% technical help为什么不算worker？

他这块没有定义work，我记得它其实这是一个它的类型，对吧？你看用电脑的编程的只占4.2%对吧？你想想这个cloud基本上应该是3分之1强，甚至快2分之1了都是用来编程的了。所以现在GPT用chat BT真的是来干活的真的挺少，就是比起cloud来说，所以这个也是为什么这周我觉得他发了GPT5的那个codex我觉得特别值得关注的一个原因就是他也关注到自己的明显有一大部分的使用场景是没有满足的，就是专业的coding。这波人那直接补短板呗，因为其他的部分其实大家都默认都会用chat VT，那现在其实就是主攻cloud阵地呗，所以这样的一个场景，然后它里面有一些使用的，叫什么专业方向，什么跟电脑相关的，这个0.5几，什么engineer，这差不多。然后这个就没啥了，没啥意思。

我觉得这个挺比较有意思。你看这个男性跟女性的使用的量几乎持平，而且现在女性开始反超男性的使用量，而且这个趋势发展的非常快。你看就从二三年1月份开始，还这个玩意儿还是一个男性俱乐部的产品。然后到25年的七月，就是两年之后，基本上就变成了一个女性其实用的更多的这样的一个地方。所以我觉得这个挺有意思，就是说明这个结合咱们前几周说的那个国际劳工组织的那个报告，对吧？就是这个AI职业暴露的这个东西也可以看出，其实女性也在快速的使用起来AI的这类的工具。

然后这个share是人数还是用量？

比例，我不知道我我的。

意思是他那个是人数的比例还是那个用量。

应该是message OK，就是usage。对对，所以这就是chat BT我觉得这个跟想象中的差不太多，只是我觉得陪伴这个事儿怎么这么少。对，就是relation这部分怎么这么少。联想起来像这个character AI这样的一些专门做陪伴类的工具，这个用量非常大了。所以感觉确实是大家如果比如说出海想创业的话，就从这张图里找，对吧？这个找信息，那就是perplexity。然后tutoring或者teaching，就专门做一个学习类的一个东西呗，然后这个个人写作也有这个个人写作有一个产品，我不知道大家有没有听说过，叫速度right。

我觉得这个挺有意思，这个是一个专门用来写剧本的工具，然后你可以直接登上去，基本上默认的给你的那个token够写一些了。就是直接你可以去描述，你想写个什么剧本，然后他就会帮你补全很多东西。然后甚至还有很多字段是等于是让你预设一些，比如说世界观背景这样的一些东西，让你整个的因为写小说那肯定是一个特别长上下文的一个事儿。有些你不想让他随着这个内容变化，比如说这些世界观这些东西，那你就可以都写的那个部分，这什么东西被吃的荣耀，这应该是单。对，你可以看里面它就会有教你怎么写这个小说，以及你想的一些东西全都档次在这儿。就是你所有想的东西，然后风格、style，这些东西都可以选角色对吧？

你在这个小说里有哪几个角色，然后世界构建outline都可以写在这儿。然后基于这些东西你可以写上面这个小说。然后这个小说它也可以大量的帮你去做这个rewrite，做直接帮你写，做改写或者做这个脑报，什么都OK。我觉得这个挺有意思，而且据说是这个叫什么好莱坞那边的很多编剧都在用这个东西，当然最早他们开始罢工也是因为这种AI的蟹编剧的工具，说是抢了他们的工作，现在他们也不罢工了，对吧？反正这个就是这速度right挺好玩的一个东西。所以这就是刚才说的这个大家去如果想创业的话，那就找呗，找里面使用量大的这个框然后去做。所以我这么看起来，你看搜索还是一个非常明确的大机会，而且是空间足够大，5分之1的机会。好，然后这个图就没啥意思了，就不说了。

第二个，大家不知道前天前两天有没有看这个平头哥的这个就是央视的采访平头哥的李强去调研的时候，有一张图是这样的，就是国产卡跟NV的这个卡的参数对比。那基本上平头哥，大家知道平头哥是谁的？然后后面有华为的升腾910B和这个必认这样的一个104P的这样几个对比。

那平头哥你看这个显存的容量96G，挺好的。这块正好说一嘴，之前不是给大家说过那个AIAMD max的那个机器吗？不知道还记不记得？没展示过吗？我忘了，大家还记不记得我给大家看过这个AMD的电脑，就这个。国内其实有好多公司在做这事。

从京东大家搜一下AMDAMD max那台电脑，就可以搜到大量的这样的一个东西，然后都是跑它。你看这个对比就很明显，它有它其实有128G的共享显存，就是GPU跟RAM共享的那部分。然后其中有96G可以用来跑模型，跑AI模型，那个32G就用来跑系统用的，所以它其实可以跑非常大的模型。

然后这个机器到了，我给大家看一下能不能，我看能不能连上去。开着呢开着就这台机器，它内置了这么个东西。谁知道怎么把这个搜狗输入法这破广告关上，真的我都醉了。它内置了这么一个叫nova studio的一个应用，这是它官方做的这么一个东西，就是这台电脑出厂就配了个东西，大家看看这都啥呢？它叫玲珑星河。

最底下的这个叫什么星河AI启动器，这就是它的说白了就是这网页整页是叫local house 5050这种端口说白了就是做了一个内部的在本地的一个web server，然后让你能够很方便的进到不同的应用。然后这个启动器，就是用来启动这个东西的，其他所有东西都是啥？你看看这个，这是一个外部UI，然后你可以直接跟他说，写篇小说吧。看大家可以看这个速度，这个速度还挺快的，基本上每秒有个感觉，几十小几十万投肯。

多大参数的？

这个是30B33 30Q4是吧？对，是的。然后可以在这儿选模型，他给你做了一个挺好的一个模型推管理的这么一个平台，你可以选不同的模型是吧？

GLMLGLM的air，然后GPT那个OSS120B也能跑。因为它是一个做了个，对，看你看60G，所以说明做了一个int 4，估计是做了int 4，然后你就可以启动它，你可以把这个停掉，然后把一个把它骑起来就OK了。然后现在像千万三的235B你其实就看这个一个88G的显存的一个模型是可以跑起来的，那这已经挺难的了。你想这个50905090多大3 32吗？还是24G其实也都很小对吧？你看5070，你看32G这样的一个东西。所以你要跑一个80B的模型还是挺难的，但是这个AMD这玩意儿就可以。谁有回声？有回声吗？

是我吗？我听着小声。

那OK的对，大家听到有回声你可以说，然后你看这上面其实能跑不少大一点size的模型。你看这个最大的其实就是这个828GB的这个模型，其他的对，再其次也有60G。对，所以而这台机器多少钱呢？这台机器。

13000。

对，然后你要在京东去搜这个AMDNDAl max。然后你看还有更便宜的，这个13000都不到的。怎么这么便宜这个问题。对，一万说白就是你想如果现在我想跑一个80B的模型，然后花多少钱呢？我要传统意义上我们买4090，买5090，那可是一张卡就对吧？15000了。

现在AMD这个东西能推理速度还可以，然后可以直接跑。然后这波厂商都在拼啥呢？就拼这东西，就是你看我这儿跑了个YUI，然后这是个康复UI config UI杂志，就是生图的那个玩意儿。直接你可以在本地去跑工作流，然后就可以去生成图片，对吧？像这种直接让它生成一个图，然后本地就抽卡呗，也很快。然后还有啥？对你像这个AIPPT，他还弄了一个本地版的AIPPT言行，对吧？

这个也好用吗？

没没没咋用它，我这还是用java的。对我看看。

那生成一个今天这个multi agent的主题的那个。

多多智能体技术概览。你让他看吧，让他搞。然后还有一个deep research，这应该是哪一个来着？哪个项目我都忘了。对他其实就连了D连的模型，然后接一个搜索，然后就可以直接在本地里面去做这个deep research了。

比如说我前两天知道的一个叫什么东方通财务造假。你可以就可以让他去自己去搜，然后自己去分析。然后这个除了搜索，肯定要连公网，但是模型是用本地的，所以挺有意思的这个东西还有个搜索引擎，然后还有cos还有reck floor，其实都可以在本地跑。说白了他干了个啥，就是拿大量的开源项目给你兑了一个应用面板。

你可以直接在这里面去做很多的，用你本地的这个机器的模型，是不是出来了，用你本地这个机器的模型来去跑一些AI的应用这样的话，我觉得其实很好的一点就是我们有很多企业所谓的担心，或者想想去私有化的时

候，那动辄就几百万一台机器，那这玩意儿一万多对吧？你你你一个人配一台其实都够。所以我觉得这挺有意思。

就是AMD的这一波带来这个机会，就是我们用跑模型的这个成本，就是个人跑模型的这个成本真的是下降的非常快。所以这个对大家如果想想去用的话，也可以说一下。大家如果想去试试这个什么应用，然后上面其实跑各种模型都OK，跑各种开源项目都OK。

我回过头来国产卡跟N卡，所以它里面其实没有对比这个AMD，我觉得值得去对比。就是平头哥，平头哥的这个显存能到96G那也挺不错的。这个当然成本肯定它价格肯定高。然后这个显存类型它用的是HBM22E，然后这个H20是HBM3，基本上现在国内好像还没有，应该是只有长兴。长兴好像说要在后年，应该是要造出这个HBM3。它差别肯定就是这个显存的读取速度什么这些东西了，应该是HBM3会在会比2E还高一倍左右的带宽。

那么这个为啥有意义呢？就是显存的这个存储速度到底重不重要呢？其实挺重要的。因为据说deep seek也在优化的时候发现好像卡钳带宽其实都已经不是瓶颈了。反而是这个显存读取速度，就是DDR这个读取速度成为了一些瓶颈。当然这就取决于你到底想怎么优化你的训练和推理这部分的流程。

然后卡钳带宽你看700，如果是700的话，那真的是跟NV的这一套东西有一拼了。那比起华为，比起别人的都高了不少。功耗400，刚才那个AMD那台机器的功耗好像我记得好像才一两百，真的还挺低的对，所以这个瓶颈点其实真的不一定。

大家去看这个卷什么就是纯卷这个卡件带宽卡这个卷算力这些东西。这个瓶颈点其实在这几个地儿都可能会有，就是包括你单卡的显存，包括单卡DDR然后卡片带宽，这些其实都是瓶颈点之一。所以我觉得这哥们评价的还挺挺那啥的，就没提算力。看来好像是在说除了芯片本身，其他周边都ready了，那周边就包括了像显存的卡机带宽，这些switch这样一些东西。

我插一句，像AMB的话，它用什么拍套餐什么之类会有障碍吗？

对他有一套东西叫什么东西来，就是AMD的那个哭的叫叫这个rock m这个东西。所以其实由于他的生态的推广也不太好，或者说挺慢的，所以他对这个像VRM什么的其实支持都没有那么好。就是没有很新，是没有狠心，所以你还是能用拍to watch，你还是能用TensorFlow。

然后因为这些它底层其实都已经就这个AMD，它这个rock m会去做适配，会去做底层兼容这些事儿。所以你上层该该该对于开发者来说差别不大。就是对于中间层的这些人的这个会比较痛苦。就是中间的这个就类似传统的酷大这个部分的sack来说。

对，差不多这些。所以大家想想啥就插一嘴，中美不是要见面吗？这个老大们要见面吗？据说中国这边其实连就是一嘴都没有提要谈这个所谓科技管制或者芯片算力管制的这方面的话题，好像一嘴都没说。所以我觉得可能是真的是快到一转折点了。当然现在做大模型训练，这些厂商肯定是苦苦哈哈在做什么升腾的这些东西适配，然后成功率肯定会低很多。比酷大来说，但是我觉得这个从整个的硬指标上来说，有点快到转折点那个意思了。

对，好，然后这个就是这几个东西。好，那我们看看模型有啥。我觉得今天这有篇文章，这两天有篇文章很好。这篇文章大open I又是OKI写的，是五号的时候，这个9月5号这篇文章就是为什么大模型会产生幻觉，而且是open I写的。所以其实相对来说，大家可以先比较相信它的这个结论的准确性。

这个我们看看，就是他说的幻觉其实就是你比如说你问他个这个，比如说你问他冯小平啥时候生的，或者说这个什么昌浩，昌浩是是是个是个哪儿的人，他家庭住址是哪儿？如果模型能准确回答到，那大概率是什么呢？是因为这个数据在互联网上有很多，而且有比较多的数量，而不是就一个地儿。那幻觉是啥呢？就是如果互联网上没有这一个数据，就没有串号，是住哪一行都没有。但是你问他他依然给你回答一个什么什么一个具体的地址，看起来像模像样，一个地址正好就是幻觉。

那这个到底是什么原因造成的呢？大家有各种的说法，包括什么？这玩意儿就是个概率模型。所以必然会有所谓的概率的答错的问题。这个东西其实不是一个对于我们现在已经认为这个推理能力，什么各种能力这么强的这样一个模型的一个简单的解释，有点太过于简单。所以他的结论是这样的，对他说是这样的事儿，他第一方面的原因是什么？他只指我们现在对于模型训练的评估标准，评估标准有问题，啥意思呢？

就这句话就是想想如果有一个多选题，然后你不知道选择答案的时候，你随便猜，随便写，比如选C选D。但是如果你留空和你选错了，其实你的得分是一样的。那这事儿合理吗？如果对于一个考生来说，那可能还行，对吧？反正学校就是你反正答错了，跟你都不选都是一个意思，你都你不会。但是我们想想，如果对于幻觉这个问题来说，我们肯定是不希望他产生幻觉的那如果不希望他产生幻觉的时候，他说我不知道或者不答和他瞎打是不是这个就应该有不同的对待。肯定我们希望他，如果他真不知道，他就说不知道就完了别瞎打。

所以这直指一点，就是我们现在的各种的奔驰。大家还记不记得有一期我们讲奔驰mark那一节课的时候，给大家看了一大堆奔驰2。这一大堆奔驰二醛是啥呢？都是QA就是问答。我们都希望的是，我有一个问题了以后，模型甭管怎么着都给我打个结果。这个结果看跟我的正确答案相不相似，如果相似我就给他分儿，如果不相似我就不给他分儿。但是这个其实就带来他如果他他他与其啥都不搭，还不如给瞎造一个，那还有可能有点机会。

所以这个就是他第一点就是他只指说我们现在所有的这种奔驰很大的一个问题，就是我们不会给瞎答的大模型的答案，大模型瞎打的答案打负分对吧？我们肯定不希望他瞎打，所以我们应该给他打负分。在如果他瞎打的话，那如果他说不知道好，那我们可以给他个零分，那零分也比负分好，对吧？答对了给他正分，然后你不答得零分，然后答错了或者不是答错了就是瞎答，能给他个负分。所以这是一个一个点，就是他认为现在bencher很大的问题就是我我我太多下达了。然后另一个这是一个问题，然后另一个是什么呢？就是有一类的这个叫single ten的这种东西。三个好，我们应该在论文里。

等会看一会，真头疼。对。另外一类就是这个东西，就是如果我们的数据里面只有有一类的数据，就是它只有一个例子。比如说这个五十七的训练数据里，只有一行写着昌昊住在北京市哪这么一个数据。好，那这种情况下就很容易产生幻觉，只有一个证据，你但凡有多个证据，两个以上，这个幻觉的率就会低很多。所以他就说好。

如果说有一类的数据，比如说你问有多少人的家庭住址在哪儿？这个事情这个数据有20%的数据是single就单立的，就只出现过一次的。又比如说20%，那你问用问这个大模型说某某某住在这儿这件事情的问题的时候，他产生幻觉的概率就会在差不多是这个以上，对不对？百分大于20%这样一个概率。所以这就是代表说我们的数据也需要去改进，我们的评估方法也应该去改进。那这种情况下我们就才有可能去实现说我们怎么去提高我们的这个啊所谓的降低我们的这个幻觉率。他也基本上就是这两个主要观点，就是幻觉其实是主要是由刚才说的这两个问题产生的。

好，那他结论是啥呢？第一个就是说不可能有百分之百不会产生幻觉的模型，这个是直接上来就说了，所以大家就放弃说哪个模型或者什么时候我们能够有一个绝对不会幻觉的东西。这个是不可避免的，这个hello station is inevitable，是不可避免的。因为在大模型里的不确定性是这个是是对，就是他说这个是不可避

免的。但是其实是如果你在数据在整个训练，在这个bencher在在评估的时候，做非常细的调试的话，maybe也可能有一些可以避免的机会。然后那另外一个就是说是不是要智力更强才可能可以避免幻觉呢？那看刚才那个结论肯定不是，对吧？

然后第四就是幻觉是现代大语言模型中的一个神秘故障。但是他发现好像像刚才说的，就是我们鼓励他瞎答，或者鼓励他不留白。这件事情有可能是我们了解幻觉产生的一个机理之一，然后要衡量幻觉，我们需要一个好的幻觉评估。不一定我们benchmark其实更重要。对，就是我们做出一个好的benchmark比这个就做一个很好的专门针对幻觉的评估，其实可能更重要。我们如果做出的benchmark都是奖励你不要瞎答的那甚至我们可能都不需要一个非常专业的幻觉评估，所以大概就是这样一篇文章。

所以这个是大家带来什么呢？就是之前给大家讲过说可解释性那张对吧？就是像SR pic说那个大模型是怎么工作的。然后我们现在也逐渐的看到了大模型是怎么产生幻觉的，或者说产生幻觉的背后的一些原因。所以感觉我们其实可以逐渐的看到了一个，就是对大模型更越来越深度理解的这样一个可能性。

然后这块简就简单说一嘴，这个nature大家知道吧？这个nature的自然杂志，然后他的最新一期的封面文章就是deep thick，我觉得这个非常的牛。这篇文章其实是通过评审以后，关于r one的那篇文章的一个一个说明，就是R一的那篇文章的一个说明，就是一个大模型要激发他的推理能力，其实可能不需要去那么多人工的标注，甚至不需要人工标注就可以去做最小的人工输入，就可以激活或者是增强模型本身的推理能力。通过啥呢？就通过强化学习来去做这件事情。

所以这篇文章为什么现在才登？是因为他通过了大量的同行评议，叫peer review。所以他专门写篇文章说，为什么要把你的大模型拿过来通过同行评议，这个事儿是对AI模型有帮助的，他就反正吐槽了一通各家闭源模型公开内容太少，然后猛夸了一通deep stick，说干得好。所以我觉得一方面也是应对说整个现在大家投稿在这种期刊里的这个内容越来越迟，然后也越来越不愿意。因为大家看到所有的文章，基本都先从刚才给大家看了一下r cave什么这样的一些地方去去发表。像这个就直接动r cap上，就没有什么去，当然该投还是得投，但是直接都发到了cup，然后大家就觉得OK了，这个我觉得是个nature觉得对吧他他的地位不保，所以大家知道这个阿卡还是nature其实没有啥地位不保的这个担心。我觉得但是他其实就吐槽一下，大家都不在，不不不follow这个peer review了，然后或者开始瞎说。

好，然后这个GPT5发了个新的模型，发发了个新的专门用来coding的模型，叫GPT5 code dex。然后codex这个名是不是有点眼熟？大家打开这个GPT的时候，就能看到这个东西在这儿，在这上面有一个codex玩意，这是个啥呢？点开你就可以看到这个东西，就这么就是你想够你想你想code点啥，然后直接describe一个任务。这块是指的是你某一个github的一个代码库，然后你就可以说了，当然它现在也支持巷扣扣扣的什么可以跑到你命令行，跑到你ID里。

我当时我就跑了一个什么例子呢？就这个东西我直接让他帮我做一个。比如说我想做一个会议会议这个会议录音的这么一个后台处理平台。前端有各种硬件，对吧？然后录音，然后把这个数据实时的或者一次性的传给后端。后端拿到音频以后，转成文字，或者如果有视频的话，我提取出关键帧，然后设计一个后台的服务，对前端提供API，然后来做一个前端的页面来测试OK就这么一段话，基本上大家可以理解成是我的一个点子的一个最简化的语言描述。

你会发现他就开始干活了。开始自己写在这个架构的规划，然后这个端口设计，然后前端页面的设计。因为我这个时候选的是所谓的聊，所以他就给我写了这样一个架构设计。我就开始说，好，那继续做技术选型呗。然后咋他给我选了几个技术选型，不同的地方应该用什么技术站OKOK，然后就开始说了，那开始干活呗，然后他就开始写代码了，写了大概几个4555556个代码。但是大部分其实都是非常少，它实际的业务代码非常少。就这俩，一个网页，一个后端的这个GS，其他都是些包，然后大概花多长时间呢？



花了两分钟，我就开始说那运行测试呗，然后他就会真的去写一个测试脚本。然后你可以在这看到，他直接在这跑了测试脚本，并且把它跑起来了，真的运行在300 3000端口OK然后告诉你是这七个文件跑起来一个项目，那最后就没啥，最后就说那根据这个代码写个架构文档保存下来。他的钱保存下来了，然后还有最新版的，最新版。对，然后给我写了个文件来去保存整个项目的架构OK了整个全过程他完全没有跑在我自己的电脑，我的服务器上什么都没有。我只提供给他了我的那个就是我的代码库，我到底针对哪一个代码对吧？我这个任务到底是你应该把代码放在哪一个代码库里就OK了。所以如果你只让他设计，你就点这个ask。如果你觉得设计的差不多了，你直接让他code，他就开始干活了。

所以我觉得这个越来越好用，之前我也跑过这类用code dex跑过一些东西。我觉得尤其是55出来以后，整个代码的生成的速度又快了，然后又准确率什么的都高了不少。然后它整个codex提供所有的完整的运行时环境。所以你看我这个我就算拿一个手机，我其实都可以完成整个这套东西的实现，所以大家其实推荐，因为这个codex其实如果就算，像我这种盖板的ChatGPT，就20到1个月的其实也能用。

然后最后你那口袋不受到限制吗？

一共多少不让用。我之前跑的一个被卡住的，应该是一天一直在跑，然后跑了大概几个小时，他才会有那个token的限制。然后对，就是好像很少，或者说我这用的不够狠呗。你看他现在的的环境什么的，都还是他现在环境都直接归到这个就是归到rapper上，归到代码库，而不说什么你的这个你的那个什么多少机器，多少电脑，多少GPU什么这些东西上。所以现在越来越感觉啥呢？就是大家写代码这个东西？就是越来越离开发环境，真的越来越远。所以这个GBD5的code x，其实就是一个针对编程的一个专门优化的一个版本，它在什么上面呢？

SWE bench大家知道以前知道就是软件工程的这个bench，其实也是，基本大家看code agent一个标准评估方式，基本上差不多，没啥区别，跟以前的但是在一些任务，比如像代码重构的任务上，他能力增强了很多。所以说白了也就是在具体的一些脏活累活上，可能能力会强很多，但是标准的coding能力其实差别并不大。对，然后他底下就说了一大堆各种能力，所以这个大家真的可以看，如果即使不是，大家即使不是代码出身的，其实也可以开始尝试应用这些工具了。

好，然后下一个我觉得这模型挺牛逼的。这个就是还我我以前有没有讲过李飞飞的这个word laps这个世界实验室，他在很早应该是在什么时候，24年底的时候。对，当时他发了一个模型，叫做他的第一个世界模型，他发的第一个世界模型就这个东西，他现在是不是都打不开了？都打不开了行吧？

当时他其实就是啥呢？就是你给他一张图片，然后这张图片就可以生成一个可以在里面玩来玩去的这么一个11个1个一个世界，然后这个世界其实可以在一定范围内去移动的。不知道咋咋点不开了。

就在前天他发了第二版本，就是这个叫generating bigger and Better world。然后你看这个图，你看这个视频，其实就这样。对，看右边右上角，这是他的实际的这个空间。就是你原来它的第一版就是你你拿一张图它就生成一个空间，现在变成啥呢？它由于它的不同空间的一致性很强，所以它可以把不同空间拼起来，拼成一个大的空间。你可以在里面去走，来回在不同的空间内去穿梭转悠。然后整个这些空间都是靠几张图生成的空间，拼起来的效果非常不错。

对，所以他就做了这么一个，他发了这么一个新版本模型。然后新新版本模型有非常多的，他专门还做了一个网站叫什么大理石，这个world lab的展示，大家可以直接看到这个效果，我觉得这个挺挺对，又是挺震惊的一个新的版本。然后基本这些就是他的给你的一些样例。



如果你真的想上传，然后生成你要去发他的这个要申请的。比如说我们选个这个，选个我之前打开过的，快一点。然后你看的风格其实差别很大，这个可以是很写实的，也可以是很奇幻的这样的一些不同的东西。然后你打开了以后就是这样，它它是一个还在loading的过程中，这个东西就是一大堆叫什么高斯建设的这个数据原始数据的效果。而整个这个效果，其实就是在纯网页纯网页端在打开，他用的是这个CGS来去来去跑的。我看对cgs，这是推荐给大家一个插件，如果是技术同学的话，可以看这个叫这个插件。这个rap是什么？

Weaponized这样的一个东西，你打开以后，你就可以看到所有这个网页里面用到的技术站。比如说你看这东西，他他怎么能这么酷炫？怎么能走来走去还这个还挺漂亮的？你直接打开这个，你就可以看到它的GS库用的是cgs，如果你不熟的话，那你就转好，那我也会去用这个呗。所以这个是一个对可以看各种技术站，比如网站技术站的这么一个工差价。这网速太慢了，我们等不等，我们待会儿回来再看看吧。

对所以这个世界模型，其实我们看这个例子呗，就是这个世界模型现在已经可以做到，你给他就几张图，然后直接生成一个事件，然后通过几张图就可以在一个全更大的一个世界里去探索。然后不同的风格都行，看这种卡通形状的也可以玩，科幻风格的也可以玩，然后更大的场景就是刚才上面那张图。好，那这东西能干啥？这是问题。你想这东西看着是挺好玩的，但是有啥用呢？我就看到了这么一个这样几个例子。

比如这是一哥们儿用这个东西来去做这件事儿，他是干啥呢？他先去拍了张他的卧室的照片，living room的客厅的照片，然后用啥用这个这是他拍的那个照片。然后用GMI去重新生成了几个新的图，比如这个风格的都是基于它的原始图片生成出来的这样的一个客厅的这样一个图，对吧？你看其实风格很一致，不是那个那个布局很一致，就是风格不一样。然后他干了啥呢？

他用这些图片去world lab去生成了几个三维的话环境，三维的场，说白就是每一个图你扔给world lab，它都能生成几乎一致的一个空间，一个三维空间。你可以在里面玩走来走去的，然后他干了个啥呢？他用一个叫scan verse的玩意儿。这个scammers我不知道大家有没有玩3D扫描的，有有玩3D扫描的吗？对，然后如果玩的话就知道说sky verse其实就是一个应用。然后你可以直接扫，比如说扫这个石狮子扫几个角度，扫这个拱门扫几个角度，你就可以直接够3D建模出来这个东西和这个空间。

好，他干啥呢？他拿这个skin worse扫了一下自己这个客厅，然后把这个空间给准确的扫出来了。然后把前面的这几个拿word laps生成的这个空间点云，或者叫高斯建设这样的一些东西，给他所谓的对齐到这个空真实的空间物理大小空间里。好，那这时候你不就能得到一个真实空间的不同风格的一个三维空间的这个内容了。好，然后他就干嘛了，他就开始可以不断的切对。就是我虽然这边看的是这个，我不知道他这是拿什么什么去构建的，但是有点像什么大家看那个vision pro什么这样的东西。但是我猜他应该是我看看。

这个太有冲动感了。

对，就是你可以直接在你的现有的空间看看另一个风格。然后那你想这个是不是我可以说以后大家如果自己重新装修一下自己的这个屋子，你可以把你的图生成出来，用这个生成出来你想要的这个风格，然后做成world lab，然后就是用word LAB做成这个虚拟空间，然后再把它通过像vision pro什么的叠上去，你就可以直接在你的这个客厅里看到，对吧？你想要这个空间的未来效果。

就省去装修费用。

装修费用是最最不值得一提的是。这里面的对对，你就是可以想象有很多很新的这个场景这出来了，你看这个出来这俩就是一张图，你就可以直接生成这样一个空间，然后你前后左右走都OK。

这不是无限的空间吗？

它其实就一张图，它如果实现无线，你看你要走到外面，它的细节就变少了，非常多了，对吧？你越走到这儿几乎就没细节了，就变成一些虚幻的空间了。所以他其实还是要所谓的在信息论的约束下，就是我能看的东西，肯定我能拍下来的一些信息的东西，肯定是相对来说更精细的。

然后稍微远生成的角度讲，应该是往远了它一样，对吧？它就不断生成对。

但你那里边生成就没有任何信息依据了，那就是瞎编呗。然后这个是这个，然后你看这个大街挺不错的。你看它后面其实一片一看到后面它的细节就少很多。然后你看前面这个前面的部分细节还是挺挺充分的那我走到这儿看这啥玩意儿。

大家基于李飞飞的新的模型，大家可以想象非常多的玩法。好，然后界面三可能要来了，大家注意这个界面三可能又要来去搞掉GPT5的最牛逼的模型了。他在现在在LM rena，大家知道吧？LM rena上在测试，然后据说大家发现这个新的模型代码名叫ocean ref。Ocean ref这么一个模型，大家在这上面看就可以，没准用几次就能用到它，然后据说能力很强。

这提一嘴就是你怎么发现这个模型到底是啥呢？是谁做的呢？其实最直观的一个做法就这个你问你你问他是谁啊，然后他就说什么我是大模型，谁寸的。然后你可以问他说现在美国总统是谁啊？你看他说2025年，september，美国总统是特朗普。所以这个也是一个挺好的用来评估到底大模型的知识到了就是停留在哪儿，他训练知识到哪儿了这样的一个办法。

之前给大家讲那个GPT OSS的时候也讲过，怎么评判一个大模型的训练数据到底到哪儿了呢？他讲的一个更我觉得那个其实更准。就是你问他python现在最新的版本是多少？Python现在最新版本是啥？然后你在哪看呢？你就在这个python的官方这看，你看啥时候release，然后你就问他说现在最新版本是啥？基本上就能判断出他的训练数据到了什么时候，这样一个东西。所以这边三三大可以期待，可能下一步就快来了。

但是比较可惜的是deep seek这个R2一直没任何性，而且感觉这几周更没消息了，就是更没对什么东西了。好，然后语数发了个模型，语数语数这个机器人那家公司发了个模型叫什么unio LM，他也在这掺和所谓的大师，就世界模型，这个还记不得以前也给大家说机器人的时候，说过一种模型叫VLM对吧？VLM, VLM是个啥？大家还记不记得？就是vision language action模型，这个我找一个。

这个对，叫这个名字叫vision language action模型，啥意思呢？就是我的输入是啥？我的输入是vision，是视觉。你看是视觉机器人，肯定看到视觉好，它的输出是啥呢？输出不是字儿，不是那些话，不是什么小说，乱七八糟的，是action，是机器人的action。就是比如说某个舵机往往前几圈或者多少度，这些东西都叫action。所以这一类的模型是现在主流的。

大家说机器人这类东西，这类模型的这样一个统一的模型都叫vision language action模型。但是语速搞了一个新词儿叫也不知道是不是全新的词，叫世界模型action对吧？就是不用那个视觉语言模型了视觉模型了。对，视觉语言模型而用视觉模型加action，就是他说他输入的东西是一个世界知识，或者一个世界上的信息，然后他又干嘛呢？我们看看能不能，他有张图。

对，figure的那个是figure那个是标准的一个VOM，对吧？还记得那个figure的那个figure AI叫什么模型来着？我都忘了。Halo x对。

对，看这个。这个也是没啥东西，我这有一个有预测的，稍等我看哪个图呢？

那这个就拿这个。对，啥意思呢？右上角这个图代表的是它通过世界模型预测出来的未来的场景。你看就是他到了这儿，他先预测说我放进去以后的效果是啥，或者说他预测未来以后来去从而生成现在的行为action。你看他预测他一开这个钳子，他就这个东西就落到盒子里了这样一个事儿。

预测大家有没有觉得预测这个就很很耳熟。啥模型呢？还记得吗？上次说啥模型能预测v japan。还记得吗？大家有人还记得这个模型吗？今儿网咋这么差？V ja这个模型。还记得这个玩意儿meta的杨乐坤大神做的这个世界模型。他当时给大家看的这个图，其实就是所谓anticipate what next，就是给你看这张图。

好，这张图完了以后，他就开始预测说下一步可能会发生啥呢？然后比如说这咋不出来，这两天网太差了。对，反正就大概意思就是这个视频你播到了这儿，他就会预测你可能要打开冰箱。然后打开冰箱他就预测你可能拿出瓶子。拿出瓶子以后他就会预测你什么关掉冰箱什么这些东西。对，所以就是大家可以看到这个东西真的放到了这个机器人身上，那当然肯定放在我们的这个语速，现在是最相对来说最最比较综合的这么一个机器人。我们看到这个世界模型，可能他真的用世界模型，我没有详细看啊，因为它是一个开源的，我觉得肯定也是不会太瞎说。

你看它这个是一个世界模型来去驱动的这个机器人，去先预测我干了这事儿以后会发生啥再干。然后干完了以后再预测，说我如果这么干会发生啥，然后再干。对所以我觉得这个世界模型加机身智能加机器人，逐渐的开始说用到这个实际的场景中了，开始有用了。这种这个是语数的这个模型，我觉得这个挺有意思的。

然后安全方面有一个特别神奇的，在上节课给的，是上节课给大家讲那个前信道攻击，我不知道还有人记得吗？前线的工资也不知道大家有没记得。这次又有一个很类似的一个前倾倒攻击的一个做法，是啥？我这个是我第一次听说是这么一个东西，有一种攻击叫做roll hammer，肉就是列，行行，锤子，啥意思呢？简单的说就是看看能不能找到一个图。直接找一张图吧。就这张图挺好的。对，这是google的一篇文章里讲的。

你说hammer啥意思？就是我们的所有的存储设备里面，其实里面都是这样一个格每格存一个零，存一个一对吧？就是存一个01，基本上就是好像高电位代表一，低电位代表0。大概就看你怎么定义了这样一个东西。好，每格代表一个数据好。一般来说都是因为像ddr什么的，它都需要通过不断的刷，不断的去发一个脉冲，让这一行去重置，来去保证这一行的数据都能持续的保存住。然后过一段时间他可能就这个电量就丢失了，以后这数据就丢了，所以要不断的刷，那一次刷一行，一次刷一行。

但是有一种问题是，如果你刷这个东西刷的速度太高，然后离得近的两个电容其实是都靠电容来存的。这个零一离得近的两个电容就可能产生耦合。所谓的耦合就是我其实刷的是这个，但是他反应了，所以就代表是如果我刷的太快，可能会让我这一行旁边的那一行里的某个寄存器，会由于我这边的变动而改变那边的数据，比如从零变成了一，那这件事听起来好像是一个故障，对吧？

但是你要相信这些黑客们总是有办法特别精细的设计出来一些攻击方法，从而干嘛？从而找到一个很准确的一个一些位置，来去植入它。由于这些物产生的修改，来去实现它的一些攻击的目的。比如说获得一些管理员权限这样一些东西，所以这玩意儿就叫row hammer，就是行行行锤子这样一个东西。

好，那现在就到了这儿，为什么GPU？GPU也是存储的，GPU刚才说的96G的也有大量的存储的一个数据。那是不是理论上其实也可以实现这样的一个raw hammer。但是你说一个几十B的模型好，那我就算只改了其中的一个比特，那有多大变化呢？我觉得这还挺震惊，挺震惊的，就是模型权重中只如果只有一个位的翻转足以破坏准确性从多少？从80%降到0.1，就是巨脆弱。

所以这个当时我看了这也是挺震惊的。就是大家想想一个大模型，结果他改了一个位一位一个比特就能破坏把这个模型破坏到这个几乎没法用，所以大家可以说这个AI是多么的脆弱这条东西，这也就带来了另一个攻击方法，就是但凡？你如果能摸到这个机器，就是你知道哪个机器的GPU跑了这个大模型。然后你可以想办法去在这个机器所在的GPU上去让他更高频的去刷新某些行列，从而导致一些他不应该产生变化的这些数据被修改掉。从而破坏这个模型的运行效果，所以这样叫GPU hammer。

并且已经复现了在这个NV点的A6000上复现了这个东西，那怎么办呢？那无非就是用一些校准呗，就是我多弄几个位用来去检测所谓的ECC来去检测到底是不是被修改过这些东西，所以这个挺有意思。大家如果说对攻击感兴趣，你会发现啥呢？就是什么玩意儿都能攻击，什么东西都可以攻击。录音啥意思？录音没明白啥意思。好，然后这个是啊这个我们就不说，然后这个bench bar我觉得还是挺有参考意义的。这是一个字节跟几家学校，应该是一起哥伦比亚这个商学院一起做的一个这bench man你看叫fine financial search，这个camps就是金融数据的一些金融任务的这个bench far，他做哪些任务呢？

你看这个就几个比较经典的，我觉得这个账号可能会比较有感触，就是这三类时间敏感的数据获取，比如说IBM的最新的cos Price是多少，然后这个简单的一些历史数据的查询。比如说星巴克2020年什么什么9月27号的什么东西，总资产资产，然后这个比较复杂的历史的调查，对吧？也可以去查什么标五百，什么乱七八糟这些数据，就是通过要不要这两个最大差别就是要不要计算好。这些数据其实有些是实时性的，比如说IBM当前的这个B市价格是多少，这个你每次测试的时候肯定不会是一样的。所以他设计了一套测试方法来去看各家的怎么去动态的获取这个结果。然后从而来去验证各家模型到底这方面能不能够够能力。

然后他为了做这个题，做了非常多的所谓的quality control质量控制，我觉得从这里面也能看出来大模型厂商做奔驰这件事儿，他所要求的人的水平有多高。你看这好50个专家，这个硕士以上的专家，master以上的专家，然后20个专高级专家，就是从一些知名的机构来的，20个高级专家。那你就算这些人其实一天的成本就不低了。还做了很多别的，比如说交叉验证数据对吧？我不能只签一家的数据，然后做很多这种别的方面的优化，所以最后才做出这个奔驰，然后这个奔驰的结果是啥样呢？

就看这个前面，从global来说的话，第一是clock。而且grex比GPT5还真的还高好几分，所以rox这方面还挺牛的对，然后gm比这两家低这么多，几乎跟这个豆包一样了。当然在中国领域就是大中华区，其实豆包还是第一的。但是我不知道为什么brock 4在这儿，这个其实是难道高斯还在大中华区有服务吗？这个挺奇怪的。

Anyway, 反正就是如果纯从大家如果有人做金融领域的话，就是构建首先构建benchmark很重要，可以参考它的这个方式来去构建你自己的这个benchmark，然后才是什么选模型这些事儿，对，这个就是一个奔，然后底下我觉得几个有意思的应用。这个浑圆，但不知道在这个大有没有玩3D打印机的？咱群里37623打印机的吗？有吗？有，好像是玩了。对我玩。

然后浑元的这个3D模型真的是很不错，为啥呢？就是你去hiking face看他的model里面，看浑源。浑源，现在没了，我靠，这个之前是浑源说白了文生3D和图生3D这个模型排名都挺高的对吧？那那有吗？有同学玩3D吗？那三打印，那你如果想打个东西，你要不就是从什么maker lab什么这样的一些地方去make word，什么地方去大模型，那你肯定拍东西你也想去生成。所以这个浑元3D的这个说白了就是你可以说句话，生成一个什么拉布拉多，然后你也可以扔给他一张图，让他去先生成一个图片对应的3D模型。

其实这些很多都是拿图片生成的，他的官方他肯定找了一些生成比较好啊，我当时扔了一个啥呢？扔了一个当了一个小松鼠，我就随便找了一张图，这么一个松鼠，我直接跑出来，我看看我的资产，这玩意儿它叫资产。对，然后你可以看到它跑出来的效果，这还有点差的，你看这个尾巴变成了这个玩意儿。对，但人的那种的角色我觉得都还不错。比如这个是我在好像是陕西就是不是人动物症，就是这种比较大动物，这好像在陕西机场的时候做了一个东西，然后这个就是拍的那个多利羊，然后就一张照片，然后这样好像也还行。后来我拿它去打了一下还行。

这个原图是这个样子，原图是这个样子，然后直接生成这么东西，我记得好像还不光是这样一个，后来还拿那个叫什么板布的那个那个，我用的是拓竹那个打印机，然后去生成了一些补补全了一些腿什么的的东西，结果还真打的出来，而且还还能能用。所以这个浑元的这个3D模型还真的有点意思。然后下面点两看对对看两看几个设备，看几个硬件设备的这个东西。一个叫lukie I—这么一个东西，它是啥呢？它所谓的世界第一个AI生命记录设备就是life logging camera，可以全天候的拍照。这种东西啥意思呢？就是你你你你胸口带这么一个东西，或者是你放在哪儿都行。对，就这样就戴在胸前这么一个这么大的一个玩意儿，他就不断的拍照，不断的拍照，你可以拿到很多的图片，然后拿他拿AI给你分析说，帮我分析一下我今天一天怎么样，然后他就根据你的第一人称视角的所有的图来给你做分析。这玩意儿30克也不。

大还行为什么长成这样的还不对。

我觉得就是有点傻，它本来应该是一个存在感很低的玩意儿，你就记就好了，为什么一定要这么夸张的造型？就是没必要。他30克其实也没有很轻，跟一个眼镜差不多重这么个东西，然后还要搞的这个自己很操。

这他伸出那四个。

对，就很没必要。

数学的天线吗？还是什么？

不可能，为啥一定要搞这个天线？它这玩意儿也不小，你看放在这个胸口这很大的这个东西，所以这个我觉得就是为了造型，就为造型，但这事儿他号称第一个life logging的这camera这事儿我就觉得很过分了，为啥呢？在大概十年前，我当时买过这个设备叫narrative clip这么一个小东西，十年前就这么一个小东西，这个小东西其实比刚才那个小多了，而且非常的不起眼儿。你看就这么大，然后你就戴在胸口，就别在胸口就OK了。我看有没有图。对，就这种。对你就可以戴在这儿。他我我买的是黑色的，这样比较隐蔽。

他就会干嘛呢？他就会每30秒拍一张照片，你可以调15秒还是30秒，还是一分钟。你拍一张照片，然后你只要连上wifi，你就可以他就不断的把你的这个照片传到云端去，传到你的这个云服务上。

然后你就可以得到一个你全天候的，类似于长报。长叫什么来着？那个time clubs，那个叫叫叫不叫长报，叫什么东西来着？

延迟摄影对，延迟摄影的这样一个视频，然后你就可以直接在里面看我一天都干了啥，这么个东西。但是当时这个产品出来的时候，还没有这种现在这种多模态的模型这么好。所以他当时的这个想法非常好。

就是我录你一天的东西，然后给你找到你一天里面最精彩的片段，然后给你做成视频，然后你就花钱买我的服务，订阅服务呗。结果当时这个模型能力很差，所以这事儿就没做起来。但是当时你看，当时800万像素，然后wifi加蓝牙都支持，然后可以戴在胸口带一天这么一个设备非常做的非常好啊。这个硬件，你在联想刚才看这个look 1L1这破玩意儿，这啥玩意儿这东西，所以我觉得这个就还是得聪明人很多，一直都有更聪明的人在做这个事儿。

刚刚正好有同学说meta新一代眼镜，我们就直接看看新一代眼镜。Map up的新一代眼镜，它新一代眼镜出了好几款。然后我觉得其实值得关注的其实就是它的带显示这一款。就是所谓的inland s的这款就是有彩色头显彩色的这个光波导的这一款叫meta ribbon e display。

然后这款确实还挺有意思的，但是挺贵的。这个来看它其实是一个单方向的，它只有右边的屏这个镜片才能够显示，只有右边的镜片三线左边是没有的。所以说白了啥呢？就是他只在这边做了一个光机，只在一侧做了喇叭，然后能干嘛呢？我们就直接看看还带了这么多东西，这个手腕带这腕带有没有想到可能好几节课前，给大家说meta做了一个也是他的flair那个那个研究室，做了一个什么呢？就是我能通过手部的电流，肌肉电流来识别到你现在什么动作，甚至能干嘛呢？甚至你的手在这在桌面上自己在写字，假装写字，他也能识别出你写的是什么字这样一个东西。

好，他现在把它做成了产品，这个玩意儿这个腕带就是一个带所谓的这个东西，这个东西叫神经腕带。所谓的神经腕带其实就是EMG，EMG就是这个叫肌肉电流的这么一个技术。我能够你看它其实有就有些触点，这些触点就可以直接读你的当前的肌肉表面。当肌肉表面稍微动的时候，其实那个表面都有一些电流的变化。

那通过压MG就可以读读到这个电流变化，从而把它还原成你的手势。然后甚至说你手势对应到的这样一些文字的书写这些事儿，然后他把它包成了一个挺好看的一个东西，然后你就可以直接带着，然后就可以直接识别到你那些首饰。那些首饰还不少，我看他这个行为，而这个东西大概要多少钱呢？你直接看这个东西，EMG，我们要搜淘宝，这东西其实不便宜，确实不便宜。我去。

淘宝现在反反爬真的是疯了。我不登录，那那我看看京东有没有。这种东西其实挺如果没有量产的话，确实挺贵的。你像这款，我就是相对来说做的偏产品化比较好的。你看卖三千多这么个东西，当然国外其实很早就有这一类东西。你看那里面触点比较多，就是他那个那个贴你机那个表皮肤表面那个电流的那个叫什么金属片挺比较多。

如果就是你表面可不要，那就这个东西，就是一个也不便宜的，好几百，六七百这么个东西，然后点还很少，好像就几个点这样一所以EMG他能把它做到这样的一个产品的水平，我觉得确实做的挺不错的。然后它标配变色镜片，大家知道小米那个镜片还是你得花钱。你要想那个变色镜片还能更贵一点，能它能干啥呢？

其实就是这个里面的一些场景，就是你随时对方说的话的翻译字幕给你直接呈现出来，然后还能拍照，或者说直接说这个什么什么花来着这样一些东西。你看它直接刚才这个就是我直接在手在一个材料上去假装写字，然后他就能识别到，确实也不错。接AI肯定要接的，就接他meta的自家的AI什么识别。这番茄咋样？能不能吃？然后一步一步教你咋做这个意大利面，然后一些提醒、导航这些事儿。不过他这个手势的动作确实做的还挺不错的。你看这个这样的一些基本动作，但是问题是啥呢？

就是为什么卖他一定得做这东西呢？因为他他没有手表对吧？如果苹果搞这东西就非常正常，而且他现在苹果手表其实也都有一定的几个简单动作的识别了。所以这个苹果表如果搞下一代，我增加几个EMG的金属触点，就是传感器的触点，那直接就可以实现它的这样一个操作的识别的功能。

然后他你可以拿这个东西来去发消息，对吧？我所谓的静默回复，静默回复就是我不说话，然后我就在底下选一个，我想回哪个。这寂寞回复不就是apple watch的这个选到底想回哪一个，对吧？然后别的这个就是所谓的实时的字幕，就是对方到底说了啥，实时的显示在你的这个眼镜里，可以拍张照，我给你做识别，这太太普通了。

对，这样的一些东西我觉得它亮点都在这儿，都在这次的这个手势识别，结合他眼镜的这个操作上，确实做的挺不错。比如说我要这个放大缩小，然后直接可以靠手势来去做这件事儿，那确实手机就不需要了。也挺符合扎克伯格想搞的所谓的脸上的AI这个方向，然后还能做什么？两个人就视频对话，然后这些东西就不重要了。对，所以这么的其他的他还做了个什么滑雪眼镜，这个就不管了。

然后这个多少钱呢？八百多八百刀，现在八百多多少钱？800到5600人民币，挺贵的。

所以这个确实看起来这个体感挺不错的，但是我觉得还是太贵了。这个东西现在做的它的功能其实就这些，那无非就是但是它是一个彩色的这个光波导，我觉得这个他如果做的那么小，其实彩色的质量还不错。它的那个像素率像素还挺高的。我看看是多少。像素是多少来着？找不到。对，但这有一个问题，你看它的镜片只支持-4.0到正4.0的近视度数，那我这种高度近视就不OK了，所以这个是挺讨厌的。他其实不支持，比如说800度这样的以上的近视。

而且800度以上先给你做个手术。

那那400度是不也得做一个手术？对，然后这个眼镜其实重量不还行，就是有点儿。就这样。你看600乘600的这个pixel，像确实还是比较高分了。然后全彩色的，然后六个麦，这个meta的眼镜的音质大家是可以是可以相信的这确实很牛逼。然后1200万像素的，能用6小时，这还挺不错的，能用6小时。但是我觉得你作为一个眼镜，如果不能我全天用，确实就很尴尬。那你说我6个小时以后干嘛呢？尤其是我戴近视镜镜片的话，那我换个眼镜怎么着？那我不用了。

其实就很讨厌这个事情，就是我觉得还是得如果真的能全天候日常佩戴的话，你要不就买两副，你要不就等他这个这叫什么续航能到这个程度，然后多重？看看还不清楚，就是70克，70克的框架。然后那个那个充电盒160克，170克也不轻。所以整个东西我觉得大家如果有钱可以去买一个玩一玩。但是我觉得这个不是那么值得，现在就去就入手。

然后说到这个meta这个眼镜，我就联想到另外一个，就上次说这个air pod s three air pods pro这个三里面有几个挺有意思的东西，一个是我看能不能找。一个是这个就是实时的translation，实时的翻译。你听到的语言在你耳朵里自动就翻译成你想要的语言。好的语言问题是啥？这个大家不要太那不要太太激动，一看就买了，当然我也买了。所以这个是啥？他这块专门写了适用于air pod 4以及搭配了什么固件的。比如像air pod pro 2也行，所以其实这个没有必要一定得买air pro 3。

二其实也行，但是出于测试版，而且是什么呢？翻译成中文这件事年底晚些，今年晚些时候才支持。所以他现在只支持的是英法德葡萄牙西班牙语这样的一些东西。然后据说你晚一些，那晚一些，其实如果他不跳票的话，那还好，对吧？那万一跳票到明年那就就挺讨厌的，所以还不如apple 2。

这大家如果有的话，就直接用就好了。所以苹果这个做的挺不错。但是我不知道他到底是把模型应该不会跑在它它的这个唇二极端对吧？他虽然上了个HR的芯片，但是肯定也算力也撑不住，也没那么小的模型。所以很肯定还是受益于它air pod跟手机端它自己整个生态的非常好的连接词这个链路上来去做这件事情。



然后另外一个这个功能，跟刚才的那个眼meta那个眼镜也很像，它有一个叫conversation boost。就是你跟谁聊天的时候，他会特意的去提高你正在跟你讨论的那个人的声音，而减少周围的干扰的噪音。比如在什么咖啡馆，在这个商场什么的，他会去故意的把对方的别人的人生给你提高，而降低旁边的噪音，来提高你们的效率。尤其是加上这个翻译以后，那就很爽了对吧？就是你可以只更专注的听对方说的话的翻译的语言。然后这个事儿其实就是所谓他的叫什么计算空间，计算什么来着，计算音频这个概念下衍生出来的东西。

然后meta那个眼镜也有这个功能，但是我看matter眼镜问题是它没有一个入耳式的东西，所以他没法去强的来去提高某一个人的声音。他还是只能去呈现在屏幕上，或者说帮你做一些音频上的修改而已。没法去像ipod pro那样，等于劫持了你整个的听声音的链路。

对，然后这个就是最近几个硬件，我觉得挺有意思。然后有一个产品我觉得这个可以大家可以去，如果有出海的话可以去试一试，这叫listen lives。这个上次没有说吧，有没有说两副就够了？对，happy bird真的是有钱。这个两买两副，1万11000 12000，这个就没了。这个眼镜镜头有电池没电了就换镜头。对，哪个眼镜还真的这么搞的？

我都忘了是有一架眼镜说我把镜腿的一部分是可以变成磁吸的，然后戴眼镜带电池和换。对，看到有人。对，我也是看到有一个哥们儿，那个是一个数码博主，反正就是整天就测这种的那他是可以弄两台。

对，然后这个场景叫listen，listen点a list labs点AI它是做啥呢？其实就是大家现在要去做一个产品调研，这件事咋做？那肯定是说我要去找大量的可能我想调研的人，然后来去跟他们聊。而这个东西咋做呢？就这个listen labs怎么做呢？其实就是我直接先去你我看看有没有视频，是这个不是。算了，就对着这个，就是你直接去跟这个。就有一个视频。

对，就是你把你想要去说的这个想要去评测这个点。比如说我想去做一款新的SUV，然后我想这个SUV是针对比如说30岁的男性，这样来去推款一推出的一款什么越野SUV。好，那我肯定希望找到一个不这个目标用户去聊，那怎么聊呢？那这个他就会帮你干嘛？他就会帮你找大量的受众，然后这个受众怎么聊呢？就是拿voice agent直接他帮你打电话也找不到这个视频了。然后这个大家可以自己去看个listen labs点AI肯定有那个demo视频，就直接说对，就这样，introducing listen。对你就给他我想去调研什么东西，他就会跟帮你分析，这个边就是边跟你聊边澄清你的需求。然后一旦澄清完了以后，你看一旦澄清完了以后，你看他会告诉你说，可能我需要去聊10到20分钟每个人然后要找多少个人，总共加起来花多少credit OK了，你直接点这个recruit，recruit就是招招人，他就会自己帮你找。通过他的整个网络里去找对你这件事儿合适这些被采访的受众。怎么去采访，就是怎么去聊呢？

你看这就这个what do you think about this site？

cool. What's cool about IT？

I mean, having in the eye? 对。

说白了就是他有一个平台可以让这些被采访的，被做焦点小组，做产品访谈的人，直接看到你想被让他去调研的这个产品，然后靠语音跟他聊，就纯靠聊的。所以我觉得这个事儿挺有意思的，就是你只要去想好在前面跟他跟这个agent沟通好说我想做个什么东西，然后所有后面的事儿都是他来帮你干。干完了以后，他你看咋咋聊，咋咋聊完了以后，最后给你一个report，给你一个报告，这个报告会告诉你说有哪些主题，大家对你的反馈都怎么样。然后有一些比较高亮的这个采访的点，你看高亮的采访的时刻都给你整理出来，还会干嘛呢？他给你做个PPT，给你做了个给老板用，给老板讲的PPT。Iconic brands like mico。对，所以这个产品很有意思，我觉得这个可能是未来产品所谓的找这个PMF或者快速试错，快速的研究新产品，就开发新产品的

一个很重要的一个能力功能。就是我有想法，我怎么能快速的扑出去来去获得比较低成本的获得大量的用户反馈，来去决定我到底要不要继续投入这个方向。好，然后最后讲一个大家知道有没有玩过这个Polly market的人，有有玩。昌浩你玩过这个吗？

没有。

这个是个啥呢？就是一个基于区块链。

的赌博。

类似下注。比如说它有大量的event，比如说卖tiktok的这件事儿会什么时候宣布？比如说是这个september 30宣布，还是这个december 31宣布呢？然后你就可以投票。所谓的下注我买33欧，9月30号他会发，然后我要值就OK了。你可以用各种的什么VISA，或者用paypal或者用数字货币，这些都可以往您处置。然后我就下注，然后下注完了以后，就是到点了然后评判一下，然后这个就自动的打给各方。它的最大区别就是啥玩意儿都可以赌，也不叫赌，就押注25年tika会不会被ban，对吧？

然后啥都可以读，那大家想想这些东西很多都可以读，那代表的是什么呢？就是它不像股票什么这种东西有非常强的信息透明度，那你会想着说这个肯定会有一些问题，可能我有一些消息或者说我做一些比较深入的研究，我就更可能获胜。这块就联系到了一个产品。

对，就是大家会想象说，我能不能不人来赌，我用A卷来去赌，对吧？那就有这么一个有意思的东西叫policy er。你只要把你关注的这个赌局，比如说美联储25年会cut掉多少的rate，对吧？然后把这个链接扔到这个policy页里面。然后你会发现现在干嘛呢？他开始用A方式来去分析，我已经今天都用过了。我看看之前我分析的结果，在这儿我当时扔的是tiktok的sale会在哪一天公布这个度。然后你会发现现在干嘛。

他开始爬数据，爬链上的数据，爬外面的数据，然后做优化，然后做research对吧？就是所谓的这种deep research这种东西，然后开research，然后各种的research到最后强化的分析还在干活，你看这个干了得有挺久，他怎么没停？我靠，到点了，不是到限制了，行吧。对，说白了就是他做了一个你想用agent再去policy在Polly market上去赌博的这么一个agent，那这个其实就跟这个钱就更关系了。因为股市我觉得还是一个特别信息充分这样的一个博弈。但是像这种policy里面这样，就Polly market里面这样一些话题，那还真的是有可能可以靠一些比较深入的研究来去做到一个预测的。所以这个挺有意思的一个，大家如果对这个预测各种东西感兴趣，都可以去看Polly market它是一个基于区块链的，所以所有的这些打钱，然后执行都是靠智能合约来完成的，大家不用担心的起码现在不用担心他跑路这些东西。

好，对我说一下这个，就是刚刚说的硬件时候，忘了说这个嘴了。就是google前两天发布了几个硬件，它里面有一个很有意思的功能叫magic q magic q这个东西，magic q它是干啥呢？你看比如说别人问说嘿，你有没有今天晚上地址？然后这一段话是他自动出来提醒你的，是这个手机操作系统提供给你这个建议，就是他觉得你应该可能要回复这个，然后你可以直接点，他就可以把它这个发给对方了。但是他做了很多这种跟他的原生的应用做很好结合，说白了就是啥呢？就是他觉得你这个时候应该发什么，做什么操作，他给你一个提示，然后你唯一需要做的事儿就是允不允许，要不要接受他的一个建议，这玩意就叫magic q然后刚才的这个像meta这个眼镜里面好像也有一个这样类似的功能，就是它去提示你可能哪儿可能会需要去干这件事。我看看能不能找到Q。对，这个他love AI里面也可以有。

就是你跟人聊的时候，他自然会说，给你不断的提示出你可能会涉及到的问题，可涉及到各种信息，比如说这个什么东西忘了就看不清了。比如说你跟他讲，那我们明天上午九点去这儿吃饭。然后他这个时候就自动的弹出来一个说要不要加到calendar这样一些东西。他可以把整个的这种基于AI提示做到一个完全主动性的这样一

个提示，所以我觉得这一类的产品会越来越多，就是像magic q，像麦太的眼镜里的这样一个几乎主动或者半主动式这样的AI，这是一个特别明确的一个趋势。这个我觉得还是说一嘴，这个还挺重要的。

大家记得我有一期讲A镇支付，还记得吧？然后这两天昨天对昨天google annos了一个大东西，叫agent payment protocol。Agent支付协议这个事儿，其实就是我们之前说的。如果我们想让一个agent能够自主的支付的话，那需要的东西其中一个就是我得有一个标准协议。而这个标准协议谁能搞得出来呢？也就这几家大厂，对吧？

大家知道MCP是cloud，是SR pic这家公司说的那A to A是google提的，那这个所谓的APP就叫简称叫APAP two。这个协议又是google提的，他宣布了一个叫agent的支付协议。这个支付协议是一个所谓的之前的agent to agent这个协议的一个扩展。并且还支持了这个MCP这样一个东西。它里面涉及到什么？

就这个整个协议涉及到的三方，user就是买东西的人，merchant就是商家和支付提供商。比如说像中国就是支付宝，然后VISA、银联，这些都算支付提供商。然后他这个协议就是为第三方提供的，而且现在他跟谁合作，我觉得这挺牛逼的。你看这个VISA、运通、蚂蚁国际、paypal这些都有，而且还有谁国际银联国际，就中国的银联国际居然也在里面，我觉得还挺欣慰的。因为我们之前跟银联有过一些合作，感觉他们贼慢。后来发现银联国际其实是一个更步步子更大的这样一个组织。对。

那要小心点。

对对对，反正银联有很多安全合规方面的担心，这个考虑那很正常。好，为什么要搞这个协议呢？其实核心是这个事儿。这三个点就是我用户怎么表明，通过这个协议表明我授权这个agent帮我买东西。这个authorization以及authenticate authentication是啥呢？就是一商家要明确说这个agent他的请求是反映了买家的人类的真实意图的这其实还挺难的，就是怎么证明agent给我下的这个单真的是人类的需求呢？这个是auth nation，对，LLOCCT，对吧，就真实性。然后最后就是责任，就是问责制，就是到底出现事儿的时候到底怎么规则，对吧？

你你你让A镇去花5000块钱，结果你回过头来说这不是我买的，是A镇买的，那不行，对吧？所以他这个AP two这个协议其实就提供了一个所谓的这样的全流程的一套协议，他支持的钱从信用卡到借记卡到稳定币，到实时的银行转账都支持。所以是一个特别完整的一个链路。

大家有没有觉得这个事儿就跟前几次给大家讲过的一个事儿就连起来了。Google在做自己的链。还记不记得这个事儿，就是google在搞自己的L1L1的券，拿着L一就是像比特币什么这种就是L一的券。然后google在做自己的LE的block chain，是叫GCUL这么个东西，就这个东西universal什么larger这个东西，那是不是就联系起来了？就是既然我要做一个给agent支付，然后支持各种类型货币，尤其是现在这个RWA什么是稳定币，这么火的情况下，那我肯定是希望有一个很稳定的，我可以在上面运行的，而且成本还比较低的一个量来去支持我的稳定币的运行。因为稳定频率运行它不一定在哪个链上，哪个网络其实都行，那它就只是跑的B不同，所以它最好的做法就是我自己起个料，您把各种的稳定币都跑到我这上面就OK了。

好，那他咋做呢？其实就通过一个所谓的防篡改加密的数字合同，这个digital contract来去建立所谓的信任。他就分两类了，一类是说有人类在场的买东西，比如说我说我要买个鞋，然后这个agent给我展示一下是不是这双，我说OK，是的，然后这就是所谓的人类present，present就是人类在场，那这个就相对来说比较容易，对吧？你你你靠一些生物ID什么的就能证明说，这真是我说的。难的是这个人类不在现场的情况下，比如说什么呢？就是一旦开票了，这个演唱会开票了，我立刻就A站，我让我的A站立刻就去买一张。

那这个东西就很重要了一点，就是你得事先签一个强制的授权的意图。授权在你你你你授权给agent花你的钱之前，你要去上一个你的这个意图，表明这个agent干的事儿真的是你的意图把这个事儿绑定，你们还定了很多我们一般叫pay control的东西，就是支付控制。包括说什么价格限制，时间、条件这些东西。好，然后他把它加密起来以后，就可以建这个叫什么来签名以后就可以作为你的agent帮你花钱的一个确定性的依据了。所以整个过程其实就是干这件事儿，就是把你的安全的这个支付方式跟你的被验证的内容，就整个链给绑定起来，其实从这儿，从你的意图到购物车到支付，整个链条全都给连起来，然后创建一个不可以否认的审计轨迹。这样的话你的A证干了啥事儿，我至少能最后规则都追责到你这个user身上，或者追责到什么商户身上，反正不是agent的责任。所以这是一个很关键的一个点，就是我怎么通过一个协议，把A的从整个购买行为中给在责任链上给连起来，把用户跟商家连起来。

那能干啥呢？其实就可以做很多事儿了，他就设计了很多想法。比如说有一个客户发现他现在某一个夹克无货。如果说我很想要这个东西，并且愿意多花20%的钱，那A人一旦发现那就自动买。

还有一个我觉得这个是更可能性更高的，叫personalized offer。就是我专门就给这个人，因为他表达了他要去想买一个新自行车的意图，要去旅行，所以我就专门给这个意图构建一个打折优惠。好，那你这个agent接受了，或者说我就专门针对你的agent构建这个offer，OK就OK了，因为他带着他的意图，然后还有什么协同任务，比如说你如果发了一个说我要去哪儿哪旅游，我要鸡酒，对吧？那你鸡和酒是不是这两个agent可以协同一下，交互一下，然后最后给我一个整体的满足我预算的这么一个方案，那就OK了。所以这个是一个多一点协作的这样一个情况下的一个支付，那他就带来可能以后会有大量的他们跟谁合作呢？现在coin base、以太坊基金会、meta mask，还有很多别的组织都在合作这件事儿。然后还支持了所谓的X402在数字货币里面大家比较公认的agent支付的这样的一个协议，所以这个可以看出google这次是一个对于数字货币很很大幅度的一个拥抱。

我觉得还是挺明显的一个拥抱，尤其是从他开始倒L一开始，然后你看他跟谁合作，这一大堆公司都在合作，这里面有谁呢？这个银联文件，还有这个家伙，manus，所以我觉得minus自从跑路了以后，玩的越来越大。他确实是在有一次采访里面也说了，他们要在尝试做支付方面的事儿，对吧？那确实是他既然想做general agent，肯定是要要去把这个agent怎么赚钱或者怎么花钱这件事搞打通的。所以对大家可以期待一下。

然后底下我靠剧场都是讲各家合作厂商怎么怎么吹他们，怎么夸他们。我觉得这篇文章很神奇，差不多得有得有一半的内容都是在说各家厂商怎么夸他们的。这个agent payment protocol的这个事就不说了。对，详细的就没有啥了。然后AABR，它AB two也有一个开源项目，基本上就可以也讲了说这东西到底咋用，也挺简单的，挺简单的。然后跟X402这个东西怎么结合，也有一个东西，这就详细的就不讲了，然后这个就是它的量，所以这个事情今儿又没讲到那个much，我觉得还是讲一下这个。FDEFDE昌浩，你知道这啥意思吗？

FDD对吧？我特别认同这个FDE这个。

你真特别认同，那我特别认，我先给你我觉得他只是不好实现。

就是他需要一个特定。

的对对对，对，这是plantier官方的。大家知道plantier吧？就是那个那个股价涨疯了的那家公司。有一个同事买了plantier，然后在好像是三年前，多少两年前，我靠，涨了好几十倍了，我惊了。然后他提了一种新的软件工程师。大家知道软件工程师叫software engineer对吧？然后如果是软件开发工程师，一般叫什么SDE对吧？

这个soft software development，什么什么engineer SDE，然后他提了一个叫前向部署软件工程师。而且这个概念确实是，我记得要应该就是plantier官方提的这样的一个概念啥意思呢？其实就是这么个东西，他专门有一种叫FDSE或者叫fd这个角色被称为叫delta。

这个delta是干啥呢？说白了就是你的一个软件要去部署在客户的这个系统中。你需要做的事情不光是说你吧软件给它布上，你还有非常多的事情要去适配客户的业务，客户的流程。那谁去干呢？不可能让客户的这个为主去干这件事情，因为乙方这个姿态得摆对。

对，所以他就说好，那我去放一些工程师到你那客户那儿去帮你做件事儿。那这件事儿，如果是就单纯的是这个现场工程师，那大家太多了，什么驻场都是干这个事儿的对吧？驻场工程师都是干这个事儿的。但是他的这个plantier做这件事就做的非常的极端，就是直接到现场跟客户一起做到一起去聊说你的业务场景到底是啥样？

然后你到底需要怎么样的一些功能，要怎么样一个结果。我现场给你去写，现场给你去配置，现场给你去写代码，甚至来去完成你的工作。而且是一个非常的快速原型开发的这样一个方式。

所以这个好处就是比如说客户说，你这平台一坨屎，这个我不想用。但是他可能比如说一两天他就可以立刻手搓出来一个客户想要的这样一个东西的。比如说10%的一个效果，一天以后就立刻给你看，你看这个是不是好点。然后客户说那就好像是，然后再提一些需求，然后他立刻又快速搓一个东西出来。那这个东西可以想象它绝对是一个巨操的结果，对吧？就是巨操的代码。

但是好处是什么呢？就是你真的深入到他的现场业务里面去，帮他去完成了，你又懂他的业务了，然后客户又越来越相信你，对吧？因为他能看到你整个的这个进展过程，所以这玩意儿就可以理解成是叫线前线部署工程师的这样一个角色。

这个角色其实大家一听就想，是不是有点类似于咨询的软件咨询呢？他其实他说不是，其实核心还是要基于他现有的平台去做开发，所以并不是一个纯从头来去做的东西，所以本质上他还是为了他的产品的这个迭代研发这样的一个过程来去做的。所以他底下就说了一大堆，他在plantation时候的时候，你看那个cov nineteen，这个新冠的时候的这样一些经历。

所以应该是几年前的这样一个经历。他怎么做的？他基本上就是一个特别不确定性的，就是他好像是一个硬件工程师，但是来这儿以后学了一大堆东西，就是任何一个事儿都是直接到现学现卖这样来去做这件事的。所以他有一大堆的说plantier这个事儿特别有挑战，但是特别的感谢，那那他就写了这么个东西，但是这个不是，这是planty官方的这个说法。

然后这个家伙叫barry的这个人，他的这篇文章写的就更真实。就是因为他是之前的一个FDE的入在在planted干了好几年的这个人，然后后来自己做了公司，然后他就讲了说当时他FD怎么做的，他就真的是一个直接在客户那边待着，然后这个要去现了解，所以叫burn in the field，在现场干活，然后就是先去根据用户的需求来去写代码，来去甚至发明新的产品技术。我觉得这有点过有点夸张，肯定大概率还是基于他们的产品来去做的。然后就开始去再怎么怎么去线去做，然后这个线去开发这些东西，然后他就开始往回找吧。就是说这个事儿为什么不是大家都搞？我觉得康浩你那边可能也是有这个困扰，他把fd这件事情定义成rd就是研发而不是成本，不是成本核算。他认为在前RD这个工程师干的事儿都算他的RD的成本，而不是他的项目交付成本。所以他做了非常多的说这个模式需要很高的水平的薪资对吧？

他招google的人，招招facebook的人来去做FDE。然后这些人比传统的这种坐在办公室去整天写代码的人，其实工资差不多甚至更高。那这些人怎么能够直接到客户那儿去服务客户，这是一个很大的问题。然后甚至有

些项目他们直接是亏的负无穷的毛利的，甚至有些情况下他直接把这个项目送给客户了，然后等于说你怎么样花费用顶尖的1%的工程师的价格来去做那些没有办法扩展skill的这事儿。所以这是一个特别大的，很难很困难能够说服投资人的这么一个点。

刚才说了一大堆别的东西，说FD到底怎么做，然后问什么情况下才能做，我觉得这是一个挺挺挺诚实的一个说法。你得有一个足够高价格的市场，比如什么呢？比如说这个大型的政府机构对吧？政府有钱，当然他说的是美国政府或者军方。

然后第二个就是你得有个心态，就是你实际在做的事情大概率是你不了解的，你要去现学现卖，现做现去开发的。然后第三个，就是你得有一个所谓的可扩展的平台，就是说白了你在这儿做的事情不能就是一个项目，一个单独的的事儿。你还是得想出来我怎么把这个项目里面做的东西，不断的做到我的这个可扩展的平台上来。本质上还是要扩展自己的这个产品，所以这件事这三个条件一筛，这事儿就极其的罕见，而且非常难实现。所以这个事儿就是他说鼓励任何的正在构建新事物的人采用这个模式，他只是说采用这个模式，而不是你一定得去招什么FDE这样的人。对，所以如果咱们群里有同学是这些？就预算也挺充足的这些公司，那我其实觉得还真有可能可以考虑这件事儿。

他我觉得跟预算足不足是两个概念，就是它是一个特定的工种，它介于咨询跟交付中间，它是一个比咨询problem solving能力更强。我不仅仅给你提个建议，甚至我把这个事情都做起来，所以我觉得是有更好的一个理解，是具备具备IT技术能力对吧？这种的咨询的咨询师。

对他其实就是这张图，我觉得挺明显的。就是一个软件工程师和架构师，就是解决方案架构师和平台工程师中间的这个角色。

你就我觉得你就属于这种。

所以整天跑到客户那去搞事情是吧？

但是你看你没搞完，吧？

你还差点对我待不住，但是还是没法在客户那儿一直待着。

对不？我觉得这个问题在于，你你你之所以不交不做那交付，是因为那些交付是boring。我认为你还要注意一点，就帕兰提尔他真正的起家的時候，它能支持F第一是因为它解决的都是一些非常夸张的问题，然后既能收来高价，而且让这些人觉得非常proud。你看看早期解决什么，对，比如说抓捕拉登可以。对你想想这是可以吸引一个比如说甚至hover吧？就最牛的人过来，他愿意去说这是我一辈子的荣耀对吧？

但是钱困难。

那你看我们现在的所谓的这些大公司，缩小LSD，它解决什么问题对吧？你怎么可能去吸引那些真正特别牛的人去做。其实我觉得回归到这个问题。就当你是这样的problem，对吧？你根本就不会你可能像麦肯锡他们有时候解决问题还能多少算一点那些更更那个的。然后如果你要咨询的话，你想想看他们咨询体系的薪资待遇，工作的压力就会更符合潘切尔的FD.

E的这个逻辑。

那那一样，大家challenge咨询公司这个商业模式的原因就是说你不能skill。因为你的人？你咨询公司为了抵抗这种我可以skill，就是花了大量的精力在我的方法论的标准化。然后你看就对应着类似plantier的那种把平台工具化对吧？在不断的有培训的体系，他更牛的是branding很好，然后不断的能从最top的学校里面吸引毛多的人去，就让他能够供他能够第一波去筛选，我觉得这是一个整个的体系。它你国内的公司，你光想抄这个形式或者naming，这是不成立的。

你觉得国内啥公司能干这事儿？

我最近倒是真真看有几家公司也在类似旁听的逻辑。但是他们也在做军工的项目，然后聊了几下确实技术很强。厦门有一家公司就。

不说人高毛利。

对我觉得高毛利是一个核心点。高毛利前提就是说得解决客户的高价值的问题。

挑战足够大对感觉好。

所以上次某也清华系的公司，然后现在在做政务。然后我们跟我跟他CTO聊一个师弟，然后聊他们想去学paper，我说你这学不了。你看看你去政府做的那些项目都是什么样的项目。你看看潘特尔区政府解决的项目什么项目。所以就是你你永远不可能把你最牛的人派到前线去。

对，但政府这块就不一样，你要找一些什么这种比较特殊的部门对吧？安全这些方面的部门，那还是预算还是OK.

那你也得看你挑战的是什么。等于如果是能帮国家造导弹，这个就那肯定是。

帮帮国家统一台湾的，那是真的能吸引一些人。明白，没事儿，看看今儿，来不及讲后面那个东西了。对，反正你看这plantier的官网，他的招聘from for world。哎。For world对吧？前项部署工程师一大堆，而且都是啥都是政府类的，前线部工程师美国的，而且他几乎都在每个地方很少就几个人，然后你就在那待着，然后就整天跑泡在客户那，而且据说open I都有了，open I现在应该有个几个人。对，你看对我。

突然想起来了，我觉得国内特别像这个逻辑的是可能是早期的，我现在也有。

可能是华为。

那拨人，海外那拨人我认识几个确实很厉害，就是他们遇到的困难非常的，然后他们就是那种蛮挑战，每个人都挺有探险精神的那种感觉。

对对联，欧派现在有据说有10个FDE，分布在得有十个地儿，七八个地儿。所以这些人绝对他妈都是单打独斗的。



你能把这种人叫成交付吗？

对，就别说薪资了对吧？你就算名儿叫错了他就跑。对，所以这个听着确实很难，但是你想open I都搞了。所以至少在表面上来说，我觉得至少国内大模型厂商总会有干这事儿的。为什么？就是大型厂商干这事儿很合理。

因为我觉得你就应该立了这么个team.

就整天泡在客户那儿是吧？

不是你挑那些最有挑战性的客户。

赵老师，对，然后有很多挑战的活就可能就都说不出来了。这些项目。

其实是有的，其实有，但是你们这些资源被当成售前用，然后你解决完之后又有又又有相对来说普通一点的交付同事去问我。

当时看这张图就特别感兴趣，这就是好像planted，还是open I的open I的一个FDE。跑到人家那个农场里去跟农民现场去讨论，然后帮他们去做这个所谓获取实际经验这些东西。我觉得这玩意儿就是一个很屌的D这样一个工程师应该是待的地儿是吧？要不在矿井里，要不在。

听众朋友们如果有自己觉得自己能干得了这种FDE的，可以跟我们联系。

你要招吗？

我肯定要招。好好制服也照。大车童装我觉得。

未来真的。

是很多的dirty work其实都可以用AI来做。但是需要有有挑战精神的人去想不同的解决方法，然后去定义问题，我觉得这是未来的FD所以我认为就这种人的性格。

就这种。

是真正缺乏。

的东西。所以他说plantier里面这么搞出来的很多FD最后都去创业了。因为对整个这个过程其实就是一个创业者的培训，就是创始人的培训过程。然后它里面还提了好多这个阶段还挺实在的，就是你面对客户的FD应该怎

么第一阶段做啥几天，第二阶段做啥几天，第三阶段做啥几天，然后整个的给你展示出来这样一个效果，好像就是open l的这个做的OK的。

对，OKI的FD有面对客户的，有面对内部人的，对吧？面对客户搞定这个FMMVP，然后来去deliver，面对内部去做知识的分享沉淀这些事情，这个非常重要。我比这个内部在后台做产品的更重要。我感觉是。行，大家今儿问的不多，今天的问今天问题不多。我觉得大家有什么想法，或者说确实说的太多了，可能有啥随时说。有啥问题没？

你只给大家提问题留了三分钟。

我的我的我的下次再多说，多多了解。今儿说的有点杂的，确实是一个直接给大家看一下。对，正好给大家也不算留个作业，算吧啊，算留个作业玩一下这个MGXMGX点dive，MGX点dive，这个就是meta GPT那个那个项目的团队做了Martin agent项目叫MGX点dep其实就是一个多agent体的干活这么一个东西。我当时的一个项目，就这个东西，我给他的需求就帮我做一个钢铁的表面的defect的检测，用幽默角来干，是用的marty agent，所以他搞了这么几个agent，一个team leader，一个数据分析师。是不是还在干活呢？我看看疯狂的写，搞定了，没钱了，我操你充多少钱，寇塔没了。行吧，但是可能这活确实要写代码比较多，你看这已经写了这么多代码了。

这个是我看的代码，里面属于比较清爽。

所以你看这个这evil一下data，这跟人差不多写。

的挺规范。

就是没有那么多乱七八糟的那个那个叫什么软件工程的那么多很复杂的结构。

1690 folder下面是什么？他这块是他直接把UO引用过来，对吧，这不是他写的。

chat t你看看，这优乐酒的应该是。

已经看过了。

你看这代码应该不像是献血的，我搜一下。

你因为味不浓是吧？

没有，对，这应该就是169的对，留个作业，大家玩一下这个MGX点到，然后。

六个月你批不批批。

展示展示，下次这同学能不能展示？一开始跑那个PPT的啥意思？

你最开始跑的把那个PPT，不是用你那个电脑。

这个是吧？对，对，看看PPT咋样。

看着还行。

我说没有这么多人。

要不你再往下拖，看看靠不靠谱。

来。

智能交通调度应用场景。往下不了。卡住。

分布式优化。

这就不靠谱了吧，拉个老师。不太像是这个agent。感觉是模型问题。

对，感觉就是能力比较饭，是那种对。

对，但是你想想这个他跑的是个，我看看跑多少钱，32B的，30B的还是int 4以后的才18G的一个模型已经很不错了。把它用改成GPT很方便。真的大家有预有有这个预算的话，推荐大家买一台这个AI max。挺不错的，挺好玩的。那个东西。

如果买这个或者买那个3D打印机，两个你只能买一个。

那肯定。那还是买三打一吧。关键我是个用云的人，基本上这里面很多我都有付费的云端产品，3D打印机这玩意儿没法云的，好吧。对，大家可以看看这个还挺好玩的。好，还有吗？还有啥问题没？今天。但是问题比较少。

FD那事儿改天详细聊聊呗，我觉得这个还是挺挺挺对于组织结构来说影响挺大的一件事。

对，所以还是回归到阿里的三板斧，我觉得是对的，就是你要业务决定了你的组织，你的组织决定了你的文化。对所以很多时候大家觉得我就是什么样人我就定好一个文化，我用这个文化去吸引符合这文化的人，然后我再去做对应的事儿。那只能说你用这种思路的话，做不了一个特别大的事情。阿里的牛之处就在于它可以有好几个第二曲线，对吧？从最早的B2B然后变成了第二遍，变成淘宝，最后就支付宝。

这个AAP two是吧？不是AA two p是吧？AP two就刚刚那个agent payment那个是吧？太慢了，是这个是吧。

收钱平台。

所以这个有什么就业机会？就是你是想找工作还是想找创业机会？我觉得这个其实挺重要的一个点，就是你想这这几个角色里大家普遍有啥有机会的。这个里面几个角色里面其实就是user，merchant就是用户商家和支付宝支付叫什么支付服务提供方。这个其实也有可能，比如说先从用户或者说他其实用户跟machine之间就是你的agent，那个agent肯定是最大的机会，对吧？但凡比如说我们找一些能够支持AP two这样的一个支付方式的这样一些场景，然后把merge打通说你如果愿意接这个支持我这样一个支付方式，然后我就可以帮让你用一个agent来去吸引更多的用户。这个是一个很标准的一个点。

然后第二个就是这个merch本身改造，比如说什么呢？比如说像这个企查查或者万德这种数据提供方，那他其实都要去为了这个A镇支付来去做改造的。因为你不可能如果你想赚这个，比如说一次A镇用一个数据花个几块钱、几毛钱这样一个生意的话，你想赚这个钱的话，你就得把你的电商改造成适合于A镇支付的那我觉得这个A镇支付merchant改造其实也是个机会。

黑板provider我不知道，我觉得可能才可以参考这个上一代的移动支付，就是有三方支付对吧？还有什么，那叫什么来着，四方还是什么的，反正就那种几级的支付代理商，那那那那还有这种上市的这个3A2级了还是三级的那个那个支付方的叫什么来着？收钱，不对，是不是收钱这种。所以就是支付方其实也支付服务提供商其实也有机会，我觉得是，然后推荐电脑是这个其实不一定。买我那台，你就搜AMD AI max.

你就说你买那台是哪个就行了，大家也少避点坑对吧？

我买的是是不是这个叫什么玲珑什么的，你买的。

19000，你买多少钱？

我买的是13000，但是那个是小米上的这个星河AI超级电脑，这是众筹的。当时我众筹的参与众筹的就这个叫什么星河超级电脑。然后京东上这些反正你看这个样子跟我的一模一样，对吧？一模一样，那怎么还19000呢？感觉这些都是在在包装的，我觉得我那个那个清河那也挺好的。因为他给你装了一大堆开源项目，你是可以直接用的。然后他也做了不少这种linux的适配，就比如说他他一上来就把这个WWSL，就是linux子系统什么的都给你配好了。如果大家自己装的话还有点麻烦。

对，所以可以看看这个星河有没有，不知道星河搜一搜。没有，是不是那边预售还没卖完？还没发完货，可能是行，那就这几个，大家可以有预算的话，可以买一玩玩。好，没啥了，还有啥吗？

好，拜拜。

好的，行。

感谢大家，下周咱们继续。

下周见，拜拜。

