

开播了，你得靠自己。

小平同志是不会紧张的这小明你估计今天今今天晚上大概能讲多长时间？

1个小时呗。

没问题，没问题，然后就是聊1个小时正好跟大家在这个什么正好跟大家在有些问题我估计头一次，咱们再看看这个，我我你就这个你你你没发现你的颜值稍微差点意思吗？

我为什么我终于看到我自己了。

大家能看到了吗？

看到了一位颜值主播。

你没发现你这个颜值跟我和小平还是明显有差距的，我不要来做，能看到吗？我们我我们聊天注意一点，注意点，注意一下。

咱八点我觉得我比你强。

一点。没事，咱们把PD开开，然后人显得小一点。这样的这个颜值瑕疵不是特别明显，尤其是右下角那个同学。

我现在你是不是开了美颜了知道吗？我没有。

我就这样。对。

今天是大家。

稍微等，八点咱们正式开始。然后因为今天晚上试讲，大家找找感觉，我是不可能开美颜的，你想什么呢？就是天生丽质。这个我一会儿给大家稍微介绍，这个课大概是个什么思路，什么想法，然后接下来可能在这个课上会有什么样的收获。但是当然了，今天来大家听肯定也是小白鼠了，对吧？然后要给我们一些反馈，就是这个课大家听完了是什么感受？所以今天还是希望大家能够认真的听，好吧。

哥哥，我这么跟你说开始之前扯两句闲篇，冯小平老师，小平同学。这是典型的清华工科男的长相，知道吧？这颜值绝对是在线的，是不是？直播间里很多朋友当年没有选择考清华，还是有些遗憾的。我没准。

小平老婆也在听听讲。

那我控制一下。

没有没有我我没有告诉我，不让他不要了，紧张。

我控制一下，我控制下，我控制一下，那个人怎么样来的差不多了。那咱这样，虽然是今天是咱们人工智能这个课的试讲，咱们还是准点开始。当然头一次我还是要稍微铺垫一下，这样给大家。虽然这个老师可能你们有熟悉的有不熟悉的，还是给大家留下个今天稍微长一点，3到5分钟的时间，然后给这两位老师打个招呼。该问好问好，该打招呼打招呼，一会儿我们还是要保持课堂纪律。

我简单介绍一下，这课就关于人工智能，关于AI这个方向，其实从去年的下半年就跟大家预告过很多次了。之前可能跟大家说的这个范围更窄一些，因为我知道线上有很多的人工智能的什么各种的科普课，然后小平老师其实也几乎他那天跟我说，他看过大部分都看过，有有一些讲的不错的。你们要是想什么科普的，你可以问问小平，回头这个事儿哪些可能更好一点。但是我总觉得咱们这个课，直接上开个科普课，好像不是我们以往的调性。所以去年大概跟大家提过，就是希望开一门课。

这门课主要是针对什么呢？主要是针对大家，比如说你自己的公司，你在人工智能未来方向上享有一些探讨或者应用。你在公司内部可能在人工智能这个领域可能有一些未来的诉求。甚至我们个人来讲的话，我们希望能够跟得上整个前沿的这些技术和前沿的应用，所以这个课我们还是希望能够紧追整个人工智能发展的脉络，让大家能够在目前或者说未来，甚至未来两三年、三四年的时间里头能够跟得上这次的变化。是这么个情况。所以这个课跟我们其他有一个类似的地方，就是门槛稍微有点高。有些东西可能不像大家在其他的一些什么1999的课中听到的那么基础，这个大家还是要努力跟一跟好吧。

然后基于这么一个想法，所以给大家介绍一下这两位老师。其中右边这位我先介绍不重要的，右边这位江辰浩老师。之前其实给大家在量化的课程上，量化的课程效果。因为它的这个副业是做量化，然后包括在北大副业是在北大叫量化系统，主页是叫北京亦庄人工智能研究院的CTO。当然其实在做很多的人工智能的服务的工作，就是人工智能如何在这个应用场景中实现，尤其是一些to b的。嫦娥是不是有一些，因为我不知道能不能说，比如说一些大公司的名字等等，我就不在这提了，如果需要的话，你们回头再沟通。这个老师就比较熟了，大家这个就客气就行了。

重点介绍一下在我我直播间里左边这位叫冯小平老师，小平同学。冯老师那是这个小平是清华智谱的创新生态中心的负责人，清华智谱大家也知道了，这是清华系的一家人工智能的公司。因为跟我有一些渊源，所以跟质朴的很多的同学都比较熟。创新生态中心在质谱里面主要的任务就是紧盯住前沿的技术和前沿的应用，就是跟咱们这个课的诉求特别的匹配。他们的任务就是每周去做大量的对前沿应用技术的了解、学习甚至探索。然后本身他们就每周到行程报告，然后我这个汇报等等的。包括给一些国内的一些专家学者，甚至一些政府的领导，都是由小平来负责介绍，或者说是定期的汇报的。所以我从这个角度考虑能把他拉过来，然后给大家分享，好像是比较匹配的。

今天这个课大家可以重点的欢迎就可以了，主要是小平来主讲。但是因为第一次在线上我们开人工智能这个课，这不像是在领域我那么熟悉，就大概的那个深度、尺度还是有把握的。所以今天这个课大家来了。首先第一个我非常的感谢，这都是老朋友，估计今天才来听这个。然后给大家提两个小要求，第一个肯定要认真听，因为这些东西都是比较新的，尤其今天可能会有很多跟depth相关的这个内容。第二个希望客户大家给我个反馈，就你们想希望听到什么深度。

我这么说，这两人都是清华大学计算机系的，你们想讲多深我估计都问题不大。但是或者说你比如说想更多的听哪个方向，比如说前端应用侧等等的，这些都可以探讨。所以还是希望大家能够听完了之后给我一些反馈。

然后小袁，我们一般这个课是这么个情况。因为今天在这个领域我没有那么熟，在技术领域把称号拉过来对吧？做个陪，然后一般的课都是主讲人先分享，大概分享1个小时左右的时间。然后另外今天咱们这个情况特殊，因为头一次，我们尽量多的留出一时间来跟大家互动答疑一下。我估计可能大家有些问题你有思想准备，这个不一定有些问题都特别的靠谱。我们线上就这么个情况，然后我觉得我这课就没有什么我能总结的地方了，最后可能跟这个课的反馈，我们收集一下信息，需要总结的话可能稍后来总结一下，大概就这么个情况好吧。然后希望咱们直播间的老朋友自觉维护直播间秩序，尤其是小平老师第一次来，你们还是要给老师们留下好印象。

行，怎么样？剩下时间交给你，辛苦。我就这样，我就我我因为我这个形象不太好，所以一般开始讲了之后，我就关视频，关声音了，你俩露脸就行了OK辛苦你来。

谢谢小苏介绍。大家好，第一次来到苏直播间简直是我刚才群里说我这个紧张已经过了个年，舌头要打结了。然后又来到了这个小厮的这个直播间，简直是诚惶诚恐。对，所以还是非常感谢今天有这个机会。然后也是像刚刚小四说的，因为我也不知道大家想听哪些内容，或者说大家都是什么样的一个背景的同事。然后大家就很希望说大家对于我讲的东西有一些反馈，然后能够知道说我们后面分享什么样的东西，或者大家对什么样的东西感兴趣，对这个非常希望大家能给我一个反馈。

好，那我就开始。我是投屏吗？我看到了我投我的屏好吧。

老师您直接点那个屏幕共享，有一个桌面对就可以了。

现在是OK的是吧？因为我只要打开了这个全屏，我就看不见别的东西了。对，就是有能跟我说一下，这个是OK。我现在投屏的这个内容。

老师您稍微翻一下页我看一下，目前我这边是能看到没问题。

OK没问题，没问题。好，好，那我就开始。今天起这个名字叫dipstick时刻。其实是因为前段时间美国对于咱们dic发的这个R一的模型反响特别大，然后还说出了斯普尼克时刻这样的词儿，所以我就把它起名叫dific时刻对于咱们来说其实就是这么一个时刻。然后前面因为我不知道大家的背景是什么样的，所以我在前面把几个概念跟大家对齐一下。因为我们说现在这一代的大模型其实也是AI然后上一代的比如说这个深度学习那一波，就是5678年前那一波，所以也叫这个AI然后再往前这个机器学习也叫，我们现在其实讲的AI是经过了很多几十年以来的这样一个沉淀，然后到大家现在开始尝试，或者开始从大模型这波技术看到了所谓的AGI的这样一个曙光。然后当然前一段时间这个奥特曼也说了，所谓的ASI就是所谓的超或人工的人类的智能的这样的一种智能。大家可以想象就alpha zero那种玩意儿，就是你你你你原来还能够给人类棋手定什么1到10级的棋，这个骑手然后现在f zero你说你他定的哪个级都定不出来了，就是有点像这种意思，就超过了人的本身的对于级的定义，那我们怎么去看这一代的AI，我觉得就先扔出这张图就非常好。

我们这一代的就不能像以前是来说我这个人工人脸识别，声音的转语音，不是转转转文字这样的一些模型，我们或者ai我们看它准确率多少。这些其实已经我们这一代的模型已经超过了这样的局限性的这阶段了。进入到了下一个阶段，就是我们怎么看一个AGI的这样一个水平，那就涉及到这张图，这张图是一个挺好的一篇所谓里面的一个图，就是关于大模型到底他的能力怎么去定义，或者怎么去划分它，就是跟人类怎么去看自己的智能是很像的。我们说一个人他有最左边的像基础的这种绿色的部分。基础的一个人，我们说他聪不聪明，从这几个方面，比如他的理解能力，他的多语言的能力，他的这个世界知识，就是他知道多不多，当然有一些coding能力，这个是普遍的对于AI的这样一个认知。这部分的能力我们认为是看大语言模型这一代的AI的一个基本的能力。我们认为他应该基本的具有这些方面能力，然后才是中间的这部分蓝的我们叫涌现。

大家前面也听了很多这种涌现这个词emerging这个能力什么东西是涌现的出来呢？就是比如说这个instruction following，就是叫这个指令遵循，就你告诉他干啥，他就真的知道你要干啥。比如说你原来帮我翻译一段话。那以前的模型就是我要先找到这个翻译模型，我再把这段话扔进去。但是现在的模型就一个模型，我就告诉他说我你现在给我翻译，然后翻译哪一个呢？翻译我下面这句话，他就知道你到底这个指令到底是干啥的。

然后包括这个in counter earning，咱们现在用的各种的项目，质朴的这个质朴卿言或者文心一言，或者什么chat BT里面都有一个很重要的功能，就是你扔给他一个word文档PDF，然后问他的PDF里有啥东西。这种它背后对应的能力是实际上是就是in context learning，基于上下文的学习这方面能力，所以举个简单例子，比如说你说你问大模型说这个太阳从哪边升起，那他这个按世界知识他肯定告诉你从东边升起。但是你跟他说太阳其实从西边升起的。好，根据以上内容回答以下问题，太阳从哪边升起？正常的或者说有这种income taxing能力的这样模型，他就应该回答你太阳从西边升起。

这个就是基于上下文，然后上面这是最重要的一部分，就是最近最重要的部分叫推理能力，reasoning能力。Reasoning有很多了。你说一个人他推理能力很强，或者他叫逻辑王，那他逻辑王对应的是什么王呢？它比如它的符号推理，它的数学推理、它的逻辑推理、它的常识推理，这些方面能力很强，那我们就认为这是一个逻辑王，那对于模型，对于AI来说也是类似的。所以就对应到先不说右边这个增强的，我们说这个对应到OKI去年在它怎么定义AI的级别的，或者叫AGI的级别的这样的一个图就可以看出来。他认为一级的就是chat out，就是能聊能有对话能力的。基本上现在我们市面上所有主流的大模型都能达到这个级别的。我估计90%多百分之八九十这样一个状态。

Level 2叫这个reasoner，叫推理者。他就是说能达到人类级别的问题，解决的这样的一个能力，这个级别其实推理模型包括今天我们讲的这个r one或者OPI的这个OE，这类模型其实都是算是这个级别的能力提升，就是这个模型在这方面的能力特别强。所以我们就说它能达到RY或者说RY的某一个等级的水平的能力这样的一个级别。然后R三大家看看level 3其实就是agent，它定义就是可以行动的系统，所以结合正好结合昨天奥特曼发布了他这个chat BT4.55，GPT5的这样的一个计划，里面还可以看到它有一些蛛丝马迹，就是什么叫统一的模型，且以一个什么样的形态，可能是个机器人的形态来去输出，或者以一个什么机器的形态来系统的形态来去输出。就是我们后面要去level 3，他open I认为的就是应该是一个可以行动的系统了。那它背后的模型或者它背后的这样的一套逻辑就不一定是那么突出，就一定是也是某个OE模型或者什么GPT模型不那么重要了，是一个agent这些小东西。

四和5我们就再说了什么创新者，组织者以后，然后最后看一下这个其实就是所谓的增强的能力。我们刚才说了模型涌现，对我说说一嘴为什么叫涌现？就是我们这一代的大模型，其实都是大家肯定听说过叫transformer这套模型的出现。

但是这套模型最开始是干啥用的？希望干啥用呢？主要的用途其实是做翻译，就是拿它来去做各种语言之间的翻译。结果翻译这个模型越做越大，数据越问越多，参数越来越大。然后趁的越来越久，他发现他有了这样的一些别的能力。这些能力其实并不是所谓的我们叫by design，就是预先设计好，让他能有这方面的能力的这种能力所以我们叫他emerging，就是他涌现出来的他他他的不知道为什么他就出来这种能力。

那再往后可能是什么呢？他就是增强的或者以后的自我能学习，能用工具，能跟人很好的沟通，交流互动这方面的能力。所以我们说这一代的AI其实是这种AGI。

所以与之对应的的就是什么呢？比如可能我们说的人脸识别，我们能识别个几百万、几千万、几亿个人脸，或者是做这个语音识别这类的能多准。那我们就不把它定义成叫AGI这个时代的，或者我现在认为的大模型时代的模型。

这个引入到第二个说什么叫模型，或者说我们说大模型是啥？刚才也说了，基本上我们说的AI它从机器学习到深度学习到大语言模型，其实是这样的一个过程。我们最近听的这个大语言模型出的太多了，最近又出来像RE这种推理模型。

那是啥叫推理模型呢？其实就看左边左下角这个意思就行了。就是比如说我们要正常的问他，一个火车以60迈的速度跑3个小时大概能跑多远？正常的单元模型，它直接给你出来一个180 miles，然后一个推理模型。

我们认为一个应该具有推理能力的模型，它会生成右边这样就是他自己去生成他的思考过程。比如说他说决定到底跑了多远，应该用以下公式。这个公式是距离等于速度乘以时间。我们认为现在我们知道已知60迈的这个速度，然后跑了3个小时，那我们距离就应该是60乘以三等于180，所以最后结论是180。大家看这个就特别像小学数学或者从小到大学到的这样一个计算的过程。这个就是最直观的这样的一个人reason推理模型的样子。

但你说它背后跟大元模型有多大差别呢？它底层结构至少目前看来大元模型跟推理模型的结构基本上都是一样。待会儿讲这个DS的这个r one的时候也大家会提到。那你说未来会不会推理模型又是一个新的结构呢？

没准现在大模型的发展非常快，那么下一个过程的下一个概念就是大模型训练和推理。大家要知道说这个大模型是咋训练出来的，以及是咋用的。这个我就简单说一下，其实就这么几步骤。这是借了这个叫zome的这哥们儿的这样一张图，这是华为的一个小孩，那个内容非常他做的内容非常好，也是推荐大家去看。如果大家想学的比较底层的这个内容的话，可以看他的这个课程和他都是开源的，他在B站上面都有内容。那去一个大模型基本上是这样几个步骤。因为它是华为的，所以他开始说要准备算力，说白了就是我要去建AI的这个GPU的集群，那里面包括了计算、存储、网络，然后各种运维的工作。

然后第二步就是我要准备数据，准备算法。这个数据其实就是一个特别几乎现在大模型领域，数据就是一个特别核心的壁垒竞争壁垒。因为大各家大模型其实厂商你看各种的技术报告什么的，在数据方面或者数据的处理，数据的预处理或者后处理这方面的事儿，说的是相对来说是更少越少的是很少的，大家都会愿意去share自己的分享自己的这个算法多牛逼，然后自己的训练的这个方法多牛逼这些东西。而反而数据这种听起来很朴实无华的部分，是很多模型厂商的最核心的壁垒所在。我们有了数据，有了算法，算法其实就是最基本的。我们说穿summer，然后现在像去年曼巴什么的，这些新的同时替代这个穿梭的这种模型的结构也出来了，而且这个可能势头还挺猛的。然后有了准备好这部分，其实大家想象就是说我准备好了食材，准备好了这个食谱，然后锅就是这个AI集群，我要开始炒菜了，就开始训练模型了。

模型训练就是到第四步这部分了，那就涉及到什么各种类型的特别多的技术分布式训练。为什么有分布训练？这个也跟后面为什么我们说这个NVDA这波受影响很大的一个原因就是后面DDS那块我就简单说一下。

就是如果我们发现这个NVD，它其实很核心的一个能力是两个东西，一个是它的大规模集群构建能力。说白了就是比如说咱们现在家里用的一张4090，一张3090这样的卡。它能有多大算力呢？其实很有限。虽然我们觉得这个已经非常算算力很大了，这个跑步游戏都都嗡嗡叫的。但是对于一个模型训练来说，这种训练的量 and 这个算力量还是非常远远不足的。那我们就需要去把很多张这种卡给存起来，让他们能协同起来去训练一个更大的模型。

终极的形态就是假设说我们现在有一个什么样的东西，我们用来训模型最好呢？其实并不是一个说我一定要弄个分布式的，1万张100万张，50万张卡。而是我希望有一张巨大的一张卡，一张GPU，比如他有个几十T的内存，或者是更大的这样一个内存，然后他算力非常强，他的晶圆可能半径1米，半径2米这样一个巨大的一个GPU。那么中期形态肯定希望这样的东西。但是这种东西其实在可见的工艺，可见的时间内是做不出来的

那我们就要说我把一堆没那么大的这种GPU给攒起来。攒起来不光是大家把它拿出来能互相能连上能能一起去。他其实在上面有非常多的这种分布式的要去调优的地方，包括说这个卡之间怎么通信，就是我算了个东西，我可能因为这个我互相是关联的，所以我这张卡算完一个东西，我要交给另一张卡，然后再交给后一张卡。或者说我怎么把我算出来的东西广播给缩短卡，这些其实都是很关键的。

这样的一个分布式并行计算，或者说模型训练里面的分布并行计算这个部分很关键的一个技术，包括后面的推理其实也涉及到这部分。这部分就是DS这次做的非常多的一个很多期工程的优化，对小很tRicky的一些技巧所在的地方。他也带来了一个结果，就是为什么NVDA被被打的很厉害呢？

就是硅谷资本市场发现你DS一家中国的创初创公司，可以通过它的这样的一些奇技淫巧也好，基金我绝对是褒义的，就是一个小技巧也好。我能把原来可能跑1万张卡才能跑出来这个效果，我只需要跑个两三千张卡就可以跑出来了。好，那你明年大各大厂商NV的卡的这个预算，你是不是报虚高了？你这帮做算法的，他这个团队是不是应该更努力一些，把现有的卡的效率用高了，然后用高了以后，我可能就不需要买那个NVNVNN卡了。那整个NNV的的估值的逻辑就有点松动，没有说崩溃。大家千万别信什么NV的会崩溃什么这些东西，只是有一点点冲动而已。

对，然后那训练完了以后，肯定需要微调。因为现在的大模型基本上都需要两部分。一个是所谓叫预训练这个预训练就是拿巨大量的数据。比如说几十T的、十几T的、二十多T的这样一个纯文本数据来去训一个几百个B几百个billion，就是几千亿参数的这样的一个模型。这个量其实非常大的那可能要跑个几个月，甚至到这个一两个季度这样的维度。那训练出来以后，这就要预训练完了。

那下一步其实就是所谓的我把预训练完的模型再去做微调，目的就是为了让这个模型它可能更会说话。因为你预训练出来的模型可能他就是一个特聪明的一个，他啥都知道，他也有些能力，但是他不大会说话，不太会像就跟老板似的跟老板说话那样的一个有条有理。然后汇报这样的一个策划，那我们就把它微调一下，他不大会推理，那我们就再把它另外一种方式微调一下。所以就是训练完了就要做微调微调。现在呈现的这次DS的很多的创新，也都在这儿做了这种强化学习的微调。在这部分都在都算是在这个领域。

好，我们到这儿基本上就模型就算串出来了，或者说在某些场景我们就串出来一些特定场景的模型了。那下一步干嘛呢？就要去做验证，要去做部署，验证其实就是一大堆这种评测集，然后我们测它这个模型到底他的各方面能力是不是够强，够厉害，满足业务需求。然后这个OK了过了比如说80分以上了，那90分以上了，然后我们就可以扔出来了。

扔出来以后大家就要用那就涉及到推理的部署这部分，就是我们串出来一个这样一个模型。这个模型要部署在很多张GPU卡上才能输出文字，才能像大家用这个信息，用ChatGPT这样去聊天。部署其实也是非常需要技术和工程能力的这样一个部分。所以大家说像DP放上线了以后，整天绷对吧？大家一天能问的问题，可能问十次只能回你两次，正常的回复两次。就是他的推理的部分，其实它的这个工程能力没有达到一个很强的水平。

为什么chat BG能搞呢？因为他爸爸是O是微软对吧？是是他基本上世界最强的几家云服务厂商，他在推理方面、部署方面有非常强的能力，可以帮他干这个事儿。而district其实就没有，大家就然后在那涉及到一些小作文什么什么，国内的很多家厂商来去全力支持这个，浴血奋战的帮着desk去去去部署什么的这些这些都挺挺扯淡的。对。

然后这个部署完了以后，我们除了说给人类用，就是给普通的用户来去用这个at以外。我们其实非常多的弊端的业务其实要去做类似agent或者做业务编排，做这种很强的to b的应用的那这部分就会涉及到说这个推理跟agent的编排，agent的这种构建怎么去结合，那就到这儿有很多工作这部分。所以整个过程其实是一个特别好几步节奏和阶段的一个事儿。大家去听，甭管是哪家模型厂商提出来的一些新的突破，大家如果有这样一个

地图的这样一个感觉的话，就能知道说这家厂商在吹的到底是哪一个环节的哪一个部分的技术，大家不要去就不至于说这家厂商是不是灭天灭地。

现在大模型领域是一个特别大的一个整个产业的一个过程。所以听到一个东西，希望大家以后能知道说它到底指的是哪方面的创新。这个技术站其实就简单看一眼，为什么呢？要看就是看这个东西就是整个大模型应用的开发是一个从顶层到算从算法到工程开发，到分布式框架，到AI推理，到这个编译。编译其实就是怎么跟底层的这些计算节点打交道的这个部分这部分其实就是大家常听到的哭的，或者这个华为叫什么。A time这样的一层都在这儿做了非常多的事儿。大家说这次DS把这个codd给舍去了，这其实也是假的。他用的扩大的更底层一点的语言，只是用来说我不用哭打这种更高层语言，而是用它的更底层叫PTX来去直接操作GPU这样一个部分来完成的。

好，我们知道这个大模型怎么训练的，是什么东西？这儿我觉得有一个点可以注意，就是我们看了这么多模型，我们这儿建了这么多模型，到底谁强？在各家模型都会吹他的这个榜单。

至少目前咱公认的还是这个叫一般叫chat about rena这样的一个网站，它里面的公布的这样的一个榜单是大家最公认的。可以看到直接叫LM arena，点NI这个网站，点这个the leadership就能看到。然后可以看到，从前这个榜是总榜，这有一个叫category，就是总榜。总榜里面第一现在其实是Jimmy这样当然也不叫低压并列低压这个germany chat BT4O就是deep sit，然后又是jam的，然后又是open I的OEDE，然后千问的2.5 max deep sit，然后这个open I的这个GRM4是质谱的最新的模型4 plus，然后step 2是接乐，接上海那家大模型厂商。所以其实可以看到这个里面就大家真实的比较认的还都是这个领域里面的，就这个榜单里面的一个模型的排名。因为它是纯盲测，然后靠人类来去打分这样来去得到的。可以看到其实前排名前面的，国内的有其实有好几家了，就包括质朴千问，然后disc都在里面，所以说明其实我们并没有说这个被辣的很厉害这样的一个状态。

然后另外一个就我插个话题，就这儿我觉得其实如果有程序员的这个同同同同学同学值得去看一下这个东西。他把rena开了，另一个rena叫web death arena。这玩意儿是啥呢？你把它打开就可以看到了这么一个网页，我可以帮你你构建什么呢？今天你直接让他建一个email APP，然后他就会像他就会直接去问两个模型，让两个模型来去帮你构建一个像gmail一样的一个邮箱服务。好，那这两边到底是谁，他不会告诉你了，这个就是你现在不知道了。你要让它在生成完了以后，你去选到底左边更牛还是右边更牛，然后这样一个过程，然后你看构建应用，其实构建一个web的web应用，现在其实非常火，就是已经能有不少这种小应用，都可以靠大模型直接生成了。所以在这个拆包arena，大家最公认这个arena又增加了一个web deb rena。

如果大家去这个有工程开发的同学的话，大家可以盯一盯绑这个榜就代表了很有可能代表了你下一步去怎么去写代码，怎么去做工程的一个选择的这样一个模型的依据。对，所以第一个是去哪儿看啊？然后这块我留一个小问题，就是在这就是这个问题，就是用哪些奔驰来去看那模型的排名。大家可以看到，刚才我说这是overall，是这个总榜，你把这个榜打开，你能看到有很多别的有戏绑。这个详细的分类，我留个作业，其实就是到底看哪一个绑才能看到这个推理模型它的排行。

对，刚才说这个排行了这个部分，然后我觉得大家经常会看到这些benchmark的。包括比如说我们看到deep sick的这个官网，然后你会看到这个网页贼简单，贼直接，就是介绍他直接给你绑，直接给你一个各家模型的榜，他对标的这些模型的绑。左边这一大堆这个第一列，第二列，这一列其实就是各种模型，各种的单串，各种分叉。然后这个部分的bench 2其实就对应到说模型的这个评测。我们怎么看这种东西到底是啥？就是它这些的二到底是怎么办出来，或者说他到底背后去测模型的啥能力，我觉得还是希望大家能看到。所以这一页可以看一下，就是我们说MMLU就对应到这个里面的这个东西，这个EM应该是这叫exact match，就是准确匹配，这个精准匹配这样的一个意思。



这里面他问啥呢？大家如果打开这个奔驰MMLU的这个奔驰2，你就可以看到他问这种问题，谁是美国的第一任总统？然后以下哪些是史料？这些问题是MMLU。所以可见其实MMOU是更多的是去评测一个模型它本身的真实度，就是它的基础知识或者它的这个世界知识这方面能力。

对应到又回到前面这张图，评的是basic的这个基础能力里面的知识的部分，更多的是评测这部分不是说全是，但是是这样。然后还有一些评测的单据，比如像这个BBH，这个大家可以看挺有意思。比如说Alice比bob大，bob比查理年轻，那谁最老？然后所有的猫都是哺乳动物，那有些哺乳动物是宠物，那有没有可能有一些猫是宠物呢？对吧？就是很这项推理啥呢？就是常识推理或者像这个逻辑推理这部分的能力，我觉得这个奔放我是特别喜欢的一个。这感觉其实是以前这些评测，就是小学生或者中学生在这方面能力逻辑能力的这类题。

然后max就简直特别明确，就是做计算，比如二元一次方程组，矩阵乘法这样的一些东西。随着推理模型，就像dept r一出来以后，大概就是在R一推理模型之前，就是OE模型出来之前，大家评测都是这一类。当然不可能这么简单，有很多问题不是这么简单，但是也大可以感受一下。而EOE模型推理模型出来之后，整个推理的我们叫benchmark。这个推理模型benchmark画风就变了，大家可以看这种，这就叫AIME。

大家可以基本理解成是这个高中数学竞赛这一类的题。美国的高中数学竞赛题你可以看到都是这种题。就是什么每天他跑9公里什么这些东西，然后让他去做一个比较复杂的推理计算，还有这种底下叫call false，如果大家是写代码的同学就能感觉到，这就特像这种比较基础的立扣的，或者像这种ACM的这种比较简单这种题，三兄弟经典的问题。

然后带来了另一个更复杂的本事，就是GPQA，这就就反正我就看不懂，什么什么两个量子态，什么1112生命周期都是多少，然后求他们的什么什么能量差，还是什么东西。对，反正我看不懂了。基本上这种NH2就是那种号称是这个PDAPHD能达到60分儿，但是OE这种推理模型能答个70分的这样这类的题。所以这类问题是加这个基本上是我们现在看到的主流的大语言模型推理模型的主要的这种奔驰二它的内容。

所以我就是说希望大家能看到说，不光是看到说什么什么叫MMLU，什么叫GPQA，那还能判断说到底他的问题是啥？有啥。这个为什么要看这个东西呢？就是我们一方面是我们能学的更深一点，我们知道说模型到底是未来是往哪方面能力，或者他到当前到了什么能力了。另一方面我觉得也其实也是给大家个人一个主观的感受，就是现在我们测模型什么方面能力。

好，那我到了看这种题是什么样方面的水平了，那我应该怎么办呢？我应该绕着走。我说我我这个GPQA我能考100分，我牛逼。然后你模型你什么时候能赶到这个90分，那再说。

对，这样的一个是给大家一个体感的这个目标，我们说现在有这种模型，但是其实行业或者大家如果是各种的，比如金融行业，什么建筑行业什么的。你觉得拿这么一个模型，比如说他非常知道美国第一任总统或者第75任总统是谁，这样一个模型对你的业务有用吗？其实没啥用，对吧？就是我不可能相信一个一个比如来了新招的一个小孩，这小孩儿他对于美国的历史如数家珍，然后他来写代码，那我肯定不相信他写代码，或者说我不能作为证据，他写代码很强的证据。所以行业里面有一大堆奔驰。当然我觉得大家如果是各个行业内的想去采用大模型的，也要注意这件事儿。就是你这个行业，我或者我们叫工业界的industry行业领域里面的奔驰到底有没有比较好的问？

如果比如像这个其实就是一个金融行业的一个叫patronise petroleos AI他提了一个叫finance bench这么一个bencher。比如说这个我们看看一下，比如3M是不是在2023年Q2有1个省所里的健康的什么现金流profile，然后他的回答第二列是回答是no，为什么no呢？它有一个quicker，这个是0.96，这个no然后不光是看这个，因为金融行业它还很核心要讲究。你这个回答到底证据对不对？所以还有一列叫evidence，你会看到他的证据，你得把证据也得答对了。我才这个奔驰上才认为你这个模型是对的，或者说你这套系统是OK的。



所以大家如果有在行业内应用这个大模型的想法的这样一些同学的话，我觉得这是一个很好的机会。就是你一定要把你的行业内怎么去评估一个高级人才的这样一个标准给抽出来，抽成一个奔驰2。而且这个奔驰马最好是当前你跑了一波大模型，发现大部分大模型都只能跑到，或者最顶尖的大模型只能跑到。比如说二三十分、一二十分这种水平。

那证明了啥呢？证明一是证明这个行业确实AI替代的，这个可能性还低一些。二是说你做出这个bencher，可能就是成为以后去想去做这个领域的这些模型厂商的必备的分叉，对这样的一个东西，所以这是一个提点，对OK这就是刚才那个问题。那怎么去看好下面一个session前面就是基本上概念花的有点时间有点长。这个其实也是想希望大家能够我们对齐一些对于现在一些概念的观念。

然后第二部分我就不说这些了，其实这张图想让大家先看一下，这个是anthropic，这个就是做cloud的一家公司最近刚出的一个报告。为什么要说这个？待会儿最后会提到一点，这张图很有意思，就是他把美国的各类的工人，各类的员工的比例，这是这个灰色的部分。然后用一种他用了一种很强的一种去敏感，去去个人信息的这样一个技术。把大量的用户跟cloud对话的部分被映射到了到底这个人在在在做什么样的工作。说白了就是美国的平均的不同这个工种的人和用好的人到底是什么样的工种，这样的对应关系。他也做了一张图。

所以可以看到大部分工作工种里面，比如说有啊百分之9.1%的人都从事的是运输运输行业。但是这个领域里面问运输行业问题的人只有0.3%就在cloud里面的一个问题里面只占0.3%。那说明啥呢？说明用cloud的人大概率不是什么运输行业的人。所以你看大部分行业其实实际的这个叫什么红色的或者浅红，这个红色的比例都比深色的比例会低很多。唯有这个行业computer and mathematics，mathematical就是计算机领域或者数学领域的人，最巨大量的实际从事这行业的只有3.4%的人口。但是把3分之1的问题全是问这类，或者coding，写代码都可以放在这一类里面。

然后有一些art，这个live physical，什么这个社科类的，不是物理什么这个社科类的会用到的用的比较多，这个也就代表了是你不同的AI产品，它所面对的用户是不一样。可以想象我们国内的这个我说大家日常平时用的这一类几类的几个的这种AI的产品，肯定在分布上也是差异挺大的。当然这次的给大家带来一个非常大的镇，这个叫什么强心针。就是很多原来根本不用，不知道原来的这些人也开始用起来，也会对这样的一个比例有一个很大的影响。

好，我们下面就到这个despite时刻这部分，然后再换方。其实大家肯定知道这家公司是一个巨赚钱的一个量化公司，量化投资的公司。那deep thick的中文名叫深度求索。其实是在二三年5月份，这个换方漫画他把他的这个AI的一个团队给单独成立出来的这么一家district，深度求索的公司，这家公司的全名叫杭州深度求索人工智能基础技术研究有限公司。可以看到它其实对于这个从名就可以看出来，这是一家对于他的目标非常的深的深深深远的这样的一个公司的计划。

他其实我们现在看到的这波很火的R1，你得追溯到至少追溯到V3。V3是去年12月底发布的这个第三代模型。然后今年1月，就是前几天20号才发的RR1。然后这个东西发出来以后，过两天这个东西就炸的比较厉害了。逐渐的尤其是海外，尤其是美国炸的越来越厉害。包括这个alex王，就是ski OI的老板，他评论了说deep take其实没有不止那么点卡，然后非常多卡。说白了就是他说这个他意思就是你dept其实他发出来的东西有点骗人的意思，然后大家不要被他忽悠了，他其实非常多卡，他说他有5万张卡，然后后面这个semi，analysis的跟那家，一家非常有名的一家网站。

他公布的也差不多，就他认为有大概1万张110万张，1万张H800然后因为换方非常早就开始买很多的这种A100的卡，所以一万张一百倒是很有可能。但是一万张所谓的H100可能性很小。H800还有可能，因为当时还没有禁运，然后还有很多的这种更低算力的，这个大概3万张那种很低算力的这种卡，所以是这样一个然后

后我们就开始发酵了，包括说特朗普也开始说，然后整个deep thick就在美版给炸了，基本上现在大家去看还是排名很高的这样一个。然后我觉得这个DC肯定其实大概率没想到火成这个样子。所以他整个的用户涌入，包括也带来了一些肯定会有一些人，有一些团队去攻击他，所以就带来了大规模的攻击，然后他的服务也中断了一段时间，然后整个的吵得非常沸沸扬扬。所以，对对对，然后后面28号其实大家都知道整个大跳水，整个估值的尤其是资本端，他们对于这个NVDA这一类的算力资质算力的估值的逻辑可能有了一些动摇。所以吓一下干下去，两万一刀好像是差不多，反而这样的一些消息，前面这几个消息反而是换回国内，然后国内就开始疯了，一大堆人开始说扬我国威，国运一大堆。当然也不一定是这个换回来以后，之前也有很多这个消息。

所以这次我不说这些，其他的我就问一个问题，就是如果大家像这个换方要巨有钱，那大家会想做啥呢？为什么说非常有钱，然后想干啥？就是换方。如果按照3 analysis这家公司的这个网站的评估的话，他有5万张卡差不多至少有大几亿的投资都投在算力方面。那这家公司如果有大家如果有这样一个钱的话，会去想去做一个深度求索这样的一家公司吗？这个真不一定。

然后就是刚才各种的关键世界上大家看到的什么，梁峰发了一个小感人的小作文，然后黄仁勋说的如何评价deep sick，什么AI沙皇5绝杀，这些全是假的，全都是AI小作文出来的。所以大家可以看到，包括从上一次美国选举，然后到这一次的这种第四事件，AI小作文越来越深入到事件中了。包括大家现在搜这些小作文，你都能看到还有很多内容还存在。当然主流的一些什么新浪这样一些知乎这些网站已经把这小头都给下架了。但是很多电影像包括抖音什么地方，大家还能看到这些非常明目张胆的拿这些假的内容来去做营销的这样一些内容一直存在。可以想象下一次这样一个甬管是叉叉叉时刻，这类东西可能只会更真实，甚至是直接上让这个数字人直接给你演演小电影了，直接给你拍出来了。

所以这件事情我觉得对于不同的人其实是不一样的。比如对于普通用户来说，我可以理解他是一个基础民主化的一个狂欢。有点像当年说数字货币，然后大家说什么基础模型推理模型不说，其实大家对于这一代非常好的一个或者正面的一个影响，就是大家所有全民对于AI是一个巨好的一个几乎是可以说是免费的市场教育。然后对于这个技术行业，杨乐坤说这个事儿一个开源的闭源的一个胜利，当然他把他拔的很高。那我觉得其实是一个社区的胜利。就开社区的一个胜利就是大家做的非常多工作，通过开放的方式，甬管是开源还是技术报告这种方式分享出去，能激发别的人社区了别的人更多的这种创新。我觉得这个是一个对于闭源，对于这个open I 这样的这样一个一年或者一年多的这样的这样一个越来越封闭的这样的这样一个行为的反叛，或者说一个打脸。

那当然反过头来说，我觉得也是一个提醒，就是这句话就是程序员才看是不是开源，用户只看好不好用。所以大家可以看到很多人说你你你这个模型deep sit开源了，然后杀了这个对于用户来说是非常好，不重要，用户就看你聪不聪明，或者这个模型这个APP好不好用。然后对于资本来说，我觉得就这句话，就是所谓的杰维斯被杰维斯悖论。

就是说当时什么发明了一种新的技术，这个技术对于传统的资源的利用效率更高了以后，那我们是不是对于这种资源的使用的需求反而变少了。那结论是不，那肯定是就放到咱们这儿也是。但凡我能够靠一个低一个数量级的成本训出一个模型，那我以后用GPU量只会更多。因为你像这个用户量，这个deep sig带来的用户量都不是一个数量级的提升了。我觉得可能至少一个数量级以上的这样一个提升。那总共对于以后算力的需求，我们不说信创，至少说对于GPU的需求肯定是一个更大量的一个增高增多这样的这样一个结果。

对于政策来说其实就是挺可怕的。是我就跟我最开始说的斯普尼克时刻一样。斯普尼克时刻就是苏联发了卫星以后，美国就是我的对手怎么能比我技术先进了呢？那我们的美国的这帮政策就开始提这个词儿了。可能很可能或者说大概率的就是会对现在已经还可以允许销售的这些GPU，对中国销售的GPU可能会有更严的这样一个约束。比如像H20这种可能也都会接受。

下面其实就是给大家简单的过一下这个技术的这样一些解析，我不知道大家有多少人感兴趣，但是我就比较快速过一下，DPC的这绝对不是一个，而是刚才说的RE模型就是一个他这次爆发出来的这样一个时间点，并不是

说这家公司就干了半天，然后就干出一个R1，然后就炸了，而且而是实际上他之前干了非常多的事儿。你可以看他之前就从这个二三年发就发了很多这种模型，然后一直到去年的V3IR1这个事儿才算是比较破圈。当然以前比如说之前的V2.5、V2的时候，其实大家就已经引起技术行圈内的这样一些影响。但是R3V3R1出现以后才是真的破圈。所以模型做的多，祸事儿做的多还是很重要的，并不是能以什么整个大的这样的一个事儿。

前面其实介绍了这个dict sick，我就不说这个技术信息了。然后几个关键的这样一个洞察。第一个就是我们说V3跟R3，其实R一其实应该是一个我们说R一并不是一个单纯的一个新的模型。它其实是基于跟V三的这个结构很相似的这样一个基本上一致的这样一个模型。只是但是通过算法，通过这种训练的技术，来去让V三本身这个模型在某些方面，有些推理方面能力有一个巨大提升。所以R一是基于V3出来的东西。

那这个过程中，你说他说的发了这次R一其实并不只是发了RE，而是发了三个模型。我们可以说是三个模型，一个是RE zero没有发出来，另一个是RE或者叫DQ。但是DCU刚才说这个蒸馏，大家肯定最近也听说过很多。但是这个蒸馏的模型一定要注意，这个蒸馏的模型它的主语是被蒸馏的这个模型比如说千问，它其实主语是千问，并不是dept r一蒸馏R1。所以我说的这些蒸馏的模型可以叫dip sit产出的这个技术报告产出结果。当然其实本质上还是它原来那个被蒸馏的那个模型本本型。对所以我们可以说这个V3R1 zero r一是这次模型的一个主题或者主角。

刚才也说了模型基础、模型深度、模型，推理模型到底是啥，这就不说了。我们现在主流的这样一些模型基本就分成这两大类。这个DB4是它的基础模型，然后它对应的推理模型可能就是O1或者O3。当然我不知道是对应关系是啥，比如说质谱的这个GM4，GM4 plus对应的它的推理模型就是我们叫GM zero DK的V3对应的推理模型就是R1。然后google的gym l然后千万这面其实缺失的就是靠它，其实还没有推出它的推理模型，但是kimi也有它的这个K1.5对应的基础模型，但是我们才知道到底是啥。

那里面还有一个另外一个很很很提了很多的词儿，就是所谓的MOE。这个大家的理解就是可以理解成我一个大模型，我一个模型每次的计算的时候，我动用的是不是所有我的参数。假设一个比如说比如671B，这个模型671B其实就是6710亿个模型，1亿个参数。那我如果这是一个所谓的叫投币模型，就是跟MOE对应的这样一个模型成品模型。那我每次计算就是这些参数都得过一遍，那可以想象这个计算量是非常大。

MOE模型说白了就是我虽然整个模型大，但是我整个模型其实里面分成了非常多的小部分小块儿我每次推理的时候，我每次计算的时候，我只动用其中一小部分。这个deep sick的这个模型其实就是37B每一个一般的我们叫专家，就是每个小块只有37B个参数。比起比如671个B的这个参数那就小得多了。所以对对应到的整个推理的成本也就低得多了。所以这就是MOE模型，就是所谓的混合多专家的这样一个混合专家的模型来去做。所以现在的这个主流的MOE模型，除了deep t还有千万的nars然后mr就是法国那家大模型公司，它也是最早的以MOE模型为起家的。但是现在基本上已经被这个别的家伙给甩的不知道甩哪里去了，尤其是被district的甩的很厉害。

另外一个值得提一点就是这个difficult模型的license，就是大家知道模型本身它是一大堆参数和它本身这个模型的一个结构。这个东西其实是有它的版权的那像这个我说拉玛或者像这个，反正就各种开源模型，其实都会有它自己的开源的license。Dip thick非常牛的一点就是他用了MIT license。

MIT license一个特别大的特点就是你可以用它来去商用。说白了这就是为什么大家看到市面上一大堆说教你部署deep seek，对本地部署或者教你怎么去部署一个desert。你从理论上来说，用人家这个模型来去牟利，或者说你部署完了一个东西，一个deep sick模型来去赚钱。OK的，你都甚至不需要去去提到或者开源，或者把你的这各种东西给开放出来，MIT模型LIT license就是这么一个非常开放的一个东西。甚至你把它模型拿来去做一些衍生的训练，做一些优化，你都不需要去把你这个衍生的部分，你的工作给开放出来。当然最主流的其实就是MIT或者阿帕奇的这个license，其实都不不叫最主流，其实最主流的其实就是阿帕奇license。大家可以看到这个有一个这个东西。

大家如果想对于模型领域的法规比较感兴趣的话，可以看这个guitar。这里面列了基本上很多主流模型，它对应的这个license你可以看到这些。但是他我看了一下没有V3，还没有上录进去。他把之前的district收录进去了，他会很详细的分析每一个说明每一个模型的license。你看有些是标准，有些是这种所谓的定制化的，就是你说他有一些定有一些基于某的license但是他做了一些修改一些限制，这些其实都是后面去做这种不同模型，你去商业化可能性的这样一些点。

当然有一大堆别的模型lesson就不说了，然后技术报告这个就简单看一下。其实我是推荐大家，如果即使不是这个行业内的，或者不是做技术的，也可以看一下这个模型报告的这个开头的APP check，大家把它翻译一下就行了。这个不需要去一定的看英文，直接看到就报告的APP。大概你看这个东西就比你可能看看三四篇这个叫什么这个营销号好的多了。然后他在这个APP shock完了以后，就列出了他的在这个模型的bench park和能力方面的这样一个比分。

大家会经常看到各家模型的本场都会以这样一张图来呈现，可以看到它每一坨每一个group都是一个刚才看到记得就这个MNH2，比如MMLU的pro GPQA，这醋里面的每一个颜色就代表了一个模型。比如DPCV3V2点5000万，这个DB4O这样的一些模型，可以看到基本上它在每一个奔驰上都有一定程度提高，而且是不小的程度。比如像这种我们就直接对标这个BP4O，就这一条线，你可以看到很多，基本上每一个奔驰2都比他高个几分甚至十几分，甚至像这个，当然对标四欧在推理上是不太合理的。你说AME去对标一个4O应该对标O1。来去做这方面的对比，都有一个很大的提升。

所以这个是一般大家如果看模型的这个paper的话，一个点就是直接看这个东西是可以有一个整体的感受了，这个就是DPC官网的这样的一个能力。大家也是刚才一点，就是大家看这些东西。到底哪些是考验你模型的推理能力呢？还是刚才那道题大家去自己琢磨一下。然后这个就是说模型到底这个DPC模型到底是一个对于就看了一大堆说部署教你怎么部署这些模型这样的一些文章以后，到底对于企业来说是好事还是坏事呢？或者在工程上是更容易还是更难的。其实总体来说，我觉得是更麻烦的一点情况。

比如你看一个R1，它在它参数667B，然后他需要的一个GPU的总的v rum的数是大概一点，就是1300G这样一个量级。这可以给大家提一下为什么这咋算的？就是你一个模型，其实大家刚才这个叫我就说了，这一个模型其实就是一个模型结构加一个巨大参数。那一个参数671B其实就是这么多个参数。

那怎么算它可能会需要占多少RAM呢？那核心就是我一个参数有多大，对吧？就是我这是671B0的参数。好，那假设我一个参数就是一个back，就大家整天说的什么一照1G11T什么的，其实都是一兆but 1t but假设我这是每参数只有一个but就是一个battle，就是八个bit，八位，88对8位这么多，那其实就是一个671BG这样的一个量级，就是六百多GGB，这个需要这么多G，这么多RAM。但是这个八位其实是不足以比较好的描述一个值的。

所以一般来说一个就是大语言模型里面的每一个参数其实是一个浮点数。那正常的一个浮点数，大家如果确切记得知道它是一个32位的。刚才说一个半它是八位，正常的浮点数是32位。那你可想象乘以四把这个值乘以4才能部署一个32位。那正常一般来说我们部署一个16位的这个16位精度的浮点数的模型就OK了。那基本就是把它乘以2，就是一千差不多1300G这样的一个大小。所以1300G要多少机器呢？

需要一个16台的A880G的AA100对80G的A100。那16 16块，基本就是两台机器。一般来说我们说一台机器就是八张卡那就是两台A版。大家如果知道这个A110台机器多少钱，对吧？就是一台差不多一块卡差不多十几万，然后那一台八卡就一百多万，然后两台就是两三百多万这么一个预算才能跑。

一个模型的一个实例，RE的一个实例。所以其实是这个成本是真的不低的，而且挺可怕的。因为当然这取决于说这个deep seek r—是一个MOE的一个模型。

刚才说了它虽然推理的时候用的参数不多，但是你总所有的参数都得搂在内存里才能好推理，所以这是一个原因。所以这也为什么我后面有一大堆蒸馏的模型，什么前面拉玛这些牵蒸馏的前这个模型，很在在上传播的非常广。就是因为这些玩意儿基本上跑个306040803080都OK，那就只能跑起来了。所以这些模型还是能推理的，但是绝对要有预期。就是你想这个东西一个670B671B跟一个7B这么一个参数的量级就差了俩数量级了。那它背后的能力肯定也差的很多，差的不少。所以大家用这个蒸馏的模型的时候，不要对它的推理能力有什么太高的预期了，右边这就是另外一种方式来去算是对然后这就是刚刚说的V3的一些特征，就是它的总参数非常大。

但是因为它ME模型，所以每次推理的时候，我的token其实激活的并不多，可能只有20 20分之1的参数参与了这样的一个推理或者训练的过程。所以这个推理的过程，所以他的还是挺挺好挺好玩的这样一个挺有意思的这样一个结构。然后他训练的数据，就是114点几T的这样一个数据，其实就挺常规的。

然后所谓的无辅助的负载均衡，这块提一嘴，为什么叫这个负载均衡？就是刚才说了，我假设我一个671B的这样一个参数那么多，然后有一大堆专家或者一大堆块。这些块儿我训练的时候，我不可能每次我都激活671B的这个参数去训练，我只激活其中几块去训练。那我训练的时候很有可能我如果就逮着这么几个专家训练，那其他的我记得好像有个22五六个专家。那我就逮着其中的，比如说这个六个专家去训练，那我其他250个专家就傻子了，就完全是傻子不懂，所以他要做负载均衡。

传统的负载均衡在这块做多专家的负载均衡其实是一个挺复杂的一个工厂。他们用了个特别简单粗暴的方式来做这个负载均衡，结果效果还挺好。然后多次元预测后面这两个，其实这两个技术都是为了提高训练效率，然后双pipeline的这个算法，多头注意力，其实这个FP8的一个精度其实都是为了提高训练效率用的对。然后他所谓的所谓一训练一次用了550万，这五个million的美元，其实就是只是算力成本，而且它是按照租赁这个H800GPU小时来计算的一个成本，差不多五百多万刀。当然这个钱也不少了，你说咱有谁能花五百多万刀称一次呢？可以看到这是单次训练，但是对于大模型厂商来说，这个量级的训练的成本其实也已经远低于。

比如像拉玛3，他的训练成本差不多是一个数量级的降低。但是其实如果只说比如说我们很牛逼，工程方面做了非常多优化，比lama 3的这个训练的单个成本降了一个摄像机。其实如果按照美国的这样一个资本市场的话，也不会有那么大的影响。它其实无非就是慢慢提高，我现在是你的十倍，我慢慢变成你的五倍，变成你的三倍、2倍。但是这一次单次训练成本的五百多万刀，这个事儿就被经常被炒作成了整个换方训练一个这么牛逼的OE的相类似的模型的能力训练只花螺板刀。所以整个给炒的非常的有很多misr understanding，让大家变得非常模糊。

所以我是大家，咱们在场的各位同学一定要清楚，这只是一次序列，而且是GPU的租赁时间换算成的成本。那一个模型厂商去训练模型的成本，那老了去了，研究架构，买数据，清洗数据，做这个算法，去做这个分布式的集群的维护搭建这些工作全是，然后人员工资全都是成本。这个比起来说这完全是不是一个数量级的。所以大家可以假设说它的总成本，比如说我们说open l拉纳他们的训练的成本来去对标的话。基本上第四个它的成本我们可以按照他这个钱的随便来这么算。但是就算是十倍，其实大家知道，基本上美国这些大模型厂商一融资都是什么几十个billion的这么来去融资，那几个billion这么来去融资，几十亿刀的这么来去融资，那比起来这个钱也还是比人家少了，确实少不少，不得不说咱们中国人还是非常聪明。对。

然后MOE就刚才说的这个多专家这个模型，我希望大家记得就是这一点，就是deep seek的MOE其实还不是一个专门的常识。常规意义上的MOE是这个deep sick MOE是连在一起的，其实他自己做了不少的MOE方面的优化，当然这个MOE的优化其实从应该是他的V2开始就做了。所以这个功劳也应该快递到去年的一个V2的

这样的一个小工作上。只是这次大家报出来，可以看到一个共享的专家和256个路由的专家，每次只激活八个路由专家。然后这样的一些工作去做了非常多的MOE的优化，然后多投显达。

注意力其实就是大家可以简单理解成一个大模型在推理过程中，我或者我训练了一大堆，训练出的结果和最核心的部分就是一个叫配位的玩意儿。一个大的简单理解成是一个大的矩阵，巨大的一个巨巨巨巨巨大的一个矩阵。我现在要把这个巨大的矩阵来去用起来或者来去训练，需要非常多的算力或者说计算优化这方面的工作。MLV其实就做了这方面的很多的工作。

我把大量的算计算的巨大的这张举证的计算，能够尽量的放在一些单独的或者一张机器或者一个节点内的几个卡之间去算，为什么呢？其实就是回到了H800的那个问题，为什么H800卡的非常厉害，卡脖子卡的很厉害？就是他把大家可以简单理解成这个巨大量的AI集群，是一大堆GPU攒起来。但是这些GPU又不是平铺的，不是说12345一直码到10万，而是传承。

就是先组成了一大堆节点，每个节点里面可能比如说有几张卡或者十几张卡。然后这几张节点之间的卡，就这个节点内的这些卡之间也要通信。这个通讯的带宽和节点跟节点之间这个带宽，比如节点一般就是一个机柜或者一台机器，它们之间带宽更不一定是一致的，很有可能是不一致的。比如说我一个节点内的几张卡之间可能是非常快，比如150G的这个带宽。但是节点跟这节点之间可能只有50T带宽。那我们就要想说，我要在这么一个集群里去处理这一大堆巨大的一个矩阵乘法的话，矩阵计算的话，我肯定希望更多需要通讯的部分都放在一个节点内，用的150G带宽来去来去计算。或者更多的用那150亿的带宽来去通信，而少用那50G的那个低速带宽。

所以在这方面就做了非常多的优化来去做这个，包括AMA也是干这个事儿用的，然后包括这个T这个倒不是这方面来去做的，这个其实也是对就是来去增加这个训练密度，然后让这个模型每每一次的token训练的效果更好。这方面都是来去针对刚才说的，我希望能把更多的计算停留在当场或者一个节点内这种高带宽的计算的环境下完成。包括这个FP8，就是我为什么用FP8呢？就回到刚才说的，我一个参数如果能用八位八个bit来表示的话，那我是不是一张卡内比如都是20G那我是不是就可以装下更多参数呢？肯定是啊，对吧？那如果是所谓的FP16，就是我16个B的表示一个参数的话，那我一张卡可能就少装了一半的这个参数。所以我尽量希望在尽量多的参数在一张卡内，或者在一个高带宽的这个小区内去运行。所以这个FP8这些方面的混合精度，所谓的混合精度其实就是我又用了F8，用了FP16，用了更多的不同的精度来去一起训练。

它本质上的需求，就这一技术我觉得大家都不用管本质上的原因，这些优化原因都是因为最近我们被卡了脖子，说H800这种卡。它在这个节点内带宽跟它的节点间带宽，其实它的带宽是不一样的，所以我们提到dixit他们做的这些很多优化都是针对这种级别的，网络情况下，我们被卡着脖子这些约束情况下，做了非常多的工程上的优化，才能让最后并且产生出了一个OE类似的这样一个模型。所以这是为什么被逼出来了？这也就引申出了一个词儿，就是我不知道大家没听懂，就是所谓的资源诅咒。

就是你但凡钱太多，像中东那些国家，整天挖油就是赚钱，那你就不太会有心思去好好学习或者好好生产，所以这个就是自然诅咒带来的，我觉得就是资源诅咒带来的。欧美这些大厂他这个钱太多了，一次就搞个什么几千万张AAAT版GB100这种东西来去搞了。那他就不会去操心这些小的工程上，或者说能做非常甚至能做到数量级级别的这种工程优化的事儿。然后商路流水线，大家看这怎么看呢？其实就看这种东西，你看里面的有绿色的、有黄色的、有白色的，有白色的部分就代表了这个时候这个设备是没事干，他闲着。那说白了就是我那那我手头比如说我八张卡，我肯定希望每一个格都满的，都在工作工工作都在干活，对吧？那这个白色的泡泡越少，代表了你的这个流水线做的越好。所以他在这个流水线上也做了非常多的工作，来去降低了这个白色的泡泡，我们叫double这部分的一个比例。

那第4个RE怎么搞出来呢？整个流程其实就这样，好像时间有点赶对吧？不好意思讲的有点多。这个怎么搞出来呢？其实就是这么几个阶段，我们说这个V3其实也不是一个模型。



V3有base模型就是这个open l其实当时非常有名的一个东西叫RARLHF这么一个提出这么一个概念。那人这个玩意叫人类反馈强化学习，就是有人类的反馈的消息，我看能不能找一张图。对，这个东西。我们对就是用大量的数据，巨大的，比如十几T20多T这种数据训出来一个模型。这个模型可能确实挺聪明的，他能接龙返回挺挺好的话，挺好的字，挺对的结果，但是他可能不会说人话，所以需要先去一部分微调，先去做这个发音训，做这个微调的部分，那微调的东西就调的本身那个模型。

最开始做那个模型就是所谓的base模型基础模型。然后他通过一个模型能够出来一个这个东西就是没有现在说白了就是这玩意儿还不会说不太会说人话这么一个模型。但是他通过了大量的数据来去串出这个模型，他已经挺聪明的了。然后R-1的第一步就是先通过直接通过所谓的基于规则的词法学习，就直接串出来一个RE zero。而这个RE zero输出的结果就已经有了一定程度的思考过程。说白了就是你通过一个基础模型，就刚才最早我们讲的基础模型这个base模型，它能够直接衬出推理模型的能力，RE zero就是干这事儿用的。

当然RE zero他没有开放出来，他在文章里面写了说RE zero有一些问题。比如说他推理过程中这个中各种语言混杂，我倒觉得其实混杂不是个问题。对大家自己思考的时候肯定也就比如说看各种语言的内容的时候，那完了以后自己思考可能也是中英混杂的，中中各种语言混杂，但是他就认为这个不是一个好的结果。但是这块儿有一个特别大的突破点，就是我们原传统的这个，自从去年回来发了OE以后，不知道大家都不知道到底推理这件事儿是怎么这种能力是怎么涌现出来，或者怎么算出来的。好，deep sig第一次公开了，说好我纯用强化学习，我连这个所谓叫有监督的学习就给他正确答案。这种学习都不需要我直接强化学习，让他自己探索，自己摸索，他都能够把一个挺不错的模型衬出来，一个有推理的能力，这个是他第一个大的发现。

好，他发现了这个RE zero以后，他就干了另外一个事儿。就是当我们说这个还是得益于这个OKI的这样一个成果，就是他的所说的这个人类巧反馈强化学习用到了SFT所以就是有正确答案的学习和强化学习ROL这两个技术一起串出来的模型。它又有语言能力强，它又能够有推理能力。参考这样一个路径，我们现在已经既然已经有了一个RE zero这么一个它纯通过强化学习搞出来。就说白了就不需要人类标注，就能搞出来这么一个推理能有推理能力的模型。我们让这个zero去生成一波数据，再拿人工去写一部分数据来把它让这个base还是把这个base模型再去调一下，让他变成一个有推理能力的这样一个有有推理能力的这样的一个模型，然后再跑RL跑强化学习出来的一个结果。这时候我们就发现了这个时候的贝斯模型已经变成了有一定程度推理模推理能力又有一些还不错的这样一个FST，就是有有能说人话吧，这样的一些能力的这样一个模型了。

好，有了这个能力了以后，开始加大量加大剂量，把一些全场景的COT的数据也都扔进去。这时候对COT数据还是也是拿着zero生成了一部分，人工做了一部分，好再搞进去整个这部分数据其实差不多是几百K也就是几十万的这个量级。这个在传统的概念上还是挺少的一个量级。再通过强化学习，最后推出了一个大家现在耳熟能详的R-1的这样的一个全血版的一个模型。所以整个过程最后会有一个参考的资料。这是一个一个人写了一篇文章，写的挺不错的，大家可以参考他来去看整个训练过程，我就不提了，这个太多了。

然后the RE zero其实最重要的一个突出特点就是我们发现强化学习是可以直接出来一个有来激发这个模型的推理能力的，来去做这件事儿。这个图其实也能看出来，就是主要看右边，就是你在强化学习的时候，随着训练的步数变多，就是训练的次数越多，然后自己摸索越多，他自己输出的这个长度也会越来越长。那输出长度越来越长代表什么呢？就代表他想的越来越多了。我们可以看，至少它那个输出长度里面其实不会是单纯的结果，也会包括越来越多的它的中间思考过程。所以这个过程就是带来了一个通过一个纯强化学习，就是你自己玩，可能不需要人指导这样一个过程。他能够让他产生一个更长的思考COT思考过程的这样一个过程。

在这样一个阶段，这个图特别好，这个图就是所谓的R-1的这个呃为什么？就是研究人员发现他在训练的过程中发现了他的推理能力或者他的这个COT能力的涌现出来。这个时刻你们可以看得出来一个问题，然后他开始尝试去解决了，解决。突然说了这么一句话，wait wait wait, 有一个harm moment，然后我发现了一个hard moment，然后换了一种做法来去剪，这个是最让人就让这个还大家很兴奋的一点，这个moment非常



好，非常牛。大家为什么为什么一个传统的基础模型可以靠这样的一个RL而且没有人的标注，就可以让它串出一个他自己可以很强推理的这样一个能力，这个就是一个特别moment的时刻这样一个东西。

然后最后其实就是他除了最开始我说的这个大家一定要注意蒸馏出来的RE模型，我觉得不能称为叫RE模型。它就是它的主语在后面，比如说这个deep seek RE，这个千问32B主语是千问32B，不是deep sit RE。他只是用DCRE出来的数据去蒸馏，让他去训了一下home的这个模型，所以本身还是home的一个模型，就是它的主语还是home的一个模型。但是好的是为什么这个事儿非常值得说呢？就是因为我们说传统的训练一个模型的过程发现，那就我来了一个拿了一个32B我按照deep sick内容，像学习方法是它的结果出来的推理能力，比拿R一生产出来的数据去趁去强化学习。这蒸馏后面的主语模型，就是后者的这个效果好的多的多的多，所以说白了就是你当你有一个很强的推理模型的时候，或者说只是RE这个模型的时候，我可以把手头的这一大堆模型没有那么强。翠明的模型能够给蒸馏成一个能力挺强的小size的基础。

之前我这个模型所以这个也是为什么整个在行业内带来非常大的一个震动的问题。就是大家以后去趁模型以后的趁模型的范式可能会变，这不是大家常听的时候，我来微调一个模型，那很有可能变成一个我来去蒸馏微调一个我的模型，而且是拿一个比如像二一这种模型来去蒸馏微调。对，所以有几个点，比如说第一个前提就是说我们之所以能干这些事儿，当然deep能干这些事儿，前提还是它的V3模型足够强。比如像我们的4 plus，就GM的4 plus模型也是足够强的。只有这种模型足够强的模型才能够干刚才说的这样，它纯强化学习直接能衬出来一个有推理能力的这么一个RE zero这个模型。然后小模型的蒸馏带来的效果可能比我们的这个强学习，甚至SFT会强好多。然后它里面其实提到了一个大家可能听说过的蒙特卡洛树这样的一个技术，或者PRM这样的技术，他的结论是效果不好，这也代表了一部分当时猜测OE模型怎么去实现的这一波猜测其实是有点不太对，或者说可能方法没用对。

最后说的defect的影响，其实是在刘志远老师的这个说法，就是说chat拉玛之于ChatGPT这个就一个开源源闭源。那现在就可以对标是deep seek r一对置于O1或者O三这样一个模型，开元复现，第一次提出这样的——一个对标，其实还是给了非常高的评价。

另外一个影响，其实就是我们已知的现有的去改进模型的推理能力的方法有基本上有4种，这个所谓的推理时间缩放，其实就是让他推理的更久一点，就是多想想这样的一个事儿。另外一种纯强化学习，监督学习，家长强化学习或者纯这个SFT加蒸馏这几条路，基本上这四个都帮都烫了一下。第一点可能它的应用都还做了都烫了一下，都带来一些不错的反馈，整个给而且还关键还得开放出来了，对开这个所谓开源出来了。然后另一个点，就是在于这张图，这个就是我们在我当时说这个画的怎么去看这一代模型的应用，构建的这样一个架构的领域图。我们以前之前老是说什么算力、模型、框架，就agent reg这些东西构建出应用。但是我们想这些应用的时候，像这些架构的时候，其实经常忽略的最顶上我们要解决这个架构要解决的问题是什么？我们要解决的是系统一级别那种，这个玩意儿的正确答案是啥？还是说我们先说要解决一个系统二级别的，比如我要去常思考，要去分析常分析的这类的问题，那我们带来这种推理模型的免费化，带来的是我们的挑战域增加了一个系统二级别的挑战，整个会对底下的结构或者架构也带来一个非常大的影响。

昨天的奥特曼的说法也是非常博眼球，就是GB4.5将会是OKI最后一个非思维链，非COT的模型。这也是基本上代表了整个OPI或者说整个大模型领域，就全面迈向这个全推理模型这样一个时代的一个标志。对各家的影响，其实其他几家就不说了，其实我就回到刚才说的这个cloud，其实cloud就是挺大的一个问题，就是他的最强项。大家看到了吧？写代码，结果现在来了一个开源，来了一个R1，开源的一个家伙能干的O一的程度。其实我觉得对于cloud是一个挺大的影响的。再加上他自己还没有处理模型，那它的主要用户都是用拿出来扣定的那我觉得可能他的用户流失是最严重，当然对于mr也是挺挺尴尬的，在这个先把OMOE发扬光大的结果，现在干不过别人了。

然后最后其实除了推理之后有可能什么呢？我们这个其实大家一定要开始关注，或者说如果有类似的工具，或者大家买了账号的话，非常强的一个人，大家开始用OKI的这个deep research的提出，其实就是推理模型加search结合起来。比如说这么一篇文章就可以生成的非常好啊。当然这一个前提是你要等四分钟，你要等好几

分钟才能得到这篇文章。但是也就代表了说我们现在对于所谓的时延或者这个效率，会有另外一种刚才说的这种系统二级别的需求出现了。那我们级别需求靠什么来满足呢？Deep reserve可能是第一个大家能全面体验这种能力的这个产品，然后thinking很重要，这个是啥意思呢？就是我们现在比如说我们现在我们打开这个看看能不能打开deep c，我们现在去玩一下这个之前。这儿我就拿之前我用的这些东西来去来去问答，我直接把这个说，就我让他dip sic来去。

用刻薄的语气写一段描述小厮是天下最聪明的人的一个内容。然后结果不重要，我们看他这个核心是看他的整个思考过程。因为open I的OE是不给你暴露出来这些东西的。但是我们可以通过看他整个思考过程学到非常多。比如说我想让刻薄写一句话，我要理解用户需求表面是赞扬，但实际是讽刺。是啊我们看反过来去表达，这个小4其实自负什么这些东西。然后开始接下来我应该如何用这个刻薄的语言，还要注意语气还有幽默，然后还要注意用词选择。

这个整个过程是啥呢？其实这不就是咱们经常上学去学的很多这种写作技巧或者这种方法论它本身的内容。所以其实这个thinking，为什么我说thinking matters？就是我们现在发现以前大家说这个教育或者所有的行业都在被大元模型直接一个问题拿到结果就完了，搞定了，或者说看到了一大堆人。现在随着推理模型出现，我们发现中间的这个部分，也很多人的或者很多老师的这个水平，也还已经不如这种推理模型本身给出你的这个推理过程了。所以这个带来的我觉得是教育领域或者说这种管理层，就是这些做有方法论的这样一些人，他的核心技能也在被开始进食了。

所以我觉得第最后一点就是大家多试一下，赶紧试一下。比如说各种的disc的问题，一定要用类似这样的这种问题，千万别问什么明天会不会下雨，这样的一些很无聊的这种问题了。一定要是越来越尽量让他会思考的越深越好啊。甚至有些人其实可以去试出那种让dept这个叫什么呢？自己能够无限循环，无限重试，或者他这个trial这个thinking过程无限重复的这样一个这一类问题。如果大家能试出来，好，非常欢迎大家能够把它发出来让大家来参考。这个才是真正的thinking的方面的很重要的使用方法。而不是像以前大家用chat PT这种普通的问问题这种方式。

好，这个超时了，严重超时了，抱歉。然后最后几个文章，挺挺有意思的文章，包括对这几篇文章供大家去参考。好，就到这儿，谢谢大家。

陈好，这个专业的问题你来提，我我先提几点，能听得明白吗？我估计直播间里很多朋友你听清了吧？

感觉大家应该听的特别明白的是最后那段。

最后那段他明白我简单的展示，然后剩下的那个大家提问题。因为今天没关系，今天小明我刷个脸，你多聊一会儿，大家可能有些问题你多答两句。头一回还是有很多东西超，你看看问题，你看大家的问题，尤其在专业技术等等方面。我简单说几句，今天第一次讲，肯定我先强调一点，这个课不是为投资服务的，我之前说的很清楚，这个课不是跟炒股票相关的。如果大家奔着炒股票什么什么通过这种课，然后你要知道买哪只股票，出门左转，你去听买方，去听首席，然后今年还有其他内容的课，这个我可能还有很贵的收费的课，也可能得二三十万甚至千万的什么什么一个点两个点的回撤不是，这是第一点。

第二点头一次讲的确深浅大家是没有把握的。小平尽量的是讲的宽，讲的广。当然第一节课肯定是要往深里去讲一讲的这是毫无疑问的。不然的话让大家觉得一听这玩意儿，这清华的水平也就这么回事，这个智博也就这样的。还是要代表一些公司的这个诉求的，这第二点，第三点，这个我可以非常负责任的讲，今天的整个的流程是水平非常质量非常高的，当然从另外一个角度来讲，成本新技术哪有那么简单，这就是为什么我说大家要自己去评判这个课的价值，我实话实说，能请到冯老师，能请到小平是很不容易的这是经常是给很多很多这个我就不说，不太好意思说是给谁讲课的人，能给他搂出来给他讲这个东西。

对于如果你能听得懂的话，你就知道今天这个课的价值很大的。但同时如果听不懂的话，你们要做自行选择。真的，大家要做自行选择。你们要不要在这个行业里去追？没有那么容易，这是最前沿的东西，同志们，这是最前沿的东西。如果你们要想追的话，这个东西你去使使劲儿。我估计以后比如说每次课上，小平给大家留点什么作业什么，大家去使使劲。如果你能追得上的话，你可能会比这个社会中绝大多数的人，的确在未来5年到10年你会占得先机。这个课就是这样，我必须把这个事说清楚，这就是可能最后就是5%、10%甚至都不到，甚至3%。

大家这个事真的咬咬牙，所以这个事大家自己去量力好吧？然后等提完问题之后再讨论完了之后我再最后说一下，包括大家的反馈等等的。我先铺垫，我知道很多朋友听迷糊了等等，肯定比马老师讲的复杂的多。你们想啥呢？马老师站在投资的角度来看这个问题，然后你挑一些有代表性的问题。我觉得是这样，小标提问题的时候，这个回答问题的時候，咱们还是尽量用一些案例结合什么的。我就是第一次别再给大家都吓唬走了，我还是指这个挣钱的，你要满足一个奸商的基本诉求，行，陈浩你来。

OK我先对大家有问题的可以先抱歉，这段时间。

尽量少说英文，尽量少说英文。

你们俩对对对对，我也感觉小平可以少说点英文。奔驰market我觉得很多可能大家不太。

清楚这个具体的OK好OK.

我觉得这个问题挺好。他说想提问一下deep这个大概能维持多长时间开源的领先地位，会不会有新的模型火出圈？

我觉得肯定会，而且应该挺快的。因为你看整个的这个氛围，就甭管是就不是中国了，美国的这些开源社区都已经炸了。你看having face，基本上你看training那个那个趋势榜，就霸榜无数，就基本上几个榜全是deep take相关的这些rapper。

那带来的结果是什么呢？肯定是有大量的我们叫AI lab这样的团队再去用这个技术或者来复现这个技术。我把这个技术用到他们自己的新的模型训练过程中，回过头就是AI lab这种公司，其实就是像deep sik这种。你想deep sik 1共1百多个人这样一个团队。然后他他他真的不像是一个正常的上市公司，不像一个电商公司。对，他他就是一个真的是一个lab类的这样的一个公司。所以这类的团队其实大量的在去复用。当然我们也在复现，我们也在去尝试把它整合到我们的这样一些技术的这个模型的训练系统过程中。所以我猜应该过去一两个月就会有一些新觉得。

新的开源能复现它这种火爆的程度，就是说能有他这么破圈。

的人悬。

因为你看这次的程度，大概率他大部分其实并不是本身这个模型多牛或者多多那啥的，就是他杠杆贼大，那杠杆哪来的？就是那些panick，那些恐慌的那些资本，或者那些大佬们的这个说法上，这个肯定是有巨大的杠杆的。你说再等下一次杠杆有点难，对吧？除非马斯克或者特朗普再做个妖什么的。

OK还有一个问题挺不错的，就是AI写的文字如何被AI检测工具检测出来。其实这事儿我们其实之前也讨论过对吧？就我们说过那个AI含膜率？有没有检测的方法？现在其实我觉得最大的应用场景应该是教育，对吧？老师现在留任何作业题，理论上讲都可以用AI对不对？如果AI解决不了的那可能就又可以成为一个新的奔驰mark。所以我这个问题就是说有没有现在一些AI工具能够检测一下，一段文字是AI使用的。

还是我反正之前测过几个都很一般。因为你像google他们D卖的，我记得之前也有几篇paper专于说我怎么去在做一些引引水印是这种东西来去在我的生成内容里面去。当然他是在好像在最后一层，输出层去做了一些不那么随机随机数生成器来去做这事儿。但是你但凡把这个输出的跑一遍，再找另一个模型跑一遍，然后润色一下，你就不可能查出来了。我觉得现在最好查的方法就是你这个输出结果是不是很漂亮，语法是不是很通顺，有没有错别字，这个就是最好的。这个太讽刺了。

我跟陈浩拆出来，这个我问的更小白一些。反正就是这次在整个的过程中，在反复停的提到这个蒸馏技术，提高效率。我两个问题结合起来，第一个你能不能给我们解释什么叫蒸馏技术，这是第一个。第二个就是直播间里其实很多的朋友不是专门干这个事的。但是我估计可能半年以后，可能一年以后、三年、五年，他们的工作的领域都可能会被AI渗透进去。那么deep sik就是出现了之后，让AI这个东西离这些领域又近，大家都说近了一大步，门槛降低了很多，这个到底门槛是怎么降低的？你比如说有些场景，刚才我看到我朋友说什么银行，什么体系什么的。因为我知道你们在做很多的应用的测试等等的。

这个门槛到底是降在哪儿？是不是比如说举个例子，之前100米，现在一下到了10米这个距离了。很多公司可能用type c的这个技术，有可能半年之后或者有可能一年之后，就真的能够在工作中去使用了，或者叫高频使用了等等的。两个问题，一个就是蒸馏技术，一个是结合这个东西能不能帮我们尽量收的少用英文。

对，蒸馏其实是一个特别既学习时代就有的这样的一个技术。所以现在大家听到的各种大模型蒸馏，或者说首先deep seek是周流这事肯定是扯淡的，就没有什么可能性。这东西说什么回答我是不是你是谁，他说回答我是什么chat PT是吧？这种东西其实你看别的模型其实很多也是并不是因为这个就是你你训练的语料，你很难去不去混入open l产生的这种数据。这个是整个大模型方向训练的带来的问题，就是训练数据带来的问题。

然后蒸馏最简单的肯定就是最常见的这个说法，就是我用一个很牛的大模teacher模型叫老师模型，让他来去指导一个小模型来去训练。或者说让teacher模型生成老师模型生成一大堆数据，然后让一个参数小一点的模型来去用这个数据来去学习。说白了就是我已经正确答案告诉你了，你都不需要去知道这个，不需要去逐渐这个书山这个叫什么书珊指海里面什么的去摸索，我直接告诉你答案了，你去学会就行了。然后这样的一个过程，它带来一个好处，肯定就是我不需要那么大的，比如671B这样的模型，我一个特别小的模型，我把你老师模型里知道这些东西，我吹进去，我大部分的知识也能学过来。当然肯定差一些，但是这个某些方面能力，我也可以根据这个蒸馏的过程，我去调整数据能学的更深。比如说就是把一个很小的模型训出一个它能产生思维过程的这样一个这样一个能力，所以这个基本上可以这么说。但是大模型领域的蒸馏其实被跟传统那种机械性蒸馏其实已经差了非常多了。所以大家不要把那种什么传统那种把一个模型的一部分参数铲掉，然后铲掉以后变成一个小模型，再把这个模型怎么输出，输出为模型，不要不要把这个混在一起，混为一谈去聊。

我的理解是现在大家说的蒸馏已经非常泛化了，就有点像什么涌现这种词儿已经被就用烂了。对，所以这是一个。然后第二个啥来着，就是有什么是吧？

就这个就是大家都说是大大降低了应用的门槛。你比如说很多的企业，比如说现在AI企这个在企业信息化中已经应用了。但是现在可能是在个人的领域，我们现在很多人，比如说我查可能更多的豆包了，不用百度。那这个东西到底我们说这个技术出来了之后，因为我这么讲，我为咱们直播间里可能有没有一些国企的话，不知道有没有，就至少我知道的你们的高层都在谈这些事儿，很多都是在跟小平他们在谈这个事儿。你们可能很可能

半年以后，一年之后，你们就会批量的有一些工具用上了。这个事儿出现了之后，到底是在哪些地方降低了门槛，跟整个企业级的应用，跟B端的应用，或者跟C端的应用就更近了呢？

这个点到底是在哪儿呢？我觉得其实反而是反过来，就是你想想我们去年大模型领域里面这种弊端应用，如果大家有在B端这个企业内去实施过这种的模型的应用的场，这个同学应该知道大部分都在做reg少部分在做所谓的agent或者说这种流程编排的这种东西。那这些东西用传统的基础模型大元模型是挺挺成熟的了。然后只是不断的涌现出一些新的rac技术而已。但是R—推理模型一出来以后，一直到现在，其实都还没有一些比较好的方案去整合推理模型跟去年很火的reg和agent这种东西对吧？就唯一见到的一个还是个新形态，deep research. 这样一个新形态的产品，你说你现在知识库结合推理模型咋搞搞怎么做集成这事儿放在任何一家企业里面，其实现在都是懵逼的，都没有找到一个比较好的一个实施方式。所以他反而是带来了就我拿到一个新能力，这能力还不知道怎么用。

这个能力已经他有那个都想着急用。对。

啥没听清。

小四先说，小四先说，长得帅的像没有你，你刚才你先说。

那我问但是小明现在这个东西，你比如说可能直播间里还有很多是学生家长，那这个东西是不是在教育侧已经现在已经在突飞猛进的？

是，当然就是我就刚才最后讲的一点，就是大家尤其是家长，我觉得或者让学生自己去用deep seek很重要的点不是看答案，是看中间的思考过程。这个思考过程你想想大家以前比如请就比如像我以前请家教或者什么的，那些家教核心的是不是告诉你这玩意得5，是告诉你他怎么算出的捂。而现在第四个，我靠能把一些至少一部分这种推理的题，能告诉你，能把整个思考过程告诉你。是的，这个我觉得对教育影响太大了，你老师有些都都达不到这种思考的维度。

我我我这么说，大家可以去看看最近我的几篇视频。我年后给我们那个编辑团队开了会，因为你们也知道我视频划水严重。我我在这举个例子，我顺着小编这事说，我这培养编辑团队培养了这么多年，就是他妈练不出来，我说你们就是给我用的深入思考，然后用这个什么什么你各种词儿你去给我试。你们就可以看看最近的几篇视频，你们可以去看看哪篇deep six系列的，肯定不止一片。这个可能陆陆续续未来都会发出来。马上就是我我讲了这么多年，他们拧不过来，就这一顿，尤其他中间那个思考过程，好像我们的编辑团队有点开窍了，真的是这个情况。好，你记我想问如果。

你的视频都是deep seek生成的那如果观众朋友们都用了deep seek，是不是就是。

不需要小4？我我我我我我说一下我的体会，我说一下我的体会，就是这个在整个的实操过程中，生成是很容易的，然后学习比生成要难一点，最难的是设计题目。所以这个事你们可以问问陈浩，就涉及一个问题是最难的。就是真的我我就听完这个课之后，哪怕今天晚上这个课你们一点都没听懂，我都特别建议你们设计一下。你们要问这个别问一个什么问题，什么明天什么周围哪个地方好吃，稍微复杂一点，然后大家多换几个词儿，多去试一试。你们真的感觉用他的深度思考真的感觉不一样，真的是感觉不一样的。这个是我拿今天晚上这个课，如果上完了之后，大家能把这下来。但是现在卡的比较厉害，可能一天我两次、三次，你们真的都能去下载下来，然后去试一试，我都觉得这个课就值了，真的是这么个情况。

来场也可以用深度思考的deep sick来帮你生成一些更有价值的问题，看看有没有比小说的选题更好。我刚才我看有一个朋友坚持问了好几次，其实我觉得是特别好的问题，就deep c对SOC的影响，我理解这个朋友想说的，SOC应该还是那个边缘推理芯片，对吧？所以我觉得这个。

问题调整一下。

小平你觉得deep c出来前和后，对于边缘芯片这个推理，因为可能很多人也关心炒股，就是我觉得这个事儿里面对于算力这块儿的影响是什么？

这其实我不专业，所以我觉得我但是我至少目前看起来，他并没有给比如像SOC或者像什么asic的这种就比较偏asic的那种推理芯片，那种定制化推理芯片带来太多的参考意义，或者说决定性的成败。你想其实现在大家真的是缺那部分，什么领域最开始先拥抱了AC可能肯定是像那个那个BBBB coin那种东西，对吧？这个圈的他是最早拥抱这个东西的，但是为什么呢？是因为它的算法足够确定，确定性足够大。而现在reading 8的这种推理模型三天两头出个新东西。然后他其实自己这套的推理的训练的框架推理方案，其实也没有逃出之前的大元模型的这个范畴，就范式没有变化。所以我觉得对SOC的影响到帧，或者说从这个维度来说，SOC对这个影响真不大。但反而是说它带来的小的蒸馏出来的小的模型，推理能推理的这样的模型。

这个东西它可能是真的能够让一些场景能实现了，就是一些端侧场景能实现了。比如说像刚说有些比如说变电站，就是这种边远地区，他一定得在本地计算。你你你你在他那个叫什么那个那个铁塔底下的本地那点算力，它还得要去做一些分本地的分析，比如说我看看这个什么什么有没有变坏，那个叫什么绝缘子，或者说我现在本地的负载有没有一些异常。然后这个周围有没有一些。

比如军舰上的发动机的设备的智能维护。

那得持续了。

什么国家太多场景了75对，我们最近也在在聊一些场景。我昨天是在港科大，然后也跟他们的相关的人在聊就边缘芯片这块事儿，反正我觉得业内的人都会觉得边缘推理芯片这个事儿特别成立。我自己搬运的原因是因为DP这个蒸馏的那个，原来就是因为刚才我看到也有人提问题，就是什么14B的这干不了什么活，大家我觉得回到去年，我觉得也许是，但大家可以试试这个蒸馏出来那个确实在我们自己很多场景里面还是挺强的。

对它蒸馏能做很多垂直场景的这个蒸馏模型以后，就是有可能能够真的满足那种边缘场景的需求。所以它本质上还是说一个网上购能力的这么一个小模型，跟实际这个业务需求在这儿这够上了这个tipping point，这个交点，所以带来的那SOC只是我觉得就是够的这一部分的这个是不是再能加速一点，再往上跑跑。

我问一个小白一点问题。

一个问题你说。

张浩你先说。

对我觉得这个问题其实挺好。我觉得如果在这方面没有太多储备，就是这方面的小白我应该怎么学习才能跟上老师的节奏？



我把这个问题说，那我我你问题我我这我我就我我也想问这个问题，当然我把这个问题稍微深化一下，稍微深化一下。小平你比如说不是说小白，然后怎么去跟上你这个课的学习节奏。你比如说我就是个。我三四十岁了，我觉得未来5到10年，可能C的这个东西可能会在我说的功利一点，就是会在我的工作中大批量的使用，我就是想在未来5到10年，在这个过程中我能走在前面，我能比别人更快。那我现在要去学哪些东西，或者验证哪些东西。包括你听了那么多的各种的什么扫盲课、科普课，这些都没有用？我觉得从多个角度，你们因为小明你是天天在里面，你可以拨出来跟我们聊聊这个事儿。

我觉得反正我现在听的一方面我得学这些原理，学这种技术。但是我觉得对于大部分同学，我包括我自己其实也是我觉得最大的一个改的改变或者说这交界点。就是要对自己的需求敏感，就是我突然有个什么想法，然后这个事儿可能肯定是小孩最最典型就是十万个为什么。就因为他对于需求，对于人类的因果这种执念是最敏感的那你如果大家对于自己的需求，对于想自己做什么工作，或者对于日常工作中自己这个想法的需求敏感了，才可能衍生出我怎么去用AI来去尝试帮我去解决，或者是来去扩展我自己的这个叫什么好奇心。所以我觉得敏感或者叫好奇心，就这个事儿是特别重要的。

比如说前两天我们比如说我去那有一个地方，它有一大堆定向麦，就是那个定定向喇叭，他那个就跟什么广场舞似的那种定向喇叭。然后我带着我的AIR pod进去，然后我的air pod就就炸了，声音就炸了。所以那个时候，我就想说，这为啥呢？就是你所有的别的那个那个喇叭都不会产生这个IR pod这种，因为它通透模式还是很好用的。但是就在定向卖的时候就出问题了。那这个时候我就会想说，大家如果觉得这个一笑了之，或者觉得那又出bug了就完了。

但是如果你去追下去，你就去问，甭管是deep sit还是OE还是什么，我们的GRM的这个制作的模型，你就去问他，多问他到底为啥，然后他就会给你几个答案，然后你就觉得挑里面你觉得更可靠的。比如他是这种信号处理算法的一个问题，你就去继续去问他。你觉得如果像处理算法有问题，可能是啥原因？然后就去挖。后面我就觉得有可能是一个一个原因，挖出可能是一个启动点就具体就不说了。对，所以我觉得这个最大的希望，希望大家能改变一点的点，就是啥事儿都保持一个比较初心，或者是我第一次去处理这件事情的一个心态。而不是说我老油条了，我经验可丰富了，这事儿就这么干。

换一个想我追一下，小明我追两个更细化的问题，就顺着形式往下说。第一个就是我知道你花了光买课花了几万块钱了，当然你是从高维度看低维度，这一课有没有用，这是第一点。第二点，比如说大家真的就是听完这个课之后真没听明白，但是产生了浓厚的兴趣。你讲的这些东西大家用deep seek，然后反复的去这个有没有提高，有没有帮助。就是把你里面的一些不懂的东西，拿这个来反复的循环用，就是去有吗？

我第一类反正分不同的学习的内容。我是比如说我觉得我学现在学这个大模型领域的知识，学学到东西最多的反而是youtube上的一些视频，就是免费的。对对对，不是那些买的课的那个内容。对，就是因为那些内容里面有非常多的频道是非常专业。当然BB站上也有不少，也都是免费的。所以就是找我如果真的学技术的话，就看那种课就好了。

然后那些培训课，比如模糊什么这些上的，它其实适合这种更偏想去做工程开发的这些同学。我想学工程开发，我又不想去学那么多基础知识，我就想这个快速你给我几个demo，给我举个例子，我就能上手开始写这种应用。然后能快速跟通过面试，通过进入公司来去干活。其实学这种课我觉得是挺好的，就是效率挺高的。因为它里面那些老师其实都是这种在行业内有工程经验，并且能告诉你一些这个企业大概需要什么样的东西人。

对，然后这是这类。但是我觉得对于所有人来说，其实都应该更更重视的是这种就是刚才说这种日常的这种，怎么能激发你用AI的这一类的内容。那这类内容其实养成习惯，对，很少有人学到。包括清华前两天发那个什

么dipt，什么一百多页使用手册，我看一下，我我我不我不建议大家看那个东西，因为那个太体系化。

那玩意儿就是等于说就跟上一代的problem engineer，就是皮尔斯工厂一样，他就会开始会让你如果真的很认真很答应去学那套东西，你会觉得我用推理模型就应该按照这样的一个步骤来去用这样的结构来去写提示词。这个其实我觉得是反这一代大模型的趋势的。这代大模型应该是让模型更像人一样思考，或者说他应该去solo服从你的想法。

你应该不是跟父亲对话对吧？对对他。

会持续学习。他以前我们比如说一年前大家还有一大堆写学写提示词，结构化提示词的这些课测放到现在多模态，现在推理模型OPI的官方文档建议你不要干，不要不要什么不要去写你让他怎么思考的内容，你就把你的问题写出来就行了，不要干扰他的思考，不要假装去你觉得你比他思考的更更牛，你就让他想。对，所以就应该是越来越像人话。当然如果你人话都说不出来，那是另外一回事儿。确实这种但凡能说出来，我觉得可期的未来的模型都能把你的这个理解的。当然不行的话，你可以看大家看deep research这样的产品，他会追问你的，你提了一个特别傻的或者特别浅的问题，他会持续追问，追问几遍觉得OK了，他才会给你完成这个任务。这些都应该是模型和模型的应用的框架完成的事儿。

张。

对我觉得刚才也有一个产业的问题，就deep sik你觉得会用在狙神智能机器人里面吗？

肯定会。那你像为什么去年底的这个word lab这么激动人心，或者李菲菲这个教母她这么大。就是因为大家发现，如果有一个世界模型的话，我们的整个的包括其实主要是针对机器人，它就有一个很硬的，我们叫grounding，或者叫事实依据。去做任何的公事儿的时候都有一个物理约束。这个物理约束是逃不开的，而且是确定性的那现在推理模型出来了，那我们让这个模型去，它在物理上有一个说法，靠世界模型，然后他在干活上，他在干事情上，他也有一定的逻辑约束了，那他绝对会变得更强大对吧？就你你你的模型干你的机器人干活会更更合理，更更有道理。

我问一个，说我感觉大模型全行业知识的模型不见得适用我认为更合理的行业模型更实用。比如法律、工业设计、材料工艺开发等。老师怎么看这问题？我问你们俩，因为我知道你们都在这个领域有涉猎。来，小文你先说。

行业模型肯定还会有的，但是这个会变。比如说我们说去年或者前年、去年初、年前、年底的这种十年，整个的行业模型是干啥的呢？反正按那种是吧，它就是个证据工程，很多地方他要去搞所谓的这是我的模型，那玩意的行业模型根本是瞎扯，我觉得是瞎扯。他就为了跑通内部，把自己内部的这这样一个测试集跑的分更高一点，搞个行业模型那瞎扯。但是从去年底，就是这一这个时候开始，我们看这个模型本身在行业应用里面是有一定的叫什么这个行业策划的需求的。就是它在某些行业内的某些工种，它是有特殊需求。

再联系到什么呢？联系到apple intelligence，就是苹果的那个那个AI，最近不是选了这个千万，然后它里面怎么实现的？你会发现它在手机端的那个模型是大量的微调的。Lora回email是一个lora就所谓的lower，就是微调的一个小模型。模型的一对就是理解成一个垂直功能的小模型。你回e mail的时候用一个Laura用一个模型，然后发短信的时候用一个模型，然后看什么这个就做摘要的时候用另一个小的模型。这个其实是任务特定任务的模型，还是有用的，尤其是在资源受限的情况下，或者说对于精准度要求很高。但是这个任务又很窄的这样一个场景确实有用。

而且现在也有不少的这种公众化的方式，可以让我们把这种微调以后的小模型非常快速的切换来切换去。所以我觉得可能像推理还是挺好的。既然推理模型可以去在做垂直行业的策划，那对应到的这个推理场景，各个行业的推理场景，当然你也可以去做很很好的这种。调试了。所以我觉得推理模型在行业内，垂直行业的推理模型还是挺有需求。

对我简单补充，我也觉得行业大模型是有价值的。其实过去我认为比较扯，但是后来发现就是说到不同行业里面，确实一个是有一些领域知识，第二个有一些需要对齐的地方。就是这个领域里面简单来说打个不恰当的比喻，就是他们是怎么说话的，他们的黑话有哪些，对吧？然后他们的这个思考方式可能跟其他行业也不是那么一致。其实这事儿就包括医疗，就是说这个行业里面，你做医生的话。

他要的特别火。药物发现这个领域就一下就年后就炒起来了，稍微结合一下，不是。

我对要发现是一回事儿。另外一个就是做AI医生对吧？现在也有些大模型公司，其实在未来定位就是做AI医生。我觉得这个事儿里面确实还是需要围绕这个垂直的职业，垂直的领域去做一些模型上的一些策划的处理，我觉得这个逻辑上还没问题，只是说在过去大家有点盲目，就是很多我们反对的是说你就是为了有一个自己的模型去搞一个。但今年我觉得很多大家真正把没事用起来了。当你有特殊的需求的时候，发现通用模型满足不了你，或者效率太低，那做一些特殊的处理去训练一个行业大模型，我觉得还是成立的。

张小明，没事，小飞你继续。

小飞你继续。我来补充一点，其实就是但是千万别因此去一门心思的跳进去说我怎么训练一个模型去干这事儿。因为这事儿的门槛会被快速拉低。就是你可能以后有有一部分数据，有一部分你思考过程扔进去就能成一个你的这个行业的推理模型了。当然如果你想从事这个行业那也可以。但是我我觉得大概率大部分大家不会去想说我这辈子还不去做了个模型训练师。

我我我就想问这个事儿，但是可能顺着这个思路往下走，最后一个问题，因为马上十点了，我我我还得接着直播，你们让我歇一会儿。你看我们从整个open a开始火到现在差不多的时间。其实欧曼开始火的时候，我们当时翻墙出去问等等的。其实那个时候火归火，但是好像包括我实际用起来都没有感觉到这个变化那么大。但是这一次你看有两年的时间，然后第四个出来，尤其是他他常考那一块，就深度思考。就是刚才小明说逻辑那块的确是我感觉好像是如果我把我自己，当然我本来就是个小ai，我按照一个小ai来讲，好像一下感觉就完全质变了。那你们俩的判断，这个的变化速度理论上肯定是会加速的。

那你们预想一下，可能半年以后，一年以后可能会到一个什么程度。就是我觉得是不是对于至少你比如说我这么讲，一会儿你们俩走的时候，我可能会给大家提点要求。比如说70岁以下的或者60岁以下的，我觉得大家现在都要用。这个时候不然的话，你半年之后，可能你在整个获取信息的模式上就会跟不上了。就跟当年大家都用信用卡的时候你不用，登微信时候你不用，对吧？都开始刷抖音了，你不刷，你们俩怎么看这个问题？

我觉得不是70岁以下，所有人都应该，尤其是大年龄的，你千万别去看。

越是高年龄越有，对吧？

广告小文里面的什么养生建议，你一定要问，有事儿去问大模型，你别瞎看那些东西。对，然后对于就是中中年年轻的那你肯定是怎么能尽快的把自己的这个日常工作里面的这个效率能提上来。就是谁先把自己的工作替代了，才可能去主动替代别人，那肯定还会留下。甭管说这个未来产生的新职业，还是说现在留下了这样的一些管理AI和人的这样的一个工作的这波人。那肯定是谁先把他自己替代了，自己干哪些活，替代的人去干这

个事儿，你不可能说来这叉号把我的活给替代了，然后我去当他领导对吧？我肯定不是这样办的，所以他巴不得。

他其实对我我我我个人其实我。

不太喜欢给大家制造焦虑。其实我觉得就是说早早学员晚学员结果都一样。

是啥意思？

就是该影响你职业的也你也阻挡不了，大家好好享受生活。比如说现在你去学一些东西，其实再过一年可能这东西已经好用到你学那些东西也不是特别有价值。

会发展的非常，我觉得它是两个逻辑。

我其实觉得最有最大家最好的状态是说，这玩意儿挺有意思对吧？我感兴趣，然后我想了解一下他，然后我的工作里面，我看看有哪些东西，而不是说是被焦虑驱动的，我好怕丢掉工作对吧？我得先学，我觉得那种心态很难有一个很有效的一种进展，而且学到的一些东西其实也可能没啥用。

OKOKOK小明，我最后补一个问题，不是你看今天我们其实因为第一次讲了很多框架的东西，逻辑东西，你那有没有一些案例的东西？比如说就在一些教育方面的应用，在在什么行业上应用，这些东西你们还有吗？

你stake的案例我还真没有。

但是不是sorry，我听sorry，我说是我说顺嘴了。人工智能在一些教育等等。我觉得你比如说很多像我们可以举两个例子，就不一定举这个对吧？就我什么什么就是不要。当然拿我举例子，我也没我有一个朋友这个例子举得很好啊，就是我听的最认真的就是那一段儿。

好了，这样给大家留下一分钟的时间，对于小平老师和陈浩今天晚上的分享表示也感谢。我估计大家可能听得云里雾里的，这样我会再留一点时间，然后跟大家稍微梳理总结一下。就是按照我们的课的一贯的这个情况，小明正好简单梳理总结两句呗，反正这课都是习惯都是这样的。你们谁先来？

我先来。对，因为我今天算是个助教，或者是旁观者的身份，听了小平讲的，我其实也挺有收获的。我觉得大家听不懂是正常的，因为小平讲的很多内容其实是完全是站在前沿，然后给从业者。但是我是觉得其实你把小平讲内容当成一个目录，当成一个生词本，把一些概念，大致觉得哪些重要，然后去deep take上再搜索，我觉得你会发现很不一样的一个感受。

怎么样。

我觉得确实我不是想给大家制造焦虑，我这个就是想让大家去了解新东西。然后我是觉得像反而像那些营销文，那些制造焦虑比我厉害多了。我本身想法就是还跟刚刚那个常老师类似，就是不要焦虑，然后听不懂没关系，就是多去感受，为什么呢？就是多去感受这种新的这种发展的过程和内容，为什么呢？是因为你要相信人脑本身比现在所有的算法都牛逼非常多倍。你要知道是相信人脑本身去吸收或者去听这些东西在里面进行的过

程就能学到很多。而且你能去想象到激发出来的创造，是现在创造力是大模型完全取代不了的，我觉得很长时间但是取代不了的。所以不要焦虑，就多听多多看，然后这个放轻松多用就好。

我就我觉得小明最后这个说的特别好。如果现在人工智能其实是激发我们潜能的一个工具的话，如果大家能把它理解成这个段位的话，其实对于可能每个人帮助都是很大的。兄弟们，再次感谢。然后我最后等你们俩撤了之后，我再背着你们俩说点坏话。感谢。好，拜拜，争取下周四的继续。

我们后面说不要制造焦虑，是不是影响你麦克？

那肯定，但是没关系，作为一个奸商，这不差这点事儿，你知道该卖肯定OKOK。拜拜，辛苦了。小明，拜拜，拜拜。

我留一点时间稍微给大家梳理总结一下。因为今天这个课比较奇怪，这可能是我我们上课这么多这么长时间以来，第一次叫跟股市几乎一点关系都没有我我我来说一说我对这事的看法和理解，当然我会在这问一些问题，就收集一些反馈，我先收集反馈，因为我估计因为这个小鹅通上谈的特别慢。我最后再总结咱们直播间里有多少朋友，你们的公司或者你自己的公司，或者你觉得未来你是会用到这些东西的。

这个呢大概给我个反馈好吧？对我开始POA了。有多少你们觉得尤其是在企业级，尤其是在企业级，这是第一个这个大家就打字行了，因为我这边刷的特别慢，咱们这个滞后性是比较多的。不会的，怎么不会？就是你觉得会的走，不会，怎么不会，这是第一个。

第二个，那个股票我是绝对不拉群的，但是如果是企业级的应用，你们要做一些深度探讨。因为刚才说实话，我看到有些问题问的很专业，包括一些那就是很多技术上的了。我可以考虑拉个小群在这个问题上，你们有没有需要的这企业级的需要怎么需要？不需要了，怎么不需要？

给我点反馈，这个群里绝对不要聊股票的事，就是我可以想办法，你比如说小平特别忙，正好也特别忙。但是我们定期的是不是因为大家这些沟通，可能也会对他们后面的一些分享有帮助，就是包括一些企业级的探讨，包括因为不管大家说他俩现在面对的企业客户偏大，有一些中小企业他们接触不到，现在一些大企业他们已经忙不过来了。我就应该是有这个敬业要求的，是这个报名要求的，我是不能提的。

耳熟能详国内外一些公司，他俩都在服务。如果需要他，我在这可以拉去，股票我是绝对不会拉的，在这儿我会给他，但是我做完以后，大家不要浪费。你比如说我有钱，我今天就在没有用。你们真是在企业级的，你需要的话，我这个可以考虑。比如说下一次我让他们建好群来，然后怎么怎么的，咱们组织一下一个群收费，这课肯定收费，开玩笑，年卡两千多少？现在2400多少？2480，2485，这是跟月卡年卡一个价。

这是第二个问题第二个问题。第三个未来我大概的想法，就今天因为是第一次，就是我小平开始问我说不就是要降难度，降到什么程度？我说你稍微就降降一半，稍微降一降，然后把但是还要把大框，我说你别指望那他们俩也有很强的焦虑感，就怕讲的大家听不懂。我说你开玩笑的这种，他妈讲完了之后大家都能听明白才奇怪了。

但是今后这个课可能会有更多的案例，因为他俩都在实操，很多的案例，这个可能会在这块给大家分享，好吧？这是三个对于案例，就是大家什么需要，尤其是各个行业，你们需不需要在群里给一些提前的反馈，针对一些行业等等的，当然技术方面第四个，最后补一个问题，你们有没有觉得今天讲的不够深的？哼这个大量的方向都不是被取代，这是加强你不要老想动不动取代的事儿，人这么聪明，怎么就轻易被取代了呢？重视加强

哪些领域？你们觉得不够深的，你们就走波浅了，不够深的就走了。我已经都用它编程，编程现在是很好用的。实话实说。这个好吧，那就觉得不够深的这个你们就都遣了，我大概看一看好吧。

大概这么情况我来简单说一下，这个课大概的定位是什么？实话实说这个课最初的定位跟股市一点关系都没有。我是这个课有私心的，我来给大家讲讲，我很坦率的讲，这么几个定位。第一个就是对于大家人工智能这个领域，肯定毫无疑问是前沿。如果我知道咱们直播间的朋友的平均素质非常高的，有抖音的朋友给我反馈，可能我的直播间是所有知识付费主播里头，本科生学历以上比例最高的，然后正好近水楼台先得月。

因为大家知道清华智谱的两几位天使里头，有俩都是我合伙人，所以这个领域我很早就接触了，包括在算力，包括在数字经济其他领域，还有一些其他的涉猎等等。这个领域实话实说，我可能认识人比大家的稍微多一点，有这个机会我说给大家创造个条件，能跟最前沿的，至少国内最前沿的这些人接触上。小平他们是经常要去给一些领导，给一些什么什么去分享的，这个基本上是我能接触到的就到头的了，这是第一点。

第二个，人工智能这个东西就是一层窗户纸。人工智能这个东西的确就是一层窗户纸。没关系，这个大家浅了就浅的，深了就深了。你让他来讲太大，可以给你讲的很深，一点问题都没有，就是一层窗户纸，尤其对于咱们绝大多数朋友，我对这今天的课两个体感，两个要求。

如果就是其如果你有这种想法的，你该买买。如果你没有想法，这种课你们连碰都不要碰，浪费时间。最不济哪怕你听不懂，听完了这种课，你有强烈的冲动。你们要把deep seek放到你们的置顶，或者放到你们的下面那个手机里面，你会反复的试，在各种场景中你都会拿它来试一试。我觉得是最不济你在考虑以后要不要买这种课，或者是长期来跟踪听这种课，这是底线。

就是你听完这种东西之后，对这玩意儿一点兴趣都没有，一点想法都没有，觉得无所所谓，听不懂跟股市没关系。我现在就是要挣钱，我就要挣明天的钱，那你连碰都不要碰，这是底线。那么顶层的要求我来说一下我的私信，因为整个的我不知道大家还有印象没有。

去年6 7月份我当时跟大家讲，我说我从那个时候就开始特别忙，对吧？5 6月份6 7月份开始特别忙。其实这个转型那波我经济体制转型我是感觉到特别早的，非常早就感觉到了。因为整个人工智能起来了之后，尤其是经济体制转型，然后国家政策开始发力。因为清华这个学校是理工工科为主，大家在科技上，在尤其是清华的这个，你不要老觉得什么刘美燊为宜，我们需要的这个爱国主义教育是很那什么的。就大概在去年6 7月份的时候，我们学校就发了基本上类似于召集令的这么一个东西，就是各种的口口相传，手里的事该放放一放，这报效国家的。

说到了大家在科技上是有很多的想法的。在这么个领域。然后其中有一个很重要的我们正在做的，也可能会补得上的，就是在人工智能和各种企业间的那个信息不对称是信息不对称。在这个地方我们继续要补充很多，就是其大家的真实需求到底什么样子。

我们在整个的执行过程中遇到的最大的问题是，不管是大的企业也好，中的企业也好，小企业也好，大中小企业需求几乎没有能提出来的。就是这个东西放在这儿，大家就是提不出来，就是没有理解。就是这个企业中的各种跟人工智能相关的这些领导也好，这些部门也好，就是很少能把需求提清楚。这也不知道现在大家就是一片混沌，我不知道咱们直播间有没有这样的，教学相关学习资源吧，那回头群里说吧。

这是这么个情况，所以我当然这里面两层意思，第一个就是断点，就是我们很多的东西下不去，服务能力下不去，然后提高效率。其实这个都到这个程度了，但是整个服务上的推进是很慢的，可能就像刚才小明说的，什么政绩工程搭个服务器，搭点算力，然后配个模型，然后做个本地化部署结束，真正能对有效的是不多的。但是反过来讲，这是机会。就是这些公司里面需要一批能你不用懂你不用太懂人工智能的技术，但是你要懂这个

东西怎么提需求。未来在人工智能跟大量的传统领域中，我觉得会出现一批这样的岗位，或者会出现一批量的。

所以我不知道咱们直播间里有你们有没有你你可能你的这是你的领域，或者这是你的交叉领域，或者是你未来的话一定会出现大量这样的，就你们去需要去握手，就你站在你的本行业去跟人工智能握手。现在这种事提不清楚，这个太头疼了。我们很大的国企，很大的外资企业很大听不清楚。就隔行就现在还仍然是存在着大量的信息不对称。诉讼时代叫做总用户。是的，所以我们这个课理论上实话实说。这种课你别管是定价200也好，定价两千也好，定价两万也好，我们小平同志拉出来肯定不止这个价我的核心目的，我是希望能够通过这个课能够我实话实说就跟股市。

当时我跟大家讲一下，迈克的主要原因是找到一批能对自己投资负责，然后能够有学习能力的人，这是我的根本诉求。这个课的根本诉求就是我希望能够找到一批你未来有可能能在站在我们的另外测来完成这个传统行业和人工智能握手的人。这是我的目的所以我很坦诚的讲，因为我觉得这个地方的价值会非常非常大会非常非常大我个人判断价值会非常的大，所以基于这些大家来判断这个课你们要不要买。这就是为什么我说我对这种事的定位是什么呢？就是如果你们连冲动都没有，没有说去试一试人工智能的冲动，没有连想都不用想你就纯粹给我面子来听课，多浪费时间。

如果这个国家数据集团的如果如果你们是高的维度的要求，就是不管是你们在什么样的企业，尤其你们自己的企业什么的，有人能够来握手太难了。而且我但是我我觉得这个事儿就是难归难，但是这是我不做，也有人来做，我觉得很多人都会在做的事。这是大家都在想办法去消除人工智能和这个传统行业的不对称。

请那为什么请小平和昌浩两个人来做这个事儿呢？然后其中小平就是在这个质朴，你们也知道质朴是准国家队，质朴里面主要负责前端技术的前端应用的研究，他可以把这东西讲的非常深，当然我也可以想办法让他拔的浅一点。然后这个亦庄人工智能研究院，他的一个其中很重要的任务就是完成传统行业和这个传统行业和人工智能对接，就是这么一个情况。所以我请他俩来，基本上当然我纯粹是小白代表，就这么个情况我说清楚了吧？我说的很坦率。当然你说你听这种课你能不能跟得上，你有一些自己的收获，然后你能能在里面应用，我觉得这是可以的。所以我从最开始就跟大家讲，我们今天这个课其实应该是叫to b端用户，不是对一个公司，而是真正你们觉得在公司里面有价值，未来能做到这样好吧？我说我说到这个程度，你们对这个课仍然有兴趣。

这波有我看一下，搞企业IT系统咨询的，现在迫切的了解IP能够在企业端落地的场景。是的，仍然有的，仍然有的没有了。我听完刚才那些，本来你有，但你听完我刚才讲那些你没有了的，你也打一下。没有，我真的感谢大家感谢大家，感谢大家好吧。那那可能这就是这个，所以这个课我估计人不一定特别多。但是我会让小平刚才什么有道理使用，一要简单素质开出来讲，然后这个现在很少结合的比较好的，我就没跟大家讲，很少，几乎看不到，可能走的偏前面的是教育。

当然我还有一朋友叫洪晓丹，他叫和气聚力的那个公司，他们就是这个你大家知道当时教育整顿对吧？什么什么学而思什么，当时都是受了很大的冲击。我这个同学也是清华的，就是脑子比较怪，就属于那种大家都做to c的时候都做to b现在合计已经完成了六个省，六个省是集采。我忘了哪六个省了，我猜咱们直播间里肯定你们是不是有人知道这家公司吗？你们在那个省可能已经是用他的系统做集采的，来支持初中高中的中学教育来做中学教育的。他们在人工智能领域，就你比如说这种人工智能的批改能做到什么程度？比如说提了作文，类似这样的阅卷等等这样的他们有大量的，包括其实他们想转C他们的技术储备是完全没有问题的。

可能在接下来我也有可能会请小丹过来给大家聊一聊。比如说AI结合教育，因为他就太有发言权了，完全一线实操。现在我那个教育部谈到什么时候，我就不能在这说了。但是六省就是已经完成了，六省已经做了集采，就整个六省的教育体系跟他们公司做了对接和集采等等等等，好吧，所以可能今年陆陆续续今年陆陆续续我可能还会做一些类似其他的尝试，你比如说这个，那正好说到这跟大家简单说一说，因为我大家也知道我这个人



是很克制的，我过去三年就卖了两套课，就是我就是有价值东西我才会拿出来，或者说甚至我还得掂量掂量风险等等的。

今年大概有这么几个想法，一个就是一个就是这个课。这个课实话实说我不觉得能卖太多。这个课更多的是有点理想主义的这么个东西。因为人工智能这个东西就是前沿的，说白了你还真的有点理想，有点信念感，你才能干这个东西。你真的就是那种就是奔着恨不得明天就能挣500万，然后明天就能挣5000万，然后时间能翻一翻，你是不可能有这么耐性的，这个课需要很大的耐性，这是第一个。第二个有可能会有一个很小的类似于，其实我不太想起什么私董会什么这样的名字，但是那个的确承载有限。他们原来说什么100人、200人我都觉得到不了，可能30人到50人，大概这么个情况。

然后呢这就因为我的确还有一些朋友，不太方便在线上露脸，我连名字不能提的。有可能会有线下的更小的，但这个原来我跟大家提过，这个可能会很贵。对，比如说可能你得至少在可能二级市场中有500万或者1000万以上，可能一个点到2个点的回撤，可能是一年就几十万这样的。可能有些线下的活动，这是今年的一个，这个你们有兴趣吗？有的，但我这么说，在市场中资金体量小的，你连打字都不要打字，你们完全不要参加这种东西，你这个太脱离实际了。

我觉得你至少在股市里500万以上，因为的确有一些朋友没办法在线上录制我会把这些也打开，然后给大家再看一看。因为大家到这个时候，其实都有一些互相的诉求。说白了对他们来说挣钱不是什么诉求，更多的去结合一线。因为在转型期大家都能跑得更快一点好吧。然后真的这个东西我可不是那啥，钱不够你们就不要碰这个东西。我估计至少你在股市五百，一年可能至少得二三十甚至更多，好吧？

然后这是第二个。第三个就是人工智能在股市中的一些信息的筛选。其实刚才他们提到了一个很重要的事儿，就对比C上你们去看小作文是非常多的。其实大家5000万个，其实你们去看过去一年我做了很多的事是什么呢？

有点互联网P，你比如说M1除了换了口径怎么样，然后就怎么能够帮助大家更快速的净化资讯，然后找到有用的。其实这些东西你们去用人工智能模型也行，因为我们是我的小兄弟，然后他们也做了好年了，就是基于这个，然后整个的一套这些东西我没有想好，这些东西我要是想好了之后，我会再给大家推的。当然这是其他几个想法，简单一说。

第二个就是可能会加一些课，比如说买方就不加了。但首席比如说下周邓老师，我请邓老师来给大家讲宏观策略。然后去年年底太忙了，还有一些其他的，我可能也要半导体行业等等，今年会很快的假，然后刘老师回来之后也会请刘老师来等等。行，等我看一个什么。我刚才有一个马刺的六个年轻人，不就就是用AI执行效率部，我们的政府也会用AI就是提高商。是的，然后就是还会加一些东西，总之今年就大概这么个想法，我会腾出一些精力来，把更多的一些优质的内容在课里多放一放。大概这种情况，的确春节之后我大家也能看出来，我天天文英搭载都没时间睡觉，就在传这些东西好吧。然后这个课如果不出意外的话，下周四晚上继续。

北朝我实话实说是春节之前太敏感，你们能感觉出来最近流量是在限流吗？我不是不想请北厂，北厂太敏感，你线下拉他见面一点问题都没有，线上太敏感了。我都还来这个直播间的时候，大家放心，就是在互联网尺度这个领域我还是有发言权的，太敏感了，好吧，然后大模型过滤假信息等等等等，有一些想法，然后都在动，今年我们可能会动的更快一些。过去三年我其实还是足够克制的，你要三年就卖两套课能充分体现出我得有多懒。但今年的确会陆陆续续的，不管是从人员储备、知识储备等等的都够了。我可能会做一些动作，到时候我会提前跟大家讲，然后也会有一些视角或者线下等等的情况。

刘玉鹏老师说我肯定会有的，你放心，我数据落地对不？这个想问怎么办？我这么说，人工智能领域现在落地太难了，太难。这是为什么？我想在这边做一做，结果很感谢大家，你们还花着钱来帮我忙，对吧？太难。

如果说真的在咱们直播间里有一些哪怕很简单的企业级和人工智能的应用能够实现的话。我都能想办法帮帮你们双侧。然后在很多地方，不管是在传媒，还是在其他的一些领域，帮你们推广。这个我还是能够注意到太难。你别看这个到这个程度，更多的还是大家深度思考的。你像去去行业的一些形态的，这就是我想在这儿去做点事儿的，这个就是看看吧。但是刚才有朋友说是马斯克使命感，什么信念感？

我就这么讲，不管是人工智能也好，经济体制转型也好，然后复苏也好，中华民族伟大复兴也好。就在面对这种时刻的时候，就这几个事有一点是一样的。你要想在这个过程中这几件事任何一个事情干成，还是的确是有点儿得有点使命感，有点点信念感的这种时候大家刚才有朋友说说今天这个课就是个筛筛选器。是的，其实咱们的用户都非常优秀，尤其是常年的。但是的确这种课的要求会更高一点，就是你得真的有足够的耐心去把那层窗户纸捅破。就在这种转型期，在技术突破期，在经济复苏，在这种变革的时候，就跟你看股市一样。为什么老跟大家讲别折腾，那么多朋友还是瞎折腾，然后还是一不小心怎么怎么地了。就这种时候你能这个时候谁能稳得住，谁能耐住性子，谁能一步一步往前走，谁能真的去把那个双物质同步，其实很多东西是相通的。

我是这么看这个问题的，这种时候是需要有点信念感，需要点使命感的。往往信念和使命感最大的体会，最大的价值就在这种时候体现。你平时看不出来，你有点信念和使命感，别人还说明你傻。那这种时候真正需要定力的时候，需要坚持的时候，需要咬牙的时候，那才是这种时候发挥发光发热的时候。好吧，大概就这样，好吧，其他就这堂课再过去。

这些东西需要录，没关系的，我这么说了，今天晚上这个课听不懂太正常了，听不懂太正常了这很正常。你比如说你们听不懂很多东西，我也听不懂。阿姨们就用小四的话说，大姐阿姨们就注意。当然了你要站在股市角度，我想提醒大家注意一点，你不要觉得人工智能。

说那么简单，我从一开始跟大家讲，我说对不起，这个事出来了之后也没有定论，对吧？我说这个事儿在我来看，第一个就是全民普及，第二个就是给年轻人创造榜样。然后对这个定性来看，第一是个好事，第二个这个都没定论。所以你知道为什么出来之后那么火，我就实在调不起精神头来录个视频，然后讲一讲，然后去蹭流量什么的。你想想我天天周围是这帮人，所以的确阻碍了我挣钱和吸流量了，是吧？

就是对这种事大家一出来之后，相对看的还是比较客观的。这些人的看法跟那些投资圈的还是什么，说实话又是两码事。所以我这人比较精神分裂，这周围都是。所以大家不要老觉得好像这个首席说了一个什么就一定是对的这圈里的可能短时间大家投资上会形成一些共识，但是不是每一个共识都是对的，价值是有共识产生的，但是有的时候价值也会消失吗？那就共识消失。你从技术领域来讲的话，现在应该叫大家速度更快了，更卷了，变化更大了。

那相对来说，哪怕站在投资领域这个方向的投资也会更大。真的是这样的，可能一会儿在哪直播，一会儿想深度参与你说的，但是我资产不够，资产不够，就我这么说，大家别勉强，你们老觉得，小孙你说就刚才我可能说的那个那个线下那个资产不够深度的。这个东西我这么说，你相信我这个东西它肯定有门槛是有道理的。资产不够你们就别放着了别勉强，别勉强别勉强好吧。

理性资产上，象牙塔里的专家到工厂田间看一看，应该象牙塔里的专家到工厂田间专家到工厂田间看一看应该会更好。我们学校的作风还不是象牙塔，这个工厂车间我也没少去，我们学校实习的时候都是这真的是要求还是实干的。说白了行了，今天就这样，我是太累了，我歇一会儿。我看看今天晚上这课说我更烧脑，尤其这种新课，你们让我歇一会儿，今晚上这课基本还可以吧啊啊，基本还可以是吧？辛苦大家了辛苦大家了，现在还有1800多人陪着我在，辛苦了辛苦了，辛苦好吧。然后我看看下周四是不是再试两次，然后我们就开始正常的，有可能就要下一步的这种课的一些动作。

当然如果我真的我非常欢迎的就是如果大家真的是在企业机构需要的话，我希望大家能够形成一个很好定时的互动我觉得这个东西是在未来一段时间里价值特别特别大的，真的特别特别大的，好吧。然后今天课要资产管理，不是，今天课资产管理我是另外一个事，就是今年有几个想法。我的天，这我说话真不清楚吗？大概什么样的？现在千万的10001000个点回撤，500万两个点回撤。不，10003000个点回收，5006000个点回收，大概就这种情况，好吧，这样。

然后最后我请我的小伙伴给大家讲讲新朋友怎么开课提醒。因为今天是买房手机都能听，有些新朋友你们可能开课提醒怎么开等等之类的。是不是今天我个别新朋友第一次听课就赶上这课了，然后问什么都是关心股市的，不知怎么怎么的，是不是有极个别那样？对不起，sorry，这个课主要是给老家伙听的，我真只看钱。爱你们，拜拜。

新百客的需要把这个相关上课提醒开通。一就是开了课之后，首席知圈微信公众号首席知识圈左下方看客中心点开之后，第一个选项我的已购，我的已购点开之后，这里边就是大家购买的课程，就是大家购买的课程。然后点开您购买的课程，把这个橙色的按钮开一下。我刚刚也没开通，然后我点开之后是已开启状态就可以了。然后咱们每次上课的时候，就会在这个微信公众号里边给大家去推送，推送上课时间。什么时候上课，都会提前给提前一天或者两天给大家推送。如果说老师那边已经确定，然后就会在这里边给大家推送。如果说您没开通的话，咱们是没办法去给大家推送的。

还有就是我再强调一点，就是您不管每次开课都是需要去主动的等短信。每次拍课，您拍了月卡之后又拍了年卡，然后年卡也是需要去从重新的去按照短信去操作。如果说你又拍了续卡，还是要再去激活一次，按照短信再去激活一次好吧。如果说您是两套课程都有的话，或者有多套课程的话，都是需要去开通这个上课提醒的，好吧？

一会儿在哪直播？一会儿抖音快手，一会儿抖音快手直播，不一定，不一定。总刚刚说有点累，然后咱们应该四总歇一会儿，咱们会去播一会儿，稍微播一会儿好吧？那咱们就一会儿直播间见，大家也休息一会儿。

拜拜。